

1. ARTICULO 01

Author (s): Gligorea, I.; Cioca, M.; Oancea, R.; Gorski, A.-T.; Gorski, H.; Tudorache, P.

Title of paper: Aprendizaje adaptativo mediante inteligencia artificial en el aprendizaje electrónico: una revisión bibliográfica.

Journal: Education Sciences

Volume (issue): 13(12)

pag – pag (year): 1216–1216 (2023)

Estado del arte que hace el autor

El estado del arte presentado por los autores se centra en la evolución del aprendizaje adaptativo dentro de los entornos de e-learning, destacando el papel fundamental que han adquirido la inteligencia artificial (IA) y el machine learning (ML) en los últimos años. A partir de una revisión sistemática de literatura, se evidencia que la educación digital ha pasado de modelos tradicionales homogéneos hacia enfoques personalizados, donde cada estudiante recibe contenidos ajustados a sus necesidades, ritmo de aprendizaje y características cognitivas. Este cambio responde a la limitación histórica del modelo educativo “one-size-fits-all”, el cual no considera la diversidad de estilos de aprendizaje y genera brechas en el rendimiento académico.

En este contexto, los autores identifican que los sistemas de aprendizaje adaptativo han sido desarrollados gracias a la integración de algoritmos inteligentes capaces de recolectar y analizar grandes volúmenes de datos del estudiante, como su desempeño, interacción con la plataforma, preferencias y progreso. Estas tecnologías permiten construir perfiles dinámicos de aprendizaje y, a partir de ello, ajustar automáticamente el contenido, la dificultad de las actividades y las estrategias pedagógicas. El estado del arte muestra que diversas investigaciones han implementado técnicas como redes neuronales, árboles de decisión, algoritmos de clustering y aprendizaje por refuerzo, los cuales contribuyen a optimizar la experiencia educativa y mejorar los resultados académicos.

Asimismo, se destaca que el uso de IA en e-learning no solo se limita a la personalización de contenidos, sino que también incluye herramientas como sistemas de recomendación, chatbots educativos y analítica de aprendizaje. Estas soluciones permiten brindar retroalimentación en tiempo real, detectar debilidades en el aprendizaje y proponer rutas educativas más eficientes. De acuerdo con la literatura revisada, estas innovaciones han demostrado un impacto positivo en variables clave como el compromiso del estudiante, la retención del conocimiento y el rendimiento académico, consolidando el aprendizaje adaptativo como una de las tendencias más relevantes en la educación digital contemporánea.

Sin embargo, el estado del arte también identifica desafíos importantes. Entre ellos destacan los problemas de privacidad de datos, la complejidad en la implementación de modelos de IA, la necesidad de grandes volúmenes de información para entrenar los algoritmos y el riesgo de depender excesivamente de la tecnología, dejando de lado el rol del docente. Además, se evidencia que aún existe una falta de estandarización en los modelos de aprendizaje adaptativo y una limitada integración en sistemas educativos reales, lo que abre oportunidades para futuras investigaciones.

En síntesis, el estado del arte desarrollado por los autores demuestra que el aprendizaje adaptativo impulsado por IA representa una transformación significativa en el ámbito educativo, pasando de enfoques estáticos a modelos dinámicos, personalizados y basados en datos. No obstante, también resalta la necesidad de seguir investigando para superar las limitaciones actuales y lograr una implementación más eficiente, ética y accesible en distintos contextos educativos.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal del estudio surge de la necesidad de superar las limitaciones identificadas en investigaciones previas sobre e-learning y aprendizaje adaptativo. Los autores señalan que, aunque existe una amplia producción científica en el uso de inteligencia artificial aplicada a la educación, muchos trabajos presentan un enfoque fragmentado, centrándose únicamente en algoritmos específicos o en casos aislados, sin ofrecer una visión integral del impacto real de estas tecnologías en el proceso educativo. Esta falta de sistematización dificulta comprender cómo las diferentes técnicas de IA contribuyen de manera conjunta a la mejora del aprendizaje adaptativo.

Asimismo, critican que gran parte de los estudios revisados se enfoca en el desarrollo técnico de modelos, dejando en segundo plano aspectos pedagógicos clave como la interacción docente–estudiante, el desarrollo de habilidades críticas y la adaptabilidad en contextos educativos reales. En este sentido, evidencian que existe una brecha entre la investigación teórica y la implementación práctica, ya que muchas propuestas no han sido validadas en escenarios educativos amplios o presentan resultados limitados a entornos controlados.

Otra crítica relevante es la escasa atención que se ha dado a los desafíos asociados al uso de IA, especialmente en temas de privacidad de datos, costos de implementación y complejidad de los sistemas. Los autores destacan que algunos estudios tienden a resaltar únicamente los beneficios del aprendizaje adaptativo, sin analizar de manera crítica sus limitaciones o riesgos, lo cual genera una visión incompleta del problema. Además, se menciona la falta de consenso en metodologías y estándares, lo que dificulta comparar resultados entre investigaciones y avanzar hacia soluciones más robustas.

En este contexto, la motivación del artículo radica en realizar una revisión sistemática que permita integrar, organizar y evaluar de manera crítica la literatura existente, proporcionando una base sólida para futuras investigaciones y contribuyendo a un mejor entendimiento del verdadero potencial del aprendizaje adaptativo basado en inteligencia artificial.

Descripción del aporte del autor

El principal aporte del artículo radica en la elaboración de una revisión sistemática integral sobre el uso de la inteligencia artificial (IA) y el machine learning (ML) en el aprendizaje adaptativo dentro de entornos de e-learning. A diferencia de estudios previos que analizan casos aislados o tecnologías específicas, los autores proponen una visión global que permite comprender cómo distintas técnicas de IA se integran para transformar el proceso educativo. Este enfoque proporciona un panorama estructurado y actualizado del estado de la investigación, facilitando la identificación de tendencias, oportunidades y limitaciones en el desarrollo de sistemas educativos inteligentes.

Uno de los aportes más relevantes es la sistematización de 63 artículos científicos seleccionados mediante un proceso riguroso basado en bases de datos reconocidas como Scopus y Web of Science. A partir de esta muestra, los autores logran clasificar y analizar una amplia variedad de algoritmos utilizados en aprendizaje adaptativo, tales como redes neuronales, árboles de decisión, algoritmos genéticos, clustering, aprendizaje por refuerzo y sistemas de recomendación. Esta clasificación no solo permite entender qué tecnologías se están utilizando, sino también cómo se aplican en contextos educativos específicos, evidenciando su rol en la personalización del aprendizaje.

Asimismo, el artículo aporta un análisis detallado de la forma en que estos algoritmos contribuyen a la adaptación del contenido educativo. En particular, se destaca cómo los sistemas basados en IA pueden recolectar datos del estudiante, como su desempeño académico, comportamiento en la plataforma y preferencias de aprendizaje, para generar perfiles

dinámicos. A partir de estos perfiles, los sistemas son capaces de ajustar la dificultad de los contenidos, recomendar recursos específicos y definir rutas de aprendizaje personalizadas. Este aporte es clave, ya que demuestra cómo la tecnología puede replicar, en cierta medida, la atención individualizada que tradicionalmente solo era posible en entornos educativos presenciales.

Otro aporte significativo del estudio es la identificación clara de los beneficios del aprendizaje adaptativo impulsado por IA. Los autores evidencian que estas tecnologías permiten mejorar el rendimiento académico, aumentar el nivel de compromiso de los estudiantes y optimizar la retención del conocimiento. Además, destacan que los sistemas adaptativos facilitan la retroalimentación en tiempo real, lo cual ayuda a los estudiantes a corregir errores de manera inmediata y avanzar de forma más eficiente en su proceso de aprendizaje. Este enfoque orientado a resultados refuerza la importancia de integrar herramientas inteligentes en plataformas educativas modernas.

El artículo también aporta valor al analizar el impacto de estas tecnologías desde una perspectiva multidimensional, considerando no solo los resultados académicos, sino también aspectos como la experiencia del usuario, la motivación y la interacción en entornos virtuales. En este sentido, los autores destacan el uso de herramientas como chatbots, sistemas de recomendación y analítica de aprendizaje, las cuales contribuyen a crear entornos más interactivos y personalizados. Este enfoque integral permite comprender que el aprendizaje adaptativo no es únicamente una cuestión técnica, sino también pedagógica y experiencial.

Además, un aporte importante del trabajo es la formulación de respuestas estructuradas a preguntas de investigación clave (RQ1–RQ5), las cuales abordan aspectos fundamentales como la implementación de algoritmos, los beneficios del aprendizaje adaptativo, los desafíos existentes, su impacto en el desempeño estudiantil y las mejores prácticas para su integración. Esta organización facilita la comprensión del tema y convierte el artículo en una referencia útil tanto para investigadores como para profesionales del ámbito educativo.

Por otro lado, los autores contribuyen al campo al identificar los principales desafíos asociados a la implementación de IA en e-learning. Entre estos destacan la complejidad técnica de los sistemas, la necesidad de grandes volúmenes de datos, los costos de desarrollo y mantenimiento, así como los problemas relacionados con la privacidad y seguridad de la información. Este análisis crítico permite equilibrar la visión optimista sobre la tecnología, mostrando que su adopción requiere un enfoque responsable y bien planificado.

Finalmente, el artículo ofrece recomendaciones y líneas futuras de investigación que constituyen otro aporte relevante. Los autores sugieren la necesidad de desarrollar sistemas más transparentes y explicables, conocidos como “explainable AI”, que permitan a los usuarios comprender cómo se toman las decisiones dentro de los sistemas adaptativos. Asimismo, proponen integrar factores contextuales, como el entorno del estudiante o su estado emocional, para mejorar aún más la personalización del aprendizaje. Estas propuestas abren nuevas oportunidades para el desarrollo de soluciones más avanzadas y centradas en el usuario.

En conjunto, el aporte del artículo se resume en la consolidación de un marco teórico y práctico que permite entender el papel de la inteligencia artificial en la evolución del e-learning. Al integrar evidencia científica, análisis crítico y propuestas de mejora, los autores logran posicionar el aprendizaje adaptativo como una de las principales innovaciones en la educación digital, proporcionando una base sólida para futuras investigaciones y aplicaciones en el ámbito educativo.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para obtener su aporte se basa en una metodología de revisión sistemática de la literatura, diseñada para garantizar rigor científico, objetividad y validez en los resultados obtenidos. En primer lugar, se definió claramente el objetivo de la investigación, el cual consistió en analizar cómo la inteligencia artificial (IA) y el machine learning (ML) están siendo aplicados en el aprendizaje adaptativo dentro de plataformas de e-learning. A partir de este objetivo, se formularon preguntas de investigación específicas (RQ1–RQ5), orientadas a explorar el uso de algoritmos, los beneficios, las limitaciones y el impacto en el desempeño educativo.

Posteriormente, los autores realizaron una búsqueda exhaustiva de información en dos de las bases de datos científicas más importantes: Scopus y Web of Science. Para ello, diseñaron una estrategia de búsqueda basada en palabras clave relacionadas con “adaptive learning”, “artificial intelligence”, “machine learning” y “e-learning”. Esta estrategia permitió identificar inicialmente un total de 698 artículos potencialmente relevantes. Sin embargo, con el fin de asegurar la calidad de la información, se aplicaron criterios de inclusión y exclusión, eliminando duplicados, artículos fuera de contexto, documentos sin acceso completo y aquellos que no estaban enfocados en educación superior o en el uso de IA en aprendizaje adaptativo.

Como resultado de este proceso de filtrado, se redujo la muestra a 537 artículos únicos, los cuales fueron sometidos a una revisión más detallada. En esta etapa, los autores analizaron los resúmenes y textos completos, evaluando aspectos como la metodología empleada, la descripción de los algoritmos y la relevancia del estudio. Finalmente, se seleccionaron 63 artículos que cumplían con todos los criterios establecidos, constituyendo la base del análisis del estudio. Este procedimiento permitió asegurar que el aporte del trabajo se sustente en evidencia científica sólida y representativa del estado actual de la investigación.

Una vez definida la muestra final, los autores procedieron a la extracción y organización de la información relevante. Para ello, diseñaron una estructura de análisis en la que cada artículo fue evaluado según el tipo de algoritmo utilizado, su aplicación en el aprendizaje adaptativo y los resultados obtenidos. Esta sistematización permitió identificar patrones, tendencias y relaciones entre las diferentes técnicas de inteligencia artificial empleadas en e-learning. Asimismo, se utilizó una herramienta colaborativa (Rayyan) para facilitar la clasificación y revisión de los artículos, garantizando un proceso transparente y consensuado entre los investigadores.

En la etapa final, los autores sintetizaron los resultados obtenidos y los organizaron en función de las preguntas de investigación planteadas inicialmente. Esto permitió estructurar el aporte del estudio en torno a cinco ejes principales: la forma en que se implementan los algoritmos de IA en e-learning, los beneficios del aprendizaje adaptativo, los desafíos existentes, el impacto en el rendimiento educativo y las mejores prácticas para su integración. Este enfoque sistemático no solo facilita la comprensión del tema, sino que también aporta claridad y coherencia al análisis.

En conjunto, el proceso seguido por los autores evidencia un enfoque metodológico riguroso, que combina búsqueda exhaustiva, selección crítica y análisis estructurado de la información. Gracias a este procedimiento, el estudio logra ofrecer un aporte sólido y confiable, basado en evidencia científica, que permite comprender de manera integral el papel de la inteligencia artificial en el aprendizaje adaptativo dentro del e-learning.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema del aprendizaje no personalizado en entornos de e-learning se basa en la integración de inteligencia artificial (IA) y machine learning (ML) dentro de sistemas de aprendizaje adaptativo. El problema central identificado es que los modelos tradicionales de educación digital aplican un enfoque homogéneo para todos los estudiantes, sin considerar sus diferencias individuales, lo que limita el rendimiento académico y reduce el nivel de compromiso. Frente a ello, los autores proponen un enfoque basado en datos que permita adaptar el proceso educativo a las necesidades específicas de cada estudiante.

El primer paso en este proceso consiste en la recolección de datos del estudiante dentro de la plataforma de e-learning. Estos datos incluyen información sobre su desempeño en evaluaciones, patrones de interacción, tiempo de dedicación, progreso en los contenidos y preferencias de aprendizaje. Esta etapa es fundamental, ya que constituye la base para comprender el comportamiento del estudiante y detectar sus fortalezas y debilidades. La recopilación puede realizarse en tiempo real o de forma diferida, permitiendo una actualización continua del perfil del usuario.

Una vez obtenidos los datos, el siguiente paso es su análisis mediante algoritmos de inteligencia artificial. En esta fase, se emplean diversas técnicas de machine learning, como redes neuronales, clustering, árboles de decisión o aprendizaje por refuerzo, con el objetivo de identificar patrones y relaciones en la información recolectada. A partir de este análisis, el sistema puede construir modelos de aprendizaje personalizados que representen las características cognitivas, el nivel de conocimiento y el estilo de aprendizaje de cada estudiante.

El tercer paso consiste en la adaptación del contenido educativo. Con base en los modelos generados, el sistema ajusta dinámicamente los materiales de aprendizaje, la dificultad de las actividades, la secuencia de los contenidos y el ritmo de enseñanza. Esto permite que cada estudiante reciba una experiencia educativa personalizada, en la que se priorizan los temas que requieren mayor refuerzo y se optimiza el tiempo de aprendizaje. De esta manera, se busca maximizar la eficiencia del proceso educativo y mejorar los resultados académicos.

Posteriormente, el sistema proporciona retroalimentación en tiempo real, lo cual constituye otro elemento clave del proceso. A través de herramientas como sistemas de recomendación, analítica de aprendizaje y chatbots, los estudiantes reciben orientación inmediata sobre su desempeño, lo que les permite corregir errores, reforzar conocimientos y avanzar de manera más efectiva. Esta interacción continua también contribuye a mantener altos niveles de motivación y compromiso en el entorno virtual.

Finalmente, el proceso se cierra mediante un ciclo de mejora continua, en el cual el sistema sigue recolectando y analizando nuevos datos para actualizar constantemente el perfil del estudiante y optimizar las decisiones pedagógicas. Este enfoque de “bucle cerrado” permite que el aprendizaje adaptativo sea dinámico y evolutivo, ajustándose a medida que el estudiante progresa. En conjunto, este proceso integral permite resolver el problema de la educación uniforme, transformándolo en un modelo personalizado, eficiente y centrado en el estudiante.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En el estudio, los autores no se enfocan en una única métrica experimental propia, sino que analizan diversas métricas utilizadas en los trabajos revisados para evaluar la efectividad del aprendizaje adaptativo basado en inteligencia artificial. Entre las principales métricas identificadas se encuentran el rendimiento académico (medido a través de calificaciones o puntajes en evaluaciones), el nivel de engagement o participación del estudiante, la retención del conocimiento y la tasa de finalización de cursos. Estas variables permiten evaluar de manera integral el impacto de los sistemas adaptativos en el proceso de aprendizaje.

Los resultados obtenidos a partir de la revisión de los 63 artículos muestran una tendencia clara: el uso de algoritmos de IA y ML en e-learning contribuye significativamente a mejorar el desempeño de los estudiantes. En varios estudios analizados, se reporta un incremento en los puntajes de evaluación, así como una mayor permanencia de los estudiantes en las plataformas educativas. Asimismo, se evidencia un aumento en la participación activa, debido a la personalización de contenidos y a la adaptación del ritmo de aprendizaje, lo que genera una experiencia más atractiva y efectiva.

Al comparar estos resultados con enfoques tradicionales de e-learning, los autores concluyen que los sistemas adaptativos presentan ventajas claras. Mientras que los modelos convencionales ofrecen el mismo contenido para todos los estudiantes, los sistemas basados en IA ajustan dinámicamente los recursos educativos, lo que permite atender necesidades individuales y reducir las brechas de aprendizaje. Como consecuencia, los resultados son superiores en términos de rendimiento y motivación, evidenciando que la personalización es un factor clave para mejorar los resultados educativos.

No obstante, los autores también señalan que estos resultados, aunque positivos, dependen en gran medida de la calidad de los datos y de la correcta implementación de los algoritmos. En este sentido, si bien el aprendizaje adaptativo demuestra ser más eficiente que los enfoques tradicionales, su efectividad puede variar según el contexto y el diseño del sistema. Aun así, en términos generales, la evidencia revisada respalda que los resultados obtenidos mediante IA son mejores y más prometedores en comparación con métodos educativos convencionales.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte sólido al analizar el aprendizaje adaptativo basado en inteligencia artificial; sin embargo, desde la perspectiva del proyecto propuesto —*Sistema Inteligente de Nivelación Académica Adaptativa basado en Machine Learning para la reducción de la desigualdad de aprendizaje en estudiantes de la zona VRAEM*— se identifican algunas limitaciones importantes. En primer lugar, el estudio tiene un enfoque principalmente teórico y global, sin considerar contextos específicos de alta vulnerabilidad como el VRAEM, donde existen problemas estructurales como la limitada conectividad, brechas digitales y condiciones socioeconómicas adversas. Esto representa una debilidad, ya que la implementación de sistemas adaptativos en estos entornos requiere soluciones tecnológicas más robustas y adaptadas a la realidad local.

Asimismo, aunque el artículo destaca la personalización del aprendizaje mediante algoritmos de IA, no profundiza en estrategias concretas de nivelación académica para estudiantes con rezagos significativos, que es justamente el problema central en zonas como el VRAEM. La mayoría de los enfoques revisados están orientados a optimizar el aprendizaje en estudiantes con acceso regular a plataformas digitales, dejando de lado poblaciones que presentan dificultades en habilidades básicas como comprensión lectora o razonamiento matemático.

Otra observación relevante es que el artículo no aborda de manera suficiente la inclusión educativa ni la equidad, aspectos fundamentales para reducir la desigualdad en el aprendizaje. Si bien menciona beneficios generales como mejora del rendimiento y engagement, no propone mecanismos específicos para garantizar que estas tecnologías beneficien a estudiantes en contextos rurales o de difícil acceso. En este sentido, el estudio podría fortalecerse incorporando enfoques de educación inclusiva y adaptaciones tecnológicas de bajo costo.

Finalmente, desde una perspectiva crítica, se considera que el artículo ofrece una base conceptual valiosa, pero requiere ser complementado con propuestas aplicadas y contextualizadas. Para el desarrollo del sistema planteado en la zona VRAEM, será necesario integrar no solo algoritmos de machine learning, sino también factores sociales, pedagógicos y tecnológicos propios del entorno, con el fin de lograr una solución realmente efectiva en la reducción de la desigualdad educativa.

- Estado del arte (1 página)
- Motivación del autor (0.5 página)
- Descripción del aporte del autor (2 páginas)
- Proceso para obtener el aporte (1 página)
- Proceso para resolver el problema (1 página)
- Métricas y resultados (0.5 página)
- Observaciones/críticas (0.5 página)

2. ARTICULO 02

Author (s): Jing, Y.; Zhao, L.; Zhu, K.; Wang, H.; Wang, C.; Xia, Q.

Title of paper: Panorama de la investigación sobre el aprendizaje adaptativo en la educación: un estudio bibliométrico de las publicaciones de investigación desde el año 2000 hasta el 2022.

Journal: Sustainability

Volume (issue): 15(4)

pag – pag (year): 3115–3115 (2023)

Estado del arte que hace el autor

El estado del arte desarrollado en el artículo se enfoca en analizar la evolución del aprendizaje adaptativo en educación a lo largo de más de dos décadas (2000–2022), destacando su crecimiento como un campo interdisciplinario impulsado por el avance de tecnologías emergentes como la inteligencia artificial, el big data y el aprendizaje automático. Los autores señalan que el aprendizaje adaptativo se ha consolidado como un enfoque centrado en el estudiante, cuyo objetivo principal es personalizar el proceso educativo en función de las capacidades, necesidades y estilos de aprendizaje individuales, superando así los modelos tradicionales homogéneos.

Históricamente, el concepto de aprendizaje adaptativo tiene sus raíces en sistemas tempranos como las pruebas adaptativas de inteligencia (por ejemplo, el test de Binet en 1905) y las primeras máquinas de enseñanza automatizadas desarrolladas en el siglo XX. Sin embargo, estos sistemas iniciales estaban limitados por la tecnología disponible y se centraban en procesos mecánicos de evaluación. Con el desarrollo de la informática y posteriormente de internet, el aprendizaje adaptativo evolucionó hacia sistemas más complejos, como los entornos hipermedia adaptativos y los sistemas tutoriales inteligentes, los cuales marcaron el inicio de una educación digital más personalizada.

En las últimas décadas, el crecimiento de tecnologías como la inteligencia artificial ha permitido avances significativos en este campo. Plataformas modernas como Knewton, Smart Sparrow y Cerego han demostrado la capacidad de ofrecer contenidos personalizados en tiempo real, ajustando dinámicamente los recursos educativos según el comportamiento del estudiante. Este cambio ha transformado el e-learning tradicional en un modelo más flexible, donde el aprendizaje se adapta al usuario en lugar de que el usuario se adapte al sistema.

El estado del arte también evidencia que la investigación en aprendizaje adaptativo ha crecido de manera acelerada, especialmente a partir de 2018, lo cual refleja un aumento en el interés académico y en la aplicación práctica de estas tecnologías. Según el análisis bibliométrico presentado, este campo ha sido impulsado principalmente por países como China, Estados Unidos e India, así como por disciplinas como la informática, la inteligencia artificial y la tecnología educativa, lo que confirma su carácter interdisciplinario.

Asimismo, los autores identifican cuatro grandes líneas de investigación dentro del aprendizaje adaptativo: el uso de deep learning para el análisis de datos educativos, el desarrollo de modelos adaptativos basados en IA, la implementación de sistemas de tutoría inteligente y el uso de tecnologías avanzadas para el modelado y seguimiento del aprendizaje. Estas áreas reflejan una tendencia hacia el uso de técnicas cada vez más sofisticadas para comprender y mejorar el proceso educativo.

Sin embargo, a pesar de estos avances, el artículo destaca que aún existen limitaciones importantes en el campo. En particular, se señala la falta de análisis sistemáticos y visuales que permitan comprender de manera integral la evolución del aprendizaje adaptativo, así como la dificultad para identificar tendencias claras y áreas prioritarias de investigación. Esta carencia

ha motivado el desarrollo del presente estudio, el cual busca llenar ese vacío mediante un enfoque bibliométrico que permita organizar y analizar el conocimiento existente.

En síntesis, el estado del arte presentado muestra que el aprendizaje adaptativo ha evolucionado desde sistemas básicos de evaluación hasta complejas plataformas inteligentes basadas en datos, consolidándose como una de las principales tendencias en educación moderna. No obstante, también evidencia la necesidad de estudios más integrales que permitan comprender su desarrollo, identificar sus desafíos y orientar futuras investigaciones en este campo en constante crecimiento.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una limitación clara en la literatura previa sobre aprendizaje adaptativo: aunque el tema ha crecido de forma importante en las últimas dos décadas, todavía existen pocos estudios que ofrezcan una visión integral, sistemática y visual de cómo ha evolucionado este campo. Los autores señalan que sí existen investigaciones teóricas y empíricas sobre adaptive learning, así como revisiones relacionadas con tecnología educativa y aprendizaje personalizado, pero consideran que estos trabajos no permiten comprender con suficiente claridad el panorama completo de la investigación, sus tendencias, sus principales actores y sus fronteras emergentes.

Una crítica importante que plantean es que varios estudios previos se han concentrado en aspectos específicos, como el diseño de plataformas, algoritmos, intervenciones pedagógicas o tecnologías concretas, sin desarrollar un análisis profundo del desarrollo global del campo. Esto dificulta identificar cuáles son los temas más trabajados, qué países o autores lideran la investigación y hacia dónde se dirige actualmente el aprendizaje adaptativo. En otras palabras, los autores consideran que faltaba una lectura estructurada del campo que permitiera ordenar el conocimiento ya producido.

Además, el artículo menciona que algunos estudios anteriores, como revisiones sistemáticas sobre aprendizaje personalizado y adaptive learning, cubrieron periodos anteriores y ya no reflejan el crecimiento acelerado que ha tenido el área en los últimos años, especialmente desde 2018. Por ello, los autores critican implícitamente que esos antecedentes resultan insuficientes para explicar el estado actual del tema, sobre todo considerando la influencia reciente de tecnologías como inteligencia artificial, deep learning, big data y sistemas tutoriales inteligentes.

También sostienen que la ausencia de análisis bibliométricos profundos genera dos problemas: primero, dificulta clarificar la estructura del campo y fortalecer su sistema de investigación; segundo, impide que nuevos investigadores puedan reconocer con precisión los focos, avances y tendencias del área. A partir de estas limitaciones, los autores justifican su estudio como una necesidad académica: construir un análisis bibliométrico que permita visualizar con mayor claridad las fuerzas de investigación, los clústeres temáticos, la evolución histórica y las fronteras actuales del aprendizaje adaptativo.

Descripción del aporte del autor

El principal aporte del artículo consiste en ofrecer una visión integral, estructurada y cuantitativa del desarrollo del aprendizaje adaptativo en educación a lo largo del periodo 2000–2022, mediante un enfoque bibliométrico. A diferencia de estudios previos que analizan aspectos específicos del tema, los autores construyen un panorama global que permite comprender cómo ha evolucionado este campo, quiénes son sus principales actores, cuáles son sus líneas de investigación predominantes y hacia dónde se dirige en la actualidad. Este aporte resulta especialmente relevante, ya que organiza el conocimiento existente y facilita su interpretación para investigadores y profesionales del área.

Uno de los aportes más importantes es la recopilación y análisis de un conjunto amplio de datos científicos, específicamente 644 artículos seleccionados de la base de datos Web of Science. A partir de esta muestra, los autores aplican herramientas especializadas como VOSviewer y CiteSpace, las cuales permiten realizar análisis de co-ocurrencia, clustering y evolución temporal. Gracias a este enfoque, el estudio logra transformar grandes volúmenes de información en representaciones visuales y métricas que facilitan la comprensión de las dinámicas del campo. Este proceso aporta rigor metodológico y objetividad al análisis, convirtiendo al estudio en una referencia confiable.

Otro aporte relevante es la identificación de las principales fuerzas de investigación en el campo del aprendizaje adaptativo. Los autores analizan quiénes son los investigadores más influyentes, qué países lideran la producción científica y cuáles son las revistas más importantes. Por ejemplo, se destaca que China lidera la producción académica en este campo, seguida por Estados Unidos e India, lo cual evidencia una concentración geográfica del conocimiento. Asimismo, se identifican autores clave y revistas de alto impacto, lo que permite a futuros investigadores ubicar fuentes relevantes y establecer redes de conocimiento.

El estudio también aporta una clasificación clara de las principales líneas de investigación mediante el análisis de clústeres de palabras clave. En este sentido, los autores identifican cuatro grandes áreas: (1) el uso de deep learning en el análisis de datos educativos, (2) el desarrollo de modelos de aprendizaje adaptativo basados en inteligencia artificial, (3) la implementación de sistemas de tutoría inteligente y (4) el uso de tecnologías avanzadas para el modelado y seguimiento del aprendizaje. Esta clasificación permite comprender la estructura del campo y facilita la identificación de áreas de investigación consolidadas y emergentes.

Asimismo, un aporte significativo del artículo es el análisis de la evolución del aprendizaje adaptativo a lo largo del tiempo. Los autores identifican tres etapas principales: una fase inicial (2000–2007) caracterizada por el surgimiento de conceptos básicos, una fase intermedia (2008–2013) marcada por la incorporación de tecnologías y una fase reciente (2014–2022) dominada por el uso de inteligencia artificial y técnicas avanzadas. Este análisis evolutivo permite entender cómo los avances tecnológicos han influido directamente en el desarrollo del campo, evidenciando que el progreso del aprendizaje adaptativo está estrechamente vinculado a la innovación tecnológica.

Además, el artículo aporta valor al identificar las tendencias y fronteras actuales de investigación mediante el análisis de “burst keywords” o términos emergentes. Entre estos destacan conceptos como deep learning, feature extraction, adaptation model y computational modeling, los cuales representan las áreas más dinámicas y prometedoras del campo. Este aporte es fundamental, ya que permite anticipar hacia dónde se dirige la investigación y qué temas tendrán mayor relevancia en el futuro.

Otro aspecto importante del aporte del estudio es su capacidad para demostrar el carácter interdisciplinario del aprendizaje adaptativo. A lo largo del análisis, se evidencia que este campo integra conocimientos de áreas como la informática, la inteligencia artificial, la psicología y la educación. Esta convergencia de disciplinas permite desarrollar soluciones más completas y efectivas, pero también plantea desafíos en términos de integración de conocimientos y metodologías. Al destacar esta característica, el artículo contribuye a una mejor comprensión de la complejidad del campo.

Finalmente, el artículo aporta una base sólida para futuras investigaciones, ya que no solo describe el estado actual del campo, sino que también identifica vacíos y oportunidades de estudio. Al proporcionar un análisis estructurado de tendencias, actores y temáticas, los autores facilitan la toma de decisiones para nuevos investigadores, quienes pueden orientar sus estudios hacia áreas poco exploradas o en crecimiento. En este sentido, el trabajo no solo tiene valor

descriptivo, sino también estratégico para el desarrollo del conocimiento en aprendizaje adaptativo.

En conjunto, el aporte del artículo se centra en transformar un campo amplio y disperso en un marco organizado, comprensible y basado en evidencia cuantitativa. Gracias a su enfoque bibliométrico, los autores logran consolidar el conocimiento existente, identificar patrones de desarrollo y proponer una visión clara del futuro del aprendizaje adaptativo, convirtiendo este estudio en una referencia clave dentro del área.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para obtener su aporte se basa en una metodología bibliométrica rigurosa, orientada a analizar de manera cuantitativa y visual la evolución del aprendizaje adaptativo en educación. En primer lugar, los autores definieron claramente el objetivo de la investigación, el cual consistía en comprender el panorama general del campo, identificar las principales fuerzas de investigación, analizar los temas predominantes y determinar las tendencias y fronteras actuales. A partir de este objetivo, se formularon preguntas de investigación enfocadas en autores relevantes, países líderes, revistas principales, clústeres temáticos y evolución del área.

El siguiente paso fue la selección de la fuente de datos. Para garantizar la calidad y confiabilidad de la información, los autores eligieron la base de datos Web of Science (WoS), específicamente los índices SCI-Expanded y SSCI, debido a su alto nivel de rigurosidad científica y reconocimiento internacional. Asimismo, se estableció un rango temporal que abarca desde el año 2000 hasta 2022, considerando que a partir del inicio del siglo XXI el aprendizaje adaptativo comienza a desarrollarse de manera sistemática gracias al avance tecnológico.

Posteriormente, se llevó a cabo la fase de recuperación de información mediante el uso de palabras clave relacionadas con “adaptive learning”, “adaptive system” y términos asociados. Esta búsqueda inicial permitió obtener un total de 1610 documentos. Sin embargo, para asegurar la pertinencia de la muestra, los autores aplicaron un proceso de filtrado en varias etapas. En primer lugar, se eliminaron documentos duplicados utilizando herramientas especializadas. Luego, se excluyeron aquellos artículos que no estaban directamente relacionados con el aprendizaje adaptativo en el contexto educativo, así como documentos incompletos o de baja relevancia. Como resultado de este proceso, la muestra final se redujo a 964 artículos, los cuales constituyeron la base del análisis.

Una etapa clave del proceso fue la limpieza y estandarización de los datos. Los autores identificaron que en los registros bibliográficos podían existir inconsistencias, como diferentes formas de escribir un mismo término (por ejemplo, “neural network” y “neural networks”). Para evitar errores en el análisis, se realizó una normalización de los datos, unificando términos y eliminando redundancias. Este paso fue fundamental para garantizar la precisión de los resultados obtenidos en los análisis posteriores.

Una vez preparada la base de datos, los autores procedieron al análisis bibliométrico utilizando herramientas como VOSviewer y CiteSpace. Estas herramientas permitieron realizar distintos tipos de análisis, como la identificación de autores más influyentes, países con mayor producción científica, revistas más relevantes, así como el análisis de co-ocurrencia de palabras clave para identificar clústeres temáticos. Además, se utilizó el análisis de evolución temporal para observar cómo han cambiado las tendencias de investigación a lo largo del tiempo.

Finalmente, los resultados obtenidos fueron organizados e interpretados en función de las preguntas de investigación planteadas inicialmente. Esto permitió estructurar el aporte del estudio en tres dimensiones principales: las fuerzas de investigación (autores, países y revistas), el estado actual del campo (temas y clústeres) y las tendencias futuras (fronteras de

investigación). Gracias a este proceso sistemático, los autores lograron construir un panorama claro, ordenado y fundamentado del aprendizaje adaptativo, consolidando su aporte como una referencia clave para comprender la evolución y proyección de este campo.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema de la falta de una visión integral sobre la investigación en aprendizaje adaptativo se basa en un análisis bibliométrico sistemático. El problema central identificado es que, aunque el aprendizaje adaptativo ha crecido de manera importante en las últimas décadas, no existía una organización clara del conocimiento acumulado que permitiera reconocer sus principales actores, temas de investigación, evolución histórica y tendencias emergentes. Frente a esta situación, los autores proponen un proceso metodológico orientado a recopilar, depurar, analizar y visualizar la producción científica del área, con el fin de construir un panorama estructurado del campo.

El primer paso del proceso consistió en definir con precisión el objeto de estudio y el periodo de análisis. Los autores delimitaron su investigación al aprendizaje adaptativo en educación y establecieron como rango temporal los años 2000 a 2022. Esta delimitación responde a que, si bien el concepto de aprendizaje adaptativo tiene antecedentes anteriores, es a partir del inicio del siglo XXI cuando se desarrolla de manera más sistemática gracias al avance de internet, los sistemas inteligentes y las tecnologías digitales aplicadas a la enseñanza.

El segundo paso fue la recuperación de la información científica. Para ello, se seleccionó la base de datos Web of Science, específicamente los índices SCI-Expanded y SSCI, debido a su alta calidad académica. A partir de una estrategia de búsqueda con términos relacionados con adaptive learning, adaptive system y adaptive learning system, los autores obtuvieron inicialmente 1610 documentos. Esta etapa permitió reunir una base amplia de literatura científica potencialmente relevante para el análisis.

Posteriormente, se realizó un proceso de depuración de la información para asegurar la calidad y pertinencia de los datos. En esta fase, se eliminaron documentos duplicados y luego se aplicaron criterios de inclusión y exclusión para descartar artículos que no estuvieran realmente enfocados en aprendizaje adaptativo en contextos educativos. También se excluyeron trabajos incompletos o con información insuficiente. Como resultado de esta depuración, la muestra quedó conformada por 964 artículos válidos para el estudio. Este filtrado fue clave para resolver el problema de dispersión e imprecisión de la información disponible.

El siguiente paso fue la normalización de los datos. Los autores detectaron que en la base de información había términos repetidos o expresados de distintas maneras, lo cual podía afectar los resultados del análisis bibliométrico. Para solucionarlo, unificaron palabras clave equivalentes y limpiaron la base de datos mediante procesos automáticos y revisión manual. Esta etapa permitió construir un conjunto de datos más coherente y confiable para las siguientes fases del estudio.

Después, los autores aplicaron herramientas especializadas de análisis bibliométrico, principalmente VOSviewer y CiteSpace. Con estos programas pudieron examinar autores más influyentes, países con mayor producción, revistas principales, co-ocurrencia de palabras clave, clústeres temáticos y evolución temporal del campo. Gracias a este análisis, lograron identificar cuatro grandes temas de investigación y también las fronteras actuales del aprendizaje adaptativo, como deep learning, feature extraction, adaptation model y computational modeling.

Finalmente, el problema se resuelve mediante la organización e interpretación de todos estos hallazgos en una estructura clara. Los autores presentan un mapa del campo que permite entender cómo ha evolucionado el aprendizaje adaptativo, cuáles son sus núcleos temáticos y

qué direcciones está tomando la investigación reciente. En conjunto, este proceso transforma un panorama disperso de publicaciones en un conocimiento ordenado y útil para orientar futuras investigaciones y aplicaciones educativas.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, las métricas utilizadas por los autores son principalmente bibliométricas, ya que el estudio no evalúa directamente el rendimiento de estudiantes en una plataforma, sino la evolución de la investigación sobre aprendizaje adaptativo. Entre las métricas más importantes se encuentran el **número de publicaciones por año**, el **número de citas**, el **promedio de citas por artículo**, la **cantidad de documentos por autor**, la **producción por país**, la **cantidad de artículos por revista**, la **frecuencia de palabras clave**, la **co-ocurrencia de términos** y la **detección de burst keywords** o palabras clave emergentes. Estas métricas permiten medir la productividad científica, el impacto académico y las tendencias de desarrollo del campo.

A partir de estas métricas, los autores obtienen varios resultados relevantes. Primero, identifican que la investigación sobre aprendizaje adaptativo presenta un crecimiento notable, especialmente desde 2018, alcanzando uno de sus picos más altos en 2021. Segundo, encuentran que **China** es el país con mayor número de publicaciones, seguida de **Estados Unidos** e **India**. Tercero, identifican a autores influyentes como **Qiao J. F.**, **Han H. G.** y **Song Q.**, y revistas destacadas como **IEEE Transactions on Neural Networks and Learning Systems**. Además, el análisis de palabras clave y clústeres revela cuatro grandes líneas temáticas del campo, mientras que los términos emergentes muestran que las nuevas fronteras de investigación se concentran en **deep learning**, **feature extraction**, **adaptation model** y **computational modeling**.

En comparación con otros trabajos, los resultados de este artículo pueden considerarse mejores en cuanto a amplitud, organización y capacidad explicativa, porque no se limitan a describir un solo sistema o una experiencia puntual, sino que presentan una visión global del campo durante más de veinte años. Mientras otras investigaciones revisan casos concretos o periodos más reducidos, este estudio ofrece una comprensión más completa del desarrollo del aprendizaje adaptativo, permitiendo identificar tendencias, actores y vacíos de investigación con mayor claridad. Por ello, su aporte resulta más sólido como referencia general para futuros estudios, aunque no debe entenderse como “mejor” en términos experimentales, sino más bien como superior en alcance analítico y valor para mapear el estado de la investigación.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte valioso porque organiza de manera clara la evolución del aprendizaje adaptativo entre 2000 y 2022, permitiendo identificar autores, países, revistas y líneas temáticas dominantes. Una de sus principales fortalezas es el uso del análisis bibliométrico, ya que ofrece una visión amplia y estructurada del campo, algo muy útil para quienes recién se incorporan a esta línea de investigación. Además, el estudio logra demostrar que el aprendizaje adaptativo se ha consolidado como un tema interdisciplinario, vinculado tanto a la educación como a la inteligencia artificial, lo cual le da relevancia académica y proyección futura.

Sin embargo, una primera observación crítica es que el estudio se centra exclusivamente en la base de datos Web of Science. Aunque esta fuente es rigurosa y de alta calidad, limitar la búsqueda solo a esta base puede dejar fuera publicaciones relevantes indexadas en Scopus, ERIC u otras fuentes especializadas en educación. Esto reduce en cierta medida la amplitud del panorama presentado, especialmente en un campo tan dinámico e interdisciplinario como el aprendizaje adaptativo.

Otra crítica importante es que el artículo privilegia el análisis cuantitativo de publicaciones, citas y palabras clave, pero profundiza poco en la calidad pedagógica de las investigaciones revisadas. Es decir, muestra qué se ha investigado y cómo ha evolucionado el tema, pero no analiza con suficiente detalle si las propuestas de aprendizaje adaptativo realmente han sido efectivas en contextos educativos reales, ni qué impacto concreto han tenido en poblaciones vulnerables o con brechas de aprendizaje.

Asimismo, aunque identifica tendencias actuales como deep learning, feature extraction y computational modeling, el artículo mantiene un enfoque muy orientado a la tecnología. Desde una perspectiva educativa, hubiera sido valioso que se profundizara más en temas como inclusión, equidad, acompañamiento docente y adaptación a contextos con limitaciones de conectividad. Esto es especialmente importante si se piensa en aplicar el aprendizaje adaptativo en realidades como zonas rurales o socialmente vulnerables.

En síntesis, se trata de un artículo sólido y útil como mapa general del campo, pero su enfoque bibliométrico y tecnológico hace que todavía sea necesario complementarlo con estudios más aplicados, pedagógicos y contextualizados, para comprender mejor cómo el aprendizaje adaptativo puede responder a problemas reales de desigualdad educativa.

3. ARTICULO 03

Author (s): Bayounes, W.; Bayoudh Saâdi, I.; Kinshuk

Title of paper: Aprendizaje adaptativo: hacia un modelo intencional para la orientación del proceso de aprendizaje basado en la motivación del alumno.

Journal: Entornos de aprendizaje inteligentes

Volume (issue): 9(1)

pag – pag (year): 33–33 (2022)

Estado del arte que hace el autor

El estado del arte presentado por los autores se centra en el problema de la adaptación del proceso de aprendizaje dentro de los sistemas tutores inteligentes (ITS), especialmente cuando se busca que dicha adaptación responda no solo a necesidades cognitivas, sino también al nivel de motivación del estudiante. Desde el inicio del artículo, se reconoce que en los últimos años se ha intensificado la investigación sobre el desafío de la adaptación en los ITS, debido a la necesidad de generar procesos de aprendizaje más apropiados para cada individuo. En este contexto, la finalidad general de esta evolución ha sido ofrecer al estudiante un aprendizaje más cómodo, pertinente y personalizado, es decir, presentar el contenido adecuado, de la forma adecuada y en el momento adecuado.

Los autores señalan que, aunque ya existen diversas definiciones y propuestas sobre aprendizaje adaptativo en la literatura, la mayoría se ha concentrado en el modelado táctico del proceso, sin prestar suficiente atención a la estructura intencional del aprendizaje. En otras palabras, muchos trabajos previos entienden el proceso de aprendizaje como una simple secuencia de fases o actividades, pero sin considerar de manera rigurosa los diferentes objetivos que deben alcanzarse ni las distintas estrategias que pueden utilizarse para lograrlos. Esta observación es importante porque evidencia que, en el estado actual del campo, todavía predominan enfoques lineales o rígidos, con poca flexibilidad para responder a situaciones reales de aprendizaje.

Otro aspecto clave del estado del arte es la incorporación del concepto de motivación como una variable central del aprendizaje adaptativo. Los autores revisan distintas definiciones teóricas de motivación y muestran que esta puede entenderse como la fuerza que impulsa la conducta, orienta el esfuerzo y sostiene la acción hacia una meta. Asimismo, recogen aportes que distinguen entre motivación intrínseca y extrínseca, destacando que ambas influyen en el comportamiento del estudiante dentro del proceso de aprendizaje. El artículo subraya que la motivación no puede considerarse un elemento secundario, ya que afecta directamente la participación, el compromiso y la continuidad del estudiante tanto en contextos presenciales como en entornos virtuales.

Dentro de esta revisión, los autores destacan especialmente el modelo ARCS de John Keller como uno de los marcos más efectivos para abordar la motivación en contextos de aprendizaje adaptativo. Este modelo organiza la motivación en cuatro dimensiones: atención, relevancia, confianza y satisfacción. Según los autores, varias investigaciones recientes sostienen que el modelo ARCS ofrece una base útil, sistemática y aplicable para diseñar experiencias de aprendizaje más motivadoras, sobre todo en e-learning, donde sostener el interés del estudiante resulta más difícil que en la enseñanza presencial. Por ello, consideran que este modelo constituye una base teórica adecuada para orientar la adaptación del proceso de aprendizaje dentro de un ITS.

Además, el estado del arte revisa estudios que muestran que la motivación del estudiante es compleja, multifacética y dependiente del contexto. No basta con conocer las preferencias del alumno o su estilo de aprendizaje; también es necesario comprender su disposición, su confianza, su interés y las recompensas que percibe en la experiencia de aprendizaje. En ese sentido, el artículo remarca que antes de determinar el método o la estrategia de enseñanza más adecuada, conviene identificar primero el nivel motivacional del estudiante. Esta idea

representa una crítica implícita a muchos sistemas adaptativos previos, que se enfocaban en contenidos o estilos cognitivos, pero no en el estado motivacional del aprendiz.

Finalmente, el estado del arte también muestra la evolución de investigaciones previas del propio grupo autoral, orientadas a la ingeniería de procesos de aprendizaje apoyados por sistemas adaptativos. Sobre esa base, el artículo plantea que todavía existe la necesidad de un modelo más flexible e intencional que permita guiar la progresión del aprendizaje considerando simultáneamente la intención del estudiante, las estrategias pedagógicas, su estilo de aprendizaje y su motivación. En síntesis, el estado del arte evidencia que el campo ha avanzado en personalización y adaptación, pero aún presenta vacíos en la integración entre proceso, intención y motivación, vacío que el presente trabajo busca atender.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores nace de una limitación que identifican en muchos estudios previos sobre aprendizaje adaptativo e intelligent tutoring systems (ITS): aunque la literatura ha avanzado bastante en la adaptación del contenido y en la personalización del aprendizaje, todavía no se ha resuelto adecuadamente el problema de cómo guiar el proceso de aprendizaje considerando de manera conjunta los objetivos del estudiante, las estrategias pedagógicas y su motivación. Los autores señalan que gran parte de los trabajos revisados se enfoca sobre todo en el modelado táctico del proceso, es decir, en describir fases o secuencias de actividades, pero sin respetar claramente los distintos objetivos que deben alcanzarse ni las diversas estrategias que pueden aplicarse para lograrlos.

Otra crítica importante que plantean es que muchos estudios no consideran de forma suficiente las necesidades individuales del estudiante ni su estado motivacional. En particular, sostienen que la motivación del aprendiz sigue estando poco integrada en los modelos de guía del aprendizaje, a pesar de ser un factor decisivo para sostener la participación, la energía y la orientación hacia la meta. Desde esta perspectiva, los autores consideran insuficientes los enfoques que adaptan únicamente contenidos o actividades, pero no toman en cuenta si el estudiante mantiene atención, percibe relevancia, desarrolla confianza o experimenta satisfacción durante el proceso.

Además, los autores critican implícitamente la rigidez de varios modelos existentes. Según el artículo, muchos enfoques previos representan el aprendizaje como un conjunto fijo de fases, lo que reduce la flexibilidad necesaria para adaptarse a situaciones reales y cambiantes. Frente a ello, proponen adoptar el concepto de proceso intencional, que permite modelar el aprendizaje a partir de intenciones y múltiples estrategias posibles, en lugar de asumir una única secuencia lineal. De esta manera, buscan superar los límites de los modelos tradicionales y ofrecer una guía más variable y flexible dentro de los ITS.

También se apoyan en estudios recientes que consideran al modelo ARCS como uno de los marcos más eficaces para enfrentar el reto del aprendizaje adaptativo, especialmente en contextos de e-learning, donde motivar al estudiante resulta más difícil que en la educación presencial. Por ello, la motivación del artículo no solo es teórica, sino también práctica: diseñar un modelo de guía del aprendizaje que incorpore de forma explícita la motivación del estudiante y permita que el ITS seleccione estrategias más adecuadas según su estilo, modo de aprendizaje e intención educativa.

Descripción del aporte del autor

El principal aporte del artículo radica en la propuesta de un modelo intencional para la guía del proceso de aprendizaje dentro de sistemas tutores inteligentes (ITS), integrando de manera explícita la motivación del estudiante como un elemento central en la adaptación del aprendizaje. A diferencia de enfoques tradicionales que se limitan a adaptar contenidos o

secuencias de actividades, los autores introducen una perspectiva estratégica e intencional, donde el proceso educativo se organiza en función de los objetivos del estudiante, sus preferencias, su estilo de aprendizaje y su estado motivacional. Este enfoque representa una contribución significativa, ya que permite avanzar hacia sistemas más flexibles, personalizados y centrados en el aprendiz.

Uno de los aportes más importantes es la incorporación del concepto de “proceso intencional” para modelar el aprendizaje. En este modelo, el aprendizaje no se entiende como una secuencia fija de pasos, sino como un conjunto dinámico de intenciones que el estudiante busca alcanzar. Cada intención representa un objetivo específico dentro del proceso educativo y puede ser alcanzada mediante distintas estrategias. Esta visión permite introducir variabilidad y flexibilidad en el aprendizaje, ya que el sistema puede seleccionar diferentes caminos para lograr un mismo objetivo, adaptándose a las características individuales del estudiante.

Asimismo, el artículo aporta un modelo estructurado del proceso de aprendizaje basado en cuatro tipos principales de intenciones: explorar, reflexionar, involucrarse (engage) y elaborar. Estas intenciones representan diferentes etapas cognitivas del aprendizaje y permiten organizar la progresión del estudiante de manera coherente. Cada una de estas etapas puede ser alcanzada mediante diversas estrategias pedagógicas, lo que otorga al sistema la capacidad de adaptarse a múltiples escenarios de aprendizaje. En la *Figura 1 del artículo (página 6)* se observa el modelo del proceso de aprendizaje, donde se visualizan las conexiones entre estas intenciones y las posibles rutas que puede seguir el estudiante, evidenciando la naturaleza no lineal del modelo.

Otro aporte fundamental es la integración del modelo ARCS de motivación dentro del sistema de aprendizaje adaptativo. Los autores incorporan las cuatro dimensiones del modelo (atención, relevancia, confianza y satisfacción) como factores clave para guiar la selección de estrategias de aprendizaje. Esto permite que el sistema no solo considere aspectos cognitivos, sino también emocionales y motivacionales, mejorando así la experiencia del estudiante. De esta manera, el modelo logra una adaptación más completa, ya que responde tanto a lo que el estudiante necesita aprender como a su disposición para hacerlo.

Además, el artículo introduce un mecanismo innovador de selección de estrategias basado en diferentes tipos de argumentos: lógicos, cuasi-lógicos y retóricos. Los argumentos lógicos se relacionan con el modo de aprendizaje del estudiante (como acumulación, estructuración o ajuste), los cuasi-lógicos se vinculan con la motivación (según el modelo ARCS) y los retóricos se basan en el estilo de aprendizaje del estudiante (según el modelo Felder-Silverman). Esta combinación de factores permite tomar decisiones más precisas y personalizadas al momento de guiar el aprendizaje, constituyendo un aporte metodológico importante.

El modelo también se apoya en el uso del formalismo Map, una herramienta que permite representar procesos como un conjunto de intenciones y estrategias interconectadas. Este formalismo facilita la construcción de múltiples rutas de aprendizaje, permitiendo que el sistema seleccione la más adecuada según las características del estudiante. Gracias a este enfoque, el modelo logra superar la rigidez de los sistemas tradicionales y ofrece una estructura más adaptable y dinámica.

Otro aporte relevante es la definición de guías de selección, como las *Intention Selection Guidelines (ISG)* y las *Strategy Selection Guidelines (SSG)*, las cuales permiten determinar qué intención o estrategia debe seguir el estudiante en cada momento del proceso. Estas guías consideran variables como la motivación, el estilo de aprendizaje y el modo de aprendizaje, lo que garantiza una adaptación continua y coherente. En las *Figuras 2 y 3 del artículo (páginas 8 y 9)* se muestran ejemplos de estas guías, donde se evidencia cómo el sistema toma decisiones en función de diferentes criterios, reforzando la capacidad adaptativa del modelo.

Finalmente, el artículo aporta evidencia empírica a través de una experimentación realizada con estudiantes universitarios. Los resultados muestran que el modelo propuesto presenta niveles de utilidad mayormente valorados como “frecuente” o “siempre”, con una media de 2.33 en una escala de 0 a 4. Esto sugiere que el modelo tiene un impacto positivo en la experiencia de aprendizaje, aunque los autores reconocen que se trata de resultados preliminares y que se requieren más estudios para validar su efectividad en distintos contextos.

En conjunto, el aporte del artículo se centra en la construcción de un modelo innovador que integra intención, estrategia y motivación en un mismo sistema de aprendizaje adaptativo. Este enfoque no solo mejora la personalización del aprendizaje, sino que también ofrece una base teórica y metodológica sólida para el desarrollo de futuros sistemas educativos inteligentes, posicionándose como una contribución relevante dentro del campo de los ITS y el e-learning.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en un enfoque metodológico teórico–conceptual complementado con validación experimental. En primer lugar, los autores parten de una revisión crítica de la literatura existente sobre aprendizaje adaptativo y sistemas tutores inteligentes (ITS), identificando las principales limitaciones de los enfoques tradicionales, especialmente la falta de integración entre la estructura del proceso de aprendizaje, las estrategias pedagógicas y la motivación del estudiante. Esta fase inicial les permite justificar la necesidad de un modelo más flexible e intencional que supere la visión lineal del aprendizaje.

El siguiente paso consiste en la definición del marco conceptual del modelo propuesto. Para ello, los autores integran diferentes teorías y enfoques existentes. En primer lugar, adoptan el concepto de proceso intencional, el cual permite modelar el aprendizaje en función de objetivos que el estudiante desea alcanzar. En segundo lugar, incorporan el modelo ARCS de motivación como base teórica para representar el estado motivacional del estudiante a través de cuatro dimensiones: atención, relevancia, confianza y satisfacción. Finalmente, integran el modelo de estilos de aprendizaje de Felder-Silverman y los modos de aprendizaje definidos por teorías cognitivas, con el fin de enriquecer el proceso de adaptación.

Posteriormente, los autores desarrollan la estructura del modelo de aprendizaje. En esta etapa, definen los cuatro tipos de intenciones que guían el proceso (explorar, reflexionar, involucrarse y elaborar), así como las diferentes estrategias que permiten alcanzar cada una de estas intenciones. Además, establecen una clasificación de estrategias basada en dimensiones cognitivas, metacognitivas, sociales y afectivas, lo que permite ampliar las posibilidades de adaptación del sistema. Este diseño estructural constituye el núcleo del aporte, ya que organiza el aprendizaje de forma flexible y no lineal.

Una etapa clave del proceso es la formalización del modelo mediante el uso del formalismo Map, el cual permite representar el proceso de aprendizaje como un conjunto de intenciones conectadas por múltiples estrategias. Gracias a este enfoque, los autores logran definir rutas alternativas de aprendizaje, en lugar de imponer una única secuencia. Además, introducen mecanismos de decisión basados en diferentes tipos de argumentos (lógicos, cuasi-lógicos y retóricos), que combinan factores como el modo de aprendizaje, la motivación y el estilo del estudiante para seleccionar la mejor estrategia en cada caso.

A continuación, los autores diseñan guías específicas para la toma de decisiones dentro del sistema, como las Intention Selection Guidelines (ISG) y las Strategy Selection Guidelines (SSG). Estas guías permiten determinar de manera dinámica qué intención debe alcanzarse a continuación y qué estrategia debe aplicarse, considerando el estado del estudiante. Este paso

es fundamental para convertir el modelo teórico en una herramienta aplicable dentro de un sistema tutor inteligente.

Finalmente, el proceso se completa con una validación experimental del modelo. Para ello, los autores aplican su propuesta en un entorno educativo real con estudiantes universitarios, evaluando la utilidad del modelo a través de encuestas y análisis de resultados. Según los datos presentados en la *Tabla 1 (página 10)*, la mayoría de los procesos de aprendizaje fueron valorados como “frecuentes” o “siempre” útiles, lo que evidencia una aceptación positiva del modelo. Aunque los resultados son preliminares, esta fase experimental permite verificar la viabilidad del aporte y sustentar su relevancia práctica.

En conjunto, el proceso seguido por los autores combina análisis teórico, integración de modelos existentes, diseño estructurado, formalización técnica y validación empírica. Gracias a este enfoque, logran construir un aporte sólido que no solo propone un nuevo modelo de aprendizaje adaptativo, sino que también demuestra su aplicabilidad en contextos reales de educación.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema de la guía del aprendizaje en sistemas tutores inteligentes parte del reconocimiento de una dificultad central: muchos sistemas adaptativos no logran orientar de manera adecuada el proceso de aprendizaje porque no integran suficientemente los objetivos del estudiante, sus estrategias de aprendizaje y su motivación. Frente a ello, los autores diseñan un procedimiento que busca construir una guía más flexible, personalizada e intencional, capaz de adaptar el recorrido formativo a las características individuales del aprendiz.

El primer paso del proceso consiste en redefinir la manera en que se entiende el aprendizaje dentro del sistema. En lugar de asumir que aprender significa seguir una secuencia fija de actividades, los autores proponen considerarlo como un proceso intencional, es decir, como un conjunto de acciones orientadas al cumplimiento de propósitos concretos. Bajo esta lógica, el aprendizaje deja de ser lineal y pasa a organizarse en función de intenciones que el estudiante debe alcanzar. Esta redefinición es fundamental porque permite que el sistema pueda ofrecer distintas rutas para llegar a un mismo objetivo, aumentando la flexibilidad de la guía pedagógica.

El segundo paso es la identificación de los elementos que deben intervenir en esa guía adaptativa. Para resolver el problema, los autores consideran que no basta con conocer el contenido a enseñar, sino que también es necesario incorporar el estado motivacional del estudiante, su estilo de aprendizaje y su modo de aprender. Por esta razón, integran el modelo ARCS de motivación, que contempla atención, relevancia, confianza y satisfacción, junto con el modelo de estilos de aprendizaje de Felder-Silverman y los modos de aprendizaje basados en acumulación, estructuración y ajuste. Esta combinación permite que la guía del aprendizaje responda de forma más precisa a las características del estudiante.

A partir de ello, el tercer paso consiste en estructurar el proceso de aprendizaje en torno a cuatro grandes intenciones: explorar, reflexionar, involucrarse y elaborar. Estas intenciones representan las metas pedagógicas que el estudiante debe alcanzar durante su progresión. Para cada intención, el modelo contempla varias estrategias posibles, tales como practicar, analizar y razonar, cooperar con otros o planificar el propio aprendizaje. De este modo, el sistema no impone una única estrategia, sino que puede seleccionar la más adecuada según el perfil del estudiante. En la *Figura 1 del artículo (página 6)* se observa precisamente esta estructura flexible del proceso, donde una intención puede conectarse con varias alternativas estratégicas.

El cuarto paso es la formalización de estas decisiones mediante guías de selección. Los autores diseñan dos tipos principales: las guías de selección de intención (ISG), que ayudan a decidir cuál debe ser la siguiente intención a trabajar, y las guías de selección de estrategia (SSG), que determinan qué estrategia concreta debe usarse para alcanzar esa intención. Estas decisiones se toman considerando distintos argumentos: lógicos, cuasi-lógicos y retóricos. Los lógicos están ligados al modo de aprendizaje, los cuasi-lógicos a la motivación, y los retóricos al estilo de aprendizaje. Gracias a esta combinación, el sistema puede tomar decisiones más contextualizadas y adaptadas. Las *Figuras 2 y 3 (páginas 8 y 9)* muestran ejemplos concretos de estas guías y cómo se seleccionan rutas en función de diferentes criterios.

Finalmente, el proceso para resolver el problema se valida mediante una experimentación con estudiantes universitarios en un curso sobre certificación MOS Word 2016. Los estudiantes siguieron procesos de aprendizaje definidos según su motivación y estilo, y luego evaluaron la utilidad del modelo. Los resultados muestran que la mayoría de los procesos fueron considerados útiles con frecuencia, lo que sugiere que la propuesta responde adecuadamente al problema identificado. Aunque los autores reconocen que se trata de resultados iniciales y que aún se requieren más experimentos, el proceso ya demuestra ser una vía viable para mejorar la guía adaptativa del aprendizaje en entornos ITS.

En conjunto, el proceso de solución se basa en pasar de una visión rígida del aprendizaje a una visión intencional, adaptable y motivacionalmente informada, donde el sistema orienta al estudiante mediante distintas rutas posibles, seleccionadas según sus características individuales.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, las métricas utilizadas por los autores se centran en la **utilidad percibida** del modelo propuesto durante su aplicación en un entorno real de aprendizaje. Para evaluar ello, los estudiantes calificaron cada sección del proceso de aprendizaje mediante una **escala de Likert de cinco niveles**, donde 0 significaba “never”, 1 “rarely”, 2 “sometimes”, 3 “often” y 4 “always”. A partir de estas respuestas, los autores analizaron indicadores como el **overall usefulness** de cada proceso, el **número de secciones** por proceso y la distribución de secciones según los niveles de utilidad. Además, calcularon la **media general de utilidad** y la **desviación estándar**, lo que permitió tener una medida cuantitativa del desempeño del modelo.

Los resultados obtenidos muestran una valoración mayormente positiva del modelo intencional propuesto. Según la **Tabla 1 del artículo (página 10)**, el **50% de los procesos de aprendizaje** fueron evaluados con un nivel de utilidad de “often”, el **20%** alcanzó el nivel “always” y el **30%** obtuvo “sometimes”. En términos globales, la **media de utilidad fue 2.33**, correspondiente al nivel “often”, con una **desviación estándar de 0.79**, lo que indica una aceptación moderadamente alta del modelo. Además, los autores señalan que en la mayoría de los procesos las secciones no fueron valoradas como “rarely”, y que alrededor del **50% de las secciones** fueron calificadas como “often” o “always”, lo cual refuerza la percepción positiva sobre la guía del aprendizaje basada en motivación.

Al comentar estos resultados, puede decirse que son favorables porque muestran que el modelo logra orientar el aprendizaje de manera útil para la mayoría de estudiantes, especialmente considerando que integra motivación, estilo de aprendizaje e intención pedagógica en un mismo sistema. Sin embargo, los propios autores son prudentes y no afirman que sus resultados sean definitivamente superiores a otros modelos, ya que reconocen limitaciones como el tamaño reducido de la muestra, la corta duración de la experimentación y el hecho de haberse aplicado solo en un curso específico. Por ello, más que afirmar que los resultados son “mejores” que otros de forma concluyente, lo correcto es comentar que los hallazgos son **prometedores** y muestran una ventaja conceptual importante frente a enfoques más rígidos, porque evidencian

que considerar la motivación del estudiante puede mejorar la utilidad percibida del proceso de aprendizaje adaptativo.

Observaciones y/o críticas suyas al artículo

El artículo presenta un aporte interesante al proponer un modelo intencional de aprendizaje adaptativo que incorpora la motivación del estudiante dentro de los sistemas tutores inteligentes. Una de sus principales fortalezas es que no se limita a adaptar contenidos, sino que intenta guiar el proceso de aprendizaje considerando la intención del alumno, sus estrategias de aprendizaje y su estado motivacional. Esto le da un valor importante, porque ofrece una visión más humana y flexible del aprendizaje adaptativo. Además, el uso del modelo ARCS como base motivacional resulta adecuado, ya que permite estructurar la adaptación en torno a dimensiones claras como atención, relevancia, confianza y satisfacción.

Sin embargo, una primera crítica es que la validación experimental del modelo todavía es limitada. El estudio se aplicó con una muestra pequeña de estudiantes, en un solo contexto universitario y durante un tiempo corto, lo que reduce la posibilidad de generalizar los resultados. Aunque los autores reportan valoraciones positivas sobre la utilidad del modelo, estos resultados siguen siendo preliminares y no permiten afirmar con plena seguridad que el modelo sea superior a otros enfoques de aprendizaje adaptativo.

Otra observación importante es que el modelo depende de cuestionarios explícitos para identificar el estilo de aprendizaje y el estado motivacional del estudiante. Esto puede convertirse en una limitación práctica, ya que exige tiempo adicional, esfuerzo del alumno y respuestas sinceras para que la adaptación funcione correctamente. Si esos datos no se recogen con precisión, la recomendación del sistema podría no corresponder a la situación real del aprendiz. Los propios autores reconocen esta dificultad como una de las principales restricciones del modelo.

Además, aunque el artículo tiene una base conceptual sólida, su enfoque sigue siendo bastante teórico y técnico. Se explica bien la estructura del modelo, pero se profundiza menos en el impacto pedagógico real que podría tener en contextos más diversos, como educación escolar, entornos rurales o estudiantes con mayores brechas de aprendizaje. Desde esa perspectiva, sería valioso que futuras investigaciones prueben el modelo en escenarios más amplios y con poblaciones distintas.

En síntesis, se trata de un artículo valioso por su innovación conceptual y por integrar la motivación en la guía adaptativa del aprendizaje, pero todavía necesita más evidencia empírica y mayor validación práctica para consolidarse como una propuesta aplicable a gran escala.

4. ARTICULO 04

Author (s): Contrino, M. F.; Reyes-Millán, M.; Vázquez-Villegas, P.; Membrillo-Hernández, J.

Title of paper: Utilizar una herramienta de aprendizaje adaptativo para mejorar el rendimiento y la satisfacción de los estudiantes en la educación en línea y presencial, con el fin de lograr un enfoque más personalizado.

Journal: Entornos de aprendizaje inteligentes

Volume (issue): 11(6)

pag – pag (year): 1–24 (2024)

Estado del arte que hace el autor

El estado del arte presentado por los autores se enmarca en la necesidad creciente de ofrecer una educación más personalizada, partiendo de la idea de que no todos los estudiantes requieren la misma forma de enseñanza. En este contexto, el artículo sitúa el aprendizaje adaptativo como una de las estrategias más importantes dentro del aprendizaje personalizado, ya que permite ajustar objetivos, secuencia de contenidos, ritmo e instrucción de acuerdo con las necesidades específicas del estudiante. Los autores señalan que el avance tecnológico actual ha abierto la posibilidad de construir trayectorias de aprendizaje personalizadas, donde el estudiante no sigue necesariamente un único camino fijo, sino que puede avanzar de acuerdo con su comprensión, desempeño y necesidades particulares.

Dentro de este panorama, el artículo reconoce que el aprendizaje adaptativo no es un concepto completamente nuevo, pero sí uno que continúa evolucionando y cuya definición sigue siendo compleja. Los autores retoman posturas previas que entienden el aprendizaje adaptativo tanto como un proceso, centrado en cómo se presentan los contenidos y cómo estos se modifican en función del progreso del estudiante, como una estrategia apoyada en dispositivos, software y recursos tecnológicos que permiten registrar datos del aprendizaje para ajustar la instrucción. Desde esta perspectiva, el aprendizaje adaptativo se basa en conocer el nivel previo del estudiante, monitorear sus resultados y utilizar esa información para ofrecer una experiencia más adecuada y efectiva.

El estado del arte también muestra que la incorporación de sistemas adaptativos en instituciones educativas ha tenido propósitos diversos. En algunos casos, estas herramientas se emplean para tareas, ejercicios o reforzamiento del contenido durante el curso; en otros, funcionan como mecanismos de remediación para estudiantes que necesitan fortalecer conocimientos previos. A partir de estas experiencias, la literatura ha comenzado a estudiar el impacto del aprendizaje adaptativo en variables como resultados de aprendizaje, compromiso académico, retención y satisfacción estudiantil. Es decir, el campo ya no se enfoca solo en el diseño tecnológico, sino también en su efecto real dentro del aula y en modalidades virtuales.

Los autores revisan varios antecedentes empíricos relevantes. Por ejemplo, mencionan estudios en universidades donde los estudiantes valoraron positivamente los entornos flexibles con adaptive learning, señalando mayor efectividad educativa, flexibilidad y fortalecimiento en la adquisición del conocimiento. También se citan investigaciones donde la adaptación de materiales al nivel de dominio del estudiante incrementó su engagement con el curso. Asimismo, se presentan antecedentes en programas de farmacia, álgebra, biología, trigonometría y precálculo, donde el uso de aprendizaje adaptativo mostró mejoras en ciertos contenidos, en tasas de aprobación o en reducción de abandono, aunque no siempre con resultados uniformes en todas las disciplinas. Esto permite observar que la evidencia disponible es prometedora, pero todavía heterogénea.

Otro elemento importante del estado del arte es el reconocimiento explícito de una brecha de investigación. Los autores sostienen que, aunque existen estudios sobre adaptive learning, la evidencia cuantitativa en educación superior todavía sigue evolucionando. En particular, destacan que faltan investigaciones que demuestren diferencias en calificaciones y satisfacción cuando se utilizan estrategias adaptativas integradas y contextualizadas dentro del diseño

completo de un curso universitario. Esta observación es central, porque indica que el problema no es únicamente si la tecnología adaptativa funciona, sino cómo se integra pedagógicamente dentro de una asignatura real y qué impacto tiene según la modalidad de enseñanza.

Además, el artículo incorpora un marco teórico que fortalece el estado del arte. Los autores explican que la teoría del aprendizaje adaptativo defiende una enseñanza ajustada al estilo y necesidades de cada estudiante mediante decisiones basadas en datos. También señalan que, según marcos recientes, la tecnología digital crea entornos de aprendizaje inteligentes, flexibles y personalizados que pueden mejorar el rendimiento. A ello se suma la importancia del ambiente educativo, ya sea online o presencial, como factor que puede influir en la relación entre tecnología adaptativa y desempeño del estudiante. Por eso, el estado del arte no solo presenta antecedentes tecnológicos, sino también fundamentos conceptuales sobre personalización, rendimiento y satisfacción.

En síntesis, el estado del arte elaborado por los autores muestra que el aprendizaje adaptativo se ha consolidado como una estrategia valiosa dentro de la educación personalizada, con evidencia creciente de beneficios en aprendizaje, participación y satisfacción. Sin embargo, también deja claro que en el nivel universitario aún se requieren más estudios cuantitativos y contextualizados que permitan medir con mayor precisión su efecto en cursos concretos y comparar su impacto entre modalidades online y presenciales. Precisamente desde esa necesidad se justifica el desarrollo del estudio.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores parte de una observación clara: aunque el aprendizaje adaptativo ha ganado presencia en los últimos años como estrategia para personalizar la educación, la investigación sobre su impacto en la educación superior todavía es insuficiente y sigue en desarrollo. Los autores reconocen que existen antecedentes valiosos sobre adaptive learning en distintos contextos, pero consideran que aún no se cuenta con suficiente evidencia cuantitativa que permita demostrar con claridad sus efectos sobre variables concretas como las calificaciones y la satisfacción de los estudiantes cuando esta estrategia se integra de manera estructurada y contextualizada dentro de un curso universitario.

Una crítica importante que plantean es que gran parte de los estudios previos se ha enfocado en describir el uso del aprendizaje adaptativo como herramienta de apoyo, remediación o acompañamiento, pero no siempre como una estrategia plenamente integrada en la secuencia didáctica del curso. Esto significa que muchas investigaciones analizan el adaptive learning de forma parcial, sin considerar cómo influye cuando forma parte del diseño instruccional completo, articulado con actividades, evaluaciones, analíticas y decisiones pedagógicas del docente. Desde la perspectiva de los autores, esta es una limitación relevante porque impide comprender el verdadero alcance del aprendizaje adaptativo en escenarios universitarios reales.

Además, los autores observan que los resultados previos no son completamente consistentes. Algunos trabajos muestran mejoras en engagement, tasas de aprobación o adquisición de conocimientos, mientras que otros reportan efectos limitados o incluso ausencia de ganancias claras en aprendizaje. Esta variabilidad en los hallazgos sugiere que todavía no existe una conclusión sólida y definitiva sobre el impacto del aprendizaje adaptativo en todos los contextos, lo cual refuerza la necesidad de continuar investigando. En ese sentido, el artículo se motiva por la necesidad de aportar evidencia empírica más concreta y comparativa, especialmente en cursos universitarios STEM y en modalidades de enseñanza distintas.

Otra crítica implícita es que muchos estudios no comparan adecuadamente el efecto del aprendizaje adaptativo entre modalidades educativas diferentes, como la enseñanza online y la enseñanza presencial. Los autores consideran que esta comparación es necesaria porque el entorno de aprendizaje puede influir en la efectividad de la tecnología adaptativa. Por ello, su

motivación también consiste en analizar no solo si el adaptive learning mejora el rendimiento, sino en qué modalidad lo hace con mayor impacto y cómo afecta la satisfacción del estudiante. A partir de estas limitaciones detectadas en la literatura, justifican su investigación como un aporte orientado a cerrar esa brecha de evidencia en educación superior.

Descripción del aporte del autor

El principal aporte del artículo consiste en demostrar, con evidencia cuantitativa y en un contexto universitario real, que la incorporación de una herramienta de aprendizaje adaptativo puede mejorar tanto el rendimiento académico como la satisfacción de los estudiantes en cursos impartidos en modalidad online y presencial. A diferencia de otros trabajos que se centran principalmente en discutir el potencial del aprendizaje adaptativo desde una perspectiva teórica o exploratoria, este estudio ofrece una evaluación concreta de su implementación dentro de un curso universitario de estadística para la toma de decisiones, una asignatura considerada compleja para estudiantes de primeros semestres. De este modo, el artículo aporta no solo una reflexión conceptual, sino también resultados empíricos aplicados a la educación superior.

Uno de los aportes más importantes es la integración de una estrategia de aprendizaje adaptativo dentro de un modelo educativo innovador denominado FIT (flexible, interactive, and with technology), que combina el uso de CANVAS como plataforma de gestión del aprendizaje y Zoom como medio de interacción sincrónica con los estudiantes. En este contexto, los autores muestran que el aprendizaje adaptativo no se incorpora como un recurso aislado, sino como parte de una secuencia didáctica completa, diseñada para acompañar al estudiante antes, durante y después de la clase. Esta integración es valiosa porque permite entender el aprendizaje adaptativo como una estrategia pedagógica articulada, y no solamente como una herramienta tecnológica complementaria. En la *Figura 1 del artículo (página 7)* se presenta esta secuencia didáctica, donde se observa claramente cómo el estudiante revisa recursos y cuestionarios antes de clase, el docente analiza las analíticas del sistema para planificar la sesión, y durante la clase se desarrollan actividades activas de aplicación, análisis y síntesis.

Otro aporte central del estudio es la implementación concreta de la plataforma CogBooks como herramienta de aprendizaje adaptativo. Los autores no se limitan a usarla de forma estándar, sino que adaptan internamente su diseño didáctico para responder a las necesidades del curso. El sistema organiza el contenido jerárquicamente por temas y conceptos, ofrece materiales base y recursos de reforzamiento alternativos, incorpora autoevaluación del grado de comprensión por parte del estudiante y presenta cuestionarios automatizados con retroalimentación inmediata. Esta estructura permite construir una experiencia personalizada, donde cada estudiante puede recibir apoyos distintos según su nivel de entendimiento. En las *Figuras 2, 3, 4 y 5 del artículo (páginas 7, 8 y 9)* se observa el funcionamiento de la plataforma, desde la navegación por módulos hasta la evaluación de comprensión y los cuestionarios adaptativos.

Asimismo, el artículo aporta una propuesta de personalización basada en decisiones pedagógicas concretas del docente a partir de los datos generados por el sistema adaptativo. El instructor revisa antes de cada sesión las analíticas de progreso y comprensión obtenidas en CogBooks, y con base en ello ajusta la clase para enfocarse en los temas donde los estudiantes presentan mayores dificultades. Esto significa que el aporte del estudio no se reduce a la adaptación automática realizada por la plataforma, sino que incluye una dimensión docente muy importante: la utilización de datos del aprendizaje para rediseñar la enseñanza presencial o sincrónica. En la *Tabla 4 del artículo (página 11)* se muestran incluso escenarios específicos para la preparación de la clase, según el número de estudiantes que no han comprendido un tema, lo que evidencia una aplicación pedagógica concreta del aprendizaje adaptativo.

El estudio también aporta evidencia comparativa entre distintas modalidades de enseñanza. Los autores analizan, en primer lugar, el efecto del aprendizaje adaptativo en cursos FIT con y sin adaptive learning; y, en segundo lugar, comparan cursos con adaptive learning en modalidad

online y en modalidad presencial. Esta doble comparación resulta especialmente valiosa porque permite responder no solo si el aprendizaje adaptativo mejora el desempeño, sino también en qué contexto educativo parece tener mayor efecto. Los resultados muestran que el adaptive learning mejora el logro estudiantil independientemente de la modalidad, pero que los estudiantes obtienen mejores resultados en cursos presenciales con aprendizaje adaptativo que en cursos online con la misma estrategia. Este hallazgo constituye un aporte importante para la toma de decisiones institucionales sobre cómo y dónde implementar este tipo de tecnologías.

Otro aporte destacado del artículo es el uso de indicadores académicos y de satisfacción para evaluar la efectividad de la estrategia. Los autores no se limitan a una percepción subjetiva, sino que analizan exámenes parciales, exámenes finales, calificaciones finales, porcentaje de aprobación y porcentaje de estudiantes con calificaciones superiores a 90. Además, complementan este análisis con resultados de encuestas de satisfacción estudiantil (SOS), lo que permite valorar tanto el rendimiento como la experiencia de aprendizaje. Este enfoque integral fortalece el estudio, pues muestra que el aprendizaje adaptativo no solo puede influir en resultados medibles, sino también en cómo los estudiantes perciben la calidad de la enseñanza.

En términos institucionales, el artículo aporta una experiencia de innovación educativa desarrollada dentro del Tecnológico de Monterrey, en el marco del modelo Tec21. Esto le da al estudio un valor aplicado importante, porque demuestra cómo una universidad puede rediseñar un curso problemático mediante adaptive learning para enfrentar bajos desempeños, reforzar conocimientos previos y mejorar la comprensión de contenidos abstractos. El artículo muestra así que el aprendizaje adaptativo puede ser una estrategia viable para fortalecer cursos universitarios de alta complejidad, especialmente en áreas STEM o cuantitativas.

Finalmente, el trabajo aporta una conclusión relevante para la investigación en educación superior: el aprendizaje adaptativo debe entenderse como una estrategia sólida para la enseñanza universitaria, siempre que vaya acompañado de rediseño instruccional, capacitación docente y uso inteligente de analíticas de aprendizaje. Esta idea es importante porque desplaza la discusión desde la simple adopción de una herramienta tecnológica hacia la necesidad de construir entornos de aprendizaje personalizados, integrados y pedagógicamente coherentes. En conjunto, el artículo ofrece un aporte práctico, metodológico y empírico que fortalece la comprensión del papel del aprendizaje adaptativo en la educación superior contemporánea.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para obtener su aporte se basa en un enfoque aplicado y experimental, desarrollado en un contexto real de educación superior. En primer lugar, los autores parten de la identificación de un problema concreto: el bajo rendimiento académico y las dificultades de aprendizaje en cursos de estadística para estudiantes universitarios, especialmente en los primeros semestres. A partir de este diagnóstico, se plantea la necesidad de incorporar estrategias innovadoras que permitan mejorar la comprensión de los contenidos y fortalecer el desempeño estudiantil, lo cual conduce a la integración del aprendizaje adaptativo como solución potencial.

El siguiente paso consiste en el diseño del entorno educativo donde se implementará la propuesta. Para ello, los autores utilizan el modelo educativo FIT (flexible, interactive, and with technology), el cual combina herramientas digitales y metodologías activas de aprendizaje. Dentro de este entorno, se integran plataformas como CANVAS para la gestión del curso, Zoom para la interacción sincrónica y CogBooks como sistema de aprendizaje adaptativo. Esta fase es clave, ya que permite estructurar un ecosistema educativo donde la tecnología no funciona de manera aislada, sino como parte de una estrategia pedagógica integral.

Posteriormente, los autores desarrollan la estructura didáctica del curso incorporando el aprendizaje adaptativo. En esta etapa, organizan los contenidos en módulos jerárquicos y diseñan actividades que permiten al estudiante avanzar de manera personalizada. El sistema adaptativo incluye materiales base, recursos de reforzamiento, autoevaluaciones de comprensión y cuestionarios automatizados con retroalimentación inmediata. Además, se establece un ciclo de aprendizaje en tres momentos: antes de la clase (preparación autónoma del estudiante con la plataforma), durante la clase (actividades interactivas guiadas por el docente) y después de la clase (refuerzo y consolidación del aprendizaje). Este diseño permite integrar la personalización con la enseñanza activa.

Una etapa fundamental del proceso es la recolección y análisis de datos generados por el sistema adaptativo. A través de CogBooks, se obtienen analíticas sobre el progreso del estudiante, su nivel de comprensión y las dificultades en determinados temas. Estos datos son utilizados por el docente para ajustar la planificación de cada sesión, enfocándose en los contenidos donde los estudiantes presentan mayores problemas. De esta manera, el aprendizaje adaptativo no solo se basa en la automatización del sistema, sino también en la toma de decisiones pedagógicas informadas por datos.

Luego, los autores implementan el curso en diferentes grupos de estudiantes, lo que les permite comparar escenarios con y sin aprendizaje adaptativo, así como modalidades online y presenciales. Durante esta fase, se recopilan datos sobre el desempeño académico de los estudiantes, incluyendo exámenes parciales, finales, calificaciones globales, tasas de aprobación y niveles de logro. Asimismo, se recogen datos de percepción mediante encuestas de satisfacción estudiantil (SOS), lo que permite evaluar no solo el rendimiento, sino también la experiencia del estudiante.

Finalmente, los autores analizan e interpretan los resultados obtenidos para determinar el impacto del aprendizaje adaptativo en el proceso educativo. A partir de este análisis, logran demostrar que la integración de esta estrategia mejora tanto el desempeño académico como la satisfacción de los estudiantes, especialmente cuando se implementa en modalidad presencial. Este conjunto de evidencias permite consolidar el aporte del estudio, mostrando que el aprendizaje adaptativo, cuando se integra adecuadamente en el diseño del curso, constituye una herramienta efectiva para mejorar la enseñanza universitaria.

En conjunto, el proceso seguido por los autores combina diagnóstico del problema, diseño pedagógico, implementación tecnológica, análisis de datos y evaluación de resultados. Gracias a este enfoque integral, el estudio logra generar un aporte sólido, basado en evidencia empírica, que demuestra el valor del aprendizaje adaptativo en contextos reales de educación superior.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema del bajo rendimiento académico y las dificultades de aprendizaje en cursos universitarios, especialmente en estadística, se basa en la integración del aprendizaje adaptativo dentro de un modelo pedagógico estructurado. El problema central identificado es que los estudiantes presentan debilidades en conocimientos previos, baja comprensión de contenidos abstractos y dificultades para seguir el ritmo de la clase, lo cual se traduce en bajos resultados académicos. Frente a ello, los autores proponen un proceso que combina tecnología, analítica de datos y rediseño didáctico para ofrecer una experiencia de aprendizaje más personalizada y efectiva.

El primer paso del proceso consiste en rediseñar el curso bajo el modelo FIT (flexible, interactive, and with technology), el cual busca integrar herramientas digitales con metodologías activas. Este rediseño permite organizar el aprendizaje en tres momentos clave: antes, durante y después de la clase. En la fase previa, los estudiantes interactúan con la

plataforma adaptativa (CogBooks), revisando contenidos y realizando actividades que les permiten identificar su nivel de comprensión. Este paso es fundamental, ya que permite que cada estudiante llegue a la clase con un conocimiento previo más homogéneo.

El segundo paso es la personalización del aprendizaje mediante el sistema adaptativo. A través de CogBooks, los contenidos se organizan en módulos jerárquicos que incluyen materiales base, recursos de refuerzo y cuestionarios automatizados. El sistema recoge información sobre el desempeño del estudiante y ajusta el contenido en función de sus respuestas, ofreciendo explicaciones adicionales o actividades de práctica cuando detecta dificultades. De esta manera, cada estudiante sigue un recorrido de aprendizaje distinto, acorde a sus necesidades, lo que permite reducir las brechas de conocimiento dentro del grupo.

El tercer paso es la utilización de analíticas de aprendizaje para la toma de decisiones pedagógicas. Antes de cada sesión, el docente revisa los datos generados por la plataforma, identificando los temas donde los estudiantes presentan mayor dificultad. Con base en esta información, ajusta la planificación de la clase, enfocándose en reforzar esos contenidos mediante actividades interactivas, discusión de casos y ejercicios aplicados. Esto permite que la clase presencial o sincrónica sea más eficiente, ya que se adapta a las necesidades reales del grupo y no a una planificación rígida.

El cuarto paso consiste en el desarrollo de actividades activas durante la clase. En esta etapa, el docente guía a los estudiantes en la aplicación de los conceptos aprendidos, promoviendo el análisis, la resolución de problemas y el trabajo colaborativo. Esta fase es importante porque complementa la personalización tecnológica con interacción humana, fortaleciendo el aprendizaje significativo. Posteriormente, en la fase posterior a la clase, los estudiantes continúan utilizando la plataforma adaptativa para reforzar conocimientos y consolidar lo aprendido.

Finalmente, el proceso se cierra con la evaluación de resultados, donde se analizan indicadores como calificaciones, tasas de aprobación y niveles de satisfacción estudiantil. Los resultados obtenidos muestran mejoras en el rendimiento académico y en la percepción del curso por parte de los estudiantes, lo que indica que el proceso propuesto logra resolver, en gran medida, el problema inicial. Además, los autores evidencian que el impacto del aprendizaje adaptativo es positivo tanto en modalidad online como presencial, aunque con mejores resultados en esta última.

En conjunto, el proceso de solución se basa en transformar un modelo tradicional de enseñanza en un sistema adaptativo, donde el aprendizaje se personaliza mediante tecnología, se optimiza con datos y se refuerza con estrategias pedagógicas activas. Gracias a esta integración, se logra mejorar el desempeño académico y reducir las dificultades de aprendizaje en cursos universitarios complejos.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, los autores utilizan métricas académicas y de satisfacción para evaluar el impacto del aprendizaje adaptativo. En cuanto al rendimiento, analizan principalmente las **calificaciones del examen parcial (midterm exam), examen final, nota final del curso, porcentaje de estudiantes aprobados y porcentaje de estudiantes con calificaciones mayores a 90**. Además, para asegurar rigurosidad estadística, aplican pruebas como **Shapiro-Wilk** para verificar la normalidad de los datos, y luego emplean **t de Student** y **Mann-Whitney U** para comparar promedios entre grupos. También evalúan la confiabilidad de la calificación final mediante **Alpha de Cronbach**, obteniendo valores de **0.779, 0.7694 y 0.8190**, lo cual indica una consistencia alta de las evaluaciones.

Respecto a los resultados, cuando se compararon cursos FIT sin aprendizaje adaptativo con cursos FIT + AL, los estudiantes con AL obtuvieron mejores promedios en el **midterm exam** (63.9 vs 59.3), en el **final exam** (80.6 vs 61.4) y en la **calificación final** (80.3 vs 79.9). Aunque el porcentaje de aprobación fue ligeramente menor en FIT + AL (89.2%) que en FIT sin AL (97%), los autores explican que esto se debió a que en los cursos con AL las actividades en la plataforma eran obligatorias y afectaban la nota final. Aun así, el porcentaje de estudiantes con calificaciones superiores a 90 fue claramente mayor en FIT + AL (24.3%) que en FIT sin AL (15.2%), lo que sugiere una mejora en la calidad del desempeño.

Cuando los autores compararon cursos con AL en modalidad online (FIT + AL) y presencial (classroom + AL), encontraron que el aprendizaje adaptativo funcionó en ambas modalidades, pero con mejores resultados en la modalidad presencial. En el semestre enero-mayo, por ejemplo, el promedio del **final exam** y de la **nota final** fue más alto en presencial + AL (70.4 y 83.7) que en FIT + AL (59.8 y 77.3). En agosto-diciembre también ocurrió lo mismo: el promedio de **midterm exam**, **final exam** y **nota final** fue superior en presencial + AL (62.8, 77.9 y 84.2) frente a FIT + AL (57.5, 71.4 y 80.8). Además, el porcentaje de aprobados y de notas mayores a 90 también fue más alto en presencial + AL.

Al comentar estos hallazgos, se puede afirmar que los resultados son mejores que los de enfoques sin aprendizaje adaptativo, especialmente porque muestran mejoras claras en exámenes, nota final y estudiantes de alto rendimiento. Sin embargo, frente a otras modalidades con AL, los mejores resultados se obtienen en el entorno presencial, lo que indica que la tecnología adaptativa funciona mejor cuando se complementa con una interacción más cercana con el docente. Por tanto, el estudio demuestra que el aprendizaje adaptativo sí mejora el rendimiento, pero su impacto depende también del contexto en que se aplica.

Observaciones y/o críticas suyas al artículo

El artículo presenta un aporte valioso porque no se limita a discutir el aprendizaje adaptativo en términos teóricos, sino que lo aplica en un curso universitario real y evalúa su impacto con datos concretos de rendimiento y satisfacción. Una de sus mayores fortalezas es que integra el adaptive learning dentro de una secuencia didáctica completa, combinando plataforma tecnológica, analíticas de aprendizaje y ajustes pedagógicos del docente. Además, el estudio tiene valor práctico porque compara distintas modalidades de enseñanza, lo que permite observar que el aprendizaje adaptativo puede funcionar tanto en entornos online como presenciales.

Sin embargo, una primera observación crítica es que los resultados no son totalmente uniformes. Aunque los cursos con adaptive learning muestran mejoras en exámenes y en el porcentaje de estudiantes con notas altas, en una de las comparaciones el porcentaje de aprobación fue menor que en los cursos FIT sin AL. Los autores explican esto por el carácter obligatorio de las actividades en la plataforma, pero esta situación también sugiere que la incorporación de una herramienta adaptativa no garantiza automáticamente mejores resultados para todos los estudiantes, especialmente si no completan las actividades requeridas.

Otra crítica importante es que el estudio se desarrolla en un solo curso, dentro de una sola institución y en un contexto muy específico. Esto limita la posibilidad de generalizar sus hallazgos a otras disciplinas, universidades o niveles educativos. Aunque los resultados son prometedores, todavía no se puede afirmar que el mismo efecto se replicará en contextos distintos sin nuevas investigaciones. Del mismo modo, el uso de una herramienta específica como CogBooks hace que parte de los hallazgos dependan también de las características particulares de esa plataforma.

Además, aunque el artículo analiza rendimiento y satisfacción, podría profundizar más en variables pedagógicas como la autonomía real del estudiante, la calidad de la retroalimentación

o las diferencias entre tipos de estudiantes. También sería interesante explorar con más detalle por qué el adaptive learning resultó más efectivo en la modalidad presencial que en la modalidad online, ya que esto podría aportar información importante para mejorar futuras implementaciones.

En síntesis, se trata de un artículo sólido, bien estructurado y con evidencia relevante para educación superior, pero todavía necesita ampliarse a más contextos, cursos y perfiles estudiantiles para consolidar sus conclusiones. Aun así, ofrece una base muy útil para comprender cómo el aprendizaje adaptativo puede mejorar la enseñanza universitaria cuando se integra pedagógicamente de forma adecuada.

5. ARTICULO 05

Author (s): Rincon-Flores, E. G.; Castano, L.; Guerrero Solis, S. L.; Olmos Lopez, O.; Rodríguez Hernández, C. F.; Castillo Lara, L. A.; Aldape Valdés, L. P.

Title of paper: Mejorar el proceso de enseñanza-aprendizaje mediante una estrategia de aprendizaje adaptativo.

Journal: *Smart Learning Environments*

Volume (issue): 11(27)

pag – pag (year): 1–27 (2024)

Estado del arte que hace el autor

El estado del arte presentado por los autores se desarrolla en torno a la necesidad de mejorar el proceso de enseñanza-aprendizaje mediante estrategias de aprendizaje adaptativo que no dependan únicamente de la plataforma tecnológica, sino de una integración didáctica más amplia. Desde el inicio, el artículo reconoce que el desarrollo acelerado de la tecnología en las últimas décadas ha generado múltiples propuestas para elevar la calidad educativa, entre ellas las plataformas de Adaptive Learning (AL), las cuales utilizan datos, algoritmos, evaluaciones y retroalimentación para ajustar contenidos y secuencias según el progreso del estudiante. Estas plataformas permiten una aplicación masiva de la personalización, ahorrando tiempo al docente y ofreciendo rutas individualizadas que serían muy difíciles de construir manualmente.

Los autores sitúan el aprendizaje adaptativo dentro del marco más amplio del aprendizaje personalizado. En este sentido, explican que la personalización del aprendizaje funciona como un concepto paraguas que engloba diversos enfoques, como la enseñanza diferenciada, los modelos tutoriales, el aprendizaje basado en competencias y el propio aprendizaje adaptativo. A partir de diferentes aportes teóricos, el artículo resalta que la comunidad educativa ha buscado sistemas capaces de ajustar pedagogía, currículo y ambiente de aprendizaje según las necesidades, fortalezas, habilidades e intereses de cada estudiante. Bajo esta lógica, el aprendizaje adaptativo se presenta como una estrategia específica que, apoyada en analítica de datos, permite construir trayectorias personalizadas para favorecer el dominio progresivo de los contenidos.

Dentro del estado del arte, los autores revisan distintas definiciones de Adaptive Learning. Señalan que este implica adaptar el proceso de aprendizaje a las necesidades, competencias y capacidades del estudiante, promoviendo no solo la adquisición de información según diferencias cognitivas, sino también el aprendizaje activo y la autorregulación. Los antecedentes revisados muestran que el AL respeta el conocimiento previo del estudiante, responde a sus necesidades y reduce vacíos de comprensión al asegurar que cada alumno alcance cierto nivel de dominio antes de avanzar. Al mismo tiempo, la literatura reporta beneficios para el docente, quien puede monitorear mejor las áreas problemáticas y detectar con mayor anticipación a estudiantes en riesgo de fracaso o deserción. Sin embargo, también se reconoce que para obtener estos beneficios los profesores deben saber utilizar correctamente estos sistemas y acompañarlos con decisiones pedagógicas adecuadas.

Otro aspecto central del estado del arte es que el artículo no reduce el aprendizaje adaptativo al uso de una plataforma, sino que lo articula con otras estrategias didácticas. En particular, revisa la relación entre AL, flipped classroom, self-regulated learning y microlearning. Respecto al flipped classroom, los autores destacan estudios que señalan que invertir la clase permite optimizar el tiempo presencial, promover el aprendizaje activo y asegurar una educación más personalizada. En este modelo, el estudiante revisa contenidos antes de la sesión y en clase participa en actividades de mayor complejidad cognitiva. Sobre self-regulated learning, se enfatiza que la autorregulación implica que el estudiante planifique, monitoree y evalúe su propio aprendizaje, rasgo que se vincula estrechamente con la lógica del adaptive learning, donde el alumno avanza según su propio ritmo y necesidades. Finalmente, el microlearning

aparece como una estrategia complementaria, basada en contenidos breves, graduales, autocontenidos y de rápida consulta, que ayuda a reducir la carga cognitiva y facilita trayectorias de aprendizaje más personalizadas.

Además, el estado del arte incluye una revisión de diferentes modalidades de aplicación del aprendizaje adaptativo en educación superior, especialmente en ingeniería. Los autores distinguen una primera línea basada en plataformas comerciales que utilizan analítica de desempeño para recomendar contenidos y rutas de aprendizaje personalizadas. En esta línea mencionan experiencias con plataformas como Smart Sparrow, ALEKS y Knewton, orientadas a adaptar contenidos según los resultados diagnósticos y el progreso del estudiante. Una segunda línea corresponde a procesos “facilitator-driven”, donde la adaptación no recae exclusivamente en la plataforma, sino en las acciones del profesor apoyadas por dashboards, indicadores y registros de desempeño. En esta modalidad, la evidencia sugiere que los docentes pueden personalizar mejor la enseñanza a partir de pronósticos y analíticas basadas incluso en algoritmos como Random Forest. También se mencionan desarrollos más avanzados apoyados en biometría y neurocognición, así como plataformas expertas que generan rutas adaptativas a partir de árboles de decisión.

A pesar de todos estos avances, los autores subrayan que aún es necesario no solo medir el impacto del aprendizaje adaptativo en el proceso de enseñanza-aprendizaje, sino también identificar cuáles son los elementos clave de un modelo efectivo de implementación. Esta idea es central en su estado del arte: no basta con tener una plataforma adaptativa, sino que se requiere una estrategia didáctica integral que incluya diseño de contenidos, monitoreo docente, actividades antes, durante y después de clase, y una adecuada articulación con metodologías activas. En síntesis, el estado del arte muestra que el aprendizaje adaptativo es un campo en expansión, con bases sólidas en la personalización y en el uso de analítica, pero que alcanza mejores resultados cuando se integra con otras estrategias pedagógicas y con un modelo de implementación cuidadosamente diseñado.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una pregunta crítica que aparece desde el resumen del artículo: aunque se ha escrito mucho sobre aprendizaje adaptativo, ¿su implementación por sí sola garantiza el éxito? A partir de esta inquietud, los autores cuestionan implícitamente enfoques previos que han puesto el énfasis casi exclusivamente en la plataforma o en la tecnología adaptativa, sin considerar que el verdadero impacto educativo depende también de cómo esta se integra con estrategias didácticas concretas. En otras palabras, el artículo nace de la necesidad de superar una visión reducida del Adaptive Learning como simple herramienta tecnológica y avanzar hacia una estrategia integral de enseñanza-aprendizaje.

Una crítica importante que plantean es que, aunque muchos educadores reconocen las ventajas del aprendizaje adaptativo, la evidencia empírica sigue siendo limitada porque el campo aún está evolucionando. Los autores retoman la idea de que existen múltiples plataformas y modelos de personalización, pero no siempre queda claro cuáles producen una experiencia de aprendizaje realmente exitosa ni qué condiciones pedagógicas deben acompañarlas. Esta observación sugiere que parte de la literatura previa se ha concentrado en describir plataformas, algoritmos o sistemas adaptativos, pero no necesariamente en evaluar de manera suficiente el impacto de una estrategia adaptativa completa sobre el aprendizaje, el logro de competencias y la experiencia de estudiantes y profesores.

Asimismo, los autores critican implícitamente la idea de que la adaptación puede delegarse por completo a la tecnología. En el estado del arte revisado, muestran que algunos modelos dependen casi exclusivamente de contenidos adaptativos automáticos o de recomendaciones generadas por algoritmos. Sin embargo, el artículo sostiene que esto no basta, porque el rol del

profesor sigue siendo decisivo. De hecho, señalan que para que el aprendizaje adaptativo sea eficiente, el docente debe saber interpretar las analíticas, hacer intervenciones oportunas y articular la plataforma con otras metodologías. Esta postura cuestiona trabajos donde la tecnología aparece como solución autosuficiente y reivindica una visión donde el profesor pasa de ser transmisor de contenido a facilitador y diseñador de experiencias de aprendizaje.

Otra crítica del artículo es que no basta con medir si una plataforma adapta contenidos; también es necesario identificar los elementos didácticos que hacen exitosa su implementación. Por eso, los autores incorporan y valoran estrategias como flipped classroom, self-regulated learning y microlearning, sugiriendo que los trabajos que no integran estos elementos pueden quedar incompletos. En este sentido, su motivación no es solo demostrar si el Adaptive Learning funciona, sino explicar bajo qué condiciones pedagógicas funciona mejor. Así, el artículo se propone llenar un vacío: ofrecer evidencia sobre el impacto del aprendizaje adaptativo y, al mismo tiempo, proponer un modelo de implementación que articule plataforma, diseño didáctico, monitoreo docente y experiencia del estudiante.

Descripción del aporte del autor

El principal aporte del artículo radica en demostrar que el aprendizaje adaptativo no debe entenderse únicamente como el uso de una plataforma tecnológica, sino como una **estrategia didáctica integral** que, al combinarse con otras metodologías activas, puede mejorar significativamente el proceso de enseñanza-aprendizaje. Desde esta perspectiva, los autores no solo evalúan el impacto del Adaptive Learning en cursos de ciencias básicas de ingeniería, sino que también proponen un modelo de implementación institucional que articula tecnología, diseño instruccional, seguimiento docente y experiencia del estudiante. Este enfoque convierte al trabajo en una contribución relevante tanto a nivel práctico como teórico.

Uno de los aportes más importantes del estudio es la formulación de una **Adaptive Learning Strategy (ALS)** más amplia que el simple uso de una plataforma adaptativa. Los autores sostienen que los mejores resultados no se logran solo por incorporar una herramienta tecnológica, sino por integrarla con elementos de **flipped classroom, self-regulated learning y microlearning**. Esta idea representa una contribución clave, porque desplaza la discusión desde “qué plataforma usar” hacia “cómo diseñar una experiencia de aprendizaje adaptativo efectiva”. Así, el artículo aporta una visión pedagógica más robusta del aprendizaje adaptativo, en la que el valor no está solamente en el algoritmo, sino en la manera en que el sistema se articula con actividades antes, durante y después de la clase.

Otro aporte central es la **implementación y evaluación real** de esta estrategia en cursos universitarios de ingeniería y ciencias en el Tecnológico de Monterrey. Los cursos participantes fueron **Computational Thinking, Physics I, Physics II y Fundamental Mathematical Modeling**, lo que permite observar el comportamiento de la estrategia en asignaturas con diferentes niveles de complejidad y naturaleza disciplinar. Esta aplicación práctica aporta evidencia empírica importante, porque permite medir no solo la percepción de utilidad, sino también el efecto de la estrategia en el nivel de aprendizaje, el logro de subcompetencias disciplinares y transversales, y la experiencia de estudiantes y profesores.

Asimismo, el artículo aporta una **selección razonada y fundamentada de la plataforma Realizeit** después de evaluar 14 proveedores. Los autores no adoptan la plataforma de forma arbitraria, sino que establecen criterios claros relacionados con experiencia del estudiante, experiencia del profesor, diseño curricular, adaptabilidad, reportes analíticos y tipos de contenido soportados. Esta selección es relevante porque muestra un proceso institucional serio de análisis tecnológico y pedagógico. Entre las funcionalidades destacadas se encuentran los **Personalized Learning Paths**, el uso de algoritmos de inteligencia artificial, evaluaciones formativas y sumativas con retroalimentación inmediata, analíticas en tiempo real y la integración con el ecosistema digital universitario. Todo esto refuerza el aporte metodológico

del estudio, ya que ofrece una referencia útil para otras instituciones que deseen implementar estrategias similares.

Un aporte particularmente valioso del artículo es la construcción del **Didactic Model using Adaptive Learning (DMUAL)**. Este modelo organiza el proceso en función de actividades previas, durante y posteriores a la clase, alineadas con niveles cognitivos bajos y altos de la taxonomía revisada de Bloom. En la parte inferior del modelo, el estudiante revisa contenidos digitales en la plataforma adaptativa mediante videos, lecturas, podcasts y ejercicios con retroalimentación automática. Luego, durante la clase, participa en actividades de mayor complejidad, como resolución de problemas, elaboración de ejercicios complejos o atención de retos. En la *Figura 2 del artículo (página 5)* se visualiza esta combinación entre adaptive learning y active classroom, mostrando con claridad cómo la estrategia didáctica redistribuye el trabajo cognitivo dentro y fuera del aula. Este modelo constituye uno de los aportes más sólidos del estudio, porque ofrece una estructura pedagógica concreta para aplicar el aprendizaje adaptativo en educación superior.

Además, los autores aportan un **modelo de entrega o implementación** que orienta la labor del profesor en tres momentos: antes, durante y después de la clase. Antes de la sesión, el docente monitorea analíticas del aprendizaje y ajusta la instrucción; durante la clase, aplica estrategias activas y retoma contenidos de la plataforma; después, da seguimiento personalizado a estudiantes que requieren apoyo y vuelve a revisar analíticas para adaptar la enseñanza. En la *Figura 3 del artículo (página 8)* se observa este modelo original de aplicación de la estrategia adaptativa. Este aporte es especialmente importante porque responde a una necesidad que la literatura no siempre atiende: no solo saber que el AL funciona, sino **cómo debe implementarse** para que genere resultados positivos.

También constituye un aporte relevante la **diferenciación de líneas de desarrollo del aprendizaje adaptativo** que los autores presentan en su marco teórico. El artículo distingue entre una línea basada en plataformas comerciales que generan rutas personalizadas a partir de datos diagnósticos, otra línea “facilitator-driven” en la que la adaptación se construye a partir de las acciones del profesor apoyadas por dashboards y algoritmos predictivos, y una línea más reciente basada en biometría y neurocognición. Al presentar estas modalidades, el estudio no solo contextualiza su propuesta, sino que aporta una visión más amplia y organizada del campo, mostrando que el adaptive learning puede tomar formas distintas según el nivel de automatización y el papel del docente.

Otro aporte importante del artículo es el uso de un **diseño metodológico mixto y cuasi-experimental**, con enfoque secuencial Quant→Qual, lo que permite complementar los resultados cuantitativos con explicaciones cualitativas. Esta metodología fortalece el estudio, porque no se limita a medir pruebas de entrada y salida, sino que también analiza percepción estudiantil, experiencia docente y elementos didácticos de éxito. De este modo, el aporte no se queda en determinar si hubo diferencia en puntajes, sino que profundiza en por qué ciertas asignaturas funcionaron mejor, qué rol tuvo el diseño de contenidos, qué importancia tuvo la obligatoriedad de la prelectura y cómo influyó la curva de aprendizaje del profesor en la efectividad de la estrategia.

Asimismo, el artículo aporta evidencia que sugiere que el impacto del aprendizaje adaptativo no es uniforme en todos los cursos. Los resultados muestran que en asignaturas como **Computational Thinking** hubo mejoras significativas a favor del grupo experimental en ambas etapas, mientras que en otras asignaturas como **Physics I** o **Mathematical Modeling** los resultados fueron menos consistentes. Este hallazgo es un aporte importante porque muestra que el éxito del adaptive learning depende de factores como el diseño de contenidos, la obligatoriedad del preestudio, la calidad de la plataforma y la experiencia del profesor con la estrategia. En otras palabras, el estudio ayuda a entender que el aprendizaje adaptativo no debe

verse como solución automática, sino como innovación que requiere condiciones pedagógicas y operativas adecuadas.

Finalmente, uno de los aportes más sólidos del trabajo es la **propuesta de un modelo institucional de implementación del Adaptive Learning Strategy**, diseñado, aplicado y evaluado por la universidad. Esto le da al artículo un valor práctico muy alto, ya que no solo presenta resultados de investigación, sino una ruta concreta para futuras implementaciones. Los autores concluyen que una estrategia adaptativa integral debe incluir personalización de rutas, prelectura significativa, seguimiento analítico, intervención docente, contenidos bien diseñados, autorregulación del aprendizaje y recursos de microlearning. En ese sentido, el trabajo no solo aporta evidencia sobre el impacto del Adaptive Learning, sino también una guía para su implementación efectiva en educación superior.

En conjunto, el aporte del artículo puede resumirse en tres niveles: primero, redefine el aprendizaje adaptativo como una estrategia didáctica integral y no solo tecnológica; segundo, ofrece evidencia empírica de su impacto en cursos reales de ingeniería; y tercero, propone un modelo de implementación institucional que puede servir de referencia para otras universidades interesadas en personalizar y mejorar sus procesos de enseñanza-aprendizaje.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en un enfoque metodológico estructurado que combina análisis teórico, selección tecnológica, diseño didáctico e implementación en un entorno real universitario. En primer lugar, los autores parten de una revisión del estado del arte sobre aprendizaje adaptativo, aprendizaje personalizado y metodologías activas, lo que les permite identificar una limitación importante: la mayoría de implementaciones se centran en la plataforma tecnológica y no en una estrategia didáctica integral. A partir de esta observación, se plantea como objetivo desarrollar una **Adaptive Learning Strategy (ALS)** que integre tecnología, pedagogía y analítica de datos.

El segundo paso del proceso consiste en la **selección de la plataforma tecnológica adecuada**. Para ello, los autores realizan un análisis comparativo de 14 proveedores de soluciones de aprendizaje adaptativo, evaluando criterios como experiencia del estudiante, experiencia del docente, flexibilidad curricular, capacidad de adaptación, analíticas disponibles y tipos de contenido soportados. Como resultado de este proceso, seleccionan la plataforma **Realizeit**, debido a su capacidad para generar rutas de aprendizaje personalizadas, ofrecer retroalimentación inmediata y proporcionar analíticas detalladas del progreso del estudiante. Este paso es clave, ya que asegura que la herramienta elegida responda a las necesidades pedagógicas del modelo propuesto.

Posteriormente, los autores desarrollan el **modelo didáctico basado en aprendizaje adaptativo (DMUAL)**. En esta etapa, diseñan una estructura pedagógica que organiza el proceso de aprendizaje en tres momentos: antes, durante y después de la clase. Antes de la sesión, el estudiante interactúa con contenidos digitales adaptativos, como videos, lecturas y ejercicios. Durante la clase, se desarrollan actividades de mayor nivel cognitivo, como resolución de problemas y análisis de casos. Después de la clase, se refuerzan los contenidos y se realiza seguimiento del aprendizaje. Este diseño permite integrar el aprendizaje adaptativo con estrategias como flipped classroom y aprendizaje activo, generando una experiencia más completa.

Una etapa fundamental del proceso es la **implementación de la estrategia en cursos reales** de educación superior. Los autores aplican el modelo en asignaturas de ciencias básicas de ingeniería, como Computational Thinking, Physics I, Physics II y Mathematical Modeling. Esta implementación permite observar el comportamiento del modelo en diferentes contextos disciplinares y con distintos perfiles de estudiantes. Además, se asegura que el uso de la

plataforma no sea opcional, sino integrado dentro de la evaluación del curso, lo que garantiza la participación activa de los estudiantes.

El siguiente paso consiste en la **recolección de datos cuantitativos y cualitativos**. En el ámbito cuantitativo, se aplican pruebas de entrada y salida para medir el nivel de aprendizaje, mientras que en el ámbito cualitativo se recogen percepciones de estudiantes y docentes sobre la experiencia con el aprendizaje adaptativo. Este enfoque mixto (Quant→Qual) permite no solo medir resultados, sino también comprender los factores que influyen en el éxito o limitaciones de la estrategia.

Finalmente, los autores realizan el **análisis e interpretación de los resultados**, comparando grupos experimentales (con aprendizaje adaptativo) y grupos de control (sin aprendizaje adaptativo). A partir de este análisis, identifican mejoras en el desempeño en ciertos cursos, así como factores clave que influyen en la efectividad del modelo, como la calidad del contenido, la obligatoriedad de las actividades previas, el uso de analíticas y la experiencia del docente con la plataforma. Este proceso permite consolidar el aporte del estudio, demostrando que el aprendizaje adaptativo puede ser efectivo cuando se implementa como parte de una estrategia didáctica integral.

En conjunto, el proceso seguido por los autores combina diagnóstico del problema, selección tecnológica rigurosa, diseño pedagógico estructurado, implementación en contextos reales y evaluación mediante un enfoque mixto. Gracias a esta metodología, el estudio logra construir un aporte sólido que no solo analiza el aprendizaje adaptativo, sino que propone una forma efectiva de implementarlo en educación superior.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema de la implementación limitada del aprendizaje adaptativo en educación superior se basa en la construcción de una estrategia integral que combina tecnología, diseño pedagógico y análisis de datos. El problema central identificado es que muchas iniciativas de Adaptive Learning se enfocan únicamente en la plataforma, sin garantizar mejoras reales en el aprendizaje. Frente a ello, los autores proponen un proceso estructurado que permita transformar el uso de estas herramientas en una experiencia educativa efectiva, alineada con el desarrollo de competencias y el aprendizaje significativo.

El primer paso del proceso consiste en redefinir el aprendizaje adaptativo como una **estrategia didáctica integral**, y no solo como una herramienta tecnológica. Para ello, los autores plantean la integración del Adaptive Learning con metodologías activas como flipped classroom, self-regulated learning y microlearning. Esta combinación permite distribuir el aprendizaje en diferentes momentos y niveles cognitivos, favoreciendo la personalización y el aprendizaje activo. En este sentido, el estudiante no solo recibe contenidos adaptados, sino que también participa activamente en su proceso formativo.

El segundo paso es la implementación del **modelo didáctico DMUAL (Didactic Model using Adaptive Learning)**. Este modelo organiza el proceso en tres momentos: antes, durante y después de la clase. Antes de la sesión, el estudiante accede a contenidos adaptativos en la plataforma, donde revisa materiales y realiza ejercicios que permiten evaluar su nivel de comprensión. Durante la clase, el docente se enfoca en actividades de mayor complejidad cognitiva, como resolución de problemas y análisis de situaciones reales. Después de la clase, se realiza un seguimiento del aprendizaje mediante refuerzos personalizados. Este modelo permite optimizar el tiempo en el aula y adaptar la enseñanza a las necesidades del estudiante.

El tercer paso consiste en el uso de **analíticas de aprendizaje** para apoyar la toma de decisiones pedagógicas. La plataforma adaptativa genera datos sobre el desempeño, progreso y dificultades de los estudiantes, los cuales son utilizados por el docente para ajustar la enseñanza.

De esta manera, el proceso no depende únicamente de la automatización del sistema, sino también de la intervención del profesor, quien actúa como facilitador y guía del aprendizaje. Esta interacción entre tecnología y docente es clave para lograr una adaptación efectiva.

El cuarto paso es la aplicación de la estrategia en **cursos reales de educación superior**, lo que permite evaluar su efectividad en contextos concretos. Los autores implementan el modelo en asignaturas de ingeniería y ciencias básicas, donde los estudiantes presentan tradicionalmente dificultades de aprendizaje. Durante esta etapa, se asegura que el uso de la plataforma sea obligatorio y esté integrado dentro de la evaluación del curso, lo que garantiza la participación activa de los estudiantes en el proceso adaptativo.

Finalmente, el proceso se completa con la **evaluación de resultados**, donde se comparan grupos con y sin aprendizaje adaptativo, así como el desempeño en distintas asignaturas. Los resultados muestran que la estrategia puede mejorar el aprendizaje en ciertos cursos, aunque no de manera uniforme, lo que permite identificar factores críticos de éxito, como la calidad del contenido, el diseño instruccional y la experiencia del docente. Este análisis permite no solo validar la propuesta, sino también comprender las condiciones necesarias para su efectividad.

En conjunto, el proceso de solución se basa en transformar un enfoque tecnológico aislado en una estrategia educativa integral, donde el aprendizaje adaptativo se articula con metodologías activas, analítica de datos y acompañamiento docente. Gracias a esta integración, se logra mejorar la personalización del aprendizaje y avanzar hacia una educación más efectiva en el nivel universitario.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, los autores utilizan varias métricas para evaluar el impacto de la **Adaptive Learning Strategy (ALS)**. Para medir el **nivel de aprendizaje**, emplean principalmente **pre-test y post-test** en los cursos participantes, lo que les permite comparar la línea base de conocimiento y el aprendizaje alcanzado después de la intervención. Además, calculan la **ganancia de aprendizaje** entre ambos momentos. Para analizar el logro de competencias, recogen **evidencias de aprendizaje** como proyectos finales o exámenes argumentativos, evaluados por un profesor externo, con el fin de medir el desarrollo de **subcompetencias disciplinares y transversales**. También aplican un **cuestionario de percepción estudiantil** con escala Likert continua para evaluar dimensiones como **usabilidad de la plataforma, proceso de aprendizaje, engagement, experiencia de usuario y proceso de enseñanza**. Finalmente, para validar los instrumentos, utilizan indicadores como **Alpha de Cronbach**, índices de dificultad y discriminación.

En cuanto a los resultados, el estudio muestra que el impacto del ALS no fue uniforme en todos los cursos. En **Computational Thinking**, los estudiantes del grupo experimental obtuvieron resultados significativamente mejores que el grupo control en ambas etapas, lo que indica un efecto positivo claro de la estrategia. En **Physics II**, hubo una diferencia significativa a favor del grupo experimental en la primera etapa, aunque no se mantuvo en la segunda. En **Physics I** no se encontraron diferencias significativas entre control y experimental, y en **Fundamental Mathematical Modeling** los resultados fueron inconsistentes, con diferencias a veces a favor del control y otras del experimental, además de puntajes generales bajos. En términos de ganancia de aprendizaje, el grupo experimental mostró descriptivamente mejores resultados en la mayoría de cursos, aunque solo en algunos casos estas diferencias fueron estadísticamente significativas.

Respecto a las subcompetencias, los autores no encontraron diferencias significativas entre grupos control y experimental. Esto indica que, aunque la estrategia adaptativa parece favorecer el nivel de aprendizaje en algunos cursos, no necesariamente produce mejoras visibles en todas

las competencias evaluadas. En cambio, las métricas de experiencia estudiantil fueron más favorables en cursos como **Computational Thinking** y **Physics II**, donde la plataforma obtuvo mejores puntuaciones en usabilidad, proceso de aprendizaje, engagement y experiencia de usuario. Esto sugiere que la calidad del diseño de contenidos y la experiencia del profesor influyen mucho en los resultados.

Al comentar estos hallazgos, puede decirse que los resultados son **mejores que los de enfoques donde solo se usa una plataforma sin integración didáctica**, porque aquí se demuestra que el adaptive learning funciona mejor cuando se combina con flipped classroom, autorregulación y microlearning. Sin embargo, no se puede afirmar que los resultados sean superiores en todos los cursos o dimensiones, ya que el impacto depende bastante del diseño del contenido, de la obligatoriedad del preestudio y de la experiencia docente. Por eso, el artículo muestra algo muy valioso: el aprendizaje adaptativo sí puede mejorar resultados, pero no por la tecnología sola, sino por la calidad de la estrategia pedagógica que la acompaña.

Observaciones y/o críticas suyas al artículo

El artículo presenta un aporte importante porque no reduce el aprendizaje adaptativo al uso de una plataforma, sino que lo entiende como una estrategia didáctica más amplia, integrada con flipped classroom, self-regulated learning y microlearning. Esta es una de sus principales fortalezas, ya que ofrece una visión más realista y pedagógicamente sólida de cómo implementar el Adaptive Learning en educación superior. Además, el estudio tiene valor práctico porque fue desarrollado en cursos reales de ingeniería y ciencias, con grupos de control y experimentales, lo que le da mayor seriedad metodológica. También resulta valioso que los autores no solo analicen el aprendizaje, sino también la experiencia de estudiantes y profesores.

Sin embargo, una primera crítica es que los resultados no fueron consistentes en todos los cursos. Mientras en **Computational Thinking** se observaron mejoras claras en favor del grupo experimental, en **Physics I** no hubo diferencias significativas y en **Mathematical Modeling** incluso aparecieron resultados débiles o contradictorios. Esto indica que la estrategia no garantiza éxito automático y que su efectividad depende mucho de factores como la calidad de los contenidos, la experiencia del docente y el diseño instruccional. En ese sentido, el propio estudio confirma que el adaptive learning no funciona igual en cualquier contexto, lo cual es una limitación importante.

Otra observación relevante es que, aunque el artículo propone un modelo integral, su aplicación sigue dependiendo fuertemente de recursos institucionales, tiempo de diseño, capacitación docente y acompañamiento técnico. Esto puede dificultar su implementación en universidades con menos infraestructura o menor soporte pedagógico-tecnológico. Además, el estudio reconoce problemas concretos en algunos cursos, como errores de diseño de contenido, baja motivación estudiantil y poco aprovechamiento del pre-reading en una primera etapa, lo cual muestra que la calidad de la estrategia no depende solo de la plataforma, sino de todo el ecosistema educativo que la rodea.

También se puede criticar que, aunque se mide el logro de subcompetencias, no se encontraron diferencias significativas entre grupos control y experimental. Esto sugiere que el impacto del Adaptive Learning fue más claro en algunos niveles de aprendizaje y en la experiencia de uso, pero no necesariamente en el desarrollo integral de competencias. Por ello, sería importante que futuras investigaciones profundicen más en el efecto a largo plazo y en la transferencia real de lo aprendido.

En síntesis, el artículo es sólido, útil y aporta una visión más madura del aprendizaje adaptativo, pero también evidencia que esta innovación exige buen diseño, seguimiento docente y condiciones institucionales favorables para producir resultados realmente consistentes.

6. ARTICULO 06

Author (s): Guerrero-Roldán, A.-E.; Rodríguez-González, M. E.; Bañeres, D.; Elasri-Ejjaberi, A.; Cortadas, P.

Title of paper: Experiencias en el uso de un sistema inteligente adaptativo para mejorar el rendimiento de los estudiantes en línea: un estudio de caso en cursos de Economía y Negocios.

Journal: International Journal of Educational Technology in Higher Education

Volume (issue): 18(36)

pag – pag (year): 1–27 (2021)

Estado del arte que hace el autor

El estado del arte presentado por los autores se centra en el uso de sistemas tecnológicos para fortalecer el proceso de enseñanza-aprendizaje en entornos virtuales, con especial atención a los cursos totalmente online. El artículo parte reconociendo que en los últimos años el uso de herramientas digitales en educación superior ha crecido con rapidez, y que la literatura ha analizado ampliamente cómo las tecnologías de la información y la comunicación pueden apoyar tanto la forma en que enseñan los docentes como la manera en que aprenden los estudiantes. En estos entornos, los profesores diseñan actividades diversas para fomentar la comunicación, la participación y el desarrollo de competencias dentro del Virtual Learning Environment (VLE), mientras intentan mantener motivados a los estudiantes mediante retroalimentación rica y oportuna.

Dentro de este panorama, los autores ubican el problema del abandono o *dropout* como uno de los temas más estudiados en la educación superior online. Señalan que los estudiantes suelen dejar los cursos cuando se sienten desmotivados, inseguros sobre sus posibilidades de aprobar o abrumados por las próximas actividades y competencias por desarrollar. A esto se suma la sensación de aislamiento, muy común en los entornos totalmente virtuales, donde la escasa interacción o la falta de retroalimentación son factores decisivos para que muchos alumnos dejen de participar activamente en el curso. Por ello, el estado del arte no solo revisa tecnologías para enseñar, sino también mecanismos para acompañar, motivar y retener a los estudiantes durante todo el proceso formativo.

Un elemento central de esta revisión es precisamente la **retroalimentación**. Los autores destacan que distintos trabajos han estudiado cuándo conviene ofrecer feedback y qué tipo de retroalimentación resulta más adecuada según cada situación. En el contexto online, la retroalimentación se convierte en una pieza clave porque permite al estudiante conocer su avance, corregir errores, mantenerse comprometido y sentirse acompañado. Según el artículo, el feedback actúa como una herramienta de seguimiento, motivación y orientación, y se vincula directamente con la posibilidad de reducir el abandono y mejorar el rendimiento académico.

El estado del arte también introduce el papel de la **personalización** en el aprendizaje online. Los autores explican que conocer mejor a los estudiantes permite adaptar la enseñanza a sus necesidades y trayectorias. En este punto, revisan dos campos de investigación relevantes: **learning analytics** y **educational data mining**, ambos enfocados en recolectar y analizar datos generados por los sistemas digitales para mejorar el proceso educativo. Sin embargo, señalan una limitación importante: gran parte de estos enfoques se ha centrado en rastrear el comportamiento del estudiante dentro del entorno virtual, como navegación o interacción en foros, pero menos en los procesos de evaluación y en el nivel real de compromiso con las actividades de aprendizaje. Esta observación es clave, porque muestra que todavía existe un vacío en sistemas que utilicen los datos de evaluación para anticipar riesgos y actuar pedagógicamente a tiempo.

A partir de esta limitación, los autores revisan el desarrollo de **sistemas adaptativos e Intelligent Tutoring Systems (ITS)**. Retoman la idea de que los ITS surgen de la convergencia entre instrucción asistida por computadora, avances en ciencias cognitivas, inteligencia

artificial y mayor poder de cómputo. En la literatura aparecen ejemplos exitosos en campos específicos como bases de datos, matemáticas, programación o diseño de sistemas digitales. No obstante, el artículo subraya que muchos ITS siguen siendo altamente especializados y requieren poca intervención del profesor, por lo que uno de los grandes retos del campo es construir sistemas adaptativos más amplios, aplicables a distintas disciplinas académicas y capaces de predecir con precisión el comportamiento del estudiante.

En este marco, el estado del arte dedica una parte importante a los **Early Warning Systems (EWS)**. Los autores mencionan que probablemente el caso más influyente en la literatura sea **Course Signals** de Purdue University, por su impacto en rendimiento, retención y satisfacción. A partir de allí, identifican distintos tipos de EWS: algunos orientados a la retención en entornos presenciales, otros al abandono en cursos online y otros a la detección temprana de estudiantes en riesgo de fracasar. Sin embargo, advierten que muchos enfoques se han concentrado sobre todo en construir modelos predictivos a partir de datos disponibles, mientras que existen menos desarrollos completos implementados en escenarios reales de enseñanza. También señalan que algunos sistemas informan solo a los docentes mediante paneles de control, mientras que otros avanzan un poco más e incluyen también información para los estudiantes.

Otro componente del estado del arte es la relación entre **evaluación, actividades de aprendizaje y seguimiento del estudiante**. Los autores enfatizan que el modelo de evaluación y el tipo de feedback ofrecido son pilares del modelo educativo institucional, especialmente en universidades a distancia o totalmente virtuales. En estos contextos, el syllabus se vuelve fundamental para que el estudiante comprenda cómo será evaluado, qué actividades debe entregar y qué retroalimentación recibirá. Desde esta perspectiva, el artículo remarca que la evaluación continua y el feedback son piezas esenciales para acompañar el progreso del estudiante y detectar tempranamente cuándo está en riesgo de no aprobar.

Finalmente, el estado del arte se sitúa en el contexto de una universidad completamente online, la **Universitat Oberta de Catalunya**, cuyo modelo educativo se basa en el estudiante, en las competencias a desarrollar y en una evaluación continua con retroalimentación cualitativa. Los autores muestran que, aunque ya existían apoyos docentes y tutoriales, persistía la necesidad de contar con sistemas como LIS que reforzaran el autoconocimiento del estudiante sobre su situación académica y potenciaran la personalización. En síntesis, el estado del arte evidencia que el campo ha avanzado en analítica, feedback, ITS y sistemas de alerta temprana, pero todavía existe una necesidad clara de soluciones adaptativas que se enfoquen no solo en la navegación dentro del entorno virtual, sino en el proceso de evaluación, la detección de riesgo y la provisión de retroalimentación útil para mejorar rendimiento y reducir abandono en educación online.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una limitación que identifican en la literatura sobre tecnologías educativas para entornos virtuales: aunque se han desarrollado muchas herramientas para mejorar el proceso de enseñanza-aprendizaje, la mayoría se ha concentrado en el proceso en sí mismo y no en el **proceso de evaluación** como medio para detectar estudiantes en riesgo, intervenir a tiempo y ofrecer retroalimentación que realmente les ayude a aprobar el curso. Desde esta perspectiva, los autores consideran que aún son escasos los sistemas que utilizan la evaluación continua y el rendimiento en actividades de aprendizaje como base para anticipar dificultades y actuar pedagógicamente antes de que el estudiante fracase o abandone.

Otra crítica importante que plantean es que, aunque áreas como **learning analytics** y **educational data mining** han avanzado mucho en el análisis de datos generados dentro de los entornos virtuales, gran parte de esos enfoques se ha centrado sobre todo en el seguimiento de la navegación o de la interacción del estudiante en el VLE, más que en su proceso de evaluación

y en su nivel real de compromiso con las actividades académicas. Según los autores, esto deja pocos aportes concretos para reducir el abandono, incrementar la motivación o mejorar el rendimiento de los estudiantes desde una lógica verdaderamente preventiva.

Asimismo, los autores critican implícitamente que muchos **sistemas adaptativos** y **Early Warning Systems** existentes han sido diseñados con enfoques parciales. Algunos solo muestran tableros de información para docentes, mientras que otros ofrecen información limitada a los estudiantes. Además, una gran cantidad de trabajos se enfoca en la construcción de modelos predictivos, pero existen menos desarrollos completos aplicados en **contextos educativos reales**, donde el sistema no solo prediga, sino que también entregue retroalimentación personalizada y útil para orientar al estudiante durante el curso. Desde esta perspectiva, los autores consideran que la investigación previa ha producido avances relevantes, pero todavía no suficientes en términos de aplicación práctica y acompañamiento efectivo.

También cuestionan el hecho de que muchos ITS y sistemas adaptativos sean **demasiado específicos de una disciplina**, lo que dificulta su uso transversal en una institución. En la literatura se reportan sistemas potentes para áreas concretas como programación, matemáticas o bases de datos, pero sigue siendo un reto desarrollar soluciones más amplias, aplicables a distintos campos académicos y capaces de adaptarse a las características de una universidad online completa. Esta observación explica por qué el proyecto LIS busca ser una herramienta institucional y no solo una solución aislada para una sola asignatura.

Finalmente, la motivación del artículo se refuerza por el contexto de la educación superior completamente online, donde el aislamiento, la inseguridad sobre el desempeño y la falta de feedback oportuno son factores que pueden afectar fuertemente la permanencia del estudiante. Por ello, los autores proponen LIS como respuesta a ese vacío: un sistema inteligente que combine predicción, detección temprana de riesgo y retroalimentación personalizada tanto para estudiantes como para profesores, con el fin de mejorar el rendimiento, reducir el abandono y fortalecer la percepción de acompañamiento en el entorno virtual.

Descripción del aporte del autor

El principal aporte del artículo consiste en el desarrollo, implementación y evaluación de un sistema adaptativo inteligente llamado **Learning Intelligent System (LIS)**, orientado a mejorar el rendimiento de estudiantes en cursos completamente online mediante detección temprana de riesgo, retroalimentación personalizada y apoyo al docente en la toma de decisiones. A diferencia de muchas herramientas educativas que se concentran en el acceso a contenidos o en el seguimiento general de la navegación dentro del entorno virtual, el sistema propuesto pone el foco en el **proceso de evaluación continua**, en la identificación de estudiantes en riesgo de fracasar o abandonar, y en la generación de intervenciones oportunas que permitan sostener el aprendizaje. Este enfoque constituye un aporte relevante porque conecta analítica, inteligencia artificial y feedback con un problema muy concreto de la educación online: la permanencia y el éxito académico del estudiante.

Uno de los aportes más importantes del trabajo es precisamente la creación de un sistema institucional que no solo predice riesgo, sino que también **actúa pedagógicamente** sobre él. El LIS fue concebido en una universidad totalmente online, la Universitat Oberta de Catalunya, y procesa datos históricos y actuales del estudiante almacenados en un *data mart* institucional anonimizado. A partir de ellos, el sistema analiza variables como calificaciones obtenidas en actividades de evaluación, grado de engagement, utilización de recursos, número de asignaturas matriculadas, repeticiones del curso y promedio académico general. Con base en esos datos, ejecuta un análisis predictivo mediante algoritmos de clasificación de inteligencia artificial para estimar la probabilidad de que cada estudiante apruebe o no el curso. Este paso representa un aporte técnico fuerte, porque transforma grandes volúmenes de información educativa en predicciones útiles para la intervención docente.

Otro aporte clave es que el LIS no se limita a informar al profesor, sino que incorpora una lógica de **doble retroalimentación**: una para docentes y otra para estudiantes. Por un lado, los profesores reciben un **dashboard** donde pueden visualizar el estado de sus alumnos, identificar casos críticos y actuar a tiempo. Por otro lado, cada estudiante dispone de una representación gráfica sencilla de su situación, basada en un sistema de semáforo con colores que indican su nivel de riesgo, junto con recomendaciones personalizadas sobre cómo mejorar su desempeño. En la *Figura 3 del artículo (página 9)* se muestra el panel del profesor con la clasificación de riesgo de los alumnos después de una actividad evaluable, mientras que en la *Figura 4 (página 10)* se presenta el panel del estudiante, donde se le informa de su nivel de riesgo y del rendimiento mínimo esperado en las siguientes actividades. Este diseño visual y funcional aporta una forma clara de traducir predicciones complejas en orientación práctica y comprensible.

Asimismo, uno de los aportes metodológicos más sólidos del artículo es la formulación del **Gradual At-Risk model (GAR)**, que constituye el núcleo predictivo del LIS. Este modelo se entrena antes de iniciar el curso, utilizando datos históricos de cohortes anteriores, y genera tantos submodelos como actividades de evaluación continua tenga la asignatura. Cada submodelo emite una predicción binaria —aprobar o no aprobar— a partir de variables académicas y de perfil del estudiante. Para construirlo, los autores emplean cuatro algoritmos de clasificación: **Naive Bayes**, **Decision Tree**, **K-Nearest Neighbors** y **Support Vector Machine**, y posteriormente seleccionan el modelo más adecuado para cada curso tras un proceso de validación. En la *Figura 1 del artículo (página 8)* se observa el flujo de trabajo para obtener este modelo optimizado. Este aporte es relevante porque permite adaptar la predicción al momento del curso y no limitarla a una sola estimación general del semestre.

Además, el artículo aporta una **clasificación gradual del nivel de riesgo** que va más allá del simple binario aprobado/reprobado. El sistema distingue entre estudiantes en verde, amarillo, rojo y situaciones específicas de no entrega de actividades (NS1 y NS2), según el rendimiento alcanzado y la precisión del modelo en cada etapa. La *Figura 2 del artículo (página 8)* muestra este árbol de decisión para la clasificación del riesgo. Esta graduación aporta mayor fineza pedagógica, porque no trata de la misma forma a un estudiante que va bien, a uno que aprobó con dificultad, a uno que está en serio riesgo de fracaso o a uno que ya ha dejado de entregar actividades. Gracias a ello, el sistema puede ofrecer mensajes distintos y más adecuados a cada caso.

Otro aporte importante del artículo es su **validación en un escenario real de educación superior online**, con una muestra de **552 estudiantes** de dos cursos de primer año del grado en Economía y Empresa: *Introduction to enterprise* y *Markets and behavior*. Esto le da al trabajo un valor aplicado muy alto, ya que el sistema no fue probado en un laboratorio ni en simulaciones, sino en un entorno institucional auténtico, durante un semestre completo. Los resultados muestran que el rendimiento de los estudiantes que utilizaron LIS fue mejor que el de quienes no lo usaron y también superior al de cohortes del semestre anterior. Además, el sistema logró reducir el abandono y aumentar la percepción de utilidad y efectividad entre los participantes. Este aporte es clave porque demuestra que el uso de inteligencia artificial y sistemas de alerta temprana puede traducirse en mejoras observables en contextos educativos reales.

El artículo también aporta al campo al demostrar que el **feedback automatizado y personalizado** puede convertirse en una herramienta de acompañamiento valiosa para estudiantes online. El LIS no solo clasifica a los estudiantes según su riesgo, sino que activa correos electrónicos automáticos con mensajes distintos según el nivel de alerta: felicitaciones para quienes van bien, advertencias y recomendaciones para quienes están en amarillo, y alertas más directas con sugerencias concretas para quienes están en rojo o en situaciones de no entrega. Este componente aporta una dimensión pedagógica muy importante al sistema, porque

evita que la predicción quede encerrada en un panel analítico y la convierte en comunicación formativa, orientadora y motivadora.

Además, los autores aportan una reflexión institucional relevante: el LIS no fue concebido como un sistema experto para una sola materia, sino como el primer paso hacia un **ITS adaptativo más amplio**, aplicable de manera transversal en toda la universidad. De hecho, el artículo señala que el proyecto busca evolucionar desde este sistema inicial de alerta temprana hacia una herramienta capaz de recomendar recursos de aprendizaje, ejercicios y apoyos adicionales de manera adaptativa. En ese sentido, el trabajo no solo ofrece una solución puntual, sino una arquitectura de crecimiento para futuras implementaciones institucionales de personalización y apoyo al aprendizaje.

Otro aporte metodológico relevante es el uso de una **metodología mixta**, combinando análisis cuantitativo del rendimiento y análisis cualitativo de la percepción estudiantil. Esto permite al estudio responder a dos preguntas clave: no solo si el rendimiento mejora con el sistema, sino también si los estudiantes lo consideran útil y efectivo. Así, el artículo aporta evidencia tanto objetiva como subjetiva, fortaleciendo la validez de sus hallazgos.

En conjunto, el aporte del artículo puede resumirse en cuatro planos. Primero, desarrolla un sistema inteligente capaz de detectar tempranamente estudiantes en riesgo en entornos totalmente online. Segundo, integra analítica predictiva, dashboards y feedback personalizado para docentes y estudiantes. Tercero, valida el sistema en un contexto real con mejoras en rendimiento, menor abandono y buena aceptación por parte de los usuarios. Y cuarto, sienta las bases para una evolución futura hacia un sistema adaptativo institucional más completo. Por ello, el trabajo representa una contribución sólida al campo del aprendizaje online, la analítica educativa y los sistemas adaptativos centrados en el éxito del estudiante.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en un enfoque sistemático que combina análisis del problema, diseño de un sistema inteligente, desarrollo tecnológico y validación en un entorno real de educación online. En primer lugar, los autores parten de la identificación de una problemática concreta: la alta tasa de abandono y bajo rendimiento en cursos completamente virtuales, causada en gran parte por la falta de retroalimentación oportuna y por la dificultad de detectar a tiempo a los estudiantes en riesgo. A partir de este diagnóstico, plantean la necesidad de desarrollar un sistema que permita anticipar el desempeño del estudiante y ofrecer apoyo personalizado durante el curso.

El segundo paso consiste en el diseño conceptual del **Learning Intelligent System (LIS)**. En esta etapa, los autores definen los componentes principales del sistema, estableciendo que debe integrar analítica de datos, modelos predictivos y mecanismos de retroalimentación tanto para docentes como para estudiantes. Asimismo, determinan que el sistema debe basarse en el análisis de datos históricos y actuales del estudiante, provenientes de un *data mart* institucional, con el fin de construir modelos de predicción confiables. Esta fase es clave porque establece la arquitectura general del sistema y sus objetivos pedagógicos.

Posteriormente, los autores desarrollan el **modelo predictivo Gradual At-Risk (GAR)**, que constituye el núcleo del sistema. Para ello, utilizan datos históricos de cohortes anteriores y aplican diferentes algoritmos de clasificación, como Naive Bayes, Decision Tree, K-Nearest Neighbors y Support Vector Machine. Estos modelos se entrenan y validan antes del inicio del curso, con el objetivo de seleccionar el más preciso para cada asignatura. Además, se construyen submodelos específicos para cada actividad de evaluación continua, lo que permite generar predicciones progresivas a lo largo del curso. Este proceso técnico permite transformar datos educativos en información predictiva útil para la toma de decisiones.

El siguiente paso es la implementación del sistema en el entorno educativo real. El LIS se integra en el Virtual Learning Environment de la universidad, donde se conecta con los datos de evaluación y desempeño de los estudiantes. A medida que los estudiantes realizan actividades, el sistema actualiza sus predicciones y clasifica su nivel de riesgo en distintas categorías. Esta implementación incluye también el desarrollo de interfaces visuales para profesores y estudiantes, como dashboards y paneles de seguimiento, que facilitan la interpretación de los resultados.

Una etapa fundamental del proceso es la generación de **retroalimentación personalizada**. Con base en las predicciones del modelo, el sistema envía mensajes automáticos a los estudiantes, adaptados a su nivel de riesgo, con recomendaciones específicas para mejorar su desempeño. Al mismo tiempo, los docentes reciben información detallada sobre el estado de sus alumnos, lo que les permite intervenir de manera oportuna. Este componente es clave, ya que convierte el análisis predictivo en una acción pedagógica concreta.

Finalmente, los autores realizan la validación del sistema mediante su aplicación en cursos reales con estudiantes universitarios. Durante esta fase, recopilan datos sobre el rendimiento académico, tasas de aprobación, abandono y percepción de los usuarios. Los resultados obtenidos permiten evaluar la efectividad del sistema y confirmar su utilidad para mejorar el aprendizaje en entornos online. Este proceso de validación cierra el ciclo metodológico, demostrando que el aporte no solo es teórico, sino también práctico y aplicable.

En conjunto, el proceso seguido por los autores combina diagnóstico del problema, diseño conceptual, desarrollo de modelos predictivos, implementación tecnológica y evaluación en contexto real. Gracias a este enfoque integral, logran construir un sistema inteligente que no solo identifica estudiantes en riesgo, sino que también contribuye a mejorar su rendimiento mediante retroalimentación oportuna y personalizada.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema del bajo rendimiento y abandono en cursos online se basa en la creación de un sistema inteligente que permita detectar tempranamente a los estudiantes en riesgo y ofrecer retroalimentación oportuna para mejorar su desempeño. El problema central identificado es que, en entornos virtuales, los estudiantes suelen enfrentar falta de acompañamiento, retroalimentación tardía y dificultades para identificar su propio nivel de progreso, lo que puede llevarlos a abandonar el curso o a obtener bajos resultados. Frente a ello, los autores proponen un proceso estructurado que combina analítica de datos, inteligencia artificial y estrategias de feedback personalizado.

El primer paso del proceso consiste en la **recolección y análisis de datos educativos**. El sistema LIS accede a información proveniente del entorno virtual de aprendizaje, incluyendo calificaciones de actividades, participación, uso de recursos, historial académico y características del estudiante. Estos datos son almacenados en un repositorio institucional y sirven como base para la construcción de modelos predictivos. Este paso es fundamental, ya que permite comprender el comportamiento del estudiante y establecer patrones que puedan anticipar su desempeño futuro.

El segundo paso es la **predicción del rendimiento académico mediante el modelo Gradual At-Risk (GAR)**. A través de algoritmos de clasificación, el sistema analiza los datos disponibles y estima la probabilidad de que cada estudiante apruebe o no el curso. Esta predicción se actualiza de manera progresiva a lo largo del semestre, generando diferentes niveles de riesgo en función del avance del estudiante en las actividades de evaluación. Gracias a este enfoque, el sistema no espera al final del curso para identificar problemas, sino que actúa desde las primeras etapas.

El tercer paso consiste en la **clasificación del nivel de riesgo del estudiante**. El LIS utiliza un sistema de categorías (verde, amarillo, rojo, entre otros estados) que permite diferenciar distintos grados de riesgo académico. Esta clasificación facilita la interpretación de los resultados tanto para docentes como para estudiantes, ya que traduce datos complejos en información clara y accionable. De esta manera, el sistema no solo predice el rendimiento, sino que también lo comunica de forma comprensible.

El cuarto paso es la **generación de retroalimentación personalizada**. En función del nivel de riesgo identificado, el sistema envía mensajes automáticos a los estudiantes con recomendaciones específicas para mejorar su desempeño, como reforzar ciertos contenidos, dedicar más tiempo al estudio o completar actividades pendientes. Al mismo tiempo, los docentes reciben información detallada sobre el estado de sus estudiantes, lo que les permite intervenir de manera más efectiva. Este paso es clave, porque convierte la predicción en una acción pedagógica concreta orientada a mejorar el aprendizaje.

El quinto paso es la **intervención y seguimiento continuo**. A lo largo del curso, el sistema actualiza las predicciones y el nivel de riesgo del estudiante después de cada actividad evaluable, lo que permite un monitoreo constante del progreso. Esto facilita que tanto el estudiante como el docente puedan tomar decisiones oportunas para corregir dificultades antes de que se conviertan en problemas mayores. De esta manera, el proceso de aprendizaje se vuelve dinámico y adaptativo.

Finalmente, el proceso se completa con la **evaluación de resultados**, donde se analizan indicadores como rendimiento académico, tasas de aprobación y abandono, así como la percepción de los usuarios. Los resultados muestran que el uso del LIS contribuye a mejorar el desempeño de los estudiantes y a reducir el abandono, lo que confirma la efectividad del proceso propuesto.

En conjunto, el proceso de solución se basa en transformar un entorno educativo pasivo en un sistema inteligente de acompañamiento, donde la información se utiliza para anticipar problemas, guiar al estudiante y mejorar su aprendizaje de manera continua.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, los autores utilizan métricas de **predicción, rendimiento académico y percepción de utilidad** para evaluar el impacto del sistema LIS. En primer lugar, para medir la calidad del modelo predictivo emplean indicadores como **ACC (accuracy global)**, **TPR (true positive rate)**, **TNR (true negative rate)** y **F1.5**, los cuales permiten valorar qué tan bien el sistema identifica estudiantes en riesgo y estudiantes sin riesgo. Por ejemplo, en el curso *Introduction to enterprise*, la exactitud global del modelo pasó de **78.85% en la ALA1 a 92.62% en la ALA5**, mientras que en *Markets and behavior* aumentó de **78.35% a 90.38%**. Estas cifras muestran que el sistema mejora su precisión conforme avanza el curso y dispone de más datos del estudiante.

En segundo lugar, para evaluar el rendimiento académico real, los autores analizan la **tasa de abandono (dropout)**, la **tasa de aprobación en cada actividad evaluable (ALA)** y la **nota final del curso**. Los resultados muestran que los estudiantes que usaron LIS tuvieron menores tasas de abandono que quienes no lo usaron y que los grupos del semestre anterior. En *Introduction to enterprise*, el dropout fue de **14.20%** en el grupo que utilizó LIS, frente a **32.79%** en el grupo que no firmó consentimiento y **29.24%** en el semestre previo. En *Markets and behavior*, el abandono fue de **9.52%** en el grupo con LIS, frente a **31.90%** y **18.2%** en los otros grupos. Además, la tasa de aprobación de actividades fue generalmente superior en el grupo con LIS, y la comparación de la nota final mediante la prueba **Wilcoxon** mostró diferencias significativas a favor de los estudiantes que usaron el sistema en ambos cursos.

Los autores también realizan un análisis de regresión para identificar qué variables influyen más en la nota final. Encuentran que las calificaciones obtenidas en actividades intermedias del curso tienen más peso que otras variables como GPA o condición de estudiante nuevo, lo cual refuerza la importancia de monitorear el desempeño continuo más que solo características generales del alumno.

Al comentar estos resultados, puede afirmarse que son mejores que los de grupos sin el sistema LIS y mejores que los observados en semestres previos, especialmente porque muestran una combinación positiva de **mayor rendimiento, menor abandono y mejor percepción de utilidad**. Más que superar “a otros estudios” de forma absoluta, el artículo demuestra que LIS ofrece ventajas claras frente a enfoques tradicionales donde el docente debía revisar manualmente el desempeño del estudiante. Su fortaleza está en que no solo predice, sino que también interviene con retroalimentación personalizada, lo que hace más efectiva la acción pedagógica en cursos completamente online.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte muy valioso porque aborda un problema real y frecuente en la educación online: la dificultad de identificar a tiempo a los estudiantes en riesgo de fracaso o abandono. Una de sus principales fortalezas es que no se queda en la construcción de un modelo predictivo, sino que desarrolla un sistema completo, el **LIS**, que combina analítica, inteligencia artificial, paneles de monitoreo y retroalimentación personalizada tanto para estudiantes como para profesores. Además, el estudio tiene un valor aplicado importante, ya que el sistema fue probado en cursos reales de una universidad completamente online, con una muestra amplia de estudiantes y con resultados positivos en rendimiento, disminución del abandono y percepción de utilidad.

Sin embargo, una primera observación crítica es que el sistema todavía se encuentra en una etapa inicial de desarrollo. Aunque los resultados del Early Warning System son prometedores, el propio artículo reconoce que el proyecto LIS busca evolucionar hacia un sistema adaptativo más completo, capaz de recomendar recursos, ejercicios y apoyos adicionales de manera más autónoma. Por tanto, el sistema evaluado aún no representa un ITS plenamente desarrollado, sino más bien una primera fase centrada en predicción y feedback. Esto limita el alcance del aporte en comparación con sistemas adaptativos más completos.

Otra crítica importante es que el estudio se realizó únicamente en **dos cursos de primer año** del área de Economía y Empresa dentro de una sola universidad online. Aunque esto permite una validación real, también reduce la posibilidad de generalizar los resultados a otros campos académicos, otros niveles educativos o instituciones con modelos distintos. Además, la participación de los estudiantes dependió de la firma de un consentimiento, por lo que no toda la población del curso fue incluida, lo cual podría introducir cierto sesgo en los resultados.

También se puede observar que el sistema no distingue completamente entre estudiantes en riesgo de **fracaso académico** y estudiantes en riesgo de **abandono**, aunque ambos casos reciben tratamiento diferenciado en la retroalimentación. Esta es una limitación relevante, porque las causas y necesidades pedagógicas de ambos grupos no siempre son las mismas. En futuras versiones del sistema, sería importante mejorar esta distinción para ofrecer intervenciones aún más precisas.

En síntesis, se trata de un artículo sólido, innovador y muy útil para el campo de la educación online, pero todavía requiere ampliarse a más contextos, más asignaturas y una personalización más profunda para consolidarse como una solución adaptativa integral.

7. ARTICULO 07

Author (s): Wu, T.-T.; Lee, H.-Y.; Wang, W.-S.; Lin, C.-J.; Huang, Y.-M.

Title of paper: Aprovechamiento de la visión artificial para el aprendizaje adaptativo en la educación STEM: efecto del compromiso y la autoeficacia.

Journal: *International Journal of Educational Technology in Higher Education*

Volume (issue): 20:53

pag – pag (year): 1–26 (2023)

Estado del arte que hace el autor

El estado del arte presentado por los autores se centra en dos ejes principales dentro de la educación STEM: la **medición del engagement** de los estudiantes y la **implementación del aprendizaje adaptativo** en contextos donde predominan actividades prácticas, colaborativas y de resolución de problemas. El artículo parte de reconocer que la educación STEM, por su naturaleza interdisciplinaria, busca desarrollar capacidades de resolución de problemas, construcción de conocimiento y aprendizaje activo en educación superior. A diferencia de los modelos tradicionales, donde el énfasis suele colocarse en los resultados finales, en STEM cobra especial importancia el proceso de aprendizaje y, dentro de él, el nivel de involucramiento del estudiante. Por esta razón, los autores sostienen que evaluar con precisión el engagement del alumnado es una condición fundamental para comprender su desempeño y mejorar la experiencia formativa.

En este contexto, el artículo revisa el concepto de **learning engagement** como un indicador del grado de participación e inversión cognitiva, conductual y emocional del estudiante durante el aprendizaje. Los autores destacan que numerosos estudios ya han demostrado una relación positiva entre engagement y rendimiento académico, lo que convierte a este constructo en una variable central dentro de la educación STEM. Como marco de referencia para analizar este fenómeno, el estado del arte enfatiza el **ICAP framework**, uno de los modelos más consolidados para evaluar el engagement cognitivo. Este marco clasifica el compromiso del estudiante en cuatro niveles: **pasivo, activo, constructivo e interactivo**, permitiendo a docentes e investigadores distinguir con mayor claridad la profundidad de la implicación del alumno en las actividades de aprendizaje. Además, el artículo señala que el ICAP ha sido ampliamente utilizado en estudios STEM como base para valorar la participación cognitiva en tareas prácticas y colaborativas.

Los autores también revisan los métodos tradicionales para medir el engagement en educación STEM. Según el estado del arte que presentan, predominan dos enfoques: **self-reporting** y **observation methods**. El primero se basa en cuestionarios o entrevistas en los que el propio estudiante informa sobre su nivel de compromiso, pero presenta limitaciones porque depende de la memoria, la subjetividad y, en ocasiones, de la influencia de expectativas sociales. El segundo se basa en la observación de conductas, interacciones e imágenes de las actividades, lo que permite una evaluación más directa, aunque exige mucho tiempo, esfuerzo humano y costos elevados de codificación. Frente a estas limitaciones, el artículo muestra cómo investigaciones recientes han comenzado a utilizar **inteligencia artificial** para analizar expresiones faciales, movimientos del mouse, patrones de lectura o interacciones colaborativas, con el fin de obtener una medición más objetiva del engagement. Aun así, los autores subrayan que la construcción de sistemas automatizados para evaluar el engagement específicamente en educación STEM sigue siendo un reto importante.

Otro componente clave del estado del arte es la relación entre **engagement y self-efficacy**. Los autores explican que ambas variables mantienen una relación dinámica y recíproca: cuando los estudiantes se involucran activamente en tareas STEM, experimentan éxito, dominio y competencia, lo que fortalece su autoconfianza y su percepción de eficacia personal. A su vez, una mayor autoeficacia incrementa la motivación, el esfuerzo y la persistencia frente a desafíos.

complejos. En consecuencia, el artículo sostiene que engagement y self-efficacy son factores decisivos para potenciar la educación STEM y que, por ello, cualquier sistema adaptativo efectivo debería considerar ambos elementos de manera articulada.

El estado del arte también revisa el campo del **adaptive learning**. Los autores lo describen como un enfoque innovador que utiliza tecnología educativa, analítica de datos e inteligencia artificial para personalizar contenidos, procesos y métodos de aprendizaje según las características individuales del estudiante. Citan estudios que han confirmado beneficios del aprendizaje adaptativo sobre el engagement, la motivación y el rendimiento académico. Sin embargo, también aclaran que su implementación enfrenta desafíos particulares en STEM. En primer lugar, estas disciplinas enfatizan la experimentación, la indagación y las experiencias prácticas, aspectos difíciles de trasladar por completo a sistemas computarizados. En segundo lugar, la naturaleza colaborativa, dinámica y multidisciplinaria de las actividades STEM dificulta que los sistemas adaptativos tradicionales identifiquen con precisión los procesos de aprendizaje y proporcionen apoyos adecuados. Finalmente, la evaluación en STEM suele centrarse más en el proceso que en los resultados finales, lo que exige indicadores de seguimiento más variados y complejos.

A partir de esta revisión, los autores identifican una brecha clara: aunque existen avances en inteligencia artificial, análisis de engagement y adaptive learning, todavía hay escasez de herramientas automatizadas capaces de medir de forma inmediata el engagement en actividades STEM y usar esa información para recomendar materiales adaptativos. Precisamente en respuesta a esta necesidad, el artículo propone el sistema **RASEDS**, que combina **computer vision**, **YOLOR** e **ICAP** para detectar el engagement en tiempo real y, sobre esa base, sugerir recursos de aprendizaje adaptativos. En síntesis, el estado del arte muestra que la literatura ha avanzado en la comprensión del engagement, la autoeficacia y el aprendizaje adaptativo, pero todavía persiste la necesidad de soluciones automatizadas y contextualizadas para la complejidad específica de la educación STEM.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una limitación importante en la literatura sobre educación STEM: aunque el engagement del estudiante es reconocido como un factor decisivo para el aprendizaje y el rendimiento, **medirlo con precisión sigue siendo un desafío**. Los autores señalan que los métodos más utilizados hasta ahora, como el **self-reporting** y la **observación**, presentan problemas importantes. En el caso del self-reporting, los cuestionarios o entrevistas realizados después de la actividad pueden verse afectados por errores de memoria, subjetividad o por la influencia de expectativas sociales. En cuanto a la observación, aunque permite una evaluación más directa del comportamiento, exige mucho tiempo, codificación manual y altos costos de trabajo, lo que la vuelve poco eficiente para contextos educativos dinámicos y continuos.

Otra crítica relevante que plantean es que, si bien en años recientes se han realizado avances con inteligencia artificial para estudiar engagement en ambientes educativos, muchos de esos trabajos se han desarrollado en **contextos de aprendizaje online o tradicionales**, y no en actividades STEM, que son mucho más complejas, abstractas y multidimensionales. Los autores mencionan investigaciones que utilizan expresiones faciales, movimientos del mouse, lectura digital o modelos de redes neuronales para analizar participación, pero consideran que todavía existe una carencia de sistemas automatizados realmente adecuados para el contexto particular de la educación STEM. En otras palabras, los avances existentes son valiosos, pero no resuelven completamente el problema en escenarios donde predominan el trabajo práctico, la interacción grupal y la resolución de problemas con materiales físicos.

Además, los autores critican indirectamente los enfoques de enseñanza tradicionales de tipo **one-size-fits-all**, porque no logran responder a las diferencias en conocimientos previos, estilos

de aprendizaje, intereses y habilidades de todos los estudiantes. Según el artículo, este tipo de enseñanza puede generar sentimientos de inseguridad, impotencia y desconexión, afectando no solo los resultados académicos, sino también el engagement y la autoeficacia. Aunque el aprendizaje adaptativo aparece como una solución prometedora, los autores sostienen que en el pasado su implementación en STEM fue limitada por la dificultad de evaluar automáticamente y en tiempo real el nivel de engagement del estudiante.

Por ello, la motivación del estudio consiste en cerrar esta brecha: desarrollar una herramienta que permita medir de forma inmediata, objetiva y automatizada el engagement en actividades STEM, y usar esa información para recomendar materiales adaptativos que fortalezcan tanto el engagement como la self-efficacy. Así, el artículo nace no solo de una necesidad técnica, sino también pedagógica: superar las limitaciones de métodos previos y ofrecer una respuesta más adecuada a la complejidad real del aprendizaje STEM.

Descripción del aporte del autor

El principal aporte del artículo radica en el desarrollo de un sistema inteligente denominado **RASEDS (Real-time Adaptive System based on Engagement Detection in STEM)**, cuyo objetivo es medir el nivel de engagement de los estudiantes en tiempo real durante actividades STEM y, en función de ello, recomendar materiales de aprendizaje adaptativos. Este aporte es relevante porque aborda simultáneamente dos problemas fundamentales en la educación actual: la dificultad de medir el compromiso del estudiante de forma objetiva y la necesidad de personalizar el aprendizaje según su nivel de participación y comprensión. A diferencia de otros estudios que analizan engagement o adaptive learning de manera separada, este trabajo integra ambos enfoques en un solo sistema funcional.

Uno de los aportes más importantes es la utilización de **computer vision e inteligencia artificial** para detectar el engagement de los estudiantes sin necesidad de cuestionarios ni intervención manual. El sistema RASEDS emplea el modelo **YOLOR (You Only Learn One Representation)** para reconocer objetos, expresiones faciales y comportamientos dentro del aula, lo que permite analizar de manera automática la participación del estudiante. Este enfoque representa una mejora significativa frente a métodos tradicionales como el self-reporting o la observación manual, ya que ofrece una medición más objetiva, continua y en tiempo real. En este sentido, el artículo aporta una solución tecnológica innovadora para uno de los principales desafíos en educación STEM.

Otro aporte clave es la integración del modelo de engagement con el **framework ICAP (Passive, Active, Constructive, Interactive)**. El sistema no solo detecta comportamientos, sino que los clasifica en estos cuatro niveles de compromiso cognitivo. De esta manera, el sistema puede distinguir si un estudiante está simplemente observando (pasivo), participando activamente (activo), generando nuevas ideas (constructivo) o interactuando con otros (interactivo). Esta clasificación permite una comprensión más profunda del proceso de aprendizaje, ya que no se limita a medir la participación superficial, sino que evalúa la calidad del compromiso cognitivo del estudiante.

Asimismo, el artículo aporta la conexión entre engagement y **self-efficacy**, incorporando este último como una variable clave dentro del sistema. Los autores destacan que un mayor nivel de engagement contribuye a fortalecer la confianza del estudiante en sus propias capacidades, lo que a su vez mejora su motivación y persistencia. El sistema RASEDS utiliza esta relación para recomendar materiales de aprendizaje que no solo respondan al nivel de participación del estudiante, sino que también contribuyan a mejorar su autoeficacia. Este enfoque aporta una dimensión psicológica importante, ya que no se centra únicamente en el rendimiento académico, sino también en el desarrollo personal del estudiante.

Otro aporte relevante del artículo es la capacidad del sistema para generar **recomendaciones adaptativas en tiempo real**. A partir del nivel de engagement detectado, el sistema sugiere recursos específicos, como materiales de apoyo, actividades adicionales o contenidos más avanzados, dependiendo del nivel de participación del estudiante. Esto permite que el aprendizaje se ajuste dinámicamente a las necesidades individuales, evitando tanto la sobrecarga como la falta de desafío. En este sentido, el sistema no solo detecta el problema, sino que también propone soluciones inmediatas, lo que mejora la efectividad del proceso educativo.

Además, el artículo aporta una implementación práctica del sistema en un entorno educativo STEM, lo que permite validar su funcionamiento en condiciones reales. Los resultados muestran que el uso de RASEDS mejora el engagement de los estudiantes, fortalece su self-efficacy y contribuye a un mejor desempeño académico. Este aporte es importante porque demuestra que la integración de inteligencia artificial y aprendizaje adaptativo puede tener un impacto positivo en el proceso educativo, especialmente en áreas donde el compromiso del estudiante es fundamental para el aprendizaje.

Otro aspecto destacable es que el sistema permite un **seguimiento continuo del estudiante**, lo que facilita la toma de decisiones tanto para el docente como para el propio alumno. El profesor puede identificar en qué momentos el estudiante pierde interés o presenta dificultades, mientras que el estudiante recibe recomendaciones que le ayudan a mejorar su desempeño. Este enfoque bidireccional fortalece la interacción entre tecnología y pedagogía, convirtiendo al sistema en una herramienta de apoyo tanto para la enseñanza como para el aprendizaje.

Finalmente, el artículo aporta una visión integradora del futuro de la educación STEM, donde tecnologías como la inteligencia artificial, la visión por computadora y el aprendizaje adaptativo trabajan de manera conjunta para crear entornos de aprendizaje más personalizados, eficientes y centrados en el estudiante. En conjunto, el aporte del estudio puede resumirse en tres niveles: primero, propone un método innovador para medir engagement en tiempo real; segundo, integra este análisis con un sistema de recomendación adaptativa; y tercero, demuestra su efectividad en un contexto educativo real. Este enfoque convierte al trabajo en una contribución significativa al campo de la educación tecnológica y el aprendizaje personalizado.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para desarrollar su aporte se basa en una metodología estructurada que combina análisis teórico, diseño de sistema inteligente, desarrollo tecnológico y validación en un entorno educativo STEM. En primer lugar, los autores parten de una revisión del estado del arte, donde identifican dos problemas clave: la dificultad para medir el engagement de manera objetiva y en tiempo real, y la limitada integración de esta información en sistemas de aprendizaje adaptativo. A partir de esta brecha, plantean como objetivo el desarrollo de un sistema que permita detectar el nivel de engagement de los estudiantes y utilizar esa información para personalizar el aprendizaje.

El segundo paso del proceso consiste en el diseño conceptual del sistema **RASEDS (Real-time Adaptive System based on Engagement Detection in STEM)**. En esta etapa, los autores definen los componentes principales del sistema, estableciendo que debe integrar tecnologías de **computer vision**, modelos de inteligencia artificial y un marco teórico de engagement como ICAP. Además, determinan que el sistema debe ser capaz de operar en tiempo real, detectar el comportamiento del estudiante durante las actividades y generar recomendaciones adaptativas. Este diseño inicial permite estructurar la arquitectura del sistema y definir sus funciones principales.

Posteriormente, los autores desarrollan el componente tecnológico del sistema, basado en el modelo de detección de objetos **YOLOR (You Only Learn One Representation)**. Este

modelo permite identificar elementos relevantes en el entorno del aula, como expresiones faciales, gestos, materiales de trabajo y acciones del estudiante. A partir de estos datos, el sistema procesa la información y la traduce en indicadores de engagement. Este paso es clave, ya que convierte señales visuales en información útil para el análisis del aprendizaje.

El siguiente paso es la integración del sistema con el **framework ICAP**, que permite clasificar el nivel de engagement en cuatro categorías: pasivo, activo, constructivo e interactivo. Esta clasificación se realiza a partir de los datos capturados por el sistema de visión artificial, lo que permite evaluar el grado de participación del estudiante de manera estructurada. Este enfoque aporta un marco teórico sólido que respalda la interpretación de los datos obtenidos.

Una vez establecido el sistema de detección y clasificación, los autores incorporan un módulo de **recomendación adaptativa**. Este módulo utiliza la información sobre el nivel de engagement del estudiante para sugerir materiales de aprendizaje adecuados, como recursos de refuerzo o actividades más complejas. De esta manera, el sistema no solo analiza el comportamiento del estudiante, sino que también interviene activamente en su proceso de aprendizaje, ajustando el contenido según sus necesidades.

Finalmente, los autores implementan el sistema en un entorno educativo STEM y realizan su validación mediante la observación de su impacto en el engagement y la autoeficacia de los estudiantes. Durante esta fase, recopilan datos sobre el comportamiento de los alumnos y analizan cómo el uso del sistema influye en su participación y desempeño. Los resultados obtenidos permiten confirmar la efectividad del sistema y consolidar el aporte del estudio.

En conjunto, el proceso seguido por los autores combina diagnóstico del problema, diseño conceptual, desarrollo tecnológico, integración de modelos teóricos y validación en contexto real. Gracias a este enfoque integral, logran desarrollar un sistema innovador que mide el engagement en tiempo real y lo utiliza para mejorar el aprendizaje en educación STEM.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema de la dificultad de medir el engagement en educación STEM y usarlo para personalizar el aprendizaje se desarrolla en varias etapas articuladas entre sí. El problema central que identifican es que, en este tipo de educación, las actividades son prácticas, colaborativas, complejas y multidimensionales, por lo que los métodos tradicionales de medición del compromiso del estudiante, como cuestionarios o observación manual, resultan insuficientes, lentos o poco objetivos. Frente a esta limitación, los autores proponen un proceso basado en inteligencia artificial, visión por computadora y aprendizaje adaptativo, con el objetivo de detectar el nivel de engagement de los estudiantes en tiempo real y, a partir de ello, ofrecer materiales de aprendizaje más adecuados a sus necesidades.

El primer paso del proceso consistió en reunir datos reales del comportamiento de los estudiantes en actividades STEM. Para ello, antes del experimento principal, los autores organizaron tres sesiones del taller **“STEM Workshop: Python and Raspberry Pi Practical Activity”**, en las que participaron 86 estudiantes. Estas sesiones permitieron captar imágenes y videos de los alumnos mientras desarrollaban tareas prácticas con Raspberry Pi, programación y resolución de problemas. Las cámaras fueron ubicadas estratégicamente para registrar las manos de los estudiantes y su interacción con los materiales de aprendizaje, ya que esta información sería la base para reconocer el engagement. A partir de estos talleres se recopiló un conjunto de 4515 imágenes, que luego se dividió en un conjunto de entrenamiento y otro de prueba para desarrollar el sistema.

El segundo paso fue el desarrollo del sistema **RASEDS (Real-time Automated STEM Engagement Detection System)**. Este sistema utiliza el modelo de detección de objetos

YOLOR para reconocer tanto las manos de los estudiantes como los materiales con los que interactúan, por ejemplo tablet, laptop, mouse, Raspberry Pi y celular. El criterio central fue identificar si existía interacción entre la mano y el material mediante el cálculo de **Intersection over Union (IoU)**, usando un umbral de 0.7. Si había superposición suficiente, se infería una conducta de aprendizaje determinada. Así, el sistema no se limitó a observar si el estudiante estaba presente, sino que analizó de manera concreta cómo participaba durante la actividad STEM. En la *Figura 3 del artículo (página 9)* se muestra precisamente la arquitectura general de RASEDS, donde se observa cómo la entrada visual pasa por YOLOR, luego se interpreta con el marco ICAP y finalmente produce un nivel de engagement.

El tercer paso consistió en vincular estas conductas observadas con el **marco teórico ICAP**, que clasifica el engagement en cuatro niveles: **pasivo, activo, constructivo e interactivo**. Los autores definieron una correspondencia entre determinadas acciones observables y cada una de estas categorías. Por ejemplo, manipular una tablet se interpretó como comportamiento activo; trabajar con laptop, mouse o Raspberry Pi para construir el proyecto se consideró constructivo; e interactuar con otros compañeros se clasificó como interactivo. De esta manera, el sistema no solo detectó objetos y movimientos, sino que los transformó en una interpretación pedagógica del nivel de involucramiento cognitivo del estudiante. Este paso fue esencial porque permitió pasar de datos visuales brutos a información educativa significativa.

El cuarto paso fue crear un mecanismo para que esa detección del engagement se transformara en **aprendizaje adaptativo**. Para ello, los autores construyeron un **modelo de predicción del rendimiento STEM**, usando como variables independientes los porcentajes de cada tipo de engagement detectado por RASEDS, y como variable dependiente el puntaje obtenido por los estudiantes en sus proyectos STEM, evaluados por dos expertos con la matriz **CPAM**. Tras comparar varios modelos de regresión, eligieron **Elastic Net Regression**, por presentar el menor error y la mayor capacidad explicativa. Con esta fórmula, el sistema podía estimar el nivel de logro del estudiante a partir de su patrón de engagement observado. A partir de esa predicción, se diseñó la recomendación adaptativa: a los estudiantes con mayor rendimiento esperado se les asignaban materiales más desafiantes; a quienes mostraban menor rendimiento esperado, materiales más simples, con más anotaciones y apoyos.

El quinto paso fue llevar este proceso a una validación en contexto real mediante un **diseño cuasi experimental**. Participaron 87 estudiantes del curso *Networks Embedded System and Application*, divididos en un grupo control y un grupo experimental. Ambos grupos recibieron dos horas de instrucción teórica común, pero en la última hora semanal se diferenciaban: el grupo control trabajó con materiales estándar, mientras que el grupo experimental recibió materiales adaptativos recomendados según los resultados de RASEDS. Este procedimiento se mantuvo durante cinco semanas. Antes y después de la intervención, se aplicaron pruebas para medir engagement y self-efficacy. En la *Figura 5 del artículo (página 15)* se observa con claridad esta secuencia experimental, donde el grupo experimental recibe recomendaciones basadas en RASEDS y el grupo control sigue actividades tradicionales.

Finalmente, el problema se resuelve mediante la evaluación de los resultados obtenidos. El sistema demostró que podía identificar el engagement con una precisión cercana a la de expertos humanos y que la recomendación adaptativa basada en esos resultados mejoró significativamente el engagement cognitivo, conductual y emocional, además de aumentar la self-efficacy de los estudiantes. En conjunto, el proceso propuesto transforma una limitación clásica de la educación STEM —la dificultad para medir el compromiso del estudiante y actuar a tiempo— en una solución automatizada, objetiva y pedagógicamente útil, donde la inteligencia artificial se pone al servicio de la personalización del aprendizaje.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, los autores emplean métricas tanto **técnicas** como **educativas** para evaluar el desempeño del sistema RASEDS. En el ámbito técnico, utilizan indicadores propios de modelos de visión por computadora y detección de objetos, como **precision, recall y mean Average Precision (mAP)**, para medir la capacidad del modelo **YOLOR** en la identificación de manos y materiales utilizados por los estudiantes. Estos indicadores permiten verificar qué tan bien el sistema reconoce las interacciones dentro del entorno STEM, siendo fundamentales para garantizar la fiabilidad de la detección del engagement. Los resultados muestran que el modelo alcanza un alto nivel de precisión, cercano al desempeño de evaluadores humanos, lo que valida su uso en escenarios educativos reales.

En cuanto a la medición educativa, los autores utilizan métricas basadas en el **framework ICAP**, calculando el porcentaje de tiempo o frecuencia en que el estudiante se encuentra en cada nivel de engagement: pasivo, activo, constructivo e interactivo. Estas métricas se combinan con una **evaluación del rendimiento STEM**, realizada mediante la matriz **CPAM**, aplicada por expertos para calificar los proyectos desarrollados por los estudiantes. Además, se emplean instrumentos para medir la **self-efficacy** antes y después de la intervención, así como pruebas estadísticas como el **t-test** para comparar diferencias entre el grupo control y el grupo experimental.

Respecto a los resultados, el sistema demostró que puede detectar el engagement con un nivel de precisión comparable al de expertos humanos, lo cual es un avance importante frente a métodos tradicionales. En el experimento, el grupo que utilizó RASEDS con aprendizaje adaptativo mostró **mejoras significativas en engagement cognitivo, conductual y emocional**, así como en self-efficacy, en comparación con el grupo control. Asimismo, el modelo de regresión utilizado (Elastic Net) permitió predecir con buena precisión el rendimiento de los estudiantes a partir de sus patrones de engagement, lo que confirma la relación entre participación activa y logro académico.

Al analizar estos resultados, se puede afirmar que son superiores a los enfoques tradicionales, especialmente porque superan las limitaciones del self-reporting y la observación manual, ofreciendo una medición objetiva, automatizada y en tiempo real. Además, a diferencia de otros estudios que solo analizan engagement o adaptive learning por separado, este trabajo demuestra que la integración de ambos genera mejores resultados en términos de participación, motivación y desempeño. Sin embargo, el artículo también deja claro que estos resultados dependen del contexto STEM y del diseño de la intervención, por lo que su generalización a otros entornos debe evaluarse con cautela.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte innovador y muy relevante para la educación STEM, porque propone una solución concreta a un problema que suele ser difícil de abordar: medir el engagement de los estudiantes de manera objetiva y utilizar esa información para personalizar el aprendizaje. Una de sus principales fortalezas es que integra **computer vision, inteligencia artificial, el marco ICAP y adaptive learning** en un solo sistema, lo que le da un alto valor metodológico y tecnológico. Además, el estudio no se queda en la propuesta teórica, sino que valida el sistema en un contexto educativo real, mostrando mejoras significativas en engagement y self-efficacy del grupo experimental.

Sin embargo, una primera observación crítica es que el estudio se desarrolla en un contexto bastante específico: un curso universitario vinculado a sistemas embebidos, con estudiantes de ingeniería de una universidad del sur de Taiwán. Esto significa que, aunque los resultados son prometedores, todavía no se puede afirmar con total seguridad que el sistema tendría el mismo

impacto en otras áreas STEM, en otros niveles educativos o en contextos culturales diferentes. La muestra, además, no es excesivamente grande, lo que también limita el alcance generalizable de los hallazgos.

Otra crítica importante es que el sistema depende bastante de condiciones técnicas controladas, como la ubicación de cámaras, la visibilidad de las manos y de los materiales, y la correcta detección de objetos. Los propios resultados muestran que algunos errores de identificación pueden aparecer por problemas de ángulo u obstrucción. Esto sugiere que, aunque RASEDS funciona bien en condiciones relativamente preparadas, su aplicación masiva en aulas reales más complejas podría enfrentar dificultades técnicas adicionales.

Asimismo, aunque el artículo demuestra mejoras en engagement y autoeficacia, no profundiza tanto en el impacto a largo plazo sobre el aprendizaje profundo o el desarrollo sostenido de competencias STEM. Es decir, el sistema parece útil para mejorar la experiencia inmediata y la participación, pero todavía sería necesario investigar si estos beneficios se mantienen en el tiempo o se traducen en logros más amplios dentro de la formación académica.

En síntesis, el artículo es sólido, novedoso y metodológicamente fuerte, pero aún necesita más validaciones en distintos contextos y una exploración más profunda de sus efectos a largo plazo. Aun así, representa un avance importante en la integración de inteligencia artificial y aprendizaje adaptativo dentro de la educación STEM.

8. ARTICULO 08

Author (s): Riad, M.; Qbadou, M.; Aoula, E.; Gouraguine, S.

Title of paper: La nueva técnica de adaptación del aprendizaje electrónico se basa en el estilo de aprendizaje y la motivación del alumno.

Journal: Journal of Education and Learning (EduLearn)

Volume (issue): 17(3)

pag – pag (year): 472–482 (2023)

Estado del arte que hace el autor

El estado del arte presentado por los autores se desarrolla dentro del contexto del crecimiento acelerado del **e-learning**, especialmente reforzado desde la pandemia de COVID-19. El artículo parte de la idea de que el aprendizaje en línea ofrece ventajas importantes, como la posibilidad de estudiar en cualquier momento y lugar, pero también plantea un reto central: **cómo recomendar a cada estudiante los objetos de aprendizaje más adecuados según sus necesidades específicas**. En ese sentido, los autores sitúan su trabajo dentro del campo de los **sistemas adaptativos de e-learning**, cuyo objetivo es personalizar de manera dinámica el contenido educativo según el perfil individual de cada aprendiz.

Dentro de esta revisión, los autores destacan que uno de los principales objetivos de la personalización del aprendizaje es ofrecer a los estudiantes entornos coherentes con sus **preferencias, intereses y características individuales**. Para ello, dos conceptos aparecen como especialmente importantes en la literatura: los **learning styles (LS)** y los **learning objects (LOs)**. Los estilos de aprendizaje permiten describir las preferencias del estudiante sobre cómo aprender, mientras que los objetos de aprendizaje representan las unidades de contenido, recursos o actividades que pueden utilizarse para enseñar. Numerosos estudios previos han intentado combinar ambos elementos, de modo que al estudiante se le presenten objetos de aprendizaje acordes con su estilo. Desde esta perspectiva, los sistemas tutoriales inteligentes y los entornos adaptativos han venido trabajando precisamente en esa relación entre estilo y recurso educativo.

El estado del arte también muestra que la finalidad central de los sistemas adaptativos en e-learning es **predecir las preferencias del estudiante respecto a objetos de aprendizaje poco usados o aún no explorados**, a partir de su comportamiento previo. Para lograrlo, la literatura ha insistido en que no basta con conocer solo el resultado de una actividad, sino que es necesario considerar otros rasgos individuales, como **estilo de aprendizaje, nivel de conocimiento, preferencias y necesidades particulares**. En esta línea, el artículo subraya la importancia de construir escenarios pedagógicos personalizados, capaces de ajustarse al estilo del estudiante y de sugerir de manera inteligente los objetos de aprendizaje que más podrían favorecer su proceso formativo.

Otro aspecto importante del estado del arte es la revisión de los **métodos de recomendación y adaptación** utilizados en entornos e-learning. Los autores señalan que en la última década se han desarrollado numerosas técnicas, especialmente en aprendizaje informal, y destacan que la mayoría de sistemas adaptativos pueden agruparse en cuatro grandes categorías: **collaborative filtering (CF)**, **content-based filtering (CBF)**, **demographic filtering (DF)** y **knowledge filtering (KF)**. El collaborative filtering recomienda recursos según las valoraciones de otros usuarios; el content-based filtering se apoya en las características del contenido y del usuario; el demographic filtering utiliza información demográfica como edad, género o nacionalidad; y el knowledge filtering genera recomendaciones a partir del conocimiento experto sobre las características del recurso y los intereses del usuario. Esta clasificación permite ver que el campo ya cuenta con una base metodológica amplia, aunque todavía con espacio para mejorar en precisión y personalización.

Además, los autores revisan varias propuestas concretas previas. Se mencionan trabajos que personalizan recursos a partir de la cartografía entre estilos de aprendizaje y objetos de aprendizaje, sistemas basados en ontologías para recomendar recursos adecuados al perfil del estudiante, modelos híbridos que combinan **association rule mining** con **collaborative filtering**, y enfoques que integran **deep learning**, **genetic algorithms**, **reinforcement learning** o tecnologías semánticas. También se citan sistemas de recomendación para plataformas K12, modelos basados en perfiles profundos del estudiante y métodos que incorporan estilos de aprendizaje online dentro de algoritmos colaborativos. En conjunto, esta revisión muestra que existe una intensa actividad investigadora en la personalización del aprendizaje, con múltiples enfoques algorítmicos y arquitecturas de recomendación.

Sin embargo, el estado del arte también evidencia varias limitaciones de las propuestas existentes. Los autores señalan que muchas investigaciones se enfocan sobre todo en la respuesta del estudiante o en sus valoraciones, pero no consideran suficientemente **otros indicadores de desempeño**, como la **motivación**. Precisamente aquí se encuentra una de las contribuciones conceptuales del artículo: mientras gran parte de la literatura prioriza estilo de aprendizaje y objetos de aprendizaje, este trabajo introduce además el **motivation score** como un elemento clave para afinar la adaptación. Según los autores, incluir el nivel de motivación permite construir escenarios pedagógicos más ajustados y mejorar la precisión en la selección de objetos de aprendizaje realmente apropiados para cada estudiante.

Otro elemento del estado del arte es la importancia de la **estructura del dominio pedagógico**. El artículo plantea que para simplificar la adaptación, los recursos deben organizarse jerárquicamente en varios niveles: actividad de aprendizaje, capítulos, unidades y objetos de aprendizaje. Cada objeto puede tener propiedades como autonomía, accesibilidad, adaptabilidad, durabilidad, reutilización e indexación. Esta organización es relevante porque permite pasar de trayectorias lineales tradicionales, donde todos los estudiantes siguen el mismo camino, hacia rutas no lineales y personalizadas, donde se seleccionan solo los objetos que realmente se ajustan al perfil del aprendiz. En las *Figuras 2, 3 y 4 del artículo (páginas 5 y 6)* se aprecia precisamente esta diferencia entre un camino lineal tradicional y un camino adaptativo moderno, mucho más flexible.

En síntesis, el estado del arte desarrollado por los autores muestra que el e-learning adaptativo ha avanzado considerablemente gracias a la combinación de estilos de aprendizaje, objetos de aprendizaje y algoritmos de recomendación. No obstante, también deja claro que persisten vacíos en la precisión de la adaptación, especialmente por la poca consideración de variables como la motivación del estudiante. Desde esa brecha, el artículo justifica su propuesta de una nueva técnica de adaptación basada en **learning style + motivation score**, apoyada en **collaborative filtering**, **CPCC**, **ACOS** y **KNN**, con el fin de mejorar la calidad del aprendizaje y responder de manera más fina a las necesidades individualizadas de los estudiantes.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una limitación clara en los sistemas adaptativos de e-learning existentes: aunque en la literatura ya se han propuesto numerosos enfoques para personalizar el aprendizaje, todavía sigue siendo un gran desafío **recomendar a cada estudiante los objetos de aprendizaje más apropiados según sus necesidades reales**. Los autores reconocen que muchas investigaciones anteriores han avanzado en la relación entre **learning styles** y **learning objects**, y que varios sistemas de recomendación han utilizado técnicas como collaborative filtering, content-based filtering, ontologías, reglas de asociación, deep learning o algoritmos genéticos. Sin embargo, consideran que estas propuestas aún no logran una adaptación suficientemente precisa y completa.

Una crítica importante que plantean es que gran parte de los estudios previos se enfoca sobre todo en la **respuesta del estudiante** o en sus valoraciones dentro del sistema, pero no incorpora

con suficiente profundidad otros indicadores que también revelan el desempeño y las necesidades del aprendiz. En particular, los autores señalan que variables como el **motivation score** suelen quedar fuera del proceso de modelado adaptativo, a pesar de que pueden influir directamente en la calidad del aprendizaje y en la pertinencia de la recomendación pedagógica. Desde esta perspectiva, consideran insuficiente que la adaptación dependa solo del estilo de aprendizaje o del historial de interacción.

Asimismo, el artículo critica implícitamente que muchos sistemas adaptativos todavía siguen funcionando con trayectorias de aprendizaje poco flexibles o con secuencias que no responden realmente a las diferencias individuales de los estudiantes. Aunque algunos enfoques logran recomendar recursos, no siempre construyen un **escenario pedagógico personalizado** que ordene y seleccione los objetos de aprendizaje de la forma más adecuada para cada perfil. Por ello, los autores insisten en la necesidad de un sistema que no solo recomiende recursos, sino que también organice una ruta de aprendizaje ajustada al estudiante en función de su estilo y su motivación.

Otra crítica relevante es que los algoritmos existentes presentan limitaciones en la precisión de la adaptación. En respuesta a ello, los autores proponen apoyarse en **collaborative filtering, constrained Pearson correlation coefficient, adjusted cosine measure y K-nearest neighbor**, con la intención de mejorar la calidad de la recomendación. Su motivación, entonces, no es únicamente técnica, sino también pedagógica: desarrollar un método que permita construir un escenario de aprendizaje más eficaz, más preciso y más coherente con las características individuales del estudiante. En síntesis, el artículo nace de la necesidad de superar enfoques que personalizan parcialmente el aprendizaje y avanzar hacia una adaptación más inteligente, donde el **learning style** y el **motivation score** se combinen para responder mejor a las necesidades de cada aprendiz.

Descripción del aporte del autor

El principal aporte del artículo consiste en proponer una **nueva técnica de adaptación para entornos e-learning** basada en dos variables pedagógicas centrales: el **learning style** del estudiante y su **motivation score**. A diferencia de muchos trabajos previos que centran la adaptación solamente en las respuestas del usuario, en sus valoraciones o en el emparejamiento entre estilos de aprendizaje y objetos de aprendizaje, este estudio amplía el modelo adaptativo incorporando la motivación como un criterio adicional para mejorar la precisión de la recomendación. Este aporte es importante porque reconoce que el aprendizaje no depende únicamente de preferencias cognitivas, sino también del nivel de implicación y motivación del estudiante frente a los recursos educativos.

Uno de los aportes más relevantes del trabajo es la construcción de una **propuesta conceptual de sistema adaptativo e inteligente** que toma en cuenta características pedagógicas del aprendiz, especialmente su estilo de aprendizaje y su puntuación de motivación, para ajustar de forma dinámica el contenido y la secuencia de actividades. Los autores explican que, en lugar de asumir un camino lineal igual para todos los estudiantes, el sistema busca generar **learning paths personalizados**, apoyándose en la similitud entre estudiantes con características parecidas y trayectorias previas semejantes. Este enfoque representa una contribución valiosa porque se orienta a construir un escenario pedagógico más flexible, más ajustado al perfil individual y, por tanto, con mayor potencial para mejorar la calidad del aprendizaje.

Otro aporte clave del artículo es la integración de **métodos de recomendación colaborativa con medidas de similitud más refinadas**, concretamente **Collaborative Filtering (CF)**, **Constrained Pearson Correlation Coefficient (CPCC)**, **Adjusted Cosine Measure (ACOS)** y el algoritmo **K-Nearest Neighbor (KNN)**. Esta combinación metodológica permite identificar comunidades de estudiantes homogéneos en términos de estilo de aprendizaje y motivación, y luego utilizar esa información para recomendar objetos de aprendizaje más

adecuados. Los autores no se limitan a aplicar una técnica aislada, sino que proponen una arquitectura híbrida que busca elevar la precisión de la adaptación en comparación con enfoques más simples.

Además, el artículo aporta una **nueva medida de similitud propuesta por los autores**, denominada en el texto como **NewSM**, diseñada específicamente para superar ciertas limitaciones de las medidas tradicionales. Esta nueva formulación no solo considera la similitud entre estudiantes basada en su estilo de aprendizaje, sino que añade el **motivation score** como un factor de ponderación para jerarquizar mejor las adaptaciones provenientes de otros aprendices. En otras palabras, las recomendaciones de estudiantes con niveles de motivación más altos o más relevantes para el perfil del usuario objetivo reciben un mayor peso dentro del proceso adaptativo. Este es uno de los aportes más originales del artículo, ya que constituye una mejora concreta sobre las métricas convencionales de similitud.

Un aporte metodológico importante es también la formulación del **motivation score** como una variable calculable dentro del sistema. Según el artículo, esta puntuación se construye a partir de distintos componentes, como el **feedback explícito**, el **feedback implícito** y la **calificación obtenida por el estudiante al final de cada capítulo**. Esto permite que la motivación deje de ser una noción abstracta y pase a operar como un dato funcional dentro del modelo adaptativo. Gracias a ello, el sistema puede revisar el escenario pedagógico cuando el estudiante fracasa en una fase inicial y proponer nuevas actividades u objetos de aprendizaje acordes con su motivación y desempeño.

Asimismo, el artículo aporta una propuesta clara para la **organización del dominio pedagógico** del sistema adaptativo. Los autores estructuran el contenido en cuatro niveles jerárquicos: **learning activity (curso)**, **chapters (conceptos)**, **learning unit** y **learning objects (LOs)**. Esta organización, presentada visualmente en la *Figura 2 del artículo (página 5)*, permite que la adaptación no se limite a recomendar recursos aislados, sino que forme parte de una arquitectura didáctica coherente. Cada objeto de aprendizaje es descrito además por propiedades relevantes como autonomía, adaptación, indexación, accesibilidad, durabilidad y reutilización. Este aporte es importante porque ofrece una base estructural para que la personalización se desarrolle de forma ordenada y escalable dentro del sistema.

Otro aporte fuerte del trabajo es la comparación entre un **learning path lineal tradicional** y un **learning path no lineal y personalizado**. En la *Figura 3 del artículo (página 5)* se muestra cómo, en un sistema tradicional, todos los estudiantes siguen la misma secuencia de objetos de aprendizaje. En cambio, la *Figura 4 (página 5)* ilustra cómo en el sistema moderno adaptativo cada estudiante puede recibir una secuencia distinta, donde ciertos objetos se omiten porque no se ajustan a su perfil. Esta visualización refuerza uno de los aportes pedagógicos del estudio: demostrar que una adaptación más fina no solo consiste en recomendar un recurso, sino en construir una trayectoria de aprendizaje específica para cada estudiante.

Además, el artículo aporta evidencia experimental a través del uso del dataset **MovieLens100K**, compuesto por **943 learners** y **1,682 learning objects**, con el que los autores evalúan la efectividad de su técnica. Aunque el conjunto de datos proviene originalmente de un entorno de recomendación más general, los autores lo emplean como base para validar su enfoque adaptativo. La evaluación se realiza con la métrica **Mean Absolute Error (MAE)** y también se menciona el uso del **F-measure** para valorar el desempeño. Los experimentos muestran que al incorporar el motivation score junto con el learning style, la técnica mejora la calidad de la adaptación y permite seleccionar objetos de aprendizaje más adecuados para el usuario. Este aporte empírico es importante porque respalda con resultados cuantitativos la propuesta metodológica del artículo.

El estudio también aporta una interpretación clara de los resultados obtenidos con el algoritmo **KNN** y diferentes tamaños de vecindad. Los autores muestran que el rendimiento mejora a

medida que aumenta el número de vecinos y que ciertos valores, como **K=130**, alcanzan mejores resultados en términos de MAE que otras configuraciones. En las *Figuras 5, 6 y 7 del artículo (páginas 8 y 9)* se presentan estas comparaciones entre enfoques convencionales y personalizados. A partir de estos resultados, el artículo contribuye no solo con una nueva idea conceptual, sino también con parámetros prácticos para la implementación de sistemas adaptativos similares.

Finalmente, uno de los aportes más importantes del artículo es su conclusión pedagógica: la combinación de **learning style + motivation score** mejora la calidad del sistema de aprendizaje adaptativo y permite mantener la adaptación actualizada según la evolución del estudiante. Los autores sostienen que su propuesta puede satisfacer mejor las necesidades personalizadas del aprendiz y favorecer una experiencia de aprendizaje más coherente y efectiva. En este sentido, el trabajo no solo propone un algoritmo, sino una visión más completa de la personalización educativa, donde la adaptación debe responder tanto a las preferencias cognitivas como al estado motivacional del estudiante.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en una metodología estructurada que combina el análisis del problema, el diseño de un modelo adaptativo, la integración de técnicas de recomendación y la validación experimental. En primer lugar, los autores parten de la identificación de una limitación en los sistemas de e-learning existentes: aunque muchos de ellos utilizan estilos de aprendizaje o datos de interacción para personalizar contenidos, no logran una adaptación suficientemente precisa porque no consideran variables adicionales como la motivación del estudiante. A partir de este diagnóstico, plantean la necesidad de desarrollar una técnica que integre tanto el **learning style** como el **motivation score** para mejorar la calidad de la recomendación de objetos de aprendizaje.

El segundo paso consiste en el diseño conceptual del modelo adaptativo. En esta etapa, los autores definen la estructura del sistema, estableciendo que el proceso de personalización debe basarse en la similitud entre estudiantes con características comunes. Para ello, se propone utilizar técnicas de **collaborative filtering (CF)** que permitan identificar grupos de estudiantes con perfiles similares y aprovechar sus experiencias previas para recomendar contenidos. Además, se plantea la incorporación de medidas de similitud más avanzadas, como **Constrained Pearson Correlation Coefficient (CPCC)** y **Adjusted Cosine Measure (ACOS)**, con el objetivo de mejorar la precisión del sistema.

Posteriormente, los autores desarrollan una **nueva medida de similitud (NewSM)** que constituye uno de los elementos centrales de su aporte. Esta medida combina el estilo de aprendizaje y el nivel de motivación del estudiante para calcular la similitud entre usuarios de manera más precisa. A diferencia de los enfoques tradicionales, que consideran únicamente las valoraciones o preferencias, esta nueva métrica introduce un componente pedagógico adicional que permite jerarquizar mejor las recomendaciones. Este paso es clave, ya que mejora el núcleo del sistema adaptativo.

El siguiente paso del proceso es la definición del **motivation score** como una variable operativa dentro del sistema. Los autores establecen que esta puntuación se calcula a partir de elementos como el feedback del estudiante (explícito e implícito) y sus resultados en las actividades de aprendizaje. De esta manera, la motivación deja de ser un concepto abstracto y se convierte en un dato cuantificable que puede ser utilizado en el proceso de recomendación. Este componente permite que el sistema se adapte no solo a las preferencias del estudiante, sino también a su nivel de compromiso y desempeño.

Una vez definido el modelo, los autores implementan el algoritmo de recomendación utilizando el método **K-Nearest Neighbor (KNN)**. Este algoritmo permite identificar los estudiantes más

similares (vecinos) y utilizar su información para predecir qué objetos de aprendizaje serían más adecuados para el usuario objetivo. Además, se realizan pruebas con diferentes tamaños de vecindad para determinar cuál ofrece mejores resultados, lo que contribuye a optimizar el rendimiento del sistema.

Finalmente, el proceso se completa con la **validación experimental** del modelo. Para ello, los autores utilizan el dataset **MovieLens100K**, adaptándolo al contexto educativo, y aplican métricas como el **Mean Absolute Error (MAE)** para evaluar la precisión de las recomendaciones. Los resultados obtenidos permiten comparar el desempeño del modelo propuesto con enfoques tradicionales, demostrando que la incorporación del motivation score mejora la calidad de la adaptación.

En conjunto, el proceso seguido por los autores combina diagnóstico del problema, diseño conceptual, desarrollo de nuevas métricas, implementación algorítmica y validación experimental. Gracias a esta metodología, logran construir un sistema adaptativo más preciso y alineado con las características reales del estudiante, lo que constituye el núcleo de su aporte.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema de la baja precisión en la personalización de los sistemas e-learning se basa en la construcción de un modelo adaptativo que combine **learning style** y **motivation score** para recomendar objetos de aprendizaje más adecuados. El problema central identificado es que los sistemas tradicionales no logran ajustar correctamente el contenido a cada estudiante porque consideran información limitada, como valoraciones o preferencias, sin integrar factores más profundos del proceso educativo. Frente a ello, los autores proponen un proceso estructurado que permite mejorar la adaptación mediante técnicas de recomendación avanzadas y variables pedagógicas adicionales.

El primer paso del proceso consiste en la **identificación del perfil del estudiante**. Para ello, el sistema recoge información relacionada con su estilo de aprendizaje y su comportamiento dentro del entorno educativo. Esta información permite caracterizar al estudiante y establecer una base para la personalización. A diferencia de enfoques tradicionales, aquí no solo se consideran preferencias, sino también aspectos relacionados con el desempeño y la interacción del estudiante con los contenidos.

El segundo paso es la **incorporación del motivation score**, que representa el nivel de compromiso del estudiante con el aprendizaje. Esta puntuación se calcula a partir de diferentes elementos, como el feedback recibido, la interacción con los objetos de aprendizaje y los resultados obtenidos en las actividades. De esta manera, el sistema no solo identifica qué tipo de contenido prefiere el estudiante, sino también su nivel de motivación para aprender. Este paso es clave porque permite ajustar la dificultad y el tipo de recursos a la situación real del estudiante.

El tercer paso consiste en el **cálculo de la similitud entre estudiantes** mediante técnicas de collaborative filtering. Utilizando medidas como CPCC, ACOS y la nueva métrica propuesta (NewSM), el sistema identifica a los estudiantes con perfiles similares en términos de estilo de aprendizaje y motivación. A partir de esta similitud, se construye una comunidad de usuarios cuyos datos sirven como referencia para generar recomendaciones. Este enfoque permite aprovechar la experiencia de otros estudiantes para mejorar la personalización.

El cuarto paso es la **predicción y recomendación de objetos de aprendizaje**. Mediante el algoritmo KNN, el sistema selecciona los vecinos más cercanos y utiliza su información para predecir qué objetos de aprendizaje son más adecuados para el estudiante objetivo. Esta

predicción no es estática, sino que se ajusta dinámicamente según la evolución del estudiante, lo que permite una adaptación continua a lo largo del proceso de aprendizaje.

El quinto paso es la **generación de rutas de aprendizaje personalizadas**. A diferencia de los modelos tradicionales lineales, el sistema construye trayectorias no lineales, donde cada estudiante puede seguir un camino diferente según sus características. Esto implica que algunos objetos de aprendizaje pueden ser omitidos o reemplazados por otros más adecuados, lo que mejora la eficiencia del proceso educativo.

Finalmente, el proceso se completa con la **evaluación y ajuste del sistema**, utilizando métricas como MAE para medir la precisión de las recomendaciones. A partir de estos resultados, el sistema puede optimizar sus parámetros y mejorar su desempeño.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, los autores emplean principalmente métricas de **precisión de predicción** para evaluar el rendimiento de su técnica de adaptación. La métrica central es el **Mean Absolute Error (MAE)**, utilizada para medir la diferencia entre la valoración predicha de un objeto de aprendizaje y la valoración real del estudiante. Según los autores, mientras más bajo sea el valor de MAE, mejor es el desempeño del algoritmo. Además, mencionan también el uso del **F-measure**, entendido como la media armónica ponderada entre precisión y recall, aunque en la discusión experimental el énfasis principal recae en el MAE. Estas métricas permiten comparar el comportamiento de su propuesta frente a enfoques convencionales de recomendación y adaptación.

Para realizar la validación, los autores utilizan el dataset **MovieLens100K**, conformado por **943 learners, 1,682 learning objects y 100,000 ratings**, con una densidad del **6.3%**. El conjunto de datos se divide en **80% para entrenamiento y 20% para prueba**. A partir de allí, aplican el algoritmo **KNN** con diferentes medidas de similitud, especialmente **CPCC** y **ACOS**, y comparan el rendimiento de enfoques tradicionales frente a su propuesta personalizada que incorpora **learning style** y **motivation score**. Los experimentos muestran que al variar el número de vecinos (**K**) se observan mejoras en la precisión, y que a partir de ciertos valores el MAE se estabiliza en niveles más bajos. Por ejemplo, en una de las comparaciones los autores señalan que desde **K=45** el valor de **MAE** se vuelve estable alrededor de **0.7** para CPCC y ACOS. Además, en otra prueba concluyen que el mejor desempeño del algoritmo KNN con múltiples medidas de similitud se obtiene aproximadamente con **K=85**, y en otra comparación encuentran que **K=130** ofrece el mejor valor de predicción porque alcanza el menor MAE.

En cuanto a los resultados, los autores sostienen que la consideración conjunta del **learning style** y del **motivation score** permite satisfacer mejor las necesidades personalizadas del aprendiz y mejora la calidad del sistema de aprendizaje. Esto significa que su técnica obtiene mejores predicciones que los enfoques convencionales, ya que el error absoluto medio disminuye cuando se incorporan estas variables pedagógicas al proceso adaptativo. En otras palabras, la propuesta logra seleccionar objetos de aprendizaje más adecuados para cada estudiante y construir rutas de aprendizaje más precisas que las de los modelos tradicionales.

Al comentar estos hallazgos, puede afirmarse que los resultados son **mejores respecto a otros enfoques tradicionales** porque no se basan únicamente en similitud de valoraciones, sino que añaden variables pedagógicas que enriquecen la personalización. La mejora no radica solo en un cambio técnico de algoritmo, sino en que el sistema considera de manera más realista cómo aprende y se motiva cada estudiante. Por ello, la propuesta resulta más sólida que los modelos convencionales de adaptación, aunque los propios autores reconocen que todavía quedan desafíos futuros, como tratar mejor la correlación de datos y el problema de la sparsity.

Observaciones y/o críticas suyas al artículo

El artículo presenta un aporte interesante porque propone una técnica de adaptación en e-learning que no se limita únicamente al estilo de aprendizaje del estudiante, sino que incorpora también el **motivation score** como variable pedagógica relevante. Esta es una fortaleza importante, ya que muchos sistemas adaptativos previos suelen concentrarse en preferencias, valoraciones o estilos cognitivos, dejando de lado factores motivacionales que también influyen directamente en la calidad del aprendizaje. Además, el trabajo ofrece una propuesta clara en términos algorítmicos, integrando **collaborative filtering**, **CPCC**, **ACOS** y **KNN**, lo que le da consistencia metodológica y una base técnica sólida.

Sin embargo, una primera observación crítica es que la validación experimental se realiza con el dataset **MovieLens100K**, que originalmente no fue creado para contextos educativos, sino para sistemas de recomendación de ítems en otro tipo de entornos. Aunque los autores lo adaptan a su investigación, esto puede limitar la validez pedagógica de los resultados, ya que los patrones de comportamiento en ese dataset no necesariamente representan con precisión interacciones reales entre estudiantes y objetos de aprendizaje. En ese sentido, hubiera sido más fuerte validar la propuesta con datos provenientes directamente de una plataforma e-learning real.

Otra crítica importante es que el artículo se enfoca bastante en la **precisión algorítmica** y en la reducción del MAE, pero profundiza menos en el impacto educativo real de la propuesta. Es decir, demuestra que la recomendación puede mejorar técnicamente, pero no evalúa con suficiente detalle si esa mejora efectivamente se traduce en mayor aprendizaje, mejor desempeño académico o mayor satisfacción del estudiante dentro de un contexto real de enseñanza. Esta ausencia de validación pedagógica práctica hace que el trabajo sea fuerte en lo técnico, pero todavía limitado en cuanto a evidencia educativa directa.

Además, aunque el artículo propone una combinación entre estilo de aprendizaje y motivación, la forma de calcular el **motivation score** podría discutirse más a fondo, ya que depende de variables como feedback explícito, implícito y calificaciones, pero no se profundiza tanto en la validez pedagógica de esa construcción ni en cómo podría variar entre distintos contextos o perfiles de estudiantes. Esto deja abierta la posibilidad de seguir refinando el modelo en futuras investigaciones.

En síntesis, el artículo es valioso porque amplía la lógica adaptativa al incluir la motivación y propone una técnica novedosa para mejorar la recomendación de objetos de aprendizaje; sin embargo, necesita validaciones más cercanas a contextos educativos reales y una mayor profundización en el impacto pedagógico de la adaptación para consolidar plenamente su propuesta.

9. ARTICULO 09

Author (s): Han, J.; Liu, G.; Xiang, S.

Title of paper: Participar o no en la IA: la participación en el aprendizaje entre estudiantes de secundaria de zonas rurales en un entorno de aprendizaje adaptativo impulsado por IA.

Journal: Humanities and Social Sciences Communications

Volume (issue): 12

pag – pag (year): 1292–1292 (2025)

Estado del arte que hace el autor

El estado del arte presentado por los autores se sitúa en el campo del **aprendizaje adaptativo impulsado por inteligencia artificial (AI-powered adaptive learning system, ALS)** y su relación con el **learning engagement** de estudiantes de secundaria en contextos rurales. Desde el inicio del artículo, los autores explican que el aprendizaje adaptativo apoyado en inteligencia artificial se concibe como una forma de ofrecer una enseñanza más precisa, personalizada y a gran escala, ajustada a las necesidades del estudiante. Esta línea de investigación adquiere especial relevancia en contextos rurales de China, donde persisten desigualdades educativas importantes, como escasez de docentes de calidad, limitaciones en los materiales de aprendizaje y condiciones familiares que dificultan el acompañamiento escolar. En este escenario, los sistemas ALS aparecen en la literatura reciente como una posible vía para compensar estas brechas mediante tabletas subsidiadas y recursos personalizados.

Dentro de este panorama, los autores revisan primero el desarrollo general de los **AI-powered ALS**. Señalan que el diseño y desarrollo de estos sistemas es un tema clave en la investigación sobre aprendizaje adaptativo, y citan estudios recientes que muestran que este tipo de herramientas puede ofrecer experiencias educativas personalizadas, mejorar el rendimiento, reducir la ansiedad y apoyar la comprensión del estudiante. Por ejemplo, el artículo menciona trabajos donde los ALS mejoran el desempeño en matemáticas o donde chatbots adaptativos apoyados en IA aumentan la percepción positiva del usuario y favorecen el aprendizaje. Sin embargo, los autores subrayan que gran parte de estos estudios se ha centrado en experimentos pequeños posteriores al diseño del sistema, más enfocados en resultados de aprendizaje o en la experiencia de usuario, y menos en comprender en profundidad la **naturaleza del engagement** dentro de estos entornos.

Otro eje fundamental del estado del arte es la revisión de la literatura sobre **learning engagement**. Los autores explican que el compromiso del estudiante con el aprendizaje se ve afectado por múltiples factores, como el nivel de conocimiento, la motivación, la autoeficacia y la aceptación tecnológica. Además, destacan que el engagement en estudiantes de secundaria ha sido ya abordado en diversos estudios, por ejemplo, en relación con las relaciones entre pares, la creatividad en entornos de realidad virtual, la autorregulación del aprendizaje o los factores que influyen en la participación en aulas inteligentes. Esta revisión muestra que el engagement es un tema actual y relevante en secundaria, pero al mismo tiempo deja ver que la mayoría de estudios previos no se sitúa específicamente en entornos de aprendizaje adaptativo impulsados por IA.

Precisamente ahí los autores identifican una brecha importante: aunque están emergiendo nuevas tecnologías de IA en educación, los estudiantes de secundaria, y en particular los de zonas rurales, han tenido menos oportunidades de interactuar con estos dispositivos en clase que los estudiantes universitarios. Por ello, la investigación previa sobre ALS se ha concentrado más en educación superior, mientras que existe poca evidencia sobre cómo se configura el engagement en alumnos más jóvenes dentro de sistemas adaptativos con IA. Asimismo, el artículo señala que los trabajos anteriores han puesto mayor atención en si los ALS mejoran o no el aprendizaje, pero no en **qué factores explican el nivel de engagement de los estudiantes dentro de esos entornos**. Desde esa carencia se justifica el presente estudio.

En el plano teórico, el estado del arte se construye integrando tres marcos: **Self-Determination Theory (SDT)**, **Technology Acceptance Model (TAM)** y **Cognitive Load Theory (CLT)**. Los autores revisan la literatura de cada uno para fundamentar su modelo. Desde la **SDT**, se retoma la idea de que la satisfacción de tres necesidades psicológicas básicas —**autonomía, competencia y relación**— favorece la motivación y el engagement. Estudios previos citados en el artículo muestran que estas necesidades tienen efectos positivos sobre distintas formas de compromiso del estudiante en contextos online y tecnológicos. Además, se menciona que investigaciones recientes en aprendizaje con IA confirman que la percepción de competencia es un impulsor fuerte del uso sostenido de la tecnología.

Desde el **TAM**, el estado del arte revisa la importancia de la **perceived ease of use (PEU)** y la **perceived usefulness (PU)** como variables centrales en la aceptación tecnológica. Los autores recuerdan que numerosos estudios han demostrado que cuando los estudiantes perciben una tecnología como útil y fácil de usar, aumenta su probabilidad de aceptarla, seguir utilizándola y comprometerse más con el aprendizaje. Esta línea de investigación resulta especialmente pertinente en el caso de los ALS con IA, porque el éxito del sistema no depende solo de su capacidad técnica, sino de que el estudiante quiera adoptarlo y pueda utilizarlo con comodidad.

Por su parte, desde la **CLT**, el estado del arte distingue entre **intrinsic cognitive load** y **extraneous cognitive load**. Los autores explican que, en teoría, un ALS bien diseñado puede reducir la carga cognitiva innecesaria al ajustar la dificultad de las tareas, pero que en la práctica también pueden aparecer problemas como instrucciones poco claras, interfaces ambiguas o retrasos del sistema, que incrementan la carga extrínseca y afectan negativamente al compromiso del alumno. La literatura revisada muestra, además, que la carga cognitiva puede mediar o influir de forma negativa sobre el engagement, por lo que se convierte en un elemento indispensable para comprender el aprendizaje en estos entornos.

Un aspecto especialmente valioso del estado del arte es que no revisa estos tres marcos de manera aislada, sino que muestra cómo investigaciones previas ya han comenzado a vincularlos. El artículo menciona trabajos donde la SDT y el TAM se integran para explicar la intención de uso de tecnologías educativas, otros donde se combinan SDT, TAM y autoeficacia, y otros donde se relacionan CLT y TAM. A partir de esta revisión, los autores proponen una vía integradora: **SDT + CLT → TAM → Learning Engagement**, es decir, las necesidades psicológicas básicas y la carga cognitiva influyen en la aceptación tecnológica, y esta a su vez repercute en el engagement del estudiante. Esta síntesis constituye el núcleo conceptual del estado del arte y prepara el terreno para el modelo empírico del estudio. En la *Figura 1 del artículo (página 5)* se muestra visualmente este modelo teórico, donde se articulan autonomía, competencia, relación, carga cognitiva, aceptación tecnológica y las cuatro dimensiones del engagement.

Finalmente, el estado del arte se conecta con el contexto específico del estudio: estudiantes rurales de séptimo grado en matemáticas. Los autores argumentan que la transición de primaria a secundaria es una etapa especialmente difícil en esta materia, porque implica mayor carga académica, contenidos más complejos y riesgo de ansiedad matemática. En zonas rurales, estas dificultades se agravan por la falta de apoyo familiar y la escasez de recursos escolares. Por eso, el uso de AI-powered ALS en matemáticas se plantea como una posibilidad de ofrecer apoyo personalizado en una fase crítica del desarrollo escolar. En síntesis, el estado del arte muestra que ya existe una base importante de investigaciones sobre ALS, engagement, aceptación tecnológica, motivación y carga cognitiva, pero que todavía faltan estudios enfocados en **cómo interactúan estos factores en estudiantes rurales de secundaria dentro de un entorno adaptativo impulsado por IA**. Precisamente ese vacío es el que el artículo busca cubrir.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una limitación clara en la investigación previa sobre **AI-powered adaptive learning systems (ALS)**: aunque ya existen estudios que muestran que estos sistemas pueden mejorar el rendimiento, la comprensión, la motivación o incluso la experiencia de usuario, todavía se sabe poco sobre **qué factores explican realmente el learning engagement** de los estudiantes dentro de estos entornos. Es decir, gran parte de los trabajos anteriores se ha concentrado más en evaluar si el sistema funciona o no, pero no en comprender con suficiente profundidad la naturaleza del compromiso del estudiante cuando aprende con una plataforma adaptativa impulsada por IA.

Otra crítica importante que plantean los autores es que la mayor parte de la investigación previa sobre ALS se ha desarrollado con **estudiantes universitarios**, mientras que los alumnos de secundaria, especialmente los de zonas rurales, han recibido mucha menos atención. El artículo subraya que los estudiantes de junior high school tienen menos oportunidades de interactuar de forma autónoma con herramientas de IA durante las clases, por lo que los hallazgos obtenidos en educación superior no pueden trasladarse automáticamente a este contexto. En consecuencia, los autores consideran necesario desplazar el foco de la investigación hacia estudiantes más jóvenes y hacia contextos donde las desigualdades educativas hacen más urgente la exploración de soluciones tecnológicas.

Asimismo, los autores cuestionan que muchos estudios sobre ALS hayan priorizado los **resultados de aprendizaje** y la **evaluación posterior del sistema**, dejando en segundo plano los factores del propio proceso de aprendizaje. Desde su perspectiva, no basta con saber si el uso del sistema mejora las notas o la comprensión; también es indispensable comprender cómo variables como la **aceptación tecnológica**, la **carga cognitiva** y la **satisfacción de necesidades psicológicas básicas** influyen en el engagement. Esta observación representa una crítica conceptual importante a trabajos que evalúan el efecto del sistema sin analizar suficientemente los mecanismos internos que sostienen o debilitan el compromiso del estudiante.

También hay una crítica implícita a la falta de integración teórica en investigaciones previas. Los autores señalan que el contexto del aprendizaje con IA plantea al mismo tiempo demandas **motivacionales, tecnológicas y cognitivas**, por lo que estudiar el engagement desde una sola teoría sería insuficiente. Por eso consideran necesario integrar **Self-Determination Theory (SDT)**, **Technology Acceptance Model (TAM)** y **Cognitive Load Theory (CLT)** en un mismo modelo. De este modo, buscan superar enfoques parciales y ofrecer una comprensión más amplia de cómo los estudiantes rurales se involucran en un entorno adaptativo con IA.

Finalmente, la motivación del artículo también se apoya en el contexto rural de China. Los autores destacan que en estas zonas persisten problemas como escasez de docentes calificados, limitados recursos de aprendizaje, alta presencia de niños “left-behind” y poca alfabetización digital con fines académicos. Frente a ello, el ALS con IA aparece como una posible herramienta de apoyo, pero su éxito depende de que los estudiantes quieran usarla, puedan comprenderla y se mantengan comprometidos con ella. Por eso, el estudio nace de la necesidad de identificar qué factores favorecen o dificultan ese engagement para orientar mejor la implementación educativa de la IA en contextos rurales.

Descripción del aporte del autor

El principal aporte del artículo radica en el desarrollo y validación de un **modelo integral para explicar el learning engagement de estudiantes de secundaria en entornos de aprendizaje adaptativo impulsados por inteligencia artificial (AI-powered ALS)**, específicamente en contextos rurales. A diferencia de muchos estudios previos que analizan el impacto de estos sistemas solo desde el rendimiento académico o la experiencia del usuario, este trabajo propone

un enfoque más completo que busca comprender **qué factores determinan el compromiso del estudiante** cuando interactúa con tecnologías educativas avanzadas.

Uno de los aportes más importantes del estudio es la **integración teórica de tres modelos ampliamente utilizados en la investigación educativa y tecnológica**: la **Self-Determination Theory (SDT)**, la **Technology Acceptance Model (TAM)** y la **Cognitive Load Theory (CLT)**. Mientras que investigaciones anteriores suelen abordar estas teorías de manera independiente, los autores proponen un modelo unificado donde las necesidades psicológicas básicas (autonomía, competencia y relación) y la carga cognitiva influyen en la aceptación tecnológica (perceived usefulness y perceived ease of use), y esta, a su vez, impacta en el engagement del estudiante. Este enfoque integrador constituye un aporte significativo porque permite analizar el aprendizaje desde una perspectiva multidimensional que combina factores motivacionales, cognitivos y tecnológicos.

Otro aporte clave del artículo es la **operacionalización del learning engagement en cuatro dimensiones: behavioral engagement, cognitive engagement, emotional engagement y social engagement**. Esta clasificación permite medir el compromiso del estudiante de manera más completa, considerando no solo su participación observable, sino también su implicación cognitiva, sus emociones frente al aprendizaje y su interacción social. De esta manera, el estudio amplía la comprensión del engagement más allá de enfoques tradicionales que suelen centrarse únicamente en el comportamiento o el rendimiento.

Asimismo, el artículo aporta evidencia empírica relevante mediante la aplicación de su modelo en un contexto real: estudiantes de séptimo grado en áreas rurales que utilizan un sistema de aprendizaje adaptativo en matemáticas. Este enfoque es especialmente valioso porque la mayoría de investigaciones previas se ha realizado en educación superior o en contextos urbanos. Al centrarse en estudiantes rurales, el estudio contribuye a reducir una brecha importante en la literatura y ofrece información útil para contextos donde las desigualdades educativas son más marcadas.

Otro aporte importante es el análisis detallado de cómo las variables del modelo interactúan entre sí. Los autores demuestran que la **perceived usefulness (PU)** y la **perceived ease of use (PEU)** tienen un impacto significativo en el engagement, lo que confirma la relevancia del modelo TAM en entornos de aprendizaje con IA. Además, muestran que la **satisfacción de las necesidades psicológicas básicas**, especialmente la competencia, influye de manera positiva en la aceptación tecnológica y, en consecuencia, en el compromiso del estudiante. Por otro lado, evidencian que la **extraneous cognitive load** puede afectar negativamente el engagement, lo que resalta la importancia de diseñar sistemas que no sobrecarguen cognitivamente al usuario.

El artículo también aporta una comprensión más profunda del papel de la inteligencia artificial en la educación. En lugar de considerar los ALS únicamente como herramientas tecnológicas, los autores los analizan como **entornos de aprendizaje complejos** donde interactúan factores psicológicos, cognitivos y tecnológicos. Esta perspectiva permite identificar no solo los beneficios potenciales de la IA en educación, sino también los desafíos asociados a su implementación, como la necesidad de interfaces claras, contenido adecuado y estrategias que fomenten la motivación del estudiante.

Además, el estudio ofrece implicaciones prácticas importantes. Por ejemplo, sugiere que para mejorar el engagement en sistemas ALS es necesario diseñar experiencias que **fortalezcan la percepción de utilidad y facilidad de uso**, satisfagan las necesidades de autonomía, competencia y relación, y reduzcan la carga cognitiva innecesaria. Estas recomendaciones son valiosas para diseñadores de sistemas educativos, docentes y responsables de políticas educativas, ya que proporcionan lineamientos claros para mejorar la efectividad de las tecnologías de aprendizaje adaptativo.

Finalmente, el artículo aporta una contribución significativa al campo de la educación digital al demostrar que el éxito de los sistemas de aprendizaje adaptativo no depende únicamente de su capacidad tecnológica, sino de su capacidad para **integrarse con las características humanas del estudiante**. En este sentido, el estudio propone una visión más equilibrada entre tecnología y pedagogía, donde la inteligencia artificial se convierte en un medio para potenciar el aprendizaje, pero siempre considerando los factores psicológicos y cognitivos que influyen en el compromiso del estudiante.

En conjunto, el aporte del artículo puede resumirse en tres niveles principales. Primero, ofrece un modelo teórico integrador que combina SDT, TAM y CLT para explicar el engagement en entornos de aprendizaje con IA. Segundo, proporciona evidencia empírica en un contexto poco explorado, como el de estudiantes rurales de secundaria. Y tercero, genera implicaciones prácticas que pueden orientar el diseño de sistemas adaptativos más efectivos. Por ello, el trabajo representa una contribución sólida tanto desde el punto de vista teórico como aplicado dentro del campo de la educación basada en inteligencia artificial.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se desarrolla mediante una metodología estructurada que combina fundamentación teórica, diseño de modelo conceptual, recolección de datos en contexto real y validación empírica. En primer lugar, los autores parten de una revisión del estado del arte donde identifican una brecha importante: la falta de estudios que expliquen de manera integral el **learning engagement en sistemas de aprendizaje adaptativo impulsados por inteligencia artificial**, especialmente en estudiantes de secundaria en contextos rurales. A partir de este análisis, establecen la necesidad de desarrollar un modelo que integre factores motivacionales, cognitivos y tecnológicos para comprender el compromiso del estudiante.

El segundo paso del proceso consiste en el **diseño del modelo teórico**. Para ello, los autores integran tres marcos conceptuales: la **Self-Determination Theory (SDT)**, la **Technology Acceptance Model (TAM)** y la **Cognitive Load Theory (CLT)**. A partir de estas teorías, construyen un modelo que plantea relaciones entre variables como autonomía, competencia, relación, carga cognitiva, percepción de utilidad, facilidad de uso y engagement. Esta etapa es fundamental, ya que define la estructura conceptual del estudio y las hipótesis que serán evaluadas posteriormente. En la *Figura 1 del artículo (página 5)* se presenta este modelo, donde se observa la relación entre las variables teóricas y el engagement del estudiante.

El siguiente paso es la **operacionalización de las variables**. Los autores definen cómo medir cada uno de los constructos del modelo, incluyendo las dimensiones del engagement (behavioral, cognitive, emotional y social), las variables del TAM (perceived usefulness y perceived ease of use), las necesidades psicológicas de la SDT y los tipos de carga cognitiva de la CLT. Para ello, utilizan instrumentos validados en investigaciones previas, adaptándolos al contexto del estudio. Este paso permite convertir conceptos teóricos en variables medibles que pueden ser analizadas estadísticamente.

Posteriormente, los autores realizan la **recolección de datos en un contexto real**. El estudio se lleva a cabo con estudiantes de séptimo grado en zonas rurales que utilizan un sistema de aprendizaje adaptativo en matemáticas. Los datos se obtienen mediante cuestionarios aplicados a los estudiantes después de interactuar con el sistema, lo que permite recoger información sobre su percepción, su nivel de engagement y otros factores relevantes. Este enfoque es importante porque proporciona evidencia empírica basada en experiencias reales de aprendizaje con IA.

El siguiente paso consiste en el **análisis de datos y validación del modelo**. Los autores emplean técnicas estadísticas para evaluar las relaciones entre las variables propuestas y verificar las

hipótesis del estudio. A través de este análisis, determinan cuáles factores influyen de manera significativa en el engagement y cómo se relacionan entre sí. Este proceso permite confirmar la validez del modelo teórico y demostrar que la integración de SDT, TAM y CLT es adecuada para explicar el comportamiento de los estudiantes en entornos ALS.

Finalmente, el proceso culmina con la **interpretación de los resultados y la formulación de conclusiones**. Los autores analizan los hallazgos obtenidos y los relacionan con la literatura previa, identificando las implicaciones teóricas y prácticas de su estudio. A partir de ello, proponen recomendaciones para mejorar el diseño de sistemas de aprendizaje adaptativo y fomentar el engagement en estudiantes de secundaria.

En conjunto, el proceso seguido por los autores combina revisión teórica, diseño conceptual, medición empírica y análisis estadístico. Gracias a este enfoque integral, logran construir un modelo sólido que explica el engagement en entornos de aprendizaje adaptativo con inteligencia artificial, constituyendo así el núcleo de su aporte.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema del bajo o insuficiente **learning engagement** de estudiantes rurales en un entorno de aprendizaje adaptativo impulsado por inteligencia artificial se construye a partir de una lógica tanto teórica como práctica. El problema central que identifican es que, aunque los **AI-powered adaptive learning systems (ALS)** pueden ofrecer enseñanza personalizada y compensar en parte la falta de recursos educativos en zonas rurales, su efectividad real depende de que los estudiantes acepten la tecnología, puedan usarla sin sobrecarga cognitiva excesiva y se mantengan comprometidos con el aprendizaje. Por ello, los autores no se limitan a preguntar si el sistema funciona, sino que diseñan un proceso para comprender **qué factores favorecen o dificultan ese engagement** y cómo pueden orientarse mejoras en la implementación del ALS.

El primer paso del proceso consistió en **delimitar el contexto educativo y el problema específico**. Los autores seleccionaron cinco escuelas rurales del suroeste de China, caracterizadas por problemas compartidos: escasez de docentes calificados, alta carga laboral del profesorado, estudiantes “left-behind” con poco apoyo familiar y baja experiencia previa con herramientas digitales de aprendizaje. En este escenario, el uso de tabletas con un ALS impulsado por IA se plantea como una solución potencial para ofrecer apoyo personalizado en matemáticas, especialmente en séptimo grado, una etapa crítica de transición entre primaria y secundaria. Esta delimitación contextual es importante porque convierte el problema abstracto del engagement en una situación concreta donde la tecnología puede ayudar, pero también fracasar si no se comprenden bien las condiciones de uso.

El segundo paso fue la **construcción de un modelo explicativo** que permitiera entender el problema de manera integral. Para ello, los autores integraron tres marcos teóricos: **Self-Determination Theory (SDT)**, **Technology Acceptance Model (TAM)** y **Cognitive Load Theory (CLT)**. Desde la SDT consideran que la satisfacción de las necesidades de **autonomía, competencia y relación** favorece la motivación y el compromiso. Desde el TAM incorporan la **perceived ease of use** y la **perceived usefulness**, entendidas como dimensiones centrales de la aceptación tecnológica. Y desde la CLT analizan la **intrinsic cognitive load** y la **extraneous cognitive load**, para ver cómo la exigencia cognitiva del sistema puede afectar el engagement. De esta manera, los autores convierten el problema en un modelo causal donde la motivación, la aceptación tecnológica y la carga cognitiva interactúan para explicar el compromiso del estudiante. En la *Figura 1 del artículo (página 5)* se visualiza precisamente este modelo, donde las variables de SDT y CLT se conectan con TAM y, finalmente, con las dimensiones del engagement.

El tercer paso fue la **implementación práctica del ALS en el aula**. Las clases seleccionadas fueron equipadas con tabletas que contenían un sistema adaptativo basado en IA para matemáticas. Antes del uso formal del sistema, los estudiantes recibieron una capacitación de una semana para aprender a operar las tabletas y comprender sus funciones, y en cada clase estuvo presente personal técnico para resolver problemas en tiempo real. Esto es importante porque muestra que los autores no asumieron que la simple presencia de la tecnología resolvería el problema, sino que prepararon condiciones de uso para reducir barreras iniciales de aceptación y manejo.

El cuarto paso fue el **funcionamiento pedagógico del propio ALS**, que constituye una parte central del proceso de solución. El sistema primero presenta **preguntas diagnósticas**, luego construye un **knowledge graph** sobre los puntos que el estudiante domina o no domina, recomienda **recursos y rutas personalizadas de aprendizaje**, y finalmente activa fases de **precision learning** y **precision practice**. Si el estudiante falla en ciertos ejercicios, el sistema insiste en los puntos débiles, proporciona análisis y videos explicativos y no permite avanzar hasta consolidar esos conocimientos. La *Figura 3 del artículo (página 6)* resume este procedimiento mostrando cómo el sistema pasa del diagnóstico a la recomendación personalizada, la práctica y la actualización del conocimiento del estudiante. Este diseño resuelve el problema desde el plano instruccional porque ofrece apoyo continuo, adaptación a errores y seguimiento individualizado, algo que en contextos rurales sería difícil de garantizar solo con el docente.

El quinto paso fue la **medición sistemática de las variables implicadas en el engagement**. Los autores aplicaron cuestionarios a estudiantes que habían usado el ALS durante un año académico completo, recogiendo datos sobre autonomía, competencia, relación, aceptación tecnológica, carga cognitiva y engagement. Además, complementaron esta información con entrevistas a estudiantes y docentes, así como con observaciones en aula, lo que permitió triangular la información y no depender únicamente del autorreporte. Este paso es fundamental porque convierte el proceso de solución en algo verificable y no solo en una intuición pedagógica.

El sexto paso consistió en **analizar estadísticamente las relaciones entre las variables** mediante modelamiento estructural y análisis de mediación. Los resultados mostraron que la **perceived competence** y la **technology acceptance** tienen efectos positivos significativos sobre el learning engagement, mientras que la **extraneous cognitive load** tiene un efecto negativo significativo. También hallaron que la aceptación tecnológica media parcialmente la relación entre competencia y engagement, y media completamente la relación entre relatedness y engagement. En cambio, la autonomía no mostró efecto directo significativo sobre el engagement. Esta fase permite a los autores identificar con precisión qué componentes del problema deben atenderse prioritariamente.

Finalmente, el problema se resuelve a nivel propositivo mediante **recomendaciones concretas para el diseño e implementación de sistemas ALS**. A partir de sus hallazgos, los autores concluyen que para mejorar el engagement no basta con introducir IA en el aula; es necesario **fortalecer la aceptación tecnológica**, mejorar la **usabilidad del sistema**, ofrecer **retroalimentación inmediata y eficaz** para reforzar la percepción de competencia y **reducir la carga cognitiva extrínseca** mediante instrucciones y retroalimentación más claras. En otras palabras, el proceso de solución transforma un problema amplio —la baja participación del estudiante en entornos adaptativos con IA— en una serie de factores concretos que pueden intervenir desde el diseño tecnológico y pedagógico.

En conjunto, el proceso seguido por los autores va desde la identificación del problema en un contexto rural real, pasando por la construcción de un modelo teórico integrador, la implementación práctica del ALS, la recolección de evidencia y el análisis empírico, hasta llegar a orientaciones concretas para mejorar el engagement. Así, el artículo no solo describe

un problema educativo, sino que propone una ruta clara para comprenderlo y enfrentarlo dentro de entornos de aprendizaje adaptativo con inteligencia artificial.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, los autores utilizan principalmente **métricas de ajuste del modelo, coeficientes de ruta y análisis de mediación** para evaluar qué factores explican el **learning engagement** en un entorno de aprendizaje adaptativo impulsado por IA. En la validación del instrumento emplean indicadores como **KMO = 0.915**, AVE, CR y **Cronbach's α** , mostrando buena validez y confiabilidad de las escalas. Para el ajuste del modelo estructural usan índices como **$\chi^2/df = 1.778$** , **RMSEA = 0.057**, **SRMR = 0.048**, **CFI = 0.927**, **IFI = 0.928** y **TLI = 0.919**, todos dentro de rangos aceptables, lo que indica que el modelo teórico propuesto se ajusta bien a los datos.

En cuanto a los resultados sustantivos, el análisis de rutas muestra que **perceived competence** tiene un efecto positivo significativo sobre el engagement (**$\beta = 0.340$, $p < 0.001$**), y que la **technology acceptance** ejerce un efecto aún más fuerte (**$\beta = 0.496$, $p < 0.001$**). Además, **perceived autonomy** (**$\beta = 0.167$, $p = 0.044$**), **perceived competence** (**$\beta = 0.458$, $p < 0.001$**) y **perceived relatedness** (**$\beta = 0.283$, $p < 0.001$**) influyen positivamente sobre la aceptación tecnológica. En cambio, **perceived autonomy** sobre engagement (**$\beta = 0.034$, $p = 0.654$**) y **perceived relatedness** sobre engagement (**$\beta = 0.083$, $p = 0.245$**) no resultan significativas de forma directa. El artículo también concluye que la **extraneous cognitive load** afecta negativamente el engagement, mientras que la **intrinsic cognitive load** no muestra un efecto significativo directo.

Otra métrica importante es el **análisis de mediación**. Los autores encuentran que la **technology acceptance** media **parcialmente** la relación entre **perceived competence** y engagement, media **totalmente** la relación entre **perceived relatedness** y engagement, y **no media** la relación entre **perceived autonomy** y engagement. Esto quiere decir que la aceptación de la tecnología es una variable clave para transformar ciertas condiciones psicológicas del estudiante en verdadero compromiso con el aprendizaje dentro del ALS.

Al comentar estos hallazgos, puede decirse que los resultados son especialmente valiosos porque no se limitan a afirmar que el sistema AI-powered ALS “mejora el aprendizaje”, sino que explican **por qué** algunos estudiantes se involucran más que otros. En comparación con estudios previos centrados solo en rendimiento o experiencia de usuario, este trabajo ofrece una comprensión más profunda del engagement al mostrar que **la aceptación tecnológica y la percepción de competencia son los factores más fuertes**, y que reducir la **carga cognitiva extrínseca** es más importante que intervenir sobre la carga intrínseca. Por ello, el aporte del artículo puede considerarse mejor que otros enfoques más descriptivos, ya que permite orientar con mayor precisión el diseño pedagógico y tecnológico del sistema.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte importante porque no se limita a estudiar si un sistema adaptativo con inteligencia artificial mejora el aprendizaje, sino que profundiza en los factores que explican el **learning engagement** de estudiantes rurales de secundaria. Una de sus principales fortalezas es la integración de tres marcos teóricos sólidos —**SDT, TAM y CLT**— en un mismo modelo, lo que permite analizar el fenómeno desde una perspectiva motivacional, tecnológica y cognitiva al mismo tiempo. Además, el estudio tiene mucho valor aplicado porque se desarrolla en un contexto real de escuelas rurales, donde el uso de AI-powered ALS puede tener un impacto social relevante al compensar limitaciones como la falta de docentes calificados o el poco apoyo familiar fuera de la escuela.

Sin embargo, una primera observación crítica es que el estudio se basa principalmente en **cuestionarios de autorreporte**, lo cual puede introducir sesgos en las respuestas de los estudiantes, especialmente al tratarse de alumnos jóvenes. Aunque los autores aplican medidas para reducir este problema y complementan la información con entrevistas y observación, el núcleo del análisis sigue dependiendo de la percepción subjetiva del estudiante. Por ello, los resultados explican bien la vivencia del engagement, pero menos el comportamiento real o el desempeño objetivo dentro del sistema.

Otra crítica importante es que el estudio se centra en un contexto muy específico: **estudiantes rurales chinos de séptimo grado en matemáticas**. Este enfoque le da pertinencia local al trabajo, pero también limita la generalización de los resultados. No se puede asumir automáticamente que las mismas relaciones entre competencia, aceptación tecnológica, carga cognitiva y engagement se repetirán igual en otros niveles educativos, otras asignaturas o contextos culturales distintos. En ese sentido, el modelo necesita ser probado en escenarios más diversos para confirmar su alcance.

También se puede observar que el artículo ofrece una explicación muy clara de los factores que influyen en el engagement, pero profundiza menos en las características técnicas concretas del ALS que podrían estar generando esos efectos. Por ejemplo, se menciona la importancia de reducir la **extraneous cognitive load** y mejorar la usabilidad, pero sería útil un análisis más detallado de qué aspectos específicos de la interfaz, del feedback o de la navegación están afectando la experiencia del estudiante. Esto permitiría traducir los resultados en orientaciones de diseño más precisas.

En síntesis, se trata de un artículo sólido, bien fundamentado y valioso para comprender el engagement en entornos adaptativos con IA, especialmente en contextos rurales. No obstante, sus resultados deben interpretarse dentro de su contexto específico y podrían fortalecerse aún más con más evidencia objetiva del comportamiento del estudiante y con estudios comparativos en otros escenarios educativos.

10. ARTICULO 10

Author (s): Valencia-Arias, A.; Méndez Velásquez, L. M.; Agudelo-Ceballos, E.; et al.

Title of paper: Educación virtual en el sector rural: análisis de la literatura científica

Journal: *Frontiers in Education*

Volume (issue): 10

pag – pag (year): 1567733–1567733 (2025)

Estado del arte que hace el autor

El estado del arte presentado por los autores se construye a partir de una revisión amplia de la literatura sobre **virtual education in the rural sector**, especialmente intensificada después de la pandemia de COVID-19. Desde el inicio, el artículo sitúa el tema en el contexto de la transición acelerada de la enseñanza presencial hacia modalidades digitales, subrayando que esta transformación volvió más visible tanto el potencial de la educación virtual como las desigualdades estructurales de los entornos rurales. Según los autores, la virtualidad puede contribuir a cerrar brechas de acceso y equidad educativa, ya que ofrece a los estudiantes rurales recursos y oportunidades de aprendizaje que de otro modo serían difíciles de alcanzar debido a limitaciones geográficas, de infraestructura y de disponibilidad docente.

Dentro de este panorama, el estado del arte destaca que la literatura reciente ha documentado tanto **oportunidades** como **dificultades** derivadas de la digitalización educativa. Por un lado, se reconoce que la educación virtual ha permitido continuidad académica, mayor flexibilidad y acceso a recursos en contextos donde la enseñanza presencial enfrenta barreras físicas o sociales. Por otro lado, también se ha evidenciado que la transición forzada hacia lo digital no puede reducirse simplemente a trasladar la clase presencial a una pantalla. Investigaciones revisadas por los autores muestran que la educación online requiere enfoques pedagógicos específicos, preparación institucional y apoyo emocional, especialmente durante situaciones de crisis como la pandemia. Esta idea aparece, por ejemplo, en estudios que muestran cómo estudiantes universitarios en España experimentaron la educación virtual no como una simple continuidad, sino como una experiencia que exigía rediseño y acompañamiento.

El estado del arte también incorpora investigaciones que muestran los **efectos emocionales y sociales** de la educación virtual en contextos de confinamiento. Los autores mencionan trabajos realizados en China con niños y adolescentes que relacionan el encierro y la educación online con sensaciones de ansiedad y depresión, lo que pone de relieve que la educación virtual en zonas rurales no puede entenderse solo en términos de acceso tecnológico, sino también desde la dimensión del bienestar psicológico. Esta revisión permite ampliar el enfoque y mostrar que el campo ha comenzado a integrar la salud mental como un tema relevante dentro de la discusión sobre virtualidad educativa.

Otro componente importante del estado del arte es la relación entre educación virtual y **desarrollo de competencias específicas en comunidades rurales**. El artículo cita estudios donde la alfabetización digital de adultos mayores en zonas rurales se promueve mediante redes sociales y navegación lineal, así como investigaciones sobre el aprendizaje móvil en áreas STEM. Estos antecedentes revelan que la virtualidad en contextos rurales no se limita a la escolaridad formal, sino que también puede funcionar como herramienta de inclusión social, participación digital y formación en habilidades útiles para la vida cotidiana y productiva. De esta manera, el campo ha empezado a reconocer la educación virtual rural como un fenómeno más amplio que abarca formación, ciudadanía digital y desarrollo comunitario.

Asimismo, el estado del arte dedica atención a la **aceptación de tecnologías educativas móviles y entornos virtuales basados en la nube**. Se mencionan estudios que destacan cómo las actitudes positivas hacia la tecnología y la percepción de utilidad favorecen la adopción del aprendizaje móvil en zonas rurales, especialmente en áreas de ciencia, tecnología, ingeniería y matemáticas. También se revisan trabajos que proponen los entornos virtuales cloud-based

como una vía para reducir desigualdades entre estudiantes urbanos y rurales. Esta línea de investigación evidencia que la literatura no solo estudia la existencia de tecnología, sino también las condiciones de aceptación y apropiación que permiten que esta genere un impacto educativo real.

Un rasgo destacable del estado del arte es que los autores hacen una **distinción conceptual cuidadosa entre términos relacionados**, tales como digital education, digital teaching, online education, mobile learning, distance education y remote education. Aunque todos se vinculan con el uso de tecnologías, el artículo aclara que no son equivalentes y que cada uno remite a modalidades y metodologías distintas. Esta precisión conceptual es importante porque muestra que la investigación sobre virtual education in rural areas ha ido diversificándose y refinando sus categorías, en lugar de tratar toda experiencia digital como si fuera homogénea.

Además, el estado del arte revisa estudios más recientes que refuerzan la centralidad del tema en el contexto rural. Los autores mencionan análisis longitudinales sobre escuelas virtuales en zonas rurales, estudios sobre el impacto de la pandemia en la educación rural, investigaciones sobre la formación en competencias TIC de futuros docentes y trabajos que subrayan las brechas de infraestructura tecnológica y conectividad. Estas investigaciones coinciden en que la educación virtual tiene potencial para ampliar cobertura y acceso, pero también revelan limitaciones persistentes relacionadas con desempeño académico, formación docente, calidad de la conectividad y disponibilidad de dispositivos. En otras palabras, la literatura revisada no presenta la virtualidad como una solución automática, sino como un campo lleno de tensiones entre inclusión y desigualdad.

Precisamente desde allí emerge una de las conclusiones centrales del estado del arte: **la literatura existente sigue siendo insuficiente**, especialmente porque gran parte de los estudios previos se han enfocado en contextos urbanos o en instituciones mejor equipadas, dejando relativamente desatendidas las condiciones específicas de la ruralidad. Los autores señalan que persiste una falta de enfoques analíticos adaptados a las particularidades de las comunidades rurales, así como una comprensión limitada de cómo implementar y optimizar tecnologías avanzadas en estos contextos. También advierten que muchas investigaciones sobre motivación, rendimiento o experiencias durante la pandemia no distinguen con suficiente claridad entre estudiantes urbanos y rurales, lo que deja vacíos importantes en el conocimiento.

En síntesis, el estado del arte elaborado por los autores muestra que la educación virtual en zonas rurales se ha convertido en un tema de creciente interés científico, impulsado por la pandemia y por la necesidad de reducir desigualdades educativas. La literatura ha abordado temas como acceso, inclusión, alfabetización digital, formación docente, salud mental, aprendizaje móvil y conectividad. Sin embargo, también ha dejado claro que el campo aún presenta vacíos importantes, sobre todo en el análisis específico de la ruralidad, la adecuación curricular, la infraestructura tecnológica y la construcción de estrategias diferenciadas para estas comunidades. Desde esa brecha, el artículo justifica su objetivo de analizar tendencias de investigación mediante un enfoque bibliométrico y ofrecer una visión más estructurada del conocimiento acumulado sobre virtual education in the rural sector.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una constatación clara: aunque la **virtual education in the rural sector** ha ganado mucha relevancia en los últimos años, especialmente después de la pandemia, la base de conocimiento disponible sigue siendo **fragmentada, insuficiente y poco específica para los contextos rurales**. Los autores señalan que buena parte de la literatura existente se ha concentrado en contextos urbanos o en entornos educativos mejor equipados, dejando en segundo plano las particularidades de las comunidades rurales, donde las limitaciones de conectividad, infraestructura, formación docente y acceso a recursos son

mucho más marcadas. Desde esa perspectiva, el artículo nace de la necesidad de comprender mejor qué se ha investigado realmente sobre educación virtual rural y qué vacíos persisten.

Una crítica importante que plantean es que muchas investigaciones anteriores, aunque valiosas, **no distinguen suficientemente entre las experiencias de estudiantes urbanos y rurales**. Por ejemplo, estudios sobre motivación, desempeño académico o transición a la virtualidad durante la pandemia suelen analizar poblaciones con mejores condiciones tecnológicas y educativas, lo que limita su capacidad para explicar las necesidades reales de los sectores rurales. Esta falta de diferenciación genera un vacío de conocimiento, porque las soluciones pensadas para contextos urbanos no siempre responden a las dificultades específicas de las comunidades rurales.

Además, los autores critican implícitamente que parte de la literatura previa ha tendido a presentar la educación virtual como una solución general al problema del acceso, sin profundizar lo suficiente en los **desafíos estructurales que condicionan su implementación en zonas rurales**. Entre estos desafíos mencionan la debilidad de la infraestructura tecnológica, la limitada disponibilidad de dispositivos, la escasa formación digital de los docentes y las barreras sociales y económicas que afectan a los estudiantes. En consecuencia, consideran que no basta con afirmar que la virtualidad amplía el acceso; también es necesario analizar cómo y bajo qué condiciones esa virtualidad puede funcionar de manera efectiva y equitativa en áreas rurales.

Otra crítica relevante es que los trabajos previos suelen abordar aspectos parciales del fenómeno, como conectividad, motivación o aprendizaje móvil, pero **faltan aproximaciones integradoras que permitan mapear de manera sistemática las tendencias, temas emergentes, referencias principales y vacíos de investigación**. Por ello, los autores justifican el uso de un enfoque bibliométrico siguiendo PRISMA-2020, con el fin de ofrecer una visión estructurada del campo y no solo estudios aislados. En este sentido, su motivación no es únicamente describir lo que ya se sabe, sino también construir una base más sólida para orientar futuras agendas de investigación.

En síntesis, la motivación del artículo se apoya en la necesidad de superar una literatura todavía dispersa y poco adaptada a la realidad rural, identificar con mayor precisión las tendencias y lagunas del campo, y generar una base analítica que permita diseñar mejores estrategias de investigación y de intervención educativa para la virtualidad en zonas rurales.

Descripción del aporte del autor

El artículo realiza un aporte significativo al campo de la educación al ofrecer un **análisis bibliométrico sistemático sobre la virtual education in the rural sector**, abordando una temática que ha cobrado gran relevancia en los últimos años, especialmente tras la pandemia de COVID-19. A diferencia de otros estudios que se centran en casos específicos o en análisis cualitativos aislados, este trabajo propone una **visión global y estructurada del conocimiento científico existente**, permitiendo identificar tendencias, vacíos y líneas de investigación emergentes en el ámbito de la educación virtual en contextos rurales.

Uno de los aportes más importantes del artículo es la aplicación de una **metodología rigurosa basada en PRISMA-2020**, que permite seleccionar, filtrar y analizar de manera sistemática la literatura científica relevante. A partir de esta metodología, los autores construyen una base de datos de artículos indexados en **Scopus y Web of Science**, lo que garantiza la calidad académica de las fuentes analizadas. Este enfoque metodológico aporta solidez al estudio, ya que evita la revisión superficial o sesgada de la literatura y permite generar resultados confiables sobre el estado actual del conocimiento en el área.

Otro aporte clave es la identificación de las **principales tendencias de investigación** en el campo de la educación virtual rural. A través del análisis bibliométrico, los autores logran determinar cuáles son los temas más estudiados, los autores más influyentes, las revistas con mayor producción científica y los países que lideran la investigación en este ámbito. Este mapeo del conocimiento permite comprender cómo ha evolucionado el campo y cuáles son las áreas que han recibido mayor atención por parte de la comunidad científica. Además, facilita la identificación de redes de colaboración y de los enfoques predominantes en la investigación actual.

El artículo también aporta una **clasificación de los principales ejes temáticos** que estructuran la investigación sobre educación virtual en zonas rurales. Entre estos ejes destacan la inclusión digital, la conectividad, el aprendizaje móvil, la formación docente, el impacto de la pandemia, la alfabetización digital y la equidad educativa. Esta organización temática es relevante porque permite comprender el fenómeno de manera integral, reconociendo que la educación virtual rural no es solo un problema tecnológico, sino también social, pedagógico y económico.

Asimismo, el estudio aporta un análisis detallado de los **vacíos de investigación existentes**. Los autores evidencian que, aunque la producción científica sobre educación virtual ha crecido, todavía existen limitaciones importantes, como la falta de estudios específicos en contextos rurales, la escasa diferenciación entre entornos urbanos y rurales, y la ausencia de enfoques que integren múltiples dimensiones del problema. Este aporte es especialmente valioso porque no solo describe lo que ya se sabe, sino que también orienta futuras investigaciones hacia áreas donde el conocimiento aún es insuficiente.

Otro aporte relevante es la **distinción conceptual entre diferentes modalidades de educación digital**, como online education, distance education, mobile learning y remote education. Esta diferenciación permite evitar confusiones terminológicas y contribuye a una comprensión más precisa del fenómeno. Al clarificar estos conceptos, el artículo facilita el desarrollo de investigaciones más rigurosas y comparables dentro del campo.

El artículo también ofrece implicaciones prácticas importantes para el diseño e implementación de políticas educativas. A partir de sus hallazgos, los autores destacan la necesidad de fortalecer la **infraestructura tecnológica en zonas rurales**, mejorar la formación digital de los docentes y diseñar estrategias educativas adaptadas a las características de estas comunidades. Este enfoque aplicado convierte el estudio en una herramienta útil no solo para investigadores, sino también para responsables de políticas públicas y gestores educativos.

Además, el trabajo contribuye al campo al demostrar que la educación virtual en zonas rurales debe ser abordada desde una perspectiva **multidimensional**, donde se consideren factores tecnológicos, pedagógicos, sociales y económicos. Esta visión amplia permite superar enfoques reduccionistas que limitan el problema únicamente a la conectividad o al acceso a dispositivos, y propone una comprensión más completa de las condiciones necesarias para que la virtualidad educativa sea efectiva.

Finalmente, uno de los aportes más importantes del artículo es que establece una **base de conocimiento estructurada** que puede servir como punto de partida para futuras investigaciones. Al identificar tendencias, actores clave, temas emergentes y vacíos de investigación, el estudio proporciona una guía clara para investigadores que deseen profundizar en el campo de la educación virtual rural. En este sentido, el artículo no solo sintetiza el conocimiento existente, sino que también contribuye a orientar el desarrollo futuro del área.

En conjunto, el aporte del artículo puede resumirse en tres dimensiones principales. Primero, ofrece una revisión sistemática y bibliométrica rigurosa del campo de la educación virtual en zonas rurales. Segundo, identifica tendencias, temas y vacíos de investigación, proporcionando una visión clara del estado actual del conocimiento. Y tercero, genera implicaciones prácticas

y teóricas que pueden guiar tanto la investigación futura como la implementación de políticas educativas. Por ello, el trabajo representa una contribución sólida y relevante dentro del ámbito de la educación digital y la equidad educativa en contextos rurales.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en una **metodología bibliométrica sistemática**, orientada a analizar de manera rigurosa la producción científica sobre la **virtual education in the rural sector**. En primer lugar, los autores parten de la identificación del problema: la existencia de una gran cantidad de estudios sobre educación virtual, pero con información dispersa, poco organizada y con escasa diferenciación entre contextos urbanos y rurales. A partir de esta necesidad, plantean como objetivo desarrollar un análisis estructurado que permita identificar tendencias, vacíos y direcciones futuras de investigación.

El segundo paso del proceso consiste en la **definición del enfoque metodológico**, para lo cual adoptan el protocolo **PRISMA-2020 (Preferred Reporting Items for Systematic Reviews and Meta-Analyses)**. Este marco proporciona una guía clara para realizar revisiones sistemáticas de literatura, asegurando transparencia, replicabilidad y rigor científico en la selección de los estudios. Con base en este protocolo, los autores establecen criterios de inclusión y exclusión que permiten filtrar únicamente los artículos relevantes para el análisis.

El tercer paso es la **búsqueda y recopilación de información científica**. Los autores seleccionan dos de las bases de datos más importantes a nivel académico: **Scopus y Web of Science (WoS)**. En estas plataformas realizan búsquedas utilizando palabras clave relacionadas con educación virtual y entornos rurales, obteniendo inicialmente un conjunto amplio de artículos. Posteriormente, aplican los filtros definidos para eliminar duplicados, documentos irrelevantes o aquellos que no cumplen con los criterios establecidos, reduciendo progresivamente la muestra hasta obtener un conjunto final de estudios válidos para el análisis. Este proceso se representa en el diagrama PRISMA incluido en el artículo, donde se visualiza cómo se pasa de un número inicial elevado de publicaciones a una selección más específica y manejable.

El cuarto paso consiste en la **organización y procesamiento de los datos recopilados**. Los autores estructuran la información de los artículos seleccionados considerando variables como autores, año de publicación, país de origen, revista, palabras clave y número de citas. Esta organización permite construir una base de datos que sirve como insumo para el análisis bibliométrico. En esta etapa, también se preparan los datos para ser analizados mediante herramientas especializadas que permiten visualizar relaciones y tendencias dentro del campo de estudio.

El quinto paso es el **análisis bibliométrico propiamente dicho**, donde se aplican técnicas para identificar patrones en la producción científica. Entre los análisis realizados se incluyen la identificación de los autores más influyentes, las revistas con mayor número de publicaciones, los países con mayor producción académica y las palabras clave más frecuentes. Asimismo, se analizan redes de coautoría y co-ocurrencia de términos, lo que permite visualizar cómo se conectan los diferentes temas y actores dentro del campo de la educación virtual rural. Este análisis es fundamental porque transforma datos dispersos en información estructurada y significativa.

El sexto paso consiste en la **interpretación de los resultados obtenidos**. A partir del análisis bibliométrico, los autores identifican tendencias, áreas de mayor desarrollo y vacíos de investigación. Esta interpretación permite comprender cómo ha evolucionado el campo, qué temas han sido más estudiados y cuáles requieren mayor atención en futuras investigaciones.

Además, los autores relacionan estos hallazgos con el contexto actual de la educación virtual, especialmente en zonas rurales, lo que les permite generar conclusiones relevantes y aplicables.

Finalmente, el proceso culmina con la **formulación del aporte del estudio**, que consiste en ofrecer una visión estructurada y actualizada del conocimiento científico sobre educación virtual en contextos rurales. Gracias a este proceso, los autores logran identificar no solo el estado actual del campo, sino también sus principales desafíos y oportunidades, contribuyendo así al desarrollo de futuras investigaciones y a la mejora de políticas educativas.

En conjunto, el proceso seguido por los autores combina revisión sistemática, análisis bibliométrico e interpretación crítica, lo que les permite construir un aporte sólido, riguroso y útil para comprender la evolución y las tendencias de la educación virtual en zonas rurales.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema de la **falta de organización, claridad y enfoque específico en la investigación sobre educación virtual en zonas rurales** se basa en un enfoque metodológico sistemático que permite transformar información dispersa en conocimiento estructurado. El problema central identificado es que, aunque existe un número creciente de estudios sobre educación virtual, estos se encuentran fragmentados, con poca diferenciación entre contextos urbanos y rurales, lo que dificulta comprender el estado real del campo y diseñar soluciones adecuadas para comunidades rurales. Frente a esta situación, los autores proponen un proceso basado en análisis bibliométrico para organizar, clasificar e interpretar la información existente.

El primer paso del proceso consiste en la **delimitación del problema y del alcance del estudio**. Los autores definen que su interés se centra específicamente en la educación virtual en contextos rurales, lo cual es importante porque permite diferenciar este fenómeno de otros estudios más generales sobre educación digital. Esta delimitación asegura que el análisis se enfoque en las condiciones particulares de la ruralidad, como limitaciones de conectividad, infraestructura tecnológica y acceso a recursos educativos.

El segundo paso es la **recolección sistemática de información científica**, utilizando bases de datos reconocidas como Scopus y Web of Science. A través de una estrategia de búsqueda bien definida y el uso del protocolo PRISMA-2020, los autores logran identificar un conjunto de artículos relevantes. Posteriormente, aplican criterios de inclusión y exclusión para depurar la información, eliminando duplicados y documentos no pertinentes. Este proceso permite obtener una muestra representativa y confiable del conocimiento existente sobre el tema.

El tercer paso consiste en la **organización y clasificación de la información recopilada**. Los autores estructuran los datos en función de variables como autores, años de publicación, países, revistas y palabras clave. Esta organización permite transformar datos aislados en una base estructurada que facilita el análisis. Además, se agrupan los estudios según temáticas principales, lo que ayuda a identificar áreas de investigación predominantes y relaciones entre diferentes enfoques.

El cuarto paso es el **análisis bibliométrico**, donde se aplican técnicas para identificar patrones dentro de la producción científica. Este análisis permite determinar cuáles son los temas más investigados, qué países lideran la investigación, cuáles son las revistas más influyentes y cómo se relacionan los distintos conceptos a través de redes de co-ocurrencia. De esta manera, el proceso convierte información dispersa en una visión estructurada del campo de estudio.

El quinto paso es la **interpretación de los resultados**, donde los autores identifican tendencias, fortalezas y vacíos en la investigación existente. Este análisis revela, por ejemplo, que aunque

la educación virtual ha crecido significativamente, aún existen limitaciones en su implementación en zonas rurales, especialmente en términos de infraestructura tecnológica, formación docente y acceso equitativo. Esta etapa es clave porque permite comprender no solo qué se ha investigado, sino también qué aspectos requieren mayor atención.

Finalmente, el proceso culmina con la **propuesta de lineamientos y orientaciones para futuras investigaciones y políticas educativas**. A partir de los hallazgos, los autores sugieren la necesidad de desarrollar enfoques más específicos para contextos rurales, mejorar la conectividad, fortalecer la formación digital de los docentes y diseñar estrategias educativas adaptadas a las características de estas comunidades. De esta manera, el problema no solo se describe, sino que se aborda mediante recomendaciones concretas que pueden guiar la acción educativa y la investigación futura.

En conjunto, el proceso transforma un problema de desorganización del conocimiento en una solución basada en análisis sistemático, permitiendo comprender mejor la educación virtual en zonas rurales y ofreciendo una base sólida para el desarrollo de nuevas investigaciones y políticas educativas más efectivas.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, las métricas utilizadas por los autores son principalmente **bibliométricas**, ya que su objetivo no es evaluar directamente el rendimiento de estudiantes, sino analizar la evolución de la producción científica sobre **virtual education in the rural sector**. Entre las métricas más importantes se encuentran el **número de publicaciones por año**, la **tasa de crecimiento de la producción científica**, el **número de citas**, la identificación de **autores con mayor productividad e impacto**, las **revistas más influyentes**, los **países con mayor producción**, la **co-ocurrencia de palabras clave**, la **evolución temática**, la **frecuencia y validez conceptual de keywords** y la conformación de **clusters temáticos**. Además, el estudio usa herramientas como **Microsoft Excel** y **VOSviewer** para representar redes de colaboración, mapas de palabras clave y evolución temática.

A partir de estas métricas, los autores obtienen varios resultados relevantes. En primer lugar, identifican un **crecimiento muy marcado de la literatura**, con una expansión del **97.8%**, y señalan que los años **2021, 2022 y 2023** fueron los de mayor productividad científica. En segundo lugar, encuentran que **Wang J.** es el autor más destacado en productividad e impacto, mientras que revistas como **Computers and Education** y **Telemedicine and E-health** sobresalen por su alta productividad e influencia. En cuanto a países, el análisis muestra que **Estados Unidos e India** destacan por productividad e impacto, mientras que **China** sobresale por cantidad de publicaciones. Además, el análisis temático revela una evolución desde temas iniciales como **transportation** hacia asuntos más actuales como **professional learning, mental health, public health y online learning**. También identifican ocho clusters temáticos, entre los cuales resalta uno vinculado a **e-learning, ICT y teacher training**, y otro relacionado con **digital literacy, agriculture e Internet of Things**.

Otra métrica importante es el análisis de frecuencia y validez de palabras clave, donde emergen conceptos como **rural health, teachers, digital inclusion, higher education, ICT y blended learning**, mientras que **education** aparece como un concepto consolidado y en crecimiento. Estos resultados permiten a los autores concluir que la investigación en este campo no solo está creciendo, sino que se está desplazando hacia temas más complejos e interdisciplinarios.

Al comentar estos hallazgos, puede decirse que los resultados son mejores que los de estudios aislados o revisiones narrativas, porque este artículo ofrece una **visión mucho más amplia, estructurada y cuantificable del campo**. Mientras otros trabajos se enfocan en experiencias concretas, aquí se logra mapear el desarrollo global de la investigación, identificar actores clave,

detectar vacíos y mostrar con evidencia objetiva hacia dónde evolucionan los temas. Por ello, su aporte resulta más sólido en términos de **alcance analítico y valor estratégico**, ya que permite orientar futuras investigaciones y políticas educativas con una base más completa y organizada.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte valioso porque ofrece una visión amplia y ordenada del campo de la **educación virtual en zonas rurales**, algo muy útil en un tema donde la información suele estar dispersa. Una de sus principales fortalezas es el uso de un **análisis bibliométrico con PRISMA-2020**, apoyado en bases de datos sólidas como **Scopus** y **Web of Science**, lo que le da rigor metodológico y permite identificar con claridad tendencias, autores influyentes, revistas relevantes, países líderes y temas emergentes. Además, el estudio tiene mérito porque no se limita a describir crecimiento en publicaciones, sino que también analiza **clusters temáticos, evolución de palabras clave, vacíos de investigación y una agenda futura**, lo cual lo vuelve útil tanto para investigadores como para quienes diseñan políticas educativas.

Sin embargo, una primera observación crítica es que, al tratarse de un estudio bibliométrico, el artículo ofrece una visión **muy panorámica**, pero no profundiza demasiado en la calidad pedagógica o en la efectividad real de las experiencias de educación virtual en entornos rurales. Es decir, permite saber qué se ha investigado y hacia dónde evoluciona el campo, pero no analiza con detalle cuáles estrategias concretas han funcionado mejor en la práctica ni qué modelos de intervención han generado mejores resultados de aprendizaje en comunidades rurales.

Otra limitación importante, reconocida por los propios autores, es la dependencia de **Scopus** y **Web of Science** como fuentes principales. Aunque estas bases son confiables y de alta calidad, esta decisión puede dejar fuera estudios relevantes publicados en revistas no indexadas, informes técnicos, literatura regional o investigaciones locales, que en un tema como ruralidad y educación virtual podrían ser especialmente importantes. Esto significa que el mapa construido por el artículo es sólido, pero no necesariamente exhaustivo en términos de realidad territorial o producción académica periférica.

Asimismo, el artículo muestra que la investigación en este campo ha crecido mucho, pero también deja ver que buena parte de los estudios siguen siendo **desiguales en su enfoque**, con énfasis frecuentes en conectividad, inclusión digital y formación docente, mientras que otros temas como adaptación curricular, bienestar socioemocional, sostenibilidad tecnológica o evaluación del impacto a largo plazo todavía requieren mayor desarrollo. En ese sentido, el trabajo evidencia bien los vacíos, pero también confirma que el campo aún está en consolidación.

En síntesis, se trata de un artículo sólido, útil y bien estructurado como mapa general del conocimiento sobre educación virtual rural, pero su naturaleza bibliométrica hace que aún sea necesario complementarlo con estudios empíricos más profundos, contextualizados y aplicados a realidades rurales específicas.

11. ARTICULO 11

Author (s): Valencia-Arias, A.; Martínez Rojas, E.; Cardona-Acevedo, S.; Castañeda-Peláez, L.

Title of paper: Uso del aprendizaje automático en entornos de aprendizaje virtual: una revisión bibliométrica

Journal: EURASIA Journal of Mathematics, Science and Technology Education

Volume (issue): 21(9)

pag – pag (year): em2695 (2025)

Estado del arte que hace el autor

El estado del arte presentado por los autores se desarrolla en torno al creciente uso del **machine learning (ML)** dentro de los **virtual learning environments (VLEs)**, entendidos como plataformas digitales flexibles y accesibles que permiten gestionar procesos de enseñanza y aprendizaje en línea. Desde el inicio del artículo, los autores destacan que el ML se ha convertido en un componente crítico de la educación contemporánea, ya que ha demostrado ser eficaz para **predecir el desempeño académico, identificar estudiantes en riesgo y personalizar la experiencia de aprendizaje** a partir del análisis de grandes volúmenes de datos generados por los propios entornos virtuales. Esta revisión sitúa al ML no solo como una innovación tecnológica, sino como una herramienta con capacidad real de transformar la educación online.

Dentro de este panorama, los autores revisan estudios que muestran cómo distintas técnicas de **deep learning** y otros algoritmos de ML se han utilizado para **predecir resultados de aprendizaje** a partir de datos generados por los VLEs. La literatura reseñada indica que estos modelos pueden analizar patrones de interacción del estudiante, comportamientos de navegación, secuencias de acceso a recursos y otro tipo de trazas digitales, para anticipar dificultades académicas o necesidades de apoyo. Así, el estado del arte muestra que uno de los grandes intereses del campo ha sido convertir los datos educativos en información accionable para apoyar decisiones pedagógicas.

Un segundo eje importante del estado del arte es la **detección temprana de estudiantes en riesgo**. Los autores señalan que numerosos trabajos han evidenciado la utilidad del ML para identificar de forma temprana a quienes tienen alta probabilidad de bajo rendimiento, abandono o fracaso en contextos virtuales. Esta línea ha cobrado especial relevancia porque permite implementar **intervenciones preventivas y personalizadas**, algo crucial en la educación actual. Según la literatura revisada, la capacidad predictiva del ML resulta especialmente valiosa en contextos donde el seguimiento individual del estudiante es más difícil y donde los VLEs generan suficiente información para construir modelos de alerta temprana.

El estado del arte también incorpora investigaciones orientadas a evaluar los **estados cognitivos y emocionales de los estudiantes** en entornos digitales e incluso de realidad virtual. Los autores mencionan trabajos donde el ML se utiliza para monitorear aspectos más complejos del proceso de aprendizaje, con el fin de adaptar el entrenamiento o los recursos educativos a las necesidades individuales. Esto indica que la literatura ya no se limita a estudiar solo rendimiento o permanencia, sino que ha comenzado a interesarse por variables más finas, como el compromiso, la experiencia del usuario o la carga cognitiva en entornos virtuales.

Otro elemento central del estado del arte es la relación entre ML y **learning analytics**. A lo largo del artículo se observa que la literatura reciente ha dado mucha importancia al análisis sistemático de datos educativos para comprender el progreso del estudiante, detectar patrones de participación y mejorar la toma de decisiones en los VLEs. En la *Figura 7 del artículo (página 7)*, por ejemplo, el clúster temático más fuerte incluye precisamente términos como **learning analytics, at-risk students, clustering, academic performance y higher education**, lo cual evidencia que esta combinación se ha convertido en uno de los núcleos conceptuales más consolidados del campo.

Además, el estado del arte revisa el papel de técnicas específicas como **random forest**, **artificial neural networks**, **deep learning**, **clustering** y **recommender systems**. La revisión muestra que el campo se ha ido sofisticando progresivamente: en etapas tempranas se estudiaban sobre todo los VLEs como plataformas, mientras que en años más recientes se han incorporado enfoques de predicción, clasificación y recomendación basados en ML. En la *Figura 6 (página 7)* se aprecia esta evolución temática: en 2005 destacaba el tema **virtual learning environment**, mientras que en los años recientes ganan protagonismo términos como **student engagement**, **random forest**, **learning analytics** y **machine learning**. Esto demuestra que la investigación ha transitado desde una preocupación por la plataforma hacia una preocupación por los procesos inteligentes que pueden optimizarla.

Los autores también incluyen en el estado del arte una línea relevante sobre **equidad y reducción de brechas educativas**. Se menciona que los **cloud-powered VLEs** pueden contribuir a mitigar disparidades académicas entre zonas urbanas y rurales, ofreciendo acceso más equitativo a recursos de calidad. Desde esta perspectiva, el ML en VLEs no solo se asocia con personalización y eficacia, sino también con **inclusión educativa**. Esto amplía la comprensión del campo, ya que la aplicación del ML no se concibe únicamente en términos técnicos, sino también como parte de una agenda más amplia de justicia educativa.

Sin embargo, el estado del arte no es presentado como un panorama completamente resuelto. Los autores señalan que aún existen **retos importantes** en el diseño de VLEs inteligentes, como la integración de tecnologías emergentes, la necesidad de personalización a gran escala y la construcción de sistemas que sean al mismo tiempo efectivos, escalables y eficientes en recursos. También subrayan que, a pesar del crecimiento de la literatura, persisten **limitaciones relacionadas con la equidad y la justicia en learning analytics**, así como una falta de estudios suficientemente profundos sobre la aplicación de principios de equidad en este tipo de entornos. Esta observación muestra que el campo ha avanzado mucho en lo predictivo y técnico, pero todavía tiene desafíos éticos, sociales e institucionales por resolver.

A partir de todo ello, el estado del arte deja ver que el uso de ML en VLEs se ha consolidado como un campo emergente y estratégico, donde confluyen temas como predicción del rendimiento, detección de estudiantes en riesgo, minería de datos educativos, personalización del aprendizaje, aprendizaje analítico y recomendación de contenidos. No obstante, también muestra que el conocimiento sigue en expansión y que aún se requieren más estudios sistemáticos que organicen las tendencias, vacíos y áreas prioritarias del campo. Precisamente desde esa necesidad, los autores justifican su objetivo de realizar una **bibliometric review** que permita mapear la evolución de la investigación, identificar clústeres temáticos, reconocer palabras clave emergentes y construir una agenda futura sobre el uso del ML en VLEs.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge del reconocimiento de que, aunque el uso de **machine learning (ML)** en **virtual learning environments (VLEs)** ha crecido de manera notable y ya ha mostrado resultados prometedores en predicción, personalización e identificación de estudiantes en riesgo, todavía existe una **necesidad de revisar de forma completa y estructurada las tendencias de investigación** en este campo. Desde el resumen y la introducción, los autores dejan claro que algunas áreas muestran la necesidad de una bibliografía más exhaustiva, lo que implica una crítica implícita a la literatura existente: hay muchos estudios valiosos, pero el conocimiento sigue estando disperso y no suficientemente organizado para comprender con claridad hacia dónde evoluciona el campo.

Otra crítica importante que plantean es que, pese al creciente interés en el uso de algoritmos de ML para mejorar resultados educativos, la literatura aún presenta **limitaciones en aspectos de equidad y fairness dentro del learning analytics**. El artículo menciona explícitamente que faltan estudios más profundos y sistemáticos sobre cómo aplicar principios de equidad en los

VLEs, lo que sugiere que buena parte de las investigaciones previas se ha centrado más en la eficacia predictiva de los modelos que en sus implicancias éticas, sociales y distributivas. En otras palabras, los autores cuestionan que el avance técnico no siempre ha ido acompañado de una reflexión suficientemente robusta sobre justicia educativa.

Asimismo, los autores critican implícitamente que muchas investigaciones previas se han enfocado en **casos puntuales o aplicaciones específicas**, como predicción del rendimiento, identificación de estudiantes en riesgo o monitoreo cognitivo, pero sin ofrecer una visión global del campo. Esto genera una dificultad para identificar cuáles son los autores más influyentes, los temas que dominan la agenda, las áreas emergentes y los vacíos que deberían priorizarse en el futuro. Por eso, la motivación del artículo no es solo describir nuevas aplicaciones del ML, sino ordenar el panorama científico existente mediante una revisión bibliométrica rigurosa.

Otra observación crítica del artículo apunta a los **desafíos no resueltos en el desarrollo de VLEs inteligentes**, tales como la integración de tecnologías emergentes, la necesidad de personalización a nivel de sistema, la escalabilidad y la eficiencia en recursos. Al mencionar estos problemas, los autores sugieren que la literatura previa ha avanzado mucho en modelos y algoritmos, pero todavía enfrenta obstáculos importantes en términos de implementación real y sostenibilidad de estos entornos.

En síntesis, la motivación del estudio nace de la necesidad de superar una literatura fragmentada, demasiado centrada en aplicaciones aisladas o en la eficacia técnica, y avanzar hacia una comprensión más completa del campo. Los autores buscan identificar tendencias, vacíos, temas emergentes y desafíos estratégicos para orientar mejor la investigación futura sobre el uso de ML en VLEs.

Descripción del aporte del autor

El artículo realiza un aporte relevante al campo de la educación digital al desarrollar una **revisión bibliométrica integral sobre el uso de machine learning (ML) en virtual learning environments (VLEs)**. A diferencia de muchos estudios previos que se enfocan en aplicaciones específicas o en resultados particulares, este trabajo propone una **visión estructurada, global y sistemática del conocimiento científico existente**, permitiendo comprender cómo ha evolucionado el campo, cuáles son sus principales líneas de investigación y hacia dónde se dirige en el futuro.

Uno de los aportes más importantes del estudio es la aplicación de una **metodología bibliométrica rigurosa**, basada en el análisis de publicaciones indexadas en bases de datos reconocidas como **Scopus**. Este enfoque permite identificar patrones cuantificables dentro de la producción científica, tales como el crecimiento de publicaciones, la distribución de autores, las revistas más influyentes y las redes de colaboración académica. De esta manera, el artículo no solo recopila información, sino que la transforma en conocimiento estructurado que facilita la comprensión del campo.

Otro aporte clave es la **identificación de tendencias temáticas en la investigación sobre ML en VLEs**. A través del análisis de palabras clave y su evolución en el tiempo, los autores logran evidenciar cómo el campo ha transitado desde un enfoque centrado en los entornos virtuales como plataformas hacia un enfoque más sofisticado orientado al uso de algoritmos inteligentes. Por ejemplo, en etapas iniciales predominaba el término *virtual learning environment*, mientras que en años recientes han cobrado protagonismo conceptos como **machine learning, learning analytics, student engagement y random forest**. Esta evolución demuestra que la investigación ha pasado de una preocupación tecnológica básica a una orientación más analítica y predictiva.

El artículo también aporta una **identificación clara de los principales clústeres temáticos** dentro del campo. Entre ellos destacan áreas como:

- **Learning analytics y predicción del rendimiento académico**, donde el ML se utiliza para analizar datos educativos y anticipar resultados.
- **Detección de estudiantes en riesgo**, orientada a prevenir abandono o bajo desempeño.
- **Sistemas de recomendación y personalización del aprendizaje**, que buscan adaptar contenidos a las necesidades del estudiante.
- **Student engagement y análisis del comportamiento**, que estudian la interacción del usuario con el entorno virtual.

Este mapeo temático es especialmente valioso porque permite comprender la estructura interna del campo y cómo se relacionan sus diferentes líneas de investigación.

Asimismo, el artículo aporta una **visión clara de los actores más influyentes en la investigación**, identificando autores, instituciones, países y revistas con mayor impacto. Esto permite reconocer quiénes están liderando el desarrollo del conocimiento en esta área y facilita la construcción de redes académicas. Además, este análisis contribuye a orientar futuras investigaciones, ya que permite identificar fuentes relevantes y tendencias consolidadas.

Otro aporte importante es el análisis de la **evolución temporal del campo**, donde los autores evidencian un crecimiento significativo en la producción científica en los últimos años. Este crecimiento está asociado al avance de tecnologías de inteligencia artificial y al aumento del uso de entornos virtuales en educación. El estudio demuestra que el campo se encuentra en una fase de expansión, lo que indica que seguirá siendo un área clave de investigación en el futuro.

El artículo también contribuye al identificar **vacíos y desafíos en la investigación existente**. Entre ellos destacan la necesidad de profundizar en temas de **equidad y fairness en learning analytics**, la falta de estudios integradores que aborden múltiples dimensiones del aprendizaje y los retos asociados a la implementación real de sistemas basados en ML en contextos educativos. Este aporte es especialmente relevante porque no solo describe lo que se ha hecho, sino que también orienta lo que aún falta por investigar.

Además, el estudio aporta implicaciones prácticas importantes. Al analizar cómo se utilizan las técnicas de ML en VLEs, los autores destacan su potencial para mejorar la **personalización del aprendizaje, la detección temprana de problemas académicos y la toma de decisiones educativas basada en datos**. Esto convierte al artículo en una herramienta útil no solo para investigadores, sino también para diseñadores de sistemas educativos, docentes y responsables de políticas públicas.

Otro aporte relevante es la incorporación de una **perspectiva crítica sobre el uso de ML en educación**, señalando que el desarrollo tecnológico debe ir acompañado de consideraciones éticas, especialmente en lo relacionado con la equidad, la privacidad y la justicia en el uso de datos. Este enfoque amplía la discusión más allá de lo técnico y posiciona al ML dentro de un marco más amplio de responsabilidad social en la educación digital.

Finalmente, uno de los aportes más importantes del artículo es que proporciona una **base sólida para futuras investigaciones**, al ofrecer una visión clara de las tendencias, actores clave, temas emergentes y vacíos del campo. Este conocimiento permite orientar nuevas líneas de investigación, mejorar el diseño de sistemas educativos y fortalecer el uso del ML en entornos virtuales.

En conjunto, el aporte del artículo puede resumirse en tres dimensiones principales. Primero, ofrece un análisis bibliométrico riguroso que organiza el conocimiento existente sobre ML en VLEs. Segundo, identifica tendencias, clústeres temáticos y actores clave dentro del campo. Y

tercero, propone una agenda futura que incluye desafíos técnicos, pedagógicos y éticos. Por ello, el trabajo representa una contribución sólida y estratégica para el desarrollo de la educación digital basada en inteligencia artificial.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en una **metodología bibliométrica estructurada**, orientada a analizar de manera sistemática la producción científica sobre el uso de **machine learning (ML) en virtual learning environments (VLEs)**. En primer lugar, los autores parten de la identificación del problema: aunque existe un número creciente de investigaciones sobre ML aplicado a la educación, el conocimiento se encuentra **disperso, fragmentado y poco organizado**, lo que dificulta comprender las tendencias reales del campo. A partir de esta necesidad, plantean como objetivo desarrollar una revisión bibliométrica que permita mapear la evolución del área y estructurar la información existente.

El segundo paso del proceso consiste en la **definición del enfoque metodológico**. Los autores optan por una revisión bibliométrica, ya que este tipo de análisis permite estudiar de manera cuantitativa la producción científica, identificar patrones y establecer relaciones entre diferentes elementos del conocimiento, como autores, palabras clave y revistas. Este enfoque es adecuado porque permite transformar grandes volúmenes de información en una visión estructurada del campo de estudio.

El tercer paso es la **recopilación de información científica**. Para ello, los autores seleccionan una base de datos académica reconocida, como **Scopus**, y realizan búsquedas utilizando términos relacionados con machine learning y virtual learning environments. A partir de esta búsqueda, obtienen un conjunto inicial de publicaciones, el cual posteriormente es depurado mediante criterios de selección que aseguran la relevancia y calidad de los artículos incluidos en el análisis.

El cuarto paso consiste en la **organización de los datos recopilados**. Los autores estructuran la información en función de variables como autores, año de publicación, palabras clave, número de citas y fuentes de publicación. Esta organización permite construir una base de datos que facilita el análisis posterior. Además, se identifican los elementos más relevantes dentro del conjunto de datos, lo que permite enfocar el análisis en los aspectos más significativos del campo.

El quinto paso es el **análisis bibliométrico**, donde se aplican técnicas para identificar patrones dentro de la producción científica. En esta etapa, los autores analizan la evolución temporal de las publicaciones, la frecuencia de palabras clave, la formación de clústeres temáticos y las redes de relación entre diferentes conceptos. También utilizan herramientas como **VOSviewer** para visualizar estas relaciones, lo que permite identificar tendencias y áreas emergentes dentro del campo.

El sexto paso consiste en la **interpretación de los resultados obtenidos**. A partir del análisis, los autores identifican las principales tendencias, los temas más estudiados y los vacíos de investigación. Este proceso permite comprender cómo ha evolucionado el uso del ML en VLEs y cuáles son los desafíos que aún deben abordarse. Además, los autores relacionan estos hallazgos con el contexto actual de la educación digital, lo que les permite generar conclusiones relevantes.

Finalmente, el proceso culmina con la **formulación del aporte del estudio**, que consiste en ofrecer una visión estructurada del campo, identificando tendencias, actores clave y áreas de oportunidad para futuras investigaciones. Gracias a este proceso, los autores logran transformar información dispersa en conocimiento organizado, lo que constituye el núcleo de su contribución.

En conjunto, el proceso seguido por los autores combina recolección sistemática de datos, análisis cuantitativo y reflexión crítica, permitiendo construir un aporte sólido que organiza y clarifica el estado actual del uso del machine learning en entornos virtuales de aprendizaje.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema de la **falta de organización y claridad en la investigación sobre machine learning (ML) en virtual learning environments (VLEs)** se basa en un enfoque sistemático que permite transformar información dispersa en conocimiento estructurado. El problema central identificado es que, aunque existe una gran cantidad de estudios sobre ML aplicado a la educación, estos se encuentran fragmentados, con enfoques aislados y sin una visión global que permita comprender las tendencias, los actores clave y los vacíos del campo. Frente a esta situación, los autores proponen un proceso basado en análisis bibliométrico que permite organizar y analizar de manera integral la producción científica existente.

El primer paso del proceso consiste en la **delimitación del problema y del alcance del estudio**. Los autores definen que su interés se centra específicamente en la relación entre ML y VLEs, lo que permite enfocar el análisis en un área concreta dentro de la educación digital. Esta delimitación es importante porque evita la dispersión temática y asegura que los resultados sean relevantes para comprender la evolución de este campo específico.

El segundo paso es la **recopilación sistemática de información científica**. Para ello, los autores utilizan bases de datos académicas reconocidas, como Scopus, y realizan búsquedas con palabras clave relacionadas con ML y entornos virtuales de aprendizaje. A partir de esta búsqueda, obtienen un conjunto de artículos que posteriormente es filtrado mediante criterios de inclusión y exclusión, garantizando que solo se consideren estudios relevantes y de calidad. Este proceso permite construir una base sólida de información sobre la cual se desarrollará el análisis.

El tercer paso consiste en la **organización y estructuración de los datos recopilados**. Los autores clasifican la información en función de variables como año de publicación, autores, palabras clave, número de citas y fuentes de publicación. Esta organización permite transformar datos aislados en una base estructurada que facilita el análisis posterior. Además, se identifican los elementos más representativos del campo, lo que permite centrar el estudio en los aspectos más relevantes.

El cuarto paso es el **análisis bibliométrico**, donde se aplican técnicas para identificar patrones dentro de la producción científica. En esta etapa, los autores analizan la evolución temporal de las publicaciones, la frecuencia de palabras clave, la formación de clústeres temáticos y las relaciones entre diferentes conceptos. También utilizan herramientas de visualización como VOSviewer para representar redes de co-ocurrencia y colaboración, lo que permite comprender mejor la estructura del campo.

El quinto paso es la **interpretación de los resultados**, donde los autores identifican tendencias, áreas de mayor desarrollo y vacíos de investigación. Este análisis permite comprender cómo ha evolucionado el uso del ML en VLEs, cuáles son los temas más estudiados y qué aspectos requieren mayor atención en el futuro. Además, los autores destacan desafíos importantes, como la necesidad de mejorar la equidad en el uso de learning analytics y la implementación práctica de sistemas basados en ML.

Finalmente, el proceso culmina con la **propuesta de orientaciones para futuras investigaciones y aplicaciones educativas**. A partir de los hallazgos, los autores sugieren la necesidad de desarrollar enfoques más integradores, mejorar la aplicación de principios éticos

y fortalecer el uso del ML para la personalización del aprendizaje y la toma de decisiones educativas. De esta manera, el problema no solo se describe, sino que se aborda mediante recomendaciones concretas que pueden guiar el desarrollo del campo.

En conjunto, el proceso transforma un problema de fragmentación del conocimiento en una solución basada en análisis sistemático, permitiendo comprender mejor el campo del ML en VLEs y ofreciendo una base sólida para el desarrollo de futuras investigaciones y aplicaciones educativas.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, las métricas utilizadas por los autores son principalmente **bibliométricas**, ya que el objetivo del estudio no es medir directamente el aprendizaje de estudiantes, sino analizar la evolución de la producción científica sobre el uso de **machine learning (ML) en virtual learning environments (VLEs)**. Entre las métricas más importantes se encuentran el **número de publicaciones por año**, la **tasa de crecimiento de la producción científica**, la identificación de **autores con mayor productividad e impacto**, las **revistas más influyentes**, los **países con mayor producción**, la **co-ocurrencia de palabras clave**, la **evolución temática** y la **frecuencia y vigencia de keywords**. Además, para el análisis de palabras clave y redes bibliométricas, los autores utilizan herramientas como **VOSviewer**, lo cual les permite representar gráficamente los clústeres temáticos y las asociaciones conceptuales dentro del campo.

A partir de estas métricas, los autores obtienen varios resultados relevantes. En primer lugar, identifican un **crecimiento de 99.66% en la producción científica** relacionada con ML en VLEs, lo que demuestra una expansión casi total del interés en este tema. También encuentran que los años **2023, 2021, 2019 y 2022** fueron los de mayor producción de artículos, lo que indica que el campo se ha intensificado especialmente en los años más recientes. En cuanto a autores, destacan **Nawaz, R., Waheed, H., Aljohani, N. R. y Hassan, S.-U.** por su alta productividad e impacto. Respecto a revistas, sobresalen **Computers in Human Behavior** y **Frontiers in Neuroscience** por su influencia, y **CEUR Workshop Proceedings** por su productividad. En el plano geográfico, el **Reino Unido** y **Estados Unidos** aparecen como líderes tanto en productividad como en impacto, mientras que **India** resalta por su elevada producción científica.

Otra métrica importante es la **evolución temática**, que muestra un cambio desde temas iniciales como **virtual learning environment** hacia conceptos más recientes como **student engagement, random forests, learning analytics y machine learning**. Asimismo, la red de co-ocurrencia de palabras clave evidencia ocho clústeres temáticos, siendo el más fuerte el relacionado con **learning analytics, at-risk students, clustering, academic performance y higher education**. En el análisis de vigencia y frecuencia de keywords, los autores encuentran que términos como **at-risk students, Covid-19, online learning platforms, student performance, artificial neural networks y random forests** se posicionan como palabras emergentes, mientras que **machine learning** aparece como un concepto en descenso relativo de novedad, aunque sigue siendo central.

Al comentar estos hallazgos, puede decirse que los resultados son **mejores que los de revisiones tradicionales o estudios aislados**, porque este trabajo no se limita a describir aplicaciones puntuales del ML, sino que ofrece una visión estructurada y cuantificable de toda la producción científica del campo. Mientras otros trabajos muestran casos concretos de predicción o personalización, este artículo permite ver **qué temas dominan la agenda, qué autores lideran la investigación, qué países están impulsando el área y qué líneas emergen con más fuerza**. Por ello, su aporte es superior en términos de **alcance analítico y utilidad estratégica**, ya que no solo informa sobre el presente del campo, sino que ayuda a orientar

futuras investigaciones y decisiones educativas basadas en evidencia bibliométrica sólida.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte importante porque ofrece una **visión amplia, organizada y actualizada** sobre el uso de **machine learning en virtual learning environments**, un tema que ha crecido mucho en los últimos años. Una de sus principales fortalezas es que no se limita a describir estudios aislados, sino que construye un **mapa bibliométrico del campo**, identificando autores influyentes, revistas relevantes, países líderes, clústeres temáticos y palabras clave emergentes. Esto lo vuelve muy útil para investigadores que necesitan comprender el panorama general del área y ubicar con claridad dónde están las principales tendencias y vacíos de investigación.

Otra fortaleza relevante es el uso de una **metodología sistemática alineada con PRISMA 2020**, junto con herramientas como **VOSviewer**, lo que da mayor rigor al análisis y permite visualizar redes temáticas y de colaboración científica. Además, el artículo no solo presenta resultados cuantitativos, sino que también formula una **agenda de investigación futura**, destacando temas como big data, learning analytics, educational data mining, deep learning, at-risk students, VLEs y recommender systems. Esto le da un valor estratégico importante, porque no solo describe el estado actual del campo, sino que orienta hacia dónde debería avanzar.

Sin embargo, una primera observación crítica es que, al tratarse de una **revisión bibliométrica**, el artículo ofrece una mirada muy panorámica, pero profundiza menos en la **calidad pedagógica real** de las aplicaciones de ML en los entornos virtuales. Es decir, muestra bien qué se investiga, quién investiga y qué términos predominan, pero no entra con suficiente detalle en cuáles modelos de machine learning han sido más eficaces en la práctica educativa, ni en qué condiciones concretas producen mejores resultados de aprendizaje.

Otra limitación importante es que el estudio depende de bases de datos como **Scopus y Web of Science**, lo cual garantiza calidad académica, pero también puede dejar fuera investigaciones relevantes publicadas en otros espacios, especialmente literatura técnica, reportes institucionales o estudios aplicados no indexados. Esto significa que el panorama construido es sólido, pero no completamente exhaustivo, sobre todo en un campo tecnológico que avanza también fuera de los circuitos académicos tradicionales.

Además, aunque el artículo menciona cuestiones como la **equidad, la privacidad y la ética**, estas aparecen más como líneas futuras o vacíos de investigación que como un análisis profundo dentro del estudio mismo. En un tema tan sensible como el uso de ML en educación, hubiera sido valioso profundizar más en cómo estos riesgos están siendo tratados en la literatura actual y no solo señalarlos como pendientes.

En síntesis, se trata de un artículo sólido y muy útil como **mapa general del conocimiento** sobre ML en VLEs, pero que necesita complementarse con estudios más empíricos y pedagógicos para comprender mejor el impacto real de estas tecnologías en el aprendizaje y en la justicia educativa.

12. ARTICULO 12

Author (s): Calderón Maldonado, O. D.; Florencia Ponce, M. F.; Vera Zambrano, M. M.; Zamora Valle, R. C.

Title of paper: Inteligencia Artificial y Aprendizaje Adaptativo: una Estrategia Innovadora para Optimizar la Formación de Estudiantes en la Educación Superior

Journal: Reincisol

Volume (issue): 4(8)

pag – pag (year): 3553–3579 (2025)

Estado del arte que hace el autor

El estado del arte presentado por los autores se desarrolla en torno a la incorporación de la **inteligencia artificial (IA)** y el **aprendizaje adaptativo** como estrategias innovadoras en la educación superior. Desde la introducción, el artículo plantea que la irrupción de la IA ha abierto nuevas posibilidades para transformar los procesos de enseñanza-aprendizaje, especialmente al permitir la **personalización de los itinerarios formativos** de los estudiantes según sus ritmos, estilos y necesidades. Esta idea sitúa el estado del arte en una línea de investigación contemporánea donde la educación universitaria ya no se concibe únicamente como transmisión de contenidos, sino como un proceso flexible, pertinente y centrado en el estudiante.

Uno de los primeros ejes del estado del arte es la relación entre **educación superior y sociedad del conocimiento**. Los autores explican que, en este contexto, las universidades deben formar profesionales capaces de responder a entornos dinámicos, globalizados y altamente digitalizados. La literatura revisada señala que las instituciones de educación superior ya no solo generan y transmiten saberes, sino que deben promover aprendizajes flexibles, críticos, colaborativos y orientados al desarrollo de competencias cognitivas, digitales y socioemocionales. Así, el estado del arte muestra que la incorporación de tecnologías inteligentes no surge como una moda pasajera, sino como respuesta a exigencias estructurales de la formación universitaria actual.

En esta misma línea, los autores revisan las **transformaciones educativas del siglo XXI**, destacando que la educación superior ha pasado de modelos tradicionales centrados en la enseñanza estandarizada hacia enfoques basados en competencias, resolución de problemas y pensamiento crítico. La literatura citada en el artículo resalta que la integración intensiva de tecnologías digitales ha diversificado los modelos pedagógicos y ha impulsado metodologías como la gamificación, el aprendizaje adaptativo y el uso de inteligencia artificial. Desde esta perspectiva, el estado del arte sitúa la IA y el aprendizaje adaptativo dentro de una tendencia más amplia de innovación pedagógica y transformación institucional.

Otro eje importante del estado del arte es la noción de **calidad, pertinencia y flexibilidad** en la formación universitaria. Los autores señalan que la literatura reciente insiste en que la calidad educativa no puede medirse solo por cobertura o contenidos, sino también por la capacidad de adaptar la enseñanza a los estilos y ritmos de aprendizaje de los estudiantes. Aquí aparece con fuerza el aprendizaje adaptativo, entendido como un enfoque que ajusta contenidos, actividades y evaluaciones según las características individuales del estudiante, con apoyo de herramientas tecnológicas y sistemas de inteligencia artificial. De este modo, el estado del arte presenta el aprendizaje adaptativo como una respuesta a la necesidad de construir trayectorias formativas más personalizadas e inclusivas.

En cuanto a la **innovación educativa y las tecnologías digitales**, el artículo revisa aportes que destacan cómo plataformas virtuales, simuladores, laboratorios en línea y recursos interactivos han modificado profundamente los procesos de enseñanza-aprendizaje en la educación superior. Esta revisión muestra que la innovación educativa no se limita a usar tecnología, sino

que implica transformar metodologías, estrategias y modos de interacción en el aula universitaria. Los autores sostienen, a partir de la literatura revisada, que estas tecnologías contribuyen a generar entornos más dinámicos, participativos y centrados en el desarrollo integral del estudiante.

El estado del arte dedica además una sección específica a la **inteligencia artificial en la educación**. Allí se explica que la IA se define, en el contexto académico, como un conjunto de tecnologías capaces de aprender, razonar y tomar decisiones a partir de datos, con aplicaciones concretas en tutorías inteligentes, analítica de aprendizaje, sistemas de recomendación y chatbots educativos. La revisión teórica del artículo muestra que estas herramientas permiten automatizar evaluaciones, ofrecer retroalimentación inmediata, anticipar dificultades de aprendizaje y personalizar contenidos. En consecuencia, el estado del arte presenta a la IA como una tecnología estratégica para optimizar tanto la experiencia del estudiante como la gestión pedagógica de las instituciones.

De manera complementaria, el artículo revisa la literatura sobre **ventajas y limitaciones de la IA en entornos educativos**. Entre las ventajas, se destacan la personalización del aprendizaje, la capacidad de analizar grandes volúmenes de datos, la detección temprana de dificultades y el incremento de la motivación y el compromiso estudiantil. Sin embargo, también se reconocen limitaciones importantes, como la dependencia de infraestructura tecnológica, la necesidad de formación docente especializada, los riesgos en privacidad de datos y las desigualdades en el acceso. Esta parte del estado del arte es relevante porque no presenta una visión ingenua de la IA, sino una comprensión equilibrada de sus potencialidades y desafíos.

En relación con el **aprendizaje adaptativo**, los autores muestran que este se sustenta en principios de personalización, flexibilidad y retroalimentación continua. El estado del arte explica que este enfoque ajusta los niveles de dificultad, prioriza contenidos según las necesidades del estudiante y promueve la autonomía, la autorregulación y la motivación. También se revisan recursos como plataformas adaptativas, simuladores, laboratorios virtuales y recursos educativos inteligentes, que permiten monitorear el progreso y ofrecer intervenciones oportunas. Todo esto refuerza la idea de que el aprendizaje adaptativo constituye una evolución pedagógica que desplaza el foco desde la enseñanza uniforme hacia experiencias individualizadas.

Uno de los puntos más fuertes del estado del arte es la **sinergia entre IA y aprendizaje adaptativo**. Los autores sostienen que la IA aporta la capacidad de analizar datos, predecir desempeños y automatizar respuestas, mientras que el aprendizaje adaptativo usa esa información para reorganizar rutas, contenidos y actividades. Así, la literatura revisada por el artículo muestra que la combinación de ambas estrategias facilita la detección temprana de dificultades, incrementa la personalización y fortalece competencias cognitivas, digitales y profesionales. En las páginas dedicadas al marco teórico, esta sinergia aparece como el núcleo conceptual de la propuesta del artículo.

Finalmente, el estado del arte incluye referencias a **estudios de caso recientes**, donde se evidencia que la IA ya está siendo considerada una herramienta relevante en la educación superior, tanto para mejorar la retroalimentación personalizada como para fortalecer el aprendizaje autónomo. Estas referencias, junto con la revisión sistemática presentada por los autores, permiten concluir que el campo ha avanzado en reconocer el potencial de la IA y el aprendizaje adaptativo para optimizar la formación universitaria. Sin embargo, también se mantiene la necesidad de abordar con mayor profundidad temas como infraestructura, capacitación docente, ética, privacidad y equidad. En síntesis, el estado del arte muestra un campo en expansión, con bases conceptuales sólidas y aplicaciones prometedoras, pero todavía en proceso de consolidación dentro de la educación superior.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una problemática muy clara dentro de la educación superior actual: aunque la **inteligencia artificial (IA)** y el **aprendizaje adaptativo** ofrecen grandes posibilidades para transformar la enseñanza, su incorporación en las universidades todavía es **limitada, desigual y poco articulada con los modelos pedagógicos tradicionales**. En la introducción del artículo, los autores señalan que muchos procesos formativos siguen centrados en metodologías estandarizadas que no responden a la diversidad de ritmos, estilos y necesidades de aprendizaje de los estudiantes. Esta observación constituye una crítica directa a los enfoques tradicionales, que continúan priorizando esquemas homogéneos de enseñanza en lugar de trayectorias formativas personalizadas.

Otra crítica importante que plantean es la existencia de una **brecha tecnológica entre instituciones**, ya que no todas cuentan con el mismo nivel de acceso a recursos digitales, plataformas inteligentes o infraestructura suficiente para implementar estas innovaciones. Esto significa que, aunque la literatura reconoce los beneficios de la IA y del aprendizaje adaptativo, en la práctica su incorporación no avanza con la misma intensidad en todos los contextos universitarios. Por tanto, la motivación del estudio también se relaciona con la necesidad de generar evidencia que permita orientar a las instituciones en la adopción de modelos más equitativos e innovadores.

Asimismo, los autores critican de forma implícita la **falta de formación especializada del profesorado** en el uso de estas herramientas. Según el artículo, persiste una resistencia al cambio por parte de docentes que no han sido preparados para integrar tecnologías basadas en IA dentro de sus prácticas pedagógicas. Esta limitación no solo dificulta la implementación técnica de estas herramientas, sino que también frena la transformación metodológica que requiere una educación superior centrada en el estudiante. En este sentido, el artículo deja ver que el problema no está únicamente en la tecnología, sino también en las capacidades institucionales y humanas necesarias para aprovecharla de forma pertinente.

Otra observación crítica relevante es que, junto a los beneficios de la IA, siguen presentes desafíos relacionados con la **ética, la privacidad de los datos y la sostenibilidad de las plataformas**. Los autores subrayan que estos aspectos dificultan la implementación plena de la IA y del aprendizaje adaptativo como estrategia innovadora en la educación superior. Esto implica una crítica a los enfoques que presentan estas tecnologías únicamente desde una visión optimista, sin considerar los riesgos y tensiones que acompañan su uso en entornos universitarios.

En síntesis, la motivación del artículo nace de la necesidad de responder a los desafíos de calidad, pertinencia y flexibilidad que enfrenta la educación superior en un contexto de transformación digital. Los autores consideran que la IA y el aprendizaje adaptativo pueden contribuir de manera importante a personalizar la formación, optimizar el rendimiento académico y fortalecer competencias relevantes para la sociedad del conocimiento, pero reconocen que para ello es necesario superar limitaciones pedagógicas, tecnológicas, éticas e institucionales todavía presentes en la educación universitaria.

Descripción del aporte del autor

El artículo realiza un aporte relevante al campo de la educación superior al analizar de manera integrada el papel de la **inteligencia artificial (IA)** y el **aprendizaje adaptativo** como estrategias innovadoras para mejorar los procesos de enseñanza-aprendizaje. A diferencia de otros trabajos que estudian estas tecnologías de forma aislada o desde una perspectiva únicamente técnica, este estudio propone una **visión articulada entre tecnología, pedagogía y formación profesional**, lo que permite comprender su impacto real dentro del contexto universitario.

Uno de los principales aportes del artículo es la **conceptualización clara de la inteligencia artificial en educación**, definiéndola no solo como una herramienta tecnológica, sino como un conjunto de sistemas capaces de **analizar datos, aprender de ellos y tomar decisiones para optimizar el aprendizaje**. Esta definición permite comprender que la IA no se limita a automatizar procesos, sino que tiene el potencial de transformar la forma en que se diseñan y ejecutan las experiencias educativas. A partir de esta base, el artículo posiciona a la IA como un elemento clave para avanzar hacia modelos educativos más personalizados y eficientes.

Otro aporte fundamental es la explicación del **aprendizaje adaptativo como un enfoque pedagógico centrado en el estudiante**. El artículo destaca que este tipo de aprendizaje permite ajustar contenidos, actividades y evaluaciones según las características individuales de cada estudiante, considerando factores como su ritmo de aprendizaje, nivel de conocimiento previo y estilo cognitivo. De esta manera, se supera el modelo tradicional de enseñanza homogénea, promoviendo una educación más flexible, inclusiva y orientada al desarrollo de competencias.

El aporte más significativo del artículo radica en la **integración de la inteligencia artificial con el aprendizaje adaptativo**. Los autores explican que la IA proporciona las herramientas necesarias para recopilar y analizar grandes volúmenes de datos sobre el comportamiento y desempeño de los estudiantes, mientras que el aprendizaje adaptativo utiliza esta información para personalizar la experiencia educativa. Esta sinergia permite desarrollar sistemas capaces de **identificar fortalezas y debilidades del estudiante, ofrecer retroalimentación inmediata y proponer rutas de aprendizaje personalizadas**, lo que mejora tanto el rendimiento académico como el compromiso del estudiante.

Asimismo, el artículo aporta una **visión integral de los beneficios de estas tecnologías en la educación superior**. Entre los principales beneficios identificados se encuentran la mejora del rendimiento académico, el fortalecimiento de la motivación y el engagement, la promoción del aprendizaje autónomo y la optimización de la toma de decisiones pedagógicas. Estos beneficios se sustentan en la capacidad de la IA para analizar datos en tiempo real y en la flexibilidad del aprendizaje adaptativo para ajustar los procesos educativos según las necesidades del estudiante.

Otro aporte relevante es el análisis de la **aplicación práctica de estas tecnologías en entornos educativos**. El artículo menciona el uso de herramientas como plataformas virtuales inteligentes, sistemas de tutoría automatizada, simuladores, laboratorios virtuales y recursos interactivos, que permiten implementar el aprendizaje adaptativo en la práctica. Esto demuestra que el enfoque propuesto no es solo teórico, sino que tiene aplicaciones concretas que pueden ser utilizadas por instituciones educativas para mejorar sus procesos formativos.

Además, el estudio aporta una reflexión importante sobre los **desafíos y limitaciones de la implementación de la IA en la educación superior**. Entre estos desafíos se encuentran la necesidad de infraestructura tecnológica adecuada, la formación docente en el uso de estas herramientas, la resistencia al cambio y los problemas relacionados con la privacidad de los datos. Este análisis es valioso porque permite comprender que la innovación educativa no depende únicamente de la tecnología, sino también de factores institucionales y humanos.

El artículo también contribuye al destacar la importancia de desarrollar **competencias digitales y cognitivas en los estudiantes**, necesarias para interactuar eficazmente con entornos de aprendizaje basados en IA. De esta manera, el aporte no se limita a la tecnología, sino que se extiende a la formación integral del estudiante, preparándolo para enfrentar los retos de la sociedad del conocimiento.

Otro aspecto importante del aporte es la **orientación hacia la mejora de la calidad educativa**. Los autores plantean que la integración de IA y aprendizaje adaptativo permite avanzar hacia una educación más pertinente, flexible y de calidad, capaz de responder a las demandas del

entorno actual. Esto implica no solo mejorar el rendimiento académico, sino también formar profesionales con habilidades críticas, creativas y adaptativas.

Finalmente, el artículo aporta una **base conceptual y práctica para futuras investigaciones**, al identificar áreas donde aún existen vacíos de conocimiento, como la evaluación del impacto a largo plazo de estas tecnologías, la equidad en el acceso y el desarrollo de modelos pedagógicos más integrados. Este enfoque prospectivo permite orientar nuevas líneas de investigación y contribuir al desarrollo del campo.

En conjunto, el aporte del artículo puede resumirse en tres dimensiones principales. Primero, ofrece una integración teórica entre inteligencia artificial y aprendizaje adaptativo. Segundo, demuestra su aplicación práctica en la educación superior. Y tercero, identifica beneficios, desafíos y oportunidades futuras. Por ello, el trabajo representa una contribución sólida para la transformación de la educación universitaria en el contexto digital.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en un enfoque **teórico-analítico**, orientado a comprender y articular el papel de la **inteligencia artificial (IA)** y el **aprendizaje adaptativo** dentro de la educación superior. En primer lugar, los autores parten de la identificación de un problema central: la necesidad de transformar los modelos educativos tradicionales hacia enfoques más flexibles, personalizados y alineados con las demandas de la sociedad del conocimiento. A partir de este diagnóstico, plantean la integración de tecnologías inteligentes como una vía para mejorar la calidad y pertinencia del aprendizaje universitario.

El segundo paso del proceso consiste en la **revisión del marco teórico**, donde los autores analizan conceptos fundamentales como educación superior, innovación educativa, inteligencia artificial y aprendizaje adaptativo. En esta etapa, se recopilan y sistematizan aportes de diferentes estudios que explican cómo estas tecnologías han sido utilizadas en contextos educativos. Esta revisión permite establecer una base conceptual sólida que sustenta el desarrollo del artículo y orienta la propuesta de integración entre IA y aprendizaje adaptativo.

El tercer paso es la **definición conceptual de las variables principales del estudio**. Los autores caracterizan la inteligencia artificial como un sistema capaz de analizar datos y tomar decisiones, y el aprendizaje adaptativo como un enfoque pedagógico que ajusta los contenidos y actividades según las necesidades del estudiante. Esta conceptualización es clave porque permite delimitar claramente el objeto de estudio y establecer las relaciones entre ambos elementos.

El cuarto paso consiste en la **integración de los conceptos analizados**, donde los autores articulan la relación entre IA y aprendizaje adaptativo. En esta etapa, explican cómo la IA proporciona las herramientas necesarias para recopilar y analizar datos educativos, mientras que el aprendizaje adaptativo utiliza esta información para personalizar el proceso de enseñanza-aprendizaje. Esta integración constituye el núcleo del aporte del artículo, ya que permite comprender cómo ambas tecnologías pueden trabajar de manera conjunta para mejorar la experiencia educativa.

El quinto paso es el **análisis de aplicaciones prácticas**, donde los autores examinan cómo estas tecnologías pueden implementarse en entornos educativos reales. En esta etapa, se describen herramientas como plataformas virtuales, sistemas de tutoría inteligente, simuladores y recursos interactivos, que permiten aplicar la IA y el aprendizaje adaptativo en la práctica. Este análisis demuestra que la propuesta no es únicamente teórica, sino que tiene implicaciones concretas para la educación superior.

El sexto paso consiste en la **identificación de beneficios y desafíos**, donde los autores evalúan el impacto de estas tecnologías en el aprendizaje. Se analizan aspectos como la mejora del rendimiento académico, la personalización del aprendizaje, el aumento del engagement y la necesidad de infraestructura tecnológica y formación docente. Esta etapa es importante porque permite comprender tanto las ventajas como las limitaciones de la implementación de la IA en la educación.

Finalmente, el proceso culmina con la **formulación del aporte del estudio**, que consiste en proponer la integración de la inteligencia artificial y el aprendizaje adaptativo como una estrategia para mejorar la calidad educativa en la educación superior. A partir de este análisis, los autores establecen una base conceptual que puede orientar futuras investigaciones y aplicaciones en el ámbito educativo.

En conjunto, el proceso seguido por los autores combina revisión teórica, análisis conceptual e integración de enfoques, lo que les permite construir un aporte sólido orientado a la transformación de los procesos de enseñanza-aprendizaje mediante el uso de tecnologías inteligentes.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema de la **rigidez de los modelos educativos tradicionales en la educación superior** y la falta de personalización en el aprendizaje se basa en la integración progresiva de la **inteligencia artificial (IA)** y el **aprendizaje adaptativo** como ejes de transformación pedagógica. El problema central identificado es que los sistemas educativos convencionales no logran atender la diversidad de ritmos, estilos y necesidades de los estudiantes, lo que afecta la calidad, la pertinencia y el rendimiento académico. Frente a esta situación, los autores proponen un proceso orientado a construir entornos educativos más flexibles, personalizados y eficientes.

El primer paso del proceso consiste en la **identificación de las limitaciones del modelo educativo tradicional**. Los autores reconocen que la enseñanza uniforme y estandarizada no responde a las demandas actuales de la sociedad del conocimiento, donde se requiere formar estudiantes con capacidades críticas, adaptativas y digitales. Esta etapa permite definir con claridad el problema y justificar la necesidad de incorporar tecnologías innovadoras en el proceso educativo.

El segundo paso es la **incorporación de la inteligencia artificial como herramienta de análisis y toma de decisiones**. En este punto, la IA se utiliza para recopilar y procesar grandes volúmenes de datos sobre el desempeño, comportamiento y progreso de los estudiantes. Esta capacidad permite identificar patrones de aprendizaje, detectar dificultades y generar información relevante para mejorar el proceso educativo. De esta manera, la IA se convierte en el componente analítico que sustenta la personalización del aprendizaje.

El tercer paso consiste en la **aplicación del aprendizaje adaptativo como estrategia pedagógica**. A partir de los datos analizados por la IA, el sistema ajusta los contenidos, actividades y evaluaciones según las necesidades individuales de cada estudiante. Esto implica modificar el nivel de dificultad, priorizar ciertos contenidos y ofrecer rutas de aprendizaje personalizadas. Este paso es fundamental porque permite transformar la información generada por la IA en acciones pedagógicas concretas que mejoran la experiencia de aprendizaje.

El cuarto paso es la **implementación de herramientas tecnológicas en entornos educativos reales**. Los autores mencionan el uso de plataformas virtuales, sistemas de tutoría inteligente, simuladores y recursos interactivos que permiten aplicar la IA y el aprendizaje adaptativo en la práctica. Esta implementación facilita la interacción del estudiante con el sistema y permite que el proceso de aprendizaje se desarrolle de manera dinámica y personalizada.

El quinto paso es la **evaluación continua del aprendizaje**, donde el sistema monitorea el progreso del estudiante y proporciona retroalimentación inmediata. Esta evaluación constante permite ajustar nuevamente el proceso de enseñanza, generando un ciclo de mejora continua. De esta manera, el aprendizaje se convierte en un proceso dinámico, donde las decisiones pedagógicas se basan en datos actualizados.

El sexto paso consiste en la **identificación de beneficios y ajustes necesarios**, donde se analizan los resultados obtenidos y se evalúan aspectos como el rendimiento académico, la motivación y el engagement de los estudiantes. Además, se consideran factores como la infraestructura tecnológica, la formación docente y los aspectos éticos relacionados con el uso de la IA. Esta etapa permite optimizar el proceso y asegurar su sostenibilidad en el tiempo.

Finalmente, el proceso culmina con la **consolidación de un modelo educativo innovador**, donde la IA y el aprendizaje adaptativo se integran como componentes fundamentales para mejorar la calidad educativa. Este modelo permite ofrecer una educación más flexible, personalizada y alineada con las necesidades de los estudiantes y del entorno.

En conjunto, el proceso propuesto transforma un problema de enseñanza estandarizada en una solución basada en personalización, análisis de datos y adaptación continua, posicionando a la inteligencia artificial y al aprendizaje adaptativo como herramientas clave para la transformación de la educación superior.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, las métricas utilizadas por los autores no corresponden a indicadores experimentales únicos como precisión, exactitud o error estadístico, sino que se derivan de una **revisión sistemática de la literatura** enfocada en evaluar el impacto de la **inteligencia artificial (IA)** y el **aprendizaje adaptativo** en la educación superior. A partir de los estudios revisados, los autores valoran principalmente variables como la **optimización de los procesos de enseñanza-aprendizaje**, la **personalización de la formación académica**, la **retroalimentación inmediata**, la **detección temprana de dificultades**, el **rendimiento académico**, la **motivación**, la **autonomía del estudiante** y el **fortalecimiento de competencias cognitivas, digitales y profesionales**. Estas dimensiones aparecen sintetizadas en la **Tabla 1 de resultados (páginas 18 a 20)**, donde se resume el efecto de la IA y del aprendizaje adaptativo en distintas categorías del proceso educativo.

En cuanto a los resultados, los autores concluyen que la integración de la IA y el aprendizaje adaptativo permitió **transformar los procesos de enseñanza-aprendizaje**, generando experiencias más **flexibles, personalizadas y centradas en el estudiante**. Según la síntesis presentada, las plataformas virtuales, simuladores, laboratorios en línea y recursos educativos inteligentes mejoraron la **autonomía**, la **retroalimentación inmediata** y la **adaptabilidad del aprendizaje**. Asimismo, se señala que herramientas como las **tutorías inteligentes**, la **analítica de aprendizaje**, los **chatbots educativos** y los **sistemas de recomendación** favorecieron la interacción estudiante-entorno, optimizaron el rendimiento académico y promovieron un aprendizaje más individualizado y motivador. El artículo también afirma que el aprendizaje adaptativo permitió ajustar contenidos y actividades según las necesidades individuales, fomentando la **autorregulación** y la **reflexión crítica** del estudiante.

Además, los autores destacan que la **sinergia entre IA y aprendizaje adaptativo** produjo efectos positivos en la **detección temprana de dificultades**, en la **adaptación de contenidos y actividades** y en el desarrollo de un modelo educativo más dinámico y eficaz. En la discusión y en las conclusiones se afirma que estas tecnologías contribuyeron de manera significativa a mejorar la **calidad y pertinencia de la formación universitaria**, así como a fortalecer competencias clave para la sociedad del conocimiento. También se menciona que el aprendizaje

adaptativo tuvo un impacto positivo en el **rendimiento académico** y en la **motivación** de los estudiantes universitarios, al ofrecer experiencias basadas en retroalimentación continua y rutas personalizadas.

Al comentar estos hallazgos, puede decirse que los resultados son **mejores respecto a enfoques tradicionales de enseñanza estandarizada**, porque muestran ventajas claras en personalización, flexibilidad, motivación y seguimiento del progreso estudiantil. Sin embargo, frente a otros estudios más empíricos, el artículo no ofrece métricas cuantitativas comparativas tan precisas, ya que su aporte se basa en una **síntesis de evidencias previas** más que en un experimento propio. Aun así, su conclusión es consistente: la IA y el aprendizaje adaptativo ofrecen mejores resultados que los modelos convencionales cuando se busca una educación superior más personalizada, centrada en el estudiante y orientada al desarrollo de competencias relevantes.

Observaciones y/o críticas suyas al artículo

El artículo presenta un aporte valioso porque aborda un tema muy actual en la educación superior: la relación entre **inteligencia artificial** y **aprendizaje adaptativo** como estrategias para mejorar la formación universitaria. Una de sus principales fortalezas es que ofrece una **visión amplia y bien organizada** del tema, articulando conceptos pedagógicos, tecnológicos y formativos. Además, resulta útil que no solo destaque los beneficios de estas herramientas, sino que también mencione limitaciones como la infraestructura tecnológica, la capacitación docente, la privacidad de los datos y las desigualdades en el acceso. Esto le da al trabajo una perspectiva más equilibrada y cercana a la realidad institucional.

Otra fortaleza importante es el uso de la **revisión sistemática** como método principal. Esto permite reunir información académica diversa y construir una síntesis ordenada sobre aplicaciones de la IA, principios del aprendizaje adaptativo, recursos digitales inteligentes y efectos en el rendimiento, la motivación y la autonomía del estudiante. La inclusión del esquema PRISMA también aporta claridad metodológica al proceso de selección de estudios. En ese sentido, el artículo funciona bien como un trabajo de integración teórica y de actualización del estado del conocimiento sobre el tema.

Sin embargo, una primera observación crítica es que el estudio mantiene un enfoque **mayormente descriptivo y general**, y profundiza menos en la comparación detallada entre investigaciones o en la solidez empírica de cada resultado reportado. Por ejemplo, aunque se afirma que la IA y el aprendizaje adaptativo mejoran el rendimiento académico, la motivación y la personalización, el artículo no desarrolla con suficiente detalle cuáles estudios ofrecen la evidencia más fuerte, qué diseños metodológicos utilizaron o qué resultados cuantitativos concretos respaldan esas afirmaciones. Esto hace que la argumentación sea clara, pero a veces más sintética que analítica.

Otra crítica importante es que el artículo presenta una visión bastante favorable de la IA y del aprendizaje adaptativo, pero podría profundizar más en los **riesgos pedagógicos y éticos**. Aunque menciona privacidad, brecha tecnológica y necesidad de formación docente, no desarrolla con suficiente detalle cómo estos problemas afectan realmente la implementación en contextos universitarios diversos. Tampoco se profundiza mucho en las diferencias entre instituciones con altos recursos y aquellas con limitaciones tecnológicas, lo cual sería clave para valorar la viabilidad real de estas propuestas.

Además, se observa que varias de las referencias utilizadas son recientes y pertinentes, pero el artículo podría fortalecerse con una discusión más crítica entre posturas distintas, ya que la mayoría de la exposición apunta a resaltar beneficios y menos a debatir posibles contradicciones o resultados menos favorables encontrados en la literatura.

En síntesis, se trata de un artículo útil, actual y bien estructurado, que aporta una buena visión general sobre la IA y el aprendizaje adaptativo en educación superior. No obstante, podría enriquecerse con un análisis más profundo de la evidencia empírica, una discusión más crítica de los riesgos y una comparación más detallada entre contextos de aplicación.

13. ARTICULO 13

Author (s): du Plooy, E.; Casteleijn, D.; Franzsen, D.

Title of paper: Aprendizaje adaptativo personalizado en la educación superior: una revisión exploratoria de las características clave y su impacto en el rendimiento académico y la participación.

Journal: Heliyon

Volume (issue): 10

pag – pag (year): e39630 (2024)

Estado del arte que hace el autor

El estado del arte presentado por los autores se desarrolla en torno al concepto de **personalized adaptive learning** en educación superior, entendido como una estrategia que combina principios de personalización con tecnologías adaptativas para ajustar las trayectorias de aprendizaje a las necesidades individuales de cada estudiante. Desde la introducción, el artículo sitúa esta temática dentro de un contexto de transformación acelerada de la educación superior, impulsada por la digitalización, la pandemia de COVID-19 y la Cuarta Revolución Industrial. En este escenario, los sistemas de gestión del aprendizaje, el big data y la analítica educativa han modificado profundamente las prácticas docentes, ofreciendo mayor flexibilidad y acceso a recursos, pero también dejando al descubierto problemas persistentes de retención, progreso académico y compromiso estudiantil.

Uno de los ejes principales del estado del arte es precisamente la relación entre **student success**, **academic progress** y **student engagement**. Los autores explican que, a pesar del avance tecnológico, las instituciones de educación superior siguen enfrentando dificultades para mejorar el rendimiento y la permanencia de sus estudiantes. Por ello, el aprendizaje adaptativo personalizado aparece en la literatura como una alternativa con potencial para responder a estos desafíos, ya que permite individualizar el aprendizaje y ofrecer apoyos más ajustados a las características de cada alumno. Esta preocupación por la retención y el desempeño académico constituye la base del problema que el artículo busca abordar.

El estado del arte también revisa la **evolución histórica y conceptual** del aprendizaje adaptativo personalizado. Los autores señalan que su desarrollo no es reciente, sino que ha sido moldeado por una serie de innovaciones a lo largo del último siglo, desde la educación progresiva de Dewey hasta los sistemas adaptativos contemporáneos apoyados en inteligencia artificial y machine learning. Esta revisión histórica es importante porque muestra que el aprendizaje adaptativo no surge de manera aislada, sino como resultado de una trayectoria donde han convergido ideas pedagógicas sobre individualización, autonomía y diseño de experiencias significativas de aprendizaje.

En el plano teórico, los autores destacan que el personalized adaptive learning se apoya en una **amplia base de teorías educativas y psicológicas**, que van desde el **behaviorism** hasta enfoques más recientes como **connectivism** y **learning analytics**. Según el artículo, esta evolución teórica refleja un cambio progresivo desde visiones del aprendizaje entendidas como respuestas observables, hacia comprensiones más complejas donde intervienen factores cognitivos, sociales, tecnológicos y contextuales. De esta manera, el estado del arte presenta al aprendizaje adaptativo personalizado como un fenómeno multifacético, no solo técnico, sino también profundamente pedagógico.

Otro componente central del estado del arte es la **definición misma de personalized adaptive learning**, citada en el artículo como una pedagogía apoyada por tecnología que ajusta oportunamente las estrategias de enseñanza a partir del monitoreo en tiempo real de las diferencias, cambios en características individuales, desempeño y desarrollo del estudiante. Esta definición es importante porque muestra que el foco no está únicamente en adaptar contenidos, sino en adaptar estrategias, decisiones pedagógicas y trayectorias a partir de datos

del estudiante. Desde esa perspectiva, el artículo sitúa la adaptatividad como una evolución del ideal de personalización dentro de la educación superior.

El estado del arte también revisa las **fuentes de datos e indicadores** que la literatura ha utilizado para activar rutas adaptativas. Entre ellas se mencionan cuestionarios previos, niveles de confianza del estudiante, registros de actividad en los learning management systems y otros indicadores derivados del comportamiento de aprendizaje. Asimismo, se recuerda que algunos estudios han utilizado estilos de aprendizaje para adaptar la forma de entrega del contenido. Esta revisión muestra que la investigación en el campo ha explorado múltiples vías para construir modelos de personalización, aunque todavía de manera dispersa.

Además, el artículo destaca que la literatura ha descrito la aplicación del aprendizaje adaptativo personalizado en **campos disciplinares muy diversos**, como ingeniería, humanidades, tecnologías de la información, ciencias de la salud y veterinaria. Esto indica que el interés por esta estrategia no está restringido a un solo ámbito del conocimiento, sino que existe una expansión transversal dentro de la educación superior. Al mismo tiempo, esta amplitud revela la necesidad de estudios de síntesis que permitan ordenar un campo que se ha vuelto muy heterogéneo.

Un aspecto muy importante del estado del arte es la revisión de la **diversidad terminológica y taxonómica** en torno al tema. Los autores señalan que existe una gran variedad de definiciones y términos asociados a personalized and adaptive learning, lo que ha llevado al desarrollo de taxonomías para clasificar la literatura según contenido, learner model y learning environment. También se menciona el Personalized Adaptive Learning Framework como una guía para la implementación del aprendizaje adaptativo según las diferencias individuales de los estudiantes. Esta parte del estado del arte deja ver que el campo ha crecido, pero también que sigue necesitando mayor claridad conceptual y organizativa.

Otro eje relevante es la relación entre personalized adaptive learning y **equidad en el aprendizaje**. Los autores citan estudios que muestran que la personalización puede contribuir a fomentar mayor equidad y mejorar el éxito estudiantil, algo especialmente relevante para universidades del **global South**, donde ingresan estudiantes diversos a programas no siempre diseñados para responder a sus necesidades individuales. El artículo menciona barreras sistémicas, históricas, de género, raza y desigualdad socioeconómica que condicionan el acceso a tecnología, infraestructura y recursos. En este sentido, el estado del arte no presenta el aprendizaje adaptativo solo como innovación tecnológica, sino también como una posible herramienta para responder a desigualdades estructurales en la educación superior.

Finalmente, los autores identifican con claridad la **brecha en la literatura existente**. Aunque reconocen que revisiones previas han determinado tendencias y dominios de investigación — como learning analytics, AI education, intelligent tutoring systems y knowledge tracing—, señalan que esos trabajos no sintetizaron de manera suficiente las **fortalezas y debilidades de los sistemas adaptativos**, ni tampoco cuáles son las plataformas más utilizadas, los tipos de indicadores más frecuentes o las prácticas de recolección de datos más comunes. Además, sostienen que la investigación previa permanece dispersa y focalizada en uno o varios aspectos aislados de la implementación tecnológica. Desde esa carencia, el artículo justifica su propósito de ofrecer una síntesis comprensiva sobre las características clave del personalized adaptive learning y su impacto en el rendimiento académico y el engagement en educación superior.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una realidad persistente en la educación superior: a pesar de los avances en digitalización, en analítica de datos y en sistemas de gestión del aprendizaje, las instituciones universitarias siguen enfrentando problemas importantes de

retención estudiantil, progreso académico y engagement. Desde el inicio del artículo, los autores dejan claro que el aprendizaje adaptativo personalizado aparece como una posible respuesta a estos desafíos, porque permite ajustar rutas de aprendizaje según las necesidades individuales del estudiante. En otras palabras, la motivación del estudio nace de la necesidad de encontrar enfoques más eficaces para responder a dificultades que los modelos educativos tradicionales y uniformes no han logrado resolver completamente.

Otra motivación importante proviene de la propia evolución del campo. Los autores reconocen que el *personalized adaptive learning* ha sido impulsado por avances en **inteligencia artificial, machine learning, learning analytics y tecnologías educativas**, pero al mismo tiempo señalan que la literatura sigue siendo **dispersa y fragmentada**. Esta observación funciona como una crítica a investigaciones previas que, aunque han aportado conocimiento valioso, suelen concentrarse en uno o varios componentes aislados del fenómeno, como la tecnología, los algoritmos, los modelos adaptativos o algunos resultados puntuales, sin ofrecer una visión suficientemente integrada del campo.

Además, los autores critican explícitamente que revisiones anteriores ya habían identificado dominios importantes en *adaptive learning* —por ejemplo, *deep learning* en análisis de datos educativos, modelos adaptativos en educación basada en IA, *intelligent tutoring systems* y *feature modeling*—, pero **no investigaron con suficiente detalle las fortalezas y limitaciones de los sistemas adaptativos**, ni sintetizaron las plataformas más utilizadas o las prácticas de recolección de datos más frecuentes. Es decir, existía ya un panorama parcial de tendencias, pero no una síntesis completa que permitiera entender cómo se implementa realmente el aprendizaje adaptativo personalizado en educación superior y qué impacto concreto tiene en el rendimiento académico y el engagement.

Otra crítica implícita del artículo apunta a la falta de estudios que integren de manera suficiente la dimensión de **equidad y diversidad estudiantil**. Los autores señalan que la personalización es especialmente relevante en contextos como el **global South**, donde ingresan a la universidad estudiantes con trayectorias, barreras y necesidades muy diversas, pero muchos programas siguen sin estar diseñados para responder a esas diferencias. En ese sentido, el artículo cuestiona indirectamente enfoques que todavía conciben al estudiante universitario desde una lógica homogénea, cuando en realidad existen desigualdades sistémicas, históricas, económicas y tecnológicas que deberían ser consideradas en el diseño educativo.

En síntesis, la motivación del estudio se basa en dos necesidades centrales: por un lado, responder a problemas persistentes de desempeño, permanencia y compromiso estudiantil en educación superior; y por otro, superar la fragmentación de la literatura previa mediante una síntesis amplia que permita comprender mejor las características, fortalezas, limitaciones e impacto del *personalized adaptive learning* en el ámbito universitario.

Descripción del aporte del autor

El artículo realiza un aporte significativo al campo de la educación superior al desarrollar una **síntesis integral sobre el personalized adaptive learning (PAL)** y su impacto en el rendimiento académico y el compromiso estudiantil. A diferencia de estudios previos que analizan componentes aislados del aprendizaje adaptativo, este trabajo propone una **visión global, estructurada y crítica del fenómeno**, integrando dimensiones tecnológicas, pedagógicas y contextuales. De esta manera, el artículo no solo describe el estado del conocimiento, sino que organiza y clarifica un campo que se caracteriza por su diversidad conceptual y metodológica.

Uno de los principales aportes del estudio es la **sistematización del concepto de personalized adaptive learning**, el cual es definido como una pedagogía apoyada en tecnología que ajusta dinámicamente las estrategias de enseñanza a partir del análisis en tiempo real de las

características y el desempeño del estudiante. Esta definición es relevante porque permite distinguir el PAL de otros enfoques similares, resaltando su carácter dinámico, basado en datos y orientado a la personalización continua del aprendizaje. Con ello, el artículo contribuye a reducir la ambigüedad conceptual existente en la literatura.

Otro aporte fundamental es la **integración de múltiples enfoques teóricos y tecnológicos** que sustentan el PAL. El artículo muestra cómo este campo se nutre de diversas corrientes, como el behaviorismo, el constructivismo, el conectivismo, el learning analytics y la inteligencia artificial. Esta integración permite comprender que el aprendizaje adaptativo no es únicamente una herramienta tecnológica, sino un enfoque pedagógico complejo que combina teorías del aprendizaje con sistemas inteligentes capaces de analizar datos y tomar decisiones educativas.

El estudio también aporta una **clasificación de los elementos clave del aprendizaje adaptativo**, identificando componentes como los modelos del estudiante (learner models), los entornos de aprendizaje (learning environments), los mecanismos de adaptación y las fuentes de datos utilizadas para personalizar la enseñanza. Esta organización resulta especialmente útil porque permite entender cómo funcionan los sistemas adaptativos y cuáles son los elementos necesarios para su implementación. Además, contribuye a ordenar un campo que hasta ahora se presentaba de forma fragmentada.

Otro aporte importante es la **identificación de indicadores y fuentes de datos utilizados en los sistemas adaptativos**. El artículo muestra que la personalización del aprendizaje se basa en información proveniente de cuestionarios, niveles de confianza del estudiante, registros de actividad en plataformas virtuales y otros datos generados durante el proceso de aprendizaje. Este análisis permite comprender cómo se construyen las rutas adaptativas y qué tipo de información es relevante para mejorar la experiencia educativa.

Asimismo, el artículo aporta una **visión clara del impacto del PAL en la educación superior**, destacando su influencia en variables como el rendimiento académico, el engagement y la retención estudiantil. Según la síntesis realizada, el aprendizaje adaptativo permite mejorar la personalización, ofrecer retroalimentación oportuna y ajustar las estrategias de enseñanza de manera dinámica, lo que contribuye a una experiencia de aprendizaje más efectiva. Este aporte es relevante porque conecta el desarrollo tecnológico con resultados concretos en el proceso educativo.

Otro aspecto clave del aporte es la **identificación de fortalezas y debilidades de los sistemas adaptativos**. A diferencia de trabajos anteriores que se enfocaban principalmente en beneficios, este artículo también analiza limitaciones, como la dependencia de infraestructura tecnológica, la complejidad de implementación, la necesidad de formación docente y los desafíos asociados a la equidad en el acceso. Este enfoque crítico permite ofrecer una visión más equilibrada y realista del uso del PAL en la educación superior.

El artículo también contribuye al destacar la relación entre el PAL y la **equidad educativa**, señalando que la personalización del aprendizaje puede ayudar a reducir desigualdades en contextos diversos, especialmente en el global South. Este enfoque es relevante porque amplía la discusión más allá de lo tecnológico, incorporando dimensiones sociales y educativas que son fundamentales para el desarrollo de sistemas educativos más inclusivos.

Además, el estudio aporta una **síntesis de plataformas, herramientas y prácticas utilizadas en la implementación del aprendizaje adaptativo**, lo que permite entender cómo se aplica este enfoque en contextos reales. Esta información resulta útil tanto para investigadores como para instituciones educativas interesadas en adoptar estas tecnologías.

Finalmente, uno de los aportes más importantes del artículo es la **identificación de vacíos en la literatura y la propuesta de líneas futuras de investigación**. Los autores señalan la

necesidad de estudios más integradores, que analicen de manera conjunta los diferentes componentes del aprendizaje adaptativo y su impacto en el rendimiento y el engagement. También destacan la importancia de investigar con mayor profundidad aspectos como la equidad, la diversidad estudiantil y la sostenibilidad de estas tecnologías.

En conjunto, el aporte del artículo puede resumirse en tres dimensiones principales. Primero, organiza y clarifica el concepto de *personalized adaptive learning*. Segundo, integra enfoques teóricos, tecnológicos y pedagógicos para explicar su funcionamiento. Y tercero, identifica su impacto, fortalezas, limitaciones y desafíos futuros. Por ello, el trabajo representa una contribución sólida para comprender y mejorar la implementación del aprendizaje adaptativo en la educación superior.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en una **revisión sistemática y analítica de la literatura** sobre el **personalized adaptive learning (PAL)** en educación superior. En primer lugar, los autores parten de la identificación de un problema central: a pesar del crecimiento del aprendizaje adaptativo y de su potencial para mejorar el rendimiento académico y el engagement, la literatura existente se encuentra **fragmentada, dispersa y poco integrada**, lo que dificulta comprender sus características, aplicaciones e impacto real. A partir de esta problemática, los autores plantean como objetivo desarrollar una síntesis que permita organizar el conocimiento existente y clarificar el campo.

El segundo paso del proceso consiste en la **definición del enfoque metodológico**, basado en una revisión sistemática de la literatura. Este enfoque permite analizar múltiples estudios de manera estructurada, identificando patrones, tendencias y elementos comunes. Para ello, los autores establecen criterios de selección que garantizan la inclusión de investigaciones relevantes relacionadas con el aprendizaje adaptativo personalizado en educación superior.

El tercer paso es la **recopilación de información científica**, donde los autores revisan estudios previos que abordan el aprendizaje adaptativo desde diferentes perspectivas, incluyendo aspectos tecnológicos, pedagógicos y contextuales. En esta etapa, se consideran investigaciones relacionadas con inteligencia artificial, learning analytics, sistemas de tutoría inteligente y plataformas de aprendizaje, lo que permite construir una base amplia de conocimiento sobre el tema.

El cuarto paso consiste en la **organización y clasificación de la información recopilada**. Los autores estructuran los estudios analizados en función de diferentes dimensiones, como modelos de aprendizaje, entornos educativos, fuentes de datos, indicadores utilizados y resultados obtenidos. Esta organización permite transformar información dispersa en un marco estructurado que facilita su análisis y comprensión.

El quinto paso es el **análisis e integración de los hallazgos**, donde los autores identifican patrones comunes, tendencias emergentes y relaciones entre los diferentes elementos del aprendizaje adaptativo. En esta etapa, se integran los enfoques teóricos, tecnológicos y pedagógicos, lo que permite construir una visión global del fenómeno. Este proceso de integración es clave, ya que constituye el núcleo del aporte del artículo.

El sexto paso consiste en la **identificación de fortalezas, limitaciones y vacíos de la literatura**, donde los autores analizan tanto los beneficios del aprendizaje adaptativo (como la personalización y la mejora del rendimiento) como sus desafíos (como la infraestructura tecnológica, la equidad y la implementación). Esta etapa permite evaluar de manera crítica el estado del conocimiento y orientar futuras investigaciones.

Finalmente, el proceso culmina con la **formulación del aporte del estudio**, que consiste en ofrecer una síntesis estructurada del **personalized adaptive learning**, identificando sus características clave, su impacto en la educación superior y las áreas que requieren mayor desarrollo. Gracias a este proceso, los autores logran transformar una literatura fragmentada en un marco conceptual claro y organizado.

En conjunto, el proceso seguido combina revisión sistemática, organización de información e integración conceptual, permitiendo construir un aporte sólido que clarifica el campo del aprendizaje adaptativo personalizado y facilita su comprensión y aplicación en la educación superior.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema de los **bajos niveles de retención, progreso académico y engagement en educación superior** se basa en la implementación del **personalized adaptive learning (PAL)** como una estrategia pedagógica apoyada por tecnología. El problema central identificado es que los modelos tradicionales de enseñanza no siempre logran responder a la diversidad de necesidades, ritmos y características de los estudiantes, especialmente en contextos online o híbridos. Frente a esta situación, los autores proponen un proceso que combina personalización, análisis de datos y adaptación continua de la enseñanza para mejorar la experiencia y los resultados académicos de los estudiantes.

El primer paso del proceso consiste en la **identificación de las dificultades persistentes en la educación superior**, como la baja retención, el escaso progreso académico y la limitada participación estudiantil. Los autores explican que, aunque la digitalización ha generado nuevos recursos y entornos de aprendizaje, estos avances no resuelven por sí solos los problemas de éxito estudiantil. Por ello, el PAL se plantea como una respuesta específica para abordar esas limitaciones mediante trayectorias de aprendizaje más individualizadas.

El segundo paso es la **recopilación de datos sobre los estudiantes**, que constituye la base del aprendizaje adaptativo. Según el artículo, los sistemas PAL pueden activarse a partir de distintos indicadores, como **pre-knowledge quizzes, student confidence levels, learning analytics, activity logs y learning styles**. Estos datos permiten identificar diferencias individuales, niveles de conocimiento previo y patrones de comportamiento, lo que hace posible adaptar el contenido y las estrategias de enseñanza. En la revisión, los autores muestran que el **pre-knowledge quiz** es el indicador más utilizado para activar la adaptación del contenido.

El tercer paso consiste en la **activación de rutas adaptativas de aprendizaje**. A partir de la información recogida, los sistemas PAL ajustan el tipo de contenido, el orden de presentación, el nivel de dificultad o la modalidad de entrega de acuerdo con las características del estudiante. Este ajuste puede basarse en un solo tipo de dato o en múltiples fuentes combinadas, como logs de actividad, cuestionarios y preferencias. El objetivo es que cada estudiante reciba una experiencia de aprendizaje más adecuada a sus necesidades y posibilidades reales.

El cuarto paso es la **entrega personalizada de contenidos y actividades**. Los autores muestran que el PAL se implementa sobre todo para distribuir **academic teaching content, self-assessment quizzes, homework assignments, tutorials y remedial teaching**. Esto significa que la solución no se limita a identificar dificultades, sino que modifica de manera concreta la experiencia formativa del estudiante, ofreciendo contenidos más pertinentes y apoyos específicos cuando son necesarios. En la revisión, también se observa que plataformas como **McGraw-Hill's Connect LearnSmart** y **Moodle** son de las más utilizadas para este fin.

El quinto paso es el **acompañamiento y monitoreo continuo del aprendizaje**. Una vez implementadas las rutas adaptativas, el sistema sigue observando el desempeño del estudiante,

permitiendo ajustar nuevamente la enseñanza si cambian sus resultados, su participación o sus necesidades. Este carácter dinámico es clave, porque el PAL no es una adaptación única y fija, sino un proceso de ajuste continuo. Además, el artículo subraya que, aunque el sistema esté automatizado, el papel del docente sigue siendo central en el diseño del aprendizaje, la creación de contenidos, el seguimiento y el soporte técnico y pedagógico.

El sexto paso consiste en la **evaluación del impacto del PAL** sobre el rendimiento académico, el engagement y el aprendizaje. Los autores sintetizan que, de los 69 estudios incluidos, **41 reportaron mejoría en el rendimiento académico** y **25 señalaron incremento en el engagement estudiantil**. También se observan beneficios como la mejora en pensamiento crítico, autorregulación y adquisición de competencias. Esto indica que el proceso de solución no solo cambia la forma de enseñar, sino que puede traducirse en resultados positivos para el aprendizaje.

Finalmente, el proceso se completa con la **identificación de fortalezas y limitaciones** para seguir refinando la implementación. Entre las fortalezas destacan la personalización, la mejora de los resultados de aprendizaje, la motivación y la accesibilidad. Entre las limitaciones aparecen los problemas tecnológicos, las restricciones de tiempo y recursos, la necesidad de alta autorregulación del estudiante y ciertas limitaciones algorítmicas. Esto muestra que el problema no se resuelve únicamente con incorporar tecnología, sino con un proceso de mejora continua que tenga en cuenta el contexto, la infraestructura y el acompañamiento pedagógico.

En conjunto, el proceso propuesto por los autores transforma una enseñanza uniforme y poco sensible a la diversidad en un modelo de aprendizaje más flexible, personalizado y basado en datos. Así, el *personalized adaptive learning* se presenta como una estrategia capaz de responder de forma más eficaz a los desafíos de retención, rendimiento y participación en la educación superior.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, las métricas utilizadas por los autores se derivan de la **revisión sistemática de estudios sobre personalized adaptive learning (PAL)** en educación superior. A diferencia de investigaciones experimentales individuales, el análisis se basa en la síntesis de múltiples trabajos, por lo que las métricas principales corresponden a variables educativas recurrentes en la literatura. Entre ellas destacan el **rendimiento académico (academic performance)**, el **engagement o compromiso estudiantil**, la **retención**, el **progreso académico**, así como indicadores cualitativos como el **pensamiento crítico**, la **autorregulación del aprendizaje** y el desarrollo de competencias. Estas métricas permiten evaluar el impacto del PAL desde una perspectiva integral, no solo en términos de resultados académicos, sino también en la calidad del proceso de aprendizaje.

A partir de estas métricas, los autores obtienen resultados concretos que evidencian el impacto positivo del aprendizaje adaptativo. En el análisis de los **69 estudios revisados**, se reporta que **41 investigaciones muestran mejoras en el rendimiento académico**, mientras que **25 estudios evidencian un incremento en el engagement de los estudiantes**. Estos datos indican que una proporción significativa de la literatura respalda la efectividad del PAL en mejorar tanto los resultados académicos como la participación activa del estudiante. Además, se identifican beneficios adicionales como la mejora en la **autorregulación**, el **pensamiento crítico** y la **personalización del aprendizaje**, lo que sugiere un impacto más amplio que va más allá de las calificaciones.

Otra métrica relevante utilizada en el artículo es el análisis de los **indicadores que activan la adaptación del aprendizaje**, como los **pre-knowledge quizzes**, **activity logs**, **student confidence levels** y **learning analytics**. Entre estos, el pre-knowledge quiz destaca como el

más utilizado, lo que evidencia que la evaluación inicial del conocimiento del estudiante es clave para personalizar la enseñanza. Asimismo, se analizan métricas relacionadas con el uso de plataformas y herramientas tecnológicas, identificando sistemas como **Moodle** y **McGraw-Hill's Connect LearnSmart** como los más empleados en la implementación del PAL.

Al comentar estos resultados, se puede afirmar que el PAL presenta **mejores resultados en comparación con modelos tradicionales de enseñanza**, especialmente en términos de personalización, motivación y mejora del rendimiento académico. A diferencia de enfoques convencionales, donde todos los estudiantes reciben el mismo contenido y ritmo de enseñanza, el aprendizaje adaptativo permite ajustar la experiencia educativa según las necesidades individuales, lo que se traduce en mayores niveles de engagement y mejores resultados académicos en una parte significativa de los estudios analizados.

Sin embargo, frente a estudios experimentales específicos, el artículo no presenta métricas cuantitativas homogéneas (como porcentajes exactos de mejora en todos los casos), ya que su enfoque es de síntesis. Aun así, la consistencia de los resultados en múltiples investigaciones permite concluir que el PAL es una estrategia más eficaz que los enfoques tradicionales cuando se busca mejorar el aprendizaje en contextos de educación superior.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte sólido y útil porque organiza de manera clara el campo del **personalized adaptive learning (PAL)** en educación superior y no se limita solo a describir tecnologías, sino que también analiza su relación con el **rendimiento académico**, el **engagement** y las condiciones de implementación. Una de sus principales fortalezas es que ofrece una revisión amplia de **69 estudios**, lo que le permite mostrar con mayor claridad cuáles son las plataformas más utilizadas, qué indicadores activan la adaptación del contenido y qué resultados se reportan con más frecuencia. Además, resulta valioso que el artículo no adopte una postura ingenuamente optimista, sino que también reconozca limitaciones como problemas tecnológicos, restricciones de tiempo y recursos, exigencias de autorregulación del estudiante y debilidades de algunos algoritmos.

Otra fortaleza importante es que el estudio ayuda a reducir la dispersión conceptual del campo. Los autores muestran que en la literatura se usan muchos términos diferentes para referirse a sistemas adaptativos, lo que puede generar confusión. En ese sentido, su esfuerzo por sintetizar las **características clave del PAL**, las formas de implementación y sus impactos constituye un aporte útil tanto para investigadores como para instituciones de educación superior interesadas en aplicar estas estrategias. También es destacable que incorporen una mirada sensible a la **diversidad estudiantil** y a la necesidad de mayor equidad, especialmente en contextos del **global South**, donde la personalización puede responder mejor a trayectorias educativas muy heterogéneas.

Sin embargo, una primera crítica es que, aunque el artículo presenta una síntesis muy rica, su enfoque sigue siendo **principalmente descriptivo**. Es decir, organiza muy bien la literatura, pero profundiza menos en una comparación crítica entre la calidad metodológica de los estudios incluidos. Por ejemplo, se informa que **41 estudios reportaron mejora en el rendimiento académico y 25 aumento del engagement**, pero no se analiza con suficiente detalle cuáles de esos estudios tenían diseños más robustos, qué tan comparables eran entre sí o qué peso deberían tener sus hallazgos frente a otros con resultados menos favorables. Esto hace que la revisión sea muy informativa, aunque no siempre igualmente fuerte en términos de jerarquización de evidencias.

Otra observación crítica es que el artículo muestra el potencial del PAL en muchos campos disciplinares, pero podría profundizar más en las **diferencias contextuales** entre áreas de conocimiento, tipos de estudiantes o entornos institucionales. No necesariamente un sistema

adaptativo funciona igual en humanidades, salud o informática, ni en universidades con distinta infraestructura tecnológica. Aunque estas diferencias se sugieren, el artículo no siempre las desarrolla con suficiente profundidad. Asimismo, se mencionan limitaciones algorítmicas y tecnológicas, pero habría sido útil una discusión más amplia sobre riesgos éticos, privacidad de datos y dependencia excesiva de sistemas automatizados.

En síntesis, se trata de un artículo bien estructurado, amplio y muy útil como panorama del aprendizaje adaptativo personalizado en educación superior. No obstante, podría fortalecerse aún más con un análisis más crítico de la calidad de la evidencia, de las diferencias contextuales y de las implicancias éticas de estas tecnologías.

14. ARTICULO 14

Author (s): Tan, L. Y.; Hu, S.; Yeo, D. J.; Cheong, K. H.

Title of paper: Artificial intelligence-enabled adaptive learning platforms: A review

Journal: Computers and Education: Artificial Intelligence

Volume (issue): 9

pag – pag (year): 100429 (2025)

Estado del arte que hace el autor

El estado del arte presentado por los autores se desarrolla en torno a las **adaptive learning platforms (ALPs)** potenciadas por inteligencia artificial, entendidas como plataformas de e-learning capaces de ajustar dinámicamente el contenido y las trayectorias instruccionales según las necesidades individuales de cada estudiante. Desde la introducción, el artículo sitúa este campo en el marco de una educación superior transformada por la digitalización, por eventos recientes como la pandemia de COVID-19 y por la Cuarta Revolución Industrial. En este contexto, los sistemas de gestión del aprendizaje, el big data y la analítica educativa han impulsado nuevas estrategias de enseñanza más flexibles, aunque las instituciones continúan enfrentando problemas persistentes de retención, progreso académico y participación estudiantil. Por ello, el estudio posiciona a las ALPs como una respuesta prometedora a limitaciones que los enfoques tradicionales no han logrado resolver completamente.

Uno de los ejes centrales del estado del arte es la contraposición entre las ALPs y el enfoque **“one-size-fits-all”** de la enseñanza tradicional. Los autores explican que en los entornos convencionales, tanto presenciales como virtuales, todos los estudiantes suelen recibir los mismos recursos, el mismo orden de contenidos y similares niveles de dificultad, lo que puede ralentizar a quienes avanzan rápido y sobrecargar a quienes presentan más dificultades. Frente a ello, la literatura revisada muestra que las ALPs permiten personalizar la experiencia de aprendizaje de múltiples maneras: ajustando el formato del contenido, recomendando recursos específicos, ofreciendo retroalimentación individualizada y modificando la secuencia o dificultad de las tareas según el progreso del estudiante. Esta revisión teórica muestra que el aprendizaje adaptativo se ha consolidado como un intento serio de llevar la personalización a gran escala dentro de la educación formal.

El estado del arte también incorpora una base histórica y conceptual importante. Los autores relacionan las ALPs con el problema clásico formulado por **Benjamin Bloom**, conocido como el **2-sigma problem**, según el cual los estudiantes con tutoría individual alcanzan rendimientos muy superiores a los enseñados en grupo. En este marco, las ALPs aparecen en la literatura como una forma de aproximarse a los beneficios de la tutoría personalizada, pero a escala institucional, mediante el uso de algoritmos y sistemas inteligentes. De esta manera, el artículo vincula la tecnología adaptativa contemporánea con una preocupación pedagógica de larga data: cómo ofrecer instrucción individualizada sin depender exclusivamente del uno a uno humano.

Otro aporte importante del estado del arte es la descripción de la **anatomía de las ALPs**, organizada en tres componentes principales: **learner model**, **domain model** y **adaptation model**. Los autores explican que el learner model construye un perfil del estudiante a partir de datos demográficos, cognitivos, conductuales, afectivos y contextuales; el domain model organiza los conocimientos y recursos del área disciplinar; y el adaptation model decide cómo adaptar el contenido y las estrategias de enseñanza a partir de la información del estudiante. En la *Figura 1 del artículo (página 3)* se muestra claramente esta estructura, donde el sistema adapta contenido y retroalimentación con base en la interacción continua entre estudiante, docente, modelo del estudiante y modelo de adaptación. Esta revisión permite entender que el campo no se reduce a una sola tecnología, sino a una arquitectura compleja de personalización educativa.

El estado del arte revisa asimismo las **fuentes de datos** que alimentan las ALPs. La literatura citada muestra que estas plataformas pueden construir perfiles del estudiante a partir de cuestionarios, respuestas a evaluaciones, registros de actividad, interacción con recursos, preferencias de aprendizaje, motivación, personalidad, autoeficacia, conectividad e incluso estados afectivos detectados mediante sensores, expresiones faciales, movimientos oculares, ritmo cardíaco o reconocimiento de voz. Esta amplitud indica que la investigación sobre ALPs ha avanzado desde simples pruebas diagnósticas hacia modelos cada vez más ricos y contextuales del estudiante, lo que amplía notablemente la capacidad de adaptación.

Otro eje clave del estado del arte es la revisión de las **formas de adaptación** que utilizan estas plataformas. Los autores distinguen entre **adaptive content**, **adaptive assessment** y **adaptive sequencing**. La adaptación puede consistir en ofrecer materiales alternativos, impedir que el estudiante avance sin dominar un contenido, personalizar preguntas según desempeño previo, o reorganizar el orden de los recursos para obligar al estudiante a reforzar áreas débiles antes de pasar a temas más avanzados. Esta clasificación ayuda a entender que la adaptación no ocurre en un solo punto del proceso educativo, sino en diferentes momentos y niveles de la experiencia formativa.

En el plano pedagógico, el estado del arte no se limita a describir algoritmos, sino que también analiza las **bases teóricas** que sustentan el diseño de las ALPs. Los autores responden a críticas previas que señalaban una débil fundamentación pedagógica en muchos estudios sobre IA en educación, y por ello revisan principios como **mastery learning**, **aptitude-treatment interactions**, **dynamic scaffolding** y la **Revised Bloom's Taxonomy**. Esta revisión muestra que las ALPs no deben entenderse solo como sistemas inteligentes que entregan recursos, sino como dispositivos pedagógicos que buscan ajustar el apoyo, la dificultad, la secuencia y la profundidad cognitiva de las tareas según el progreso del estudiante.

El estado del arte también dedica espacio a las **técnicas algorítmicas** que alimentan tanto el learner model como el adaptation model. En el análisis de la literatura se mencionan enfoques como **Fuzzy C-Means**, **Random Forest**, **Deep Knowledge Tracing**, **Item Response Theory**, **Bayesian Networks**, **Matrix Factorization**, **reinforcement learning**, **collaborative filtering**, **LSTM**, **genetic algorithms**, **ant colony optimization** e incluso **Large Language Models**. En la *Figura 5 del artículo (página 7)* se observa una evolución temporal de estas técnicas: entre 2014 y 2019 predominaban métodos basados en reglas, mientras que entre 2020 y 2024 aumentan el deep learning y aparece el uso de generative AI. Este punto es clave porque muestra que el campo está evolucionando rápidamente hacia formas de adaptación más contextuales y sofisticadas.

Además, la revisión muestra que las ALPs ya se han aplicado en **múltiples niveles educativos y áreas disciplinares**. Aunque predominan en campos STEM como computación y matemáticas, también aparecen en música, psicología, salud, idiomas y otras áreas. En las *Figuras 6 y 7 del artículo (páginas 7 y 8)* se visualiza esta distribución, observándose que más de la mitad de los estudios empíricos se ubican en educación terciaria, aunque también existen implementaciones en primaria y secundaria. Esto confirma que el interés por las ALPs no es marginal, sino cada vez más transversal dentro de la educación.

Finalmente, el estado del arte reconoce que, junto a sus beneficios, las ALPs enfrentan **desafíos importantes**. La literatura revisada advierte preocupaciones sobre privacidad y seguridad de datos, falta de apoyo institucional, resistencia al cambio, costos de implementación, necesidad de formación docente y dificultades de adaptación por parte de los propios estudiantes. Los autores también señalan que futuras tendencias apuntan a la integración de **AR**, **VR**, **gamificación**, **chatbots** y **LLMs**, lo que ampliará aún más las posibilidades de personalización. En síntesis, el estado del arte muestra que las ALPs representan una evolución relevante de la educación digital: tienen una base pedagógica cada vez más sólida, usan algoritmos más complejos y ofrecen promesas claras de mejorar desempeño, motivación y engagement, aunque

todavía dependen de condiciones tecnológicas, éticas e institucionales para desplegar todo su potencial.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una tensión muy clara dentro de la educación actual: aunque las tecnologías digitales han avanzado rápidamente y han abierto nuevas posibilidades para personalizar el aprendizaje, los sistemas educativos todavía arrastran limitaciones estructurales del enfoque tradicional **“one-size-fits-all”**. En la introducción del artículo, los autores señalan que la enseñanza uniforme sigue siendo común tanto en aulas presenciales como en entornos virtuales, sobre todo por restricciones de tiempo, tamaño de clase y recursos. Esta lógica, aunque práctica, no responde adecuadamente a las diferencias individuales entre estudiantes, ya que puede frenar a quienes avanzan más rápido y, al mismo tiempo, sobrecargar a quienes presentan más dificultades. Desde esta crítica surge el interés por las **adaptive learning platforms (ALPs)** como una alternativa más flexible y personalizada.

Otra motivación importante del artículo proviene de la necesidad de **organizar y clarificar un campo de investigación que ha crecido mucho, pero de forma dispersa**. Los autores reconocen que las ALPs se han desarrollado ampliamente en los últimos años, impulsadas por inteligencia artificial, big data y learning analytics, pero también observan que el conocimiento disponible se encuentra distribuido entre múltiples enfoques, terminologías y disciplinas. Por ello, consideran necesario realizar una revisión que sintetice sus fundamentos pedagógicos, sus implementaciones basadas en IA, sus métricas de evaluación y sus aplicaciones reales en distintos contextos educativos. En este sentido, el artículo nace no solo del interés por la tecnología en sí, sino también de la necesidad de dar orden a una literatura amplia y fragmentada.

Además, los autores recogen una crítica que ya había sido formulada por otros investigadores: muchos estudios sobre ALPs y, en general, sobre IA en educación, presentan una **fundamentación pedagógica limitada**. El artículo menciona explícitamente que algunos académicos cuestionan que los desarrollos tecnológicos avancen más rápido que la validación de las teorías educativas que deberían sostenerlos. Por eso, una parte importante de la motivación del trabajo consiste en revisar y destacar los **marcos pedagógicos** que están detrás de las ALPs, como mastery learning, dynamic scaffolding, aptitude-treatment interactions y la Revised Bloom’s Taxonomy. Esta decisión implica una crítica a trabajos anteriores excesivamente centrados en la dimensión técnica, dejando en segundo plano la lógica pedagógica que debería justificar la adaptación.

Otra crítica relevante del artículo se dirige a los **retos no resueltos de implementación real**. Los autores señalan que, aunque las ALPs ofrecen grandes promesas, en la práctica enfrentan obstáculos importantes como preocupaciones de privacidad, falta de apoyo institucional, resistencia al cambio, carencia de formación docente y altos costos de infraestructura. Esta observación implica que la investigación previa no puede limitarse a mostrar beneficios potenciales; también debe prestar atención a las condiciones concretas que facilitan o dificultan la adopción de estas tecnologías en contextos reales.

En síntesis, la motivación del estudio se apoya en tres necesidades centrales: superar las limitaciones de la enseñanza uniforme, responder a la fragmentación del conocimiento sobre ALPs y fortalecer el vínculo entre innovación tecnológica y fundamento pedagógico. Desde ahí, los autores justifican su revisión como un esfuerzo por comprender mejor cómo las ALPs pueden aplicarse de forma más sólida, efectiva y sostenible en la educación.

Descripción del aporte del autor

ognitivas, conductuales, afectivas, demográficas, entre otras); el domain model organiza los contenidos del área de conocimiento; y el adaptation model toma decisiones sobre cómo presentar el contenido y qué estrategias aplicar. Esta estructura, ilustrada en la *Figura 1 del artículo*, permite comprender de manera clara cómo funcionan los sistemas adaptativos y cómo se logra la personalización del aprendizaje.

El estudio también aporta una **clasificación de los tipos de adaptación** que realizan estas plataformas. Los autores identifican tres grandes formas: **adaptive content, adaptive assessment y adaptive sequencing**. Esto significa que la personalización no se limita a qué contenido se muestra, sino que también incluye cómo se evalúa al estudiante y en qué orden se presentan los temas. Este aporte es importante porque amplía la comprensión del aprendizaje adaptativo, mostrando que se trata de un proceso complejo que actúa en diferentes niveles del sistema educativo.

Otro aporte relevante es la **identificación y análisis de las fuentes de datos utilizadas en las ALPs**. El artículo muestra que la personalización se basa en información diversa, como cuestionarios, resultados de evaluaciones, registros de actividad, preferencias de aprendizaje, motivación, personalidad e incluso indicadores fisiológicos como expresiones faciales o ritmo cardíaco. Esta visión amplia permite entender cómo los sistemas adaptativos han evolucionado desde modelos simples hacia enfoques más complejos y contextualizados, capaces de representar mejor al estudiante.

Asimismo, el artículo aporta una **revisión exhaustiva de las técnicas de inteligencia artificial utilizadas en las ALPs**. Entre ellas se incluyen métodos clásicos como Random Forest y Bayesian Networks, así como técnicas más avanzadas como Deep Learning, reinforcement learning, collaborative filtering, LSTM, genetic algorithms y Large Language Models. Además, el estudio muestra la evolución temporal de estas técnicas, evidenciando un cambio hacia enfoques más sofisticados en los últimos años. Este aporte es clave porque permite comprender la base tecnológica que sustenta la personalización del aprendizaje.

Otro aspecto importante del aporte es la **integración de fundamentos pedagógicos en el análisis de las ALPs**. Los autores destacan teorías como mastery learning, aptitude-treatment interactions, dynamic scaffolding y la Revised Bloom's Taxonomy, mostrando que la adaptación no debe basarse únicamente en datos, sino también en principios educativos sólidos. Este enfoque responde a críticas previas sobre la falta de sustento pedagógico en muchos desarrollos tecnológicos, y fortalece la validez del aprendizaje adaptativo como estrategia educativa.

El artículo también aporta una **visión amplia de las aplicaciones de las ALPs en diferentes contextos educativos**. Se evidencia que estas plataformas se utilizan principalmente en educación superior y en áreas STEM, aunque también se aplican en disciplinas como idiomas, salud, psicología y música. Esta diversidad demuestra que el aprendizaje adaptativo no es exclusivo de un campo específico, sino que tiene un potencial transversal en distintos ámbitos del conocimiento.

Otro aporte significativo es la **identificación de beneficios y desafíos de las ALPs**. Entre los beneficios destacan la personalización del aprendizaje, la mejora del rendimiento académico, el aumento del engagement y la posibilidad de ofrecer retroalimentación inmediata. Sin embargo, el artículo también reconoce limitaciones como problemas de privacidad, falta de infraestructura, resistencia al cambio, costos de implementación y necesidad de formación docente. Este enfoque equilibrado permite comprender tanto el potencial como las dificultades de estas tecnologías.

Finalmente, el artículo contribuye al señalar **tendencias futuras del campo**, como la integración de tecnologías emergentes (realidad aumentada, realidad virtual, gamificación, chatbots y modelos generativos de lenguaje), que podrían potenciar aún más la personalización del aprendizaje. Además, identifica la necesidad de investigaciones que profundicen en la evaluación de estas plataformas, su impacto a largo plazo y su implementación en contextos diversos.

En conjunto, el aporte del artículo puede resumirse en tres grandes dimensiones: primero, organiza y clarifica el concepto de adaptive learning platforms; segundo, integra aspectos tecnológicos y pedagógicos para explicar su funcionamiento; y tercero, analiza sus aplicaciones, beneficios, limitaciones y proyecciones futuras. Por ello, el estudio representa una contribución sólida para comprender y desarrollar el aprendizaje adaptativo basado en inteligencia artificial en la educación contemporánea.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en una **revisión sistemática y estructurada de la literatura** sobre **adaptive learning platforms (ALPs)** potenciadas por inteligencia artificial. En primer lugar, los autores parten de la identificación de un problema central: a pesar del crecimiento acelerado de las ALPs y su potencial para personalizar el aprendizaje, el conocimiento existente se encuentra **disperso entre múltiples enfoques técnicos, pedagógicos y aplicaciones aisladas**, lo que dificulta comprender su funcionamiento integral y su impacto real en la educación. A partir de esta problemática, los autores plantean como objetivo desarrollar una síntesis que permita organizar y clarificar el campo.

El segundo paso del proceso consiste en la **definición del enfoque metodológico**, basado en una revisión sistemática de la literatura. Este enfoque permite analizar múltiples investigaciones de manera organizada, identificando patrones, tendencias y relaciones entre diferentes componentes del aprendizaje adaptativo. Para ello, los autores establecen criterios de selección que aseguran la inclusión de estudios relevantes relacionados con plataformas adaptativas, inteligencia artificial y educación.

El tercer paso es la **recopilación de estudios científicos**, donde los autores reúnen investigaciones que abordan distintos aspectos de las ALPs, como su arquitectura, sus modelos de adaptación, sus fundamentos pedagógicos y sus aplicaciones en diversos contextos educativos. Esta recopilación incluye estudios sobre técnicas de inteligencia artificial, modelos de estudiante, sistemas de recomendación y plataformas de aprendizaje, lo que permite construir una base amplia de información.

El cuarto paso consiste en la **organización y clasificación de la información recopilada**. Los autores estructuran los estudios en función de diferentes dimensiones, como los componentes de las ALPs (learner model, domain model y adaptation model), los tipos de adaptación (contenido, evaluación y secuencia), las fuentes de datos utilizadas y las técnicas de inteligencia artificial empleadas. Esta clasificación permite transformar información dispersa en un marco estructurado que facilita su análisis.

El quinto paso es el **análisis e integración de los hallazgos**, donde los autores identifican patrones comunes, tendencias emergentes y relaciones entre los diferentes elementos del aprendizaje adaptativo. En esta etapa, se integran aspectos tecnológicos y pedagógicos, lo que permite comprender cómo funcionan las ALPs y cómo se logra la personalización del aprendizaje. Este proceso de integración constituye el núcleo del aporte del artículo.

El sexto paso consiste en la **incorporación de fundamentos pedagógicos**, donde los autores analizan teorías educativas que sustentan el aprendizaje adaptativo, como mastery learning, dynamic scaffolding y la taxonomía de Bloom. Este paso es importante porque permite

fortalecer la base teórica del estudio y responder a críticas previas sobre la falta de sustento pedagógico en algunos trabajos tecnológicos.

El séptimo paso es la **identificación de beneficios, limitaciones y desafíos**, donde los autores evalúan el impacto de las ALPs en variables como el rendimiento académico, el engagement y la personalización del aprendizaje, así como los problemas asociados a su implementación, como la privacidad de los datos, la infraestructura tecnológica y la formación docente.

Finalmente, el proceso culmina con la **formulación del aporte del estudio**, que consiste en ofrecer una visión integral de las ALPs, integrando sus componentes técnicos, sus fundamentos pedagógicos, sus aplicaciones y sus desafíos. Gracias a este proceso, los autores logran transformar una literatura fragmentada en un marco conceptual claro y organizado.

En conjunto, el proceso combina revisión sistemática, organización de información e integración teórica, permitiendo construir un aporte sólido que clarifica el campo de las plataformas de aprendizaje adaptativo y facilita su comprensión y aplicación en la educación.

Proceso para resolver el problema considerado por el autor

El proceso planteado por los autores para resolver el problema de la **falta de personalización en la enseñanza y las limitaciones del enfoque “one-size-fits-all”** se basa en la implementación de **adaptive learning platforms (ALPs)** apoyadas por inteligencia artificial. El problema central que identifican es que los métodos tradicionales, tanto en aula como en e-learning, suelen ofrecer los mismos recursos, actividades y secuencias a todos los estudiantes, aun cuando cada uno presenta ritmos, necesidades, conocimientos previos y estilos de aprendizaje distintos. Esta uniformidad puede frenar a los estudiantes más avanzados y, al mismo tiempo, dificultar el aprendizaje de quienes necesitan más apoyo. Frente a ello, los autores proponen un proceso de solución centrado en la **adaptación dinámica del aprendizaje** a partir del análisis continuo de datos del estudiante.

El primer paso del proceso consiste en la **construcción del learner model**, es decir, del perfil del estudiante. Para ello, las ALPs recopilan información variada sobre cada usuario, como datos demográficos, conocimiento previo, respuestas a evaluaciones, tiempo de interacción, preferencias de aprendizaje, motivación, autoeficacia, comportamiento en la plataforma e incluso estados afectivos o emocionales. Según el artículo, estos datos pueden obtenerse mediante cuestionarios, rastreo de interacciones, sensores, reconocimiento de voz y algoritmos de machine learning. El objetivo de este paso es conocer al estudiante de manera suficientemente detallada como para que el sistema pueda decidir qué tipo de apoyo necesita.

El segundo paso es la **organización del contenido a través del domain model**. Los autores explican que el sistema debe estructurar el conocimiento del área en objetos de aprendizaje bien definidos, como lecciones, ejercicios, cuestionarios o tareas, y establecer relaciones entre ellos. Este modelo del dominio permite construir una jerarquía de recursos alineada con resultados de aprendizaje específicos. En otras palabras, antes de adaptar algo, el sistema necesita tener bien ordenado qué puede ofrecer, en qué secuencia y con qué nivel de complejidad.

El tercer paso es la activación del **adaptation model**, que constituye el núcleo del proceso de solución. Aquí el sistema utiliza los datos del learner model para decidir cómo adaptar la experiencia educativa. El artículo muestra que la adaptación puede hacerse según variables como conocimiento previo, estilo cognitivo, formato preferido del recurso o nivel de motivación. Así, las ALPs seleccionan contenidos, ajustan la dificultad, reorganizan la secuencia de aprendizaje y ofrecen apoyo personalizado con el fin de que cada estudiante siga una trayectoria más adecuada a sus necesidades reales. En la *Figura 1 del artículo (página 3)* se observa precisamente esta interacción entre learner model, domain model y adaptation

model, mostrando cómo la plataforma determina las adaptaciones y entrega retroalimentación personalizada al estudiante.

El cuarto paso consiste en la **implementación concreta de tres formas de adaptación**. La primera es el **adaptive content**, donde el sistema cambia el tipo de material o impide que el estudiante avance hasta dominar ciertos contenidos; la segunda es el **adaptive assessment**, donde la dificultad de las preguntas se modifica según las respuestas previas; y la tercera es el **adaptive sequencing**, donde se altera el orden del contenido para que el estudiante refuerce primero sus áreas débiles antes de continuar. Este paso es importante porque transforma el diagnóstico inicial del estudiante en acciones pedagógicas concretas.

El quinto paso es el uso de **algoritmos de inteligencia artificial y sistemas de recomendación** para hacer viable la adaptación en tiempo real. Los autores revisan distintas técnicas, desde sistemas basados en reglas hasta métodos más complejos como fuzzy logic, reinforcement learning, collaborative filtering, LSTM, clustering, genetic algorithms y Large Language Models. Estos algoritmos permiten recomendar recursos “en el momento adecuado, en el contexto adecuado y de la forma adecuada”, reduciendo la sobrecarga de información y mejorando la pertinencia del contenido para cada estudiante. En la *Tabla 2 del artículo (páginas 5 y 6)* se muestran precisamente varios enfoques de implementación de estos sistemas de recomendación.

El sexto paso del proceso es el **seguimiento mediante learning analytics**. Una vez que la ALP ha comenzado a adaptar la instrucción, el sistema continúa recogiendo datos sobre desempeño, progreso, engagement y patrones de interacción. Esta información se visualiza en dashboards para docentes y, en algunos casos, también para estudiantes. El artículo subraya que esto permite al profesor monitorear en tiempo real el progreso, detectar estudiantes en riesgo y ajustar sus estrategias de enseñanza. Así, la solución no depende solo del algoritmo, sino también del uso pedagógico de los datos por parte del docente.

El séptimo paso es la **intervención pedagógica complementaria**. Los autores insisten en que, aunque la plataforma automatice muchas decisiones, el rol del docente sigue siendo esencial. El profesor diseña contenidos, interpreta reportes, brinda apoyo focalizado y usa los hallazgos del sistema para intervenir donde sea necesario. Esto resulta especialmente importante en contextos blended o híbridos, donde la ALP funciona como complemento que libera tiempo del docente para atención más dirigida.

Finalmente, el problema se resuelve a través de la **evaluación de resultados**. El artículo muestra que las ALPs han sido implementadas en distintos niveles y disciplinas, y que en muchos casos han mejorado rendimiento académico, motivación, engagement y satisfacción. Sin embargo, los autores también reconocen desafíos, como privacidad de datos, falta de apoyo institucional, necesidad de formación docente y resistencia al cambio. Por eso, el proceso no termina en la adopción de la tecnología, sino que incluye ajustes continuos, soporte institucional y diseño pedagógico sólido. En conjunto, el proceso propuesto transforma una enseñanza uniforme en una experiencia de aprendizaje más personalizada, escalable y basada en datos, posicionando a las ALPs como una estrategia concreta para enfrentar problemas persistentes de rendimiento y participación en la educación.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, los autores utilizan diversas **métricas de evaluación** para valorar la efectividad de las **adaptive learning platforms (ALPs)**. En la *Tabla 1 del artículo (página 5)* se identifican cuatro métricas principales: **learning gains**, **learner satisfaction**, **student engagement** y **learner motivation**. Para medir los **learning gains**, se emplea con frecuencia la comparación entre **pre-test y post-test**, lo que permite observar cuánto mejora el estudiante

después de interactuar con la plataforma. La **satisfacción del estudiante** se evalúa mediante cuestionarios sobre facilidad de uso, pertinencia del contenido y experiencia general. El **engagement** se mide a partir de escalas adaptadas, como la **Dixson scale**, que considera participación, habilidades, emoción y desempeño. Finalmente, la **motivación** se analiza mediante cuestionarios como el **Motivated Strategies for Learning Questionnaire**, además de interacciones registradas en la plataforma e incluso sensores que detectan expresiones faciales, postura o ritmo cardíaco.

En cuanto a los resultados, el artículo sostiene de forma general que las ALPs muestran **impactos positivos sobre el rendimiento, la motivación y el engagement** de los estudiantes. Por ejemplo, se reporta que estas plataformas permiten mejorar resultados de aprendizaje al adaptar el contenido, la secuencia y la dificultad según las características del usuario. En los casos revisados, se mencionan resultados concretos: en el sistema **YiXue's Squirrel AI Learning**, entre **64.4 % y 75.5 %** de los estudiantes que usaron la plataforma obtuvieron puntajes superiores al promedio de los grupos con enseñanza tradicional; en **TECH8**, los estudiantes superaron al grupo control en **más de 10 %** en la evaluación sumativa; en el sistema adaptativo de Chen para física, los estudiantes obtuvieron **mejores calificaciones y mayor motivación** que el grupo control; y en el curso de **TPACK** mediado por ALP, el grupo adaptativo alcanzó un promedio de **230.67** frente a **191.97** del grupo convencional. Además, en el caso de un curso tipo MOOC adaptativo, el **engagement estudiantil fue 72 % mayor** que en cursos no adaptativos.

También se reportan efectos positivos en otras áreas: menos errores en entrenamiento musical con **BACH**, mejores notas para el **65 %** de estudiantes de ciberseguridad con **ThoTh Lab**, y altos niveles de satisfacción con plataformas como **Realizeit**, donde **78 %** de los estudiantes afirmaron que tomarían nuevamente un curso basado en esa herramienta. Todo esto indica que las ALPs no solo mejoran calificaciones, sino también la experiencia educativa, la permanencia y la motivación.

Al comentar estos hallazgos, puede afirmarse que los resultados son **mejores respecto a métodos tradicionales y sistemas no adaptativos**, especialmente porque logran combinar **mejor rendimiento académico, mayor engagement y más satisfacción**. Frente al enfoque “one-size-fits-all”, las ALPs muestran ventajas claras al personalizar la experiencia de aprendizaje y ofrecer apoyo más preciso. Sin embargo, el artículo también reconoce que no todos los estudios encuentran mejoras significativas, ya que algunos resultados dependen de factores como la duración de la implementación, la calidad de las variables usadas para adaptar el sistema y el contexto educativo. Aun así, el balance general del artículo es favorable: las ALPs suelen ofrecer mejores resultados que los enfoques uniformes cuando están bien diseñadas y pedagógicamente fundamentadas.

Observaciones y/o críticas suyas al artículo

El artículo presenta un aporte muy valioso porque ofrece una **revisión amplia, actualizada y bien estructurada** sobre las **adaptive learning platforms (ALPs)** potenciadas por inteligencia artificial. Una de sus principales fortalezas es que no se limita a describir plataformas o algoritmos, sino que integra tres dimensiones que muchas veces aparecen separadas en la literatura: la **tecnológica**, la **pedagógica** y la **práctica**. Esto se nota en la forma en que el artículo explica la anatomía de las ALPs, revisa sus fundamentos pedagógicos —como **mastery learning**, **dynamic scaffolding** y **Bloom's Taxonomy**— y luego analiza casos reales de implementación en diferentes niveles educativos y áreas disciplinares. Esa articulación le da solidez y hace que el trabajo sea útil tanto para investigadores como para docentes o diseñadores instruccionales.

Otra fortaleza importante es que el estudio no presenta una visión puramente optimista o tecnocéntrica. Los autores reconocen con claridad que, aunque las ALPs muestran beneficios

en **rendimiento, motivación, engagement y satisfacción**, también enfrentan limitaciones concretas como problemas de **privacidad**, falta de **apoyo institucional**, necesidad de **capacitación docente**, resistencia al cambio, costos de implementación y dificultades para que estudiantes y profesores comprendan adecuadamente el uso de estas plataformas. Esta mirada crítica fortalece el artículo, porque muestra que la efectividad de una ALP no depende solo del algoritmo, sino también del contexto educativo y de las condiciones institucionales.

Sin embargo, una primera observación crítica es que, aunque el artículo revisa muchos estudios y ofrece una buena panorámica, mantiene un enfoque **más descriptivo que comparativo**. Es decir, presenta múltiples casos exitosos y algunos menos favorables, pero no siempre profundiza suficientemente en la **calidad metodológica** de cada estudio ni en qué condiciones explican que una ALP funcione mejor que otra. Por ejemplo, se mencionan varios resultados positivos en distintas plataformas, pero no se desarrolla con el mismo detalle una comparación sistemática entre tipos de adaptación, duración de las intervenciones o robustez de los diseños experimentales. Esto hace que el panorama sea claro, pero a veces más general que analíticamente jerarquizado.

Otra crítica relevante es que, si bien el artículo reconoce la importancia de la **equidad** y del acceso inclusivo, podría profundizar más en cómo las ALPs pueden reproducir desigualdades cuando dependen de infraestructura avanzada, sensores, datos extensivos y apoyo técnico especializado. También sería útil una discusión más amplia sobre el riesgo de depender demasiado de datos conductuales sin captar dimensiones más profundas del aprendizaje humano, como contexto social, cultura o condiciones emocionales complejas. En algunos pasajes el artículo sugiere estas preocupaciones, pero no las desarrolla del todo.

En síntesis, se trata de un artículo sólido, actual y muy útil como revisión general de las ALPs, con un buen equilibrio entre teoría, tecnología y aplicación. No obstante, podría fortalecerse aún más con comparaciones metodológicas más profundas y una discusión más amplia sobre las implicancias éticas y sociales de la personalización basada en IA.

15. ARTICULO 15

Author (s): Popescu, D. A.; Bold, N.; Stefanidakis, M.

Title of paper: Un modelo sistemático de un entorno adaptativo de enseñanza, aprendizaje y evaluación diseñado mediante algoritmos genéticos.

Journal: Applied Sciences

Volume (issue): 15

pag – pag (year): 4039 (2025)

Estado del arte que hace el autor

El estado del arte presentado por los autores se construye alrededor del desarrollo de **entornos adaptativos de enseñanza, aprendizaje y evaluación** apoyados por tecnologías digitales avanzadas, con especial énfasis en el uso de **algoritmos genéticos**. Desde la introducción, el artículo sitúa el problema en el contexto de la necesidad creciente de ofrecer **experiencias de aprendizaje personalizadas**, capaces de responder a las diferencias individuales de los estudiantes en cuanto a ritmos, necesidades y estilos de aprendizaje. Los autores señalan que, en la educación contemporánea, persisten limitaciones importantes como la falta de personalización del contenido, la evaluación inadecuada del progreso del estudiante y la sobrecarga organizativa del docente, lo que afecta la motivación, el engagement y la calidad del proceso formativo. A partir de esa base, el estado del arte presenta la adaptación educativa como una línea de investigación necesaria para mejorar tanto la enseñanza como la evaluación.

Uno de los primeros ejes del estado del arte es la relación entre la evolución del **entorno digital y la educación**. Los autores explican que el desarrollo de arquitecturas web más complejas y paradigmas asociados a la llamada **Web 4.0** ha generado cambios profundos en la interacción humano-computadora y en los patrones de uso de la tecnología. En el ámbito educativo, esta transformación se refleja en varias tendencias clave: la **personalización de la educación**, el análisis de datos educativos mediante **machine learning** e **inteligencia artificial**, la colaboración y compartición de recursos, y una accesibilidad mucho más extendida a materiales y oportunidades de aprendizaje. Desde esta perspectiva, el estado del arte sitúa la tecnología digital como la infraestructura sobre la cual se ha hecho posible pensar en sistemas adaptativos más sofisticados.

El artículo también revisa cómo la literatura ha abordado la mejora de los **entornos de aprendizaje en línea**. Los autores señalan que los sistemas tradicionales y los sistemas más recientes comparten principios generales de enseñanza y evaluación, pero advierten que todavía existe margen para mejorar la calidad de los métodos y marcos usados para fortalecer la educación digital. La literatura, según exponen, muestra una gran diversidad de sistemas de aprendizaje, cada uno con características particulares, lo que indica que el campo ha crecido bastante, aunque todavía de manera heterogénea y con distintos grados de integración entre sus componentes.

Un componente importante del estado del arte es el **análisis cuantitativo de la literatura**, realizado por los autores sobre un conjunto de **2500 artículos**. A través del uso de la base de datos **Dimensions.ai** y del software de visualización **VOSViewer**, el artículo busca identificar términos frecuentes y su relevancia dentro del campo. En la *Figura 1 del artículo (página 3)* se presenta tanto un mapa de densidad de términos como una organización en clusters, y en la *Tabla 1 (página 3)* aparecen algunos de los términos con mayor relevancia, entre ellos **teaching, learner, teacher, systematic review y university**. Este análisis no solo sirve como apoyo metodológico, sino que también refuerza la idea de que el debate actual sobre tecnología digital en educación se centra fuertemente en los actores del proceso formativo y en la reorganización de la enseñanza y el aprendizaje.

Otro eje fundamental del estado del arte es la revisión de cómo la tecnología digital ha impactado las tres grandes fases del proceso educativo: **teaching, learning y assessment**. En

cuanto a la **enseñanza**, los autores destacan el uso de **Learning Management Systems (LMS)**, aplicaciones educativas, herramientas de gestión de contenidos, desarrollo de experiencias educativas y recursos videobasados como webinars o videoconferencias. En la fase de **aprendizaje**, la revisión menciona especialmente el **pervasive learning**, los **adaptive learning systems**, el aprendizaje colaborativo y la gamificación. Finalmente, en la fase de **evaluación**, el artículo resalta el uso de principios como **Universal Design for Assessment (UDA)** y de métodos computacionales como machine learning, algoritmos evolutivos, learning analytics e instrumentos estadísticos. Esta triple revisión es importante porque muestra que la adaptación educativa no debe pensarse de forma aislada, sino como parte de un ecosistema que integra enseñanza, aprendizaje y evaluación.

En el campo específico de la **evaluación educativa**, el estado del arte es especialmente amplio. Los autores sostienen que uno de los grandes objetivos de la automatización educativa es alcanzar resultados lo más cercanos posible a una **evaluación human-centered**, es decir, comparable a la que produciría un docente experimentado. En este contexto, revisan distintas líneas de investigación, como **Question Generation (QG)**, **Answer Evaluation (AE)**, **Automatic Essay Scoring (AES)** y **Item Analysis (IA)**. Según el artículo, buena parte de la investigación reciente se ha concentrado en la generación automática de preguntas objetivas, preguntas abiertas y en la evaluación automática de respuestas cortas o ensayos, apoyándose sobre todo en técnicas de **Natural Language Processing (NLP)**. Este recorrido muestra que la evaluación adaptativa es un campo en expansión, pero también uno donde todavía persisten retos importantes relacionados con la calidad, validez y cercanía al juicio humano.

Además, el estado del arte revisa dos marcos clásicos para el análisis de ítems y resultados: **Classical Test Theory (CTT)** e **Item Response Theory (IRT)**. Los autores explican que la CTT se basa más en herramientas estadísticas tradicionales y suele aplicarse en contextos de evaluación de menor escala, mientras que la IRT incorpora una naturaleza más adaptativa al considerar atributos latentes y el peso de la experiencia previa del estudiante. Esta distinción es clave porque ayuda a entender que el paso hacia sistemas adaptativos no ocurre solo a nivel tecnológico, sino también en la forma de concebir la evaluación del desempeño y la precisión de las mediciones.

El artículo también dedica atención a desarrollos más recientes como **Deep Knowledge Tracking**, un campo que ha ganado relevancia por su capacidad para analizar y predecir el comportamiento educativo del estudiante a partir de sus experiencias previas de aprendizaje y evaluación. La presencia de esta línea en la revisión muestra que el campo está evolucionando hacia modelos cada vez más finos de seguimiento, donde no solo importa lo que el estudiante responde, sino cómo progresa, qué patrones muestra y qué trayectorias podrían anticiparse a futuro.

Uno de los puntos más importantes del estado del arte es la **identificación explícita de brechas de investigación**. Los autores señalan cuatro vacíos principales: la falta de **personalización adaptativa en tiempo real**, el tratamiento separado de enseñanza, aprendizaje y evaluación sin integrarlos en un sistema único, el uso aún limitado de **algoritmos evolutivos** como métodos heurísticos frente al predominio de IA y ML más convencionales, y la escasa validación de modelos en entornos educativos reales. En la *sección de review summary y gap analysis* (páginas 6 y 7) se observa que estas brechas funcionan como el punto de partida directo de la propuesta del artículo.

Finalmente, el estado del arte se cierra con la justificación del enfoque adoptado por los autores: el uso de **algoritmos genéticos** para resolver tareas complejas como la generación de rutas de aprendizaje y unidades de evaluación. Los autores sostienen que estos problemas implican **optimización combinatoria**, **balance multicriterio** y **adaptación continua**, lo que hace especialmente adecuada la elección de métodos genéticos. A esto se suman ventajas como la exploración flexible de grandes espacios de solución, la capacidad de optimización

multiobjetivo y la robustez frente a óptimos locales. En síntesis, el estado del arte muestra un campo amplio y en rápida evolución, donde convergen tecnologías digitales, análisis de datos, NLP, teorías de evaluación e innovación pedagógica, pero donde todavía faltaba un modelo integrado que uniera enseñanza, aprendizaje y evaluación adaptativa mediante algoritmos evolutivos. Precisamente ese es el espacio que el artículo busca ocupar.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una problemática clara en la educación contemporánea: aunque existe un creciente interés por ofrecer **experiencias de aprendizaje personalizadas**, los sistemas educativos todavía presentan limitaciones importantes en la forma en que enseñan, acompañan y evalúan a los estudiantes. Desde la introducción del artículo, los autores señalan tres problemas principales: la **falta de personalización del contenido educativo**, la **evaluación insuficientemente ajustada al progreso real del estudiante** y la **sobrecarga de trabajo docente en tareas organizativas**. Estos problemas, según el artículo, pueden provocar disminución de la motivación y del compromiso con el aprendizaje, además de generar resultados de evaluación sesgados o poco representativos del conocimiento real del estudiante. Por ello, el estudio nace de la necesidad de diseñar un entorno adaptativo que mejore simultáneamente enseñanza, aprendizaje y evaluación.

Otra motivación importante del artículo se relaciona con una crítica a los enfoques existentes en la literatura. Los autores reconocen que tanto los sistemas tradicionales como los sistemas digitales recientes comparten principios similares de enseñanza y evaluación, pero afirman que **todavía hay margen para mejorar la calidad de las metodologías y marcos utilizados en la educación online**. Esta observación implica una crítica a muchos trabajos previos que han desarrollado soluciones parciales o poco integradas, sin lograr un modelo suficientemente robusto que articule de manera coherente las diferentes fases del proceso educativo.

Además, el artículo critica implícitamente que gran parte de la investigación previa trata **teaching, learning y assessment como componentes separados**, en lugar de integrarlos en un sistema único. En la sección donde identifican las brechas de investigación, los autores señalan explícitamente que muchas soluciones abordan estos elementos por separado, sin conectarlos en un entorno adaptativo común. Esta crítica es clave, porque explica por qué proponen un modelo que combine de manera cerrada la generación de rutas de aprendizaje, la evaluación automatizada y la interpretación de resultados, todo dentro de una misma arquitectura.

Otra crítica relevante apunta a la **limitada exploración de algoritmos evolutivos**, especialmente los **genetic algorithms**, en comparación con el uso más extendido de técnicas de IA y ML para aprendizaje y evaluación. Los autores sostienen que tareas como la generación de rutas de aprendizaje y de unidades de evaluación son problemas complejos de **optimización combinatoria y balance multicriterio**, por lo que los métodos genéticos merecen mayor atención. En este sentido, el artículo cuestiona indirectamente que la literatura haya priorizado otras técnicas más comunes, dejando relativamente subexplorado el potencial heurístico y adaptativo de los algoritmos genéticos en contextos educativos.

Finalmente, los autores también critican la **escasa validación en entornos educativos reales**. Señalan que muchos modelos descritos en la literatura se prueban solo con datos simulados o marcos teóricos, y que su integración efectiva dentro de herramientas educativas reales sigue siendo baja. Esta observación muestra que la motivación del artículo no es solamente proponer otro modelo conceptual, sino avanzar hacia una arquitectura más usable, escalable e integrable en plataformas educativas.

En síntesis, la motivación del estudio se apoya en la necesidad de superar la escasa personalización, la evaluación poco fina, la fragmentación de teaching-learning-assessment, la limitada exploración de algoritmos genéticos y la baja validación práctica de los modelos

previos. Desde ahí, el artículo justifica la construcción de un entorno adaptativo sistemático que responda de forma más completa a las necesidades del proceso educativo.

Descripción del aporte del autor

El artículo realiza un aporte relevante al campo de la educación digital al proponer un **modelo sistemático para un entorno adaptativo de enseñanza, aprendizaje y evaluación**, diseñado mediante **algoritmos genéticos**. A diferencia de muchos trabajos previos que se concentran solo en una parte del proceso educativo —por ejemplo, en el aprendizaje adaptativo o en la generación automática de preguntas—, este estudio plantea una **arquitectura integrada** que conecta de manera explícita las tres fases fundamentales del proceso formativo: **teaching, learning y assessment**. Este carácter integrador constituye uno de los aportes más importantes del artículo, ya que busca superar la fragmentación habitual de la literatura y avanzar hacia un entorno educativo más coherente y automatizado.

Uno de los principales aportes del artículo es la formulación del **DMAIR (Dynamic Model for Assessment and Interpretation of Results)** como una arquitectura modular orientada a automatizar tareas complejas del proceso educativo. Los autores explican que este modelo fue desarrollado de manera secuencial en investigaciones previas y en este artículo se presenta como una síntesis más completa, capaz de reducir la carga de trabajo humano en tareas organizativas y de aproximarse, en la medida de lo posible, a la calidad de las decisiones de un docente experimentado. Este objetivo es importante porque no se trata solo de automatizar por automatizar, sino de lograr que la automatización conserve criterios pedagógicos y de calidad comparables a los humanos.

Otro aporte central del artículo es la incorporación de **algoritmos genéticos** como núcleo metodológico para resolver dos tareas especialmente complejas: la **generación de rutas de aprendizaje** y la **generación de pruebas de evaluación**. Los autores justifican esta elección señalando que ambos problemas implican **optimización combinatoria, balance multicriterio y adaptación continua**, condiciones en las que los genetic algorithms resultan especialmente útiles por su flexibilidad, su capacidad multiobjetivo y su robustez para evitar óptimos locales. Este aporte es importante porque amplía el repertorio de técnicas aplicadas a la educación adaptativa y muestra el potencial de los métodos heurísticos en contextos pedagógicos.

En el componente de **Learning and Teaching (LT)**, el artículo aporta un modelo formal para construir **learning paths personalizados** a partir de bloques de aprendizaje. Cada learning block es descrito mediante prerrequisitos, conceptos aprendidos, niveles semánticos superiores e inferiores dentro de una ontología y procesos de enseñanza asociados. A partir de estos bloques, el sistema construye matrices y trayectorias que conectan contenidos de general a particular, usando una combinación de **ontologías de conceptos, bidimensional arrays y algoritmos genéticos**. Este diseño representa un aporte metodológico fuerte, porque no solo propone la idea de personalizar trayectorias, sino que formaliza matemáticamente cómo hacerlo. En las secciones del LT component se ve con detalle esta estructura, incluyendo la representación de bloques y matrices, así como los criterios para determinar la mejor ruta posible.

Asimismo, el artículo aporta una formalización rigurosa del **Assessment–Test Generation (TG)**, es decir, de la generación automatizada de secuencias de ítems o pruebas adaptadas a requisitos concretos. Los autores definen el ítem como una estructura con identificador, keywords, grado de dificultad, tipo de pregunta y naturaleza teórica o práctica. A partir de ahí, modelan la secuencia de ítems como un conjunto optimizable según restricciones como **tema, dificultad, tipo predominante de ítem y ratio teórico/práctico**. Este aporte es muy relevante porque permite pensar la evaluación como un proceso dinámico y configurable, no como un ensamblaje fijo de preguntas. Además, el uso de estructuras arborescentes y cromosómicas para construir tests representa una contribución técnica distintiva del trabajo.

Otro aporte importante es la incorporación de una **función de verificación y corrección automática** dentro del componente de evaluación. Para preguntas de opción múltiple, el chequeo es trivial, pero para respuestas abiertas cortas y ensayos, los autores exploran mecanismos más complejos basados en **Natural Language Processing** y medidas de similitud como la **edit distance**. Aunque este componente no agota el problema de la evaluación automática de respuestas abiertas, sí contribuye con una aproximación concreta y funcional que se integra dentro del modelo general. Esto refuerza el carácter sistémico del artículo, ya que no se queda solo en generar preguntas, sino que también se ocupa de verificar y evaluar respuestas.

El estudio también aporta un componente de **Item Analysis (IA)** orientado a interpretar resultados y detectar áreas conceptuales que requieren revisión. A partir de indicadores como el promedio por ítem, el número de respuestas correctas, el índice de discriminación, el punto biserial, el número de estudiantes que respondieron el ítem y el grado de dificultad, el modelo genera reportes que permiten identificar conceptos débiles dentro de un grupo o para un estudiante particular. En la *Figura 5 del artículo (página 19)* se muestra el esquema general de este módulo, donde los resultados de múltiples tests alimentan un reporte que produce una lista de conceptos a revisar. Este es un aporte valioso porque convierte la evaluación en retroalimentación accionable para la enseñanza, cerrando el ciclo entre assessment y pedagogical intervention.

Otro aporte muy claro del artículo es la identificación explícita de cómo su modelo responde a **brechas de investigación previas**. Los autores afirman que el DMAIR responde directamente a la falta de personalización dinámica, a la falta de integración entre enseñanza, aprendizaje y evaluación, y al uso limitado de algoritmos genéticos en educación. Además, subrayan que la arquitectura fue concebida con criterios de **escalabilidad y compatibilidad con LMS**, lo que la vuelve más cercana a una implementación real que muchos modelos puramente teóricos. Este punto es especialmente importante, porque el artículo no solo propone una idea conceptual, sino que intenta construir una arquitectura modular y técnicamente integrable.

El artículo también aporta una **fundamentación pedagógica** explícita. Los autores señalan que el DMAIR se alinea con el **constructivismo**, al favorecer la construcción individual del conocimiento mediante bloques ajustados al rendimiento previo del estudiante, y con los principios de la **formative assessment**, ya que incorpora un bucle continuo de retroalimentación entre evaluación y entrega de contenido. Esto fortalece el valor del modelo, porque muestra que la propuesta no se apoya solamente en la computación, sino también en teorías educativas que justifican su sentido pedagógico.

Además, el estudio aporta una metodología clara para el **desarrollo, implementación, prueba y análisis del modelo**. En la sección de resultados, los autores describen un proceso que incluye definición de objetivos, implementación, testing, integración, recolección de datos, preprocesamiento, análisis e interpretación. Aunque reconocen que en esta fase las pruebas se realizaron con **datasets sintéticos**, diseñados para simular escenarios educativos realistas, esta explicitación metodológica también constituye un aporte, porque transparenta el estado actual del modelo y prepara el terreno para futuras validaciones empíricas.

Finalmente, uno de los aportes más importantes del artículo es su visión de **entorno adaptativo completo**, donde el aprendizaje personalizado, la evaluación adaptativa y la interpretación automática de resultados no aparecen como herramientas separadas, sino como partes de un mismo ecosistema. Esta visión sistémica es lo que diferencia más claramente al trabajo frente a muchas investigaciones previas. En lugar de enfocarse solo en adaptive learning, o solo en question generation, o solo en analytics, el artículo propone una articulación cerrada entre estos componentes para apoyar al docente y mejorar la calidad del proceso educativo.

En conjunto, el aporte del artículo puede resumirse en cinco planos. Primero, propone un modelo integrado de **teaching-learning-assessment**. Segundo, introduce el uso de **algoritmos**

genéticos como estrategia central de optimización educativa. Tercero, formaliza rutas de aprendizaje y secuencias de evaluación mediante estructuras rigurosas. Cuarto, incorpora verificación automática e interpretación de resultados. Y quinto, establece una arquitectura modular, escalable y pedagógicamente fundamentada, que abre una línea prometedora para futuros entornos educativos inteligentes. Por ello, el artículo representa una contribución sólida y novedosa al diseño de ambientes adaptativos de enseñanza y evaluación.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en una **metodología sistemática de desarrollo e integración de componentes**, orientada a diseñar un entorno adaptativo completo que articule enseñanza, aprendizaje y evaluación mediante el uso de **algoritmos genéticos**. En primer lugar, los autores parten de la identificación de un problema central: la **fragmentación de los sistemas educativos digitales**, donde teaching, learning y assessment suelen desarrollarse de forma independiente, junto con la falta de personalización y la sobrecarga de trabajo docente. A partir de este diagnóstico, plantean como objetivo construir un modelo integrado que permita automatizar y optimizar estos procesos.

El segundo paso del proceso consiste en la **revisión y análisis del estado del arte**, donde los autores estudian múltiples investigaciones relacionadas con entornos de aprendizaje digital, evaluación automática, learning analytics y técnicas de inteligencia artificial. En esta etapa identifican brechas importantes, como la falta de integración entre los componentes educativos, la escasa personalización en tiempo real y el uso limitado de algoritmos evolutivos. Esta revisión permite definir con claridad el enfoque del modelo propuesto.

El tercer paso es la **definición de la arquitectura del modelo**, denominada **DMAIR (Dynamic Model for Assessment and Interpretation of Results)**. En esta etapa, los autores estructuran el sistema en módulos funcionales, como el componente de **Learning and Teaching (LT)**, el de **Assessment–Test Generation (TG)** y el de **Item Analysis (IA)**. Esta división modular permite organizar el sistema de manera lógica y facilita su desarrollo progresivo.

El cuarto paso consiste en el **diseño formal de cada componente del modelo**. En el caso del LT component, los autores desarrollan un esquema para generar rutas de aprendizaje personalizadas a partir de bloques de conocimiento organizados mediante ontologías. Para el TG component, diseñan un sistema de generación de pruebas basado en estructuras cromosómicas y restricciones pedagógicas. Y para el IA component, establecen métricas para analizar resultados y detectar áreas de mejora. Este diseño formal es clave porque permite transformar conceptos educativos en estructuras computacionales operativas.

El quinto paso es la **implementación del modelo mediante algoritmos genéticos**, que se utilizan como mecanismo de optimización para seleccionar las mejores rutas de aprendizaje y las secuencias de evaluación más adecuadas. En esta etapa, los autores configuran funciones objetivo, restricciones y mecanismos evolutivos (selección, cruce, mutación), permitiendo que el sistema explore múltiples soluciones y elija las más óptimas según criterios pedagógicos y de rendimiento.

El sexto paso es la **integración de los componentes en un sistema unificado**, donde los módulos de enseñanza, aprendizaje y evaluación interactúan entre sí. Esta integración permite que los resultados de la evaluación alimenten el ajuste de las rutas de aprendizaje, generando un ciclo continuo de mejora y adaptación. Aquí se consolida el carácter sistémico del modelo propuesto.

El séptimo paso consiste en la **fase de pruebas y validación preliminar**, donde el modelo se evalúa utilizando **datasets sintéticos** diseñados para simular escenarios educativos reales. Aunque no se trata aún de una validación en contextos reales, esta etapa permite verificar el

funcionamiento del sistema, ajustar parámetros y analizar su comportamiento frente a diferentes configuraciones.

El octavo paso es el **análisis e interpretación de resultados**, donde los autores examinan el desempeño del modelo en términos de generación de rutas, construcción de evaluaciones y análisis de resultados. Esta etapa permite evaluar la eficacia del sistema y detectar posibles mejoras.

Finalmente, el proceso culmina con la **formulación del aporte**, que consiste en un entorno adaptativo integrado capaz de personalizar el aprendizaje, automatizar la evaluación y generar retroalimentación basada en datos. Gracias a este proceso, los autores logran transformar una problemática compleja en una solución estructurada, combinando teoría educativa, modelado matemático y técnicas de optimización.

En conjunto, el proceso seguido integra revisión teórica, diseño arquitectónico, modelado formal, implementación algorítmica e integración sistémica, lo que permite construir un aporte sólido orientado a mejorar la educación digital mediante entornos adaptativos inteligentes.

Proceso para resolver el problema considerado por el autor

El proceso propuesto por los autores para resolver el problema de la **falta de personalización, la fragmentación entre enseñanza–aprendizaje–evaluación y la sobrecarga docente** se basa en la implementación de un **entorno adaptativo integrado (DMAIR)** apoyado en **algoritmos genéticos**. Este proceso no se limita a una sola etapa del aprendizaje, sino que articula de forma continua la generación de contenidos, la evaluación y la interpretación de resultados, permitiendo un sistema dinámico de mejora continua.

El primer paso del proceso consiste en la **modelación del conocimiento y del estudiante**. En esta etapa, el sistema organiza los contenidos en **learning blocks**, los cuales incluyen prerequisites, conceptos asociados y relaciones dentro de una ontología. Al mismo tiempo, se considera el estado del estudiante a partir de su desempeño previo. Esta doble modelación permite que el sistema tenga tanto una estructura del contenido como una referencia del progreso del alumno, condición necesaria para iniciar cualquier adaptación.

El segundo paso es la **generación de rutas de aprendizaje personalizadas** mediante el componente de **Learning and Teaching (LT)**. Aquí se aplican algoritmos genéticos para encontrar la mejor secuencia de contenidos que debe seguir el estudiante, considerando múltiples criterios como dificultad, dependencia entre conceptos y objetivos de aprendizaje. Este proceso implica una **optimización combinatoria**, donde el sistema evalúa diferentes rutas posibles y selecciona la más adecuada. De esta manera, se reemplaza la enseñanza lineal tradicional por trayectorias adaptadas al perfil del estudiante.

El tercer paso es la **generación adaptativa de evaluaciones** a través del componente **Test Generation (TG)**. En esta etapa, el sistema construye pruebas personalizadas seleccionando ítems con base en parámetros como tema, nivel de dificultad, tipo de pregunta y proporción teórico-práctica. Al igual que en la generación de rutas, se utilizan algoritmos genéticos para optimizar la selección de preguntas, garantizando que la evaluación sea coherente con el nivel y progreso del estudiante. Esto permite superar el modelo tradicional de evaluación uniforme.

El cuarto paso consiste en la **verificación automática de respuestas y evaluación del desempeño**. El sistema corrige respuestas objetivas de forma directa y utiliza técnicas de **procesamiento de lenguaje natural (NLP)** para evaluar respuestas abiertas o ensayos mediante medidas de similitud textual. Esta automatización permite obtener resultados de

manera rápida y consistente, reduciendo la carga del docente y facilitando la retroalimentación inmediata al estudiante.

El quinto paso es el **análisis de resultados mediante el componente Item Analysis (IA)**. En esta etapa, el sistema utiliza métricas como promedio por ítem, índice de discriminación, dificultad y número de respuestas correctas para identificar patrones de desempeño. A partir de este análisis, se generan reportes que permiten detectar **conceptos débiles o áreas que requieren refuerzo**, tanto a nivel individual como grupal. Este paso es clave porque convierte la evaluación en información útil para la toma de decisiones pedagógicas.

El sexto paso es la **retroalimentación y ajuste del proceso de aprendizaje**. Los resultados obtenidos en la evaluación alimentan nuevamente el sistema, permitiendo modificar las rutas de aprendizaje y generar nuevos contenidos o evaluaciones adaptadas. Este ciclo continuo convierte al modelo en un sistema dinámico, donde cada iteración mejora la precisión de la personalización. Así, el aprendizaje deja de ser estático y se convierte en un proceso evolutivo.

El séptimo paso es la **integración del docente en el sistema**. Aunque muchas tareas se automatizan, el profesor mantiene un rol clave en la supervisión, interpretación de resultados y diseño pedagógico. El sistema reduce la carga operativa, permitiendo que el docente se enfoque en intervenciones más estratégicas y personalizadas.

Finalmente, el proceso se completa con la **evaluación continua del sistema y su mejora progresiva**. A través de pruebas con datasets (aunque inicialmente sintéticos), los autores verifican el funcionamiento del modelo y ajustan sus componentes. Este enfoque iterativo asegura que el sistema pueda evolucionar y adaptarse a diferentes contextos educativos.

En conjunto, el proceso transforma un sistema educativo tradicional, rígido y fragmentado, en un entorno **adaptativo, integrado y basado en datos**, donde enseñanza, aprendizaje y evaluación se retroalimentan continuamente. Así, el modelo propuesto ofrece una solución estructurada y escalable para mejorar la personalización y la calidad del proceso educativo.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, los autores emplean métricas distintas según cada componente del modelo **DMAIR**. En la parte de validación pedagógica general, proponen cuatro indicadores para futuras pruebas empíricas: **Knowledge Gain (KG)**, **Learning Efficiency (LE)**, **Error Reduction Rate (ERR)** y **Engagement Level (EL)**. Estos indicadores buscan medir, respectivamente, la mejora entre pretest y posttest, la rapidez y eficacia con que el estudiante alcanza objetivos, la disminución de errores repetidos y el nivel de interacción del estudiante con el contenido. No obstante, en la fase experimental actual del artículo, la validación se realiza principalmente con **datasets sintéticos** y se concentra más en métricas de desempeño computacional y de optimización del modelo que en resultados pedagógicos directos.

En el componente de **generación de pruebas con estructuras arborescentes**, los resultados se evalúan mediante el **número de intersecciones entre palabras clave deseadas y palabras clave de los ítems**, así como por la cantidad de **conexiones válidas** dentro del árbol generado. En uno de los ejemplos, el sistema obtuvo un subárbol con **9 coincidencias de palabras clave** y **8 aristas válidas**, lo que los autores interpretan como una selección eficiente de ítems relevantes. En la segunda simulación arborescente, el sistema generó varias secuencias de 5 ítems que cubrían correctamente los keywords solicitados por el usuario, lo que muestra que el modelo logra construir pruebas coherentes respecto al tema pedido.

En el componente de **generación genética de pruebas**, las métricas principales son el **fitness inicial y final**, la **dificultad obtenida**, el **runtime** y la **population variation**. En una simulación de laboratorio, el algoritmo alcanzó un **fitness final de 0.7054**, mejorando el valor previo de **0.6961**, con un **tiempo de ejecución de 0.19 segundos** y una dificultad promedio del cromosoma ganador de **0.4170**, muy cercana al valor objetivo de **0.4**. En una segunda serie de 10 ejecuciones, el fitness final osciló aproximadamente entre **0.583 y 0.599**, con runtimes entre **11.85 y 21.35 segundos**, mostrando un comportamiento relativamente estable. Además, el artículo compara estos tiempos con una versión previa del algoritmo y señala que la implementación actual obtiene **menores tiempos de ejecución** en los escenarios presentados.

Otra métrica importante aparece en el análisis de complejidad y rendimiento, donde los autores construyen un **modelo de regresión lineal múltiple** para estimar el runtime según **N** (número de ítems), **K** (ítems por prueba) y **NG** (número de generaciones). El modelo obtuvo resultados muy fuertes: **MSE = 0.331**, **RMSE = 0.576**, **MAE = 0.429**, **MAPE = 0.045** y **R² = 0.975**, lo que significa que explica el **97.5 %** de la variabilidad del tiempo de ejecución. Además, el artículo muestra que el parámetro con mayor influencia sobre el runtime es **NG**, seguido de **N**, mientras que **K** tiene una influencia menor.

En el componente de **Item Analysis**, los autores usan métricas clásicas de evaluación como **degree of difficulty (dd_q)**, **standard deviation (sd_q)**, **item discrimination (d_q)**, **point-biserial (pbs_q)**, **mean score (m_q)** y **number of correct answers (l_q)**. A partir de estas métricas, el sistema identificó ítems problemáticos y generó una lista de temas que requerían revisión, como **sistemas operativos, Windows OS, programación, Microsoft Word, formatting, algoritmo y aplicaciones prácticas de programación**. Los autores señalan que cerca del **27 % de los ítems** fue seleccionado como problemático bajo su criterio de corte.

Al comentar estos resultados, puede decirse que son **mejores que enfoques más simples o versiones previas del algoritmo**, sobre todo en términos de **optimización, convergencia y tiempo de ejecución**. El propio artículo concluye que los enfoques **tree-based y genetic-based** ofrecen resultados prometedores en generación de contenido de evaluación y rendimiento. Sin embargo, frente a otros trabajos educativos más empíricos, todavía hay una limitación: los autores no validan aún con estudiantes reales, sino principalmente con datos sintéticos. Por eso, los resultados son sólidos en el plano **computacional y estructural**, pero todavía necesitan validación pedagógica real para afirmar con total certeza que también son superiores en aprendizaje efectivo.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte interesante y bastante sólido porque propone un modelo que no se limita únicamente a la generación de evaluaciones, sino que intenta integrar de manera conjunta **enseñanza, aprendizaje y assessment** dentro de un mismo entorno adaptativo. Esta es una de sus principales fortalezas, ya que muchos trabajos previos se concentran solo en una parte del proceso educativo, mientras que aquí se plantea una arquitectura más amplia, modular y con intención de escalabilidad. También resulta valioso que los autores no se queden en una descripción general, sino que formalicen matemáticamente buena parte de la propuesta, incorporando estructuras como **ontologías, árboles, cromosomas, matrices y funciones de fitness**, lo que le da rigor computacional al modelo.

Otra fortaleza importante es la elección de **algoritmos genéticos** como mecanismo de optimización. El artículo justifica bien esta decisión, señalando que la generación de rutas de aprendizaje y pruebas adaptativas implica problemas de **optimización combinatoria y balance multicriterio**, donde estos métodos tienen sentido. Además, los resultados muestran que el modelo logra un rendimiento computacional prometedor, con buenos valores de **fitness**, tiempos de ejecución relativamente bajos en algunos escenarios y un modelo de regresión con **R² = 0.975**, lo que sugiere una buena consistencia en la predicción del comportamiento del

sistema. Desde el punto de vista técnico, esto hace que la propuesta sea seria y bien argumentada.

Sin embargo, una primera observación crítica es que el artículo sigue teniendo un enfoque **más computacional que pedagógico**. Aunque menciona principios como el constructivismo y la formative assessment, la mayor parte del desarrollo se concentra en la formalización algorítmica, en la optimización y en la generación automática de rutas o pruebas. Esto hace que el trabajo sea fuerte desde la ingeniería del sistema, pero menos profundo en la discusión de cómo esas adaptaciones impactan realmente en la experiencia educativa, en el aprendizaje significativo o en la interacción docente-estudiante.

Otra limitación importante, reconocida por los propios autores, es que la validación actual se realiza principalmente con **datasets sintéticos**, contruidos para simular escenarios realistas. Aunque esto es útil para probar la lógica interna del modelo, todavía no permite asegurar con total solidez que el sistema funcionará igual de bien en contextos educativos reales, donde intervienen factores mucho más complejos, como la motivación auténtica del estudiante, la variabilidad del aula, las decisiones del docente o los problemas de infraestructura. En ese sentido, el artículo ofrece una propuesta prometedora, pero todavía en una etapa de validación preliminar.

También se puede observar que, aunque el artículo menciona temas como **privacidad, transparencia algorítmica y learner autonomy**, estos aspectos aparecen más como advertencias o consideraciones generales que como un análisis profundo de riesgos éticos. Dado que el sistema recopila y procesa información del estudiante para personalizar aprendizaje y evaluación, habría sido útil una discusión más desarrollada sobre sesgos, interpretabilidad y límites de la automatización.

En síntesis, se trata de un artículo fuerte en términos de **modelado, integración y optimización computacional**, con una propuesta original y bien estructurada. No obstante, necesita todavía mayor validación en escenarios educativos reales y una profundización más fuerte en sus implicancias pedagógicas y éticas para consolidarse plenamente como solución educativa integral.

16. ARTICULO 16

Author (s): Song, C.; Shin, S.-Y.; Shin, K.-S.

Title of paper: Implementación del marco de optimización del aprendizaje basado en retroalimentación dinámica: un enfoque de aprendizaje automático para personalizar las trayectorias educativas.

Journal: Applied Sciences

Volume (issue): 14

pag – pag (year): 916 (2024)

Estado del arte que hace el autor

El estado del arte presentado por los autores se desarrolla en torno a la **personalized education** y a la forma en que el **machine learning** ha comenzado a transformar las trayectorias de aprendizaje dentro de entornos digitales. Desde el inicio del artículo, los autores sitúan el problema en el contexto de la era digital, donde la educación personalizada deja de ser solo una aspiración teórica y pasa a convertirse en una necesidad práctica frente a la diversidad de habilidades, estilos de aprendizaje e intereses de los estudiantes. El artículo señala que los enfoques tradicionales de enseñanza, basados en un modelo uniforme para todos, resultan cada vez menos adecuados en un entorno donde las plataformas digitales permiten recopilar datos en tiempo real, analizar el progreso del aprendiz y ajustar los contenidos según sus necesidades.

Uno de los primeros ejes del estado del arte es la revisión histórica de la **evolución de la educación personalizada en la era digital**. Los autores muestran que este proceso se ha ido consolidando progresivamente: desde la expansión de internet a finales de los años noventa, pasando por la aparición de plataformas de aprendizaje online en los 2000, el auge del mobile learning en la década de 2010 y, más recientemente, la irrupción de la inteligencia artificial y el machine learning como herramientas centrales de personalización. En la *Figura 1 del artículo (página 2)* se presenta precisamente una línea de tiempo con hitos clave, donde se visualiza cómo la educación personalizada ha ido evolucionando junto con el desarrollo tecnológico. Esta revisión histórica es importante porque muestra que la propuesta de los autores no aparece de la nada, sino como parte de una transformación más amplia del ecosistema educativo.

Otro componente central del estado del arte es el papel del **machine learning en educación**. Los autores sostienen que su incorporación representa un punto de inflexión en la personalización educativa, ya que permite pasar de métodos estáticos y reactivos a enfoques más dinámicos, predictivos y adaptativos. Según el artículo, el machine learning usa grandes volúmenes de datos para identificar patrones de aprendizaje, anticipar resultados y personalizar tanto el contenido como la experiencia educativa. Esta revisión presenta al ML no solo como una herramienta técnica, sino como un motor que permite comprender con mayor profundidad las necesidades del estudiante y ajustar el currículo y la instrucción de forma más precisa.

En la revisión de la literatura, los autores identifican varias **aplicaciones concretas del machine learning en contextos educativos**. Entre ellas destacan los **personalized learning environments**, donde los algoritmos analizan patrones, preferencias y desempeño para construir trayectorias adaptadas; la **automatización de tareas administrativas**, como grading y assessment; la **predictive analytics**, que permite anticipar riesgos de bajo rendimiento y activar intervenciones tempranas; y los **adaptive testing mechanisms**, donde la dificultad de las pruebas cambia según las respuestas del estudiante. Además, el artículo menciona entornos gamificados, simulaciones interactivas y laboratorios virtuales como ejemplos de cómo el ML contribuye a generar experiencias de aprendizaje más activas e inmersivas. En la *Figura 2 (página 4)*, estas aplicaciones se resumen visualmente en cuatro bloques: **Personalized Learning Pathways, Automated Grading System, Adaptive Testing Mechanisms y Predictive Analytics**.

El estado del arte también dedica una parte importante a los **fundamentos teóricos del aprendizaje personalizado**. Los autores revisan varias teorías educativas y psicológicas que sostienen conceptualmente este enfoque. En primer lugar, presentan la **constructivist theory**, que entiende el aprendizaje como un proceso activo donde el estudiante construye nuevas ideas a partir de conocimientos previos. Luego incorporan la **cognitive load theory**, que enfatiza la necesidad de regular la cantidad de información para evitar que el estudiante se sienta sobrecargado o subestimulado. También se revisa la **theory of multiple intelligences** de Gardner, donde se plantea que los estudiantes poseen distintas fortalezas y modos de aprender, lo que justifica la creación de caminos diversificados. A esto se suma la **zone of proximal development (ZPD)** de Vygotsky, que inspira la idea de ajustar la dificultad dentro de un margen óptimo de reto, y los principios de **self-regulated learning**, que destacan la autonomía y la motivación del aprendiz. En la *Tabla 1 del artículo (página 5)* se resume claramente el aporte de cada una de estas teorías al aprendizaje personalizado.

Otro eje fuerte del estado del arte es la revisión de estudios previos sobre **adaptive learning systems**. Los autores explican que estos sistemas han recibido amplia atención en la literatura como una convergencia entre pedagogía y tecnología, ya que ajustan contenidos y rutas de aprendizaje en función de las necesidades del estudiante. El artículo resume que investigaciones anteriores han mostrado beneficios sobre **engagement** y **academic performance**, reducción de **cognitive overload**, fomento de la **inclusive education** e integración con otras estrategias como el **project-based learning**. En la *Tabla 2 del artículo (páginas 5 y 6)* se presenta un resumen de estudios clave, incluyendo trabajos que reportan mejoras en el engagement y el rendimiento, acomodación a distintos learning styles y la eficacia de técnicas de machine learning para optimizar trayectorias de aprendizaje.

El estado del arte también muestra que la personalización no debe entenderse solo desde la dimensión cognitiva, sino también desde la **motivación, el engagement y la interacción social**. En la sección de marco teórico, los autores revisan cómo el ML puede incrementar el involucramiento del estudiante mediante contenido adaptado, feedback inmediato y actividades interactivas. Además, se explica que los sistemas personalizados pueden mejorar la motivación al mantener al estudiante dentro de un nivel de desafío adecuado y ofrecer recompensas o señales de progreso. El artículo también menciona la importancia de la colaboración y la interacción social, señalando que el machine learning puede agrupar estudiantes de manera más efectiva y recomendar actividades cooperativas basadas en perfiles complementarios. En la *Figura 3 del artículo (página 9)* se ilustra esta integración entre **cognitive development, motivation theory y social interaction**, conectadas con caminos de aprendizaje personalizados, evaluación adaptativa y plataformas de aprendizaje social, todo ello orientado a un mayor engagement y motivación.

Un punto especialmente importante del estado del arte es la **identificación de brechas en la investigación actual**. Los autores reconocen que, a pesar de los avances logrados por los sistemas adaptativos y el machine learning en educación, todavía hay vacíos significativos. Señalan la falta de **longitudinal studies** que evalúen el impacto sostenido del aprendizaje personalizado, la escasa evidencia sobre su efectividad en diferentes contextos demográficos, culturales y socioeconómicos, la limitada comprensión de cómo estos sistemas se integran con las clases tradicionales y el poco estudio sobre el rol del docente dentro de estos entornos. A esto se suma la necesidad de investigar con más profundidad las implicancias de **data privacy** y el uso ético de la información del estudiante. Estas observaciones permiten ver que el artículo no adopta una postura ingenuamente optimista, sino que reconoce las limitaciones del conocimiento actual.

Finalmente, el estado del arte se cierra con un esfuerzo explícito por conectar las teorías revisadas con la propuesta del artículo, el **Dynamic Feedback-Driven Learning Optimization Framework (DFDLOF)**. Los autores explican que conceptos como la cognitive load theory y la ZPD no se mencionan solo como antecedentes, sino que guían directamente el diseño del

framework, ya que este ajusta contenido, dificultad y feedback según la capacidad y evolución del aprendiz. Así, el estado del arte no solo describe lo que se sabe, sino que construye la base conceptual para justificar un marco donde machine learning, feedback dinámico y trayectorias adaptativas se integran en una propuesta más sistemática. En síntesis, el estado del arte del artículo muestra un campo en expansión, donde convergen teorías del aprendizaje, analítica de datos, machine learning, adaptive systems y psicología educativa, pero también un campo donde siguen existiendo vacíos importantes que justifican la necesidad del DFDLOF.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de los autores surge de una constatación clara: aunque la **personalized education** y los **adaptive learning systems** han avanzado mucho gracias al desarrollo de las tecnologías digitales y del **machine learning**, todavía existe un vacío importante en la investigación y en la práctica educativa. En la introducción del artículo, los autores señalan que, pese a la creciente disponibilidad de plataformas digitales capaces de recopilar y analizar datos en tiempo real, la educación sigue arrastrando limitaciones del modelo tradicional “**one-size-fits-all**”, que no responde adecuadamente a la diversidad de habilidades, intereses, estilos de aprendizaje y ritmos de progreso de los estudiantes. Desde esa crítica al enfoque uniforme nace la necesidad de proponer un marco más dinámico, sensible y adaptativo como el **DFDLOF**.

Otra motivación importante del estudio se relaciona con una crítica a la literatura existente sobre personalización educativa. Los autores afirman explícitamente que, **a pesar de los avances significativos en educational technology, existe una carencia de estudios comprensivos que integren machine learning para generar experiencias de aprendizaje realmente dinámicas y adaptativas**. Es decir, reconocen que ya hay numerosos trabajos sobre adaptive learning systems y sobre aplicaciones de ML en educación, pero consideran que la investigación previa sigue estando fragmentada y que todavía faltan marcos que articulen de forma más completa datos, feedback en tiempo real y personalización de trayectorias de aprendizaje. Esta es precisamente una de las razones por las que presentan el **Dynamic Feedback-Driven Learning Optimization Framework**.

Los autores también critican indirectamente que muchas investigaciones previas se han concentrado en efectos inmediatos o en contextos específicos, sin profundizar suficiente en varias dimensiones todavía poco exploradas. En la sección “**Identifying Gaps in Current Personalized Learning Research**”, señalan al menos cinco vacíos concretos: la falta de **longitudinal studies** que permitan conocer efectos duraderos del aprendizaje personalizado; la escasa comprensión de su eficacia en distintos contextos demográficos, culturales y socioeconómicos; la poca investigación sobre cómo integrar estos sistemas dentro de aulas tradicionales; la limitada claridad sobre el papel del **teacher** dentro de entornos altamente personalizados; y la insuficiencia de análisis sobre **data privacy** y uso ético de la información del estudiante. Esta enumeración funciona como una crítica directa a los trabajos anteriores, que si bien han demostrado beneficios, todavía no explican completamente cómo sostener, integrar y gobernar responsablemente estas tecnologías.

Otra crítica implícita del artículo apunta a ciertas bases teóricas usadas en el campo. En la sección “**Critical Examination of Theories in Personalized Learning**”, los autores reconocen el valor histórico de teorías como la de las **multiple intelligences** de Gardner, pero al mismo tiempo advierten que algunos elementos asociados a los **learning styles** han sido cuestionados por investigaciones recientes, incluso señalados por algunos autores como posibles **neuromyths**. Con esto, los autores dejan ver que no basta con repetir marcos teóricos populares: es necesario revisarlos críticamente e integrarlos con otras teorías cognitivas y socioculturales más sólidas. Esta postura muestra que la motivación del estudio no es solo tecnológica, sino también teórica.

En síntesis, la motivación del artículo se apoya en tres críticas principales: la persistencia de modelos educativos uniformes poco sensibles a la diversidad del estudiante, la fragmentación y limitación de la literatura previa sobre personalización con machine learning, y la necesidad de revisar críticamente tanto los marcos teóricos como las implicancias éticas de estas tecnologías. Desde ahí, los autores justifican el desarrollo del **DFDLOF** como una respuesta orientada a construir trayectorias educativas más adaptativas, individualizadas y respaldadas por análisis de datos y feedback continuo.

Descripción del aporte del autor

El artículo realiza un aporte significativo al campo de la educación digital al proponer un marco innovador denominado **Dynamic Feedback-Driven Learning Optimization Framework (DFDLOF)**, orientado a optimizar el aprendizaje personalizado mediante el uso de **machine learning** y sistemas de retroalimentación dinámica. A diferencia de enfoques tradicionales que ofrecen personalización limitada o estática, este modelo introduce una **arquitectura adaptativa basada en datos en tiempo real**, capaz de ajustar continuamente el contenido, la dificultad y la experiencia educativa según la evolución del estudiante. Este enfoque constituye el núcleo del aporte del artículo, ya que propone una transición desde sistemas reactivos hacia sistemas **predictivos, dinámicos y autoajustables**.

Uno de los aportes más importantes del estudio es la **integración del feedback continuo como eje central del aprendizaje adaptativo**. El modelo DFDLOF no se limita a analizar el desempeño del estudiante en momentos puntuales, sino que incorpora un flujo constante de información que permite ajustar la instrucción de manera progresiva. Este feedback se obtiene a partir de datos como resultados de evaluaciones, patrones de interacción, tiempo de uso, errores recurrentes y niveles de participación. A partir de estos datos, el sistema identifica fortalezas y debilidades, y adapta automáticamente los contenidos y las estrategias pedagógicas. Este enfoque mejora la precisión de la personalización y permite responder de forma más efectiva a las necesidades cambiantes del estudiante.

Otro aporte clave es la **estructura del framework**, que combina múltiples componentes en un sistema coherente. El DFDLOF integra procesos como la **recolección de datos**, el **análisis mediante machine learning**, la **generación de trayectorias de aprendizaje personalizadas** y la **evaluación adaptativa**. Esta integración permite que el aprendizaje no sea un proceso lineal, sino un ciclo continuo donde cada acción del estudiante influye en las decisiones futuras del sistema. En este sentido, el modelo propone un enfoque sistémico que conecta análisis de datos, toma de decisiones automatizada y adaptación pedagógica en un solo entorno.

El artículo también aporta una **aplicación concreta del machine learning en la personalización educativa**. Los autores muestran cómo los algoritmos pueden identificar patrones en grandes volúmenes de datos, predecir resultados académicos y recomendar contenidos adecuados para cada estudiante. Este uso del ML permite anticipar dificultades antes de que se conviertan en problemas graves, facilitando intervenciones tempranas. Además, el sistema puede ajustar la dificultad del contenido, proponer actividades específicas y reorganizar las rutas de aprendizaje, lo que mejora la eficiencia del proceso educativo.

Otro aporte relevante es la **articulación del modelo con teorías educativas consolidadas**. El DFDLOF no se presenta únicamente como una solución tecnológica, sino que se fundamenta en principios como la **constructivist theory**, la **cognitive load theory**, la **zone of proximal development (ZPD)** y el **self-regulated learning**. Por ejemplo, el sistema ajusta la dificultad del contenido para mantener al estudiante dentro de su zona de desarrollo próximo, evitando tanto la sobrecarga cognitiva como la falta de desafío. Esta integración teórica fortalece el valor del modelo, ya que demuestra que la personalización no es solo un problema técnico, sino también pedagógico.

El artículo también aporta una **mejora en la experiencia de aprendizaje del estudiante**, al combinar personalización, interactividad y motivación. El modelo permite ofrecer contenido relevante, feedback inmediato y actividades adaptadas, lo que incrementa el engagement y la participación. Además, al reducir la frustración asociada a contenidos demasiado difíciles o demasiado simples, el sistema contribuye a mantener la motivación del estudiante a lo largo del proceso de aprendizaje. Este enfoque tiene implicancias importantes en la retención y en el éxito académico.

Otro aporte importante es la **automatización de tareas educativas**, especialmente en evaluación y seguimiento. El DFDLOF permite automatizar procesos como la calificación, el análisis del desempeño y la generación de reportes, lo que reduce la carga administrativa del docente. Esto libera tiempo para que el profesor pueda enfocarse en actividades de mayor valor pedagógico, como la orientación personalizada y el acompañamiento del estudiante. En este sentido, el modelo no reemplaza al docente, sino que lo complementa y fortalece su rol.

El estudio también contribuye al destacar la importancia de la **predictive analytics en educación**. A través del análisis de datos históricos y actuales, el sistema puede identificar patrones de riesgo, como bajo rendimiento o falta de participación, y activar intervenciones tempranas. Este enfoque preventivo representa un cambio importante respecto a modelos tradicionales, que suelen actuar solo después de que el problema ya se ha manifestado.

Otro aporte significativo es la **visión de un entorno educativo adaptativo integral**, donde aprendizaje, evaluación y retroalimentación están completamente interconectados. El modelo propone un ciclo continuo en el que cada interacción del estudiante genera datos que alimentan el sistema, el cual a su vez ajusta el proceso educativo. Este enfoque convierte al aprendizaje en un proceso dinámico y evolutivo, en lugar de uno estático y lineal.

Finalmente, el artículo aporta la **identificación de futuras líneas de investigación**, destacando la necesidad de estudios longitudinales, análisis en distintos contextos culturales y socioeconómicos, y una mayor atención a temas como la privacidad de los datos y la ética en el uso del machine learning en educación. Este enfoque prospectivo refuerza la relevancia del trabajo y abre nuevas oportunidades para el desarrollo del campo.

En conjunto, el aporte del artículo puede resumirse en cuatro dimensiones principales: primero, propone un framework dinámico basado en feedback continuo; segundo, integra machine learning con teorías educativas; tercero, mejora la personalización y eficiencia del aprendizaje; y cuarto, plantea un enfoque preventivo y adaptativo basado en datos. Por ello, el DFDLOF representa una contribución importante para el desarrollo de sistemas educativos inteligentes y personalizados.

Proceso para obtener el aporte que considera el autor

El proceso seguido por los autores para construir su aporte se basa en una **metodología estructurada que combina revisión teórica, análisis de brechas y desarrollo de un framework basado en machine learning**. En primer lugar, los autores parten de la **identificación del problema central**, que consiste en la falta de personalización efectiva en los sistemas educativos, así como en la limitada capacidad de los modelos tradicionales para adaptarse a las necesidades individuales de los estudiantes. A partir de esta problemática, se establece como objetivo el desarrollo de un sistema dinámico que optimice el aprendizaje mediante retroalimentación continua.

El segundo paso del proceso consiste en la **revisión del estado del arte y del marco teórico**. En esta etapa, los autores analizan estudios previos sobre educación personalizada, adaptive learning systems y aplicaciones del machine learning en educación. Asimismo, integran teorías educativas como el constructivismo, la cognitive load theory, la zone of proximal development

y el self-regulated learning. Esta revisión no solo permite comprender el campo, sino también identificar las limitaciones de los enfoques existentes, lo que sirve como base para el diseño del nuevo modelo.

El tercer paso es la **identificación de brechas en la literatura**, donde los autores detectan problemas como la falta de integración entre sistemas adaptativos y clases tradicionales, la escasez de estudios longitudinales, la limitada consideración de contextos diversos y la ausencia de marcos que utilicen feedback en tiempo real de manera sistemática. Estas brechas justifican la necesidad de desarrollar un framework más completo y dinámico.

El cuarto paso consiste en el **diseño del framework DFDLOF (Dynamic Feedback-Driven Learning Optimization Framework)**. En esta etapa, los autores estructuran el modelo en diferentes componentes que permiten recolectar datos, analizarlos mediante machine learning, generar rutas de aprendizaje personalizadas y adaptar la evaluación. Este diseño integra múltiples procesos en un sistema coherente, donde cada componente cumple una función específica dentro del ciclo de aprendizaje.

El quinto paso es la **integración del machine learning en el modelo**, donde los algoritmos se utilizan para identificar patrones de aprendizaje, predecir resultados y tomar decisiones sobre la personalización del contenido. Este proceso permite que el sistema no solo reaccione ante el desempeño del estudiante, sino que también anticipe sus necesidades, mejorando la eficacia del aprendizaje.

El sexto paso es la **incorporación de mecanismos de retroalimentación continua**. En esta etapa, el sistema recoge información en tiempo real sobre el desempeño del estudiante y la utiliza para ajustar dinámicamente el contenido, la dificultad y las actividades. Este flujo constante de feedback es el elemento diferenciador del modelo, ya que permite una adaptación progresiva y no puntual.

El séptimo paso es la **formulación del modelo como un sistema cíclico y adaptativo**, donde los datos generados por el estudiante alimentan continuamente el sistema, permitiendo ajustes constantes. Este enfoque transforma el aprendizaje en un proceso dinámico, donde cada interacción contribuye a mejorar la personalización.

Finalmente, el proceso culmina con la **presentación del aporte del artículo**, que consiste en un framework capaz de integrar machine learning, feedback dinámico y teorías educativas en un solo sistema. Gracias a este proceso, los autores logran transformar una problemática compleja en una solución estructurada y escalable.

En conjunto, el proceso combina análisis teórico, identificación de vacíos, diseño conceptual e integración tecnológica, permitiendo desarrollar un modelo innovador orientado a mejorar la personalización del aprendizaje en entornos digitales.

Proceso para resolver el problema considerado por el autor

El proceso propuesto por los autores para resolver el problema de la **falta de personalización efectiva en la educación y la limitada adaptación de los sistemas tradicionales** se basa en la implementación del **Dynamic Feedback-Driven Learning Optimization Framework (DFDLOF)**, un modelo que integra **machine learning, retroalimentación continua y adaptación dinámica del aprendizaje**. Este proceso busca transformar la enseñanza uniforme en un sistema flexible, capaz de ajustarse constantemente a las necesidades individuales del estudiante.

El primer paso del proceso consiste en la **recolección de datos del estudiante**. El sistema obtiene información a partir de múltiples fuentes, como resultados de evaluaciones, patrones de

interacción, tiempo de uso, errores frecuentes, nivel de participación y comportamiento dentro de la plataforma. Esta etapa es fundamental, ya que permite construir un perfil dinámico del estudiante que servirá como base para la personalización del aprendizaje.

El segundo paso es el **análisis de los datos mediante algoritmos de machine learning**. En esta fase, el sistema identifica patrones, detecta fortalezas y debilidades, y predice el desempeño futuro del estudiante. Este análisis permite pasar de un enfoque reactivo a uno predictivo, donde el sistema no solo responde a lo que el estudiante hace, sino que anticipa sus necesidades.

El tercer paso consiste en la **generación de rutas de aprendizaje personalizadas**. A partir del análisis realizado, el sistema diseña trayectorias adaptadas al nivel, ritmo y estilo de aprendizaje del estudiante. Esto implica seleccionar contenidos adecuados, ajustar la dificultad y reorganizar la secuencia de aprendizaje para mantener al estudiante dentro de un nivel óptimo de desafío, alineado con la **zone of proximal development (ZPD)**.

El cuarto paso es la **implementación de evaluación adaptativa**. El sistema modifica la dificultad y el tipo de evaluaciones en función del desempeño del estudiante, permitiendo medir su progreso de manera más precisa. Esta evaluación no es estática, sino que se ajusta continuamente, proporcionando información más relevante sobre el aprendizaje real.

El quinto paso es la **retroalimentación continua y en tiempo real**. El DFDLOF incorpora un flujo constante de feedback que informa al estudiante sobre su desempeño, errores y avances, y al mismo tiempo alimenta al sistema para realizar nuevos ajustes. Este feedback puede incluir recomendaciones de contenido, sugerencias de mejora y alertas tempranas sobre posibles dificultades.

El sexto paso consiste en la **optimización del aprendizaje mediante ajuste dinámico**. A medida que el estudiante interactúa con el sistema, este actualiza continuamente el perfil del usuario y ajusta las estrategias pedagógicas. Este proceso iterativo permite mejorar progresivamente la precisión de la personalización y la eficacia del aprendizaje.

El séptimo paso es la **intervención del docente como apoyo estratégico**. Aunque el sistema automatiza muchas funciones, el profesor sigue desempeñando un rol clave en la supervisión, interpretación de resultados y orientación del estudiante. El modelo reduce la carga operativa, permitiendo al docente enfocarse en actividades de mayor valor pedagógico.

Finalmente, el proceso se completa con la **evaluación continua del sistema y su mejora progresiva**, donde los resultados obtenidos se utilizan para refinar el modelo, mejorar los algoritmos y adaptar el framework a distintos contextos educativos.

En conjunto, el proceso transforma un modelo educativo rígido en un sistema **dinámico, adaptativo y basado en datos**, donde el aprendizaje se ajusta continuamente a las necesidades del estudiante. Así, el DFDLOF se presenta como una solución integral para mejorar la personalización, el rendimiento y el engagement en entornos educativos digitales.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

En este artículo, las métricas que el autor utiliza para evaluar el **Dynamic Feedback-Driven Learning Optimization Framework (DFDLOF)** se relacionan principalmente con variables de **engagement, learning effectiveness, performance tracking**, personalización del contenido y capacidad de adaptación del sistema. Desde el resumen, los autores afirman que el framework mejora de manera significativa el **student engagement** y la **learning effectiveness**, gracias al uso de **real-time feedback** y de contenido instruccional personalizado según las necesidades individuales del estudiante. Además, en la arquitectura del modelo se incluyen componentes

específicos para **performance tracking and reporting**, recolección de datos, análisis con machine learning y mecanismos de retroalimentación inmediata y a largo plazo, lo que indica que la evaluación del sistema se apoya en el seguimiento continuo del desempeño, la interacción del estudiante y la calidad de la adaptación de las trayectorias de aprendizaje.

A nivel metodológico, el artículo también deja claro que el framework usa algoritmos de **supervised learning** para **predictive analytics**, **unsupervised learning** para agrupar estudiantes y personalizar rutas, **reinforcement learning** para ajustar los caminos de aprendizaje tras cada interacción, y **deep learning** para procesar datos más complejos de comportamiento y preferencias. Esto significa que las métricas no se reducen a una sola variable, sino que incluyen aspectos como predicción de desempeño futuro, identificación de estudiantes que necesitan apoyo, ajuste de dificultad, adecuación del contenido, reacción al feedback y patrones de interacción del estudiante con la plataforma. En la *Tabla 3 del artículo (página 12)* se resume precisamente el aporte de cada tipo de algoritmo al proceso de personalización.

En cuanto a los resultados, el artículo reporta de forma general que el DFDLOF **mejora significativamente el compromiso del estudiante y la efectividad del aprendizaje**, al ofrecer experiencias educativas más adaptativas, responsivas y centradas en el aprendiz. En el caso de **Khan Academy**, los autores sostienen que la aplicación del framework permite una personalización más profunda, con ajustes dinámicos de contenidos, metodologías y feedback según el progreso en tiempo real del estudiante. También destacan que el framework hace posible una mejor identificación de fortalezas y áreas de mejora, contribuyendo a una experiencia de aprendizaje más eficiente. En el caso de **Coursera**, el artículo señala que la implementación del DFDLOF mejora la capacidad de adaptación del sistema a perfiles de adultos y profesionales, optimizando recomendaciones, contenido, ritmo y evaluación. En ambos casos, el texto presenta el framework como una mejora clara frente a modelos de personalización más estáticos.

Al comentar estos hallazgos, puede decirse que los resultados son **mejores respecto a enfoques tradicionales o menos adaptativos**, porque el DFDLOF no solo personaliza contenidos, sino que introduce un ciclo continuo de **análisis–feedback–ajuste**, lo que hace el aprendizaje más flexible y sensible a las necesidades reales del estudiante. Sin embargo, es importante señalar que, en las secciones visibles del artículo, los resultados se presentan **más en términos cualitativos y de mejora significativa general** que con una batería detallada de métricas numéricas comparativas. Aun así, el aporte del estudio es valioso porque muestra que un framework guiado por feedback dinámico y machine learning puede superar modelos más rígidos y ofrecer trayectorias educativas más efectivas y personalizadas.

Observaciones y/o críticas suyas al artículo

El artículo presenta un aporte valioso porque propone un enfoque actual y bien alineado con las necesidades de la educación digital: el uso de **machine learning** y **feedback dinámico** para personalizar trayectorias de aprendizaje. Una de sus principales fortalezas es que no se limita a defender la idea general de la educación personalizada, sino que intenta articularla con una base teórica clara, incorporando referencias a **constructivism**, **cognitive load theory**, **zone of proximal development** y **self-regulated learning**. Esto le da al trabajo una base pedagógica más sólida que la de muchos estudios centrados solo en la tecnología. Además, el artículo destaca por integrar distintos niveles de análisis: teoría, aplicaciones del machine learning, arquitectura del framework y casos de implementación como **Khan Academy** y **Coursera**, lo que vuelve el texto claro y atractivo para entender el potencial del **DFDLOF**.

Otra fortaleza importante es que los autores identifican de manera explícita varias brechas en la literatura, como la falta de estudios longitudinales, la limitada investigación en contextos diversos, la poca claridad sobre el papel del docente y la necesidad de atender temas de

privacidad y ética de datos. Esta identificación de vacíos es positiva porque muestra que el artículo no asume que la personalización basada en machine learning ya está plenamente resuelta, sino que reconoce límites y desafíos pendientes. También es destacable que el trabajo intente vincular los conceptos teóricos con aplicaciones prácticas del framework, especialmente cuando explica cómo la **cognitive load theory** y la **ZPD** inspiran el ajuste dinámico del contenido y de la dificultad.

Sin embargo, una primera observación crítica es que el artículo resulta **más fuerte en el plano conceptual y argumentativo que en el empírico**. Aunque los autores afirman que el DFDLOF mejora significativamente el **student engagement** y la **learning effectiveness**, en las secciones visibles del artículo esos resultados aparecen de manera más bien general y descriptiva, sin mostrar con suficiente detalle métricas comparativas, procedimientos experimentales robustos o resultados cuantitativos extensos que permitan valorar con precisión cuánto mejora el framework frente a otros modelos. En ese sentido, el trabajo es convincente como propuesta y como visión de futuro, pero menos contundente como validación empírica exhaustiva.

Otra crítica importante es que, aunque el artículo menciona temas como **data privacy**, ética y diversidad de contextos, estos asuntos quedan más señalados como pendientes que verdaderamente desarrollados. Dado que el framework depende de la recolección y análisis continuo de datos del estudiante, habría sido útil una discusión más profunda sobre sesgos algorítmicos, consentimiento, transparencia y posibles desigualdades derivadas del uso de machine learning en educación. Asimismo, el papel del docente, aunque mencionado, todavía aparece algo secundario frente al protagonismo otorgado al sistema tecnológico, cuando en la práctica la mediación humana sigue siendo decisiva.

En síntesis, se trata de un artículo sólido y actual, con buen valor teórico y una propuesta interesante para la personalización educativa. No obstante, podría fortalecerse con una validación empírica más detallada y con una discusión más profunda sobre los riesgos éticos, pedagógicos y contextuales del uso intensivo de machine learning en educación.

17. ARTICULO 17

Author (s): Nye, B. D.; Pavlik, P. I.; Windsor, A.; Olney, A. M.; Hajeer, M.; Hu, X.

Título of paper: SKOPE-IT: superposición de tutoría en lenguaje natural sobre un sistema de aprendizaje adaptativo para matemáticas.

Journal: International Journal of STEM Education

Volume (issue): <https://doi.org/10.1186/s40594-018-0109-4>

pag – pag (year): 2018

Estado del arte que hace el autor

El desarrollo de los sistemas tutores inteligentes (Intelligent Tutoring Systems, ITS) ha representado uno de los avances más significativos dentro del campo de la educación asistida por tecnología. Diversas investigaciones han demostrado que estos sistemas pueden generar mejoras sustanciales en el aprendizaje, incluso comparables con la tutoría humana en ciertos contextos. Sin embargo, a pesar de estos resultados prometedores, el estado actual del arte evidencia limitaciones importantes relacionadas principalmente con la escalabilidad, la adaptabilidad a múltiples dominios y la integración con otros entornos educativos digitales .

Uno de los principales enfoques en ITS ha sido el desarrollo de sistemas altamente especializados, diseñados para tareas específicas como la resolución de problemas matemáticos paso a paso o la interacción mediante lenguaje natural. Por ejemplo, sistemas como AutoTutor han sido ampliamente estudiados por su capacidad de generar diálogos interactivos que fomentan la autoexplicación del estudiante, lo cual contribuye al aprendizaje profundo de conceptos. Este tipo de tutoría basada en lenguaje natural ha demostrado mejoras significativas

en diversas áreas del conocimiento, alcanzando resultados comparables a los de tutores humanos en condiciones controladas .

Por otro lado, existen sistemas como ALEKS, los cuales se centran en la adaptación del contenido a nivel macro, es decir, seleccionando problemas adecuados según el nivel de conocimiento del estudiante mediante modelos como la teoría de espacios de conocimiento. Este tipo de sistemas ha mostrado efectividad en el desarrollo de habilidades matemáticas, promoviendo el aprendizaje basado en dominio progresivo de competencias y prerrequisitos. Además, su uso en entornos educativos reales ha evidenciado mejoras en el rendimiento académico y reducción de brechas de aprendizaje .

Sin embargo, el estado del arte también revela que estos enfoques suelen desarrollarse de manera aislada, dando lugar a lo que se denomina “islas de aplicación”, donde cada sistema funciona de forma independiente sin interoperabilidad con otros entornos. Esta falta de integración limita el potencial de los ITS, ya que dificulta combinar distintas fortalezas pedagógicas, como la práctica adaptativa y la tutoría conceptual mediante diálogo. Asimismo, la expansión de estos sistemas a nuevos dominios implica altos costos de desarrollo, especialmente en módulos de evaluación y retroalimentación, lo que restringe su adopción a gran escala .

Otro aspecto relevante en el estado del arte es el uso de estrategias pedagógicas como los ejemplos resueltos (worked examples), la autoexplicación y el aprendizaje basado en impasses (momentos en los que el estudiante no puede continuar). Estas estrategias han demostrado ser efectivas para mejorar la comprensión conceptual, aunque en muchos sistemas tradicionales se presentan de forma pasiva, lo que reduce su impacto en el aprendizaje debido a la falta de interacción significativa .

En este contexto, la tendencia actual apunta hacia el desarrollo de sistemas híbridos que integren múltiples tecnologías educativas, combinando adaptatividad, interacción y personalización. No obstante, esta integración plantea desafíos técnicos y pedagógicos, como la coordinación entre sistemas, la gestión de la experiencia del usuario y la alineación de metodologías de enseñanza. Por ello, el estado del arte evidencia una necesidad clara de avanzar hacia arquitecturas más flexibles e interoperables que permitan aprovechar de manera conjunta las ventajas de distintos enfoques en sistemas tutores inteligentes.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal del autor surge a partir de las limitaciones identificadas en los sistemas tutores inteligentes existentes, los cuales, a pesar de su efectividad en contextos específicos, presentan debilidades significativas cuando se busca su implementación a gran escala o en entornos educativos diversos. Una de las críticas más relevantes es que estos sistemas suelen desarrollarse de manera aislada, lo que genera una fragmentación tecnológica donde cada plataforma cumple funciones particulares sin integrarse eficientemente con otras. Esta situación limita la posibilidad de aprovechar de manera conjunta distintas estrategias pedagógicas, como la práctica adaptativa y la tutoría basada en lenguaje natural.

Asimismo, el autor cuestiona que muchos sistemas se centran únicamente en un nivel de adaptabilidad. Por ejemplo, algunos entornos como ALEKS priorizan la selección de problemas adecuados al nivel del estudiante (adaptación externa), pero no profundizan en el acompañamiento durante la resolución del problema. Por otro lado, sistemas como AutoTutor se enfocan en la interacción conceptual mediante diálogo, pero carecen de mecanismos robustos para gestionar la progresión global del aprendizaje. Esta separación de enfoques evidencia una falta de complementariedad en las soluciones actuales.

Otra crítica importante se dirige hacia el carácter pasivo de muchos recursos educativos digitales, como los ejemplos resueltos tradicionales o contenidos estáticos, los cuales no promueven una participación activa del estudiante. Según el autor, este tipo de materiales puede generar un aprendizaje superficial, ya que no incentivan procesos cognitivos como la auto explicación o el razonamiento profundo, elementos clave para la transferencia del conocimiento.

En conjunto, estas limitaciones motivan la necesidad de desarrollar un enfoque integrador que combine lo mejor de distintos sistemas existentes, permitiendo superar las barreras de escalabilidad, interacción y efectividad pedagógica. De esta manera, el autor plantea la integración como una solución estratégica para potenciar el impacto de los sistemas de aprendizaje inteligente en contextos educativos reales.

Descripción del aporte del autor

El principal aporte del autor consiste en el desarrollo e implementación de un sistema híbrido de tutoría inteligente denominado **SKOPE-IT (Shareable Knowledge Objects as Portable Intelligent Tutors)**, el cual propone una nueva forma de integrar distintos entornos de aprendizaje adaptativo mediante una arquitectura orientada a servicios. Este enfoque busca superar las limitaciones tradicionales de los sistemas tutores inteligentes, permitiendo combinar sus fortalezas en un solo entorno educativo más completo, flexible y eficiente.

A diferencia de los sistemas convencionales, que suelen operar de manera independiente, SKOPE-IT introduce un modelo de interoperabilidad que facilita la comunicación entre múltiples plataformas educativas. En este caso, el autor logra integrar dos sistemas ampliamente reconocidos: **AutoTutor**, enfocado en la tutoría basada en lenguaje natural, y **ALEKS**, centrado en el aprendizaje adaptativo mediante la resolución de problemas. Esta integración no solo es técnica, sino también pedagógica, ya que combina la adaptatividad a nivel macro (selección de problemas) con la adaptatividad a nivel micro (interacción paso a paso con el estudiante), generando una experiencia de aprendizaje más completa.

Uno de los aportes más innovadores del trabajo es la incorporación de **diálogos de autoexplicación** dentro de ejemplos resueltos. En lugar de presentar soluciones de forma estática, el sistema introduce pequeñas interacciones conversacionales que guían al estudiante a reflexionar sobre cada paso del procedimiento. Estos diálogos están diseñados para enfocarse en conceptos clave, promoviendo una comprensión más profunda en lugar de un aprendizaje mecánico. Además, el sistema utiliza ejemplos isomórficos, es decir, problemas con la misma estructura pero diferentes datos, lo que favorece la transferencia del conocimiento a nuevas situaciones.

Otro aporte relevante es la propuesta de una **arquitectura basada en servicios web**, que permite que los distintos componentes del sistema se comuniquen mediante mensajes semánticos en tiempo real. Esta estructura elimina las dependencias rígidas entre módulos, facilitando la escalabilidad y la reutilización de componentes en diferentes contextos educativos. Gracias a esta arquitectura, SKOPE-IT puede integrarse fácilmente en plataformas existentes sin necesidad de rediseñar completamente el sistema, lo cual representa una ventaja significativa frente a soluciones tradicionales más cerradas.

Además, el autor introduce mejoras en el procesamiento del lenguaje natural para adaptarlo al contexto matemático, lo cual representa un desafío importante debido a la naturaleza simbólica de esta disciplina. Para ello, se implementan técnicas como la normalización de términos equivalentes, el uso de análisis semántico (LSA) y la conversión de expresiones matemáticas en lenguaje natural comprensible. Estas mejoras permiten que el sistema interprete adecuadamente las respuestas del estudiante y proporcione retroalimentación más precisa y contextualizada.

El sistema también destaca por su diseño modular de contenido, basado en la creación de múltiples diálogos breves asociados a pasos específicos dentro de un problema. En total, se desarrollaron más de 400 diálogos distribuidos en 50 ejemplos de álgebra, cada uno enfocado en un componente de conocimiento particular. Este enfoque modular no solo facilita la reutilización del contenido, sino que también permite adaptar el nivel de profundidad de la tutoría según las necesidades del estudiante.

Desde el punto de vista pedagógico, el aporte del autor se fundamenta en la integración de tres principios clave: el uso de ejemplos resueltos, la promoción de la autoexplicación y el aprendizaje basado en impasses. Este último se refiere a intervenir en el momento en que el estudiante presenta dificultades para resolver un problema, lo cual incrementa la efectividad del aprendizaje. Al combinar estos principios, el sistema logra generar un entorno más interactivo y centrado en el estudiante, favoreciendo tanto la comprensión conceptual como la retención del conocimiento.

Finalmente, el autor aporta evidencia empírica sobre la efectividad del sistema, mostrando que la interacción con los diálogos de tutoría tiene una relación positiva con los resultados de aprendizaje. Aunque los resultados no fueron completamente concluyentes en todos los casos, se observó que los estudiantes que interactuaron más con el sistema lograron mejores desempeños, lo que sugiere que este enfoque tiene un alto potencial para mejorar los procesos educativos en matemáticas y otros dominios.

En conjunto, el aporte del autor no solo radica en la creación de una nueva herramienta tecnológica, sino en la propuesta de un modelo innovador de integración de sistemas educativos inteligentes, que abre nuevas posibilidades para el desarrollo de entornos de aprendizaje más adaptativos, interactivos y efectivos.

Proceso para obtener el aporte que considera el autor

El autor desarrolla su aporte a través de un proceso estructurado que combina diseño tecnológico, fundamentos pedagógicos y validación experimental. En primer lugar, parte del análisis de las limitaciones existentes en los sistemas tutores inteligentes, identificando la necesidad de integrar diferentes enfoques de aprendizaje en una sola plataforma. A partir de este diagnóstico, se plantea el diseño de un sistema híbrido capaz de unir las ventajas de la tutoría basada en lenguaje natural y el aprendizaje adaptativo centrado en la resolución de problemas.

Como siguiente etapa, el autor propone la creación de una arquitectura orientada a servicios, que permita la comunicación entre distintos sistemas mediante el intercambio de mensajes semánticos. Esta decisión es clave, ya que evita la dependencia entre componentes y facilita la integración de plataformas externas. Bajo este enfoque, se implementa el sistema SKOPE-IT como un intermediario que coordina la interacción entre AutoTutor y ALEKS, permitiendo que ambos funcionen de manera complementaria dentro de un mismo entorno educativo.

Posteriormente, se desarrolla el contenido pedagógico del sistema, el cual se basa en la elaboración de ejemplos resueltos enriquecidos con diálogos de tutoría. Para ello, se seleccionan problemas representativos del dominio del álgebra y se diseñan secuencias de interacción que guían al estudiante a través de la autoexplicación de cada paso. Este proceso implica identificar los componentes de conocimiento involucrados en cada problema y construir diálogos específicos que promuevan la comprensión conceptual. En total, se generan múltiples ejemplos acompañados de cientos de diálogos, organizados de manera modular para facilitar su reutilización y adaptación.

En paralelo, el autor aborda el desafío del procesamiento del lenguaje natural en el contexto matemático. Para lograr una interacción efectiva, se implementan mecanismos que permiten

interpretar las respuestas del estudiante, incluyendo la normalización de términos, el uso de análisis semántico y la conversión de expresiones matemáticas en lenguaje comprensible. Estas mejoras son fundamentales para garantizar que el sistema pueda evaluar correctamente las respuestas y proporcionar retroalimentación adecuada.

Una vez desarrollado el sistema, se procede a su implementación en un entorno educativo real. El proceso incluye la integración del sistema dentro de un curso de matemáticas, donde los estudiantes interactúan con la plataforma como parte de sus actividades académicas. Durante esta fase, se recopilan datos sobre el comportamiento de los usuarios, el tiempo de uso, la interacción con los diálogos y los resultados de aprendizaje, lo que permite evaluar el impacto del sistema en condiciones reales.

Finalmente, el autor realiza un análisis de los resultados obtenidos, utilizando métodos estadísticos para identificar la relación entre el uso del sistema y las mejoras en el aprendizaje. Este análisis permite validar parcialmente la efectividad del enfoque propuesto, destacando especialmente la importancia de la interacción activa del estudiante con los diálogos de tutoría. Asimismo, se identifican aspectos a mejorar, como la experiencia del usuario y la forma en que se integran los distintos componentes del sistema.

En conjunto, el proceso seguido por el autor evidencia un enfoque integral que combina teoría, diseño tecnológico y validación práctica, permitiendo desarrollar una solución innovadora que responde a las necesidades actuales del aprendizaje asistido por tecnología.

Proceso para resolver el problema considerado por el autor

El autor aborda el problema de la limitada efectividad e integración de los sistemas tutores inteligentes mediante un proceso que combina innovación tecnológica y estrategias pedagógicas orientadas al aprendizaje activo. En primer lugar, identifica que el problema principal no radica únicamente en la falta de herramientas educativas, sino en la desconexión entre distintos enfoques de enseñanza, como la práctica adaptativa y la tutoría conceptual. Por ello, plantea como solución la creación de un sistema híbrido que permita integrar estas metodologías dentro de una misma experiencia de aprendizaje.

El proceso de solución inicia con la integración de dos sistemas complementarios: ALEKS, encargado de gestionar la progresión del estudiante mediante la selección adaptativa de problemas, y AutoTutor, orientado a la interacción mediante lenguaje natural. Esta integración se realiza a través del sistema SKOPE-IT, el cual actúa como un intermediario que coordina la comunicación entre ambas plataformas, permitiendo que el estudiante transite de la resolución de problemas a la reflexión conceptual sin salir del entorno de aprendizaje.

Una vez establecida la integración, el sistema interviene en momentos clave del proceso de aprendizaje, específicamente cuando el estudiante presenta dificultades para resolver un problema. En estos casos, en lugar de mostrar únicamente una solución estática, el sistema presenta un ejemplo resuelto acompañado de diálogos interactivos que guían al estudiante paso a paso. Este enfoque se basa en el principio de aprendizaje por impasse, donde la intervención ocurre en el momento de mayor necesidad cognitiva, aumentando así la efectividad de la enseñanza.

Durante la interacción, el estudiante participa activamente respondiendo preguntas, reflexionando sobre los pasos del procedimiento y construyendo explicaciones propias. El sistema evalúa estas respuestas mediante técnicas de procesamiento de lenguaje natural y proporciona retroalimentación inmediata, ajustando el nivel de apoyo según el desempeño del estudiante. Este proceso no solo permite corregir errores, sino también fortalecer la comprensión de los conceptos involucrados en la resolución del problema.

Asimismo, el sistema utiliza ejemplos isomórficos para reforzar el aprendizaje, presentando problemas con la misma estructura pero diferentes valores o contextos. Esto permite que el estudiante generalice el conocimiento adquirido y lo aplique en situaciones similares, favoreciendo la transferencia del aprendizaje. Además, la estructura modular de los diálogos facilita que el sistema adapte la interacción según las necesidades específicas de cada estudiante, ofreciendo una experiencia personalizada.

El proceso también considera la importancia del tiempo y el esfuerzo del estudiante como factores determinantes en el aprendizaje. Por ello, el sistema está diseñado para incentivar la participación activa y el compromiso, promoviendo hábitos de estudio más efectivos. A través del seguimiento de la interacción del usuario, se recopila información que permite analizar el impacto del sistema y realizar mejoras continuas en su funcionamiento.

Finalmente, el proceso de solución se completa con la evaluación de los resultados obtenidos en un entorno real, donde se analiza el rendimiento de los estudiantes y su interacción con el sistema. Este análisis permite validar la efectividad del enfoque propuesto, así como identificar limitaciones y oportunidades de mejora, contribuyendo al desarrollo de sistemas educativos más integrados y eficientes.

En conjunto, el autor propone un proceso de solución que no solo integra tecnología avanzada, sino que también incorpora principios pedagógicos sólidos, logrando así una mejora significativa en la forma en que los estudiantes interactúan con los contenidos y construyen su aprendizaje.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

El autor emplea diversas métricas cuantitativas y cualitativas para evaluar la efectividad del sistema propuesto. En primer lugar, utiliza como indicador principal los **resultados de aprendizaje obtenidos en el sistema ALEKS**, específicamente comparando el desempeño inicial y final de los estudiantes mediante evaluaciones adaptativas. Estas mediciones permiten analizar el progreso en términos de dominio de habilidades matemáticas, siendo un referente confiable debido a su alta correlación con pruebas estandarizadas.

Adicionalmente, se consideran métricas relacionadas con la **interacción del estudiante**, como el tiempo dedicado al sistema, la cantidad de diálogos completados y la calidad de las respuestas generadas durante la tutoría basada en lenguaje natural. Estas variables permiten evaluar no solo el resultado final, sino también el proceso de aprendizaje y el nivel de compromiso del usuario. Asimismo, se emplea una prueba externa (BSDT) para medir la transferencia del aprendizaje a contextos más generales, lo cual complementa el análisis.

En cuanto a los resultados, el estudio muestra que no existen diferencias estadísticamente significativas entre el grupo experimental y el de control en términos globales. Sin embargo, un hallazgo clave es que existe una **relación positiva significativa entre la cantidad de interacción con los diálogos y las mejoras en el aprendizaje**. Es decir, los estudiantes que utilizaron más intensamente el sistema obtuvieron mejores resultados, independientemente de su nivel inicial o del tiempo total de estudio.

Desde una perspectiva comparativa, estos resultados son consistentes con investigaciones previas sobre sistemas como AutoTutor y ALEKS, los cuales ya habían demostrado efectividad de manera independiente. No obstante, el aporte del presente estudio radica en evidenciar que la **combinación de ambos enfoques puede potenciar el aprendizaje**, aunque su impacto depende del grado de interacción del estudiante. En este sentido, si bien los resultados no superan de manera contundente a otros estudios, sí aportan evidencia relevante sobre el valor de los sistemas híbridos.

En conclusión, los resultados pueden considerarse parcialmente superiores en términos de potencial pedagógico, ya que demuestran que la integración de tecnologías puede mejorar el aprendizaje cuando se utiliza adecuadamente. Sin embargo, también evidencian que factores como la participación del estudiante y el diseño de la experiencia influyen significativamente en la efectividad del sistema.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte relevante en la integración de sistemas tutores inteligentes; sin embargo, al analizarlo en el contexto del desarrollo de un **Sistema Inteligente de Nivelación Académica Adaptativa basado en Machine Learning para zonas como el VRAEM**, se identifican algunas limitaciones importantes. En primer lugar, el estudio se desarrolla en un entorno educativo con acceso constante a plataformas digitales, lo cual no refleja la realidad de muchas instituciones en zonas rurales o de difícil acceso, donde la conectividad es limitada o intermitente. Esto reduce la aplicabilidad directa del modelo propuesto en contextos como el VRAEM, donde la infraestructura tecnológica es un factor crítico.

Asimismo, el sistema se basa en la interacción mediante lenguaje natural, lo cual implica que los estudiantes deben tener cierto nivel de alfabetización digital y habilidades comunicativas. En contextos con brechas educativas, como el VRAEM, esto puede convertirse en una barrera en lugar de una solución, ya que no todos los estudiantes cuentan con las competencias necesarias para interactuar eficazmente con este tipo de tecnologías. Además, el sistema no incorpora de manera explícita técnicas modernas de Machine Learning para personalización avanzada, lo cual representa una oportunidad de mejora considerando que el enfoque de tu proyecto busca precisamente una adaptación más inteligente y predictiva.

Otra observación importante es que el sistema depende en gran medida del tiempo de uso del estudiante para generar mejoras en el aprendizaje. Esto puede ser problemático en entornos donde los estudiantes no disponen de suficiente tiempo o recursos para interactuar continuamente con la plataforma. En el caso del VRAEM, factores socioeconómicos pueden influir en la disponibilidad del estudiante, lo que limitaría el impacto del sistema si no se diseñan estrategias complementarias.

Finalmente, aunque el artículo demuestra que la integración de sistemas puede mejorar el aprendizaje, no logra evidenciar mejoras significativas en la transferencia del conocimiento a contextos generales, lo cual es un aspecto clave en proyectos de nivelación académica. Para un sistema orientado a reducir desigualdades, no solo es importante mejorar el rendimiento inmediato, sino también garantizar que el aprendizaje sea sostenible y aplicable en diferentes escenarios educativos.

En conclusión, si bien el artículo aporta una base sólida en cuanto a integración de tecnologías educativas, requiere adaptaciones importantes para ser aplicado en contextos como el VRAEM, especialmente en aspectos de accesibilidad, personalización mediante Machine Learning y adecuación a condiciones reales del entorno.

18. ARTICULO 18

Author (s): Son, T.

Title of paper: Sistemas de tutoría inteligente en la enseñanza de las matemáticas: una revisión sistemática de la literatura utilizando el modelo SAMR.

Journal: Computers

Volume (issue): 13(10)

pag – pag (year): 102474 (2024)

Estado del arte que hace el autor

El autor sitúa su estudio dentro del campo de la educación matemática mediada por tecnología, específicamente en el uso de los **Sistemas Tutores Inteligentes (ITS, por sus siglas en inglés)** como una de las expresiones más representativas de la inteligencia artificial aplicada a la educación. Desde esta perspectiva, se reconoce que la tecnología en matemáticas no solo debe servir como apoyo operativo, sino que debería contribuir a transformar la enseñanza y el aprendizaje, favoreciendo entornos de resolución de problemas, indagación y construcción activa del conocimiento. Sin embargo, el estado actual de la investigación muestra que esa transformación no siempre se concreta en la práctica.

Dentro del panorama previo, el autor señala que existe abundante evidencia empírica que respalda la efectividad de los ITS en el aprendizaje matemático. Distintos estudios y metaanálisis previos han reportado que estos sistemas pueden mejorar el rendimiento académico, proporcionar retroalimentación inmediata, adaptar rutas de aprendizaje y, en algunos casos, obtener resultados cercanos a los de la tutoría humana. En ese sentido, trabajos anteriores han abordado la efectividad general de los ITS en educación, sus características, aplicaciones y métodos de evaluación, así como su impacto en contextos específicos como la educación superior o la matemática escolar K–12.

El estado del arte también evidencia que los ITS han evolucionado junto con el desarrollo de la inteligencia artificial. Inicialmente concebidos como sistemas de tutoría personalizada con retroalimentación adaptativa, hoy incorporan funciones más complejas, como análisis del desempeño del estudiante, generación de contenidos ajustados a necesidades individuales, andamiaje cognitivo y apoyo paso a paso en la resolución de problemas. Estas capacidades han convertido a los ITS en una herramienta prometedora para atender la diversidad de ritmos y estilos de aprendizaje en matemáticas, sobre todo en contextos donde un solo docente no puede responder individualmente a todos los estudiantes.

No obstante, el autor destaca que el problema no radica únicamente en si los ITS son eficaces, sino en **cómo se integran pedagógicamente** dentro de la enseñanza de las matemáticas. El análisis de la literatura previa muestra que, en muchos casos, estos sistemas no transforman de fondo la experiencia educativa, sino que simplemente reemplazan o refuerzan prácticas tradicionales. Es decir, en lugar de promover aprendizajes constructivistas, exploratorios o centrados en la autonomía del estudiante, numerosos ITS continúan funcionando como medios de práctica guiada, repetición de ejercicios o secuencias rígidas de instrucción. Por ello, aunque la tecnología esté presente, su uso no siempre genera una verdadera innovación pedagógica.

Para explicar esta situación, el autor recurre al modelo **SAMR** —sustitución, aumento, modificación y redefinición— como marco conceptual para analizar el nivel de integración tecnológica en la educación matemática. A partir de la revisión de estudios anteriores, se observa que gran parte del uso de tecnologías educativas en matemáticas se ha concentrado en los niveles de sustitución y aumento, es decir, en funciones que mejoran o digitalizan prácticas ya existentes, pero sin rediseñar sustancialmente las actividades de aprendizaje. Esta

constatación refuerza la idea de que la potencialidad transformadora de la tecnología todavía no ha sido plenamente aprovechada.

Asimismo, el estado del arte presentado por el autor identifica que las revisiones previas sobre ITS se han centrado, sobre todo, en medir efectividad y tendencias generales, pero han dejado de lado una pregunta clave: **de qué manera estos sistemas están siendo integrados en la educación matemática y qué obstáculos impiden una integración realmente transformadora**. Aunque existían metaanálisis sobre el impacto de los ITS en educación y matemáticas, no había una revisión sistemática reciente que abordara específicamente su grado de integración pedagógica en esta área, especialmente considerando los avances ocurridos después de 2013.

En ese marco, el autor plantea que el estado del arte revela una doble realidad. Por un lado, los ITS poseen un valor comprobado como herramientas de personalización, retroalimentación y apoyo adaptativo. Por otro lado, su implementación en matemáticas sigue estando, en gran medida, atada a modelos tradicionales de enseñanza, con poca intervención transformadora del docente y con experiencias que muchas veces solo mejoran la práctica existente en lugar de redefinirla. A ello se suma que las investigaciones revisadas se concentran principalmente en educación primaria y secundaria, sobre todo en contenidos de números, aritmética, álgebra y geometría, mientras que otros niveles y dominios matemáticos siguen menos explorados.

En síntesis, el estado del arte que construye el autor muestra que los ITS ocupan un lugar importante en la educación matemática contemporánea y cuentan con respaldo empírico suficiente para justificar su uso. Sin embargo, también deja claro que aún existe una brecha entre su potencial tecnológico y su aprovechamiento pedagógico real. Precisamente por esa razón, el estudio se justifica en la necesidad de revisar de manera crítica cómo se han integrado estos sistemas en las últimas dos décadas y hasta qué punto han contribuido verdaderamente a transformar el aprendizaje matemático.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal del autor nace de una preocupación clara: aunque los **sistemas tutores inteligentes (ITS)** han mostrado resultados positivos en el aprendizaje de las matemáticas, todavía no existe evidencia suficiente de que realmente estén transformando la enseñanza y el aprendizaje, tal como suele afirmarse en el campo de la inteligencia artificial aplicada a la educación. El autor cuestiona que, pese al discurso optimista sobre el potencial transformador de estas tecnologías, en la práctica muchos ITS siguen siendo usados de una manera limitada, más orientada a reforzar o digitalizar métodos tradicionales que a generar experiencias de aprendizaje verdaderamente nuevas.

Una de las críticas centrales del autor hacia trabajos previos es que varios estudios se han concentrado principalmente en demostrar la **efectividad** de los ITS, por ejemplo midiendo mejoras en rendimiento, personalización o retroalimentación, pero han prestado poca atención a **cómo** esos sistemas se integran dentro de la educación matemática. Es decir, se sabe que pueden funcionar, pero no se ha analizado con suficiente profundidad si están siendo usados para transformar el aprendizaje o si solo están reemplazando prácticas ya existentes con una versión tecnológica. Para el autor, esta omisión es importante porque el valor de un ITS no depende únicamente de su capacidad técnica, sino también del modo en que es incorporado pedagógicamente en el aula.

Asimismo, el autor critica que algunos ITS no ofrecen oportunidades constructivistas reales para que el estudiante construya su propio conocimiento. En lugar de eso, muchos sistemas se limitan a presentar ejercicios, guiar procedimientos paso a paso y proporcionar retroalimentación inmediata, lo cual mejora ciertas funciones del proceso educativo, pero no necesariamente modifica la lógica de enseñanza. Desde esta perspectiva, varios ITS continúan

operando bajo esquemas rígidos, centrados en la práctica, la secuencia predefinida y el dominio progresivo de contenidos, reproduciendo métodos tradicionales más que promoviendo exploración, autonomía o aprendizaje significativo.

Otra crítica importante es que la investigación anterior sobre ITS en matemáticas se ha enfocado más en su aplicación general o en su efectividad estadística que en los **obstáculos que impiden una integración transformadora**. El autor observa que faltaban revisiones recientes que analizaran explícitamente qué nivel de integración alcanzan los ITS en educación matemática y qué factores limitan su potencial innovador. Entre estos factores, destaca la excesiva tendencia a minimizar la intervención del docente, como si el ITS pudiera reemplazar por completo su rol. El autor considera problemático este enfoque, ya que contradice la idea, ampliamente sostenida en educación matemática, de que el éxito del uso tecnológico depende también del contexto educativo y del papel activo del profesor.

En síntesis, la motivación del autor surge de una crítica al entusiasmo poco cuestionado con el que se ha tratado a los ITS en investigaciones anteriores. Su interés no está solo en confirmar si estas herramientas funcionan, sino en examinar si realmente están ayudando a redefinir la enseñanza de las matemáticas o si continúan atrapadas en modelos pedagógicos convencionales. Precisamente por esa razón, propone una revisión sistemática que permita identificar con mayor claridad las limitaciones de los trabajos previos y abrir nuevas líneas de investigación más críticas y transformadoras.

Descripción del aporte del autor

El aporte principal del autor consiste en realizar una **revisión sistemática de la literatura sobre los sistemas tutores inteligentes en la educación matemática**, con el propósito de analizar no solo su efectividad, sino, sobre todo, el modo en que estos sistemas han sido integrados en los procesos de enseñanza y aprendizaje. A diferencia de investigaciones previas que se centraban principalmente en medir resultados o describir características generales de los ITS, este estudio propone una mirada más crítica y pedagógica, orientada a determinar si estas tecnologías realmente están transformando la educación matemática o si solo están reforzando prácticas tradicionales con apoyo digital.

Uno de los aportes más importantes del trabajo es la utilización del modelo **SAMR** —sustitución, aumento, modificación y redefinición— como marco de análisis para clasificar el nivel de integración tecnológica de los ITS en matemáticas. El autor no se limita a adoptar este modelo de manera general, sino que lo **extiende y adapta específicamente al contexto de los sistemas tutores inteligentes en educación matemática**, construyendo criterios que permiten distinguir con mayor precisión cuándo un ITS solo sustituye funciones del docente y cuándo realmente rediseña o transforma las actividades de aprendizaje. Esta adaptación representa un aporte metodológico relevante, porque ofrece una herramienta concreta para estudiar la integración pedagógica de estas tecnologías desde una perspectiva más profunda.

Otro aporte significativo del autor es que organiza y sintetiza **20 años de investigación empírica**, revisando estudios publicados entre 2003 y 2023. Para ello, emplea un procedimiento sistemático basado en el protocolo **PRISMA**, define criterios de inclusión y exclusión, y selecciona finalmente 58 artículos empíricos centrados en el uso de ITS en educación matemática. Este proceso le permite construir una visión amplia, actualizada y estructurada del campo, superando la fragmentación de estudios aislados. En otras palabras, el autor no aporta un nuevo sistema tutor como producto tecnológico, sino una **comprensión integral del estado actual del área**, lo que resulta especialmente valioso para orientar investigaciones futuras y apoyar decisiones pedagógicas fundamentadas.

Asimismo, el estudio aporta evidencia sobre las **tendencias predominantes en la investigación de ITS en matemáticas**. El autor demuestra que la mayoría de los estudios

revisados se ubican en el nivel de **aumento** del modelo SAMR, es decir, utilizan los ITS para mejorar funcionalmente prácticas tradicionales sin transformar de manera sustancial la experiencia de aprendizaje. También identifica una menor proporción de trabajos en los niveles de modificación y redefinición, lo que indica que sí existen esfuerzos innovadores, aunque todavía son minoritarios. Este hallazgo es importante porque permite cuestionar la idea de que el simple uso de inteligencia artificial en educación garantiza innovación pedagógica.

Además, el autor aporta una caracterización detallada de los contextos en los que los ITS han sido estudiados. Encuentra que las investigaciones se concentran principalmente en la educación primaria y secundaria, especialmente en contenidos de **números y aritmética, álgebra y geometría**. También muestra que en la última década ha habido un crecimiento considerable en la producción científica sobre ITS en matemáticas, así como una mayor aparición de estudios en rangos transformadores del SAMR. Con ello, el trabajo no solo describe el presente del campo, sino que también permite observar su evolución y sus vacíos, lo que ayuda a delimitar áreas poco exploradas que merecen mayor atención.

Un aporte adicional del estudio es el análisis del **rol del docente** en la implementación de los ITS. El autor evidencia que, en la mayoría de investigaciones revisadas, el profesor tiene una participación mínima o se limita a supervisar técnicamente el uso del sistema, mientras que son pocos los casos donde el docente integra activamente el ITS dentro de una estrategia matemática más amplia. Este punto resulta clave porque muestra que el potencial transformador de estas tecnologías no depende solo del sistema en sí, sino también del modo en que el profesor lo articula con el contexto de enseñanza. De esta forma, el autor reposiciona al docente como un factor decisivo para que los ITS puedan generar cambios reales en la educación matemática.

En síntesis, el aporte del autor radica en ofrecer una **visión crítica, actualizada y estructurada** sobre el uso de los sistemas tutores inteligentes en matemáticas. Su trabajo contribuye metodológicamente al adaptar el modelo SAMR a este campo, aporta evidencia empírica organizada sobre tendencias, niveles de integración y roles docentes, y deja en claro que el verdadero desafío ya no es demostrar que los ITS funcionan, sino entender cómo utilizarlos de manera que transformen de verdad la enseñanza y el aprendizaje matemático.

Proceso para obtener el aporte que considera el autor

El autor desarrolla su aporte mediante un proceso metodológico riguroso basado en una **revisión sistemática de la literatura**, cuyo objetivo es analizar cómo los sistemas tutores inteligentes (ITS) han sido integrados en la educación matemática durante las últimas dos décadas. Este proceso inicia con la identificación de una brecha en la investigación existente: aunque hay numerosos estudios sobre la efectividad de los ITS, no se ha analizado con suficiente profundidad el nivel de integración pedagógica de estas tecnologías. A partir de esta problemática, el autor plantea la necesidad de realizar un estudio estructurado que permita comprender no solo qué tan efectivos son los ITS, sino cómo se están utilizando en la práctica educativa.

Como primera etapa, el autor define una **estrategia de búsqueda sistemática**, seleccionando bases de datos académicas relevantes en el ámbito educativo, como ERIC, Web of Science y EBSCO. Para asegurar la amplitud de la revisión, se construyen cadenas de búsqueda que combinan términos relacionados con inteligencia artificial, sistemas de aprendizaje, tutoría y educación matemática. Este proceso permite identificar inicialmente miles de estudios potencialmente relevantes, garantizando así un enfoque exhaustivo en la recopilación de información.

Posteriormente, se establecen **criterios de inclusión y exclusión** para filtrar los estudios seleccionados. Entre los criterios principales se consideran: que los artículos sean investigaciones empíricas, que estén relacionados directamente con el uso de ITS en educación

matemática, que hayan sido publicados en revistas científicas y que correspondan al periodo comprendido entre 2003 y 2023. Este filtrado se realiza en varias etapas, primero revisando títulos y resúmenes, y luego mediante la lectura completa de los artículos, lo que permite depurar el conjunto inicial hasta obtener una muestra final representativa de estudios relevantes.

En una siguiente fase, el autor aplica un proceso de **codificación y análisis de los estudios seleccionados**, utilizando un esquema estructurado que incluye variables como el contexto educativo, el nivel educativo, el dominio matemático, el propósito de la investigación y, principalmente, el nivel de integración tecnológica. Para este último aspecto, se utiliza el modelo SAMR, previamente adaptado al contexto de los ITS en matemáticas. Este proceso de codificación es realizado de manera sistemática y validado mediante la comparación entre evaluadores, lo que asegura la confiabilidad de los resultados obtenidos.

A continuación, el autor realiza un **análisis comparativo e interpretativo** de los datos obtenidos, identificando patrones, tendencias y relaciones entre las variables estudiadas. Este análisis permite determinar en qué medida los ITS se utilizan para sustituir, mejorar o transformar el aprendizaje, así como identificar los contextos en los que su impacto es mayor o menor. Además, se examina el rol del docente en estos entornos, lo cual aporta una dimensión pedagógica clave al estudio.

Finalmente, el proceso culmina con la **síntesis de resultados y generación de conclusiones**, donde el autor integra los hallazgos obtenidos para ofrecer una visión global del estado actual de los ITS en educación matemática. A partir de esta síntesis, se identifican limitaciones, vacíos de investigación y oportunidades de mejora, lo que permite no solo describir la situación actual, sino también orientar futuras investigaciones y aplicaciones prácticas en el ámbito educativo.

En conjunto, el proceso seguido por el autor se caracteriza por su enfoque sistemático, estructurado y basado en evidencia, lo que le permite construir un aporte sólido y confiable sobre la integración de los sistemas tutores inteligentes en la educación matemática.

Proceso para resolver el problema considerado por el autor

El autor plantea la resolución del problema a partir de un enfoque analítico y metodológico, orientado a comprender cómo los sistemas tutores inteligentes (ITS) están siendo utilizados en la educación matemática y si realmente cumplen con su potencial transformador. El problema central identificado es que, aunque los ITS han demostrado ser efectivos, su uso no siempre genera cambios significativos en la enseñanza, limitándose muchas veces a replicar métodos tradicionales. Para abordar esta situación, el autor desarrolla un proceso basado en la sistematización, análisis y evaluación crítica de la evidencia existente.

En primer lugar, el autor propone resolver el problema mediante la **recolección estructurada de evidencia empírica**, lo cual permite evitar interpretaciones aisladas o parciales. Para ello, se seleccionan estudios relevantes que abordan la aplicación de ITS en educación matemática, garantizando que estos incluyan resultados evaluables. Este enfoque permite construir una base sólida de información que refleje cómo se utilizan realmente estos sistemas en distintos contextos educativos.

En una segunda etapa, el autor aplica el modelo **SAMR** como herramienta para clasificar el nivel de integración tecnológica. Este modelo permite diferenciar si los ITS están siendo utilizados para sustituir prácticas tradicionales, mejorarlas funcionalmente o transformar completamente el proceso educativo. A través de esta clasificación, el autor logra identificar patrones claros en el uso de los ITS, evidenciando que la mayoría de los estudios se sitúan en niveles básicos de integración, lo cual confirma la hipótesis inicial del problema.

Posteriormente, el proceso de solución incluye un **análisis contextual** de los estudios revisados, considerando variables como el nivel educativo, el dominio matemático y el propósito de la investigación. Esto permite entender en qué contextos los ITS son más efectivos y en cuáles presentan mayores limitaciones. Asimismo, el autor analiza el rol del docente dentro de estos entornos, identificando que en muchos casos su participación es mínima, lo que puede influir negativamente en el potencial pedagógico del sistema.

Un aspecto clave en la resolución del problema es la **interpretación crítica de los resultados obtenidos**, donde el autor no se limita a describir datos, sino que analiza sus implicancias educativas. A partir de este análisis, se concluye que el verdadero problema no es la falta de tecnología, sino la forma en que esta se implementa. Es decir, los ITS tienen la capacidad de transformar el aprendizaje, pero esto solo ocurre cuando se utilizan en niveles más altos del modelo SAMR, donde se rediseñan las actividades y se promueve una participación más activa del estudiante.

Finalmente, el proceso se completa con la **propuesta de orientaciones para mejorar la integración de los ITS**, destacando la importancia de considerar tres factores fundamentales: las características de la tecnología, el contexto educativo y el rol del docente. El autor sugiere que estos elementos deben trabajar de manera conjunta para lograr una implementación efectiva, evitando el uso superficial de la tecnología y promoviendo un enfoque más transformador en la enseñanza de las matemáticas.

En conjunto, el proceso para resolver el problema se basa en un análisis sistemático y crítico que permite identificar no solo las fortalezas de los ITS, sino también las condiciones necesarias para que su implementación genere un impacto real en el aprendizaje.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

Para evaluar su estudio, el autor no utiliza métricas de rendimiento estudiantil directo, como puntajes de exámenes o ganancias de aprendizaje, sino **métricas de revisión sistemática y análisis categorial** aplicadas a los artículos seleccionados. En ese sentido, la principal métrica de análisis es la **clasificación de los estudios según los niveles del modelo SAMR** —sustitución, aumento, modificación y redefinición— adaptado al contexto de los sistemas tutores inteligentes en educación matemática. A ello se suman otras métricas descriptivas, como la distribución de los estudios por **año de publicación, nivel educativo, dominio matemático, propósito de investigación y rol del docente** dentro de la implementación del ITS. Estas variables le permiten al autor identificar tendencias, vacíos y patrones en veinte años de investigación empírica.

A partir de este análisis, el autor obtiene como resultado principal que la mayoría de los estudios revisados se ubican en el nivel de **aumento**, con **67.3% de los artículos**, mientras que solo **1.7%** corresponde a sustitución, **24.1%** a modificación y **6.9%** a redefinición. Esto significa que, en la mayor parte de los casos, los ITS se usan para mejorar funcionalmente prácticas ya existentes, pero no para transformar de manera profunda la enseñanza de las matemáticas. Asimismo, encuentra que la producción científica aumentó notablemente en la última década, que la mayor concentración de estudios se da en primaria y secundaria, y que los dominios más trabajados son números y aritmética, álgebra y geometría. También concluye que, en la mayoría de investigaciones, el docente tiene una intervención mínima, lo que limita el potencial transformador de estas herramientas.

En cuanto al comentario comparativo, los resultados del autor **no buscan demostrar que este estudio “supera” experimentalmente a otros**, porque no se trata de una investigación de intervención directa, sino de una revisión sistemática. Sin embargo, sí puede afirmarse que su aporte es **más amplio y crítico** que el de muchos trabajos previos, ya que no se limita a decir

que los ITS son efectivos, sino que examina **cómo** se están integrando pedagógicamente. En comparación con revisiones anteriores, que se centraban principalmente en la efectividad o en características generales de los ITS, este estudio ofrece una visión más profunda sobre el verdadero alcance educativo de estas tecnologías. Por ello, su resultado es valioso no porque muestre mejores puntajes que otros estudios, sino porque permite entender con mayor claridad las limitaciones reales del campo y por qué el potencial transformador de los ITS aún no se ha cumplido plenamente en educación matemática.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte valioso al analizar de manera sistemática la integración de los sistemas tutores inteligentes en la educación matemática, especialmente porque no se limita a estudiar su efectividad, sino que profundiza en la forma en que estas tecnologías son incorporadas pedagógicamente. Esta perspectiva constituye una fortaleza importante, ya que permite comprender que el impacto de los ITS no depende solo de su diseño técnico, sino también del contexto educativo, del rol del docente y del tipo de aprendizaje que se promueve. Además, el uso del modelo SAMR adaptado al campo de la educación matemática ofrece una base metodológica clara para clasificar y comparar estudios previos.

Sin embargo, una primera crítica al artículo es que, aunque identifica que la mayoría de los estudios revisados se sitúan en niveles de aumento más que de transformación, el análisis se mantiene principalmente en un plano descriptivo. Es decir, el autor logra mostrar que los ITS suelen reforzar prácticas tradicionales, pero profundiza menos en propuestas concretas para revertir esa situación en contextos reales de aula. Por ello, el trabajo resulta muy útil para diagnosticar el estado actual del campo, aunque menos sólido cuando se trata de orientar estrategias prácticas de implementación transformadora.

Otra observación importante es que el estudio se centra exclusivamente en artículos empíricos publicados en inglés y en revistas científicas revisadas por pares. Si bien esta decisión fortalece la calidad metodológica de la revisión, también puede dejar fuera investigaciones relevantes desarrolladas en otros idiomas o contextos locales, especialmente en países en desarrollo. Esta limitación es significativa si se considera que el uso de ITS puede variar mucho según las condiciones tecnológicas, económicas y educativas de cada región. En consecuencia, la visión presentada por el artículo, aunque rigurosa, puede no reflejar completamente la diversidad de realidades en las que los sistemas tutores inteligentes son aplicados.

Asimismo, se puede cuestionar que el artículo otorgue un peso central al modelo SAMR como marco de análisis. Aunque este modelo resulta útil para clasificar niveles de integración tecnológica, también puede simplificar una realidad educativa mucho más compleja. En algunos casos, una experiencia de aprendizaje puede no encajar de manera absoluta en una sola categoría, o bien puede combinar elementos de varios niveles al mismo tiempo. Por eso, aunque el modelo organiza muy bien la revisión, existe el riesgo de reducir procesos pedagógicos complejos a una clasificación demasiado lineal.

Finalmente, considero que el artículo deja una reflexión muy importante: la simple presencia de inteligencia artificial en educación no garantiza innovación. Esta conclusión es acertada y útil, pero también muestra una limitación estructural del campo, ya que muchos investigadores todavía parecen enfocarse más en desarrollar sistemas o medir resultados que en transformar realmente la enseñanza matemática. En ese sentido, el artículo es fuerte como revisión crítica, pero al mismo tiempo evidencia que todavía faltan estudios que articulen mejor tecnología, pedagogía y realidad escolar.

En síntesis, el artículo es sólido, académico y metodológicamente bien construido, pero presenta limitaciones en cuanto a la amplitud contextual de los estudios revisados, la dependencia de un solo marco de clasificación y la falta de propuestas más concretas para una implementación

transformadora. Aun así, constituye una base importante para futuras investigaciones sobre sistemas tutores inteligentes en educación matemática.

19. ARTICULO 19

Author (s): Vaarma, M.; Li, H.

Title of paper: Predicción del abandono escolar mediante aprendizaje automático: un estudio empírico en la educación superior finlandesa.

Journal: Technology in Society

Volume (issue): 76

pag – pag (year): 102474 (2024)

Estado del arte que hace el autor

El autor sitúa su investigación dentro del campo de la **predicción de la deserción estudiantil en educación superior**, un problema que ha sido ampliamente estudiado debido a su impacto negativo tanto en los estudiantes como en las instituciones y la sociedad. Según el artículo, el interés por la permanencia estudiantil no es reciente, ya que existe investigación sobre este tema desde la década de 1970; sin embargo, los avances en la reducción efectiva de la deserción han sido limitados, lo que mantiene vigente la necesidad de nuevas aproximaciones analíticas y predictivas.

Dentro de este marco, el autor explica que en las últimas dos décadas la digitalización de la información académica ha abierto nuevas oportunidades para identificar estudiantes en riesgo mediante técnicas de **machine learning**. En este contexto, numerosos estudios previos han utilizado datos institucionales, especialmente **historial académico, datos demográficos, antecedentes escolares, variables financieras y registros de comportamiento**, para predecir qué estudiantes podrían abandonar sus estudios. Esos trabajos se han orientado principalmente a construir modelos predictivos y a detectar cuáles variables tienen mayor peso en la deserción. Entre los factores más señalados por la literatura previa aparecen los **créditos acumulados**, el **promedio académico (GPA)**, el **número de cursos desaprobados**, la **edad de ingreso**, la **participación académica** y algunas variables socioeconómicas o familiares.

El estado del arte también muestra que la literatura previa puede dividirse, según el autor, en **tres grandes líneas de investigación**. La primera se centra en la predicción de abandono a nivel de curso; la segunda, en la predicción dentro de un programa académico específico; y la tercera, en la predicción de abandono a nivel institucional o entre múltiples programas universitarios. El estudio se ubica en esta tercera línea, que resulta más compleja porque busca comprender la permanencia estudiantil a una escala más amplia y con trayectorias académicas más diversas.

Asimismo, el autor señala que una parte importante de la investigación reciente ha incorporado datos provenientes de los **Learning Management Systems (LMS)**, como Moodle. Estos entornos generan grandes volúmenes de información sobre la actividad digital del estudiante, por ejemplo, ingresos al sistema, apertura de enlaces, envío de tareas, comentarios o participación en actividades. La literatura ha demostrado que estos datos son útiles para analizar el rendimiento académico y para predecir la deserción, sobre todo en cursos virtuales, e-learning y MOOCs. Sin embargo, el autor subraya que la mayoría de esos estudios se han enfocado en la deserción **a nivel de curso**, no en la deserción **a nivel de programa o universidad**.

Precisamente ahí aparece uno de los vacíos más importantes del estado del arte. Aunque existen algunos trabajos que han vinculado datos LMS con la predicción de abandono en programas de educación superior, estos son todavía escasos. Además, esos estudios no han comparado de manera clara la **importancia relativa** de los datos del LMS frente a los datos académicos tradicionales y los datos demográficos. Incluso el único trabajo previo que combinó datos demográficos, transcript y LMS no realizó un análisis específico de importancia de variables, por lo que seguía existiendo una limitación importante en la comprensión de qué tipo de dato aporta más a la predicción.

Otro aspecto clave del estado del arte es la **dimensión temporal** del problema. El autor indica que la mayor parte de las investigaciones anteriores ha construido sus modelos usando datos recogidos **al final del semestre**, lo que restringe la posibilidad de intervención temprana. Si la predicción solo se hace al cierre del periodo académico, muchas veces el estudiante ya está muy cerca de desertar o incluso ya abandonó. Por ello, la literatura previa ha prestado poca atención al análisis de cómo cambian los factores predictivos **durante** el semestre o a mitad del proceso académico. Aunque algunos estudios han considerado varios semestres o puntos temporales, casi no existen trabajos que examinen mensualmente la evolución de los factores predictivos, y menos aún integrando datos del LMS.

El autor también revisa estudios específicos sobre desempeño de modelos predictivos, mostrando que la literatura ha empleado diversas técnicas, como **regresión logística, random forest, support vector machine, redes neuronales, gradient boosting y CatBoost**, con métricas de desempeño como **AUC, precisión, recall y f1-score**. Los resultados reportados en estudios anteriores muestran rendimientos variables, pero en general evidencian que el machine learning puede ser útil para identificar estudiantes en riesgo. Aun así, el estado del arte deja claro que la discusión no debe centrarse únicamente en cuál algoritmo funciona mejor, sino también en qué variables aportan realmente a la predicción y en qué momento del proceso académico lo hacen.

Finalmente, el autor contextualiza esta revisión en el caso de **Finlandia**, donde la deserción estudiantil también representa un problema importante. Allí ya se han realizado investigaciones sobre abandono universitario desde perspectivas como las causas de la deserción, el burnout estudiantil, la tutoría académica y algunos modelos predictivos. No obstante, incluso en el contexto finlandés, seguía faltando un estudio que integrara de manera sistemática datos demográficos, académicos y de LMS para analizar la deserción en educación superior con una perspectiva longitudinal más detallada.

En síntesis, el estado del arte que presenta el autor muestra que existe una base sólida de investigaciones sobre predicción de deserción con machine learning, especialmente usando datos académicos y demográficos, y que los LMS han ganado relevancia en estudios recientes. Sin embargo, también evidencia vacíos importantes: la escasa comparación entre tipos de datos, la poca atención a la importancia relativa de las variables, y la limitada exploración temporal dentro del semestre. Es justamente sobre esos vacíos donde el autor construye la justificación de su estudio.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal del autor surge de la necesidad de profundizar en la comprensión de la **deserción estudiantil en educación superior** mediante técnicas de **machine learning**, especialmente en un contexto donde el problema sigue siendo persistente pese a décadas de investigación. El autor parte de una crítica general a la literatura previa: aunque se han desarrollado numerosos estudios para predecir la deserción utilizando datos académicos y demográficos, todavía existen vacíos importantes en cuanto al tipo de datos empleados, la comparación entre ellos y el momento en que se realiza la predicción.

Una de las críticas más claras del autor es que los estudios anteriores han utilizado de forma amplia los **datos transcript y demográficos**, pero han prestado mucha menos atención a los datos generados por los **Learning Management Systems (LMS)** cuando la predicción se realiza a nivel de programa o institución. Según el autor, los LMS contienen información valiosa sobre el comportamiento académico digital del estudiante, pero la mayoría de investigaciones que los han aprovechado se han centrado en la deserción **a nivel de curso**, especialmente en entornos virtuales, MOOCs o e-learning. Por ello, existe una limitación en la literatura al no integrar suficientemente este tipo de datos en la predicción de abandono en trayectorias universitarias más amplias.

Asimismo, el autor critica que incluso los pocos estudios que sí han incorporado datos LMS en la predicción de abandono a nivel de programa **no han comparado de manera explícita la importancia relativa** de esos datos frente a los datos académicos tradicionales y los demográficos. Es decir, aunque algunos trabajos demostraron que los LMS pueden servir para identificar estudiantes en riesgo, no respondieron con claridad qué tipo de información resulta más influyente en la predicción. Esta ausencia de comparación impide conocer con mayor precisión qué variables deben priorizarse al diseñar sistemas de alerta temprana o estrategias institucionales de retención.

Otra crítica importante del autor está relacionada con la **dimensión temporal** de los estudios previos. Señala que la mayoría de las investigaciones ha construido sus modelos predictivos con datos recogidos al **final del semestre**, lo que limita el valor práctico de las predicciones. Desde la perspectiva del autor, este enfoque reduce la capacidad de intervención temprana, ya que cuando el riesgo se detecta muy tarde, muchas veces el estudiante ya ha abandonado o está muy cerca de hacerlo. En ese sentido, el autor cuestiona que la literatura previa no haya explorado suficientemente cómo varía la importancia de las variables y el rendimiento de los modelos **a lo largo del tiempo**, especialmente dentro del semestre y no solo al cierre de este.

Además, el autor observa que los trabajos previos se han enfocado sobre todo en el **desempeño predictivo de los algoritmos**, comparando métricas como precisión, recall, AUC o f1-score, pero sin profundizar tanto en el comportamiento cambiante de los factores predictivos. Para el autor, no basta con saber qué modelo clasifica mejor, sino que también es necesario entender **por qué** lo hace, qué variables explican ese resultado y cómo su relevancia cambia con el tiempo. Esta crítica es importante porque desplaza la atención desde la pura competencia entre algoritmos hacia una comprensión más interpretativa y aplicada del problema.

En conjunto, la motivación del autor se basa en una lectura crítica de la literatura existente: reconoce que el machine learning ya ha demostrado utilidad para predecir la deserción, pero sostiene que todavía faltan estudios que integren de forma comparativa **datos demográficos, académicos y de LMS**, que examinen la **importancia relativa de las variables** y que analicen la predicción desde una perspectiva **longitudinal y mensual**. Por ello, su investigación busca cubrir esos vacíos y ofrecer una comprensión más profunda y útil para la intervención institucional en educación superior.

Descripción del aporte del autor

El aporte principal del autor consiste en proponer un estudio empírico sobre la **predicción de la deserción estudiantil en educación superior mediante machine learning**, integrando tres tipos de datos que no siempre habían sido analizados conjuntamente con suficiente profundidad: **datos demográficos, datos académicos (transcript) y datos provenientes del LMS Moodle**. A partir de ello, el trabajo no solo busca construir modelos predictivos, sino también comprender qué variables tienen mayor peso en la identificación de estudiantes en riesgo y cómo esa importancia cambia a lo largo del tiempo.

Uno de los aportes más relevantes del estudio es la **comparación de la importancia relativa de los datos del LMS frente a los datos académicos y demográficos** en la predicción de deserción a nivel de programa universitario. La literatura previa ya había demostrado que los datos transcript y demográficos eran útiles para este tipo de predicción, y que los datos de plataformas virtuales servían para detectar abandono a nivel de curso. Sin embargo, faltaba una investigación que analizara, en un mismo modelo, cuánto aportaban realmente los datos de actividad digital frente a las fuentes tradicionales de información académica. En ese sentido, el autor contribuye al demostrar que la información registrada en Moodle también posee un valor predictivo importante y no debe ser ignorada en los sistemas de alerta temprana institucionales.

Otro aporte central del estudio es su **enfoque longitudinal**. A diferencia de muchos trabajos previos, que realizaban la predicción al final del semestre, el autor analiza la deserción **mensualmente como función del tiempo desde el ingreso del estudiante**. Esto representa una contribución importante, porque permite observar no solo si un estudiante está en riesgo, sino también **cuándo** ese riesgo puede ser detectado con mayor precisión. De esta manera, el estudio amplía la perspectiva tradicional centrada en cortes semestrales y muestra que tanto la capacidad predictiva de los modelos como la relevancia de ciertas variables cambian durante la trayectoria académica. Esta dimensión temporal convierte el trabajo en un aporte metodológico significativo para investigaciones futuras sobre permanencia estudiantil.

Asimismo, el autor aporta una **comparación empírica entre tres modelos de machine learning** —CatBoost, redes neuronales y regresión logística— aplicados a datos de **8,813 estudiantes** de una universidad finlandesa. Esta comparación no se limita a identificar cuál modelo funciona mejor en términos generales, sino que examina su rendimiento mensualmente mediante métricas como **precisión, recall, f1-score, AUC y average precision**. Gracias a este análisis, el estudio ofrece una visión más detallada del comportamiento de los modelos en diferentes momentos del proceso académico y permite identificar cuál de ellos resulta más sólido para la predicción de abandono.

Además, un aporte particularmente valioso del trabajo es el análisis de **importancia de variables mediante el método de permutation importance**. A través de esta técnica, el autor identifica que las variables más influyentes en la predicción de deserción son los **créditos acumulados**, el **número de cursos desaprobados** y el **conteo de actividad en Moodle**. Este hallazgo tiene gran valor práctico, porque ayuda a comprender qué indicadores deberían ser monitoreados con mayor atención por las universidades si desean prevenir el abandono. El estudio no se queda en la construcción de modelos predictivos, sino que avanza hacia la interpretación de los factores que explican el fenómeno.

El artículo también aporta evidencia de que la **actividad digital del estudiante en el LMS** puede complementar de manera significativa la información académica tradicional. El hecho de que el **Moodle activity count** aparezca entre las tres variables más importantes confirma que el comportamiento del estudiante dentro del entorno virtual refleja señales tempranas de compromiso o desvinculación. Este resultado fortalece la idea de que los datos educativos digitales no deben verse solo como registros operativos, sino como fuentes estratégicas para la gestión institucional y la retención estudiantil.

Finalmente, el autor también realiza un aporte práctico al mostrar que los modelos de machine learning pueden ser utilizados por las instituciones de educación superior para **intervenir antes de que ocurra la deserción**, especialmente entre los meses 10 y 53 desde el ingreso. Esto es especialmente relevante en el contexto finlandés analizado, donde muchas deserciones ocurren al cierre del semestre y una predicción anticipada puede marcar la diferencia entre perder al estudiante o retenerlo. En consecuencia, el estudio no solo tiene valor teórico y metodológico, sino también una aplicación concreta para la toma de decisiones universitarias.

En síntesis, el aporte del autor radica en haber desarrollado una investigación que combina **comparación de fuentes de datos, análisis longitudinal, evaluación de modelos predictivos e interpretación de variables clave** para comprender mejor la deserción estudiantil. Gracias a ello, el artículo amplía el conocimiento existente sobre machine learning en educación superior y ofrece bases más sólidas para diseñar estrategias institucionales de prevención del abandono.

Proceso para obtener el aporte que considera el autor

El autor desarrolla su aporte a través de un proceso metodológico estructurado que combina la recolección de datos, el preprocesamiento, la aplicación de modelos de machine learning y el análisis de resultados en una perspectiva longitudinal. Este proceso se orienta a comprender no solo la capacidad predictiva de los modelos, sino también la importancia relativa de diferentes tipos de datos en la predicción de la deserción estudiantil.

En una primera etapa, el autor realiza la **recolección e integración de datos** provenientes de una universidad finlandesa. Para ello, reúne información de **8,813 estudiantes**, incluyendo tres tipos principales de variables: datos demográficos (como edad, género o programa académico), datos académicos o transcript (créditos acumulados, promedio, cursos desaprobados) y datos de actividad en el sistema LMS Moodle (como el número de interacciones del estudiante en la plataforma). Esta integración de fuentes permite construir una base de datos completa que refleja tanto el desempeño académico como el comportamiento digital del estudiante.

En la siguiente fase, se lleva a cabo el **preprocesamiento de los datos**, donde se organizan y transforman las variables para su análisis. El autor convierte la información en una estructura temporal, generando registros mensuales para cada estudiante desde su ingreso hasta un máximo de 60 meses. Además, se normalizan algunas variables (por ejemplo, créditos acumulados o cursos desaprobados en función del tiempo) y se transforman variables categóricas mediante técnicas como **one-hot encoding**. También se eliminan registros incompletos para asegurar la calidad de los datos y evitar sesgos en el entrenamiento de los modelos.

Posteriormente, el autor desarrolla la etapa de **modelado predictivo**, donde aplica diferentes algoritmos de machine learning. En total, se evalúan diez modelos, entre ellos regresión logística, random forest, support vector machine, redes neuronales, CatBoost y otros. Estos modelos son entrenados utilizando subconjuntos de datos organizados por mes, lo que permite analizar cómo evoluciona la capacidad predictiva a lo largo del tiempo. Finalmente, se seleccionan los tres modelos con mejor desempeño (CatBoost, redes neuronales y regresión logística) para un análisis más detallado.

En una etapa posterior, el autor evalúa el rendimiento de los modelos utilizando métricas como **precisión, recall, f1-score y AUC**, enfocándose principalmente en la capacidad de identificar correctamente a los estudiantes en riesgo de deserción. Este análisis se realiza de forma longitudinal, es decir, evaluando el desempeño de los modelos en distintos momentos del tiempo académico, lo que permite identificar en qué etapas la predicción es más precisa y útil para la intervención.

Finalmente, el autor realiza un **análisis de importancia de variables** mediante el método de *permutation importance*, que consiste en medir cómo disminuye el rendimiento del modelo al alterar aleatoriamente los valores de una variable. A través de este procedimiento, se identifican los factores más relevantes en la predicción de deserción, destacando los créditos acumulados, el número de cursos desaprobados y la actividad en Moodle. Este análisis permite no solo validar el modelo, sino también interpretar los resultados desde una perspectiva educativa.

En conjunto, el proceso seguido por el autor combina un enfoque técnico y analítico con una perspectiva aplicada, permitiendo construir un aporte sólido que integra múltiples fuentes de datos, evalúa modelos de machine learning y aporta evidencia sobre los factores clave en la deserción estudiantil en educación superior.

Proceso para resolver el problema considerado por el autor

El autor aborda el problema de la deserción estudiantil en educación superior mediante un enfoque basado en **machine learning y análisis de datos educativos**, cuyo objetivo es identificar de manera temprana a los estudiantes en riesgo y comprender los factores que influyen en su abandono. El proceso de solución parte del reconocimiento de que la deserción no puede ser explicada únicamente por variables aisladas, sino que requiere integrar múltiples fuentes de información y analizarlas de forma dinámica en el tiempo.

En primer lugar, el autor plantea como estrategia central la **integración de datos heterogéneos**, combinando información demográfica, académica y de comportamiento digital (LMS). Esta integración permite construir una visión más completa del estudiante, superando los enfoques tradicionales que solo consideraban el rendimiento académico. A partir de esta base, el sistema busca detectar patrones que indiquen riesgo de abandono, aprovechando tanto el historial académico como la actividad en plataformas virtuales.

En una segunda etapa, el problema se aborda mediante la **modelación predictiva**, donde se entrenan diferentes algoritmos de machine learning para clasificar a los estudiantes según su probabilidad de deserción. Estos modelos aprenden a partir de datos históricos, identificando relaciones entre variables y resultados (abandono o permanencia). Lo innovador en este proceso es que la predicción no se realiza en un único momento, sino de forma **mensual**, permitiendo observar cómo evoluciona el riesgo de deserción a lo largo del tiempo académico.

Posteriormente, el sistema incorpora un **análisis longitudinal**, que constituye un elemento clave en la resolución del problema. A través de este enfoque, el autor evalúa cómo cambia la importancia de las variables y el desempeño de los modelos en distintos momentos desde el ingreso del estudiante. Esto permite identificar no solo quién está en riesgo, sino también **cuándo es más probable detectar ese riesgo**, lo cual es fundamental para implementar intervenciones oportunas dentro del semestre y no únicamente al final del mismo.

Otro componente importante del proceso es el **análisis de importancia de variables**, mediante el cual se determinan los factores que más influyen en la predicción de la deserción. Este análisis revela que variables como los créditos acumulados, los cursos desaprobados y la actividad en Moodle tienen un impacto significativo. De esta manera, el autor no solo construye un modelo predictivo, sino que también aporta una interpretación clara de los elementos que explican el fenómeno, facilitando su aplicación en la toma de decisiones institucionales.

Finalmente, el proceso de solución se orienta hacia la **aplicación práctica de los resultados**, destacando que los modelos pueden ser utilizados por las universidades para implementar estrategias de retención. Al identificar estudiantes en riesgo en etapas intermedias del proceso académico, las instituciones pueden intervenir con acciones como tutorías, seguimiento personalizado o apoyo académico, aumentando así la probabilidad de permanencia.

En conjunto, el autor propone un proceso de solución integral que combina integración de datos, modelado predictivo, análisis temporal e interpretación de variables, logrando no solo predecir la deserción, sino también ofrecer herramientas concretas para su prevención en el contexto de la educación superior.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

Para evaluar su propuesta, el autor utiliza varias **métricas de desempeño de modelos de clasificación**, principalmente **AUC**, **average precision (AP)**, **precisión**, **recall** y **f1-score**. Estas métricas le permiten medir qué tan bien los modelos identifican a los estudiantes en riesgo de deserción. El autor justifica especialmente el uso de precisión y recall porque el interés

principal no está en predecir a los estudiantes que se gradúan, sino en detectar correctamente a quienes podrían abandonar sus estudios. Además, como el conjunto de datos está desbalanceado —con mayor proporción de graduados que de desertores—, estas métricas resultan más adecuadas que una simple exactitud global.

A partir de la comparación de diez algoritmos, el autor encuentra que los tres modelos con mejor rendimiento promedio fueron **CatBoost (CAT)**, **redes neuronales (NN)** y **regresión logística (LR)**. Entre ellos, el mejor resultado general lo obtiene **CatBoost**, con un **AUC promedio de 0.853**, **AP de 0.721**, **f1-score de 59%**, **precisión de 81%** y **recall de 47%**. Las redes neuronales alcanzan un **AUC de 0.844** y la regresión logística un **AUC de 0.842**, lo que muestra que los tres modelos tuvieron desempeños relativamente cercanos, aunque CatBoost resultó ligeramente superior. Además, el autor observa que el rendimiento predictivo mejora con el paso del tiempo, siendo más bajo en los primeros meses y aumentando conforme los estudiantes acumulan más información académica y de actividad digital.

En cuanto a las variables más influyentes, el análisis mediante **permutation importance** muestra que los factores más importantes fueron los **créditos acumulados**, el **número de cursos desaprobados** y el **conteo de actividad en Moodle**. En el caso de CatBoost, por ejemplo, los créditos acumulados alcanzan una importancia promedio de **24.0**, el número de cursos desaprobados **9.4** y la actividad en Moodle **4.5**. Estos resultados indican que el desempeño académico sigue siendo el predictor más fuerte, pero también confirman que la actividad en el LMS aporta valor predictivo significativo.

Respecto a la comparación con otros estudios, los resultados del autor pueden considerarse **competitivos y en algunos aspectos superiores**, aunque no siempre de forma absoluta. Por ejemplo, el artículo señala que investigaciones previas reportaron desempeños variables: algunos trabajos lograron **f1-scores entre 58% y 66%**, otros **AUC entre 0.65 y 0.79**, y otros alcanzaron **AUC de 0.774** o **precisiones entre 72% y 83%**, dependiendo del tipo de datos y del modelo usado. Frente a ello, el AUC de **0.853** obtenido por CatBoost muestra un rendimiento alto y sólido. Sin embargo, también existen estudios con resultados más elevados en contextos particulares, como trabajos que reportan **AUC entre 0.871 y 0.961** o precisiones muy altas cuando se usan otros tipos de datos o escenarios distintos. Por eso, más que afirmar que supera a todos los anteriores, puede decirse que este estudio ofrece resultados **robustos, competitivos y especialmente valiosos por integrar datos demográficos, transcript y LMS en un análisis longitudinal**, algo que muchos trabajos previos no habían desarrollado con este nivel de detalle.

En síntesis, el autor emplea métricas adecuadas para el problema de clasificación, obtiene sus mejores resultados con CatBoost y demuestra que la combinación de datos académicos y de actividad digital permite una predicción confiable de la deserción. Sus resultados no son los más altos de toda la literatura en términos absolutos, pero sí destacan por su consistencia, por la riqueza de variables analizadas y por el valor práctico que ofrecen para la intervención temprana en educación superior.

Observaciones y/o críticas suyas al artículo

El artículo presenta un aporte importante al campo de la educación superior, ya que aborda el problema de la deserción estudiantil desde una perspectiva analítica y actual, integrando datos demográficos, académicos y de actividad en Moodle. Una de sus principales fortalezas es que no se limita a construir modelos predictivos, sino que también analiza la importancia de las variables y su comportamiento a lo largo del tiempo. Esto le da mayor profundidad al estudio y lo vuelve útil no solo para fines estadísticos, sino también para la toma de decisiones institucionales. Además, el enfoque longitudinal mensual constituye una contribución valiosa, porque permite identificar momentos más adecuados para intervenir antes de que ocurra el abandono.

Sin embargo, una primera crítica al artículo es que, aunque incorpora datos del LMS, el propio estudio reconoce que solo utiliza **dos variables de Moodle**: el conteo de actividad y la tendencia de esa actividad. Esto puede considerarse una limitación importante, porque los entornos virtuales generan información mucho más rica, como tiempos de permanencia, tipos de recursos consultados, frecuencia de participación en tareas o patrones de interacción más específicos. Por ello, aunque el artículo demuestra que Moodle tiene valor predictivo, posiblemente no aprovecha todo el potencial explicativo que ofrecen los datos digitales.

Otra observación crítica es que el estudio se basa en datos de **una sola institución finlandesa**, lo que reduce la posibilidad de generalizar los resultados a otros contextos educativos. Las características del sistema de educación superior en Finlandia, como la gratuidad universitaria y su modelo de financiamiento basado en graduaciones, son muy particulares y no necesariamente se replican en otros países. En consecuencia, aunque los hallazgos son sólidos dentro del caso analizado, su aplicabilidad a contextos latinoamericanos o a sistemas con otras condiciones socioeconómicas y académicas debe tomarse con cautela.

También considero que el artículo se apoya fuertemente en indicadores cuantitativos y predictivos, pero deja en segundo plano factores más humanos y contextuales que influyen en la deserción, como problemas emocionales, motivacionales, familiares o económicos. El propio autor menciona que futuras investigaciones podrían incluir datos provenientes de encuestas u otras fuentes. Esto evidencia que, aunque el modelo es útil para detectar riesgo, no logra explicar de manera integral todas las razones del abandono estudiantil. En otras palabras, el artículo predice bien, pero todavía no comprende completamente el fenómeno en toda su complejidad.

Además, aunque compara varios algoritmos, el estudio opta por no realizar optimización de hiperparámetros, argumentando simplicidad y repetibilidad metodológica. Esta decisión es comprensible, pero también puede verse como una limitación, ya que algunos modelos pudieron haber mostrado un mejor desempeño con ajustes más finos. Por ello, los resultados obtenidos son útiles para comparar de forma general, aunque no necesariamente representan el máximo rendimiento posible de cada técnica.

En síntesis, el artículo es metodológicamente sólido, actual y relevante, especialmente por su integración de datos y su análisis temporal. No obstante, presenta limitaciones relacionadas con la reducción del uso de variables LMS, la baja generalización de resultados por tratarse de un solo contexto institucional y la ausencia de factores cualitativos más profundos. Aun así, constituye una base muy valiosa para futuras investigaciones sobre deserción estudiantil y machine learning en educación superior.

20. ARTICULO 20

Author (s): McIntyre, N. A.

Title of paper: Acceso al aprendizaje en línea: análisis del aprendizaje automático desde una perspectiva de justicia social.

Journal: Education and Information Technologies

Volume (issue): 28

pag – pag (year): 3787–3832 (2023)

Estado del arte que hace el autor

El autor sitúa su investigación dentro del campo del **aprendizaje en línea como vía de acceso educativo**, un tema que durante años ha sido presentado como una alternativa capaz de ampliar oportunidades para poblaciones tradicionalmente desatendidas. Desde esta perspectiva, la educación en línea ha sido valorada por su flexibilidad, por su capacidad para complementar una oferta escolar insuficiente y por su potencial para llegar a estudiantes que viven en zonas remotas, presentan contextos familiares complejos o no pueden acceder fácilmente a apoyos presenciales adicionales. Incluso se ha señalado que, cuando se diseña de manera inclusiva, el aprendizaje en línea puede ser tan eficaz como la educación presencial, o incluso superior en ciertos casos.

Sin embargo, el estado del arte que presenta la autora muestra que ese optimismo convive con una realidad mucho más desigual. El acceso al aprendizaje en línea no depende solo de que exista una plataforma educativa, sino también de condiciones materiales, sociales y culturales que muchas veces no están garantizadas. En ese sentido, la literatura previa destaca que los estudiantes necesitan niveles altos de **autonomía, autorregulación y motivación** para sostener su participación en entornos digitales. Además, la presencia interpersonal —tan importante en el aprendizaje presencial— adopta formas más complejas en línea, especialmente en lo referente al rol del docente y la interacción con pares. Esto significa que el simple traslado de contenidos a un entorno digital no asegura por sí mismo un acceso educativo efectivo.

Uno de los ejes más importantes del estado del arte es la existencia de **desigualdades entre países**, especialmente entre países de ingresos altos y países de ingresos bajos y medianos. La autora explica que en estos últimos el acceso a internet, la velocidad de conexión, la disponibilidad de electricidad y la calidad de la infraestructura tecnológica son mucho más limitados. Esta situación afecta gravemente la posibilidad real de participar en el aprendizaje en línea. A ello se suma que en muchos contextos el hogar presenta aún más restricciones que la escuela, lo que vuelve especialmente problemática la promesa de que la educación digital puede compensar carencias del sistema escolar. Por tanto, el estado del arte no presenta el aprendizaje en línea como un recurso universalmente accesible, sino como un espacio donde se reproducen e incluso se intensifican las brechas estructurales.

Junto con las barreras de infraestructura, la autora incorpora en el estado del arte las **barreras de alfabetización**, particularmente la alfabetización en inglés y la alfabetización digital. Muchos contenidos de aprendizaje en línea están disponibles principalmente en inglés, por lo que el dominio de este idioma se convierte en un factor clave de acceso. Asimismo, la alfabetización digital no solo implica poder ingresar a una plataforma, sino también saber navegar en ella, comprender sus recursos y utilizarlos con eficacia para aprender. La literatura revisada muestra que estas capacidades también están distribuidas de manera desigual, lo que limita la participación efectiva de muchos estudiantes, sobre todo en contextos menos favorecidos.

Otro componente central del estado del arte es la **desigualdad de género**. La autora recoge evidencia que muestra que, en muchos países de ingresos bajos y medianos, las niñas enfrentan más obstáculos que los niños para acceder al aprendizaje, tanto presencial como virtual. Entre

esos obstáculos aparecen las responsabilidades domésticas, el cuidado familiar, normas socioculturales que desalientan su desarrollo académico y condiciones biológicas asociadas a la denominada “pobreza menstrual”. La revisión también indica que las niñas utilizan internet con menor frecuencia que los niños y desarrollan competencias digitales de forma menos completa, lo que afecta directamente su posibilidad de sostener procesos de aprendizaje en línea. De este modo, el estado del arte deja claro que las desigualdades de acceso digital no son neutrales, sino que también están atravesadas por el género.

El análisis del estado del arte también incorpora el impacto de la **pandemia de COVID-19**, la cual intensificó las desigualdades ya existentes. Durante el cierre de escuelas, el aprendizaje en línea fue visto como una solución para mantener la continuidad educativa. No obstante, la literatura revisada por la autora muestra que la pandemia amplió las brechas entre estudiantes con recursos y aquellos sin recursos, entre países con alta conectividad y otros con mayores carencias, y entre niños y niñas. En muchos casos, los hogares más pobres no pudieron compensar la pérdida de recursos escolares, mientras que las responsabilidades domésticas de las niñas aumentaron. Así, el contexto pandémico se convirtió en un elemento fundamental para comprender el acceso al aprendizaje en línea desde una perspectiva de justicia social.

En cuanto a la investigación previa, la autora señala que el acceso al aprendizaje en línea ha sido estudiado principalmente de dos maneras. Por un lado, mediante **estudios pequeños o cualitativos**, centrados en experiencias reportadas por actores educativos o en pruebas de capacidad específica. Por otro lado, mediante **análisis econométricos a gran escala** y revisiones de literatura. Sin embargo, el estado del arte identifica una limitación importante: hasta ahora, la investigación casi no había explotado los propios **datos generados por las plataformas de aprendizaje en línea** para comprender qué factores predicen el acceso. Es decir, existían estudios sobre resultados de aprendizaje o sobre acceso desde otras fuentes, pero no análisis suficientemente desarrollados que utilizaran minería de datos y machine learning sobre registros masivos de plataformas educativas para estudiar el acceso mismo como variable central.

Además, la autora observa que los pocos análisis con machine learning aplicados al aprendizaje en línea se han concentrado mayormente en **poblaciones acomodadas** y en **resultados de aprendizaje**, no en variables relacionadas con la equidad. De hecho, investigaciones anteriores habían mostrado que la experiencia acumulada era uno de los factores más importantes para explicar los resultados en línea, pero no se había indagado suficientemente qué explicaba esa experiencia acumulada, es decir, qué factores permiten o limitan el acceso continuo a la plataforma. Esta observación abre precisamente el vacío investigativo que la autora busca atender.

Finalmente, el estado del arte incorpora una reflexión metodológica sobre el valor del **machine learning para analizar grandes volúmenes de datos educativos**. La autora sostiene que el crecimiento del aprendizaje en línea ha generado bases de datos tan complejas que las técnicas estadísticas tradicionales resultan insuficientes para captar toda su multidimensionalidad. Por ello, plantea que el machine learning, combinado con un enfoque de “human-in-the-loop” y modelos interpretables como los valores de Shapley, ofrece una vía adecuada para estudiar fenómenos complejos como el acceso al aprendizaje en línea. En este punto, el estado del arte no solo revisa hallazgos sustantivos sobre desigualdad y acceso, sino que también justifica el uso de enfoques analíticos más avanzados para comprenderlos.

En síntesis, el estado del arte presentado por la autora muestra que el aprendizaje en línea ha sido promovido como una herramienta de democratización educativa, pero que en la práctica se encuentra profundamente condicionado por desigualdades de infraestructura, alfabetización, género y contexto socioeconómico, agravadas además por la pandemia. También evidencia que todavía faltaban estudios que usaran datos masivos de plataformas educativas y técnicas de

machine learning para analizar el acceso desde una perspectiva de justicia social. Sobre esa base, la autora justifica su investigación y delimita el aporte específico de su trabajo.

Motivación del autor (críticas del autor a otros trabajos)

La motivación principal de la autora surge de una crítica directa a la visión idealizada del **aprendizaje en línea como mecanismo automático de democratización educativa**. Aunque durante años se ha sostenido que la educación en línea amplía oportunidades para los sectores más vulnerables, la autora señala que esta afirmación no siempre se cumple en la práctica. Por el contrario, en muchos contextos el aprendizaje en línea no reduce desigualdades, sino que las reproduce o incluso las intensifica, especialmente entre países con diferentes niveles de desarrollo, entre hogares con distintos recursos y entre niñas y niños.

Una de las críticas más importantes que formula la autora hacia los estudios previos es que gran parte de la investigación sobre acceso al aprendizaje en línea se ha basado en **estudios pequeños**, centrados en experiencias reportadas por actores educativos, o en **análisis econométricos y revisiones de literatura**, pero no ha aprovechado suficientemente los propios datos generados por las plataformas de aprendizaje. Es decir, aunque ya se sabía que existían desigualdades de acceso, todavía no se había explorado con suficiente profundidad qué factores predecían realmente ese acceso utilizando minería de datos y técnicas de machine learning aplicadas directamente a registros masivos de uso educativo.

Asimismo, la autora critica que las investigaciones previas con machine learning en contextos de aprendizaje en línea se han concentrado, en su mayoría, en **poblaciones más favorecidas** y en el análisis de **resultados de aprendizaje**, en lugar de examinar variables relacionadas con la **equidad y la justicia social**. En otras palabras, muchos estudios previos se preguntaban quién aprende mejor o qué factores explican mejores resultados, pero no se enfocaban en una cuestión más básica y previa: quiénes logran acceder de manera sostenida al entorno en línea. Para la autora, esta limitación es importante porque el acceso es la primera condición para poder beneficiarse del aprendizaje.

Otra crítica central es que el discurso optimista en torno al aprendizaje en línea no ha considerado suficientemente las **barreras estructurales** que afectan a los países de ingresos bajos y medianos. La autora cuestiona que muchas veces se presenta la educación digital como una solución universal, sin reconocer que en esos contextos persisten problemas graves de conectividad, electricidad, alfabetización digital, dominio del inglés y disponibilidad de apoyo familiar. Por ello, critica implícitamente enfoques previos que trataban el acceso como si dependiera solo de la existencia de una plataforma tecnológica y no de condiciones sociales mucho más complejas.

Además, la autora observa que la dimensión de **género** tampoco ha recibido la atención suficiente en muchos análisis previos del acceso en línea. Aunque ya existía evidencia sobre desventajas de las niñas en contextos educativos presenciales y digitales, faltaban estudios que integraran de manera más clara esta variable dentro de modelos analíticos amplios, especialmente en relación con hogares y regiones donde las responsabilidades domésticas y las normas socioculturales afectan más intensamente a las niñas. Desde esta perspectiva, la autora critica la insuficiencia de marcos previos que no abordaban con suficiente profundidad la interacción entre género, pobreza y acceso digital.

La pandemia de **COVID-19** refuerza aún más la motivación de la autora. Ella sostiene que el cierre de escuelas hizo todavía más visibles las limitaciones de los enfoques anteriores, porque mostró que los estudiantes no partían de condiciones iguales para participar en el aprendizaje en línea. Así, critica indirectamente la idea de que bastaba con trasladar la enseñanza al entorno digital para garantizar continuidad educativa. En realidad, la pandemia demostró que los

sectores más pobres y las niñas enfrentaron barreras adicionales, lo que evidenció la necesidad de investigar el acceso desde una perspectiva más crítica y apoyada en datos reales.

En síntesis, la motivación de la autora nace de una crítica a tres vacíos principales en los trabajos anteriores: la falta de análisis basados en datos masivos de plataformas educativas, la escasa atención a la equidad y al acceso como problema central, y la tendencia a presentar el aprendizaje en línea como solución universal sin considerar adecuadamente las desigualdades estructurales de país, género y contexto socioeconómico. Frente a ello, la autora propone un enfoque de machine learning orientado explícitamente por la justicia social, con el fin de comprender mejor qué factores condicionan el acceso al aprendizaje en línea.

Descripción del aporte del autor

El aporte principal de la autora consiste en estudiar el **acceso al aprendizaje en línea** desde una **perspectiva de justicia social**, utilizando herramientas de **machine learning** aplicadas directamente a datos masivos generados por una plataforma educativa. A diferencia de muchos trabajos previos, que se centraban en resultados de aprendizaje o en estudios pequeños sobre experiencias de usuarios, esta investigación pone el foco en una pregunta más básica pero decisiva: **qué factores permiten o limitan que los estudiantes accedan de manera sostenida al aprendizaje en línea**. De esta manera, el artículo desplaza la atención desde el rendimiento hacia el acceso, entendiendo que sin acceso no puede existir un beneficio educativo real.

Uno de los aportes más importantes del estudio es su **uso innovador de datos reales de una plataforma de aprendizaje en línea** a gran escala. La autora analiza información proveniente del sistema *Maths-Whizz Tutor*, con un universo de más de **54 millones de registros** y una submuestra aleatoria utilizada para el modelamiento. Esto representa una contribución metodológica importante, porque permite estudiar el acceso educativo no a partir de percepciones, encuestas o estadísticas generales, sino mediante el comportamiento concreto de los estudiantes dentro del entorno digital. Gracias a ello, el artículo ofrece una visión mucho más empírica y detallada del problema.

Otro aporte central es la incorporación explícita de un **marco teórico orientado por la justicia social** en el desarrollo del modelo analítico. La autora no se limita a aplicar machine learning como una técnica neutral, sino que parte de hipótesis teóricas relacionadas con **las desigualdades entre países, el género y el impacto de la COVID-19**. De este modo, el estudio articula teoría y datos en dos fases: primero, una etapa guiada por hipótesis derivadas del marco conceptual; y después, una etapa de optimización orientada por los propios datos. Esta combinación entre un enfoque **theory-led** y otro **data-led** constituye un aporte relevante, porque muestra cómo el machine learning puede ser usado sin perder de vista preguntas sustantivas sobre equidad y exclusión.

Asimismo, la autora aporta una **identificación empírica de las variables más importantes** para explicar el acceso al aprendizaje en línea. En la fase final del estudio, mediante el uso de **valores de Shapley**, encuentra que variables como **math ability**, **año de nacimiento**, **nivel de dificultad de la sesión**, **mes de nacimiento** y **tiempo empleado para completar la sesión** tienen un peso importante en la predicción del acceso. Al mismo tiempo, confirma la importancia de factores esperados desde la teoría, como el **país**, el **género** y el contexto de **COVID-19**. Este hallazgo es valioso porque no solo valida supuestos previos sobre desigualdad digital, sino que también revela factores adicionales que no habían sido suficientemente considerados en el marco teórico inicial.

Otro aporte significativo es que la investigación demuestra que el **acceso al aprendizaje en línea no depende únicamente de condiciones externas de infraestructura**, sino también de características del propio recorrido del estudiante dentro de la plataforma. Esto es importante porque amplía la comprensión del problema: no basta con saber que existen desigualdades de

país o género, sino que también es necesario considerar cómo la habilidad matemática, la edad, la dificultad del contenido y el patrón de interacción digital influyen en la permanencia dentro del sistema. En ese sentido, el estudio construye una visión más compleja y completa del acceso educativo en línea.

Además, la autora aporta una reflexión metodológica sobre el valor del **machine learning explicable** en educación. En lugar de limitarse a un modelo predictivo opaco, utiliza herramientas interpretables como los **Shapley values** para explicar la importancia de las variables y sus interacciones. Esto constituye una contribución importante porque muestra que las técnicas avanzadas de análisis de datos pueden ser útiles no solo para predecir, sino también para **comprender** fenómenos educativos complejos y orientar decisiones más informadas. De esta manera, el artículo se alinea con enfoques recientes de inteligencia artificial explicable aplicada a la educación.

También es un aporte relevante el hecho de que la investigación se realice comparando **tres contextos nacionales distintos: Kenya, Thailand y el Reino Unido**, incluyendo así países de ingresos bajos y medianos junto con un país de ingresos altos. Esta comparación permite analizar el acceso al aprendizaje en línea desde una perspectiva internacional y desigual, evidenciando que la experiencia digital no puede entenderse de manera homogénea. En otras palabras, el estudio contribuye a desmontar la idea de que el aprendizaje en línea funciona igual para todos los estudiantes, mostrando que el contexto nacional sigue siendo un determinante fuerte del acceso.

Finalmente, el aporte de la autora no es solo teórico o metodológico, sino también práctico. Al identificar qué factores tienen mayor importancia en el acceso al aprendizaje en línea, el estudio ofrece insumos útiles para diseñadores de plataformas, responsables educativos y tomadores de decisiones interesados en reducir brechas digitales y ampliar oportunidades educativas. Así, el artículo no solo explica un problema, sino que también proporciona evidencia que puede orientar intervenciones más justas y contextualizadas.

En síntesis, el aporte del autor radica en haber combinado **big data educativo, machine learning explicable y una perspectiva de justicia social** para estudiar el acceso al aprendizaje en línea. Gracias a ello, el trabajo supera enfoques más limitados centrados solo en rendimiento o en estudios pequeños, y ofrece una comprensión más profunda de las desigualdades que condicionan el acceso educativo digital.

Proceso para obtener el aporte que considera el autor

La autora desarrolla su aporte mediante un proceso metodológico estructurado que combina el uso de **datos masivos provenientes de una plataforma de aprendizaje en línea**, técnicas de **machine learning** y un enfoque guiado por la teoría de la **justicia social**. Este proceso no se limita a la construcción de un modelo predictivo, sino que integra distintas etapas orientadas a comprender de manera profunda los factores que influyen en el acceso al aprendizaje en línea.

En una primera etapa, la autora realiza la **recolección y selección de datos** a partir de la plataforma *Maths-Whizz Tutor*, la cual genera grandes volúmenes de información sobre la interacción de los estudiantes con el sistema. De este conjunto inicial, que supera los **54 millones de registros**, se selecciona una muestra representativa que permite trabajar de manera eficiente sin perder la riqueza del comportamiento observado. Estos datos incluyen variables relacionadas con el estudiante (como edad, género y país), así como información sobre su actividad dentro de la plataforma (tiempo de uso, dificultad de las sesiones, desempeño, entre otros).

Posteriormente, se lleva a cabo el **preprocesamiento de los datos**, que consiste en organizar, limpiar y transformar la información para su análisis. En esta fase se eliminan valores

inconsistentes o incompletos y se estructuran las variables de forma que puedan ser utilizadas por los modelos de machine learning. Además, se definen las variables dependientes e independientes, estableciendo como variable principal el acceso al aprendizaje en línea, entendido como la participación efectiva del estudiante en la plataforma.

En una tercera etapa, la autora desarrolla el proceso de **modelado mediante machine learning**, aplicando algoritmos capaces de analizar relaciones complejas entre múltiples variables. Este modelado se realiza en dos fases complementarias. La primera es una fase **guiada por la teoría (theory-led)**, en la que se incorporan variables clave derivadas del marco conceptual, como país, género y contexto de COVID-19. La segunda es una fase **guiada por los datos (data-led)**, en la que el modelo identifica patrones adicionales no previstos inicialmente, optimizando su capacidad predictiva a partir de la información disponible. Esta combinación permite integrar conocimiento teórico con descubrimiento empírico.

A continuación, la autora realiza un proceso de **evaluación e interpretación del modelo**, utilizando técnicas de machine learning explicable, como los **valores de Shapley**. Estas herramientas permiten identificar la importancia de cada variable en la predicción del acceso, así como analizar la forma en que interactúan entre sí. Gracias a este enfoque, el estudio no se limita a predecir el acceso, sino que también explica qué factores lo determinan, lo cual es fundamental para su aplicación en el ámbito educativo.

Finalmente, el proceso se completa con la **interpretación de resultados desde una perspectiva de justicia social**, donde la autora analiza cómo las variables identificadas reflejan desigualdades estructurales entre países, entre géneros y en el contexto de la pandemia. Este paso es clave, ya que conecta los hallazgos técnicos con su significado educativo y social, permitiendo que los resultados del modelo sean útiles para la toma de decisiones orientadas a reducir brechas de acceso.

En conjunto, el proceso seguido por la autora combina análisis de datos, modelado predictivo y reflexión teórica, logrando construir un aporte sólido que permite comprender de manera más profunda el acceso al aprendizaje en línea en contextos diversos.

Proceso para resolver el problema considerado por el autor

La autora aborda el problema del **acceso desigual al aprendizaje en línea** mediante un enfoque integral que combina análisis de datos, machine learning y una perspectiva de justicia social. El problema central identificado es que, aunque el aprendizaje en línea se presenta como una solución para ampliar oportunidades educativas, en la práctica su acceso está condicionado por múltiples factores estructurales que generan desigualdades. Para resolver este problema, la autora propone un proceso basado en la identificación, análisis e interpretación de dichos factores a partir de datos reales de interacción educativa.

En una primera etapa, la solución se plantea mediante la **integración de múltiples variables relevantes**, incluyendo características del estudiante (edad, género, país), factores contextuales (como el impacto de la COVID-19) y variables relacionadas con el comportamiento dentro de la plataforma (habilidad matemática, tiempo de uso, dificultad de las sesiones, entre otros). Esta integración permite construir una visión multidimensional del acceso al aprendizaje en línea, superando enfoques simplificados que solo consideran aspectos tecnológicos o de infraestructura.

Posteriormente, la autora utiliza **modelos de machine learning** para analizar cómo estas variables influyen en la probabilidad de acceso al aprendizaje en línea. Estos modelos permiten identificar patrones complejos y relaciones no lineales entre las variables, lo cual sería difícil de lograr mediante métodos tradicionales. A través de este proceso, el sistema no solo clasifica

a los estudiantes según su nivel de acceso, sino que también permite detectar qué factores tienen mayor influencia en dicha participación.

Un elemento clave en la resolución del problema es la incorporación de un enfoque de **machine learning explicable**, que permite interpretar los resultados del modelo. Mediante técnicas como los valores de Shapley, la autora identifica la importancia de cada variable en la predicción del acceso. Esto transforma el modelo en una herramienta no solo predictiva, sino también analítica, capaz de revelar las causas subyacentes de la desigualdad en el acceso al aprendizaje en línea.

Además, el proceso incluye un **análisis comparativo entre distintos contextos nacionales**, específicamente entre países con diferentes niveles de desarrollo (como Kenya, Thailand y Reino Unido). Este análisis permite evidenciar que el acceso al aprendizaje en línea no es homogéneo, sino que depende en gran medida del contexto socioeconómico y de las condiciones estructurales de cada país. De esta manera, la solución no se limita a un modelo general, sino que reconoce la necesidad de enfoques diferenciados según el entorno.

Finalmente, la resolución del problema se orienta hacia la **aplicación práctica de los resultados**, destacando que los hallazgos pueden ser utilizados para diseñar estrategias educativas más inclusivas. Al identificar los factores que limitan el acceso, las instituciones y los desarrolladores de plataformas pueden implementar mejoras orientadas a reducir las brechas digitales, como adaptar contenidos, mejorar la accesibilidad o diseñar intervenciones específicas para grupos vulnerables.

En conjunto, el proceso propuesto por la autora permite no solo analizar el acceso al aprendizaje en línea, sino también comprender las causas de su desigualdad y ofrecer una base sólida para desarrollar soluciones más equitativas en el ámbito educativo.

Métricas que el autor usa y resultado que obtiene. Comentar (los resultados son mejores respecto a otros)

Para evaluar su estudio, la autora emplea métricas propias del **machine learning explicable**, combinando indicadores de ajuste predictivo con medidas de importancia de variables. En la fase inicial, guiada por la teoría, utiliza métricas de desempeño como **RMSE** y **Adjusted R²** para evaluar si un modelo construido únicamente con variables teóricas —país, género y contexto COVID-19— lograba explicar adecuadamente el acceso al aprendizaje en línea. Los resultados de esta primera etapa fueron débiles, ya que el modelo presentó un **RMSE de entrenamiento de 654.29**, un **RMSE de prueba de 601.58** y valores de **Adjusted R² negativos** tanto en entrenamiento como en prueba, lo que indicó que un enfoque puramente teórico no era suficiente para explicar el fenómeno.

Frente a ello, la autora pasó a una segunda fase guiada por los datos, en la que optimizó el modelo con técnicas de regularización y posteriormente con **XGBoost**, priorizando no solo capacidad predictiva sino también interpretabilidad. En esta etapa, la métrica central dejó de ser solo el ajuste global del modelo y pasó a incluir el análisis de **importancia de variables mediante valores de Shapley**. Gracias a ello, pudo identificar qué factores tenían mayor peso en la predicción del acceso al aprendizaje en línea. Los resultados muestran que las variables más importantes fueron **mathAbility** con un valor absoluto medio de Shapley de **0.263**, **birthYear** con **0.174**, **mathLevel** con **0.163**, **birthMonth** con **0.132** y **timeTaken** con **0.132**. Además, entre las variables derivadas del marco teórico, también mostraron importancia **UK** con **0.045**, **Kenya** con **0.032**, **Male** con **0.026** y **since_covid** con **0.025**, lo que confirmó parcialmente las hipótesis iniciales sobre país, género y pandemia.

En cuanto a los resultados sustantivos, la autora obtiene varios hallazgos relevantes. Primero, encuentra que **las diferencias entre países sí influyen en el acceso**, mostrando que los estudiantes de Kenya aparecen como los más desfavorecidos, mientras que estudiantes de

Thailand y del Reino Unido muestran mayores niveles de acceso. Segundo, confirma que **el género también importa**, ya que los varones presentan una mayor probabilidad de acceder al aprendizaje en línea que las mujeres. Tercero, identifica que **la pandemia de COVID-19 tuvo importancia en la predicción del acceso**, ya sea a través de la variable `since_covid` o de variables relacionadas con el año de registro. Finalmente, la autora encuentra resultados adicionales no previstos en el modelo teórico inicial, como la importancia de la habilidad matemática, la edad, el nivel de dificultad de la sesión, el mes de nacimiento y el tiempo empleado en completar las actividades.

Respecto al comentario comparativo, los resultados de este artículo pueden considerarse **valiosos y superiores en enfoque analítico**, aunque no directamente comparables con muchos estudios previos. Esto se debe a que gran parte de la literatura anterior había analizado el aprendizaje en línea mediante estudios pequeños, revisiones, análisis econométricos o modelos centrados en resultados de aprendizaje, mientras que este trabajo usa **datos masivos reales de plataforma**, integra una **perspectiva de justicia social** y aplica **machine learning explicable** para estudiar específicamente el **acceso**, no solo el rendimiento. En ese sentido, su principal fortaleza no está en reportar una métrica predictiva “más alta” que otras investigaciones, sino en ofrecer una explicación más profunda y contextualizada del problema. Es decir, el estudio resulta mejor que muchos trabajos anteriores no porque presente simplemente un mayor ajuste estadístico, sino porque combina teoría, datos y explicabilidad para entender con mayor claridad qué factores estructurales condicionan el acceso al aprendizaje en línea.

En síntesis, la autora utiliza métricas de ajuste predictivo y de importancia de variables, obtiene como resultado que el acceso al aprendizaje en línea está explicado tanto por factores estructurales esperados como por otros factores emergentes del análisis de datos, y aporta una comprensión más rica que buena parte de la literatura previa. Por ello, sus resultados destacan más por su profundidad interpretativa y valor social que por una simple comparación numérica con otros estudios.

Observaciones y/o críticas tuyas al artículo

El artículo presenta un aporte valioso porque analiza el **acceso al aprendizaje en línea** desde una perspectiva de **justicia social**, algo que no siempre aparece con suficiente fuerza en investigaciones basadas en machine learning. Una de sus principales fortalezas es que no se limita a medir resultados de aprendizaje, sino que se concentra en una condición previa y fundamental: el acceso. Además, la autora logra integrar teoría y análisis de datos, utilizando una combinación de modelo guiado por hipótesis y optimización guiada por los datos, lo cual le da solidez metodológica al estudio. También resulta destacable el uso de herramientas de interpretación como los **valores de Shapley**, ya que permiten explicar qué variables influyen más en el fenómeno analizado.

Sin embargo, una primera crítica importante es que el estudio trabaja con una **submuestra aleatoria de 5000 registros** tomada de una base mucho mayor, superior a 54 millones de datos. Aunque la autora justifica esta decisión por razones computacionales y señala que el subsampling es reconocido en la literatura, esta reducción puede generar dudas sobre cuánto de la complejidad original del fenómeno logra mantenerse en el análisis final. En otras palabras, el estudio es metodológicamente ambicioso, pero al mismo tiempo se ve obligado a simplificar su universo de datos para poder operar, lo que podría limitar la riqueza de los hallazgos.

Otra observación crítica es que el trabajo depende de datos provenientes de **una sola plataforma educativa**, *Maths-Whizz Tutor*. Aunque esta plataforma tiene valor ecológico y contextual por su uso real en distintos países, también significa que los resultados están condicionados por el diseño particular del sistema, su currículo, su forma de interacción y el perfil de sus usuarios. Por ello, los hallazgos no necesariamente pueden generalizarse a todas

las plataformas de aprendizaje en línea ni a todos los contextos educativos digitales. Esta limitación es relevante, sobre todo si se considera que el artículo aborda un problema global como el acceso desigual al aprendizaje en línea.

También considero que, aunque el artículo se apoya en una perspectiva de justicia social, su análisis sigue dependiendo en gran medida de **variables cuantificables disponibles en la plataforma**. Esto implica que factores muy importantes para comprender el acceso —como apoyo familiar, condiciones emocionales, percepción del aprendizaje, calidad del acompañamiento docente o experiencias culturales más profundas— no están recogidos de forma directa. La autora logra identificar patrones importantes, pero todavía queda fuera una parte más cualitativa y humana del problema, que podría complementar y enriquecer la interpretación de los resultados.

Asimismo, una limitación interesante del artículo es que el **modelo inicial guiado por la teoría** tuvo un desempeño muy débil, con valores negativos de **Adjusted R²**, lo que obligó a pasar a un modelo más guiado por los datos. Esto, por un lado, demuestra honestidad metodológica y flexibilidad analítica; pero, por otro lado, también puede interpretarse como una señal de que el marco teórico inicial no lograba captar por sí solo toda la complejidad del acceso al aprendizaje en línea. En ese sentido, el estudio confirma la importancia de los datos para descubrir patrones no anticipados, aunque también deja abierta la pregunta sobre si la teoría utilizada era suficientemente amplia desde el inicio.

Finalmente, me parece que el artículo es fuerte en la **identificación de desigualdades**, pero menos desarrollado en la **propuesta de soluciones concretas**. Es decir, demuestra con claridad que el acceso al aprendizaje en línea está condicionado por país, género, COVID-19 y otras variables emergentes, pero profundiza menos en cómo deberían responder las instituciones, los gobiernos o los diseñadores de plataformas frente a estos hallazgos. Por eso, su mayor fortaleza está en el diagnóstico analítico del problema, más que en la formulación de estrategias prácticas detalladas para resolverlo.

En síntesis, el artículo es sólido, innovador y muy pertinente, especialmente por su enfoque de justicia social y por el uso de machine learning explicable. No obstante, presenta limitaciones relacionadas con la reducción del tamaño muestral, la dependencia de una sola plataforma, la ausencia de variables cualitativas más profundas y el menor desarrollo de propuestas concretas de intervención. Aun así, constituye una base importante para futuras investigaciones sobre desigualdad y acceso en educación digital.

21. ARTÍCULO 21

Author (s): Javier Gamboa-Cruzado; Cinthya Y. Alvarez-Cuellar; Shirley Martinez-Medina; Josue Edison Turpo Chaparro; Aníbal Sifuentes Damián; María Rodríguez Kong.

Title of paper: *Predicción de repitencias en estudiantes a nivel escolar usando Machine Learning: una revisión sistemática.*

Journal: *Apuntes Universitarios / Revista de Investigación Apuntes Universitarios.*

Volume (issue): 13(2).

pag – pag (year): 111–141 (2023).

Estado del arte que hace el autor

El estudio sobre la predicción de la repitencia escolar mediante Machine Learning se ha convertido en una línea de investigación relevante dentro del campo de la analítica educativa, debido a la necesidad de identificar de manera temprana a los estudiantes que se encuentran en riesgo académico. La repitencia escolar no solo representa un problema de rendimiento, sino también un indicador asociado a futuras situaciones de deserción, rezago educativo y

dificultades sociales. En este contexto, el uso de técnicas de aprendizaje automático permite procesar grandes cantidades de datos educativos para reconocer patrones que, muchas veces, no son visibles mediante métodos tradicionales de evaluación.

De acuerdo con el artículo revisado, la aplicación de Machine Learning en la predicción de repitencia escolar tiene como propósito anticipar posibles casos de estudiantes en riesgo, considerando factores académicos, sociales, demográficos y de comportamiento educativo. Los autores señalan que la identificación temprana de estos estudiantes puede contribuir a reducir las tasas de repitencia y deserción, ya que permite diseñar estrategias de intervención antes de que el problema se agrave. Esta perspectiva evidencia que la tecnología no reemplaza la labor docente, sino que funciona como una herramienta de apoyo para la toma de decisiones educativas.

El estado actual de la investigación muestra que existe un crecimiento progresivo de estudios relacionados con la predicción del rendimiento estudiantil, la deserción y la repitencia escolar utilizando técnicas de Machine Learning. La revisión sistemática analizada identificó inicialmente 47 490 artículos en bases de datos académicas como ACM Digital Library, ERIC, Google Scholar, IEEE Xplore, Microsoft Academic, Science Direct y Taylor & Francis Online; luego de aplicar criterios de exclusión y calidad, se seleccionaron 90 artículos publicados entre los años 2017 y 2021. Este procedimiento demuestra que el tema ha tenido una producción científica considerable, aunque todavía requiere mayor especialización cuando se enfoca específicamente en la repitencia escolar.

Entre los antecedentes más importantes se encuentran investigaciones orientadas a predecir el desempeño académico de los estudiantes mediante algoritmos como árboles de decisión, regresión, redes neuronales, máquinas de soporte vectorial y clasificación bayesiana. Asimismo, otros estudios han abordado la deserción estudiantil en educación superior, cursos virtuales y entornos MOOC. Estos trabajos permiten observar que la predicción académica no se limita únicamente al nivel escolar, sino que también se aplica en distintos contextos educativos. Sin embargo, el artículo destaca que muchos estudios previos se enfocaron más en el rendimiento o abandono universitario, mientras que la repitencia escolar aún constituye un campo que necesita mayor desarrollo investigativo.

Respecto a las variables más utilizadas, la literatura revisada indica que las calificaciones previas y el desempeño en clase son los factores más frecuentes para construir modelos predictivos. También se consideran variables relacionadas con la actividad del estudiante en plataformas virtuales, datos demográficos, información social, características del docente y atributos de los cursos. Esto demuestra que la repitencia escolar es un fenómeno multidimensional, pues no depende únicamente de las notas, sino también del entorno familiar, económico, social y pedagógico. Por ello, los modelos de Machine Learning más efectivos son aquellos que integran diferentes tipos de variables para obtener una visión más completa del estudiante.

En cuanto a las métricas de evaluación, los estudios revisados utilizan principalmente Accuracy y AUC-ROC para medir la efectividad de los modelos predictivos. También se emplean métricas como Precision, Recall, F1-Score, matriz de confusión, sensibilidad y especificidad. Estas métricas permiten comprobar si los algoritmos realmente identifican correctamente a los estudiantes con riesgo de repetir. De acuerdo con los resultados del artículo, Accuracy fue la métrica más aplicada, seguida por AUC-ROC, lo que evidencia la importancia de evaluar no solo la cantidad de aciertos del modelo, sino también su capacidad para distinguir entre estudiantes en riesgo y estudiantes sin riesgo académico.

Finalmente, las técnicas de clasificación más utilizadas en la predicción de repitencia escolar son los árboles de decisión y los algoritmos de regresión. Los árboles de decisión destacan porque permiten interpretar con mayor claridad los criterios que llevan a clasificar a un

estudiante como posible repetidor, mientras que los algoritmos de regresión ayudan a establecer relaciones entre variables y resultados académicos. También se emplean redes neuronales, máquinas de soporte vectorial, algoritmos bayesianos, aprendizaje profundo y técnicas de agrupamiento. En conjunto, el estado del arte muestra que el Machine Learning representa una alternativa prometedora para fortalecer la prevención de la repitencia escolar, siempre que su aplicación sea acompañada por criterios pedagógicos, éticos y humanos.

Motivación del autor

La motivación principal de los autores surge de la necesidad de enfrentar un problema educativo relevante: la repitencia escolar y sus consecuencias en la trayectoria académica de los estudiantes. El artículo parte de la idea de que identificar tempranamente a los alumnos con riesgo de repetir un curso o grado puede ayudar a disminuir no solo la repitencia, sino también la deserción escolar. Esta preocupación se relaciona con el impacto que tiene el fracaso académico en la vida del estudiante, ya que puede limitar sus oportunidades futuras, afectar su autoestima y generar dificultades sociales y económicas.

Asimismo, los autores se motivan por el avance de las tecnologías aplicadas a la educación, especialmente el uso de Machine Learning como herramienta para analizar datos estudiantiles y reconocer patrones de riesgo. En el artículo se señala que, muchas veces, las causas de la repitencia están vinculadas a factores familiares, económicos o de comunicación entre escuela, docente y alumno; sin embargo, estos factores no siempre son detectados a tiempo por las instituciones educativas. Por ello, los autores consideran importante revisar qué investigaciones existen sobre este tema y qué tan efectivas han sido las técnicas de aprendizaje automático para predecir estos casos.

En ese sentido, la motivación del estudio también responde a la falta de una visión organizada sobre las investigaciones publicadas entre 2017 y 2021 acerca de la predicción de repitencia escolar mediante Machine Learning. Por esta razón, los autores desarrollan una revisión sistemática de literatura con el propósito de identificar los algoritmos más utilizados, las variables más aplicadas, las métricas de evaluación y los principales aportes científicos en este campo. De esta manera, el trabajo busca servir como una base académica para futuras investigaciones y para el diseño de estrategias educativas preventivas.

Descripción del aporte del autor

El aporte principal de los autores del artículo **“Predicción de repitencias en estudiantes a nivel escolar usando Machine Learning: una revisión sistemática”** consiste en presentar una revisión sistemática de la literatura sobre el uso de técnicas de Machine Learning para predecir la repitencia escolar. Este trabajo resulta importante porque organiza, analiza y sintetiza investigaciones previas relacionadas con la identificación temprana de estudiantes en riesgo académico. A diferencia de un estudio experimental que aplica un solo modelo predictivo a una población específica, este artículo revisa un conjunto amplio de investigaciones publicadas entre los años 2017 y 2021, con la finalidad de conocer el estado actual del conocimiento sobre el tema, las técnicas más utilizadas, las variables más relevantes y las métricas que permiten evaluar la efectividad de los modelos predictivos.

Uno de los aportes más significativos del artículo es que permite comprender la repitencia escolar como un problema que puede ser abordado con herramientas tecnológicas modernas, pero sin dejar de lado su dimensión educativa y social. Los autores explican que la identificación temprana de estudiantes con probabilidad de repetir un curso o grado puede ayudar a reducir las tasas de repitencia y deserción escolar. Esto es relevante porque la repitencia no debe entenderse únicamente como una consecuencia de bajo rendimiento académico, sino como una señal de alerta que puede estar relacionada con problemas familiares, económicos, institucionales o pedagógicos. En ese sentido, el artículo aporta una visión

preventiva: no se trata solo de reconocer al estudiante que ya fracasó, sino de detectar a tiempo los factores de riesgo para intervenir oportunamente .

Otro aporte importante de los autores es la aplicación de una metodología rigurosa de revisión sistemática. El artículo se basa en las directrices de Kitchenham y Charters, lo cual le otorga orden, transparencia y validez al proceso de búsqueda, selección y análisis de los estudios revisados. Los autores no seleccionan los artículos de manera arbitraria, sino que establecen preguntas de investigación, objetivos, fuentes de búsqueda, criterios de exclusión, criterios de calidad, estrategias de extracción de datos y síntesis de hallazgos. Este procedimiento fortalece el valor académico del trabajo, porque permite que los resultados no sean simples opiniones, sino conclusiones derivadas de un proceso organizado y verificable.

En relación con la búsqueda bibliográfica, el aporte de los autores también se evidencia en la amplitud de fuentes consultadas. La revisión identificó inicialmente **47 490 artículos** en bases académicas como ACM Digital Library, ERIC, Google Scholar, IEEE Xplore, Microsoft Academic, Science Direct y Taylor & Francis Online. Luego de aplicar criterios de exclusión y evaluación de calidad, se seleccionaron **90 artículos** considerados adecuados para el análisis. Esta reducción demuestra que los autores realizaron un proceso riguroso para depurar la información y trabajar únicamente con estudios pertinentes al tema de investigación . Por ello, el artículo no solo recopila información, sino que selecciona literatura científica relevante para comprender mejor la predicción de la repitencia escolar mediante Machine Learning.

Asimismo, los autores aportan al identificar cuáles son los artículos más citados dentro del campo de estudio. Este aspecto es relevante porque permite reconocer las investigaciones con mayor impacto académico en la predicción de la repitencia escolar y del riesgo estudiantil. Según los resultados del artículo, el trabajo de Costa et al. fue el más citado, con 200 citas, seguido por investigaciones como las de Jokhan et al., Lacave et al. y Chung & Lee. Esta información es útil para futuros investigadores, ya que les permite ubicar rápidamente los estudios de mayor influencia y tomar como base las investigaciones más reconocidas dentro del área. De esta manera, el artículo funciona como una guía bibliográfica para quienes deseen profundizar en el tema.

Un aporte fundamental del trabajo es la clasificación de las **categorías de variables** utilizadas para predecir la repitencia escolar. Los autores identifican siete categorías principales: calificaciones previas y desempeño en clase, actividad del estudiante en entornos virtuales, datos demográficos, información social del estudiante, atributos del docente, características de los cursos y otras variables. Entre ellas, las más utilizadas fueron las calificaciones previas y el desempeño en clase, con 17 %, y la actividad del estudiante en plataformas de aprendizaje electrónico, con 16 % . Esta clasificación es valiosa porque muestra que la predicción de la repitencia escolar no depende de un único dato, sino de un conjunto de factores que deben analizarse de manera integral.

El hecho de que las calificaciones previas y el desempeño en clase sean las variables más utilizadas confirma que el historial académico sigue siendo uno de los indicadores más importantes para anticipar dificultades escolares. Sin embargo, el artículo también muestra que los modelos predictivos actuales incorporan otros elementos, como la participación del estudiante en entornos virtuales, sus características demográficas y su contexto social. Este aporte permite ampliar la comprensión del problema, ya que la repitencia no se explica solamente por las notas, sino también por las condiciones en las que el estudiante aprende. En consecuencia, el trabajo de los autores ayuda a promover una mirada más completa sobre el riesgo académico.

Otro aporte destacado se encuentra en la identificación de las **métricas de evaluación** más utilizadas en los estudios revisados. Los autores señalan que las investigaciones emplean 17 métricas diferentes para evaluar los modelos de Machine Learning, entre las cuales destacan

Accuracy, AUC-ROC, Precision, Recall, F1-Score, matriz de confusión, sensibilidad, especificidad, RMSE y MAE. De acuerdo con los resultados, Accuracy fue la métrica más aplicada, con 41 %, seguida por AUC-ROC, con 38 %. Este aporte es importante porque permite conocer cómo se mide la efectividad de los algoritmos y qué criterios utilizan los investigadores para determinar si un modelo predictivo es confiable.

La revisión de métricas también tiene un valor práctico. En el ámbito educativo, no basta con que un modelo tenga una alta precisión general; también es necesario que pueda identificar correctamente a los estudiantes que realmente están en riesgo. Por ejemplo, un modelo puede tener buenos resultados estadísticos, pero si no detecta a los alumnos que necesitan apoyo, su utilidad educativa sería limitada. Por ello, al presentar las métricas más utilizadas, los autores aportan información clave para que futuras investigaciones seleccionen indicadores adecuados y evalúen sus modelos de manera más responsable.

De igual manera, el artículo contribuye al identificar las **técnicas de clasificación de Machine Learning** más empleadas para la predicción de repitencia escolar. Los autores encuentran que los algoritmos de árbol de decisión son los más utilizados, con 67 %, seguidos por los algoritmos de regresión, con 48 %. También se mencionan redes neuronales, máquinas de soporte vectorial, algoritmos bayesianos, algoritmos basados en instancias, aprendizaje profundo, técnicas de agrupamiento y otros métodos. Este aporte es relevante porque permite conocer cuáles son las técnicas con mayor presencia en la literatura científica y cuáles podrían ser consideradas en futuras aplicaciones educativas.

Los árboles de decisión destacan porque ofrecen una ventaja importante: suelen ser más interpretables que otros modelos complejos. En educación, la interpretabilidad es fundamental, ya que docentes, directivos y especialistas necesitan comprender por qué un estudiante ha sido clasificado como estudiante en riesgo. No se trata únicamente de obtener una predicción, sino de explicar los factores que llevaron a esa predicción. Por ello, el aporte de los autores no se limita a mencionar algoritmos, sino que permite reflexionar sobre la necesidad de usar modelos que puedan ser comprendidos y aplicados en contextos educativos reales.

Otro aspecto valioso del artículo es el análisis de palabras clave y coocurrencias. Los autores identifican que los términos más frecuentes en las investigaciones revisadas son “machine learning”, “educational data mining” y “learning analytics”. Además, muestran una relación importante entre “machine learning” y “educational data mining”, así como entre “machine learning” y “dropout”. Este aporte permite visualizar las tendencias temáticas del campo de estudio y comprender que la predicción de la repitencia escolar se encuentra relacionada con áreas como la minería de datos educativos, la analítica del aprendizaje y la prevención de la deserción.

Además, el artículo aporta al realizar un análisis de objetividad y polaridad en las conclusiones de los estudios más citados. Este elemento resulta novedoso porque no solo se revisa la cantidad de citas o las técnicas utilizadas, sino también el tono y la orientación de las conclusiones de los artículos analizados. Los autores encuentran que los estudios más citados presentan una alta objetividad y una polaridad generalmente neutral. Esto significa que las investigaciones revisadas tienden a basarse en hechos y mantienen una redacción moderada, lo cual fortalece su credibilidad académica.

Finalmente, el aporte general de los autores consiste en ofrecer una base ordenada para futuras investigaciones sobre repitencia escolar y Machine Learning. El artículo permite conocer qué se ha investigado, qué variables se han utilizado, qué algoritmos han sido más frecuentes, qué métricas se aplican y cuáles son las principales tendencias del tema. Asimismo, deja abierta la necesidad de continuar investigando con artículos más recientes y con aplicaciones más específicas al contexto escolar. En este sentido, el trabajo no solo describe el estado actual del conocimiento, sino que también orienta nuevas líneas de investigación.

En conclusión, el aporte de los autores es académico, metodológico y práctico. Es académico porque sistematiza literatura científica relevante; metodológico porque aplica un proceso riguroso de revisión sistemática; y práctico porque ofrece información útil para diseñar modelos de alerta temprana que ayuden a prevenir la repitencia escolar. Su principal valor está en demostrar que el Machine Learning puede convertirse en una herramienta de apoyo para la educación, siempre que se utilice con responsabilidad, con datos adecuados y con una finalidad humana: mejorar el acompañamiento a los estudiantes que más lo necesitan.

Proceso para obtener el aporte

El proceso seguido por los autores para obtener el aporte de la investigación se basó en el desarrollo de una **revisión sistemática de la literatura**, orientada a identificar, seleccionar, analizar y sintetizar estudios científicos relacionados con la predicción de la repitencia escolar mediante Machine Learning. Para ello, los autores tomaron como referencia las directrices metodológicas de Kitchenham y Charters, las cuales permiten realizar revisiones sistemáticas de manera ordenada, rigurosa y transparente. Este procedimiento fue fundamental porque el objetivo del artículo no era aplicar directamente un algoritmo a una muestra de estudiantes, sino conocer el estado del arte de las investigaciones existentes sobre el tema.

En primer lugar, los autores formularon las preguntas y objetivos de investigación. Estas preguntas guiaron todo el proceso de búsqueda y análisis, ya que permitieron definir qué información era necesaria extraer de los artículos revisados. Entre los aspectos considerados se encuentran los artículos más citados, las categorías de variables más utilizadas, las métricas empleadas para evaluar los modelos predictivos, las palabras clave con mayor coocurrencia, las técnicas de clasificación aplicadas y el análisis de objetividad y polaridad de las conclusiones. De esta manera, el estudio tuvo una dirección clara desde el inicio y evitó una revisión superficial o desorganizada.

Posteriormente, se establecieron las fuentes y estrategias de búsqueda. Los autores consultaron bases de datos académicas reconocidas, como ACM Digital Library, ERIC, Google Scholar, IEEE Xplore, Microsoft Academic, Science Direct y Taylor & Francis Online. Para realizar la búsqueda utilizaron ecuaciones compuestas por términos como “machine learning”, “prediction of school repetition”, “school repetition prediction”, “grade retention”, “dropout”, “student attrition” y “early school leaving”, entre otros. Gracias a esta estrategia inicial, se identificaron **47 490 artículos**, lo que demuestra la amplitud del proceso de recopilación de información .

Luego, los autores aplicaron criterios de exclusión con la finalidad de depurar los resultados obtenidos. Se descartaron estudios con una antigüedad mayor a cinco años, documentos que no estaban escritos en inglés, trabajos que no eran artículos científicos, publicaciones con temas poco adecuados, artículos duplicados, títulos o palabras clave poco relacionados con el tema y resúmenes que no presentaban suficiente relevancia. Este paso fue importante porque permitió reducir una gran cantidad de documentos iniciales y conservar solo aquellos que realmente aportaban al objetivo de la revisión.

Después de aplicar los criterios de exclusión, los autores seleccionaron **90 artículos** para el análisis final. Estos artículos fueron sometidos a una evaluación de calidad mediante siete preguntas o criterios, conocidos como QAs. Dichos criterios verificaban si los objetivos estaban claramente identificados, si el experimento era adecuado, si el área temática estaba definida, si el documento estaba bien organizado, si los métodos de análisis eran apropiados, si los resultados estaban claramente informados y si el artículo era adecuado en términos generales . Esta evaluación permitió asegurar que los estudios incluidos tuvieran calidad suficiente para sustentar las conclusiones de la revisión.

Finalmente, los autores realizaron la extracción y síntesis de datos. De cada artículo seleccionado recopilaban información como título, autores, año, país, fuente, número de citas,

resumen, palabras clave, tipo de artículo, número de páginas, filiación y tamaño de muestra. Además, procesaron los textos mediante técnicas de Procesamiento de Lenguaje Natural, incluyendo limpieza de datos, conversión a minúsculas, eliminación de palabras vacías, stemming, lematización y análisis de frecuencias. Con estos datos generaron tablas, gráficos, nubes de palabras, diagramas de coocurrencia y análisis de polaridad y objetividad. Así, el aporte final fue obtenido mediante un proceso sistemático, ordenado y verificable, que permitió identificar las principales tendencias, técnicas y variables utilizadas en la predicción de repitencia escolar con Machine Learning.

Proceso para resolver el problema

El proceso para resolver el problema planteado en el artículo parte de una preocupación central: la dificultad de identificar oportunamente a los estudiantes que se encuentran en riesgo de repetir un curso o grado escolar. La repitencia escolar no aparece de manera repentina, sino que suele estar relacionada con diversos factores académicos, familiares, económicos, sociales y pedagógicos. Sin embargo, muchas instituciones educativas no cuentan con mecanismos suficientes para detectar estos riesgos a tiempo. Por ello, los autores proponen abordar el problema desde el análisis de investigaciones previas sobre el uso de **Machine Learning** como herramienta de predicción y prevención.

Para resolver este problema, los autores primero delimitan el tema de estudio. No se enfocan en cualquier tipo de dificultad académica, sino específicamente en la **predicción de repitencia escolar en estudiantes mediante Machine Learning**. Esta delimitación es importante porque permite concentrar la revisión en estudios relacionados con modelos predictivos capaces de anticipar el riesgo académico. A partir de ello, se formulan preguntas de investigación que ayudan a organizar el análisis, tales como: qué variables se utilizan con mayor frecuencia, qué métricas permiten evaluar los modelos, qué técnicas de clasificación son más empleadas y cuáles son los artículos más relevantes sobre el tema.

Luego, el proceso continúa con la búsqueda sistemática de información científica. Los autores consultan bases de datos académicas reconocidas, entre ellas ACM Digital Library, ERIC, Google Scholar, IEEE Xplore, Microsoft Academic, Science Direct y Taylor & Francis Online. En estas fuentes aplican ecuaciones de búsqueda relacionadas con términos como “machine learning”, “school repetition prediction”, “grade retention”, “dropout”, “student attrition” y “early school leaving”. Con esta estrategia lograron identificar inicialmente 47 490 artículos, lo cual demuestra que el problema fue abordado desde una revisión amplia de la producción científica existente.

Después de reunir los artículos, los autores aplican criterios de exclusión para seleccionar solo los estudios más adecuados. Se descartan documentos con más de cinco años de antigüedad, textos que no estaban en inglés, trabajos que no eran artículos científicos, publicaciones duplicadas, estudios con títulos o palabras clave poco relacionados con el tema y artículos cuyo resumen no era suficientemente relevante. Este filtro permite reducir la gran cantidad inicial de documentos y trabajar finalmente con 90 artículos pertinentes. De esta manera, el problema se resuelve mediante una selección rigurosa de investigaciones confiables y directamente vinculadas con la predicción de repitencia escolar.

Posteriormente, los artículos seleccionados son evaluados mediante criterios de calidad. Los autores revisan si cada documento presenta objetivos claros, métodos adecuados, resultados bien informados, organización coherente y pertinencia general para el estudio. Este paso garantiza que la información utilizada para responder al problema no provenga de fuentes débiles o poco confiables. Además, permite que las conclusiones de la revisión tengan mayor validez académica, ya que se basan en investigaciones previamente evaluadas y consideradas útiles para el análisis.

Finalmente, el proceso de solución se completa con la extracción, procesamiento y síntesis de los datos. Los autores recogen información sobre los artículos más citados, las variables predictivas, las métricas de evaluación, las palabras clave, las técnicas de clasificación y los niveles de objetividad y polaridad. Luego organizan estos resultados en tablas, gráficos y redes bibliométricas. A partir de este análisis, identifican que las variables más utilizadas son las calificaciones previas y el desempeño en clase; que las métricas más frecuentes son Accuracy y AUC-ROC; y que las técnicas más empleadas son los árboles de decisión y los algoritmos de regresión. Así, el problema se resuelve ofreciendo una visión clara y organizada sobre cómo el Machine Learning puede contribuir a detectar estudiantes en riesgo y apoyar la prevención de la repitencia escolar.

Métricas y resultados

En el artículo, las métricas cumplen un papel fundamental porque permiten evaluar la efectividad de los modelos de **Machine Learning** aplicados a la predicción de repitencia escolar. A partir de la revisión sistemática realizada, los autores identificaron **17 métricas** utilizadas en los estudios analizados. Entre las más frecuentes se encuentran **Accuracy, AUC-ROC, Precision, Recall** y **F1-Score**. Según los resultados, la métrica más empleada fue **Accuracy**, presente en el 41 % de los artículos revisados, seguida por **Area Under the Receiver Operating Characteristic Curve (AUC-ROC)**, con 38 %. También se usaron Precision en 37 %, Recall en 33 % y F1-Score en 24 % de los estudios.

Estos resultados evidencian que los investigadores priorizan métricas capaces de medir tanto el nivel general de aciertos como la capacidad del modelo para distinguir correctamente entre estudiantes en riesgo y estudiantes sin riesgo. La presencia de Accuracy indica que muchos estudios buscan conocer qué porcentaje de predicciones fueron correctas; sin embargo, métricas como AUC-ROC, Precision y Recall permiten realizar una evaluación más completa, especialmente cuando se trabaja con estudiantes en situación vulnerable. En conjunto, los resultados muestran que los modelos predictivos basados en Machine Learning pueden ser útiles para anticipar casos de repitencia escolar, siempre que sean evaluados con métricas adecuadas y aplicados como apoyo a la toma de decisiones educativas.

Observaciones/críticas

Una de las principales observaciones al artículo es que presenta un aporte valioso al organizar investigaciones sobre la predicción de repitencia escolar mediante **Machine Learning**, pero su enfoque depende totalmente de estudios previos. Al tratarse de una revisión sistemática, no aplica un modelo propio con datos reales de estudiantes, por lo que no se puede comprobar directamente la efectividad de los algoritmos en un contexto educativo específico. Esto limita parcialmente el alcance práctico del trabajo, ya que los resultados describen tendencias generales, pero no muestran una intervención concreta en una institución escolar.

Otra crítica importante es que la investigación considera artículos publicados entre 2017 y 2021, por lo que sería necesario actualizar la revisión con estudios más recientes. El campo de Machine Learning avanza rápidamente y, en los últimos años, han surgido nuevas técnicas, herramientas y enfoques de analítica educativa que podrían modificar los resultados obtenidos. Además, aunque el artículo identifica variables académicas, sociales y demográficas, no profundiza suficientemente en los aspectos éticos relacionados con el uso de datos estudiantiles, como la privacidad, el sesgo algorítmico y el riesgo de etiquetar negativamente a los alumnos.

A pesar de estas limitaciones, el artículo cumple una función importante porque permite conocer qué métricas, variables y técnicas son más utilizadas en la predicción de repitencia escolar. Su principal fortaleza está en la organización sistemática de la información y en la claridad con la que presenta los hallazgos. Sin embargo, para futuras investigaciones sería

recomendable complementar este tipo de revisión con estudios aplicados, datos actuales y una mayor reflexión ética sobre el uso de Machine Learning en contextos escolares.

22. ARTÍCULO 22

Author (s): Benedikt Sonnleitner; Tom Madou; Matthias Deceuninck; Filotas Theodosiou; Yves R. Sagaert

Title of paper: Evaluation of early student performance prediction given concept drift

Journal: Computers and Education: Artificial Intelligence

Volume (issue): Volume 8

pag – pag (year): Article 100369, pp. 1–11 (2025)

Estado del arte que hace el autor

La predicción temprana del rendimiento académico estudiantil se ha consolidado como una de las líneas más relevantes dentro de la minería de datos educativos y la analítica del aprendizaje. En los últimos años, el crecimiento de las plataformas digitales de enseñanza, como los Learning Management Systems —LMS—, ha permitido recopilar grandes volúmenes de información sobre la interacción de los estudiantes con los recursos virtuales, sus hábitos de estudio, su participación en actividades y sus resultados académicos. Esta información se utiliza para diseñar modelos predictivos capaces de identificar, de manera anticipada, a los estudiantes en riesgo de bajo rendimiento, con el propósito de aplicar intervenciones oportunas que mejoren sus resultados de aprendizaje. En este contexto, los sistemas de alerta temprana se han convertido en herramientas estratégicas para docentes e instituciones, ya que permiten tomar decisiones basadas en evidencia y ofrecer apoyo personalizado a los estudiantes antes de que finalice el curso.

Diversos estudios han empleado variables conductuales obtenidas de los LMS, tales como el número de accesos, la visualización de materiales, la participación en foros, la realización de cuestionarios, la regularidad en el estudio y el tiempo dedicado a las actividades. Estas variables han sido consideradas indicadores importantes del compromiso académico del estudiante. Sin embargo, la literatura muestra resultados mixtos respecto a su capacidad predictiva, ya que en algunos contextos los datos de comportamiento digital se relacionan significativamente con el éxito académico, mientras que en otros su aporte es limitado o poco estable. Esto evidencia que la predicción del rendimiento no depende únicamente de la cantidad de datos disponibles, sino también del contexto pedagógico, del diseño del curso, del perfil de los estudiantes y de las condiciones en las que se desarrolla el proceso de enseñanza-aprendizaje.

Además de los datos de interacción digital, investigaciones recientes han incorporado variables relacionadas con el perfil del estudiante, como antecedentes educativos, características demográficas, motivación y estrategias de aprendizaje. En este sentido, instrumentos como el Motivated Strategies for Learning Questionnaire —MSLQ— permiten analizar dimensiones vinculadas con la autorregulación, la elaboración, el esfuerzo, la organización y la búsqueda de ayuda. Estas variables resultan importantes porque permiten comprender aspectos del aprendizaje que no siempre se reflejan en los registros automáticos de las plataformas virtuales. Por ejemplo, un estudiante puede interactuar poco con el LMS, pero desarrollar estrategias de estudio externas que influyan positivamente en su rendimiento. Por ello, los modelos más completos suelen combinar información conductual, académica y personal para obtener una visión más integral del proceso educativo.

Respecto a las técnicas utilizadas, la literatura ha aplicado diversos modelos de machine learning, como árboles de decisión, random forest, XGBoost, máquinas de soporte vectorial, regresión logística, regresión lineal, redes neuronales y métodos de regularización como LASSO y RIDGE. Aunque los modelos complejos suelen ser valorados por su capacidad para

capturar patrones no lineales, también presentan riesgos importantes, especialmente cuando se trabaja con muestras pequeñas o con muchas variables. En estos casos, puede aparecer el sobreajuste, es decir, el modelo aprende patrones específicos de los datos de entrenamiento que no se generalizan adecuadamente a nuevos grupos de estudiantes. Por esta razón, algunos estudios han destacado la utilidad de modelos más simples, interpretables y robustos, especialmente cuando se busca aplicar los resultados en contextos reales de enseñanza.

Un problema central en esta área es el cambio en los datos a lo largo del tiempo, conocido como **covariate drift** y **concept drift**. El primero ocurre cuando cambia la distribución de las variables predictoras; por ejemplo, cuando los estudiantes modifican su forma de interactuar con la plataforma. El segundo aparece cuando cambia la relación entre esas variables y el rendimiento académico. Estos fenómenos son especialmente relevantes en educación, porque los cursos, docentes, metodologías, evaluaciones y perfiles estudiantiles pueden variar de un año a otro. El artículo analizado muestra este problema a partir de datos de estudiantes de enfermería durante y después del periodo de Covid-19, evidenciando que los cambios en la modalidad educativa afectaron los patrones de aprendizaje y redujeron la estabilidad de algunos modelos predictivos.

En síntesis, el estado actual de la investigación indica que la predicción temprana del rendimiento estudiantil es una herramienta prometedora para mejorar la toma de decisiones educativas, pero aún enfrenta desafíos importantes. Entre ellos destacan la necesidad de modelos explicables, la selección adecuada de variables, la prevención del sobreajuste y la adaptación a cambios en el comportamiento estudiantil. La evidencia reciente sugiere que, en contextos con datos limitados o con posibles cambios entre periodos académicos, los modelos simples y con pocas variables pueden ser más efectivos que modelos complejos. Esto refuerza la importancia de no priorizar únicamente la sofisticación técnica, sino también la interpretabilidad, la estabilidad y la utilidad pedagógica de los modelos predictivos.

Motivación del autor

La motivación principal de los autores surge de la necesidad de mejorar la predicción temprana del rendimiento académico de los estudiantes en contextos educativos mediados por tecnología. En la educación superior, el uso de plataformas virtuales y sistemas de gestión del aprendizaje ha generado grandes cantidades de datos sobre el comportamiento estudiantil, como accesos a materiales, participación en foros, realización de cuestionarios y desempeño en evaluaciones. Sin embargo, aunque estos datos pueden ser útiles para identificar estudiantes en riesgo, los autores observan que muchos modelos predictivos utilizados en la literatura son complejos, emplean demasiadas variables y no siempre ofrecen resultados estables cuando cambian las condiciones educativas.

En ese sentido, el interés de los autores se centra en analizar si los modelos de machine learning más elaborados realmente son superiores a modelos simples cuando existe **concept drift**, es decir, cuando cambia la relación entre las variables predictoras y el rendimiento académico. Esta preocupación se vuelve más importante después del periodo de Covid-19, ya que los hábitos de estudio de los estudiantes variaron considerablemente entre la educación remota y el retorno parcial a la presencialidad. Por ello, los autores buscan demostrar que, en situaciones de cambio y con muestras limitadas, los modelos simples, explicables y con pocas variables pueden ser más precisos y menos sesgados que los modelos complejos. Su motivación no es solo técnica, sino también pedagógica: proponer herramientas predictivas útiles, comprensibles y aplicables para apoyar oportunamente a los estudiantes con bajo rendimiento.

Descripción del aporte del autor

El principal aporte de los autores consiste en demostrar que la predicción temprana del rendimiento académico estudiantil no siempre mejora cuando se utilizan modelos de machine

learning más complejos o grandes conjuntos de variables. A diferencia de una parte importante de la literatura en minería de datos educativos, que suele valorar el uso de modelos sofisticados y múltiples datos extraídos de plataformas virtuales, los autores plantean que, en determinados contextos, los modelos simples, interpretables y con pocas variables pueden ofrecer resultados más precisos, estables y útiles para la toma de decisiones pedagógicas. Este aporte resulta relevante porque cuestiona la idea de que una mayor complejidad técnica necesariamente conduce a mejores predicciones educativas.

En primer lugar, el artículo aporta evidencia empírica sobre el problema del **concept drift** y el **covariate drift** en la predicción del desempeño estudiantil. Los autores analizan datos de estudiantes de primer año de enfermería en un curso introductorio de fisiología durante tres años académicos consecutivos. Los dos primeros años corresponden al periodo de Covid-19, en el que las clases se desarrollaron principalmente de forma remota, mientras que el tercer año corresponde a un periodo posterior, con retorno parcial a la enseñanza presencial. Esta comparación permitió observar que los patrones de comportamiento de los estudiantes cambiaron de manera significativa entre los años académicos. Por ejemplo, durante el periodo posterior al Covid-19, los estudiantes fueron menos activos en la plataforma durante la primera mitad del semestre, participaron menos en el examen de prueba y mostraron cambios en la forma de interactuar con los materiales del curso.

Este hallazgo es importante porque demuestra que los modelos predictivos entrenados con datos de un contexto específico pueden perder precisión cuando las condiciones educativas cambian. En educación, estos cambios pueden deberse a múltiples factores, como modificaciones en la modalidad de enseñanza, cambios de docentes, alteraciones en el currículo, variaciones en el perfil de los estudiantes o situaciones externas como crisis sanitarias, sociales o institucionales. Por ello, los autores aportan una mirada crítica sobre la estabilidad de los modelos predictivos en escenarios reales. No basta con que un modelo funcione bien en un conjunto de datos de entrenamiento; también debe mantener un desempeño adecuado cuando se aplica a nuevos grupos de estudiantes que pueden presentar conductas distintas. Esta reflexión fortalece el campo de la analítica del aprendizaje, ya que enfatiza la necesidad de evaluar los modelos no solo por su precisión, sino también por su capacidad de generalización.

En segundo lugar, los autores aportan una evaluación comparativa entre distintos modelos predictivos, desde modelos simples hasta modelos más elaborados de machine learning. Entre los modelos analizados se incluyen regresión lineal, regresión logística, LASSO, random forest, XGBoost y máquinas de soporte vectorial. También se evaluaron modelos basados únicamente en variables seleccionadas manualmente, como el resultado del examen de prueba de mitad de semestre y el tipo de educación secundaria previa del estudiante. Esta comparación permitió identificar que un modelo lineal simple, basado en el rendimiento del examen de prueba y en la variable de educación general previa, logró un desempeño competitivo e incluso superior frente a modelos más complejos. En la clasificación de estudiantes con bajo rendimiento, este modelo identificó correctamente una proporción importante de estudiantes en riesgo, mostrando que una estrategia sencilla puede ser altamente útil en sistemas de alerta temprana.

Este aporte tiene un valor metodológico importante, porque propone una alternativa más robusta frente al sobreajuste. Cuando se utilizan muchas variables con una muestra relativamente pequeña, los modelos complejos pueden aprender relaciones accidentales o específicas del conjunto de entrenamiento, pero fallar al aplicarse a nuevos datos. Los autores muestran que este problema se agrava cuando existe cambio de contexto, como ocurrió entre el periodo de enseñanza remota y el periodo posterior al Covid-19. En ese sentido, el estudio defiende la utilidad de modelos más parsimoniosos, es decir, modelos que usan menos variables, son más fáciles de interpretar y reducen el riesgo de capturar patrones inestables. Este enfoque resulta especialmente valioso para instituciones educativas que no siempre cuentan con grandes bases de datos o equipos especializados para implementar sistemas predictivos avanzados.

En tercer lugar, el artículo aporta una selección y análisis de variables relevantes para la predicción del rendimiento académico. Los autores no se limitaron a utilizar únicamente datos de interacción con la plataforma virtual, sino que integraron diferentes tipos de información: datos demográficos y educativos, resultados del cuestionario MSLQ sobre motivación y estrategias de aprendizaje, registros de comportamiento en el LMS, participación en actividades, desempeño en cuestionarios y resultado del examen de prueba. Esta integración permitió construir una visión más completa del estudiante y analizar qué variables tenían una relación más significativa con el éxito académico. Entre las variables más relevantes se encontraron el tipo de educación previa, el desempeño en el examen de prueba, la dimensión de elaboración del MSLQ y la visualización de discusiones en foros.

La identificación de estas variables representa un aporte pedagógico, no solo estadístico. Por ejemplo, el hecho de que la dimensión de elaboración del MSLQ se relacione con mejores resultados académicos sugiere que ciertas estrategias cognitivas, como resumir, parafrasear, relacionar información nueva con conocimientos previos y explicar contenidos con palabras propias, pueden favorecer el aprendizaje. Esto ofrece al docente información útil para diseñar intervenciones más orientadas al desarrollo de estrategias de estudio. Asimismo, la importancia del examen de prueba de mitad de semestre muestra que las evaluaciones tempranas pueden funcionar como indicadores valiosos para detectar dificultades antes del examen final. De esta manera, el estudio no solo predice el rendimiento, sino que también brinda pistas sobre qué aspectos pueden trabajarse para mejorar el proceso educativo.

En cuarto lugar, los autores aportan una reflexión sobre la explicabilidad de los modelos predictivos. En contextos educativos, no basta con que un algoritmo clasifique correctamente a los estudiantes; también es necesario que docentes, coordinadores y estudiantes puedan comprender por qué se genera una determinada predicción. Los modelos complejos, aunque pueden ser potentes, suelen funcionar como “cajas negras”, lo que dificulta su uso pedagógico. En cambio, los modelos simples permiten explicar con mayor claridad qué variables influyen en la predicción. Este punto es fundamental para los sistemas de alerta temprana, ya que una predicción debe servir para orientar una acción. Si un estudiante es identificado como “en riesgo”, el docente necesita saber qué factores están asociados con esa alerta para poder intervenir de manera adecuada.

Asimismo, el artículo aporta una crítica a la dependencia excesiva de datos conductuales extraídos automáticamente de plataformas virtuales. Aunque estos datos son útiles, los autores muestran que no todos los indicadores de actividad digital tienen el mismo valor predictivo y que algunos pueden perder estabilidad cuando cambian las condiciones del curso. Por ejemplo, la frecuencia de acceso a materiales o la regularidad de las acciones en el LMS pueden variar según la modalidad de enseñanza, la organización del curso o las indicaciones del docente. Esto significa que un bajo nivel de actividad en la plataforma no siempre implica bajo compromiso académico, ya que algunos estudiantes pueden estudiar mediante libros, apuntes, clases presenciales u otros recursos externos. Este aporte invita a interpretar los datos educativos con prudencia y a no reducir el aprendizaje únicamente a lo que queda registrado en una plataforma.

Otro aporte importante es la propuesta de utilizar modelos simples como punto de referencia o “benchmark” en futuras investigaciones. Los autores sugieren que, antes de aplicar modelos complejos, los estudios sobre predicción del rendimiento estudiantil deberían comparar sus resultados con modelos lineales básicos que usen pocas variables significativas. Esta recomendación es valiosa porque permite evaluar si la complejidad adicional realmente aporta una mejora sustancial. Si un modelo avanzado no supera claramente a un modelo simple, entonces su uso puede no estar justificado, especialmente si es menos interpretable, más difícil de implementar y más vulnerable al cambio de contexto.

Finalmente, el aporte de los autores también se encuentra en su orientación práctica. El estudio no se queda únicamente en la comparación técnica de algoritmos, sino que vincula sus

resultados con la mejora de la enseñanza y el apoyo a los estudiantes. Al demostrar que un modelo simple puede detectar tempranamente a estudiantes en riesgo, los autores ofrecen una base para el desarrollo de sistemas de alerta temprana más accesibles y aplicables en instituciones educativas. Estos sistemas podrían ayudar a los docentes a intervenir a mitad del semestre, cuando todavía existe tiempo para que el estudiante modifique sus hábitos de estudio, participe en actividades de refuerzo o reciba acompañamiento académico.

En conclusión, el aporte del autor se resume en cuatro aspectos fundamentales: evidenciar el impacto del cambio de contexto en los modelos predictivos, demostrar la utilidad de modelos simples frente a modelos complejos, identificar variables relevantes y pedagógicamente interpretables, y proponer una perspectiva más crítica y práctica para el uso de la analítica del aprendizaje. El artículo contribuye al campo de la educación basada en datos al mostrar que la precisión no debe buscarse únicamente mediante algoritmos sofisticados, sino mediante modelos estables, explicables y útiles para la intervención educativa. De esta manera, los autores ofrecen una contribución significativa para futuras investigaciones y para la implementación responsable de herramientas predictivas en la educación superior.

Proceso para obtener el aporte

Para obtener su aporte, los autores desarrollaron un proceso metodológico basado en la recopilación, organización, análisis y comparación de datos educativos reales. El estudio se realizó con estudiantes de primer año de enfermería matriculados en un curso introductorio de fisiología durante tres años académicos consecutivos. Los datos de los años académicos 2020-2021 y 2021-2022 fueron utilizados como conjunto de entrenamiento, mientras que los datos del año 2022-2023 fueron empleados como conjunto de prueba. Esta división fue importante porque permitió evaluar el comportamiento de los modelos predictivos en dos contextos distintos: el periodo de enseñanza mayoritariamente remota durante la pandemia de Covid-19 y el periodo posterior, con retorno parcial a la presencialidad.

El primer paso del proceso consistió en recolectar información de diferentes fuentes. Los autores reunieron datos demográficos y educativos de los estudiantes, como el tipo de educación secundaria previa y el nivel de formación alcanzado. Además, aplicaron el cuestionario **Motivated Strategies for Learning Questionnaire —MSLQ—**, instrumento utilizado para medir aspectos relacionados con la motivación y las estrategias de aprendizaje, tales como elaboración, organización, pensamiento crítico, autorregulación, esfuerzo, aprendizaje entre pares y búsqueda de ayuda. Esta información permitió incorporar variables que no se observan directamente en la plataforma virtual, pero que pueden influir en el rendimiento académico.

El segundo paso fue extraer y procesar los registros de interacción de los estudiantes dentro del sistema de gestión del aprendizaje, Moodle. A partir de estos registros, los autores construyeron variables relacionadas con la participación y el comportamiento académico en línea. Estas variables fueron agrupadas en seis categorías: compromiso, rendimiento, participación, regularidad, repetición y perfil de aprendizaje. Entre ellas se incluyeron indicadores como número total de acciones realizadas, visualización de materiales, participación en foros, intentos de cuestionarios, días activos, acceso a capítulos, resultados del examen de prueba y promedio en actividades evaluativas. Para que la predicción fuera temprana, solo se consideraron los datos disponibles hasta la semana ocho del semestre, es decir, aproximadamente a la mitad del curso.

El tercer paso consistió en analizar si existían cambios en los datos entre los periodos estudiados. Para ello, los autores compararon el comportamiento de los estudiantes durante los años de pandemia con el comportamiento observado después de la pandemia. Encontraron que, en el año académico 2022-2023, los estudiantes fueron menos activos durante la primera mitad del semestre y participaron en menor proporción en el examen de prueba. Este análisis permitió identificar la presencia de **covariate drift**, cuando cambia la distribución de las variables predictoras, y **concept drift**, cuando cambia la relación entre esas variables y el rendimiento

final. Este punto fue esencial para el aporte del estudio, porque mostró que los modelos entrenados en un contexto pueden perder precisión cuando se aplican en otro contexto educativo.

El cuarto paso fue seleccionar las variables más relevantes para explicar y predecir el rendimiento académico. Para evitar el uso excesivo de variables y reducir el riesgo de sobreajuste, los autores aplicaron el método **LASSO**, una técnica de regularización que permite seleccionar las variables con mayor capacidad predictiva y reducir la influencia de aquellas que aportan poco al modelo. Luego, mediante modelos de regresión, evaluaron la relación de esas variables con el resultado final del estudiante. Este procedimiento permitió identificar factores significativos, como el desempeño en el examen de prueba, la educación previa del estudiante, la dimensión de elaboración del MSLQ y la visualización de discusiones en foros.

Finalmente, los autores compararon distintos modelos predictivos, desde modelos simples hasta algoritmos más complejos de machine learning, como random forest, XGBoost y máquinas de soporte vectorial. La evaluación se realizó mediante métricas de precisión para clasificación y métricas de error para regresión, como RMSE, MAE y ME. A partir de esta comparación, comprobaron que un modelo lineal simple, basado principalmente en el examen de prueba y la educación previa, podía superar o igualar el rendimiento de modelos más complejos. De esta manera, el proceso permitió demostrar que, en escenarios educativos con cambios de contexto y datos limitados, los modelos simples, explicables y con pocas variables pueden ser más adecuados para la predicción temprana del rendimiento estudiantil.

Proceso para resolver el problema

Para resolver el problema de la predicción temprana del rendimiento académico en presencia de cambios en el comportamiento estudiantil, los autores plantearon un procedimiento orientado a evaluar qué tipo de modelo podía ofrecer mejores resultados en un contexto educativo real. El problema central era que muchos sistemas predictivos en educación utilizan grandes cantidades de variables y algoritmos complejos, pero pueden perder precisión cuando las condiciones del curso cambian. Por ello, los autores buscaron comprobar si modelos más simples y explicables podían ser una mejor alternativa frente a modelos avanzados de machine learning cuando existe **concept drift** o **covariate drift**.

El primer paso para resolver este problema fue definir claramente el escenario de estudio. Los autores trabajaron con datos de estudiantes de primer año de enfermería en un curso introductorio de fisiología. La predicción debía realizarse de forma temprana, aproximadamente a mitad del semestre, para que los docentes todavía pudieran intervenir antes del examen final. Esta decisión fue fundamental, porque el objetivo no era solo predecir una nota, sino identificar con anticipación a los estudiantes que podían estar en riesgo académico y ofrecerles apoyo oportuno.

Luego, los autores recopilaron y organizaron información proveniente de distintas fuentes. Incluyeron datos del perfil del estudiante, como su formación educativa previa; respuestas al cuestionario MSLQ, relacionado con motivación y estrategias de aprendizaje; registros del LMS Moodle, como visualización de materiales, participación en foros, intentos de cuestionarios y días de actividad; y resultados de un examen de prueba realizado a mitad del semestre. Esta combinación permitió abordar el problema desde una visión amplia, considerando tanto el comportamiento digital como las características académicas y personales del estudiante.

Después, los autores analizaron si los datos presentaban cambios entre los años académicos. Compararon los periodos de enseñanza durante la pandemia de Covid-19 con el periodo posterior. En esta etapa identificaron que los estudiantes del año 2022-2023 fueron menos activos en la plataforma durante las primeras semanas y participaron menos en el examen de

prueba. Además, observaron que algunas relaciones entre las variables y el rendimiento final también cambiaron. Este análisis permitió confirmar que el problema no era únicamente construir un modelo predictivo, sino construir o seleccionar un modelo capaz de resistir mejor los cambios de contexto.

Para enfrentar el riesgo de usar demasiadas variables, los autores aplicaron el método LASSO, que permite reducir el número de predictores y seleccionar aquellos que tienen mayor relación con el rendimiento académico. Con este procedimiento se buscó evitar el sobreajuste, es decir, que el modelo aprendiera patrones demasiado específicos del conjunto de entrenamiento y luego fallara al aplicarse a estudiantes de otro año. Esta etapa fue clave porque permitió identificar variables más estables y relevantes, como el resultado del examen de prueba, el tipo de educación secundaria previa, la dimensión de elaboración del MSLQ y la visualización de discusiones en foros.

Finalmente, los autores resolvieron el problema comparando el desempeño de diferentes modelos. Evaluaron modelos simples, como regresión lineal y logística, y modelos más complejos, como random forest, XGBoost y máquinas de soporte vectorial. Los resultados mostraron que los modelos complejos no necesariamente ofrecían mejores predicciones y, en algunos casos, presentaban sesgos importantes, especialmente al subestimar el rendimiento de ciertos estudiantes. En cambio, un modelo simple basado en el examen de prueba y la educación previa logró un desempeño más estable y útil. Así, el problema se resolvió demostrando que, en contextos educativos con cambios de comportamiento y datos limitados, la mejor solución no siempre es aumentar la complejidad del algoritmo, sino utilizar modelos explicables, robustos y pedagógicamente aplicables.

Métricas y resultados

Para evaluar el rendimiento de los modelos predictivos, los autores utilizaron métricas tanto para regresión como para clasificación. En el caso de la regresión, se emplearon el **RMSE** —raíz del error cuadrático medio—, el **MAE** —error absoluto medio— y el **ME** —error medio—, con el propósito de medir la diferencia entre la calificación real y la calificación estimada por cada modelo. Para la clasificación, se utilizaron **accuracy**, **precision** y **recall**, ya que el objetivo era clasificar a los estudiantes en tres niveles de rendimiento: bajo, medio y alto. Estas métricas permitieron comparar modelos simples, como regresión lineal, con modelos más complejos de machine learning, como random forest, XGBoost y máquinas de soporte vectorial.

Los resultados mostraron que los modelos más complejos no necesariamente lograron mejores predicciones. El modelo lineal que utilizó únicamente el resultado del examen de prueba y la variable de educación general previa obtuvo un **RMSE de 3.75**, un **MAE de 3.12** y una **accuracy de 0.55**, siendo uno de los modelos con mejor desempeño general. Además, alcanzó un **recall de 0.72 para identificar estudiantes con bajo rendimiento**, lo cual es importante para sistemas de alerta temprana. En comparación, algunos modelos complejos presentaron mayor sesgo y menor estabilidad; por ejemplo, XGBoost obtuvo un RMSE de 6.73 y random forest sin selección previa alcanzó una accuracy de 0.40. En conjunto, los resultados evidencian que, ante cambios en el comportamiento estudiantil, los modelos simples y explicables pueden ser más precisos, menos sesgados y más útiles para la intervención educativa.

Observaciones/críticas

Una observación importante del estudio es que los autores demuestran con claridad que los modelos predictivos complejos no siempre son la mejor opción en contextos educativos reales. El artículo resulta valioso porque cuestiona la dependencia excesiva de algoritmos avanzados y grandes conjuntos de variables, mostrando que un modelo simple, basado en pocas características relevantes, puede ser más estable, explicable y útil para los docentes. Además, el trabajo destaca un problema muy pertinente: los cambios en el comportamiento estudiantil

entre distintos periodos académicos, especialmente antes y después de la pandemia, pueden afectar la precisión de los modelos predictivos. Esta perspectiva es relevante porque muchas investigaciones educativas prueban sus modelos en condiciones controladas, pero no siempre consideran cómo cambian los estudiantes, los cursos y las metodologías con el tiempo.

Sin embargo, también existen algunas limitaciones que deben considerarse. La principal crítica es que el estudio se realizó en un solo curso de fisiología con estudiantes de enfermería, por lo que sus resultados no pueden generalizarse completamente a otras carreras, asignaturas o instituciones. Además, el tamaño de la muestra fue relativamente limitado, lo cual puede influir en el desempeño de los modelos complejos y favorecer a los modelos más simples. Otra limitación es que el estudio se enfoca principalmente en datos registrados en la plataforma virtual, pero no incluye con suficiente detalle las actividades de aprendizaje fuera del LMS, como lectura de apuntes, estudio autónomo, trabajo grupal presencial o uso de materiales externos. A pesar de estas limitaciones, el artículo ofrece un aporte sólido, ya que resalta la necesidad de usar modelos interpretables, prudentes y pedagógicamente útiles para apoyar la toma de decisiones en la educación superior.

23. ARTÍCULO 23

Author (s): Dimitrios E. Tzimas; Stavros N. Demetriadis.

Title of paper: *Impact of Learning Analytics Guidance on Student Self-Regulated Learning Skills, Performance, and Satisfaction: A Mixed Methods Study.*

Journal: *Education Sciences.*

Volume (issue): 14(1).

pag – pag (year): 1–18 (2024).

Estado del arte

El estudio sobre **Learning Analytics** o analítica del aprendizaje se ha consolidado como una línea de investigación importante dentro de la educación superior, especialmente porque permite recopilar, procesar y visualizar datos generados por los estudiantes en entornos digitales de aprendizaje. Esta área busca comprender mejor el comportamiento académico del alumno y optimizar las condiciones en las que ocurre el aprendizaje. En el artículo revisado, los autores explican que la analítica del aprendizaje integra conocimientos de informática, diseño y educación, y se relaciona con la minería de grandes volúmenes de datos educativos para ofrecer información útil tanto a docentes como a estudiantes.

El estado actual de la investigación muestra que las instituciones de educación superior han comenzado a utilizar técnicas basadas en Learning Analytics para mejorar la retención estudiantil, apoyar trayectorias académicas complejas y utilizar de manera más eficiente los recursos educativos. Sin embargo, a pesar de sus avances, los autores señalan que la analítica del aprendizaje todavía no logra responder plenamente a las necesidades de los docentes, debido a que muchas herramientas ofrecen datos o visualizaciones, pero no siempre entregan recomendaciones claras y accionables para mejorar el aprendizaje. En otras palabras, existe una tendencia a centrarse más en el análisis de datos que en el proceso educativo mismo.

Dentro de este contexto, una parte importante de la literatura se ha enfocado en estudiar cómo la analítica del aprendizaje puede influir en el rendimiento académico, la satisfacción estudiantil y las habilidades de autorregulación del aprendizaje. La autorregulación del aprendizaje, conocida como **Self-Regulated Learning** o SRL, hace referencia a la capacidad del estudiante para planificar, monitorear y evaluar su propio proceso de aprendizaje. Esta habilidad incluye aspectos como la gestión del tiempo, la persistencia, la búsqueda de ayuda, la reflexión metacognitiva y la organización del entorno de estudio. Según los autores, la relación entre Learning Analytics y SRL resulta especialmente relevante porque los datos educativos pueden

ayudar al estudiante a tomar conciencia de su desempeño y ajustar sus estrategias de aprendizaje.

Asimismo, la literatura revisada por los autores plantea una discusión importante sobre el nivel de guía docente que debe acompañar el uso de Learning Analytics. Algunos enfoques sostienen que los estudiantes pueden beneficiarse de una guía mínima, basada principalmente en la entrega de calificaciones, estadísticas y comparaciones de rendimiento. Sin embargo, otros estudios defienden la necesidad de una guía fuerte o explícita, en la que el docente no solo presenta datos, sino que también orienta al estudiante mediante mensajes personalizados, entrevistas, retroalimentación y recomendaciones concretas. Esta discusión es fundamental porque el simple acceso a datos no garantiza que el estudiante sepa interpretarlos o utilizarlos para mejorar su aprendizaje.

El artículo de Tzimas y Demetriadis se ubica precisamente en esta línea de debate, al comparar el impacto de una guía mínima y una guía fuerte basada en Learning Analytics. La guía mínima se limita a informar a los estudiantes sobre sus notas y estadísticas, mientras que la guía fuerte incluye mensajes personalizados mediante indicadores tipo semáforo, retroalimentación basada en desempeño y participación, además de entrevistas en línea con el docente para promover la autoevaluación. Esta comparación representa un aporte importante dentro del estado del arte, porque permite analizar si la analítica del aprendizaje funciona mejor cuando se combina con una intervención pedagógica más activa.

Otro aspecto relevante del estado del arte es que los estudios previos han mostrado resultados diversos sobre el impacto de Learning Analytics en el aprendizaje. Algunas investigaciones reportan mejoras en el rendimiento académico y en la permanencia de los estudiantes, mientras que otras encuentran efectos limitados. Por ello, los autores consideran necesario seguir investigando bajo diseños metodológicos más completos, capaces de integrar datos cuantitativos y cualitativos. En este caso, el estudio utiliza un enfoque de métodos mixtos, lo que permite medir el rendimiento y las habilidades de autorregulación, pero también conocer las percepciones, emociones y satisfacción de los estudiantes frente al uso de la analítica del aprendizaje.

En síntesis, el estado del arte evidencia que Learning Analytics posee un gran potencial para mejorar los procesos educativos, pero su efectividad depende de cómo se utilicen los datos y del tipo de acompañamiento docente que se brinde. El artículo muestra que no basta con entregar información estadística al estudiante; es necesario convertir esos datos en orientación pedagógica comprensible, personalizada y útil. Por ello, la investigación aporta al debate actual al demostrar que una guía fuerte basada en Learning Analytics puede favorecer el rendimiento académico, fortalecer habilidades de autorregulación y generar una experiencia de aprendizaje más satisfactoria para los estudiantes.

Motivación del autor

La motivación principal de los autores surge de la necesidad de mejorar el uso de **Learning Analytics** en la educación superior, ya que, aunque esta herramienta permite recopilar y visualizar datos sobre el aprendizaje de los estudiantes, muchas veces no ofrece orientaciones suficientemente claras para que docentes y alumnos puedan tomar decisiones concretas. Los autores consideran que la analítica del aprendizaje no debe limitarse a mostrar estadísticas, calificaciones o comparaciones, sino que debe transformarse en una estrategia pedagógica capaz de apoyar realmente el proceso de aprendizaje.

Asimismo, los autores se motivan por investigar cómo el nivel de guía docente influye en los resultados académicos y en las habilidades de autorregulación del estudiante. En el artículo se plantea una comparación entre la guía mínima, basada principalmente en notas y estadísticas, y la guía fuerte, que incluye mensajes personalizados, indicadores tipo semáforo y entrevistas en

línea para promover la autoevaluación. Esta comparación nace de una preocupación concreta: muchos estudiantes reciben información sobre su desempeño, pero no siempre saben interpretarla ni convertirla en acciones para mejorar.

Por ello, el estudio busca comprobar si una intervención más activa del docente, apoyada en Learning Analytics, puede generar mejores resultados que una orientación mínima. La motivación también se relaciona con fortalecer habilidades como la gestión del tiempo, la persistencia, la búsqueda de ayuda y la reflexión metacognitiva. En ese sentido, los autores no solo desean medir el rendimiento académico, sino también comprender la satisfacción y percepción de los estudiantes frente a este tipo de acompañamiento.

Descripción del aporte del autor

El aporte principal de Dimitrios E. Tzimas y Stavros N. Demetriadis en el artículo **“Impact of Learning Analytics Guidance on Student Self-Regulated Learning Skills, Performance, and Satisfaction: A Mixed Methods Study”** consiste en demostrar que la analítica del aprendizaje, cuando se combina con una guía docente fuerte y personalizada, puede generar mejores resultados en el rendimiento académico, en las habilidades de autorregulación y en la satisfacción de los estudiantes. El estudio no se limita a observar el uso de datos educativos, sino que analiza cómo esos datos pueden convertirse en una orientación pedagógica útil para que el estudiante comprenda su desempeño, reflexione sobre sus hábitos de estudio y tome decisiones para mejorar su aprendizaje.

Uno de los aportes más relevantes del artículo es que cuestiona una de las principales limitaciones de la analítica del aprendizaje: muchas veces se enfoca demasiado en la recopilación, procesamiento y visualización de datos, pero no siempre ofrece recomendaciones claras y aplicables para mejorar el aprendizaje. Los autores señalan que Learning Analytics ha contribuido a identificar patrones de comportamiento estudiantil y a construir modelos predictivos; sin embargo, todavía no satisface completamente las necesidades docentes porque suele brindar información más técnica que pedagógica. Por ello, el aporte del estudio consiste en desplazar el enfoque desde una visión centrada únicamente en los datos hacia una visión centrada en la acción educativa.

El artículo también aporta al comparar dos formas de intervención basadas en Learning Analytics: la **guía mínima** y la **guía fuerte**. La guía mínima se caracteriza por entregar información básica al estudiante, como calificaciones, estadísticas, notas promedio, duración de ejercicios y comparaciones generales. En cambio, la guía fuerte incluye una intervención más personalizada, en la cual el docente utiliza indicadores tipo semáforo, mensajes de alerta, retroalimentación basada en desempeño y participación, además de entrevistas en línea para promover la autoevaluación del estudiante. Esta comparación es valiosa porque permite determinar si basta con mostrar datos al alumno o si es necesario acompañarlo en la interpretación de esa información.

Otro aporte importante es que los autores relacionan Learning Analytics con el desarrollo de habilidades de **aprendizaje autorregulado** o **Self-Regulated Learning**. Estas habilidades son fundamentales en la educación superior, especialmente en entornos virtuales o semivirtuales, porque el estudiante necesita planificar su tiempo, controlar su avance, persistir frente a las dificultades, buscar ayuda cuando la necesita y reflexionar sobre sus estrategias de aprendizaje. En este sentido, el artículo aporta una mirada pedagógica más completa: no solo interesa que el estudiante obtenga mejores calificaciones, sino que aprenda a gestionar su propio proceso formativo.

El estudio contribuye también desde el punto de vista metodológico, ya que utiliza un enfoque de **métodos mixtos**. Esto significa que los autores no se basan únicamente en datos cuantitativos, como notas finales o cuestionarios, sino que también incorporan datos

cualitativos obtenidos mediante encuestas de opinión, entrevistas semiestructuradas y análisis temático. Esta combinación permite comprender el fenómeno de manera más profunda, porque mide los resultados académicos y, al mismo tiempo, recoge las percepciones, emociones y experiencias de los estudiantes frente al uso de Learning Analytics. Por lo tanto, el aporte metodológico del artículo está en ofrecer una evaluación más integral de la intervención educativa.

En cuanto al diseño de la investigación, los autores realizaron el estudio en un curso universitario de pregrado de 13 semanas, desarrollado en modalidad en línea durante la pandemia de COVID-19. Participaron inicialmente 110 estudiantes, aunque finalmente el análisis se realizó con 93 participantes: 47 en el grupo experimental, que recibió guía fuerte basada en Learning Analytics, y 46 en el grupo de control, que recibió guía mínima. Esta organización permitió comparar dos condiciones distintas bajo un mismo contexto educativo, lo cual fortalece la validez del aporte porque muestra diferencias asociadas al nivel de guía recibido por los estudiantes.

Un aporte central del artículo se encuentra en los resultados relacionados con el rendimiento académico. Los autores encontraron que el grupo experimental obtuvo una media final más alta que el grupo de control. En concreto, el grupo con guía fuerte alcanzó una media de 7.22, mientras que el grupo con guía mínima obtuvo una media de 5.28. Además, la diferencia fue estadísticamente significativa. Este resultado permite afirmar que la guía fuerte apoyada en Learning Analytics tuvo un efecto positivo en el desempeño académico de los estudiantes. De esta manera, el estudio demuestra que no basta con disponer de datos educativos; es necesario convertirlos en orientación clara, oportuna y personalizada.

El artículo también aporta evidencia sobre el desarrollo de habilidades de autorregulación. Antes de la intervención, ambos grupos presentaban niveles similares en sus habilidades de autorregulación, lo cual permitía realizar una comparación justa. Después de la intervención, los estudiantes del grupo experimental mostraron mejoras significativas en varias dimensiones: actividades metacognitivas antes y después del aprendizaje, gestión del tiempo, persistencia y búsqueda de ayuda. Esto demuestra que la guía fuerte no solo mejora el resultado final del curso, sino también la forma en que el estudiante organiza y conduce su aprendizaje.

Este aporte es especialmente importante porque las habilidades de autorregulación tienen valor más allá de una asignatura específica. Un estudiante que aprende a planificar, reflexionar, persistir y pedir apoyo desarrolla capacidades que pueden beneficiarlo en otros cursos y en su vida académica futura. Por ello, el estudio no debe interpretarse únicamente como una investigación sobre tecnología educativa, sino también como una propuesta para fortalecer la autonomía estudiantil mediante una orientación docente más activa.

Otro aporte significativo del artículo se relaciona con la satisfacción de los estudiantes. Los resultados cualitativos muestran que los estudiantes tuvieron una percepción favorable sobre la intervención basada en Learning Analytics. Muchos consideraron que la analítica fue útil, comprensible, motivadora y valiosa para tomar conciencia de su avance en el curso. Incluso algunos manifestaron que les gustaría que este tipo de orientación se aplicara en otras asignaturas. Esto evidencia que, cuando la analítica del aprendizaje se presenta de forma clara y acompañada por el docente, puede generar una experiencia positiva y aumentar el compromiso del estudiante.

Además, los autores aportan una visión equilibrada al reconocer que Learning Analytics también puede producir emociones negativas en algunos estudiantes, como ansiedad, estrés o irritabilidad. Esta observación es importante porque evita presentar la tecnología como una solución perfecta. La comparación con otros compañeros, las alertas de bajo rendimiento o la visualización de resultados deficientes pueden generar presión emocional. Sin embargo, el estudio muestra que, cuando existe acompañamiento docente, estas emociones pueden

transformarse en motivación, conciencia y cambio de comportamiento. Por tanto, el artículo aporta una reflexión ética y humana sobre el uso de datos educativos.

Otro elemento valioso del aporte de los autores es la propuesta de intervención basada en el patrón **hacer, analizar, cambiar y reflexionar**. Este diseño permite que el estudiante no solo reciba información, sino que participe activamente en un proceso de mejora. Primero realiza actividades académicas; luego analiza sus resultados mediante la información proporcionada por la plataforma; después cambia sus hábitos o estrategias con apoyo del docente; y finalmente reflexiona sobre su experiencia. Este ciclo convierte la analítica del aprendizaje en una herramienta de formación y no solo en un sistema de monitoreo.

Asimismo, el artículo aporta al destacar el papel del docente como mediador entre los datos y el aprendizaje. La guía fuerte demuestra que el profesor sigue siendo una figura esencial, incluso cuando se utilizan plataformas digitales y sistemas de analítica. Los datos por sí solos no educan; necesitan ser interpretados, explicados y transformados en acciones pedagógicas. En ese sentido, los autores reivindican la importancia de la intervención docente en un contexto donde muchas veces se piensa que la tecnología puede reemplazar el acompañamiento humano.

Finalmente, el aporte general del artículo consiste en mostrar que la analítica del aprendizaje puede ser más efectiva cuando se utiliza con una intención pedagógica clara. La investigación demuestra que la guía fuerte mejora el rendimiento académico, fortalece habilidades de autorregulación y genera satisfacción en los estudiantes. Al mismo tiempo, advierte que la implementación de Learning Analytics debe considerar las emociones, necesidades y percepciones del alumnado. En conclusión, Tzimas y Demetriadis aportan una evidencia sólida de que el verdadero valor de Learning Analytics no está únicamente en recopilar datos, sino en convertir esos datos en orientación significativa para mejorar el aprendizaje universitario.

Proceso para obtener el aporte

El proceso seguido por los autores para obtener su aporte se basó en un diseño de investigación de **métodos mixtos**, combinando información cuantitativa y cualitativa para analizar el impacto de la guía basada en **Learning Analytics** en estudiantes universitarios. Este enfoque permitió estudiar no solo los resultados académicos, sino también las habilidades de autorregulación, la satisfacción y las percepciones de los estudiantes. De esta manera, los autores no se limitaron a medir calificaciones, sino que buscaron comprender cómo la orientación docente apoyada en datos podía influir en el proceso completo de aprendizaje.

En primer lugar, los autores plantearon como objetivo evaluar si una guía mínima y una guía fuerte basadas en Learning Analytics tenían el mismo impacto en el rendimiento académico y en las habilidades de aprendizaje autorregulado. Para ello, formularon dos preguntas de investigación: la primera buscó determinar si ambos tipos de guía influían de la misma manera en el desempeño y las habilidades SRL; la segunda se enfocó en conocer las percepciones y satisfacción de los estudiantes frente a la guía basada en analítica del aprendizaje.

Luego, se diseñó una intervención educativa en un curso universitario de pregrado de 13 semanas, desarrollado en modalidad en línea. Participaron inicialmente 110 estudiantes, aunque finalmente 93 formaron parte del estudio: 47 en el grupo experimental y 46 en el grupo de control. El grupo experimental recibió **guía fuerte**, mientras que el grupo de control recibió **guía mínima**. Esta división permitió comparar dos formas de acompañamiento bajo condiciones similares. La guía mínima consistió en informar a los estudiantes sobre sus notas y estadísticas generales; en cambio, la guía fuerte incluyó mensajes personalizados, indicadores tipo semáforo y entrevistas en línea con el docente para promover la autoevaluación.

Durante el curso, los autores aplicaron un diseño de aprendizaje basado en el ciclo **hacer, analizar, cambiar y reflexionar**. Los estudiantes realizaban actividades académicas, luego

revisaban la información obtenida mediante Learning Analytics, posteriormente modificaban sus hábitos o estrategias de estudio con apoyo del docente y, finalmente, reflexionaban sobre su propio proceso de aprendizaje. Este proceso permitió que los datos no fueran simples números o gráficos, sino recursos para tomar decisiones educativas más conscientes.

Para recoger la información cuantitativa, los autores utilizaron datos extraídos del LMS, cuestionarios antes y después de la intervención, y las calificaciones finales del curso. El rendimiento académico fue medido mediante la nota final, compuesta por ejercicios y presentación del trabajo semestral. Las habilidades de autorregulación fueron evaluadas con el cuestionario **SOL-Q-R**, compuesto por 42 preguntas relacionadas con estrategias como actividades metacognitivas, gestión del tiempo, estructuración del ambiente, persistencia y búsqueda de ayuda .

En cuanto a la información cualitativa, los autores aplicaron encuestas de opinión, sondeos e entrevistas semiestructuradas para conocer la experiencia de los estudiantes con Learning Analytics. Estas respuestas fueron analizadas mediante análisis de contenido y análisis temático, lo cual permitió identificar patrones relacionados con motivación, satisfacción, cambio de comportamiento, búsqueda de ayuda, persistencia y manejo del tiempo. Así, el aporte fue obtenido mediante una triangulación de datos que integró resultados estadísticos y percepciones estudiantiles.

Finalmente, los autores analizaron los datos cuantitativos mediante pruebas estadísticas como t-test y ANCOVA, utilizando un nivel de significancia de $p = 0.05$. Los resultados demostraron que la guía fuerte tuvo mejores efectos que la guía mínima en el rendimiento académico y en varias habilidades de autorregulación. Por tanto, el aporte del artículo fue construido a partir de un proceso ordenado, comparativo y empírico, que permitió demostrar que Learning Analytics tiene mayor valor educativo cuando se acompaña de una intervención docente personalizada y reflexiva.

Proceso para resolver el problema

El proceso para resolver el problema planteado en el artículo parte de una dificultad central en el uso de **Learning Analytics**: aunque esta herramienta permite recopilar, analizar y visualizar datos sobre los estudiantes, muchas veces no logra traducir esa información en acciones pedagógicas concretas. Es decir, los docentes y alumnos pueden tener acceso a calificaciones, estadísticas o indicadores de participación, pero eso no siempre significa que sepan cómo utilizar esos datos para mejorar el aprendizaje. Frente a esta limitación, los autores proponen comparar dos formas de acompañamiento: una **guía mínima**, basada principalmente en información estadística, y una **guía fuerte**, centrada en una intervención docente más personalizada.

Para abordar el problema, los autores diseñaron una investigación aplicada en un curso universitario en línea de 13 semanas. Los estudiantes fueron organizados en dos grupos: el grupo de control recibió guía mínima, mientras que el grupo experimental recibió guía fuerte basada en Learning Analytics. Esta comparación permitió evaluar si el grado de orientación docente generaba diferencias en el rendimiento académico, en las habilidades de autorregulación del aprendizaje y en la satisfacción de los estudiantes. De esta manera, el problema no se resolvió únicamente observando datos, sino mediante una intervención educativa estructurada y comparativa.

La guía mínima consistió en proporcionar a los estudiantes información sobre sus calificaciones y estadísticas generales, como notas máximas, mínimas, promedio y duración de los ejercicios. En cambio, la guía fuerte incluyó una intervención más completa: mensajes personalizados con indicadores tipo semáforo —rojo, amarillo y verde— para señalar el nivel de desempeño y participación, recomendaciones para mejorar hábitos de estudio y entrevistas en línea con el

docente para promover la autoevaluación. Este procedimiento fue importante porque ayudó a transformar los datos en orientaciones comprensibles y accionables para el estudiante.

El proceso también siguió un diseño pedagógico basado en el ciclo **hacer, analizar, cambiar y reflexionar**. Primero, los estudiantes realizaban actividades académicas dentro del curso. Luego, revisaban los datos generados por la plataforma y analizaban su desempeño. Después, con base en la retroalimentación recibida, modificaban sus estrategias de estudio, como organizar mejor el tiempo, pedir ayuda o aumentar la persistencia. Finalmente, reflexionaban sobre sus avances y dificultades. Este ciclo permitió que Learning Analytics no funcionara solo como una herramienta de monitoreo, sino como un recurso para mejorar la toma de decisiones durante el aprendizaje.

Para comprobar si el problema estaba siendo resuelto, los autores midieron tres aspectos principales: rendimiento académico, habilidades de autorregulación y satisfacción estudiantil. El rendimiento se evaluó mediante la nota final del curso; las habilidades de autorregulación se midieron con el cuestionario SOL-Q-R antes y después de la intervención; y la satisfacción se analizó mediante encuestas, sondeos e entrevistas. Además, se utilizaron pruebas estadísticas como t-test y ANCOVA para comparar los resultados entre ambos grupos. Esta combinación de datos cuantitativos y cualitativos permitió obtener una visión más completa del impacto de la intervención.

Los resultados mostraron que la guía fuerte fue más efectiva que la guía mínima. El grupo experimental obtuvo mejores calificaciones finales y presentó mejoras significativas en habilidades como actividades metacognitivas antes y después del aprendizaje, gestión del tiempo, persistencia y búsqueda de ayuda. Además, los estudiantes expresaron una percepción positiva hacia la guía basada en Learning Analytics, señalando que les ayudó a tomar conciencia de su desempeño, motivarse y cambiar sus hábitos de estudio. Por ello, el proceso de solución demuestra que el problema no se resuelve solo con entregar datos, sino con acompañamiento docente, interpretación adecuada y retroalimentación orientada a la acción.

Métricas y resultados

En el artículo, las métricas principales se orientan a evaluar tres aspectos: **rendimiento académico, habilidades de aprendizaje autorregulado y satisfacción estudiantil**. El rendimiento fue medido mediante la nota final del curso, considerando ejercicios y presentación del trabajo semestral. Las habilidades de autorregulación se evaluaron con el cuestionario **SOL-Q-R**, aplicado antes y después de la intervención, el cual analiza dimensiones como actividades metacognitivas, gestión del tiempo, estructuración del ambiente, persistencia y búsqueda de ayuda. Además, la satisfacción fue medida mediante encuestas de opinión, sondeos y entrevistas a los estudiantes.

Los resultados cuantitativos demostraron que el grupo experimental, que recibió **guía fuerte basada en Learning Analytics**, obtuvo mejores resultados que el grupo de control, que recibió guía mínima. En rendimiento académico, el grupo experimental alcanzó una media de **7.22**, mientras que el grupo de control obtuvo **5.28**, con una diferencia estadísticamente significativa ($p = 0.007$). También se encontraron mejoras significativas en varias habilidades de autorregulación, especialmente en actividades metacognitivas antes y después del aprendizaje, gestión del tiempo, persistencia y búsqueda de ayuda.

Respecto a la satisfacción, los estudiantes valoraron positivamente la intervención. La analítica del aprendizaje fue considerada útil, comprensible, motivadora y favorable para tomar conciencia del propio desempeño. En general, los resultados muestran que **Learning Analytics** tiene mayor impacto cuando no se limita a mostrar datos, sino cuando se acompaña de una orientación docente personalizada que ayuda al estudiante a interpretar la información y mejorar sus hábitos de estudio.

Observaciones/críticas

Una observación importante sobre el artículo es que presenta un aporte sólido al demostrar que **Learning Analytics** puede mejorar el rendimiento académico y las habilidades de autorregulación cuando se acompaña de una guía docente fuerte. Sin embargo, una limitación del estudio es que fue aplicado en un solo curso universitario, durante un semestre y en un contexto específico de educación superior en línea. Por ello, aunque los resultados son positivos, no necesariamente pueden generalizarse de manera directa a otros niveles educativos, carreras, modalidades o instituciones.

Otra crítica relevante es el tamaño de la muestra. Aunque participaron 93 estudiantes, los propios autores reconocen que la cantidad no fue suficientemente amplia y que los datos pertenecen a una asignatura concreta. Además, el sistema LMS solo registró una parte de las actividades de aprendizaje, por lo que pudieron quedar fuera otros factores personales, sociales o académicos que también influyen en el rendimiento estudiantil. Esto significa que los resultados deben interpretarse con cautela.

También se debe considerar que el uso de Learning Analytics puede generar efectos emocionales negativos en algunos estudiantes. El artículo muestra que, aunque muchos alumnos se sintieron motivados y satisfechos, otros experimentaron ansiedad, estrés, irritabilidad o incomodidad al comparar su desempeño con el de sus compañeros. Por ello, la analítica del aprendizaje debe aplicarse con cuidado, evitando que los datos se conviertan en una forma de presión excesiva.

A pesar de estas limitaciones, el artículo es valioso porque resalta que los datos educativos no son suficientes por sí solos. Su principal fortaleza está en demostrar que la tecnología necesita acompañamiento docente, interpretación pedagógica y retroalimentación personalizada para convertirse en una verdadera herramienta de mejora del aprendizaje.

24. ARTÍCULO 24

Author (s): Mohd Fazil; Angelica Rísquez; Claire Halpin

Title of paper: A Novel Deep Learning Model for Student Performance Prediction Using Engagement Data

Journal: Journal of Learning Analytics

Volume (issue): Volume 11, Issue 2

pag – pag (year): pp. 23–41 (2024)

Estado del arte

La predicción del rendimiento académico estudiantil se ha convertido en una de las áreas más importantes dentro de la analítica del aprendizaje y la minería de datos educativos. Con el crecimiento de los entornos virtuales de aprendizaje —Virtual Learning Environments, VLE—, las instituciones de educación superior han comenzado a disponer de grandes volúmenes de datos generados por la interacción de los estudiantes con plataformas digitales. Estos datos incluyen accesos a materiales, participación en actividades, uso de foros, entrega de tareas, consultas de recursos, resultados de evaluaciones continuas y otros registros que permiten comprender mejor el comportamiento académico del estudiante. En este contexto, la analítica del aprendizaje busca recopilar, analizar e interpretar dicha información para mejorar los entornos educativos, apoyar la toma de decisiones y promover el éxito estudiantil.

La literatura previa ha desarrollado diferentes enfoques para estudiar y predecir el desempeño de los estudiantes. Por un lado, existen investigaciones basadas en análisis estadísticos o exploratorios, cuyo objetivo principal es comprender la relación entre las características del estudiante, su comportamiento en la plataforma y sus resultados académicos. Por otro lado, se

encuentran los estudios de analítica predictiva, orientados a clasificar o anticipar el rendimiento de los estudiantes, especialmente para identificar a quienes están en riesgo de desaprobación, abandonar o presentar bajo desempeño. Estos modelos predictivos son relevantes porque permiten implementar acciones de intervención temprana, ofrecer apoyo académico y diseñar estrategias pedagógicas antes de que el estudiante llegue al final del curso.

Tradicionalmente, muchos estudios han utilizado modelos clásicos de machine learning, como árboles de decisión, máquinas de soporte vectorial, random forest, XGBoost, regresión logística y otros clasificadores. Estos métodos suelen trabajar con características diseñadas manualmente a partir de los datos disponibles, como número de accesos semanales, cantidad de eventos realizados, calificaciones previas, datos sociodemográficos o frecuencia de participación en el VLE. Aunque estos modelos han mostrado buenos resultados, presentan una limitación importante: la construcción manual de variables puede ser lenta, dependiente del contexto y difícil de escalar a diferentes cursos, instituciones o plataformas. Por ello, la investigación reciente ha empezado a explorar modelos más avanzados que puedan aprender representaciones de los estudiantes de manera más automática.

En los últimos años, los modelos de deep learning han ganado importancia en la predicción del rendimiento académico. Redes neuronales artificiales, redes recurrentes, LSTM, CNN y modelos basados en grafos han sido aplicados para capturar patrones complejos en los datos educativos. Estos enfoques son útiles porque permiten procesar información secuencial, temporal y multidimensional, especialmente cuando se analiza cómo cambia la interacción del estudiante a lo largo del semestre. Sin embargo, la literatura aún presenta limitaciones. Muchos modelos de deep learning aplicados a educación han sido relativamente simples, basados en redes neuronales con pocas capas o en una sola secuencia de datos, sin aprovechar completamente componentes avanzados como mecanismos de atención, redes bidireccionales o arquitecturas híbridas que combinen distintos tipos de comportamiento estudiantil.

El artículo analizado se ubica precisamente en esta brecha de investigación. Los autores señalan que los trabajos previos no han modelado de manera suficiente las distintas dimensiones del comportamiento del estudiante en los entornos virtuales. En muchos casos, toda la información del VLE se trata como una única secuencia, lo que puede ocultar patrones importantes relacionados con la frecuencia semanal de interacción, los eventos realizados, la acumulación de actividades y la regularidad diaria o semanal del estudiante. Frente a ello, el estudio propone el modelo **ASIST**, una arquitectura de deep learning basada en redes BiLSTM apiladas, redes convolucionales y mecanismos de atención, diseñada para aprender representaciones más completas del estudiante a partir de datos demográficos, académicos, evaluaciones continuas y diferentes formas de interacción con el VLE.

Un aspecto destacado del estado del arte es la importancia de la predicción temprana. No basta con predecir el resultado final cuando el curso ya terminó; el verdadero valor educativo está en anticipar el riesgo académico durante las primeras semanas, cuando todavía es posible intervenir. Por ello, varios estudios buscan desarrollar modelos capaces de trabajar con información parcial del semestre. En esta línea, el artículo aporta una extensión llamada **ASISTearly**, que utiliza los datos de las primeras siete semanas para predecir el rendimiento posterior. Esta orientación resulta importante porque conecta la innovación técnica con una finalidad pedagógica concreta: apoyar a los estudiantes vulnerables durante el periodo de mayor riesgo de transición universitaria.

En síntesis, el estado actual de la investigación muestra una evolución desde modelos estadísticos y machine learning tradicionales hacia arquitecturas de deep learning más complejas y capaces de procesar datos secuenciales. No obstante, persisten desafíos relacionados con la interpretación de los modelos, la reducción de la ingeniería manual de características, el tratamiento de datos desbalanceados y la aplicación práctica de las predicciones para apoyar al estudiante. El aporte del artículo se encuentra en proponer una

arquitectura más integral, que combina diferentes componentes neuronales para analizar múltiples dimensiones del comportamiento estudiantil y mejorar la predicción de estudiantes de alto rendimiento, rendimiento moderado y en riesgo académico.

Motivación del autor

La motivación principal de los autores nace de la necesidad de mejorar la predicción del rendimiento académico estudiantil mediante el uso de datos generados en los entornos virtuales de aprendizaje. Las plataformas VLE almacenan una gran cantidad de información sobre la interacción de los estudiantes con los recursos educativos, como accesos, eventos, actividades, evaluaciones y participación en el curso. Sin embargo, los autores observan que muchos estudios previos no aprovechan completamente esta riqueza de datos, ya que utilizan modelos tradicionales de machine learning o redes neuronales simples que no capturan adecuadamente las distintas dimensiones del comportamiento estudiantil.

Por ello, los autores buscan proponer un modelo más avanzado y completo que permita representar mejor el comportamiento de los estudiantes y predecir si serán de alto rendimiento, rendimiento moderado o estarán en riesgo académico. Su motivación no es únicamente técnica, sino también educativa: desarrollar una herramienta que facilite la identificación temprana de estudiantes con dificultades, de modo que las instituciones y docentes puedan intervenir oportunamente. En ese sentido, el estudio pretende equilibrar el progreso metodológico en minería de datos educativos con una aplicación práctica en la analítica del aprendizaje, evitando que los datos se usen solo para vigilancia institucional y promoviendo su uso como apoyo real para los estudiantes más vulnerables.

Descripción del aporte del autor

El principal aporte de los autores consiste en proponer y evaluar un modelo novedoso de aprendizaje profundo llamado **ASIST** —*Attention-aware convolutional Stacked BiLSTM*— para la predicción del rendimiento académico estudiantil a partir de datos de compromiso e interacción en entornos virtuales de aprendizaje. Este modelo busca clasificar a los estudiantes en tres categorías: estudiantes de alto rendimiento, estudiantes de rendimiento moderado y estudiantes en riesgo académico. El valor del aporte se encuentra en que no se limita a utilizar una sola fuente de información ni una arquitectura simple de red neuronal, sino que integra diferentes tipos de datos y distintos componentes de deep learning para representar de manera más completa el comportamiento del estudiante.

Uno de los aportes más importantes del artículo es que los autores proponen una arquitectura que analiza el comportamiento estudiantil desde varias dimensiones. En lugar de tratar toda la información del entorno virtual como una única secuencia de datos, ASIST separa el comportamiento del estudiante en diferentes representaciones. Entre ellas se incluyen la información demográfica y académica, el comportamiento de interacción semanal, el comportamiento de eventos semanales, el comportamiento acumulado de eventos, la interacción diaria organizada por semanas y los resultados de evaluaciones continuas. Esta separación permite que el modelo capture patrones más específicos del aprendizaje, ya que no es lo mismo medir cuántas veces ingresa un estudiante a la plataforma que analizar qué tipo de actividades realiza, en qué semanas interactúa más, con qué regularidad lo hace o cómo se desempeña en evaluaciones parciales.

Este enfoque representa una mejora frente a investigaciones anteriores, porque muchos modelos predictivos en analítica del aprendizaje trabajan con características manuales o con representaciones demasiado generales del estudiante. En cambio, ASIST combina una ingeniería de características relativamente sencilla con una arquitectura profunda capaz de aprender representaciones más complejas. Los autores no buscan depender excesivamente de variables elaboradas manualmente, sino diseñar vectores claros y comprensibles que luego son

procesados por componentes neuronales especializados. De esta manera, el estudio intenta equilibrar dos necesidades: por un lado, aprovechar la potencia del deep learning y, por otro, mantener un diseño aplicable a escenarios educativos reales.

Otro aporte central se encuentra en el uso combinado de redes **BiLSTM**, redes **CNN** y mecanismo de **atención**. Las redes BiLSTM permiten procesar información secuencial en dos direcciones, es decir, considerando tanto el contexto anterior como el posterior dentro de una secuencia temporal. Esto es importante porque el comportamiento del estudiante durante el semestre tiene una naturaleza dinámica: sus accesos, eventos y actividades cambian semana a semana. Al utilizar BiLSTM apiladas, el modelo puede aprender patrones temporales más profundos relacionados con la participación del estudiante. Por otro lado, las redes CNN se emplean para analizar la interacción diaria organizada por semanas, permitiendo identificar patrones espaciales o de regularidad entre días y semanas. Finalmente, el mecanismo de atención asigna mayor peso a las características más relevantes, ayudando al modelo a concentrarse en los elementos que aportan más información para la predicción.

La arquitectura del modelo, presentada en la figura 1 del artículo, muestra claramente esta integración. Primero se realiza la preparación y preprocesamiento de los datos; luego se modelan diferentes comportamientos del estudiante; después estos comportamientos son procesados mediante redes BiLSTM y CNN; posteriormente se aplica la capa de atención; y, finalmente, las representaciones codificadas se concatenan con la información de evaluación continua para producir la clasificación mediante una capa softmax. Esta estructura evidencia que el aporte no es solamente aplicar una red neuronal al problema educativo, sino diseñar una arquitectura específica para representar el aprendizaje estudiantil desde múltiples perspectivas.

Asimismo, los autores aportan una evaluación empírica rigurosa utilizando datos reales de una universidad irlandesa, la University of Limerick. El estudio trabajó con tres grandes módulos de primer año pertenecientes a distintas áreas académicas: negocios, ciencias y humanidades, durante cuatro años académicos, desde 2018/19 hasta 2021/22. Los conjuntos de datos incluyeron 1,557 estudiantes en el módulo 1, 2,078 en el módulo 2 y 2,433 en el módulo 3. Esta amplitud de datos fortalece el aporte del artículo, ya que el modelo no se prueba únicamente en un grupo reducido o en un contexto artificial, sino en escenarios educativos reales con cohortes numerosas. Además, los autores transformaron las calificaciones institucionales en tres categorías principales: alto rendimiento, rendimiento moderado y estudiantes en riesgo, lo que permite conectar la predicción con decisiones pedagógicas concretas.

El aporte también se observa en la comparación del modelo ASIST con diferentes métodos de referencia. Los autores evaluaron su propuesta frente a modelos tradicionales de machine learning, como árboles de decisión, random forest, XGBoost y máquinas de soporte vectorial, así como frente a modelos de deep learning más simples, como ANN, LSTM-CNN con atención, BiLSTM-CNN sin atención y una versión simplificada del propio modelo. Esta comparación permite demostrar si la arquitectura propuesta realmente ofrece mejoras frente a alternativas existentes. Los resultados muestran que ASIST obtuvo un rendimiento superior en la mayoría de métricas y conjuntos de datos, especialmente en AUC, una métrica importante cuando los datos están desbalanceados. Esto es relevante porque en educación suele existir una mayor cantidad de estudiantes de rendimiento moderado y una menor proporción de estudiantes de alto rendimiento o en riesgo, lo que puede dificultar la clasificación adecuada.

Un aporte práctico importante del estudio es la extensión del modelo hacia la predicción temprana, llamada **ASISTearly**. La predicción temprana es fundamental porque permite identificar estudiantes en riesgo durante las primeras semanas del curso, cuando todavía es posible intervenir. Si un modelo predice el rendimiento únicamente al final del semestre, su utilidad pedagógica es limitada, porque ya no hay tiempo suficiente para apoyar al estudiante. Por ello, los autores probaron una versión del modelo usando solo los datos de las primeras siete semanas de interacción en el VLE. Los resultados muestran que ASISTearly mantiene un

desempeño competitivo respecto al modelo completo, lo que confirma que es posible anticipar el riesgo académico con información parcial del semestre. Este aporte tiene una implicancia educativa directa: las instituciones podrían usar el modelo para activar protocolos de acompañamiento, tutorías, retroalimentación personalizada o recursos de refuerzo antes de que el bajo rendimiento se consolide.

Además, el artículo contribuye mediante un análisis de ablación del comportamiento, cuyo objetivo fue identificar qué componentes de información tienen mayor impacto en el rendimiento del modelo. Los autores evaluaron qué ocurría al retirar determinadas fuentes de datos, como la información demográfica y académica, la interacción semanal, los eventos semanales, los eventos acumulados, la interacción diaria-semanal y la evaluación continua. Este análisis permitió observar que el conteo de eventos semanales tuvo uno de los mayores impactos en el desempeño de ASIST, mientras que la interacción diaria organizada semanalmente tuvo un efecto menor. Este resultado es valioso porque ayuda a comprender qué dimensiones del comportamiento del estudiante son más informativas para la predicción. No basta con saber que el modelo funciona; también es necesario identificar qué tipos de datos contribuyen más a su rendimiento.

Otro aporte relevante es que el estudio reconoce la importancia de aplicar la analítica del aprendizaje de forma responsable. En la introducción, los autores señalan que la analítica del aprendizaje no debe utilizarse únicamente como un mecanismo de vigilancia institucional, sino como una herramienta para apoyar a los estudiantes, especialmente a los más vulnerables. Esta perspectiva es significativa porque sitúa el desarrollo tecnológico dentro de una finalidad educativa y ética. El modelo predictivo no debe servir solo para clasificar estudiantes, sino para facilitar intervenciones oportunas que mejoren sus oportunidades de éxito académico.

También es importante destacar que los autores aportan evidencia sobre el comportamiento diferenciado de los estudiantes según su nivel de rendimiento. Por ejemplo, en las figuras del artículo se observa que los estudiantes de alto rendimiento suelen presentar mayor frecuencia de interacción semanal y mayor cantidad de eventos en el VLE, mientras que los estudiantes en riesgo muestran niveles más bajos de actividad. La figura 4 muestra diferencias en las interacciones semanales por estudiante, y la figura 5 evidencia diferencias en el conteo semanal de eventos. Estas visualizaciones refuerzan la idea de que los patrones de interacción en plataformas virtuales contienen señales relevantes para anticipar el rendimiento académico.

En conjunto, el aporte de los autores puede resumirse en cuatro dimensiones principales. Primero, presentan un modelo novedoso de deep learning que integra redes BiLSTM, CNN y atención para representar el comportamiento estudiantil. Segundo, modelan la interacción con el VLE desde varias dimensiones, en lugar de reducirla a una sola secuencia o a variables aisladas. Tercero, validan el modelo con datos reales de tres módulos universitarios y lo comparan con modelos tradicionales y redes neuronales más simples. Cuarto, proponen una versión temprana del modelo que puede ser utilizada para apoyar intervenciones académicas durante las primeras semanas del semestre.

En conclusión, el artículo realiza un aporte significativo al campo de la analítica del aprendizaje porque combina innovación metodológica con utilidad educativa. ASIST no solo mejora la predicción del rendimiento estudiantil, sino que también ofrece una forma más completa de representar el comportamiento académico en entornos virtuales. Su valor se encuentra en demostrar que los datos de interacción, cuando son organizados adecuadamente y procesados mediante arquitecturas profundas, pueden contribuir a identificar estudiantes en riesgo y orientar decisiones pedagógicas más oportunas. De esta manera, el estudio fortalece la aplicación de la inteligencia artificial en educación superior, siempre que su uso esté orientado al acompañamiento, la prevención del fracaso académico y la mejora del aprendizaje.

Proceso para obtener el aporte

Para obtener su aporte, los autores desarrollaron un proceso metodológico basado en el diseño, entrenamiento y evaluación de un modelo de aprendizaje profundo para la predicción del rendimiento estudiantil. El estudio se realizó en una universidad irlandesa, específicamente en la **University of Limerick**, utilizando datos reales de tres módulos de primer año pertenecientes a diferentes áreas académicas. Estos datos abarcaron cuatro años académicos, desde 2018/19 hasta 2021/22, e incluyeron información demográfica, académica, registros de interacción con el entorno virtual de aprendizaje —VLE— y resultados de evaluaciones continuas. En total, se trabajó con 1,557 estudiantes en el módulo 1, 2,078 en el módulo 2 y 2,433 en el módulo 3.

El primer paso consistió en preparar los datos. La universidad proporcionó dos fuentes principales: el archivo de registro académico y los archivos de interacción con el VLE. Los autores limpiaron la información, eliminaron registros duplicados, filtraron estudiantes sin calificación final y organizaron los datos por módulo y año académico. Luego, las calificaciones originales de la universidad, que estaban distribuidas en once categorías, fueron agrupadas en tres clases: **alto rendimiento**, **rendimiento moderado** y **estudiantes en riesgo**. Esta transformación fue necesaria para convertir el problema en una tarea de clasificación útil para la intervención educativa.

El segundo paso fue modelar las distintas dimensiones del comportamiento estudiantil. Los autores no trataron toda la información del VLE como una sola variable general, sino que construyeron varias representaciones del estudiante. Se consideró la información demográfica y académica mediante un vector de 15 atributos; el comportamiento de interacción semanal, basado en la cantidad de accesos al VLE por semana; el comportamiento de eventos semanales, que mide la cantidad de actividades realizadas dentro de la plataforma; el conteo acumulado de eventos, que permite observar qué tipos de acciones fueron más frecuentes; y la interacción diaria organizada por semanas, representada como una matriz de 14 semanas por 7 días. Además, se incorporó información de evaluaciones continuas, como exámenes parciales o tareas, por ser un indicador relevante del progreso académico.

El tercer paso fue diseñar la arquitectura del modelo **ASIST**. Para procesar las secuencias temporales, los autores utilizaron redes **BiLSTM apiladas**, capaces de aprender patrones en ambas direcciones del tiempo. Para analizar la interacción diaria-semanal, aplicaron una red **CNN**, adecuada para extraer patrones locales de una estructura tipo matriz. Después, incorporaron un mecanismo de **atención**, cuya función fue asignar mayor peso a las características más importantes para la predicción. Finalmente, las representaciones generadas por las redes neuronales fueron concatenadas junto con la información de evaluación continua y enviadas a una capa densa y una capa softmax, encargada de clasificar al estudiante en una de las tres categorías de rendimiento.

El cuarto paso consistió en entrenar y evaluar el modelo. Los autores utilizaron el 80% de los datos para entrenamiento y el 20% restante para prueba. El modelo fue entrenado durante 50 épocas, con el optimizador Adam, una tasa de aprendizaje de 0.001 y una función de pérdida de entropía cruzada categórica. Para evitar sobreajuste, se aplicó dropout. La evaluación se realizó con cinco métricas: accuracy, precision, recall, fscore y AUC. Además, ASIST fue comparado con modelos tradicionales y de deep learning, como ANN, decision tree, random forest, XGBoost, SVM y versiones modificadas del propio modelo.

Finalmente, los autores realizaron análisis adicionales para fortalecer su aporte. Aplicaron un análisis de ablación para identificar qué componentes del comportamiento estudiantil tenían mayor impacto en el rendimiento del modelo. También desarrollaron una versión de predicción temprana, llamada **ASISTearly**, utilizando solo los datos de las primeras siete semanas del semestre. Este proceso permitió demostrar que el modelo no solo era útil para predecir el rendimiento final, sino también para anticipar el riesgo académico en una etapa donde todavía es posible intervenir pedagógicamente.

Proceso para resolver el problema

Para resolver el problema de la predicción del rendimiento académico estudiantil, los autores partieron de una dificultad central: muchos modelos utilizados en analítica del aprendizaje no aprovechan adecuadamente la riqueza de los datos generados en los entornos virtuales de aprendizaje. En varios estudios previos, la información del estudiante se procesa como una sola secuencia o mediante características diseñadas manualmente, lo que puede limitar la capacidad del modelo para identificar patrones complejos de comportamiento. Frente a ello, los autores propusieron el modelo **ASIST**, diseñado para clasificar a los estudiantes en tres grupos: alto rendimiento, rendimiento moderado y estudiantes en riesgo académico.

El primer paso para resolver el problema fue reunir información real de tres módulos universitarios de primer año en la University of Limerick. Los datos incluyeron registros académicos, información demográfica, resultados de evaluaciones continuas y registros de interacción con el VLE. Esta integración fue necesaria porque el rendimiento académico no depende de una sola variable, sino de varios factores relacionados con el perfil del estudiante, su trayectoria previa, su actividad en la plataforma y su desempeño durante el semestre.

Después, los autores organizaron los datos en representaciones específicas del comportamiento estudiantil. En lugar de usar una única entrada general, dividieron la información en varios componentes: interacción semanal con el VLE, eventos semanales realizados, eventos acumulados, interacción diaria organizada por semanas, información demográfica y académica, y resultados de evaluación continua. Esta estrategia permitió que el modelo analizara no solo cuánto interactúa un estudiante con la plataforma, sino también cuándo lo hace, qué tipo de acciones realiza y cómo evoluciona su participación a lo largo del curso.

Posteriormente, se diseñó una arquitectura profunda capaz de procesar cada dimensión del comportamiento. Las secuencias temporales fueron procesadas mediante redes **BiLSTM apiladas**, porque estas permiten capturar relaciones en ambos sentidos del tiempo. La interacción diaria-semanal fue tratada con una red **CNN**, adecuada para identificar patrones locales entre días y semanas. Luego, se incorporó un mecanismo de **atención**, que asigna mayor importancia a las características más relevantes para la predicción. Finalmente, todas las representaciones aprendidas fueron concatenadas con la información de evaluación continua y enviadas a una capa softmax, encargada de clasificar el rendimiento del estudiante.

Para comprobar si esta solución era efectiva, los autores compararon ASIST con modelos tradicionales y modelos de deep learning más simples, como ANN, decision tree, random forest, XGBoost, SVM, LSTM-CNN y BiLSTM-CNN sin atención. La evaluación se realizó mediante métricas como accuracy, precision, recall, fscore y AUC. Los resultados mostraron que ASIST superó a la mayoría de modelos comparados, especialmente en AUC, lo cual es importante porque los datos estaban desbalanceados. Además, los autores desarrollaron **ASISTearly**, una versión que utiliza únicamente las primeras siete semanas de información, demostrando que el modelo también puede servir para la intervención temprana. Así, el problema se resolvió mediante una arquitectura que combina integración de datos, aprendizaje profundo y predicción oportuna para apoyar decisiones educativas.

Métricas y resultados

Para evaluar el modelo ASIST, los autores utilizaron cinco métricas de clasificación: **accuracy**, **precision**, **recall**, **fscore** y **AUC**. Estas métricas fueron necesarias porque el problema consistía en clasificar a los estudiantes en tres categorías: alto rendimiento, rendimiento moderado y estudiantes en riesgo académico. Además, los conjuntos de datos estaban desbalanceados, ya que había más estudiantes de rendimiento moderado que estudiantes de alto rendimiento o en riesgo; por ello, el **AUC** fue una métrica especialmente importante para medir la capacidad del modelo de distinguir correctamente entre las clases.

Los resultados mostraron que **ASIST superó a la mayoría de los modelos comparados**, incluyendo ANN, decision tree, random forest, XGBoost, SVM y variantes de redes LSTM/BiLSTM. En los tres módulos evaluados, ASIST obtuvo valores de **AUC entre 0.8614 y 0.9040**, lo que evidencia un desempeño sólido. En el módulo 1 alcanzó una accuracy de **0.7519** y AUC de **0.8858**; en el módulo 2 logró el mejor resultado, con accuracy de **0.8245** y AUC de **0.9040**; mientras que en el módulo 3 obtuvo accuracy de **0.7207** y AUC de **0.8614**. Además, la versión temprana **ASISTearly**, usando solo las primeras siete semanas de datos, mantuvo un rendimiento competitivo, con AUC aproximado entre **0.83 y 0.89**. Estos resultados indican que el modelo es útil no solo para predecir el rendimiento final, sino también para apoyar intervenciones tempranas en estudiantes con riesgo académico.

Observaciones/críticas

Una observación importante del artículo es que presenta un aporte metodológico sólido al proponer un modelo avanzado de deep learning para la predicción del rendimiento académico. El modelo ASIST resulta valioso porque no analiza la interacción del estudiante con el entorno virtual de manera general, sino que la divide en diferentes dimensiones, como interacción semanal, eventos semanales, eventos acumulados, interacción diaria-semanal, información académica y evaluación continua. Esta forma de organización permite representar mejor el comportamiento estudiantil y demuestra que los datos generados en los VLE pueden ser útiles para identificar estudiantes en riesgo. Además, la propuesta de **ASISTearly** es especialmente relevante, porque permite realizar predicciones durante las primeras siete semanas del semestre, cuando todavía es posible aplicar intervenciones pedagógicas oportunas.

Sin embargo, también se pueden señalar algunas críticas. En primer lugar, aunque el modelo obtiene buenos resultados, su arquitectura es compleja y puede ser difícil de implementar en instituciones que no cuentan con personal técnico especializado o infraestructura suficiente. En segundo lugar, el uso de modelos profundos puede generar problemas de interpretabilidad, ya que no siempre es sencillo explicar a docentes o estudiantes por qué el sistema clasifica a una persona como estudiante en riesgo. Asimismo, aunque el mecanismo de atención ayuda a identificar características importantes, los autores reconocen que su impacto en el rendimiento fue leve. Otra limitación es que el estudio se realizó en una sola universidad, por lo que sería necesario validar el modelo en otras instituciones, carreras y plataformas virtuales. A pesar de estas limitaciones, el artículo constituye una contribución importante porque combina innovación tecnológica con una finalidad educativa: anticipar dificultades académicas y apoyar el éxito estudiantil.

25. ARTÍCULO 25

Author (s): Gomathy Ramaswami; Teo Susnjak; Anuradha Mathrani.

Title of paper: *Supporting Students' Academic Performance Using Explainable Machine Learning with Automated Prescriptive Analytics.*

Journal: *Big Data and Cognitive Computing.*

Volume (issue): 6(4).

pag – pag (year): 1–13 (2022).

Estado del arte

El estudio sobre el apoyo al rendimiento académico de los estudiantes mediante **Machine Learning explicable y analítica prescriptiva automatizada** se ubica dentro del campo de **Learning Analytics**, una línea de investigación que busca utilizar los datos generados en entornos educativos para mejorar los procesos de enseñanza y aprendizaje. En los últimos años, las instituciones de educación superior han incrementado el uso de plataformas virtuales, sistemas de gestión del aprendizaje y herramientas digitales que registran información sobre la participación, el desempeño y los hábitos de estudio de los alumnos. Esta acumulación de datos

ha permitido desarrollar modelos capaces de describir comportamientos, predecir resultados académicos y, más recientemente, recomendar acciones concretas para mejorar el aprendizaje.

De acuerdo con el artículo revisado, la analítica del aprendizaje ha estado tradicionalmente enfocada en dos niveles principales: la **analítica descriptiva** y la **analítica predictiva**. La primera permite observar datos históricos y actuales para identificar patrones de comportamiento estudiantil, mientras que la segunda emplea algoritmos de Machine Learning para anticipar posibles resultados, como el riesgo de bajo rendimiento o no culminación de un curso. Sin embargo, los autores señalan que estas formas de análisis todavía presentan limitaciones, especialmente porque muchas veces informan al estudiante o al docente sobre una situación de riesgo, pero no explican claramente por qué ocurre ni qué acciones específicas se deben tomar para modificarla.

En este contexto surge la importancia de la **analítica prescriptiva**, considerada un nivel más avanzado dentro de Learning Analytics. A diferencia de la analítica predictiva, que se centra en anticipar lo que podría suceder, la analítica prescriptiva busca sugerir qué se puede hacer para alcanzar un resultado más favorable. En el ámbito educativo, esto significa ofrecer recomendaciones personalizadas a estudiantes que se encuentran en riesgo académico, indicando qué cambios mínimos en su comportamiento o desempeño podrían aumentar la probabilidad de éxito. Por ejemplo, mejorar el puntaje en una próxima evaluación, incrementar la participación en la plataforma virtual o revisar más recursos del curso.

Otro aspecto importante del estado del arte es el problema de los modelos de **caja negra** en Machine Learning. Muchos algoritmos predictivos pueden alcanzar buenos niveles de precisión, pero no explican de manera comprensible cómo llegaron a una determinada clasificación. Esta falta de transparencia puede generar desconfianza en docentes, estudiantes y administradores, especialmente cuando las predicciones afectan decisiones académicas importantes. Por ello, el artículo destaca la relevancia de la **inteligencia artificial explicable** o **Explainable Artificial Intelligence**. Esta área busca que los modelos no solo predigan, sino que también expliquen sus resultados mediante reglas, visualizaciones o argumentos comprensibles para los usuarios.

El trabajo de Ramaswami, Susnjak y Mathrani se inserta en esta discusión al proponer una integración entre Machine Learning explicable y analítica prescriptiva automatizada. Los autores sostienen que los estudios previos en el ámbito educativo se han concentrado principalmente en predecir el rendimiento académico, pero han avanzado poco en explicar las decisiones de los modelos y en generar recomendaciones accionables para los estudiantes. Por ello, su investigación aporta una perspectiva más completa, ya que no solo busca identificar a los estudiantes en alto riesgo, sino también explicar las razones de esa clasificación y sugerir cambios específicos que podrían ayudarlos a mejorar.

Dentro de las técnicas utilizadas en investigaciones recientes, el artículo menciona algoritmos como regresión logística, k-vecinos más cercanos, Random Forest, Naïve Bayes y CatBoost. Estos métodos permiten clasificar a los estudiantes en categorías de bajo o alto riesgo según variables como calificaciones de tareas, desviación respecto al promedio del grupo, nivel de participación en el LMS, recursos visualizados, calificaciones previas, edad, género, ciudadanía, dominio del inglés y modalidad de estudio. De esta manera, el estado del arte muestra que la predicción del rendimiento académico depende de múltiples factores, tanto académicos como conductuales y demográficos.

Asimismo, el artículo incorpora técnicas de explicabilidad como **Anchors** y **SHAP**, que permiten mostrar qué características influyen más en la predicción del modelo. Por ejemplo, una predicción de alto riesgo puede explicarse por bajas calificaciones en tareas y poca participación en la plataforma virtual. Además, se utiliza el enfoque de **contrafactuales** para construir escenarios hipotéticos del tipo “qué pasaría si”, con el objetivo de identificar los

cambios mínimos necesarios para que un estudiante pase de una clasificación de alto riesgo a una de bajo riesgo. Esta aproximación representa un avance significativo porque transforma la predicción en una recomendación práctica y personalizada.

En síntesis, el estado del arte evidencia que Learning Analytics ha evolucionado desde la simple descripción de datos hacia modelos predictivos más complejos, pero todavía enfrenta el desafío de ofrecer explicaciones claras y recomendaciones útiles. El artículo revisado responde a esta necesidad al integrar Machine Learning explicable con analítica prescriptiva automatizada, proponiendo un enfoque más transparente, confiable y orientado a la acción. Su aporte principal dentro del campo es demostrar que los sistemas educativos basados en datos deben ir más allá de señalar problemas: también deben explicar sus causas y orientar al estudiante sobre cómo mejorar su rendimiento académico.

Motivación del autor

La motivación principal de los autores surge de la necesidad de superar las limitaciones de la analítica del aprendizaje tradicional, la cual se ha enfocado mayormente en describir datos y predecir el rendimiento académico, pero no siempre ofrece explicaciones claras ni recomendaciones concretas para los estudiantes. En el artículo, los autores señalan que muchos modelos de Machine Learning funcionan como “cajas negras”, es decir, pueden clasificar a un estudiante como de alto riesgo, pero no explican de forma comprensible por qué se llegó a esa conclusión ni qué acciones debería realizar el estudiante para mejorar su situación académica.

A partir de esta problemática, los autores se motivan por desarrollar un enfoque más transparente, confiable y útil dentro de Learning Analytics. Su interés no es únicamente predecir si un estudiante podría tener bajo rendimiento o no completar un curso, sino también explicar los factores que influyen en esa predicción y generar recomendaciones personalizadas basadas en datos. Por ello, incorporan técnicas de Machine Learning explicable, como Anchors, y analítica prescriptiva mediante contrafactuales, con el fin de transformar los resultados predictivos en sugerencias prácticas.

En ese sentido, la motivación del estudio está orientada a apoyar el rendimiento académico de los estudiantes mediante información clara y accionable. Los autores buscan que el estudiante no solo reciba una alerta de riesgo, sino que comprenda qué aspectos de su comportamiento académico debe modificar, como mejorar sus calificaciones en tareas, aumentar su participación en el LMS o revisar más recursos del curso. Así, el trabajo responde a la necesidad de pasar de una analítica centrada en la predicción a una analítica orientada a la acción y mejora educativa.

Descripción del aporte del autor

El aporte principal de Gomathy Ramaswami, Teo Susnjak y Anuradha Mathrani en el artículo **“Supporting Students’ Academic Performance Using Explainable Machine Learning with Automated Prescriptive Analytics”** consiste en proponer un enfoque más completo para apoyar el rendimiento académico de los estudiantes mediante la integración de tres elementos: **analítica predictiva, Machine Learning explicable y analítica prescriptiva automatizada**. Este aporte es relevante porque la mayoría de investigaciones previas en Learning Analytics se han concentrado en predecir si un estudiante está en riesgo académico, pero pocas han avanzado hacia la explicación clara de esas predicciones y la generación de recomendaciones concretas para mejorar los resultados educativos.

Uno de los aportes más importantes del artículo es que los autores reconocen una limitación frecuente en los sistemas de Machine Learning aplicados a la educación: muchos modelos funcionan como una “caja negra”. Esto significa que pueden clasificar a un estudiante como de alto riesgo o bajo riesgo, pero no explican de manera comprensible cuáles fueron los factores

que llevaron a esa clasificación. En contextos educativos, esta falta de transparencia puede generar desconfianza en docentes y estudiantes, ya que una predicción académica no solo debe ser precisa, sino también entendible y justificable. Por ello, los autores plantean que la analítica del aprendizaje debe avanzar más allá de la simple predicción y ofrecer explicaciones claras sobre el razonamiento del modelo .

El artículo aporta al demostrar cómo las técnicas de **Machine Learning explicable** pueden utilizarse para mostrar las razones detrás de una predicción. Para ello, los autores emplean el método **Anchor**s, una técnica que convierte el razonamiento de un modelo complejo en reglas comprensibles del tipo “si ocurre esto, entonces el estudiante se clasifica de esta manera”. Este procedimiento permite que el estudiante no reciba únicamente una alerta de riesgo, sino que comprenda qué elementos de su desempeño están influyendo en esa alerta. Por ejemplo, una predicción de alto riesgo puede explicarse por bajas calificaciones en tareas, bajo nivel de participación en la plataforma Moodle o pocos recursos revisados. De esta manera, el modelo se vuelve más transparente y útil para la toma de decisiones académicas.

Otro aporte esencial del estudio es la incorporación de la **analítica prescriptiva automatizada**. Mientras que la analítica predictiva responde a la pregunta “¿qué podría pasar?”, la analítica prescriptiva busca responder “¿qué se puede hacer para mejorar el resultado?”. Esta diferencia es fundamental porque, en educación, no basta con decirle a un estudiante que está en riesgo de desaprobación o abandonar un curso. Lo verdaderamente útil es indicarle qué acciones concretas podría realizar para cambiar esa situación. En ese sentido, los autores proponen utilizar modelos contrafactuales, conocidos como escenarios “what-if”, para calcular los cambios mínimos que un estudiante tendría que hacer en sus patrones de comportamiento o desempeño para pasar de una condición de alto riesgo a una de bajo riesgo.

El uso de **contrafactuales** representa un aporte novedoso porque permite transformar una predicción en una recomendación personalizada. Por ejemplo, si un estudiante tiene baja calificación en tareas y poca participación en el LMS, el sistema puede sugerir que aumente su promedio en la próxima actividad y mejore su frecuencia de interacción con la plataforma. Este tipo de recomendación es más útil que una simple advertencia, porque entrega al estudiante una ruta de acción concreta. Así, los autores no solo buscan identificar problemas, sino también orientar soluciones basadas en datos reales.

Asimismo, el artículo aporta un flujo de trabajo analítico que integra distintas etapas: recolección de datos, limpieza, transformación, construcción de modelos, evaluación, explicabilidad del modelo y generación de salidas prescriptivas automatizadas. Este flujo permite pasar de los datos brutos a recomendaciones comprensibles para los estudiantes. Los datos utilizados provienen de un entorno de educación superior e incluyen información del LMS Moodle, calificaciones de evaluaciones, datos del sistema de gestión estudiantil y características demográficas y académicas. Con esta información, los autores construyen modelos capaces de clasificar a los estudiantes en categorías de **alto riesgo** o **bajo riesgo** según su probabilidad de obtener resultados académicos desfavorables.

Otro aporte importante se encuentra en la comparación de distintos algoritmos de Machine Learning. Los autores evaluaron modelos como **Logistic Regression**, **k-Nearest Neighbors**, **Random Forest**, **Naïve Bayes** y **CatBoost**. Esta comparación permitió identificar qué algoritmo ofrecía mejores resultados para la predicción del riesgo académico. Según los resultados del artículo, **CatBoost** fue el modelo con mejor desempeño, alcanzando una precisión aproximada de 75 %, un F-measure de 0.77 y un AUC de 0.87. Este aporte es útil porque muestra que no todos los algoritmos funcionan de la misma manera y que la selección del modelo debe basarse en una evaluación rigurosa.

Además, los autores aportan al analizar la importancia de las variables utilizadas en la predicción. El artículo muestra que algunas de las variables más influyentes fueron el promedio

de calificaciones en cursos previos, el puntaje máximo obtenido en cursos anteriores, la desviación respecto al rendimiento previo, las calificaciones en tareas y el nivel de participación en el LMS. Esto permite comprender que el rendimiento académico actual no depende únicamente de una nota aislada, sino de una combinación de antecedentes académicos, comportamiento en la plataforma y participación en las actividades del curso. Esta identificación de factores relevantes puede ayudar a las instituciones educativas a diseñar mejores estrategias de apoyo estudiantil.

Un aspecto especialmente valioso del aporte de los autores es que su propuesta busca mejorar la confianza en los sistemas de analítica del aprendizaje. Cuando un estudiante recibe una predicción sin explicación, puede sentir que el sistema es injusto, arbitrario o poco confiable. En cambio, cuando la predicción está acompañada de una explicación clara y de una recomendación concreta, el estudiante tiene mayores posibilidades de aceptar la información y actuar sobre ella. Por ello, el artículo aporta una mirada más humana y transparente del uso de inteligencia artificial en educación.

También se debe destacar que el estudio contribuye a la madurez de Learning Analytics. Los autores explican que el campo ha avanzado desde la analítica descriptiva hacia la predictiva, pero todavía necesita fortalecer la analítica prescriptiva. En ese sentido, el artículo representa un paso más avanzado porque no se limita a analizar lo que ocurrió o predecir lo que podría ocurrir, sino que propone acciones específicas para alcanzar un resultado más favorable. Esta orientación es fundamental para que la analítica educativa tenga un impacto real en el aprendizaje.

El aporte práctico del artículo se evidencia en la posibilidad de integrar este enfoque en un **Learning Analytics Dashboard**. Los autores indican que su propuesta forma parte de un tablero de analítica del aprendizaje que se encuentra en proceso de pilotaje en una institución de educación superior. Esto significa que el trabajo no se queda únicamente en una discusión teórica, sino que busca aplicarse en un sistema real capaz de brindar apoyo a estudiantes. Al incluir explicaciones y recomendaciones automatizadas, el tablero puede convertirse en una herramienta de acompañamiento académico más efectiva.

Además, el artículo aporta una forma de personalizar la retroalimentación. En lugar de ofrecer recomendaciones generales para todos los estudiantes, el sistema puede generar sugerencias específicas según el perfil y la situación de cada alumno. Por ejemplo, para un estudiante el problema principal puede ser la baja participación en Moodle, mientras que para otro puede ser el bajo promedio en tareas o el escaso uso de recursos del curso. Esta personalización es importante porque los estudiantes no enfrentan las mismas dificultades y, por tanto, no necesitan las mismas orientaciones.

En términos académicos, el aporte de los autores también está en abrir nuevas líneas de investigación. El artículo plantea que futuras investigaciones deben evaluar la efectividad de estos sistemas en contextos reales, analizar cómo reaccionan los estudiantes ante las recomendaciones automatizadas y estudiar si dichas recomendaciones realmente producen mejoras en el rendimiento final. De esta manera, el trabajo no solo presenta una propuesta tecnológica, sino que invita a seguir investigando sobre la relación entre explicabilidad, confianza, toma de decisiones y mejora del aprendizaje.

Finalmente, el aporte general del artículo puede resumirse en la idea de que la analítica del aprendizaje debe ser **predictiva, explicable y accionable**. Predecir el riesgo académico es importante, pero no suficiente. Explicar por qué existe ese riesgo aumenta la transparencia y la confianza. Recomendar qué acciones realizar permite que el estudiante tenga una oportunidad real de mejorar. Por ello, el artículo de Ramaswami, Susnjak y Mathrani representa una contribución valiosa al campo de la educación basada en datos, porque propone un modelo más completo, comprensible y orientado al apoyo efectivo del estudiante.

Proceso para obtener el aporte

El proceso seguido por los autores para obtener su aporte se basó en el desarrollo de un flujo de trabajo analítico orientado a transformar los datos educativos en predicciones explicables y recomendaciones accionables. En primer lugar, los autores partieron de una problemática concreta dentro de **Learning Analytics**: los modelos tradicionales permiten predecir el riesgo académico de los estudiantes, pero no siempre explican las razones de esa predicción ni ofrecen sugerencias específicas para mejorar. Por ello, el estudio propuso integrar **Machine Learning explicable** y **analítica prescriptiva automatizada** dentro de un mismo proceso.

Para iniciar el trabajo, los autores recopilaron datos de cursos ofrecidos en una institución de educación superior de Australasia, desarrollados en un entorno de aprendizaje combinado. La información fue extraída de diferentes sistemas institucionales: Moodle como sistema de gestión del aprendizaje, el sistema de gestión estudiantil y el sistema de matrícula. Estos datos incluyeron registros de interacción en la plataforma, calificaciones de evaluaciones, información académica previa y variables demográficas como edad, género, ciudadanía, modalidad de estudio y dominio del inglés.

Luego, los datos pasaron por una etapa de limpieza, preprocesamiento y transformación. En esta fase, los autores organizaron la información para convertirla en variables útiles para los modelos predictivos. Entre las características utilizadas estuvieron el puntaje de tareas, la desviación del puntaje de tareas respecto al promedio del grupo, el nivel de participación en el LMS, la desviación de participación en la plataforma, los puntajes de cursos previos y la cantidad de recursos visualizados. Además, se utilizó la estandarización mediante puntajes Z para comparar el desempeño de cada estudiante con el promedio de su cohorte.

Posteriormente, los estudiantes fueron clasificados en dos categorías: **alto riesgo** y **bajo riesgo**. Esta clasificación se realizó tomando como referencia la nota final del curso. Los estudiantes con una calificación igual o menor al 60 % fueron considerados de alto riesgo, mientras que los demás fueron clasificados como de bajo riesgo. A partir de esta definición, los autores construyeron modelos predictivos capaces de anticipar si un estudiante podría presentar dificultades académicas o riesgo de no completar satisfactoriamente el curso.

En la etapa de modelamiento, los autores aplicaron y compararon cinco algoritmos de Machine Learning: **Logistic Regression**, **k-Nearest Neighbors**, **Random Forest**, **Naïve Bayes** y **CatBoost**. Los modelos fueron evaluados con métricas como Accuracy, Precision, Recall, F-measure y AUC. Además, se utilizó una validación cruzada modificada, entrenando los modelos con nueve entregas de cursos y probándolos con una entrega restante. Este proceso permitió comprobar cuál de los algoritmos ofrecía un mejor desempeño predictivo en los datos educativos analizados.

Después de construir los modelos, los autores incorporaron una etapa de explicabilidad. Para ello utilizaron herramientas como **Anchor**s y **SHAP**, que permiten identificar qué variables influyen más en la predicción. Anchor transformó el razonamiento del modelo en reglas comprensibles del tipo “si-entonces”, mientras que SHAP ayuda a visualizar la importancia de cada característica. Esta etapa fue fundamental para que las predicciones no quedaran como resultados de una “caja negra”, sino que pudieran ser entendidas por estudiantes y docentes.

Finalmente, los autores aplicaron analítica prescriptiva mediante **contrafactuales**, usando la herramienta DiCE. Esta técnica permitió generar escenarios “qué pasaría si”, calculando los cambios mínimos que un estudiante tendría que realizar para pasar de una clasificación de alto riesgo a una de bajo riesgo. Con ello, el sistema podía convertir una predicción en una recomendación práctica, como mejorar el promedio de tareas, aumentar la participación en Moodle o revisar más recursos del curso. Así, el aporte fue obtenido mediante un proceso

ordenado que integró predicción, explicación y recomendación personalizada para apoyar el rendimiento académico del estudiante.

Proceso para resolver el problema

El proceso para resolver el problema planteado en el artículo parte de una limitación central en la analítica del aprendizaje: muchos sistemas educativos basados en datos pueden predecir si un estudiante está en riesgo académico, pero no explican con claridad por qué se genera esa predicción ni qué acciones concretas debería realizar el estudiante para mejorar. Frente a ello, los autores proponen una solución que combina **Machine Learning explicable y analítica prescriptiva automatizada**, con el objetivo de convertir las predicciones en orientaciones comprensibles, confiables y útiles para la toma de decisiones académicas.

Primero, los autores recopilan información de diferentes sistemas institucionales de educación superior. Utilizan datos provenientes de Moodle, del sistema de gestión estudiantil y del sistema de matrícula. Estos datos incluyen calificaciones en tareas, nivel de participación en el LMS, recursos visualizados, calificaciones previas, edad, género, ciudadanía, modalidad de estudio y dominio del inglés. Con esta información, se construye una base de datos capaz de representar el comportamiento académico y digital de los estudiantes dentro del curso .

Luego, los datos son limpiados, transformados y organizados para construir variables relevantes. En esta etapa, los autores utilizan características como el puntaje de tareas, la desviación del puntaje respecto al promedio del grupo, el puntaje de participación en el LMS, la desviación de participación, los puntajes de cursos previos y la cantidad de recursos revisados. Además, aplican estandarización mediante puntajes Z para comparar el desempeño individual de cada estudiante con el promedio de su cohorte. Esto permite que el análisis no se base únicamente en valores aislados, sino en la posición relativa del estudiante frente a su grupo.

Después, los estudiantes son clasificados en dos categorías: **alto riesgo** y **bajo riesgo**. Los estudiantes con una nota final igual o menor al 60 % son considerados de alto riesgo, mientras que aquellos que superan ese umbral son considerados de bajo riesgo. Esta clasificación sirve como base para entrenar modelos de Machine Learning capaces de anticipar si un estudiante podría presentar dificultades académicas o riesgo de no completar satisfactoriamente el curso.

Posteriormente, los autores aplican distintos algoritmos predictivos, entre ellos Logistic Regression, k-Nearest Neighbors, Random Forest, Naïve Bayes y CatBoost. Estos modelos son evaluados con métricas como Accuracy, Precision, Recall, F-measure y AUC. El objetivo de esta fase es seleccionar el modelo con mejor capacidad predictiva para identificar correctamente a los estudiantes en riesgo. Según los resultados, CatBoost obtuvo el mejor desempeño general, superando a los demás clasificadores evaluados .

Sin embargo, el proceso no termina con la predicción. Para resolver realmente el problema, los autores incorporan una etapa de explicabilidad mediante técnicas como **Anchors** y **SHAP**. Estas herramientas permiten identificar qué factores influyen en la clasificación de un estudiante. Por ejemplo, el sistema puede explicar que un estudiante fue clasificado como de alto riesgo debido a bajas calificaciones en tareas, poca interacción con Moodle o escasa visualización de recursos. Esta explicación ayuda a reducir la desconfianza hacia los modelos de caja negra y permite que el estudiante comprenda mejor su situación.

Finalmente, los autores aplican analítica prescriptiva mediante **contrafactuales**, utilizando escenarios del tipo “qué pasaría si”. Esta técnica calcula los cambios mínimos que el estudiante debería realizar para pasar de una clasificación de alto riesgo a una de bajo riesgo. Así, el sistema puede generar recomendaciones concretas, como mejorar el puntaje en la próxima tarea, aumentar la participación en Moodle o revisar más recursos del curso. De esta manera, el

problema se resuelve no solo prediciendo el riesgo académico, sino también explicando sus causas y ofreciendo acciones personalizadas para mejorar el rendimiento del estudiante.

Métricas y resultados

En el artículo, los autores evaluaron los modelos predictivos mediante métricas propias de clasificación en Machine Learning: **Accuracy**, **Precision**, **Recall**, **F-measure** y **AUC**. Estas métricas permitieron medir qué tan bien los algoritmos identificaban a los estudiantes en condición de **alto riesgo** o **bajo riesgo** académico. Para asegurar una evaluación más confiable, se aplicó una validación cruzada modificada: los modelos fueron entrenados con nueve entregas de cursos y probados con una entrega restante, repitiendo el proceso con diferentes combinaciones de datos.

Los resultados muestran que el algoritmo con mejor desempeño fue **CatBoost**, alcanzando un **F-measure de 0.77**, una **Accuracy de 75 %** y un **AUC de 0.87**. En comparación, k-Nearest Neighbors obtuvo una Accuracy de 71 % y un AUC de 0.72; Naïve Bayes logró 68 % de Accuracy y 0.71 de AUC; mientras que Random Forest y Logistic Regression alcanzaron 67 % de Accuracy, con AUC de 0.74 y 0.73 respectivamente. Esto demuestra que CatBoost superó a los demás clasificadores en la predicción del riesgo académico estudiantil.

Además, los resultados de explicabilidad mostraron que variables como el rendimiento en tareas, la participación en Moodle, los puntajes previos y los recursos visualizados influyeron en la clasificación del estudiante. Finalmente, mediante contrafactuales, el sistema generó recomendaciones accionables, como mejorar la calificación de tareas o aumentar la interacción con el LMS, para que un estudiante pueda pasar de alto riesgo a bajo riesgo académico.

Observaciones/críticas

Una observación importante sobre el artículo es que presenta un aporte innovador al integrar **Machine Learning explicable** con **analítica prescriptiva automatizada**, ya que no se limita a predecir el riesgo académico, sino que también explica las razones de la predicción y propone recomendaciones concretas para el estudiante. Esta orientación resulta valiosa porque transforma la analítica del aprendizaje en una herramienta más práctica, transparente y útil para la toma de decisiones educativas.

Sin embargo, una crítica relevante es que el estudio presenta principalmente una demostración metodológica y no una evaluación amplia del impacto real del sistema en estudiantes. Aunque los autores indican que el sistema fue integrado en un tablero de Learning Analytics y que se encontraba en fase piloto, todavía no se presentan resultados definitivos sobre si las recomendaciones generadas lograron mejorar efectivamente el rendimiento académico final de los alumnos .

Otra limitación es que las recomendaciones prescriptivas dependen de la calidad de los datos disponibles. Si el sistema no registra aspectos importantes como motivación, problemas personales, contexto socioeconómico o dificultades emocionales, las sugerencias podrían ser incompletas. Además, aunque la explicabilidad mejora la confianza, existe el riesgo de que los estudiantes interpreten las recomendaciones como una presión o como una etiqueta negativa de “alto riesgo”.

A pesar de estas limitaciones, el artículo es valioso porque propone pasar de una analítica predictiva tradicional a una analítica más humana, explicable y orientada a la acción. Su principal fortaleza está en mostrar que los modelos educativos basados en datos deben ser comprensibles y útiles, no solo precisos.

26. ARTÍCULO 26

Author (s): Jovial Niyogisubizo; Lyuchao Liao; Eric Nziyumva; Evariste Murwanashyaka; Pierre Claver Nshimyumukiza

Title of paper: Predicting student's dropout in university classes using two-layer ensemble machine learning approach: A novel stacked generalization

Journal: Computers and Education: Artificial Intelligence

Volume (issue): Volume 3

pag – pag (year): Article 100066, pp. 1–12 (2022)

Estado del arte

La deserción estudiantil universitaria es uno de los problemas más relevantes y complejos dentro de los sistemas educativos actuales, debido a sus consecuencias académicas, sociales, económicas y personales. Cuando un estudiante abandona sus estudios, no solo se afecta su trayectoria individual, sino también su familia, la institución educativa y la sociedad en general, ya que se reduce la formación de capital humano y aumentan los riesgos asociados al desempleo, la baja productividad y la desigualdad social. Por ello, en los últimos años la predicción temprana de la deserción se ha convertido en un tema prioritario dentro de la analítica del aprendizaje y la minería de datos educativos.

La literatura previa ha demostrado que las técnicas de inteligencia artificial y machine learning pueden contribuir significativamente a identificar estudiantes con riesgo de abandonar sus estudios. Estas técnicas permiten analizar datos educativos registrados por las instituciones, como calificaciones, accesos a plataformas virtuales, resultados de pruebas, participación en proyectos, entregas de tareas, desempeño parcial y otros indicadores académicos. A partir de esta información, los modelos predictivos pueden detectar patrones asociados al abandono y generar alertas tempranas para que docentes, tutores y autoridades educativas intervengan antes de que el problema ocurra. En este sentido, los sistemas de alerta temprana se presentan como herramientas útiles para prevenir la deserción y mejorar la retención estudiantil.

Diversos estudios han empleado algoritmos clásicos de machine learning para predecir la deserción escolar y universitaria. Entre los modelos más utilizados se encuentran árboles de decisión, regresión logística, redes neuronales, Naïve Bayes, máquinas de soporte vectorial, random forest y métodos de boosting. Algunas investigaciones han mostrado que los árboles de decisión y los modelos basados en reglas tienen la ventaja de ser más interpretables, ya que permiten comprender con mayor facilidad los criterios que llevan a una determinada predicción. Sin embargo, otros modelos más complejos, como redes neuronales o técnicas de ensamble, suelen alcanzar mejores resultados en términos de precisión, aunque pueden presentar mayores dificultades de interpretación.

Un aspecto importante señalado por la literatura es que la predicción de la deserción no depende únicamente del modelo utilizado, sino también de la calidad de los datos, la selección de variables y el momento en que se realiza la predicción. La deserción puede entenderse como un fenómeno temporal, porque muchos estudiantes abandonan durante las primeras semanas o en etapas específicas del curso. Por esta razón, algunos estudios abordan el problema como una tarea de predicción en series temporales o como un problema de clasificación basado en ventanas de tiempo. La identificación temprana es esencial, ya que permite seleccionar intervenciones adecuadas antes de que el estudiante tome la decisión definitiva de abandonar.

A pesar del avance de los modelos predictivos, la literatura también reconoce varias limitaciones. Una de ellas es el desbalance de clases, ya que normalmente la cantidad de estudiantes que no abandonan es mucho mayor que la cantidad de estudiantes que sí desertan. Esto puede provocar que los modelos logren una alta precisión general, pero fallen al identificar correctamente a los estudiantes en riesgo. Otra dificultad es la escasez de datos en algunos

contextos educativos, especialmente cuando se trabaja a nivel de curso o con poblaciones reducidas. Además, algunos modelos funcionan como “cajas negras”, lo que dificulta que los docentes y responsables educativos comprendan por qué un estudiante fue clasificado como posible desertor.

El artículo analizado se ubica dentro de esta línea de investigación y propone una solución basada en aprendizaje ensamblado. Los autores señalan que, aunque ya existen estudios sobre deserción estudiantil en distintos niveles educativos, las técnicas de ensamble, particularmente el **stacking ensemble**, no han recibido suficiente atención para predecir la deserción en clases universitarias con conjuntos de datos escasos. Para responder a esta brecha, el estudio propone un modelo de dos capas que combina **Random Forest**, **XGBoost**, **Gradient Boosting** y una **Feed-forward Neural Network**. La idea central es aprovechar las fortalezas de varios clasificadores base y utilizar una red neuronal como meta-modelo para mejorar la predicción final.

En síntesis, el estado del arte muestra que la predicción de la deserción estudiantil ha evolucionado desde modelos individuales hacia enfoques más robustos basados en ensambles y técnicas híbridas. No obstante, persisten desafíos relacionados con el tamaño reducido de los datos, el desbalance de clases, la interpretación de los resultados y la necesidad de intervenciones educativas concretas. El aporte del artículo se encuentra en proponer un modelo ensamblado de dos capas para mejorar la precisión en la predicción de estudiantes universitarios con riesgo de abandonar una asignatura, ofreciendo una herramienta potencial para la toma de decisiones tempranas por parte de los agentes educativos.

Motivación del autor

La motivación principal de los autores surge de la preocupación por la deserción estudiantil universitaria, considerada un problema grave y complejo dentro del sistema educativo. El abandono de los estudios no solo afecta al estudiante, sino también a su familia, a la institución y a la sociedad, porque limita las oportunidades profesionales, reduce la formación de capital humano y puede generar consecuencias económicas y sociales negativas. Frente a esta situación, los autores reconocen la necesidad de contar con herramientas predictivas que permitan identificar tempranamente a los estudiantes con riesgo de abandonar una asignatura o programa académico.

Asimismo, los autores observan que, aunque existen investigaciones previas sobre predicción de deserción mediante machine learning, todavía hay poca atención al uso de modelos ensamblados, especialmente en contextos universitarios con conjuntos de datos reducidos. Por ello, su motivación es proponer un enfoque más robusto que combine varios algoritmos — Random Forest, XGBoost, Gradient Boosting y una red neuronal feed-forward— para mejorar la precisión de la predicción. El propósito final no es únicamente técnico, sino educativo: ofrecer información útil para que docentes, autoridades y otros agentes de la educación puedan intervenir a tiempo, aplicar medidas preventivas y reducir el riesgo de abandono antes de que el problema ocurra.

Descripción del aporte del autor

El principal aporte de los autores consiste en proponer un modelo novedoso de aprendizaje automático ensamblado para predecir la deserción estudiantil en clases universitarias. La investigación parte de un problema educativo relevante: muchos estudiantes abandonan sus estudios o fracasan en una asignatura sin que la institución pueda detectar el riesgo con suficiente anticipación. Frente a ello, los autores plantean que la inteligencia artificial y la minería de datos educativos pueden servir como herramientas de apoyo para identificar patrones asociados al abandono y activar intervenciones preventivas. En este sentido, el estudio no solo busca mejorar el rendimiento técnico de un modelo predictivo, sino también contribuir a la

reducción de la deserción mediante información útil para docentes, autoridades, familias y otros agentes educativos.

El aporte más importante del artículo es la creación de un modelo de **stacking ensemble de dos capas**, basado en la combinación de varios algoritmos de machine learning. En la primera capa, los autores utilizan tres modelos base: **Random Forest**, **XGBoost** y **Gradient Boosting**. Estos modelos generan predicciones iniciales a partir del conjunto de datos. Luego, en la segunda capa, dichas predicciones se introducen en una **Feed-forward Neural Network —FNN—**, que funciona como meta-clasificador y produce la predicción final sobre si el estudiante abandonará o no la clase universitaria. Esta arquitectura representa una contribución metodológica porque aprovecha las fortalezas de diferentes modelos, en lugar de depender de un único algoritmo.

La elección de un enfoque ensamblado es relevante porque cada modelo de machine learning puede capturar distintos tipos de patrones en los datos. Random Forest es útil por su capacidad de trabajar con múltiples árboles de decisión y reducir la varianza; Gradient Boosting permite mejorar progresivamente los errores cometidos por modelos anteriores; XGBoost destaca por su eficiencia, regularización y buen desempeño en problemas de clasificación; mientras que la red neuronal feed-forward puede aprender relaciones no lineales a partir de las salidas generadas por los clasificadores base. Al integrar estos métodos, los autores buscan construir un sistema más robusto, capaz de mejorar la precisión predictiva frente a modelos individuales.

Otro aporte significativo es que el estudio aborda la predicción de la deserción en un contexto con **datos escasos**. Los autores trabajan con un conjunto de datos relativamente pequeño, compuesto por 261 registros de estudiantes matriculados en una lección preparatoria de sistemas de bases de datos en Constantine the Philosopher University in Nitra, durante el periodo 2016-2020. En el campo educativo, no siempre es posible contar con grandes volúmenes de datos, ya que los registros suelen depender de cursos específicos, cohortes reducidas o información institucional limitada. Por ello, demostrar que un modelo ensamblado puede lograr buenos resultados aun con una base de datos pequeña constituye un aporte práctico importante para instituciones que no disponen de grandes repositorios educativos.

El artículo también aporta un proceso claro de preparación y selección de variables. El conjunto de datos original incluyó variables como acceso a la plataforma, pruebas, calificaciones de pruebas, examen, proyecto, nota del proyecto, tareas, puntos finales, calificación final, estado de graduación, año y año académico. Los autores realizaron limpieza de datos, eliminaron valores nulos o inconsistentes, aplicaron codificación one-hot para variables categóricas y normalizaron los datos mediante un escalador estándar. Además, utilizaron un mapa de calor de correlación para analizar la relación entre las variables de entrada y la variable de salida. Este procedimiento permitió identificar variables relevantes, como pruebas, acceso y proyecto, que presentaban una fuerte relación con los resultados académicos.

Desde el punto de vista metodológico, este proceso fortalece el aporte porque muestra que la calidad de la predicción no depende únicamente del algoritmo, sino también del tratamiento adecuado de los datos. En problemas educativos, los registros pueden contener ruido, inconsistencias o variables poco útiles. Por eso, la selección de características y el análisis de correlación son pasos importantes para mejorar la capacidad del modelo y evitar que aprenda información irrelevante. La figura 1 del artículo, mediante un mapa de calor, permite visualizar las asociaciones entre las variables, mientras que la figura 2 presenta la estructura general del modelo de stacking propuesto, desde la recolección de datos hasta la evaluación final.

Un aporte relevante del estudio es la comparación del modelo propuesto con sus modelos base. Los autores no se limitan a presentar el desempeño del stacking ensemble, sino que lo contrastan con **Feed-forward Neural Network**, **Random Forest**, **Gradient Boosting** y **XGBoost** bajo condiciones similares. Esta comparación permite comprobar si la combinación de modelos realmente mejora la predicción frente al uso individual de cada algoritmo. Los resultados

muestran que el modelo ensamblado obtuvo una precisión de prueba de **92.18%**, superando a los demás métodos evaluados. Además, alcanzó valores generales de **precisión de 0.93, recall de 0.93 y F1-score de 0.92**, lo que evidencia un buen equilibrio entre la identificación correcta de estudiantes desertores y no desertores.

Asimismo, el modelo propuesto alcanzó un **AUC de 0.983**, valor superior al de los modelos comparados. Este resultado es especialmente importante porque el AUC permite evaluar la capacidad del modelo para distinguir entre las clases, más allá de la precisión general. En problemas de deserción, esta métrica resulta relevante porque los datos suelen estar desbalanceados: normalmente hay más estudiantes que continúan que estudiantes que abandonan. Si se utilizara únicamente la accuracy, el modelo podría parecer exitoso aunque no identifique adecuadamente a los estudiantes en riesgo. Por ello, el uso de varias métricas refuerza la validez del aporte y demuestra una evaluación más completa del desempeño predictivo.

Desde una perspectiva educativa, el aporte del artículo se relaciona con la posibilidad de implementar sistemas de alerta temprana. La predicción de la deserción no tiene valor únicamente como ejercicio técnico; su utilidad real aparece cuando permite actuar antes de que el estudiante abandone. Los autores señalan que, si se identifica a tiempo a los estudiantes con riesgo, los agentes educativos pueden aplicar medidas preventivas, como tutorías, seguimiento personalizado, apoyo académico, estrategias de motivación o revisión de las condiciones de aprendizaje. De esta manera, el modelo puede contribuir a disminuir los efectos negativos de la deserción y mejorar la permanencia estudiantil.

Otro aporte importante es que el estudio destaca la necesidad de que las instituciones educativas utilicen la información disponible para tomar decisiones basadas en evidencia. Muchas veces, los datos académicos se almacenan sin ser aprovechados para comprender el comportamiento estudiantil. El artículo demuestra que variables relativamente accesibles, como resultados de pruebas, acceso a actividades, proyectos y calificaciones parciales, pueden convertirse en insumos valiosos para anticipar el abandono. Esto es especialmente útil porque no siempre se requiere información compleja o difícil de obtener; con datos institucionales básicos y un modelo adecuado, es posible construir herramientas predictivas efectivas.

También es importante señalar que el trabajo aporta al campo de la analítica del aprendizaje al enfocarse en la deserción a nivel de clase universitaria. Muchos estudios previos se han centrado en la deserción a nivel institucional, de programa o de educación básica y secundaria. Sin embargo, la predicción a nivel de curso o asignatura es relevante porque permite intervenciones más específicas y cercanas al proceso de aprendizaje. Un estudiante puede estar en riesgo dentro de una asignatura concreta antes de abandonar completamente su programa académico. Por ello, detectar el riesgo en una clase puede ser una forma temprana de prevenir problemas mayores en su trayectoria universitaria.

El aporte de los autores también se evidencia en la propuesta de un modelo con dos capas, donde la primera actúa como un convertidor no lineal de características y la segunda como un clasificador final. Esta estructura permite que las predicciones generadas por los modelos base sean utilizadas como información de entrada para la red neuronal. En términos prácticos, el sistema aprende de los errores y fortalezas de los clasificadores iniciales para producir una salida más refinada. Esto representa una aplicación concreta de la generalización apilada o *stacked generalization*, una técnica que busca reducir el error de generalización mediante la combinación estratégica de varios modelos.

No obstante, el aporte no se presenta como una solución definitiva, sino como una propuesta que abre posibilidades para futuras investigaciones. Los propios autores reconocen limitaciones, como el tamaño reducido del conjunto de datos, la dificultad para generalizar los resultados a otros contextos y la necesidad de incluir más variables relacionadas con factores

sociales, familiares o motivacionales. Aun así, el estudio demuestra que el enfoque ensamblado puede ser una alternativa viable y eficiente para mejorar la predicción de la deserción en escenarios educativos con datos limitados.

En conclusión, el aporte de los autores se resume en la propuesta de un modelo predictivo de dos capas que combina algoritmos de ensamble y una red neuronal para mejorar la detección de estudiantes universitarios en riesgo de deserción. El estudio contribuye metodológicamente al aplicar **stacked generalization** en un problema educativo específico; contribuye técnicamente al demostrar mejores resultados que modelos individuales; y contribuye pedagógicamente al ofrecer una herramienta potencial para la intervención temprana. Su valor principal está en mostrar que la inteligencia artificial puede apoyar la toma de decisiones educativas cuando se orienta a prevenir el abandono, mejorar la retención y fortalecer el acompañamiento académico de los estudiantes.

Proceso para obtener el aporte

Para obtener su aporte, los autores desarrollaron un proceso metodológico orientado a construir y evaluar un modelo predictivo capaz de identificar estudiantes universitarios con riesgo de deserción. El estudio utilizó un conjunto de datos reales recolectado en **Constantine the Philosopher University in Nitra**, correspondiente al periodo 2016-2020. La base inicial estuvo compuesta por **261 registros** de estudiantes matriculados en una lección preparatoria de sistemas de bases de datos. Entre las variables consideradas se incluyeron accesos, pruebas, calificaciones de pruebas, examen, proyecto, calificación del proyecto, tareas, puntos finales, calificación final, estado de graduación, año y año académico. La variable de salida fue binaria: **1 para estudiantes no desertores** y **0 para estudiantes desertores**.

El primer paso consistió en realizar el preprocesamiento de los datos. Los autores limpiaron la base eliminando valores nulos, irreales, ruidosos o inconsistentes. Luego, transformaron las variables categóricas mediante **one-hot encoding**, con el fin de convertirlas en vectores binarios adecuados para los modelos de machine learning. También aplicaron un proceso de normalización utilizando **standard scaler**, para eliminar la media y escalar los datos a varianza unitaria. Este procedimiento fue necesario para mejorar la calidad de los datos y evitar que algunas variables influyeran de manera desproporcionada en el entrenamiento del modelo.

El segundo paso fue la selección de características relevantes. Para ello, los autores elaboraron un **mapa de calor de correlación**, presentado en la figura 1 del artículo, con el propósito de analizar la relación entre las variables de entrada y la variable de salida. A partir de este análisis, identificaron que variables como **tests**, **access** y **project** tenían una relación importante con los resultados académicos. Por esa razón, las características más correlacionadas fueron consideradas en la construcción del modelo, ya que podían aportar mayor capacidad predictiva para distinguir entre estudiantes desertores y no desertores.

El tercer paso fue dividir el conjunto de datos en entrenamiento y prueba. Los autores utilizaron el **80% de los datos para entrenar** los modelos y el **20% restante para evaluar** su desempeño. Además, aplicaron **validación cruzada de diez pliegues** para reducir el riesgo de sobreajuste y obtener una evaluación más estable. Esta decisión fue importante porque el conjunto de datos era pequeño, y en estos casos los modelos pueden aprender patrones demasiado específicos de la muestra si no se controla adecuadamente el proceso de entrenamiento.

El cuarto paso consistió en construir el modelo propuesto de **stacking ensemble de dos capas**. En la primera capa se entrenaron tres clasificadores base: **Random Forest**, **XGBoost** y **Gradient Boosting**. Estos modelos generaron predicciones iniciales a partir del conjunto de entrenamiento. Luego, en la segunda capa, dichas predicciones fueron utilizadas como entrada para una **Feed-forward Neural Network**, encargada de producir la predicción final sobre la

deserción estudiantil. La figura 2 del artículo muestra la estructura general de este procedimiento, desde la recolección de datos hasta la evaluación del modelo.

Finalmente, los autores compararon el desempeño del modelo ensamblado con los modelos individuales. Para ello utilizaron métricas como **accuracy**, **precision**, **recall**, **F1-score** y **AUC**. Los resultados evidenciaron que el modelo de stacking ensemble obtuvo un mejor rendimiento general que los modelos base, alcanzando una precisión de prueba de **92.18%** y un **AUC de 0.983**. De esta manera, el proceso permitió demostrar que combinar varios clasificadores mediante una arquitectura de dos capas puede mejorar la predicción de la deserción estudiantil universitaria, incluso cuando se trabaja con un conjunto de datos reducido.

Proceso para resolver el problema

Para resolver el problema de la deserción estudiantil en clases universitarias, los autores plantearon una solución basada en aprendizaje automático, específicamente mediante un modelo ensamblado de dos capas. El problema central identificado fue que la deserción universitaria genera consecuencias negativas para el estudiante, la familia, la institución y la sociedad; por ello, resulta necesario anticipar qué estudiantes se encuentran en riesgo de abandonar. Además, los autores observaron que muchos modelos tradicionales pueden no ser suficientemente robustos cuando se trabaja con conjuntos de datos pequeños o con pocas variables, situación frecuente en contextos educativos reales.

El primer paso para resolver el problema fue utilizar datos históricos de estudiantes matriculados en una clase universitaria relacionada con sistemas de bases de datos. Estos datos contenían información académica y de participación, como accesos, pruebas, calificaciones, examen, proyecto, tareas y resultado final. A partir de esta información, los autores definieron una variable de salida binaria: estudiantes que no abandonaron y estudiantes que abandonaron. De esta manera, el problema fue formulado como una tarea de clasificación supervisada, donde el modelo debía aprender a diferenciar entre ambos grupos.

Luego, se realizó una etapa de limpieza y preparación de los datos. Los autores eliminaron valores nulos, inconsistentes o poco realistas, transformaron variables categóricas mediante codificación one-hot y normalizaron las variables numéricas con standard scaler. Posteriormente, aplicaron un análisis de correlación para identificar las variables más relevantes para la predicción. Este paso fue importante porque permitió seleccionar atributos con mayor relación con el resultado académico, como el acceso, las pruebas y el proyecto, evitando que el modelo trabajara con información poco significativa.

Después de preparar los datos, los autores diseñaron el modelo de solución. En la primera capa del sistema se emplearon tres clasificadores base: **Random Forest**, **Gradient Boosting** y **XGBoost**. Cada uno de estos algoritmos generó predicciones iniciales aprovechando diferentes formas de aprendizaje. Random Forest permitió combinar varios árboles de decisión; Gradient Boosting corrigió errores de modelos anteriores de manera progresiva; y XGBoost incorporó regularización y eficiencia en el proceso de clasificación. Esta combinación buscó aumentar la diversidad y precisión de las predicciones iniciales.

En la segunda capa, las predicciones generadas por los modelos base fueron utilizadas como entrada para una **Feed-forward Neural Network**, que funcionó como meta-clasificador. Esta red neuronal produjo la predicción final sobre si un estudiante tenía riesgo de desertar o no. Con esta estrategia de **stacking ensemble**, los autores intentaron aprovechar las fortalezas de varios modelos y reducir las debilidades de utilizar un solo algoritmo. Finalmente, el modelo fue evaluado con un conjunto de prueba y mediante métricas como accuracy, precision, recall, F1-score y AUC. Los resultados mostraron que el modelo ensamblado superó a los modelos individuales, demostrando que la combinación de clasificadores puede ser una solución efectiva para anticipar la deserción y apoyar intervenciones educativas tempranas.

Métricas y resultados

Para evaluar el rendimiento del modelo propuesto, los autores utilizaron varias métricas de clasificación: **accuracy**, **precision**, **recall**, **F1-score** y **AUC**. La accuracy permitió medir el porcentaje general de predicciones correctas; la precision evaluó qué tan confiables fueron las predicciones positivas; el recall midió la capacidad del modelo para identificar correctamente los casos de deserción; el F1-score integró precision y recall en una sola medida; y el AUC permitió analizar la capacidad global del modelo para diferenciar entre estudiantes desertores y no desertores. Estas métricas fueron importantes porque, en problemas de deserción, no basta con medir la precisión general, sino que también se debe verificar si el modelo identifica correctamente a los estudiantes en riesgo.

Los resultados mostraron que el modelo **stacking ensemble** obtuvo el mejor desempeño general frente a los modelos individuales. Alcanzó una **accuracy de prueba de 92.18%**, superando a Feed-forward Neural Network, Random Forest, Gradient Boosting y XGBoost. Además, obtuvo valores generales de **precision = 0.93**, **recall = 0.93** y **F1-score = 0.92**, lo que indica un buen equilibrio entre la identificación de estudiantes desertores y no desertores. En cuanto al AUC, el modelo propuesto alcanzó **0.983**, el valor más alto entre todos los métodos evaluados, seguido por XGBoost con 0.978 y Random Forest con 0.970. En conjunto, estos resultados evidencian que la estrategia de ensamble de dos capas mejora la capacidad predictiva y puede ser útil para apoyar sistemas de alerta temprana en clases universitarias.

Observaciones/críticas

Una observación positiva del artículo es que aborda un problema educativo de gran importancia: la deserción estudiantil universitaria. El estudio resulta valioso porque no se limita a explicar el problema de manera teórica, sino que propone una solución basada en machine learning para identificar estudiantes en riesgo antes de que abandonen una asignatura. Además, el uso de un modelo **stacking ensemble** de dos capas es un aporte interesante, ya que combina las fortalezas de Random Forest, XGBoost, Gradient Boosting y una red neuronal feed-forward para mejorar la predicción final. Los resultados obtenidos muestran un rendimiento alto, especialmente en accuracy y AUC, lo que evidencia que el modelo puede ser útil como herramienta de alerta temprana en contextos universitarios.

Sin embargo, también existen algunas limitaciones importantes. La principal crítica es el tamaño reducido del conjunto de datos, ya que el estudio trabajó solo con 261 registros, lo cual puede afectar la generalización de los resultados a otras universidades, carreras o asignaturas. Además, aunque el modelo obtiene buenos resultados, el artículo no profundiza suficientemente en el tipo de intervención educativa que debería aplicarse después de identificar a un estudiante en riesgo. También sería necesario incluir variables más amplias, como factores familiares, socioeconómicos, emocionales o motivacionales, porque la deserción no depende únicamente del desempeño académico o del acceso a actividades. Finalmente, el modelo ensamblado puede ser más difícil de interpretar que modelos simples, por lo que se requiere explicar mejor las razones detrás de cada predicción para que docentes y autoridades puedan tomar decisiones pedagógicas claras y responsables.

27. ARTÍCULO 27

Author (s): Thanyaluck Ingkavara; Patcharin Panjaburee; Niwat Srisawasdi; Suthiporn Sajjanaroj.

Title of paper: *The use of a personalized learning approach to implementing self-regulated online learning.*

Journal: *Computers and Education: Artificial Intelligence.*

Volume (issue): 3.

pag – pag (year): 100086, 1–18 (2022).

Estado del arte

El estudio sobre el **aprendizaje autorregulado en entornos virtuales** se ha convertido en una línea importante dentro de la educación digital, especialmente porque los estudiantes actuales utilizan cada vez más plataformas en línea para desarrollar actividades académicas de manera autónoma. En este contexto, el aprendizaje autorregulado, conocido como **Self-Regulated Learning** o **SRL**, se entiende como la capacidad del estudiante para establecer metas, organizar su ambiente de estudio, seleccionar estrategias, administrar su tiempo, buscar ayuda y evaluar su propio desempeño. Estas habilidades son fundamentales en los entornos virtuales, porque el estudiante no depende únicamente de la presencia directa del docente, sino que debe asumir un rol más activo en su proceso de aprendizaje.

De acuerdo con el artículo revisado, diversos estudios han señalado que las acciones de autorregulación influyen positivamente en el éxito académico de los estudiantes en ambientes de aprendizaje en línea. Sin embargo, también se reconoce que muchos estudiantes presentan dificultades para controlar su propio aprendizaje cuando no reciben orientación suficiente, materiales adecuados o retroalimentación personalizada. En los sistemas tradicionales de aprendizaje en línea, las actividades suelen ser iguales para todos, sin considerar las diferencias individuales, los problemas conceptuales ni las preferencias de aprendizaje de cada alumno. Esta limitación reduce las posibilidades de que los estudiantes reciban sugerencias realmente útiles para superar sus dificultades académicas.

Frente a esta situación, la literatura ha comenzado a destacar la importancia del **aprendizaje personalizado** como estrategia para mejorar la educación en línea. El aprendizaje personalizado busca adaptar contenidos, rutas de estudio, materiales y retroalimentación según las necesidades particulares del estudiante. Esta perspectiva se relaciona con el uso de tecnologías inteligentes e inteligencia artificial, ya que estos sistemas pueden analizar datos del alumno, identificar errores conceptuales y recomendar actividades o recursos adecuados para su perfil. De esta manera, el aprendizaje personalizado permite que el estudiante no solo avance a su propio ritmo, sino que también reciba apoyo específico de acuerdo con sus dificultades y preferencias.

El artículo de Ingkavara, Panjaburee, Srisawasdi y Sajjapanroj se ubica precisamente en esta línea de investigación, al integrar un enfoque de aprendizaje personalizado dentro de un entorno de aprendizaje autorregulado en línea. Los autores proponen que el sistema permita a los estudiantes establecer metas de aprendizaje, gestionar su tiempo, resolver actividades, recibir materiales adaptados a su estilo de aprendizaje y reflexionar sobre su progreso. Esta integración resulta relevante porque combina dos enfoques que, en muchas investigaciones previas, se han trabajado de manera separada: por un lado, el aprendizaje autorregulado; y por otro, los sistemas personalizados de aprendizaje.

En el campo educativo, especialmente en asignaturas como Física, los estudiantes suelen presentar dificultades para comprender conceptos abstractos, como los relacionados con circuitos eléctricos. Por ello, los autores plantean que un sistema en línea debe ser capaz de diagnosticar los problemas conceptuales de cada estudiante y ofrecer rutas remediales personalizadas. Según el artículo, el sistema analiza las respuestas de los estudiantes, calcula el nivel de error en cada concepto y determina su estado de aprendizaje. A partir de ello, genera una ruta de aprendizaje individual y recomienda materiales acordes con las preferencias del estudiante, como videos, actividades, notas en línea o recursos interactivos.

Otro aspecto importante del estado del arte es la relación entre aprendizaje personalizado y aceptación tecnológica. No basta con que un sistema sea técnicamente funcional; también es necesario que los estudiantes lo perciban como útil, fácil de usar y beneficioso para su aprendizaje. Por esta razón, el artículo incorpora elementos del modelo de aceptación tecnológica, analizando variables como utilidad percibida de las sugerencias, facilidad de uso,

actitud hacia el entorno de aprendizaje e intención de seguir utilizando el sistema. Esta perspectiva permite comprender no solo si el sistema mejora el rendimiento académico, sino también si los estudiantes están dispuestos a aceptarlo y continuar usándolo.

La investigación previa también ha demostrado que las habilidades de autorregulación pueden desarrollarse con apoyo tecnológico, especialmente cuando existen mecanismos de guía, retroalimentación y seguimiento del progreso. En este sentido, el sistema propuesto por los autores responde a una necesidad actual: diseñar entornos virtuales que no solo entreguen contenidos, sino que acompañen al estudiante en la planificación, ejecución y evaluación de su aprendizaje. Esta idea coincide con modelos de SRL que consideran tres fases principales: preparación de metas, desempeño durante la tarea y reflexión posterior.

En síntesis, el estado del arte muestra que el aprendizaje autorregulado y el aprendizaje personalizado son enfoques complementarios para mejorar la educación en línea. Mientras el primero fortalece la autonomía del estudiante, el segundo adapta el proceso educativo a sus necesidades individuales. El artículo revisado aporta a este campo al demostrar que un entorno de aprendizaje en línea personalizado puede mejorar el rendimiento en Física y fortalecer la intención de uso del sistema. Así, la investigación evidencia que la tecnología educativa tiene mayor impacto cuando combina personalización, autorregulación, retroalimentación y materiales adaptados al perfil del estudiante.

Motivación del autor

La motivación principal de los autores surge de la necesidad de mejorar los entornos de aprendizaje en línea mediante estrategias que realmente apoyen la autonomía del estudiante. En la actualidad, los sistemas virtuales permiten que los alumnos estudien con mayor independencia; sin embargo, muchos estudiantes no poseen suficientes habilidades de autorregulación para organizar su tiempo, establecer metas, seleccionar estrategias de aprendizaje y evaluar su propio progreso. Por esta razón, los autores consideran importante diseñar un entorno que no solo entregue contenidos, sino que también guíe al estudiante durante su proceso de aprendizaje.

Otra motivación importante es que los sistemas tradicionales de aprendizaje en línea suelen ofrecer los mismos materiales y la misma retroalimentación para todos los estudiantes, sin tomar en cuenta sus dificultades conceptuales ni sus preferencias de aprendizaje. Esto limita la posibilidad de que cada alumno reciba sugerencias útiles y adecuadas a sus necesidades. En el artículo se señala que, cuando no existe una guía apropiada, los estudiantes pueden mostrar poco autocontrol, baja responsabilidad y dificultades para completar las actividades requeridas en cursos virtuales.

Por ello, los autores se motivan a integrar un enfoque de **aprendizaje personalizado** dentro del aprendizaje autorregulado en línea. Su propósito es que el sistema pueda diagnosticar los problemas conceptuales del estudiante, recomendar rutas de aprendizaje y ofrecer materiales acordes con sus preferencias. Además, buscan comprobar si este enfoque mejora el rendimiento académico en Física y qué factores influyen en la intención de los estudiantes de seguir utilizando este tipo de ambiente virtual.

Descripción del aporte del autor

El aporte principal de Thanyaluck Ingkavara, Patcharin Panjaburee, Niwat Srisawasdi y Suthiporn Sajjapanroj en el artículo **“The use of a personalized learning approach to implementing self-regulated online learning”** consiste en proponer y evaluar un entorno de aprendizaje en línea que integra dos enfoques fundamentales para la educación actual: el **aprendizaje autorregulado** y el **aprendizaje personalizado**. Esta integración es importante porque los entornos virtuales no solo deben ofrecer contenidos digitales, sino también ayudar a

que el estudiante organice su proceso de aprendizaje, identifique sus dificultades, reciba materiales adecuados y reflexione sobre su propio avance.

Uno de los aportes más relevantes del artículo es que reconoce una limitación frecuente en los sistemas tradicionales de aprendizaje en línea: la falta de personalización. En muchos cursos virtuales, todos los estudiantes reciben las mismas actividades, los mismos materiales y las mismas recomendaciones, aunque sus problemas conceptuales, ritmos de aprendizaje y preferencias sean diferentes. Frente a esta situación, los autores proponen un sistema que analiza las respuestas del estudiante, identifica sus dificultades en conceptos específicos y genera rutas de aprendizaje personalizadas. De esta manera, el aprendizaje deja de ser uniforme y se adapta mejor a las necesidades individuales de cada alumno.

El artículo también aporta al fortalecer el aprendizaje autorregulado en ambientes virtuales. Según los autores, el aprendizaje autorregulado implica que el estudiante pueda establecer metas, organizar su ambiente de estudio, aplicar estrategias, manejar su tiempo, buscar ayuda y evaluarse a sí mismo. Estas habilidades son especialmente necesarias en la educación en línea, donde el estudiante tiene mayor independencia, pero también enfrenta el riesgo de desorganizarse, perder motivación o no completar las actividades. Por ello, el sistema propuesto no solo entrega contenidos, sino que guía al estudiante en la planificación, ejecución y evaluación de su aprendizaje.

Otro aporte importante es la aplicación del sistema en una asignatura concreta: Física, específicamente en el tema de circuitos eléctricos. Este detalle es significativo porque la Física suele presentar conceptos abstractos que pueden resultar difíciles para muchos estudiantes de secundaria. El sistema permite diagnosticar errores conceptuales y ofrecer materiales de apoyo según las necesidades detectadas. Así, el aporte no se queda en una propuesta teórica, sino que se aplica a un contenido académico real, con estudiantes reales y bajo un diseño de investigación cuantitativo.

Desde el punto de vista tecnológico, los autores aportan un mecanismo personalizado basado en varios procesos. Primero, el sistema permite que el estudiante establezca sus metas de aprendizaje y el tiempo que espera dedicar a la actividad. Luego, registra sus respuestas y calcula el nivel de error en cada concepto. A partir de ese análisis, determina el estado de aprendizaje del estudiante y genera una ruta personalizada. Después, recomienda materiales según su preferencia de aprendizaje, como videos, actividades interactivas, notas digitales o recursos de lectura. Finalmente, permite que el estudiante evalúe su progreso y reciba retroalimentación para mejorar en las siguientes actividades.

Este proceso representa un aporte valioso porque convierte al sistema en una herramienta de acompañamiento académico. No se trata únicamente de una plataforma donde el alumno responde preguntas, sino de un entorno que interpreta sus resultados y le ofrece orientación. En ese sentido, el sistema funciona como un apoyo inteligente para el aprendizaje, ya que identifica qué conceptos no han sido suficientemente comprendidos y qué recursos pueden ayudar al estudiante a superar sus dificultades. Esto favorece una experiencia más cercana a la enseñanza personalizada.

Otro aporte central del artículo es la comparación entre dos grupos de estudiantes. Los autores realizaron un diseño cuasi-experimental en cinco escuelas secundarias de Tailandia, con una muestra de 292 estudiantes. El grupo experimental estuvo conformado por 144 estudiantes que utilizaron el aprendizaje autorregulado en línea guiado por el enfoque personalizado, mientras que el grupo de control estuvo formado por 148 estudiantes que participaron en un aprendizaje autorregulado convencional, sin personalización. Esta comparación permitió evaluar si la personalización realmente generaba una diferencia en el rendimiento académico.

Los resultados obtenidos constituyen otro aporte importante. Antes de iniciar la intervención, ambos grupos presentaban niveles similares de conocimiento previo, ya que no hubo diferencias significativas en el pretest. Sin embargo, después de las actividades, el grupo experimental obtuvo mejores resultados en el postest. Los estudiantes que aprendieron con el sistema personalizado alcanzaron una media de 7.37, mientras que el grupo de control obtuvo una media de 6.07. Esta diferencia fue estadísticamente significativa, lo que demuestra que el enfoque personalizado ayudó a mejorar el aprendizaje del contenido de Física.

Además del rendimiento académico, el artículo aporta al analizar las percepciones de los estudiantes sobre el sistema. Los autores no se limitaron a medir si los estudiantes aprendieron más, sino que también evaluaron qué factores influyeron en su intención de seguir utilizando el entorno de aprendizaje. Para ello, aplicaron un cuestionario con constructos relacionados con el aprendizaje autorregulado y la aceptación tecnológica. Entre estos constructos se encuentran establecimiento de metas, estructuración del ambiente, estrategias de tarea, gestión del tiempo, búsqueda de ayuda, autoevaluación, impacto percibido en el aprendizaje, utilidad de las sugerencias, facilidad de uso, actitud e intención de uso.

Este análisis es valioso porque permite comprender que la efectividad de una tecnología educativa no depende solo de sus resultados académicos, sino también de cómo la perciben los estudiantes. Un sistema puede ser técnicamente avanzado, pero si los estudiantes lo consideran difícil, poco útil o poco motivador, probablemente no lo utilizarán de manera continua. En este sentido, los autores aportan una mirada más completa al estudiar tanto el desempeño como la aceptación del sistema.

Los resultados de percepción muestran que los estudiantes respondieron positivamente al entorno personalizado. Las medias de los once constructos fueron superiores a 3.00 en una escala de cinco puntos, lo que indica una valoración favorable. En particular, los estudiantes destacaron las estrategias de tarea, la gestión del tiempo y la autoevaluación como elementos importantes del sistema. Esto sugiere que el aprendizaje personalizado puede fortalecer componentes clave de la autorregulación, ayudando al estudiante a organizarse mejor y a participar activamente en su proceso formativo.

Otro aporte importante está relacionado con los factores que influyen en la intención de uso. Los autores encontraron que la actitud hacia el sistema fue un predictor significativo de la intención de seguir utilizándolo. Asimismo, la utilidad percibida de las sugerencias de aprendizaje influyó fuertemente en la actitud de los estudiantes. Esto significa que, cuando los alumnos consideran que las recomendaciones del sistema son útiles para mejorar su aprendizaje, desarrollan una actitud más positiva y tienen mayor disposición a continuar usando la plataforma.

El artículo también aporta al mostrar que algunas habilidades de autorregulación influyen más que otras en la percepción del impacto del aprendizaje. Las estrategias de tarea, la autoevaluación, la gestión del tiempo, la estructuración del ambiente y el establecimiento de metas fueron factores significativos. Sin embargo, la búsqueda de ayuda no tuvo un efecto significativo en el impacto percibido. Este hallazgo es interesante porque permite identificar qué dimensiones de la autorregulación deben reforzarse más dentro de los sistemas personalizados.

Desde una perspectiva pedagógica, el aporte del artículo consiste en demostrar que el aprendizaje personalizado puede ayudar al estudiante a asumir mayor control sobre su aprendizaje. Al permitir que el alumno establezca metas, reciba rutas personalizadas, seleccione materiales según sus preferencias y evalúe su avance, el sistema promueve una participación más activa. Esto rompe con una visión pasiva del aprendizaje en línea, donde el estudiante solo consume contenidos, y lo convierte en un agente que toma decisiones sobre su propio proceso educativo.

Finalmente, el aporte general de los autores puede resumirse en la creación y evaluación de un modelo de aprendizaje en línea que combina autonomía, personalización y retroalimentación. El estudio demuestra que un sistema virtual puede mejorar el rendimiento académico cuando se adapta a las necesidades conceptuales y preferencias de los estudiantes. Además, muestra que la aceptación del sistema depende de que los alumnos perciban utilidad, facilidad de uso e impacto positivo en su aprendizaje. Por ello, el artículo representa una contribución importante para el diseño de entornos educativos inteligentes, especialmente en contextos donde se busca fortalecer el aprendizaje autónomo y personalizado.

Proceso para obtener el aporte

El proceso seguido por los autores para obtener su aporte se basó en el diseño, implementación y evaluación de un entorno de **aprendizaje autorregulado en línea guiado por un enfoque de aprendizaje personalizado**. Para ello, primero identificaron una necesidad educativa concreta: los sistemas tradicionales de aprendizaje en línea suelen ofrecer los mismos contenidos y sugerencias a todos los estudiantes, sin considerar sus dificultades conceptuales ni sus preferencias de aprendizaje. Frente a esta limitación, los autores propusieron un sistema capaz de diagnosticar el estado conceptual de cada alumno, recomendar rutas de aprendizaje personalizadas y ofrecer materiales adecuados a sus características individuales.

En primer lugar, los autores diseñaron la estructura del sistema tomando como base los principios del aprendizaje autorregulado. El entorno permitió que los estudiantes establecieran metas de aprendizaje, definieran el tiempo que esperaban dedicar a las actividades, resolvieran tareas, revisaran materiales, evaluaran su avance y recibieran retroalimentación. Este proceso siguió la lógica del aprendizaje autorregulado, donde el estudiante planifica, ejecuta y reflexiona sobre su propio aprendizaje. Además, el sistema registró datos de autorregulación, como el cumplimiento del tiempo planificado y el avance conceptual, para apoyar la toma de decisiones durante el proceso formativo.

Luego, los autores incorporaron un mecanismo de personalización. El sistema analizaba las respuestas de los estudiantes en una prueba diagnóstica y calculaba el nivel de error en cada concepto. A partir de este cálculo, identificaba los conceptos no aprendidos, parcialmente aprendidos o bien aprendidos, y generaba una ruta de aprendizaje individual. Esta ruta permitía que cada estudiante recibiera actividades remediales según sus necesidades reales. Asimismo, el sistema aplicaba un cuestionario de estilos de aprendizaje para recomendar materiales en formatos adecuados a las preferencias del alumno, como videos, notas digitales, actividades interactivas o recursos de lectura.

Después de diseñar el sistema, los autores realizaron una investigación cuasi-experimental con enfoque cuantitativo en cinco escuelas secundarias de Tailandia. La muestra estuvo conformada por **292 estudiantes** que estudiaron el tema de circuitos eléctricos en un curso de Física. Los participantes fueron divididos en dos grupos: **144 estudiantes** formaron el grupo experimental, que utilizó el aprendizaje autorregulado en línea guiado por el enfoque personalizado; y **148 estudiantes** integraron el grupo de control, que utilizó un entorno convencional de aprendizaje autorregulado en línea sin guía personalizada.

Para medir la efectividad del sistema, los autores aplicaron pruebas de aprendizaje antes y después de la intervención. El pretest permitió conocer el nivel inicial de los estudiantes sobre el contenido de electricidad simple, mientras que el posttest permitió evaluar el aprendizaje logrado después de utilizar el sistema. Además, al finalizar las actividades, los estudiantes del grupo experimental respondieron un cuestionario de percepción sobre el uso del entorno personalizado. Este instrumento evaluó once constructos, entre ellos establecimiento de metas, estructuración del ambiente, estrategias de tarea, gestión del tiempo, búsqueda de ayuda, autoevaluación, utilidad de las sugerencias, facilidad de uso, actitud e intención de uso.

Finalmente, los autores analizaron los datos mediante pruebas estadísticas. Usaron pruebas t para comparar el rendimiento entre el grupo experimental y el grupo de control, y aplicaron regresión múltiple por pasos para identificar los factores que influyeron en la intención de uso del sistema. Con este proceso, pudieron demostrar que el grupo experimental obtuvo mejores resultados académicos y que variables como la utilidad percibida de las sugerencias, la facilidad de uso, la actitud y las habilidades de autorregulación influyeron en la aceptación del entorno. Así, el aporte fue obtenido mediante un proceso ordenado que combinó diseño tecnológico, intervención educativa y análisis estadístico.

Proceso para resolver el problema

El proceso para resolver el problema planteado en el artículo parte de una limitación frecuente en los entornos tradicionales de aprendizaje en línea: estos sistemas suelen promover la autonomía del estudiante, pero no siempre brindan orientación personalizada de acuerdo con sus dificultades conceptuales, preferencias de aprendizaje y nivel de autorregulación. Como consecuencia, muchos estudiantes pueden tener problemas para organizar su tiempo, seleccionar estrategias adecuadas, identificar sus errores y completar satisfactoriamente las actividades académicas. Frente a esta situación, los autores proponen un entorno de **aprendizaje autorregulado en línea guiado por un enfoque de aprendizaje personalizado**.

Primero, el sistema permite que los estudiantes establezcan sus propias metas de aprendizaje y definan el tiempo que planean dedicar a las actividades. Esta etapa es importante porque fortalece la planificación, una de las habilidades centrales del aprendizaje autorregulado. Luego, los estudiantes desarrollan actividades relacionadas con el tema de circuitos eléctricos en Física, mientras el sistema registra sus respuestas y su desempeño. A partir de esta información, el entorno identifica los conceptos en los que cada estudiante presenta mayores dificultades.

Después, el sistema calcula el nivel de error por concepto y determina el estado de aprendizaje del alumno. Con base en ese diagnóstico, genera una ruta personalizada de aprendizaje, de modo que cada estudiante reciba actividades y materiales acordes con sus necesidades específicas. Además, el sistema considera las preferencias de aprendizaje del alumno para recomendar recursos adecuados, como materiales digitales, tareas interactivas o contenidos de apoyo. Así, la solución no se limita a entregar información general, sino que adapta el proceso de aprendizaje a cada estudiante.

El proceso también incluye una fase de autoevaluación y retroalimentación. Los estudiantes pueden revisar si han cumplido sus metas, observar su progreso y decidir si están preparados para avanzar a nuevas unidades. Esta etapa permite que el alumno reflexione sobre sus logros y dificultades, reforzando habilidades como la gestión del tiempo, las estrategias de tarea y la autoevaluación. De esta manera, el sistema busca que el estudiante no dependa únicamente del docente, sino que desarrolle mayor control sobre su propio aprendizaje.

Para comprobar si la solución era efectiva, los autores aplicaron un estudio cuasi-experimental con estudiantes de secundaria. El grupo experimental utilizó el sistema autorregulado con personalización, mientras que el grupo de control utilizó un sistema convencional sin guía personalizada. Los resultados mostraron que el grupo experimental obtuvo mejores puntajes en el postest, lo que indica que la personalización ayudó a mejorar el aprendizaje del contenido de Física. En conclusión, el problema se resolvió mediante un sistema que diagnostica dificultades, adapta rutas y materiales, promueve la autorregulación y ofrece retroalimentación para mejorar el rendimiento académico.

Métricas y resultados

En el artículo, los autores evaluaron la efectividad del entorno de **aprendizaje autorregulado en línea guiado por un enfoque personalizado** mediante pruebas de rendimiento y cuestionarios de percepción. Para medir el aprendizaje en Física, aplicaron un **pretest** y un **postest** sobre el tema de circuitos eléctricos. Además, utilizaron análisis estadísticos como la **prueba t de muestras independientes**, estadística descriptiva, confiabilidad mediante **alfa de Cronbach**, correlación de Pearson y regresión múltiple por pasos para identificar los factores que influyen en la intención de uso del sistema.

Los resultados del pretest mostraron que no existían diferencias significativas entre el grupo experimental y el grupo de control, ya que ambos iniciaron con niveles similares de conocimiento: el grupo experimental obtuvo una media de **4.58**, mientras que el grupo de control obtuvo **4.61**. Sin embargo, en el postest sí se encontraron diferencias significativas. El grupo experimental, que utilizó el sistema personalizado, obtuvo una media de **7.37**, mientras que el grupo de control alcanzó **6.07**, con una diferencia significativa ($t = 5.350$; $p < 0.05$).

Respecto a las percepciones, los estudiantes valoraron positivamente el sistema. Las medias de los once constructos evaluados fueron superiores a 3.00, destacando estrategias de tarea ($M = 4.33$), gestión del tiempo ($M = 4.26$) y autoevaluación ($M = 4.23$). Además, el alfa de Cronbach general fue **0.923**, lo que indica alta confiabilidad del cuestionario. En conjunto, los resultados demuestran que el enfoque personalizado mejoró el rendimiento académico y fue aceptado favorablemente por los estudiantes.

Observaciones/críticas

Una observación importante sobre el artículo es que presenta un aporte valioso al integrar el **aprendizaje autorregulado** con un enfoque de **aprendizaje personalizado**, ya que responde a una necesidad actual de la educación en línea: adaptar las rutas, materiales y sugerencias según las dificultades y preferencias de cada estudiante. Esta propuesta resulta pertinente porque no todos los alumnos aprenden de la misma manera ni presentan los mismos problemas conceptuales, especialmente en cursos como Física, donde los contenidos pueden ser abstractos y difíciles de comprender.

Sin embargo, una crítica relevante es que el estudio se aplicó únicamente en el área de Ciencias, específicamente en el tema de circuitos eléctricos de Física, por lo que sus resultados no necesariamente pueden generalizarse a otras asignaturas. Los propios autores señalan que replicar este sistema en áreas como Matemática podría ser más complejo, debido a la presencia de símbolos, procedimientos y niveles conceptuales más difíciles de organizar en rutas personalizadas.

Otra limitación es que la investigación utiliza principalmente un enfoque cuantitativo. Aunque los cuestionarios permiten conocer la percepción de los estudiantes, hubiera sido útil incorporar entrevistas o respuestas abiertas para comprender con mayor profundidad cómo vivieron la experiencia, qué dificultades tuvieron y qué aspectos del sistema consideran más útiles. Además, la utilidad percibida de las sugerencias fue una de las dimensiones con menor valoración, lo que indica que el sistema aún podría mejorar la claridad y precisión de sus recomendaciones.

A pesar de estas limitaciones, el artículo es sólido porque demuestra que la personalización puede fortalecer el aprendizaje autorregulado y mejorar el rendimiento académico. Su mayor fortaleza está en mostrar que los entornos virtuales deben ir más allá de ofrecer contenidos generales: deben diagnosticar dificultades, adaptar materiales y acompañar al estudiante en su proceso de aprendizaje.

Author (s): Vasiliki Matzavela; Efthimios Alepis

Title of paper: Decision tree learning through a Predictive Model for Student Academic Performance in Intelligent M-Learning environments

Journal: Computers and Education: Artificial Intelligence

Volume (issue): Volume 2

pag – pag (year): Article 100035, pp. 1–12 (2021)

Estado del arte

En los últimos años, los entornos inteligentes de aprendizaje móvil —**m-learning**— y aprendizaje en línea han adquirido una importancia creciente dentro de la educación superior. Este crecimiento se intensificó especialmente durante la pandemia de Covid-19, cuando las instituciones educativas tuvieron que adaptar sus procesos de enseñanza, aprendizaje y evaluación a modalidades digitales y combinadas. En este contexto, surgió la necesidad de diseñar sistemas educativos más personalizados, capaces de responder al nivel cognitivo, ritmo de aprendizaje y características individuales de cada estudiante. Por ello, la investigación en educación apoyada por inteligencia artificial ha comenzado a centrarse en modelos predictivos que permitan evaluar el desempeño académico y adaptar las actividades de aprendizaje de manera dinámica.

Dentro de este campo, la **minería de datos educativos** —Educational Data Mining, EDM— y la **analítica del aprendizaje** han desempeñado un papel fundamental. La EDM se orienta al análisis de datos provenientes de sistemas educativos, registros de estudiantes, plataformas digitales y bases de datos académicas, con el propósito de descubrir patrones que ayuden a mejorar el proceso de enseñanza-aprendizaje. Por su parte, la analítica del aprendizaje busca comprender el comportamiento del estudiante, estimar su posible rendimiento y detectar situaciones de riesgo académico. Ambas áreas han permitido responder preguntas relevantes, como qué características influyen en el desempeño, qué secuencias educativas son más efectivas, qué estudiantes podrían presentar dificultades y cómo adaptar la enseñanza a las necesidades individuales.

Uno de los métodos más utilizados dentro de la minería de datos educativos es el **aprendizaje mediante árboles de decisión**. Esta técnica se caracteriza por generar modelos de clasificación y predicción fáciles de comprender, interpretar y representar gráficamente. A diferencia de otros modelos más complejos, los árboles de decisión permiten observar con claridad las reglas que conducen a una determinada clasificación. Además, pueden trabajar con datos numéricos y categóricos, requieren poca preparación previa y resultan adecuados para problemas educativos en los que se busca relacionar variables del perfil del estudiante con su desempeño académico. Por estas razones, los árboles de decisión han sido empleados en diversos estudios para predecir calificaciones, clasificar niveles de conocimiento y apoyar sistemas de aprendizaje adaptativo.

La literatura previa también ha explorado el uso de evaluaciones dinámicas y personalizadas en entornos digitales. A diferencia de los exámenes tradicionales, las evaluaciones adaptativas ajustan el nivel de dificultad de las preguntas según las respuestas del estudiante. Esto permite obtener una medición más precisa de su conocimiento, ya que no todos los estudiantes reciben exactamente las mismas preguntas, sino aquellas que se ajustan mejor a su nivel. Sin embargo, los autores señalan que todavía existe una falta notable de estudios específicos sobre **m-assessment**, es decir, evaluación mediante dispositivos móviles, como una evolución del m-learning. La mayoría de investigaciones previas se ha centrado en evaluar el aprendizaje móvil mediante cuestionarios tradicionales o pruebas no dinámicas, lo cual limita el potencial de personalización.

En este panorama, el artículo analizado propone una contribución orientada a integrar árboles de decisión con evaluación adaptativa en entornos inteligentes de m-learning. Los autores diseñan un modelo predictivo basado en el algoritmo **DT-Quest**, cuyo objetivo es determinar dinámicamente el nivel de conocimiento del estudiante y seleccionar preguntas de diferentes niveles de dificultad según su desempeño. El modelo considera variables del perfil estudiantil, como género, calificación, educación de los padres, ingreso familiar, si el estudiante es el primer hijo y si trabaja. A partir de estas variables y del rendimiento en las evaluaciones, el sistema busca construir un perfil individual que permita personalizar la experiencia de aprendizaje.

El estado del arte muestra que la personalización educativa requiere modelos capaces de clasificar, predecir y adaptar los contenidos según las características del estudiante. Aunque existen diferentes técnicas de inteligencia artificial aplicadas a la educación, los árboles de decisión mantienen una ventaja importante por su interpretabilidad y facilidad de uso en contextos pedagógicos. El aporte del artículo se ubica precisamente en esta línea, al proponer un modelo que combina minería de datos, aprendizaje por árboles de decisión y evaluación móvil adaptativa para mejorar la predicción del rendimiento académico. En síntesis, la investigación refleja una tendencia actual de la educación digital: avanzar desde sistemas generales de enseñanza hacia entornos inteligentes, personalizados y sensibles al nivel real de conocimiento de cada estudiante.

Motivación del autor

La motivación principal de los autores surge de la necesidad de mejorar la personalización del aprendizaje en entornos inteligentes de **m-learning**. En la educación superior actual, especialmente después del crecimiento de la enseñanza virtual y combinada, los docentes requieren herramientas que permitan evaluar de manera más precisa el nivel académico de cada estudiante. Los autores observan que los sistemas tradicionales de evaluación no siempre responden a las diferencias individuales, ya que suelen aplicar las mismas preguntas o pruebas a todos los estudiantes, sin considerar su perfil, conocimientos previos o ritmo de aprendizaje.

Por esta razón, los autores buscan desarrollar un modelo predictivo basado en **árboles de decisión** que permita crear pruebas dinámicas y adaptativas. Su intención es que el sistema seleccione preguntas de acuerdo con el nivel de conocimiento demostrado por cada estudiante, comparando constantemente los resultados de la evaluación con el modelo generado por el algoritmo **DT-Quest**. Además, el estudio considera variables del perfil del estudiante, como género, calificación, educación de los padres, ingreso familiar, si trabaja o si es el primer hijo. La motivación final es ofrecer un entorno educativo más inteligente, personalizado y capaz de mejorar la evaluación del rendimiento académico según las necesidades reales de cada estudiante.

Descripción del aporte del autor

El principal aporte de los autores consiste en proponer un modelo predictivo basado en **aprendizaje por árboles de decisión** para mejorar la evaluación del rendimiento académico en entornos inteligentes de **m-learning**. La investigación se orienta a resolver una necesidad importante de la educación digital: adaptar la evaluación al nivel real de conocimiento de cada estudiante. En lugar de utilizar pruebas tradicionales, iguales para todos, los autores plantean una evaluación dinámica que modifica la dificultad de las preguntas de acuerdo con las respuestas del estudiante y con su perfil académico. De esta manera, el sistema no solo evalúa, sino que también personaliza el proceso de aprendizaje.

Uno de los aportes más relevantes del artículo es la creación del algoritmo **DT-Quest**, un algoritmo basado en árboles de decisión que permite seleccionar preguntas de forma adaptativa. Este algoritmo organiza los ejercicios en cuatro niveles de dificultad y asigna pesos diferentes a cada pregunta según su nivel. La finalidad es que el estudiante no responda una prueba

estática, sino una secuencia de preguntas construida dinámicamente. Si el estudiante responde correctamente, el sistema puede aumentar o mantener la dificultad; si responde incorrectamente, puede ajustar la siguiente pregunta para identificar con mayor precisión su nivel de conocimiento. Este procedimiento permite evaluar de manera más personalizada el rendimiento académico.

El uso del árbol de decisión representa un aporte importante porque ofrece una estructura clara, interpretable y visual. A diferencia de otros modelos de inteligencia artificial más complejos, los árboles de decisión permiten comprender fácilmente el camino que sigue el sistema para llegar a una determinada clasificación. Esto es valioso en educación, porque tanto docentes como diseñadores de sistemas de aprendizaje pueden interpretar cómo se determina el nivel del estudiante y qué criterios influyen en la evaluación. Los autores aprovechan esta característica para construir un modelo que no solo predice, sino que también puede ser explicado y representado gráficamente.

Otro aporte significativo es la integración entre **minería de datos educativos** y **evaluación adaptativa móvil**. El artículo no se limita a describir el uso de árboles de decisión desde una perspectiva teórica, sino que los aplica en un contexto de m-learning, donde la evaluación puede realizarse mediante dispositivos móviles. Esta orientación resulta actual y pertinente, debido al crecimiento de la educación en línea, el aprendizaje combinado y el uso de tecnologías móviles en la enseñanza superior. Los autores buscan que el sistema responda a las necesidades individuales del estudiante y favorezca una experiencia de aprendizaje más flexible e inteligente.

El estudio también aporta una metodología organizada en cuatro etapas: **recolección de datos, clasificación, creación del modelo predictivo y evaluación**. En la primera etapa, se recopilaban datos de estudiantes universitarios y se definieron variables relacionadas con su perfil académico y personal. En la segunda etapa, se clasificó a los estudiantes según sus características. En la tercera, se construyó el modelo predictivo mediante el algoritmo DT-Quest. Finalmente, en la etapa de evaluación, se compararon los resultados obtenidos por el sistema con el rendimiento real de los estudiantes. Esta estructura metodológica permite comprender de manera ordenada cómo se obtiene el modelo y cómo se valida su utilidad educativa.

Un elemento importante del aporte es la consideración de variables del perfil estudiantil. Los autores analizaron datos de **213 estudiantes** de educación superior que participaron en un curso durante la primavera de 2020. Las variables consideradas fueron: género, calificación, educación de los padres, ingreso familiar, si el estudiante era el primer hijo y si trabajaba. Estas variables fueron seleccionadas porque, según la literatura, pueden influir en el rendimiento académico y en las necesidades de aprendizaje del estudiante. Con ello, los autores muestran que la predicción del desempeño no depende únicamente de las respuestas correctas o incorrectas, sino también de características personales y contextuales.

El aporte pedagógico se evidencia en la intención de construir un sistema que permita identificar distintos perfiles de estudiantes. Por ejemplo, el modelo permite diferenciar entre estudiantes con alto rendimiento, estudiantes con desempeño intermedio y estudiantes con mayores dificultades académicas. Esta clasificación puede ayudar a los docentes a comprender mejor las necesidades de sus alumnos y a diseñar estrategias de acompañamiento más adecuadas. En un entorno inteligente de aprendizaje, esta información puede utilizarse para seleccionar actividades, ejercicios o rutas de aprendizaje según el nivel de cada estudiante.

Asimismo, los autores aportan una forma novedosa de evaluar el conocimiento mediante preguntas con pesos. En el algoritmo DT-Quest, las preguntas tienen diferentes valores según su dificultad. Las preguntas de niveles más altos tienen mayor peso, mientras que las de niveles bajos tienen menor peso. Esto permite que la evaluación no dependa solo del número de

respuestas correctas, sino también de la dificultad de las preguntas respondidas. Por ejemplo, un estudiante que responde correctamente preguntas de mayor dificultad puede demostrar un nivel más alto de conocimiento con menos preguntas. Esta lógica hace que la prueba sea más eficiente y adaptativa.

Otro aspecto destacable es que el modelo busca reducir la cantidad de preguntas necesarias para evaluar al estudiante, sin perder precisión. El algoritmo intenta encontrar una ruta mínima dentro del árbol de decisión, es decir, una secuencia adecuada de preguntas que permita estimar el nivel académico del estudiante con el menor número posible de ejercicios. Esto es importante porque evita evaluaciones demasiado largas, mejora la experiencia del estudiante y permite una medición más rápida del conocimiento. En el artículo, los autores presentan distintos casos de uso que muestran cómo el sistema adapta la secuencia de preguntas según las respuestas del estudiante.

El estudio aporta también resultados descriptivos sobre la relación entre las variables del perfil estudiantil y el rendimiento académico. Los autores analizaron cuatro casos según rangos de calificación: estudiantes con notas entre 80 y 100 puntos, entre 51 y 79, entre 31 y 50, y entre 0 y 30. Los resultados muestran que los estudiantes con calificaciones más altas tienden a presentar mayor proporción de padres con buena educación, ingresos familiares más altos y menor porcentaje de estudiantes que trabajan. En cambio, los estudiantes con calificaciones más bajas presentan mayor presencia de padres con menor nivel educativo, ingresos familiares bajos y mayor proporción de estudiantes trabajadores.

Estos resultados son importantes porque muestran que el rendimiento académico puede estar relacionado con factores sociales y familiares. El artículo no plantea que estas variables determinen completamente el desempeño, pero sí evidencia que pueden influir en las condiciones de aprendizaje. Por ejemplo, un estudiante que trabaja puede tener menos tiempo disponible para estudiar, mientras que un estudiante con mayor apoyo familiar o mejores condiciones económicas puede tener más recursos para su formación. Esta información permite que el sistema de aprendizaje adaptativo no solo evalúe respuestas, sino que considere el contexto del estudiante.

Desde el punto de vista de la innovación educativa, el aporte del artículo se encuentra en combinar **clasificación, predicción y personalización**. La clasificación permite organizar a los estudiantes según sus características y desempeño; la predicción permite estimar su nivel de conocimiento; y la personalización permite adaptar las preguntas y la evaluación a cada estudiante. Esta combinación responde a una tendencia actual en la educación digital: pasar de sistemas generales y uniformes a entornos inteligentes capaces de tomar decisiones según el comportamiento y perfil del estudiante.

El artículo también contribuye al campo de la evaluación educativa porque propone una alternativa a las pruebas tradicionales. En muchos contextos, los exámenes convencionales presentan las mismas preguntas para todos los estudiantes, sin considerar diferencias de preparación, ritmo o nivel cognitivo. En cambio, el modelo propuesto permite que cada estudiante reciba una evaluación ajustada a su desempeño. Esto puede generar una medición más justa y precisa, ya que el sistema se adapta progresivamente a lo que el estudiante demuestra saber o no saber.

Además, la propuesta tiene valor para los docentes, porque puede ofrecer información más detallada sobre el aprendizaje de cada estudiante. En lugar de limitarse a entregar una nota final, el sistema puede mostrar rutas de desempeño, niveles de dificultad superados y áreas donde el estudiante necesita mayor refuerzo. Esta información puede orientar mejores decisiones pedagógicas, como recomendar ejercicios adicionales, modificar estrategias de enseñanza o brindar apoyo personalizado.

Sin embargo, el aporte de los autores no debe entenderse solo como una solución técnica, sino como una propuesta para mejorar la calidad del aprendizaje. El objetivo final es que los sistemas inteligentes de m-learning ayuden a fortalecer el rendimiento académico y la experiencia educativa. La evaluación adaptativa puede aumentar la motivación del estudiante, porque evita pruebas demasiado fáciles o demasiado difíciles, y permite que la actividad se ajuste mejor a sus capacidades. De esta manera, el modelo puede contribuir a un aprendizaje más individualizado y significativo.

En conclusión, el aporte de los autores se resume en la creación de un modelo predictivo basado en árboles de decisión para evaluar y personalizar el aprendizaje en entornos inteligentes de m-learning. El algoritmo DT-Quest permite seleccionar preguntas dinámicas según el nivel del estudiante, utilizar pesos por dificultad, construir rutas mínimas de evaluación y relacionar el desempeño académico con variables del perfil estudiantil. El valor del estudio está en integrar minería de datos educativos, árboles de decisión y evaluación adaptativa para mejorar la predicción del rendimiento académico y ofrecer una experiencia educativa más personalizada, interpretable y ajustada a las necesidades de cada estudiante.

Proceso para obtener el aporte

Para obtener su aporte, los autores desarrollaron un proceso metodológico basado en la combinación de **minería de datos educativos, aprendizaje por árboles de decisión y evaluación adaptativa** en entornos inteligentes de m-learning. El estudio tuvo como objetivo construir un modelo capaz de predecir el rendimiento académico del estudiante y, al mismo tiempo, adaptar dinámicamente las preguntas de evaluación según su nivel de conocimiento. Para ello, se trabajó con datos reales de **213 estudiantes universitarios** que participaron en un curso durante la primavera de 2020.

El primer paso consistió en la **recolección de datos**. Los autores identificaron variables relacionadas con el perfil del estudiante, tales como género, calificación, educación de los padres, ingreso familiar, si el estudiante era el primer hijo y si trabajaba. Estas variables fueron seleccionadas porque pueden influir en el rendimiento académico y en las necesidades de aprendizaje. Además, se consideró la nota del estudiante en una escala de 0 a 100 puntos, donde 50 puntos representaban la calificación mínima aprobatoria. Con esta información se construyó una base de datos orientada a clasificar perfiles estudiantiles y analizar su relación con el desempeño.

El segundo paso fue la **clasificación de los estudiantes**. A partir de las variables recolectadas, los autores organizaron a los estudiantes según sus características personales, familiares y académicas. Posteriormente, realizaron un análisis porcentual para identificar tendencias en los distintos grupos de rendimiento. Por ejemplo, compararon estudiantes con notas altas, medias y bajas, observando diferencias relacionadas con el nivel educativo de los padres, el ingreso familiar y la condición laboral del estudiante. Este análisis permitió reconocer patrones que podían incorporarse al modelo predictivo.

El tercer paso consistió en la **creación del modelo predictivo** mediante el algoritmo **DT-Quest**. Este algoritmo se basó en un árbol de decisión con preguntas organizadas en cuatro niveles de dificultad. Cada nivel tenía un peso específico: las preguntas de mayor dificultad aportaban más puntos y las de menor dificultad aportaban menos. El algoritmo iniciaba presentando preguntas de diferentes niveles y, según las respuestas del estudiante, decidía dinámicamente cuál debía ser la siguiente pregunta. De esta manera, el sistema construía una ruta personalizada dentro del árbol de decisión, buscando evaluar el conocimiento del estudiante con la menor cantidad posible de preguntas, pero manteniendo una medición adecuada de su nivel académico.

El cuarto paso fue la **evaluación del modelo**. Los resultados obtenidos mediante la evaluación adaptativa fueron comparados con las calificaciones reales y con las variables del perfil

estudiantil. Esta comparación permitió comprobar si existía relación entre el desempeño académico y factores como el ingreso familiar, la educación de los padres o la condición de estudiante trabajador. Los autores encontraron que los estudiantes con mejores calificaciones tendían a tener padres con mayor nivel educativo, mejores ingresos y menor carga laboral; mientras que los estudiantes con calificaciones más bajas presentaban con mayor frecuencia condiciones socioeconómicas menos favorables y mayor proporción de trabajo.

Finalmente, mediante este proceso, los autores lograron demostrar que un modelo basado en árboles de decisión puede ser útil para personalizar la evaluación académica en entornos inteligentes de m-learning. El aporte se obtuvo al integrar datos del perfil estudiantil, reglas de decisión, pesos por dificultad y evaluación dinámica, permitiendo que el sistema adapte las preguntas según el desempeño individual de cada estudiante.

Proceso para resolver el problema

Para resolver el problema de la evaluación y predicción del rendimiento académico en entornos inteligentes de **m-learning**, los autores plantearon una solución basada en **minería de datos educativos y aprendizaje por árboles de decisión**. El problema principal identificado fue que muchos sistemas de evaluación tradicionales aplican las mismas pruebas a todos los estudiantes, sin considerar sus diferencias individuales, su nivel de conocimiento, sus características personales o sus condiciones familiares y académicas. Frente a ello, los autores propusieron un modelo predictivo que permite adaptar dinámicamente las preguntas de evaluación según el desempeño del estudiante.

El primer paso fue definir las variables que podían influir en el rendimiento académico. Para ello, los autores trabajaron con datos de **213 estudiantes universitarios** y consideraron características como género, calificación, educación de los padres, ingreso familiar, si el estudiante era el primer hijo y si trabajaba. Estas variables fueron utilizadas para construir el perfil del estudiante y analizar su relación con el desempeño académico. De esta manera, el problema no se abordó únicamente desde las respuestas del examen, sino también desde factores personales y contextuales que podían afectar el aprendizaje.

Luego, los autores diseñaron un sistema de evaluación adaptativa basado en el algoritmo **DT-Quest**. Este algoritmo organiza las preguntas en cuatro niveles de dificultad y asigna un peso a cada una según su nivel. Al inicio, el estudiante responde preguntas de diferentes niveles; después, el sistema analiza si las respuestas son correctas o incorrectas y decide cuál será la siguiente pregunta. Si el estudiante demuestra buen dominio, el sistema puede presentar preguntas de mayor dificultad; si presenta dificultades, puede ajustar la ruta de evaluación para identificar mejor su nivel real de conocimiento.

El tercer paso consistió en construir un árbol de decisión que permitiera seguir rutas personalizadas de evaluación. Cada camino dentro del árbol representa una secuencia posible de preguntas según el desempeño del estudiante. El objetivo fue encontrar una ruta adecuada y de menor longitud posible, evitando aplicar una prueba extensa e igual para todos. Así, el sistema evalúa de forma más eficiente, porque adapta la cantidad y dificultad de las preguntas al comportamiento del estudiante durante la evaluación.

Finalmente, los autores compararon los resultados obtenidos mediante el modelo predictivo con las calificaciones reales y las variables del perfil estudiantil. Este proceso permitió identificar relaciones entre el rendimiento académico y factores como la educación de los padres, el ingreso familiar y la condición laboral del estudiante. Con ello, el problema se resolvió mediante una evaluación personalizada, dinámica e interpretable, capaz de predecir el nivel académico del estudiante y apoyar decisiones pedagógicas más ajustadas a sus necesidades individuales.

Métricas y resultados

En este artículo, los autores no presentan métricas clásicas de machine learning como accuracy, precision, recall, F1-score o AUC. La evaluación se realizó principalmente mediante el **análisis porcentual de variables del perfil estudiantil** y su relación con los rangos de calificación obtenidos por los estudiantes. Para ello, trabajaron con una muestra de **213 estudiantes** y organizaron los resultados académicos en cuatro casos: calificaciones de **80 a 100 puntos**, de **51 a 79 puntos**, de **31 a 50 puntos** y de **0 a 30 puntos**. Además, consideraron variables como género, educación de los padres, ingreso familiar, si el estudiante era el primer hijo y si trabajaba.

Los resultados muestran que los estudiantes con mejores calificaciones, entre **80 y 100 puntos**, tenían en su mayoría padres bien educados (**94%**), ingresos familiares altos o medios y menor proporción de estudiantes que trabajaban. En cambio, en el grupo con calificaciones más bajas, entre **0 y 30 puntos**, el **89%** tenía padres con menor nivel educativo, el **75%** provenía de familias con bajos ingresos y el **78%** trabajaba. Asimismo, los autores observaron que el ingreso familiar, la educación de los padres y la condición laboral del estudiante se relacionaban con el rendimiento académico. En conjunto, estos resultados evidencian que el modelo DT-Quest y el análisis mediante árbol de decisión permiten identificar perfiles estudiantiles diferenciados y adaptar la evaluación según el nivel de conocimiento de cada estudiante.

Observaciones/críticas

Una observación positiva del artículo es que propone una alternativa interesante para mejorar la evaluación académica en entornos inteligentes de **m-learning**. El uso del algoritmo **DT-Quest** permite adaptar dinámicamente las preguntas según el nivel de conocimiento del estudiante, lo cual representa una ventaja frente a las evaluaciones tradicionales, donde todos responden la misma prueba sin considerar sus diferencias individuales. Además, el empleo de árboles de decisión resulta adecuado en educación porque permite construir modelos interpretables, fáciles de representar gráficamente y comprensibles para docentes y estudiantes.

Sin embargo, también se pueden señalar algunas críticas. La principal limitación es que el estudio no presenta métricas predictivas formales como accuracy, precision, recall o AUC, lo que dificulta medir con mayor rigor el desempeño real del modelo. Además, la muestra utilizada fue de **213 estudiantes**, por lo que sería necesario aplicar el sistema en poblaciones más amplias y en distintas asignaturas para comprobar su generalización. También sería conveniente profundizar en la validación del algoritmo frente a otros modelos de machine learning, no solo mediante análisis porcentuales. A pesar de ello, el artículo aporta una propuesta valiosa porque combina evaluación adaptativa, minería de datos y árboles de decisión para personalizar el aprendizaje según el perfil y rendimiento del estudiante.

29. ARTÍCULO 29

Author (s): Ijaz Khan; Abdul Rahim Ahmad; Nafaa Jabeur; Mohammed Najah Mahdi.

Title of paper: *An artificial intelligence approach to monitor student performance and devise preventive measures.*

Journal: *Smart Learning Environments.*

Volume (issue): 8(17).

pag – pag (year): 1–18 (2021).

Estado del arte

El estudio sobre el monitoreo del rendimiento académico mediante **inteligencia artificial** y **Machine Learning** se ha convertido en una línea importante dentro de la analítica educativa, debido a que las instituciones actuales generan y almacenan grandes cantidades de datos sobre sus estudiantes. Estos datos pueden provenir de registros académicos, evaluaciones, asistencia, plataformas virtuales, información administrativa y antecedentes del estudiante. Sin embargo,

el problema central no es solamente recolectar información, sino saber utilizarla para mejorar la calidad educativa, detectar dificultades a tiempo y apoyar a los alumnos que presentan bajo rendimiento.

En este contexto, el artículo revisado señala que una de las principales dificultades para los docentes es monitorear de manera sistemática el progreso académico de los estudiantes durante el desarrollo de un curso. Muchas veces, el profesor identifica a los alumnos con problemas cuando ya es demasiado tarde para intervenir de manera efectiva. Por ello, los autores plantean que los modelos predictivos basados en Machine Learning pueden ayudar a reconocer tempranamente a los estudiantes con riesgo de obtener resultados insatisfactorios, permitiendo que el docente diseñe medidas preventivas antes de que finalice el semestre.

El estado actual de la investigación muestra que la inteligencia artificial se ha utilizado en distintos ámbitos educativos para analizar datos, descubrir patrones y apoyar la toma de decisiones. Dentro de este campo, Machine Learning representa una herramienta especialmente útil porque permite entrenar modelos con datos históricos y luego predecir resultados en nuevos casos. En educación, estos modelos se han aplicado para predecir calificaciones finales, detectar estudiantes con riesgo de abandono, identificar bajo rendimiento en cursos específicos y apoyar acciones de tutoría o asesoría académica.

Diversos estudios previos han utilizado algoritmos supervisados como **árboles de decisión**, **redes neuronales artificiales**, **Naïve Bayes**, **k-Nearest Neighbors** y **máquinas de soporte vectorial** para construir modelos de predicción del rendimiento estudiantil. Estos algoritmos trabajan con variables académicas y personales, como calificaciones previas, asistencia, promedio acumulado, resultados de exámenes, información demográfica y participación en actividades educativas. La literatura revisada por los autores confirma que estos métodos pueden ser productivos para anticipar el desempeño final de los estudiantes, aunque su efectividad suele depender del contexto institucional y del curso donde se aplican.

Un aspecto importante del estado del arte es que muchos modelos predictivos funcionan adecuadamente en un contexto local, pero no siempre pueden generalizarse directamente a otras instituciones o asignaturas. Los autores destacan que el aprendizaje es un fenómeno local, por lo que los estudiantes pueden comportarse de manera diferente según el entorno educativo, el curso, la metodología docente y las características institucionales. Por esta razón, el artículo desarrolla un modelo específico para un curso impartido en Buraimi University College, en Omán, con el propósito de identificar estudiantes en riesgo dentro de ese contexto particular.

Otro punto relevante es que no basta con que un modelo prediga correctamente; también debe ser comprensible para el docente. En muchos casos, los modelos de Machine Learning pueden ser precisos, pero difíciles de interpretar. Esto limita su utilidad práctica, porque el profesor necesita entender qué factores influyen en el riesgo académico para poder tomar decisiones. Por ello, los autores consideran que los árboles de decisión son especialmente útiles, ya que permiten transformar los resultados del modelo en reglas claras y fáciles de interpretar, como relaciones entre CGPA, nota del primer examen y asistencia.

En el artículo, el estado del arte se concreta en una propuesta que no solo busca predecir el rendimiento final, sino también convertir la predicción en **medidas preventivas**. Esto significa que el modelo no termina con la clasificación del estudiante como de bajo o alto rendimiento, sino que sirve como base para acciones como entrevistas de asesoría, clases adicionales, advertencias sobre asistencia y seguimiento personalizado. Esta orientación es importante porque conecta la inteligencia artificial con la intervención pedagógica directa.

En síntesis, el estado del arte evidencia que Machine Learning tiene un alto potencial para apoyar el monitoreo académico y la detección temprana de estudiantes en riesgo. Sin embargo, también muestra que los modelos deben ser interpretables, contextualizados y vinculados con

acciones concretas de apoyo. El artículo aporta a esta línea de investigación al desarrollar un modelo basado en árboles de decisión que permite al docente identificar factores clave del bajo rendimiento y aplicar medidas preventivas desde las primeras semanas del curso.

Motivación del autor

La motivación principal de los autores surge de la necesidad de ayudar a los docentes a **monitorear de manera temprana y sistemática el rendimiento académico de los estudiantes**. En muchos cursos, el profesor recién identifica a los alumnos con dificultades cuando el semestre ya está avanzado o cuando los resultados finales son insatisfactorios. Esta situación reduce las posibilidades de intervenir a tiempo y de ofrecer apoyo académico efectivo. Por ello, los autores buscan utilizar la inteligencia artificial como una herramienta que permita detectar oportunamente a los estudiantes con riesgo de bajo rendimiento.

Otra motivación importante es que las instituciones educativas actuales almacenan grandes cantidades de datos sobre sus estudiantes, como asistencia, calificaciones, promedio acumulado, resultados de cursos previos y otros registros académicos. Sin embargo, muchas veces estos datos no se aprovechan adecuadamente para mejorar la calidad educativa. En el artículo se señala que las instituciones necesitan procedimientos innovadores para utilizar esa información y fortalecer sus procesos de toma de decisiones.

Asimismo, los autores se motivan por desarrollar un modelo que no solo prediga el rendimiento final, sino que también sea comprensible para el docente. Por eso, buscan transformar el modelo predictivo en reglas claras que permitan identificar factores de riesgo y diseñar medidas preventivas. En este sentido, la investigación pretende que el uso de Machine Learning no se limite a clasificar estudiantes, sino que ayude a implementar acciones concretas como asesorías, clases adicionales, advertencias de asistencia y seguimiento personalizado.

Descripción del aporte del autor

El aporte principal de Ijaz Khan, Abdul Rahim Ahmad, Nafaa Jabeur y Mohammed Najah Mahdi en el artículo **“An artificial intelligence approach to monitor student performance and devise preventive measures”** consiste en desarrollar un enfoque basado en **inteligencia artificial y Machine Learning** para monitorear el rendimiento académico de los estudiantes desde las primeras etapas de un curso, identificar a quienes se encuentran en riesgo de obtener resultados insatisfactorios y proponer medidas preventivas para apoyarlos oportunamente. Este aporte es relevante porque responde a una necesidad concreta de los docentes: contar con una herramienta que les permita detectar dificultades académicas antes de que sea demasiado tarde para intervenir.

Uno de los aportes más importantes del artículo es que no se limita a construir un modelo predictivo, sino que busca convertir sus resultados en acciones útiles para el docente y los estudiantes. En muchos estudios de analítica educativa, los modelos de Machine Learning se usan únicamente para clasificar a los alumnos según su posible rendimiento final. Sin embargo, los autores plantean que una predicción tiene mayor valor cuando permite tomar decisiones pedagógicas. Por ello, su propuesta transforma el modelo en una herramienta práctica para diseñar medidas de apoyo, tales como entrevistas de asesoría, clases adicionales, advertencias sobre asistencia y seguimiento personalizado.

El artículo parte de un problema real en las instituciones educativas: actualmente se recopilan grandes cantidades de datos sobre los estudiantes, pero muchas veces esa información no se utiliza de manera estratégica para mejorar la calidad educativa. Los autores señalan que las instituciones almacenan datos relacionados con documentos académicos, asistencia, comportamiento, evaluaciones, interacción con plataformas digitales y registros administrativos, pero necesitan procedimientos innovadores para aprovecharlos en la toma de

decisiones. En ese sentido, el aporte de la investigación consiste en mostrar cómo esos datos pueden transformarse en conocimiento útil para prevenir el bajo rendimiento.

Otro aporte significativo es la construcción de modelos predictivos con distintos algoritmos de Machine Learning. Los autores aplicaron algoritmos como **k-Nearest Neighbors**, **árbol de decisión**, **redes neuronales artificiales** y **Naïve Bayes**, con el propósito de comparar cuál ofrecía mejores resultados para predecir el rendimiento final de los estudiantes. Esta comparación es importante porque permite seleccionar el modelo más adecuado en función de métricas objetivas y no solo por preferencia teórica. El modelo que obtuvo mejor desempeño fue el árbol de decisión, por lo que fue seleccionado para su interpretación y aplicación práctica.

El uso del **árbol de decisión** constituye un aporte fundamental del estudio, ya que este tipo de algoritmo no solo permite realizar predicciones, sino también representar el razonamiento del modelo de manera comprensible. A diferencia de otros modelos más complejos, como las redes neuronales, el árbol de decisión puede expresarse en reglas claras del tipo “si ocurre esto, entonces el estudiante pertenece a esta categoría”. Esto resulta especialmente útil para los docentes, porque les permite comprender qué factores están influyendo en el riesgo académico y cómo pueden actuar frente a ellos.

En la investigación, los autores identifican que las variables más relevantes para predecir el rendimiento del estudiante fueron el **CGPA**, las calificaciones del curso prerequisite, la nota del primer examen y la asistencia. Estas variables fueron seleccionadas mediante un procedimiento de reducción de características, utilizando el método **Gain Ratio Attribute Evaluator**, que permitió ordenar los atributos según su importancia para la clasificación. Entre todas las variables analizadas, el CGPA tuvo el mayor valor de ganancia, seguido por la calificación del curso prerequisite, la nota del primer examen y la asistencia. Este aporte permite conocer cuáles son los factores académicos más influyentes en el contexto estudiado.

Otro aspecto valioso del artículo es que el modelo permite actuar en un momento temprano del semestre. Los autores explican que el primer examen del curso se realiza aproximadamente en la sexta semana, cuando todavía queda una gran parte de la calificación pendiente. Esto significa que, si el modelo identifica estudiantes en riesgo después del primer examen, el docente aún tiene tiempo para implementar acciones correctivas. Este punto es especialmente importante, porque la detección temprana aumenta las posibilidades de que el estudiante mejore su rendimiento antes de finalizar el curso.

El aporte también se observa en la interpretación del modelo seleccionado. El árbol de decisión mostró que los estudiantes con un CGPA igual o superior a 2.79 tenían mayor probabilidad de obtener buenos resultados. En cambio, los estudiantes con CGPA menor a 2.79 necesitaban ser evaluados según otros factores, como la calificación del primer examen y el nivel de asistencia. Según las reglas del modelo, los estudiantes con CGPA menor a 2.79, nota del primer examen inferior a 91.65 % y asistencia menor a 96.35 % estaban en mayor peligro de obtener un resultado bajo en el curso. Estas reglas ofrecen al docente una guía clara para identificar situaciones de riesgo.

Desde el punto de vista pedagógico, el artículo aporta al convertir esas reglas en medidas de prevención. Antes de ejecutar el modelo, los autores sugieren que el docente enfatice la importancia de la asistencia desde el inicio del curso, ya que esta variable aparece como un factor relevante. También recomiendan prestar mayor atención a los estudiantes con CGPA bajo, incluso antes del primer examen. Después de ejecutar el modelo, el docente puede identificar a los estudiantes clasificados como de bajo rendimiento probable y ofrecerles apoyo adicional mediante asesorías, entrevistas, clases de refuerzo y recomendaciones personalizadas.

Otro aporte importante es la validación del modelo en un entorno real. Los autores no se quedaron únicamente en la fase experimental, sino que probaron el modelo durante un semestre

con una clase de 25 estudiantes. Después del primer examen, el modelo identificó a cinco estudiantes en riesgo de obtener resultados insatisfactorios. A partir de esa identificación, el docente aplicó medidas de apoyo como reuniones de asesoría, clases adicionales, advertencias sobre asistencia y orientación personalizada. Al final del curso, cuatro de los cinco estudiantes lograron obtener resultados satisfactorios, lo que evidencia la utilidad práctica del enfoque propuesto.

Este resultado demuestra que el aporte del artículo no está solo en la predicción, sino en el vínculo entre predicción e intervención. En educación, identificar a un estudiante en riesgo no tiene sentido si no se acompaña de acciones concretas para ayudarlo. Por ello, el estudio muestra que Machine Learning puede ser una herramienta de apoyo para la labor docente, siempre que se utilice como parte de un proceso más amplio de acompañamiento académico.

Además, el artículo aporta una visión contextualizada del aprendizaje. Los autores reconocen que los modelos predictivos suelen funcionar mejor en contextos específicos, porque los estudiantes pueden comportarse de manera diferente según la institución, el curso, el docente y el entorno académico. Por esta razón, el modelo fue desarrollado para un curso concreto de **Phonetics and Phonology** en Buraimi University College, en Omán. Esta decisión permite que el modelo responda a las características reales del curso y de los estudiantes analizados.

Finalmente, el aporte general de los autores puede resumirse en tres dimensiones. Primero, aportan una solución tecnológica al aplicar Machine Learning para monitorear el rendimiento académico. Segundo, ofrecen una solución interpretativa al transformar el modelo en reglas claras que el docente puede comprender. Tercero, presentan una solución pedagógica al convertir la predicción en medidas preventivas concretas. En conjunto, el artículo demuestra que la inteligencia artificial puede apoyar la mejora educativa cuando se utiliza para detectar riesgos, explicar factores de bajo rendimiento y orientar acciones de acompañamiento. Su mayor valor está en mostrar que los datos académicos pueden convertirse en decisiones oportunas para ayudar a los estudiantes antes de que fracasen en el curso.

Proceso para obtener el aporte

El proceso seguido por los autores para obtener su aporte se desarrolló mediante una metodología organizada en tres fases: **preparación de datos, evaluación experimental e implementación del modelo**. Esta estructura permitió pasar de los registros académicos de los estudiantes a un modelo predictivo comprensible y, finalmente, a medidas preventivas aplicables por el docente. El objetivo no fue solamente construir un modelo de Machine Learning, sino convertir sus resultados en una herramienta práctica para monitorear el rendimiento académico y apoyar a los estudiantes en riesgo.

En la primera fase, los autores realizaron la **preparación de los datos**. Para ello, utilizaron información académica de estudiantes de un curso presencial llamado *Phonetics and Phonology*, impartido en Buraimi University College, en Omán. El conjunto de datos estuvo compuesto por registros de tres semestres, con **151 instancias**, 10 variables predictoras y una clase de predicción que clasificaba el resultado final del estudiante como “Low” o “High”. Entre las variables consideradas se encontraban género, asistencia, especialidad, año de estudio, sesión, nota del primer examen, CGPA, patrocinio, residencia en dormitorio y calificación del curso prerequisite.

Después, los autores realizaron una limpieza de datos para eliminar información irrelevante o sensible, como nombres, códigos e identificadores de estudiantes, con el fin de proteger la privacidad y mejorar la calidad del análisis. También eliminaron o trataron instancias con valores faltantes o ruidosos, ya que este tipo de datos puede afectar negativamente el rendimiento de los algoritmos. Posteriormente, aplicaron una etapa de **selección de características** mediante el método *Gain Ratio Attribute Evaluator*, que permitió identificar

las variables más importantes para la predicción. Las cuatro variables seleccionadas fueron **CGPA, calificación del prerrequisito, nota del primer examen y asistencia**.

En la segunda fase, correspondiente a la **evaluación experimental**, los autores aplicaron distintos algoritmos de Machine Learning utilizando la herramienta WEKA. Los algoritmos evaluados fueron **k-Nearest Neighbors, árbol de decisión, red neuronal artificial y Naïve Bayes**. Para medir su desempeño, utilizaron validación cruzada de diez pliegues y métricas como Accuracy, Precision, Recall, F-Measure y Mathew Correlation Coefficient. Esta comparación permitió determinar cuál de los modelos era más adecuado para clasificar correctamente a los estudiantes según su posible rendimiento final.

Los resultados mostraron que el **árbol de decisión** obtuvo el mejor desempeño general, alcanzando una precisión superior al 86 %, un F-Measure de 0.91 y un MCC de 0.63. Además de su buen rendimiento, este modelo fue elegido porque sus reglas son fáciles de interpretar por los docentes. Esta característica era fundamental para el propósito del estudio, ya que el modelo debía transformarse en una herramienta comprensible y útil para la toma de decisiones académicas.

En la tercera fase, los autores realizaron la **implementación del modelo**. El árbol de decisión fue interpretado mediante reglas claras que relacionaban el CGPA, la nota del primer examen y la asistencia con el resultado probable del estudiante. Luego, estas reglas se utilizaron para definir medidas de apoyo antes y después de ejecutar el modelo. Finalmente, el sistema fue probado en un curso real con 25 estudiantes, donde identificó a cinco alumnas en riesgo. A partir de esa identificación, el docente aplicó asesorías, clases adicionales y advertencias de asistencia. Así, el aporte fue obtenido mediante un proceso que integró análisis de datos, selección del mejor modelo, interpretación docente y aplicación de medidas preventivas.

Proceso para resolver el problema

El proceso para resolver el problema planteado en el artículo inicia con la necesidad de detectar a tiempo a los estudiantes con bajo rendimiento académico. Los autores señalan que uno de los principales problemas del docente es monitorear de manera sistemática el progreso de los alumnos durante el curso, ya que muchas veces los estudiantes con dificultades son identificados demasiado tarde. Para enfrentar esta situación, proponen utilizar **Machine Learning** como herramienta de predicción temprana, de modo que el profesor pueda reconocer a los estudiantes en riesgo y aplicar medidas preventivas antes de que finalice el semestre .

Primero, los autores recopilaron datos académicos de estudiantes del curso **Phonetics and Phonology**, impartido en Buraimi University College. El conjunto de datos incluyó información de tres semestres, con variables como asistencia, CGPA, nota del primer examen, calificación del curso prerrequisito, género, especialidad, año de estudio, sesión, patrocinio y residencia. Luego, realizaron un proceso de limpieza para eliminar datos irrelevantes o sensibles, como nombres, códigos e identificadores, y también trataron registros con valores faltantes o ruidosos. Esto permitió trabajar con una base más confiable para el entrenamiento de los modelos.

Después, los autores aplicaron una selección de características para identificar las variables más influyentes en el rendimiento final. Mediante el método **Gain Ratio Attribute Evaluator**, seleccionaron cuatro variables principales: **CGPA, calificación del prerrequisito, nota del primer examen y asistencia**. Esta etapa fue clave porque permitió reducir la complejidad del modelo y concentrarse en los factores que realmente aportaban a la predicción del desempeño académico.

Posteriormente, se entrenaron y compararon varios algoritmos de Machine Learning: **k-Nearest Neighbors, árbol de decisión, red neuronal artificial y Naïve Bayes**. Los modelos fueron

evaluados mediante métricas como Accuracy, Precision, Recall, F-Measure y Mathew Correlation Coefficient. El modelo de **árbol de decisión** obtuvo el mejor desempeño general y fue elegido no solo por su precisión, sino también porque permite representar los resultados en reglas comprensibles para el docente.

Finalmente, el modelo se transformó en una herramienta de apoyo para la intervención educativa. Sus reglas permitieron identificar que los estudiantes con CGPA bajo, baja nota en el primer examen y asistencia reducida tenían mayor riesgo de obtener resultados insatisfactorios. Con esta información, el docente pudo aplicar medidas preventivas como entrevistas de asesoría, clases adicionales, advertencias de asistencia y recomendaciones personalizadas. En la prueba de campo, el modelo identificó a cinco estudiantes en riesgo, y cuatro de ellas lograron resultados satisfactorios al final del curso. Así, el problema se resolvió conectando predicción temprana, interpretación del modelo y acciones preventivas concretas.

Métricas y resultados

En el artículo, los autores evaluaron los modelos de **Machine Learning** mediante métricas de clasificación como **Accuracy, Precision, Recall, F-Measure** y **Mathew Correlation Coefficient (MCC)**. Estas métricas permitieron comparar el rendimiento de los algoritmos **k-Nearest Neighbors, árbol de decisión, red neuronal artificial** y **Naïve Bayes** para predecir si un estudiante terminaría el curso con un resultado “Low” o “High”. Además, se utilizó validación cruzada de diez pliegues en WEKA para asegurar una evaluación más confiable del modelo.

Los resultados mostraron que el **árbol de decisión** fue el modelo con mejor desempeño general. Este algoritmo alcanzó una exactitud superior al **86 %**, un **F-Measure de 0.91** y un **MCC de 0.63**, superando a los demás modelos evaluados. Aunque otros algoritmos también presentaron resultados aceptables, el árbol de decisión fue seleccionado porque, además de su buen rendimiento, ofrecía reglas claras y fáciles de interpretar para el docente.

En la aplicación práctica, el modelo fue probado en un curso real con **25 estudiantes**. Después del primer examen, identificó a **cinco estudiantes** en riesgo de obtener resultados insatisfactorios. A partir de ello, el docente aplicó medidas preventivas como asesorías, clases adicionales y advertencias sobre asistencia. Al final del curso, **cuatro de las cinco estudiantes** lograron resultados satisfactorios, lo que demuestra que el modelo fue útil para detectar riesgos tempranos y apoyar la intervención académica.

Observaciones/críticas

Una observación importante sobre el artículo es que presenta un aporte práctico y útil para el docente, ya que no solo desarrolla un modelo predictivo, sino que también lo transforma en medidas preventivas aplicables en el aula. Esta característica fortalece el valor del estudio, porque conecta el uso de **Machine Learning** con acciones concretas como asesorías, clases adicionales, advertencias de asistencia y seguimiento personalizado. Además, el uso del árbol de decisión es adecuado porque permite interpretar fácilmente las reglas del modelo y comprender qué factores influyen en el bajo rendimiento académico.

Sin embargo, una crítica relevante es que el estudio se realizó con un conjunto de datos relativamente pequeño, compuesto por **151 instancias** de entrenamiento y una prueba de campo con solo **25 estudiantes**. Esto limita la posibilidad de generalizar los resultados a otros cursos, instituciones o contextos educativos. Además, el modelo fue aplicado en una asignatura específica, *Phonetics and Phonology*, por lo que su desempeño podría variar si se utiliza en materias con otra estructura de evaluación o con estudiantes de características diferentes.

Otra limitación es que el modelo utiliza principalmente variables académicas, como CGPA, asistencia y nota del primer examen, pero no considera de manera profunda factores personales, emocionales, familiares o socioeconómicos que también pueden afectar el rendimiento estudiantil. A pesar de ello, el artículo es valioso porque demuestra que una predicción temprana, cuando es comprensible y va acompañada de intervención docente, puede ayudar a mejorar los resultados de estudiantes en riesgo.

30. ARTÍCULO 30

Author (s): Yi-Tzone Shiao; Cheng-Huan Chen; Ke-Fei Wu; Bae-Ling Chen; Yu-Hui Chou; Trong-Neng Wu

Título de paper: Reducing dropout rate through a deep learning model for sustainable education: long-term tracking of learning outcomes of an undergraduate cohort from 2018 to 2021

Journal: Smart Learning Environments

Volume (issue): Volume 10, Article 55

pag – pag (year): pp. 1–16 (2023)

Estado del arte

La reducción de la deserción universitaria se ha convertido en una preocupación central para las instituciones de educación superior, especialmente en contextos donde se busca mejorar la permanencia, la eficiencia académica y la sostenibilidad educativa. En los últimos años, el desarrollo de la inteligencia artificial, el aprendizaje automático y la analítica del aprendizaje ha permitido construir modelos predictivos capaces de identificar estudiantes con riesgo de abandonar sus estudios. Estos avances se relacionan directamente con el concepto de **educación de precisión**, el cual busca aplicar datos, modelos estadísticos y herramientas inteligentes para comprender las diferencias individuales de los estudiantes y ofrecer intervenciones personalizadas.

La educación de precisión parte de una idea fundamental: cada estudiante posee características, necesidades, ritmos de aprendizaje y condiciones personales distintas. Por ello, los sistemas educativos tradicionales, que suelen ofrecer los mismos contenidos y estrategias para todos, pueden resultar insuficientes para atender adecuadamente la diversidad estudiantil. En este sentido, la educación de precisión propone utilizar datos académicos, conductuales y contextuales para diagnosticar dificultades, predecir riesgos, intervenir oportunamente y prevenir problemas como el bajo rendimiento o la deserción. Este enfoque guarda similitud con la medicina de precisión, ya que no se limita a reaccionar cuando el problema ya ocurrió, sino que busca anticiparse mediante el análisis de información individual.

Dentro de este campo, la predicción de la deserción académica ocupa un lugar importante. Diversos estudios han demostrado que variables como el rendimiento académico, el número de ausencias, las alertas tempranas, la situación económica, el acceso a préstamos estudiantiles, la motivación, la ansiedad académica y el apoyo docente pueden influir en la permanencia universitaria. La literatura señala que identificar estos factores permite diseñar programas de tutoría, orientación académica, apoyo financiero, consejería psicológica y acompañamiento personalizado. De esta manera, los modelos predictivos no solo tienen valor técnico, sino también institucional y pedagógico, porque ayudan a transformar los datos en acciones concretas para mejorar la trayectoria estudiantil.

Las investigaciones previas han utilizado diferentes métodos para predecir el abandono académico. Entre ellos destacan la regresión logística, las redes neuronales artificiales, Naïve Bayes, máquinas de soporte vectorial, modelos de aprendizaje profundo y técnicas de analítica

del aprendizaje. Estos métodos permiten analizar patrones en grandes bases de datos institucionales y estimar la probabilidad de que un estudiante abandone sus estudios. Sin embargo, una limitación frecuente en la investigación es que muchos trabajos se concentran en la construcción del modelo predictivo, pero no siempre muestran cómo se aplican los resultados en estrategias reales de intervención institucional. Por ello, existe una necesidad de estudios que no solo desarrollen modelos, sino que también evalúen su impacto en el seguimiento y apoyo a los estudiantes.

El artículo analizado se ubica en esta línea de investigación y aporta una perspectiva aplicada. Los autores utilizan un modelo previamente construido mediante **aprendizaje estadístico y aprendizaje profundo** para predecir el riesgo individual de deserción en una cohorte de estudiantes universitarios. A partir del portafolio académico de estudiantes anteriores, el modelo identifica factores asociados al abandono, como la disminución del rendimiento académico, la solicitud de préstamos estudiantiles, las ausencias frecuentes y el número de asignaturas con alerta temprana. Luego, este modelo se aplica a 2205 estudiantes de primer año ingresados en 2018, con seguimiento hasta 2021, para detectar casos de alto riesgo y brindar orientación personalizada.

Un aspecto relevante del estado del arte es el paso de la predicción a la intervención. En este estudio, la inteligencia artificial no se utiliza únicamente para clasificar estudiantes, sino para activar un sistema de seguimiento y orientación. La plataforma de educación de precisión proporciona información tanto a estudiantes como a docentes, permitiendo visualizar riesgos de deserción, trayectorias de aprendizaje y recomendaciones personalizadas. En la interfaz del estudiante se muestran indicadores de riesgo y consejos de aprendizaje, mientras que en la interfaz del docente se presentan probabilidades de abandono por estudiante para facilitar la orientación oportuna. Esto demuestra una tendencia actual en la educación inteligente: integrar modelos predictivos con sistemas de apoyo académico.

En síntesis, el estado actual de la investigación muestra que la educación superior avanza hacia modelos más personalizados, preventivos y basados en evidencia. La analítica del aprendizaje y el aprendizaje profundo permiten identificar estudiantes vulnerables con mayor precisión, pero su valor real depende de que las instituciones utilicen esa información para implementar acciones de acompañamiento. El artículo contribuye al estado del arte porque combina predicción, seguimiento longitudinal e intervención educativa, demostrando que los modelos de inteligencia artificial pueden apoyar la sostenibilidad educativa al reducir el riesgo de deserción y mejorar la permanencia universitaria.

Motivación del autor

La motivación principal de los autores surge de la necesidad de reducir la deserción universitaria mediante el uso de herramientas de **educación de precisión**, inteligencia artificial y aprendizaje profundo. En la educación superior, el abandono académico representa un problema importante porque afecta la trayectoria del estudiante, disminuye la retención institucional y limita las oportunidades de desarrollo profesional. Frente a esta situación, los autores consideran necesario identificar de manera temprana a los estudiantes con dificultades de aprendizaje o con mayor probabilidad de abandonar sus estudios, para ofrecerles orientación personalizada antes de que el problema se concrete.

Asimismo, los autores se motivan por aplicar un modelo predictivo no solo como una herramienta técnica, sino como un recurso práctico para mejorar los resultados educativos. A diferencia de estudios que se enfocan únicamente en construir modelos de predicción, esta investigación busca comprobar si el seguimiento y la orientación a estudiantes de alto riesgo pueden disminuir efectivamente la probabilidad de deserción. Por ello, el estudio utiliza datos académicos, ausencias, alertas tempranas y situación económica para detectar estudiantes vulnerables y activar estrategias de apoyo. La finalidad es promover una educación sostenible,

personalizada y centrada en el estudiante, donde la inteligencia artificial permita tomar decisiones oportunas para mejorar la permanencia universitaria.

Descripción del aporte del autor

El principal aporte de los autores consiste en demostrar que un modelo predictivo basado en **aprendizaje estadístico** y **aprendizaje profundo** puede utilizarse de manera práctica para reducir el riesgo de deserción universitaria. A diferencia de investigaciones que solo construyen modelos de predicción, este estudio no se queda en la parte técnica, sino que aplica el modelo en una cohorte real de estudiantes y realiza un seguimiento longitudinal durante varios años. Esto convierte al trabajo en una contribución relevante para la educación superior, porque vincula la inteligencia artificial con acciones concretas de orientación, acompañamiento y mejora de la permanencia estudiantil.

Uno de los aportes más importantes del artículo es su enfoque en la **educación de precisión**. Los autores sostienen que los estudiantes no deben ser tratados como un grupo homogéneo, ya que cada uno posee condiciones académicas, económicas, personales y conductuales distintas. Por ello, la educación de precisión busca identificar las necesidades particulares de cada estudiante mediante el análisis de datos, con el propósito de ofrecer intervenciones personalizadas. En este sentido, el modelo propuesto funciona como una herramienta para diagnosticar, predecir, orientar y prevenir problemas académicos antes de que se conviertan en abandono definitivo.

El estudio aporta una aplicación concreta de inteligencia artificial en la gestión educativa universitaria. Los autores utilizaron un modelo previamente construido con datos históricos de estudiantes, empleando **regresión logística** como método de aprendizaje estadístico y **perceptrón multicapa** como método de aprendizaje profundo. El modelo fue diseñado para estimar el riesgo individual de abandono académico a partir de variables del portafolio académico del estudiante. Entre las variables consideradas se encuentran la solicitud de préstamos estudiantiles, el rendimiento académico, el número de ausencias, el descenso en el ranking de clase y la cantidad de asignaturas con alerta temprana. Estas variables permitieron identificar patrones asociados con mayor probabilidad de deserción.

Un aporte relevante es que los autores no solo evaluaron el modelo en términos de predicción, sino que lo integraron en un sistema institucional de seguimiento. El modelo fue aplicado a **2205 estudiantes de primer año** que ingresaron en el semestre de otoño de 2018. A partir del análisis, se identificó a un grupo de estudiantes con alto riesgo de abandonar sus estudios. En particular, los estudiantes con una probabilidad de deserción superior al 20% fueron considerados de alto riesgo y recibieron seguimiento. Esta decisión permitió convertir una predicción estadística en una acción educativa concreta, orientada a prevenir la deserción.

El trabajo también aporta una visión longitudinal, ya que los estudiantes fueron monitoreados desde 2018 hasta 2021. Esta característica fortalece la investigación, porque permite observar si el riesgo de abandono cambia con el tiempo después de aplicar estrategias de orientación. Los resultados muestran que, de los estudiantes identificados como de alto riesgo, una parte importante redujo su probabilidad de abandono luego del acompañamiento. Específicamente, el riesgo de deserción de **91 estudiantes** disminuyó de más del 20% a menos del 20%, lo que evidencia que el sistema de seguimiento y orientación tuvo un efecto positivo en una parte de la cohorte.

Otro aporte significativo es la creación de una **plataforma de educación de precisión** que permite visualizar información tanto para estudiantes como para docentes. En la interfaz del estudiante, presentada en la figura 1 del artículo, se muestra el riesgo personal de suspensión y abandono, junto con recomendaciones de aprendizaje. Esto permite que el estudiante pueda monitorear su propia situación académica y tomar conciencia de los factores que pueden afectar

su continuidad. Por otro lado, la interfaz del docente, presentada en la figura 2, muestra la probabilidad de abandono de cada estudiante de la clase, lo que facilita que los asesores o tutores identifiquen a quienes requieren apoyo inmediato.

Este aporte tecnológico es importante porque conecta la predicción con la intervención. El sistema no se limita a generar una lista de estudiantes en riesgo, sino que ofrece información útil para tomar decisiones. Los docentes pueden revisar las trayectorias de aprendizaje, conversar con los estudiantes, orientar sobre estrategias de estudio, derivar a unidades de apoyo o recomendar servicios institucionales. Así, el modelo predictivo se convierte en una herramienta de gestión educativa centrada en el estudiante.

El artículo también aporta un esquema de intervención organizado según factores académicos y no académicos. En la tabla 1, los autores relacionan variables predictivas con mecanismos de mejora y unidades responsables. Por ejemplo, si el riesgo se relaciona con bajo rendimiento académico o asignaturas con alerta temprana, se propone asesoría académica y orientación profesional. Si se vincula con dificultades económicas, se sugieren préstamos, becas o trabajos de medio tiempo dentro de la institución. Si el problema está asociado con ausencias, se consideran sistemas de control de asistencia, orientación vocacional o incluso atención frente a problemas como adicción a internet. Este enfoque muestra que la prevención de la deserción requiere una respuesta integral, no solo académica.

Desde el punto de vista institucional, el aporte de los autores es demostrar que la inteligencia artificial puede apoyar la toma de decisiones en la universidad. La deserción no es un fenómeno simple ni depende de una sola causa; por ello, las instituciones necesitan herramientas que les permitan identificar señales tempranas y coordinar acciones entre docentes, oficinas académicas, unidades de asuntos estudiantiles, equipos de orientación y servicios de apoyo. El estudio evidencia que los modelos predictivos pueden ayudar a organizar esta respuesta institucional de manera más eficiente.

Otro aporte importante es el análisis diferenciado según **género y situación económica**. Los autores encontraron que la reducción del riesgo de deserción fue mayor en estudiantes varones que en mujeres, y también fue mayor en estudiantes con dificultades económicas que en estudiantes sin desventaja financiera. En particular, la tasa de mejora en el riesgo de abandono fue de **10.2% en hombres y 2.9% en mujeres**; mientras que en estudiantes con dificultades económicas fue de **12.0%**, frente a **5.9%** en estudiantes generales. Este resultado es relevante porque muestra que los sistemas de seguimiento pueden beneficiar especialmente a ciertos grupos vulnerables.

El estudio también aporta evidencia sobre la reducción de la tasa de abandono al comparar cohortes. Los autores observaron que la cohorte de estudiantes ingresados en 2018 presentó una tasa de abandono en segundo año menor que las cohortes de 2016 y 2017. Esta comparación sugiere que el sistema de predicción, seguimiento y orientación pudo contribuir a mejorar la permanencia estudiantil. Aunque no se puede afirmar que el modelo sea la única causa de la reducción, los resultados muestran una relación positiva entre la aplicación de la educación de precisión y la disminución del riesgo de abandono.

Desde una perspectiva pedagógica, el aporte del artículo está en reforzar la idea de que los datos deben utilizarse para apoyar al estudiante, no solo para clasificarlo. La identificación de riesgo debe ir acompañada de acciones humanas: conversación con docentes, orientación individual, apoyo familiar, asesoría académica y derivación a servicios especializados. Los autores destacan que los profesores cumplen un papel clave, porque son quienes pueden interpretar la situación del estudiante, brindarle acompañamiento emocional y académico, y conectarlo con los recursos institucionales adecuados.

El estudio también aporta a la sostenibilidad educativa. La educación sostenible no se refiere únicamente al acceso a la universidad, sino también a la posibilidad de que los estudiantes permanezcan, aprendan y culminen su formación. En contextos de disminución de matrícula, dificultades económicas y altos índices de abandono, mantener la retención estudiantil se convierte en una prioridad para las universidades. Por ello, el modelo propuesto ayuda a sostener la continuidad educativa al identificar estudiantes vulnerables y activar medidas preventivas.

Otro punto relevante del aporte es que el modelo trabaja con datos institucionales disponibles, como desempeño académico, ausencias, préstamos y alertas tempranas. Esto significa que las universidades pueden aprovechar información que ya poseen en sus sistemas administrativos y académicos. El valor de la propuesta está en transformar esos datos en conocimiento útil para la toma de decisiones. En lugar de esperar a que el estudiante abandone, la institución puede anticiparse y actuar.

Además, el artículo contribuye al campo de la inteligencia artificial en educación porque muestra una aplicación centrada en el ser humano. La tecnología no sustituye al docente ni a los servicios de apoyo, sino que funciona como una herramienta para detectar señales de riesgo y facilitar intervenciones personalizadas. Esta visión es importante porque evita una interpretación puramente automatizada de la educación y resalta la necesidad de combinar modelos predictivos con acompañamiento humano.

En conclusión, el aporte de los autores se resume en la aplicación práctica de un modelo de aprendizaje estadístico y profundo para reducir el riesgo de deserción universitaria mediante educación de precisión. El estudio demuestra que es posible identificar estudiantes de alto riesgo, brindarles seguimiento, ofrecer orientación personalizada y observar mejoras en su probabilidad de permanencia. Su valor principal está en conectar predicción, intervención y seguimiento longitudinal, mostrando que la inteligencia artificial puede contribuir a una educación más sostenible, preventiva y centrada en las necesidades individuales de los estudiantes.

Proceso para obtener el aporte

Para obtener su aporte, los autores desarrollaron un proceso aplicado que combinó **aprendizaje estadístico, aprendizaje profundo**, seguimiento longitudinal y orientación educativa personalizada. El estudio se realizó con una cohorte real de estudiantes universitarios de primer año, ingresados en el semestre de otoño de 2018. En total, se analizaron datos de **2205 estudiantes**, conformados por 776 hombres y 1429 mujeres, con edades entre 18 y 19 años. La finalidad fue utilizar un modelo predictivo previamente construido para identificar estudiantes con riesgo de deserción y aplicar estrategias de acompañamiento que ayudaran a reducir dicho riesgo.

El primer paso consistió en recopilar información del **portafolio académico** de los estudiantes. Los autores consideraron variables relacionadas con el desempeño y la trayectoria académica, como el rendimiento en el primer año, la cantidad de ausencias, el número de asignaturas con alerta temprana y la solicitud de préstamos estudiantiles. Estas variables fueron seleccionadas porque estudios previos las habían asociado con un mayor riesgo de abandono. De esta manera, el modelo no se basó en datos aislados, sino en indicadores académicos y no académicos que podían reflejar dificultades reales en la experiencia universitaria.

El segundo paso fue aplicar el modelo predictivo de riesgo de deserción. Este modelo había sido construido anteriormente mediante **regresión logística y perceptrón multicapa**, usando datos históricos de estudiantes. Al ingresar la información de la cohorte 2018, el sistema calculó la probabilidad individual de abandono para cada estudiante. A partir de estos resultados, los autores identificaron a los estudiantes con mayor riesgo. En particular, aquellos con una

probabilidad de deserción superior al **20%** fueron clasificados como estudiantes de alto riesgo y seleccionados para seguimiento.

El tercer paso fue implementar una **plataforma de educación de precisión**. Esta plataforma permitió que estudiantes y docentes visualizaran información relevante sobre el riesgo de abandono, la trayectoria académica y las recomendaciones de aprendizaje. En la interfaz del estudiante se mostraba su evaluación personal de riesgo y consejos para mejorar su aprendizaje; mientras que en la interfaz del docente se presentaban las probabilidades de abandono de cada estudiante de la clase. Esto permitió transformar los resultados del modelo en información práctica para la toma de decisiones educativas.

El cuarto paso consistió en realizar seguimiento y orientación personalizada. Los docentes y las unidades responsables de la institución revisaron los casos de alto riesgo y aplicaron acciones de apoyo según la situación de cada estudiante. Algunas medidas incluyeron asesoría académica, orientación vocacional, apoyo económico, becas, trabajos de medio tiempo, tutorías, consejería y derivación a servicios especializados. Esta etapa fue clave, porque el aporte del estudio no se limitó a predecir el abandono, sino a intervenir para disminuirlo.

Finalmente, los autores evaluaron los cambios en el riesgo de deserción a lo largo del tiempo. De los estudiantes identificados como de alto riesgo, **91 lograron reducir su probabilidad de abandono de más del 20% a menos del 20%** después del seguimiento y la orientación. Además, el estudio comparó la evolución de la cohorte 2018 con cohortes anteriores y analizó diferencias según género y situación económica. Así, el proceso permitió demostrar que un modelo predictivo, integrado a una plataforma institucional y acompañado por intervención humana, puede contribuir a reducir la deserción y fortalecer la educación sostenible.

Proceso para resolver el problema

Para resolver el problema de la deserción universitaria, los autores plantearon una estrategia basada en **educación de precisión**, aprendizaje estadístico y aprendizaje profundo. El problema central era que muchos estudiantes abandonan la universidad por dificultades académicas, económicas, personales o de adaptación, pero las instituciones suelen detectar estas situaciones cuando ya es demasiado tarde. Por ello, los autores propusieron utilizar un modelo predictivo capaz de identificar de manera temprana a los estudiantes con mayor riesgo de abandono, para luego aplicar acciones de seguimiento y orientación personalizada.

El primer paso fue utilizar datos del portafolio académico de estudiantes universitarios. Se consideraron variables como rendimiento académico, número de ausencias, cantidad de asignaturas con alerta temprana y solicitud de préstamos estudiantiles. Estas variables fueron importantes porque permiten observar señales de dificultad durante la trayectoria universitaria. El modelo predictivo, construido previamente con regresión logística y perceptrón multicapa, procesó esta información y calculó la probabilidad individual de deserción para cada estudiante de la cohorte 2018.

Luego, los autores establecieron un criterio para identificar a los estudiantes de alto riesgo. Los estudiantes con una probabilidad de abandono superior al **20%** fueron seleccionados para recibir seguimiento. De esta manera, el problema dejó de tratarse de forma general y se abordó individualmente, priorizando a quienes presentaban mayor vulnerabilidad académica. Esta selección permitió que los docentes y las unidades institucionales enfocaran sus esfuerzos en los casos más urgentes.

El tercer paso fue implementar una plataforma de educación de precisión que mostraba información diferenciada para estudiantes y docentes. Los estudiantes podían revisar su riesgo personal y recibir recomendaciones de aprendizaje, mientras que los docentes visualizaban las probabilidades de abandono de sus alumnos y sus trayectorias académicas. Con esta

información, los profesores podían comunicarse con los estudiantes, ofrecer orientación, derivarlos a servicios de apoyo o recomendar estrategias específicas según sus necesidades.

Finalmente, la solución se completó con el seguimiento longitudinal y la intervención humana. Los estudiantes identificados como de alto riesgo recibieron apoyo académico, orientación vocacional, consejería, becas, préstamos, tutorías o acompañamiento según su situación. Después de este proceso, **91 estudiantes redujeron su riesgo de abandono de más del 20% a menos del 20%**, lo que demuestra que la combinación de inteligencia artificial, plataforma institucional y orientación personalizada puede contribuir a prevenir la deserción y fortalecer la permanencia universitaria.

Métricas y resultados

El estudio evaluó los resultados del modelo a partir del **riesgo individual de deserción**, expresado como porcentaje de probabilidad de abandono, y mediante el seguimiento longitudinal de la cohorte 2018. La muestra estuvo conformada por **2205 estudiantes de primer año**. Al aplicar el modelo predictivo basado en aprendizaje estadístico y aprendizaje profundo, se identificó que **448 estudiantes** presentaban un riesgo de deserción superior al **10%**. De ellos, **176 estudiantes** fueron considerados de alto riesgo, ya que tenían una probabilidad de abandono mayor al **20%**. Esta clasificación permitió iniciar acciones de seguimiento y orientación personalizada.

Los resultados muestran que el modelo fue útil para detectar estudiantes vulnerables. En el segundo año, **31 estudiantes** del grupo de alto riesgo abandonaron o suspendieron sus estudios, y se observó que la tasa real de abandono aumentaba conforme se elevaba el intervalo de riesgo predicho. Además, después del seguimiento institucional, **91 estudiantes redujeron su riesgo de deserción de más del 20% a menos del 20%**, y 50 de ellos bajaron incluso a menos del 10%. También se encontró que la reducción del riesgo fue mayor en hombres (**10.2%**) que en mujeres (**2.9%**), y mayor en estudiantes con dificultades económicas (**12.0%**) que en estudiantes sin dicha condición (**5.9%**). Finalmente, la cohorte 2018 presentó una menor tasa de abandono en segundo año que las cohortes 2016 y 2017, lo que evidencia un impacto positivo del sistema de predicción, seguimiento y orientación.

Observaciones/críticas

Una observación positiva del artículo es que no se limita a construir un modelo predictivo, sino que demuestra su aplicación práctica dentro de una universidad mediante una plataforma de educación de precisión. Esto representa un aporte importante, porque muchos estudios de inteligencia artificial en educación se quedan en la fase de predicción, mientras que este trabajo conecta el modelo con acciones reales de seguimiento, orientación académica y apoyo institucional. Además, el seguimiento longitudinal de la cohorte 2018 permite observar la evolución del riesgo de deserción durante varios años, lo cual fortalece la utilidad del estudio para la toma de decisiones educativas.

Sin embargo, también existen algunas limitaciones. El modelo fue aplicado en una sola institución, por lo que sus resultados no pueden generalizarse automáticamente a otras universidades con contextos diferentes. Además, aunque se reporta una reducción del riesgo de abandono, no siempre queda completamente claro cuánto de esa mejora se debe exclusivamente al modelo y cuánto a otros factores externos, como apoyo familiar, cambios personales o políticas institucionales. Otra crítica es que el estudio requiere datos acumulados del primer año para estimar el riesgo, por lo que no permite intervenir desde el ingreso inmediato del estudiante. A pesar de ello, el artículo es valioso porque muestra que la inteligencia artificial, cuando se combina con acompañamiento humano, puede contribuir a una educación más sostenible, preventiva y centrada en el estudiante.

31. ARTÍCULO 31

Author (s): Chien-Chang Lin; Anna Y. Q. Huang; Owen H. T. Lu.

Title of paper: *Artificial intelligence in intelligent tutoring systems toward sustainable education: a systematic review.*

Journal: *Smart Learning Environments.*

Volume (issue): 10(41).

pag – pag (year): 1–22 (2023).

Estado del arte

El estudio sobre la **inteligencia artificial aplicada a los sistemas de tutoría inteligente** se ha convertido en una línea de investigación relevante para el fortalecimiento de la educación sostenible. La educación sostenible busca garantizar una formación inclusiva, equitativa, de calidad y orientada al aprendizaje permanente, en concordancia con los Objetivos de Desarrollo Sostenible, especialmente el ODS 4 referido a la educación de calidad. En este contexto, la inteligencia artificial puede contribuir a mejorar el acceso a la educación, personalizar los procesos de aprendizaje, apoyar la toma de decisiones basada en datos y ofrecer intervenciones oportunas según las necesidades de los estudiantes.

De acuerdo con el artículo revisado, los sistemas de tutoría inteligente, conocidos como **Intelligent Tutoring Systems** o **ITS**, son entornos computacionales que utilizan inteligencia artificial para proporcionar enseñanza personalizada y adaptativa. Estos sistemas pueden modelar diferentes aspectos del estudiante, como su conocimiento previo, progreso, motivación, emociones, preferencias y comportamiento durante el aprendizaje. Además, pueden ofrecer retroalimentación, pistas, andamiaje, selección de actividades y recomendaciones de intervención. Por ello, los ITS representan una herramienta importante para pasar de una enseñanza centrada en el docente a una educación más centrada en el estudiante.

El estado actual de la investigación muestra que la inteligencia artificial se incorpora a los sistemas educativos de diversas formas. Una de las más frecuentes es el uso de algoritmos de **Machine Learning** para analizar datos de aprendizaje y predecir el rendimiento académico de los estudiantes. Estos modelos permiten identificar estudiantes con riesgo de bajo desempeño, abandono o falta de participación, lo que facilita que los docentes intervengan a tiempo. También se emplean técnicas de minería de datos para analizar patrones de comportamiento, reconocer estilos de aprendizaje y detectar necesidades específicas de apoyo.

Otra línea relevante es el uso de **procesamiento de lenguaje natural** y chatbots educativos. Estas herramientas permiten que los estudiantes interactúen con sistemas inteligentes capaces de responder preguntas, proporcionar retroalimentación y acompañar procesos de aprendizaje. Asimismo, algunos estudios revisados consideran el uso de reconocimiento facial, análisis de emociones y detección de engagement para que los docentes puedan comprender mejor el estado emocional y participativo de los estudiantes durante actividades virtuales o híbridas. Esto resulta especialmente importante en escenarios donde la educación remota reduce la interacción física y emocional entre docentes y alumnos.

El artículo también muestra que los sistemas de tutoría inteligente pueden dividirse en dos grandes enfoques. El primero corresponde a sistemas donde la inteligencia artificial no está integrada directamente en la tutoría, sino que se utiliza para analizar registros o datos generados por la plataforma. En estos casos, la IA sirve principalmente para predicción del rendimiento, análisis de comportamiento, detección de abandono o apoyo a la toma de decisiones del docente. El segundo enfoque corresponde a sistemas donde la IA está integrada dentro del proceso de aprendizaje, permitiendo rutas adaptativas, personalización, interacción mediante chatbots o intervenciones automáticas durante la actividad educativa.

A pesar de sus beneficios, el estado del arte también evidencia varios desafíos. Entre ellos se encuentran la falta de acceso equitativo a dispositivos e internet, la necesidad de fortalecer las competencias digitales docentes, la limitada interacción física y emocional en entornos virtuales, los problemas de privacidad y seguridad de datos, el riesgo de sesgos algorítmicos y la falta de transparencia de algunos modelos de inteligencia artificial. Los autores destacan que la explicabilidad de los sistemas es fundamental, ya que docentes y estudiantes necesitan comprender cómo se generan las predicciones o recomendaciones para confiar en ellas.

Asimismo, la revisión muestra que la mayoría de investigaciones se ha concentrado en educación superior, especialmente porque en este nivel existen entornos más diversos para recopilar datos y aplicar modelos de analítica del aprendizaje. Sin embargo, todavía existe la necesidad de ampliar estos estudios a otros niveles educativos y contextos. También se observa que muchas investigaciones logran buenos resultados en predicción, pero no siempre explican suficientemente las decisiones de los modelos ni ofrecen mecanismos claros de intervención pedagógica.

En síntesis, el estado del arte evidencia que la inteligencia artificial tiene un alto potencial para fortalecer los sistemas de tutoría inteligente y contribuir a la educación sostenible. Su valor principal está en personalizar el aprendizaje, predecir riesgos académicos, apoyar al docente y mejorar la toma de decisiones educativas. No obstante, para que estos sistemas sean realmente sostenibles, deben diseñarse con criterios de equidad, transparencia, confianza, seguridad y enfoque humano. Por ello, el artículo aporta una visión integral al conectar las necesidades educativas con las posibilidades tecnológicas de la inteligencia artificial.

Motivación del autor

La motivación principal de los autores surge de la necesidad de comprender cómo la **inteligencia artificial** puede apoyar a los **sistemas de tutoría inteligente** en el logro de una educación más sostenible, inclusiva y personalizada. La educación sostenible enfrenta varios desafíos, como la falta de infraestructura, recursos limitados, desigualdad en el acceso tecnológico, poca participación de los estudiantes y dificultades para atender las necesidades individuales de aprendizaje. Frente a esta realidad, los autores consideran importante analizar de qué manera la IA puede contribuir a mejorar la calidad educativa y apoyar el cumplimiento del Objetivo de Desarrollo Sostenible relacionado con la educación de calidad.

Otra motivación importante es la existencia de una brecha entre los educadores y los especialistas en tecnología. Los docentes pueden reconocer la necesidad de herramientas inteligentes, pero muchas veces no comprenden completamente cómo funcionan los sistemas basados en IA; mientras que los especialistas tecnológicos pueden desarrollar soluciones avanzadas, pero no siempre consideran adecuadamente los principios pedagógicos. Por ello, los autores buscan conectar ambas perspectivas para ofrecer una visión más clara sobre la implementación de sistemas inteligentes en educación.

Asimismo, los autores se motivan por identificar beneficios, desafíos y tendencias futuras del uso de IA en educación sostenible. Su propósito no es solo describir tecnologías, sino también analizar aspectos como privacidad, seguridad, sesgos, transparencia, confianza, personalización y apoyo docente. En ese sentido, la revisión busca orientar a investigadores, docentes y arquitectos de soluciones tecnológicas sobre cómo implementar sistemas de tutoría inteligente que sean útiles, éticos y sostenibles.

Descripción del aporte del autor

El aporte principal de Chien-Chang Lin, Anna Y. Q. Huang y Owen H. T. Lu en el artículo “**Artificial intelligence in intelligent tutoring systems toward sustainable education: a systematic review**” consiste en presentar una revisión sistemática sobre cómo la **inteligencia**

artificial puede integrarse en los **sistemas de tutoría inteligente** para apoyar una educación sostenible, inclusiva, personalizada y orientada al aprendizaje permanente. El valor del artículo está en que no analiza la inteligencia artificial únicamente como una herramienta tecnológica, sino como un recurso que puede contribuir al cumplimiento de los objetivos educativos de sostenibilidad, especialmente aquellos vinculados con la calidad educativa, la equidad y el acceso a oportunidades de aprendizaje.

Uno de los aportes más importantes del artículo es que conecta el concepto de **educación sostenible** con el desarrollo de tecnologías inteligentes. Los autores explican que la educación sostenible no se limita a enseñar contenidos relacionados con el medio ambiente o el desarrollo sostenible, sino que implica transformar los métodos, procesos y contextos educativos para responder a las necesidades actuales y futuras de los estudiantes. En este sentido, la inteligencia artificial puede ayudar a construir entornos educativos más flexibles, personalizados y capaces de adaptarse a diferentes perfiles de aprendizaje.

El artículo también aporta una definición clara del papel de los **Intelligent Tutoring Systems** o sistemas de tutoría inteligente. Estos sistemas son entornos computacionales que utilizan inteligencia artificial para ofrecer instrucción adaptativa y personalizada. Pueden analizar el conocimiento previo del estudiante, sus habilidades, preferencias, emociones, motivación y progreso académico. A partir de esa información, el sistema puede entregar retroalimentación, pistas, actividades adecuadas, recomendaciones y apoyo durante el proceso de aprendizaje. Este aporte es relevante porque muestra que los ITS pueden funcionar como mediadores entre el estudiante, el docente y la tecnología.

Otro aporte significativo es que los autores identifican los principales **desafíos de la educación sostenible** cuando se integra inteligencia artificial. Entre estos desafíos se encuentran la desigualdad en el acceso a dispositivos e internet, la falta de competencias digitales docentes, la limitada interacción física y emocional en entornos virtuales, la dificultad para promover colaboración entre estudiantes, el riesgo de abandono en ambientes en línea, los problemas de privacidad y seguridad de datos, los sesgos algorítmicos y la falta de transparencia de los sistemas inteligentes. Esta identificación es importante porque permite reconocer que la IA no es una solución automática, sino una herramienta que debe implementarse con responsabilidad.

El aporte del artículo también se encuentra en su intento de **conectar la perspectiva educativa con la perspectiva tecnológica**. Los autores señalan que muchas veces existe una brecha entre educadores y arquitectos de soluciones tecnológicas. Los docentes conocen las necesidades pedagógicas, pero pueden tener dificultades para comprender el funcionamiento técnico de la IA; mientras que los especialistas en tecnología pueden desarrollar sistemas avanzados, pero no siempre integran adecuadamente principios pedagógicos. Por ello, el artículo busca servir como una guía para ambos grupos, facilitando una mejor comunicación entre quienes diseñan tecnología y quienes la aplican en el aula.

Desde el punto de vista metodológico, el artículo aporta al utilizar una revisión sistemática basada en el marco **PRISMA**. Este procedimiento permitió seleccionar, filtrar y analizar investigaciones relevantes de manera organizada. Los autores revisaron estudios relacionados con educación sostenible, inteligencia artificial, sistemas de tutoría inteligente, analítica del aprendizaje y tecnologías educativas. Para responder sus preguntas de investigación, seleccionaron trabajos que abordaban desafíos, formas de integración de IA, resultados obtenidos y tendencias futuras. Este proceso fortalece el valor académico del artículo, porque sus conclusiones se basan en una revisión estructurada de la literatura.

Otro aporte relevante es la clasificación de las formas en que la IA se incorpora en los sistemas de tutoría inteligente. Los autores identifican dos enfoques principales. El primero corresponde a sistemas donde la IA no está integrada directamente en el proceso de tutoría, sino que se utiliza para analizar datos generados por plataformas educativas. En estos casos, la IA sirve para

predecir rendimiento, analizar comportamiento, detectar abandono, identificar emociones o apoyar decisiones docentes. El segundo enfoque corresponde a sistemas donde la IA sí está integrada en el proceso de aprendizaje, permitiendo interacción con chatbots, rutas personalizadas, adaptación de contenidos o intervención automática.

Esta clasificación aporta claridad al campo porque permite distinguir entre un uso externo de la IA, centrado en el análisis de datos, y un uso interno, centrado en la experiencia directa del estudiante. En el primer caso, la IA apoya principalmente al docente o a la institución; en el segundo, acompaña directamente al estudiante durante su aprendizaje. Esta diferencia es importante para diseñar sistemas más adecuados según el objetivo educativo que se persigue.

El artículo también aporta al identificar los principales **propósitos del uso de IA** en sistemas de tutoría inteligente. Entre ellos se encuentran la predicción del rendimiento, el análisis de comportamientos de aprendizaje, la prevención del abandono, la intervención oportuna, la personalización, el apoyo al docente, la evaluación de sistemas y la mejora del aprendizaje autorregulado. Según la revisión, la predicción del rendimiento fue uno de los propósitos más frecuentes, seguida por el análisis de comportamientos de aprendizaje. Esto demuestra que gran parte de la investigación actual se orienta a utilizar datos para anticipar problemas y comprender cómo aprenden los estudiantes.

Asimismo, los autores aportan una descripción de las tecnologías más utilizadas. Dentro de los sistemas revisados aparecen técnicas de **Machine Learning**, como regresión logística, regresión lineal, máquinas de soporte vectorial, Naïve Bayes, Random Forest, redes neuronales, árboles de decisión y modelos de boosting. También se mencionan técnicas de aprendizaje no supervisado, como agrupamiento, además de procesamiento de lenguaje natural, reconocimiento facial, análisis emocional, chatbots, sistemas de recomendación y métodos de inteligencia artificial explicable. Esta diversidad tecnológica evidencia que la IA en educación no es una sola herramienta, sino un conjunto de enfoques aplicables a diferentes necesidades educativas.

Un aporte especialmente importante del artículo es la atención que presta a la **inteligencia artificial explicable** o XAI. Los autores destacan que muchos modelos de IA funcionan como cajas negras, por lo que docentes y estudiantes pueden desconfiar de sus resultados si no comprenden cómo se generan las predicciones o recomendaciones. Por ello, señalan que los sistemas futuros deben ser más transparentes, justos y confiables. Esta reflexión es fundamental porque, en educación, una predicción puede influir en decisiones sobre apoyo académico, intervención docente o evaluación del estudiante. Por tanto, la explicabilidad no es solo un requisito técnico, sino también ético y pedagógico.

El artículo también aporta al mostrar los resultados positivos reportados por estudios previos. Entre los principales hallazgos se mencionan modelos de predicción con alta precisión, identificación de comportamientos de aprendizaje, mejora de la participación mediante notificaciones tempranas de abandono, aumento del rendimiento después de intervenciones, generación de resultados explicables para docentes, detección emocional y mejora de la satisfacción estudiantil. En los sistemas donde la IA está integrada directamente, también se reportan mejoras en el rendimiento, mayor interés, más engagement y aprendizaje personalizado.

Sin embargo, los autores no presentan una visión ingenuamente optimista. Otro aporte del artículo es que reconoce limitaciones importantes de la IA aplicada a la educación. Entre ellas se encuentran la necesidad de mayor cantidad y calidad de datos, la dificultad para extraer características que representen adecuadamente el proceso de aprendizaje, la falta de periodos largos de observación, la poca portabilidad de algunas soluciones a otros sistemas, la ausencia de teorías educativas sólidas en ciertos diseños y la necesidad de mecanismos de intervención

más claros. Esta mirada crítica fortalece el artículo porque permite comprender que el uso de IA requiere planificación, evaluación y mejora continua.

Finalmente, el aporte general de los autores consiste en ofrecer una visión integral sobre el presente y futuro de la IA en sistemas de tutoría inteligente para la educación sostenible. El artículo demuestra que la inteligencia artificial puede apoyar la personalización, la predicción, la intervención temprana, el análisis emocional y la toma de decisiones educativas. No obstante, también enfatiza que estos sistemas deben diseñarse considerando equidad, transparencia, privacidad, confianza, ética y enfoque humano. En conclusión, el trabajo aporta una guía académica y práctica para que docentes, investigadores y especialistas en tecnología puedan desarrollar sistemas inteligentes que no solo sean innovadores, sino también sostenibles y beneficiosos para los estudiantes.

Proceso para obtener el aporte

El proceso seguido por los autores para obtener su aporte se basó en una **revisión sistemática de la literatura**, orientada a analizar cómo la inteligencia artificial se integra en los sistemas de tutoría inteligente para apoyar la educación sostenible. Para ello, primero definieron el problema central de la investigación: la necesidad de conectar los objetivos educativos de sostenibilidad con las posibilidades que ofrecen la inteligencia artificial, la analítica del aprendizaje y las tecnologías de información. A partir de esta preocupación, los autores formularon una agenda de investigación enfocada en identificar desafíos, formas de implementación, resultados y tendencias futuras de los sistemas inteligentes aplicados a la educación.

En primer lugar, los autores establecieron cuatro preguntas de investigación. La primera buscó identificar los principales desafíos de la implementación de la educación sostenible. La segunda se orientó a analizar cómo la inteligencia artificial y las tecnologías de información se incorporan en los sistemas de tutoría inteligente. La tercera examinó los resultados obtenidos cuando la IA se integra en estos sistemas educativos. Finalmente, la cuarta pregunta se centró en reconocer las tendencias futuras de la IA aplicada a sistemas de tutoría inteligente para la educación sostenible.

Luego, los autores realizaron una conceptualización del estudio utilizando un modelo de analítica del aprendizaje que organiza el análisis en cuatro dimensiones: **qué, cómo, por qué y quiénes**. Esta estructura permitió ordenar la revisión de manera clara. El “qué” se relacionó con los datos y artículos seleccionados; el “cómo” con las técnicas de revisión y análisis; el “por qué” con los objetivos de la investigación; y el “quiénes” con los principales actores interesados, como educadores, investigadores y arquitectos de soluciones tecnológicas. De esta manera, la revisión no solo se enfocó en la tecnología, sino también en su utilidad para los actores educativos.

Posteriormente, los autores aplicaron un proceso de selección de artículos basado en la metodología **PRISMA**, la cual permite realizar revisiones sistemáticas de forma rigurosa y transparente. Este proceso incluyó tres etapas principales: identificación, cribado y elegibilidad. Para la primera pregunta de investigación, los autores buscaron artículos en Scopus usando términos como “sustainable education” y “challenge”. Para las preguntas restantes, utilizaron Scopus y Web of Science con términos como “artificial intelligence”, “education sustainability”, “sustainable education” y “learning analytics”. Además, limitaron los resultados a artículos de revista o conferencia, escritos en inglés y publicados entre 2014 y 2023.

Después de aplicar los criterios de inclusión y exclusión, los autores seleccionaron artículos que presentaban casos educativos reales, sistemas con tecnología incorporada, resultados observables y desafíos relacionados con la implementación. Finalmente, trabajaron con **8 artículos** para analizar los desafíos de la educación sostenible y **29 artículos** para estudiar la

integración de inteligencia artificial en sistemas de tutoría inteligente. Esta selección permitió obtener una visión organizada y actualizada del campo de estudio.

Luego, los autores construyeron un esquema de codificación para analizar los artículos seleccionados. Este esquema clasificó la información según el tipo de datos utilizados, los métodos aplicados, los objetivos del sistema y los destinatarios educativos. Por ejemplo, se consideraron métodos como Machine Learning, minería de datos, juegos educativos y otros sistemas; objetivos como monitoreo, predicción, evaluación, adaptación, personalización y recomendación; y niveles educativos como primaria, secundaria y universidad. Esta codificación permitió comparar los estudios de manera ordenada y detectar tendencias comunes.

Finalmente, los autores sintetizaron los hallazgos en tablas y discusiones temáticas. Identificaron los desafíos principales, las tecnologías más utilizadas, los propósitos frecuentes del uso de IA, los resultados reportados y las limitaciones futuras. Así, el aporte del artículo fue obtenido mediante un proceso sistemático que combinó búsqueda bibliográfica, selección rigurosa, clasificación temática y análisis crítico. Gracias a este procedimiento, los autores lograron ofrecer una visión integral sobre el papel de la inteligencia artificial en los sistemas de tutoría inteligente y su contribución a una educación más sostenible, personalizada y centrada en el estudiante.

Proceso para resolver el problema

El proceso para resolver el problema planteado en el artículo parte de una preocupación central: la educación sostenible enfrenta desafíos importantes, como la desigualdad en el acceso a la tecnología, la falta de infraestructura, la necesidad de personalizar el aprendizaje, la limitada capacitación digital docente, los problemas de privacidad y los riesgos de sesgo en los sistemas inteligentes. Frente a esta situación, los autores proponen analizar de manera sistemática cómo la **inteligencia artificial** puede integrarse en los **sistemas de tutoría inteligente** para apoyar una educación más inclusiva, equitativa, personalizada y sostenible.

Primero, los autores identifican los principales desafíos de la educación sostenible. Entre ellos destacan el acceso desigual a internet y dispositivos, la dificultad de atender a muchos estudiantes en entornos virtuales o híbridos, la falta de interacción física y emocional, la limitada colaboración entre alumnos, el riesgo de abandono, la privacidad de datos, la seguridad, la equidad, los sesgos algorítmicos y la falta de transparencia de algunos sistemas de IA. Esta identificación permite comprender que el problema no es únicamente tecnológico, sino también pedagógico, social y ético.

Luego, los autores analizan cómo la IA puede incorporarse en los sistemas de tutoría inteligente. Para ello, distinguen dos formas principales de integración. La primera ocurre cuando la IA no está directamente incorporada al sistema de tutoría, sino que analiza los datos generados por la plataforma, como registros de interacción, desempeño, participación o abandono. En este caso, la IA se utiliza principalmente para predecir rendimiento, identificar comportamientos de aprendizaje, detectar riesgo de deserción o apoyar la toma de decisiones del docente. La segunda forma ocurre cuando la IA está integrada dentro del propio sistema, permitiendo personalización, rutas adaptativas, interacción mediante chatbots, reconocimiento emocional o intervenciones automáticas.

Después, el artículo revisa los métodos tecnológicos utilizados para resolver estos problemas educativos. Entre las técnicas más comunes se encuentran los algoritmos de **Machine Learning**, como regresión, máquinas de soporte vectorial, Naïve Bayes, Random Forest, redes neuronales, árboles de decisión y modelos de boosting. También se identifican métodos de aprendizaje no supervisado para analizar comportamientos, técnicas de procesamiento de

lenguaje natural para chatbots, reconocimiento facial para detectar emociones y herramientas de inteligencia artificial explicable para mejorar la confianza en los resultados del sistema.

El proceso de solución también incluye analizar los resultados obtenidos en investigaciones previas. Los autores encuentran que los sistemas de tutoría inteligente apoyados por IA pueden mejorar la predicción del rendimiento, identificar patrones de aprendizaje, prevenir abandono mediante alertas tempranas, apoyar intervenciones docentes, personalizar rutas de aprendizaje y mejorar la participación de los estudiantes. Sin embargo, también señalan que muchos sistemas todavía necesitan mayor explicabilidad, mejores datos, más integración pedagógica y mecanismos de intervención más claros.

Finalmente, los autores proponen que la solución debe orientarse hacia sistemas más humanos, confiables y sostenibles. Esto implica diseñar sistemas de IA que no solo sean precisos, sino también transparentes, seguros, éticos, inclusivos y centrados en el estudiante. De esta manera, el problema se resuelve no solo incorporando tecnología, sino asegurando que la IA apoye realmente la labor docente, respete la privacidad de los estudiantes, reduzca desigualdades y contribuya a una educación sostenible de calidad.

Métricas y resultados

En el artículo, las métricas no corresponden a un experimento único, sino a una **revisión sistemática**. Por ello, los autores evaluaron los resultados mediante la cantidad de artículos seleccionados, las categorías de análisis y la frecuencia de uso de determinadas tecnologías, objetivos y resultados. Para la revisión, se seleccionaron **8 artículos** orientados a los desafíos de la educación sostenible y **29 artículos** relacionados con inteligencia artificial integrada en sistemas de tutoría inteligente.

Entre los resultados más relevantes, los autores identificaron que la mayoría de estudios sobre IA en sistemas de tutoría inteligente se enfocaron en **predicción del rendimiento**, con **13 investigaciones**, seguida por el **análisis de comportamientos de aprendizaje**, con **9 estudios**. También se encontraron trabajos sobre prevención del abandono, personalización, apoyo al docente, intervención educativa y mejora del aprendizaje autorregulado. En cuanto a los niveles educativos, la mayor parte de investigaciones se concentró en educación universitaria, con **19 estudios**, lo que evidencia mayor interés en la educación superior.

Respecto a los resultados reportados por los estudios revisados, se observó que varios sistemas lograron **alta precisión en la predicción del rendimiento**, identificación de patrones de aprendizaje, mejora de la participación mediante alertas tempranas, apoyo a intervenciones docentes y aumento del rendimiento en sistemas personalizados. Sin embargo, los autores también destacan limitaciones importantes, como la necesidad de más datos, mejor calidad de información, mayor explicabilidad de los modelos, protección de privacidad y reducción de sesgos. En conjunto, los resultados muestran que la IA tiene gran potencial para apoyar la educación sostenible, pero debe implementarse con criterios éticos, pedagógicos y transparentes.

Observaciones/críticas

Una observación importante sobre el artículo es que ofrece una visión amplia y actualizada sobre el papel de la **inteligencia artificial en los sistemas de tutoría inteligente** para apoyar la educación sostenible. Su mayor fortaleza está en organizar diferentes estudios, tecnologías, desafíos y tendencias futuras, permitiendo comprender cómo la IA puede contribuir a la personalización del aprendizaje, la predicción del rendimiento, la prevención del abandono y el apoyo a la labor docente.

Sin embargo, una crítica relevante es que, al tratarse de una revisión sistemática, el artículo no implementa un sistema propio ni evalúa directamente el impacto de una herramienta de IA en estudiantes reales. Por ello, sus conclusiones dependen de los estudios revisados y no de un experimento realizado por los autores. Además, aunque la revisión selecciona 29 artículos sobre IA en sistemas de tutoría inteligente, esta cantidad todavía puede ser limitada frente al rápido crecimiento de investigaciones recientes en inteligencia artificial educativa.

Otra limitación es que gran parte de los estudios revisados se concentran en educación superior, por lo que existe menor evidencia sobre la aplicación de estos sistemas en primaria, secundaria u otros contextos educativos. Asimismo, el artículo reconoce desafíos importantes como privacidad, seguridad, sesgos algorítmicos, falta de explicabilidad y necesidad de mayor formación docente. Estos aspectos son fundamentales, porque una tecnología educativa no debe ser valorada únicamente por su precisión, sino también por su equidad, transparencia y utilidad pedagógica.

A pesar de estas limitaciones, el artículo es valioso porque muestra que la IA puede fortalecer la educación sostenible si se diseña desde un enfoque humano, ético y centrado en el estudiante.

32. ARTÍCULO 32

Author (s): Jaime Govea; Alexandra Maldonado Navarro; Santiago Sánchez-Viteri; William Villegas-Ch

Title of paper: Implementation of deep reinforcement learning models for emotion detection and personalization of learning in hybrid educational environments

Journal: Frontiers in Artificial Intelligence

Volume (issue): Volume 7

pag – pag (year): Article 1458230, pp. 1–22 (2024)

Estado del arte

La integración de la inteligencia artificial en la educación ha generado nuevas posibilidades para mejorar la experiencia de aprendizaje, especialmente mediante sistemas capaces de detectar emociones y personalizar estrategias pedagógicas en tiempo real. En los entornos educativos híbridos, donde los estudiantes combinan actividades presenciales y virtuales, las emociones influyen directamente en la motivación, la atención, la participación y el rendimiento académico. Por ello, la investigación reciente ha comenzado a estudiar cómo las tecnologías inteligentes pueden reconocer estados emocionales y adaptar el proceso educativo a las necesidades individuales de cada estudiante.

La literatura señala que las emociones positivas, como la alegría, la confianza o el interés, pueden favorecer el compromiso y el desempeño académico. En cambio, emociones negativas como ansiedad, frustración, tristeza o miedo pueden afectar la concentración y disminuir la participación. Sin embargo, muchos sistemas educativos todavía carecen de mecanismos adecuados para responder dinámicamente a estos estados emocionales. La mayoría de plataformas tradicionales ofrece contenidos de manera uniforme, sin considerar si el estudiante se encuentra motivado, confundido, cansado o emocionalmente desconectado. Esta limitación ha impulsado el desarrollo de modelos de aprendizaje personalizado apoyados en inteligencia artificial.

Dentro de este campo, la detección automática de emociones se ha trabajado principalmente con técnicas de visión computacional, procesamiento de audio y análisis biométrico. Las **redes neuronales convolucionales —CNN—** han sido utilizadas para reconocer expresiones faciales, debido a su capacidad para extraer rasgos espaciales de imágenes. Por su parte, las **redes neuronales recurrentes —RNN—** y sus variantes, como LSTM o GRU, permiten analizar secuencias temporales, como cambios en la voz, patrones biométricos o evolución

emocional durante una sesión de aprendizaje. No obstante, varios estudios han empleado estas técnicas de manera aislada, lo que limita su capacidad para comprender simultáneamente información espacial y temporal del estudiante.

Otra línea importante de investigación es el uso de **aprendizaje por refuerzo profundo — Deep Reinforcement Learning, DRL**— para adaptar estrategias educativas. A diferencia de los modelos que solo clasifican emociones, el DRL permite que un agente aprenda a tomar decisiones pedagógicas mediante interacción con el entorno. Esto significa que el sistema puede ajustar la dificultad de los contenidos, modificar la presentación del material, recomendar actividades o aplicar refuerzos positivos según el estado emocional y académico del estudiante. Esta capacidad de adaptación en tiempo real representa un avance frente a sistemas estáticos, porque permite responder a cambios emocionales durante el proceso de aprendizaje.

El artículo analizado se ubica precisamente en esta brecha de investigación. Los autores señalan que muchos modelos actuales trabajan con conjuntos de datos estáticos o escenarios predefinidos, lo que impide adaptarse a emociones cambiantes en ambientes educativos reales. Además, identifican la falta de propuestas que integren simultáneamente CNN, RNN y DRL para detectar emociones y personalizar el aprendizaje. Frente a ello, el estudio propone un sistema híbrido que utiliza cámaras, micrófonos y sensores biométricos para capturar datos emocionales de 500 estudiantes. Posteriormente, estos datos son procesados mediante técnicas de preprocesamiento, como ecualización de histogramas y reducción de ruido, para mejorar la calidad de las entradas del modelo.

El aporte se relaciona con la combinación de distintos componentes tecnológicos. Las CNN se emplean para reconocer expresiones faciales, las RNN para analizar secuencias de audio y datos biométricos, y el DRL para optimizar la personalización de estrategias de enseñanza. Esta integración permite que el sistema no solo identifique emociones, sino que actúe sobre ellas mediante decisiones adaptativas. En ese sentido, el modelo responde a una tendencia actual de la inteligencia artificial educativa: pasar de sistemas que solamente predicen o clasifican a sistemas que intervienen y ajustan dinámicamente la experiencia de aprendizaje.

En síntesis, el estado del arte muestra que la personalización del aprendizaje basada en emociones es un área emergente y prometedora. Aunque ya existen avances en detección emocional mediante visión computacional, audio y datos fisiológicos, todavía persisten desafíos relacionados con la adaptación en tiempo real, la integración multimodal de datos, la privacidad y la aplicación práctica en contextos educativos reales. El artículo contribuye a este campo al proponer un modelo basado en aprendizaje por refuerzo profundo que mejora la detección emocional y permite personalizar la enseñanza en entornos híbridos, ofreciendo una experiencia educativa más adaptativa, centrada en el estudiante y sensible a sus necesidades emocionales.

Motivación del autor

La motivación principal de los autores surge de la necesidad de mejorar la experiencia de aprendizaje en entornos educativos híbridos mediante sistemas inteligentes capaces de responder al estado emocional de los estudiantes. Los autores parten de la idea de que las emociones influyen directamente en la motivación, la atención, la participación y el rendimiento académico; sin embargo, muchas plataformas educativas no cuentan con mecanismos que permitan detectar emociones en tiempo real ni adaptar las estrategias de enseñanza según esas emociones. Esta limitación puede afectar negativamente el compromiso del estudiante y reducir la efectividad del proceso educativo.

Por ello, los autores buscan implementar un sistema basado en inteligencia artificial que combine **redes neuronales convolucionales, redes neuronales recurrentes y aprendizaje por refuerzo profundo** para detectar emociones y personalizar el aprendizaje de manera dinámica. Su motivación no es solo técnica, sino también pedagógica: crear un ambiente

educativo más adaptativo, sensible y centrado en el estudiante. Al utilizar datos capturados mediante cámaras, micrófonos y sensores biométricos, el modelo pretende identificar cambios emocionales y ajustar las estrategias de enseñanza en tiempo real, con el objetivo de mejorar el rendimiento académico, la participación y el bienestar emocional de los estudiantes en contextos híbridos.

Descripción del aporte del autor

El principal aporte de los autores consiste en implementar un sistema inteligente basado en **aprendizaje por refuerzo profundo —Deep Reinforcement Learning, DRL—** para detectar emociones en tiempo real y personalizar el aprendizaje en entornos educativos híbridos. El estudio parte de una problemática actual: muchas plataformas educativas no se adaptan dinámicamente al estado emocional de los estudiantes, a pesar de que las emociones influyen directamente en la motivación, la atención, la participación y el rendimiento académico. Frente a esta limitación, los autores proponen un modelo capaz de reconocer emociones mediante datos multimodales y ajustar estrategias pedagógicas de acuerdo con las necesidades emocionales y académicas de cada estudiante.

Uno de los aportes más importantes del artículo es la integración de distintas tecnologías de inteligencia artificial en un solo sistema. Los autores no utilizan únicamente un modelo de clasificación emocional, sino que combinan **redes neuronales convolucionales —CNN—**, **redes neuronales recurrentes —RNN—** y **aprendizaje por refuerzo profundo**. Las CNN se emplean para analizar imágenes faciales y reconocer expresiones emocionales; las RNN permiten procesar información secuencial, como audio y datos biométricos; y el DRL permite que el sistema tome decisiones adaptativas en tiempo real. Esta combinación representa una mejora frente a modelos tradicionales que suelen trabajar con una sola fuente de datos o con escenarios estáticos.

El aporte también se encuentra en el enfoque **multimodal** del sistema. Para detectar emociones, los autores recopilaban información mediante cámaras, micrófonos y sensores biométricos. Las cámaras fueron utilizadas para capturar expresiones faciales; los micrófonos permitieron analizar características de la voz; y los sensores biométricos registraron señales fisiológicas como la frecuencia cardíaca. Esta integración es relevante porque las emociones no siempre se expresan de una sola manera. Un estudiante puede mostrar señales faciales, vocales o fisiológicas diferentes según su estado emocional. Por ello, combinar varias fuentes de información permite obtener una detección emocional más precisa y completa.

Otro aporte significativo es que el sistema fue diseñado para funcionar en **entornos educativos híbridos**, es decir, en contextos donde se combinan actividades presenciales y virtuales. Este punto es importante porque la educación actual ya no se desarrolla únicamente en aulas físicas tradicionales, sino también en plataformas digitales, sesiones remotas y espacios combinados. En estos escenarios, el docente puede tener mayores dificultades para percibir el estado emocional de todos los estudiantes. Por ello, un sistema capaz de detectar emociones en tiempo real puede servir como apoyo para identificar señales de desmotivación, frustración, ansiedad o desconexión, y así ajustar las estrategias de enseñanza.

El artículo aporta una arquitectura organizada en tres módulos principales. El primero es el **módulo de captura de datos emocionales**, encargado de recopilar información mediante dispositivos tecnológicos. El segundo es el **módulo de procesamiento y detección de emociones**, donde se limpian, normalizan y analizan los datos capturados. El tercero es el **módulo de adaptación y personalización educativa**, basado en DRL, que utiliza la información emocional y académica para modificar las estrategias pedagógicas. Esta estructura permite que el sistema funcione como un ciclo continuo: captura datos, detecta emociones, toma decisiones y adapta la enseñanza.

Además, los autores aportan un proceso de preprocesamiento avanzado de datos. Para mejorar la calidad de las imágenes faciales, aplicaron técnicas como ecualización de histogramas, reducción de ruido, detección facial y normalización de imágenes. En el caso del audio, se aplicaron filtros para reducir ruido, normalizar el volumen y extraer características relevantes de la voz. Para los datos biométricos, se utilizaron técnicas de filtrado y normalización con el fin de eliminar valores distorsionados o inconsistentes. Este procedimiento es importante porque la calidad de los datos influye directamente en la precisión del modelo. Si las imágenes, audios o señales fisiológicas tienen ruido, el sistema puede interpretar incorrectamente el estado emocional del estudiante.

Un aporte metodológico importante es la utilización de un modelo híbrido **CNN-RNN**. Las CNN son adecuadas para procesar información espacial, como imágenes del rostro, mientras que las RNN son útiles para analizar secuencias temporales, como cambios en la voz o variaciones biométricas. Al combinar ambos enfoques, el sistema puede comprender mejor la dimensión emocional del estudiante, ya que analiza tanto expresiones estáticas como cambios a lo largo del tiempo. Esta combinación supera las limitaciones de usar CNN o RNN por separado, debido a que un solo modelo no siempre puede capturar toda la complejidad de los estados emocionales.

Asimismo, el estudio aporta el uso de **Proximal Policy Optimization —PPO—** dentro del aprendizaje por refuerzo profundo. Esta técnica permite que el agente del sistema aprenda políticas de acción estables para adaptar las estrategias de enseñanza. En términos simples, el sistema observa el estado emocional y académico del estudiante, decide qué acción pedagógica aplicar y recibe una recompensa según el impacto de esa acción. Con el tiempo, el agente aprende qué decisiones son más efectivas para mejorar la participación, el rendimiento y la experiencia de aprendizaje. Esta capacidad de aprender y ajustar decisiones representa un avance frente a sistemas educativos que solo presentan contenidos de manera fija.

Desde una perspectiva pedagógica, el aporte central está en la **personalización del aprendizaje**. El sistema no se limita a detectar si un estudiante está feliz, triste, sorprendido o frustrado; también utiliza esa información para adaptar la enseñanza. Por ejemplo, puede modificar la dificultad del contenido, cambiar el ritmo de la clase, recomendar materiales distintos, aplicar refuerzos positivos o ajustar la presentación de las actividades. Esto convierte al modelo en una herramienta de apoyo educativo, ya que permite responder a las necesidades emocionales y cognitivas del estudiante en tiempo real.

El artículo también aporta evidencia empírica mediante una muestra de **500 estudiantes**. Los datos fueron divididos en conjuntos de entrenamiento, validación y prueba: 70% para entrenamiento, 15% para validación y 15% para pruebas finales. Esta división permitió evaluar el desempeño del modelo de forma más confiable. Los resultados muestran una mejora significativa en la precisión de detección emocional, que pasó de **72.4% antes de la implementación del sistema a 89.3% después de la implementación**. Además, la adaptabilidad en tiempo real aumentó de **68.5% a 87.6%**, y la personalización del aprendizaje se incrementó de **70.2% a 90.1%**. Estos resultados evidencian que el sistema logró mejoras importantes tanto en la detección como en la adaptación educativa.

Otro aporte relevante es la comparación entre diferentes configuraciones de modelos. Los autores evaluaron modelos CNN, RNN y CNN-RNN, además de técnicas de preprocesamiento como ecualización de histogramas y reducción de ruido. Los resultados mostraron que la configuración **CNN-RNN con reducción de ruido** alcanzó mejores valores de precisión y sensibilidad que los modelos individuales. Esto confirma que la integración de información espacial y temporal, junto con un tratamiento adecuado de los datos, mejora la capacidad del sistema para detectar emociones de manera más confiable.

El estudio también aporta una evaluación de robustez mediante **validación cruzada k-fold con $k = 10$** . Esta técnica permitió comprobar que el modelo mantenía resultados altos y consistentes en diferentes particiones del conjunto de datos. Esto es importante porque un modelo educativo no debe funcionar únicamente en una muestra específica, sino que debe mostrar capacidad de generalización. La validación cruzada fortalece la confiabilidad del sistema y sugiere que podría aplicarse en distintos contextos educativos híbridos.

Otro aspecto importante del aporte es la consideración ética y de privacidad. Los autores reconocen que el uso de cámaras, micrófonos y sensores biométricos en educación puede generar riesgos relacionados con la protección de datos personales. Por ello, el estudio incluyó consentimiento informado, almacenamiento seguro de datos, acceso restringido, anonimización y medidas de protección. Este punto es fundamental porque la implementación de inteligencia artificial en educación no debe centrarse únicamente en la eficiencia técnica, sino también en el respeto a la privacidad, la transparencia y el bienestar de los estudiantes.

Desde el punto de vista institucional, el aporte del artículo es mostrar que la inteligencia artificial puede apoyar la toma de decisiones pedagógicas en tiempo real. En lugar de depender únicamente de la observación del docente, el sistema ofrece información adicional sobre el estado emocional del estudiante. Esto no significa reemplazar al profesor, sino brindarle una herramienta complementaria para comprender mejor la experiencia de aprendizaje y responder de forma más oportuna. En contextos híbridos, donde la interacción puede ser menos directa, este tipo de tecnología puede ayudar a mantener el acompañamiento personalizado.

En conclusión, el aporte de los autores se resume en la implementación de un sistema inteligente que combina detección emocional multimodal, aprendizaje profundo y aprendizaje por refuerzo para personalizar la enseñanza en ambientes híbridos. Su valor principal está en pasar de un modelo educativo estático a uno adaptativo, capaz de responder en tiempo real al estado emocional y académico del estudiante. El estudio demuestra que la integración de CNN, RNN y DRL puede mejorar la precisión en la detección de emociones, aumentar la adaptabilidad del sistema y fortalecer la personalización del aprendizaje. De esta manera, el artículo contribuye al desarrollo de una educación más sensible, flexible, centrada en el estudiante y orientada a mejorar tanto el rendimiento académico como el bienestar emocional.

Proceso para obtener el aporte

Para obtener su aporte, los autores desarrollaron un proceso metodológico basado en la implementación de un sistema de inteligencia artificial capaz de detectar emociones y personalizar el aprendizaje en tiempo real. El estudio se realizó en un entorno educativo híbrido con la participación de **500 estudiantes**, de los cuales se recopilaban datos emocionales, biométricos y académicos. La finalidad fue construir un modelo que no solo identificara el estado emocional del estudiante, sino que también ajustara las estrategias de enseñanza según sus necesidades emocionales y su rendimiento académico.

El primer paso consistió en la **captura de datos multimodales**. Para ello, los autores utilizaron cámaras de alta resolución, micrófonos y sensores biométricos. Las cámaras permitieron registrar expresiones faciales; los micrófonos capturaron señales de voz; y los sensores biométricos recogieron información fisiológica, como la frecuencia cardíaca. Esta recolección fue realizada en un ambiente que simulaba condiciones reales de aula, con el propósito de que los datos reflejaran situaciones auténticas de aprendizaje. Además, se consideraron registros académicos para relacionar las emociones detectadas con el desempeño estudiantil.

El segundo paso fue el **preprocesamiento de los datos**. Las imágenes faciales fueron tratadas mediante técnicas como detección de rostro, normalización, ecualización de histogramas y reducción de ruido, con el objetivo de mejorar el contraste y facilitar el reconocimiento de expresiones emocionales. En el caso del audio, se aplicaron técnicas de filtrado, reducción de

ruido y normalización del volumen para mejorar la calidad de las señales de voz. Los datos biométricos también fueron filtrados y normalizados para eliminar valores erróneos o interferencias. Este proceso fue fundamental porque la precisión del modelo dependía directamente de la calidad de los datos de entrada.

El tercer paso consistió en el **entrenamiento de modelos de detección emocional**. Los autores emplearon redes neuronales convolucionales —CNN— para analizar imágenes faciales, redes neuronales recurrentes —RNN— para procesar secuencias de audio y datos temporales, y un modelo híbrido CNN-RNN para combinar información espacial y temporal. Los datos se dividieron en **70% para entrenamiento, 15% para validación y 15% para prueba**, lo que permitió evaluar el desempeño del sistema de manera controlada y confiable. Los modelos fueron entrenados para clasificar emociones como felicidad, tristeza, ira, sorpresa, miedo y disgusto.

El cuarto paso fue la implementación del modelo de **aprendizaje por refuerzo profundo**. Este modelo funcionó como un agente capaz de tomar decisiones pedagógicas según el estado emocional y académico del estudiante. A partir de las emociones detectadas y del rendimiento académico, el agente aprendía qué acciones podían mejorar la experiencia de aprendizaje, como ajustar la dificultad del contenido, modificar el ritmo de enseñanza, variar las actividades o aplicar estrategias de refuerzo positivo. Para optimizar estas decisiones, los autores utilizaron técnicas como **Proximal Policy Optimization —PPO—**, que permite una adaptación más estable en entornos dinámicos.

Finalmente, los autores evaluaron el sistema mediante pruebas comparativas y validación cruzada. Se comparó el desempeño antes y después de la implementación del sistema, observándose mejoras importantes en la precisión de detección emocional, la adaptabilidad en tiempo real y la personalización del aprendizaje. Además, la validación cruzada k-fold con **k = 10** confirmó la robustez del modelo. De esta manera, el aporte se obtuvo mediante un proceso que integró captura de datos multimodales, preprocesamiento avanzado, modelos CNN-RNN, aprendizaje por refuerzo profundo y evaluación experimental en un entorno educativo híbrido.

Proceso para resolver el problema

Para resolver el problema de la falta de adaptación emocional en los entornos educativos híbridos, los autores propusieron un sistema basado en inteligencia artificial capaz de detectar emociones en tiempo real y personalizar las estrategias de aprendizaje. El problema principal identificado fue que muchos sistemas educativos no responden dinámicamente al estado emocional de los estudiantes, a pesar de que emociones como frustración, ansiedad, tristeza, motivación o alegría pueden influir directamente en la atención, la participación y el rendimiento académico. Por ello, los autores diseñaron una solución que integra detección emocional multimodal y aprendizaje por refuerzo profundo.

El primer paso fue capturar información emocional y académica de los estudiantes. Para ello, se utilizaron cámaras, micrófonos y sensores biométricos en un ambiente educativo híbrido. Las cámaras registraron expresiones faciales, los micrófonos captaron señales de voz y los sensores biométricos recogieron datos fisiológicos como la frecuencia cardíaca. Esta información permitió observar el estado emocional del estudiante desde distintas fuentes, evitando depender de un solo tipo de dato.

Luego, los datos fueron procesados para mejorar su calidad. Las imágenes fueron normalizadas y tratadas con técnicas como ecualización de histogramas y reducción de ruido; el audio fue filtrado para disminuir interferencias; y los datos biométricos fueron limpiados y normalizados. Este paso fue necesario porque los datos capturados en ambientes reales pueden contener errores, ruido o variaciones que afectan la precisión del modelo.

Después, los autores aplicaron modelos de aprendizaje profundo para detectar emociones. Las **redes neuronales convolucionales —CNN—** se utilizaron para reconocer expresiones faciales, mientras que las **redes neuronales recurrentes —RNN—** analizaron secuencias de audio y datos temporales. Posteriormente, se integró un modelo híbrido **CNN-RNN**, capaz de combinar información espacial y temporal para mejorar la detección emocional. De esta manera, el sistema podía clasificar emociones como felicidad, tristeza, ira, sorpresa, miedo y disgusto.

Finalmente, el problema se resolvió mediante un modelo de **aprendizaje por refuerzo profundo**, encargado de adaptar las estrategias educativas en tiempo real. Este agente tomaba como entrada el estado emocional y el rendimiento académico del estudiante, y decidía acciones pedagógicas como ajustar la dificultad del contenido, modificar el ritmo de enseñanza, cambiar actividades o aplicar refuerzos positivos. Los resultados demostraron que esta solución mejoró la precisión de detección emocional, la adaptabilidad del sistema y la personalización del aprendizaje. Así, los autores resolvieron el problema proponiendo un entorno educativo más dinámico, sensible y centrado en las necesidades emocionales y académicas del estudiante.

Métricas y resultados

Para evaluar el sistema propuesto, los autores utilizaron métricas relacionadas con la **detección de emociones**, la **adaptabilidad en tiempo real** y la **personalización del aprendizaje**. En la detección emocional se consideraron indicadores como **accuracy**, **precision**, **recall**, **F1-score** y sensibilidad, con el fin de medir qué tan bien el modelo identificaba emociones como felicidad, tristeza, ira, sorpresa, miedo y disgusto. Además, se aplicó **validación cruzada k-fold con k = 10** para comprobar la robustez y capacidad de generalización del modelo. También se evaluaron diferentes configuraciones, como CNN, RNN y el modelo híbrido CNN-RNN, junto con técnicas de preprocesamiento como ecualización de histogramas y reducción de ruido.

Los resultados evidenciaron una mejora significativa después de implementar el sistema. La precisión general de detección de emociones aumentó de **72.4% a 89.3%**; la adaptabilidad en tiempo real subió de **68.5% a 87.6%**; y la personalización del aprendizaje pasó de **70.2% a 90.1%**. En la comparación de modelos, la configuración **CNN-RNN con reducción de ruido** obtuvo el mejor desempeño, alcanzando **88.0% de precisión** y **85.2% de sensibilidad**, superando a CNN, RNN, DQN, A3C y DDPG. Estos resultados demuestran que la combinación de aprendizaje profundo, datos multimodales y aprendizaje por refuerzo profundo permite detectar emociones con mayor exactitud y adaptar mejor las estrategias educativas a las necesidades de los estudiantes.

Observaciones/críticas

Una observación positiva del artículo es que propone una solución innovadora para un problema actual de la educación híbrida: la falta de adaptación de las estrategias de enseñanza al estado emocional del estudiante. El estudio resulta valioso porque integra varias tecnologías de inteligencia artificial, como **CNN**, **RNN** y **aprendizaje por refuerzo profundo**, para detectar emociones y personalizar el aprendizaje en tiempo real. Además, el uso de datos multimodales —imágenes faciales, audio, información biométrica y registros académicos— permite una comprensión más completa del estudiante. Los resultados también son relevantes, ya que muestran mejoras importantes en precisión emocional, adaptabilidad y personalización del aprendizaje.

Sin embargo, también existen algunas críticas. En primer lugar, el sistema requiere cámaras, micrófonos y sensores biométricos, lo que puede generar preocupaciones éticas sobre privacidad, consentimiento y uso responsable de los datos emocionales. Aunque los autores mencionan medidas de protección, su aplicación real en instituciones educativas podría ser compleja. En segundo lugar, el modelo puede ser difícil de implementar en centros con pocos

recursos tecnológicos o sin personal especializado. Además, la detección emocional automatizada no siempre interpreta correctamente el contexto del estudiante, ya que una expresión facial o señal biométrica puede tener varias causas. A pesar de estas limitaciones, el artículo aporta una propuesta sólida para avanzar hacia una educación más personalizada, adaptativa y centrada en el bienestar del estudiante.

33. ARTÍCULO 33

Author (s): Rodrigo Guevara-Reyes; Iván Ortiz-Garcés; Roberto Andrade; Fernanda Cox-Riquetti; William Villegas-Ch.

Title of paper: *Machine learning models for academic performance prediction: interpretability and application in educational decision-making.*

Journal: *Frontiers in Education.*

Volume (issue): 10.

pag – pag (year): 1–27 (2025).

Estado del arte

El estudio sobre la **predicción del rendimiento académico mediante modelos de Machine Learning** se ha consolidado como una línea relevante dentro de la analítica educativa, debido a la necesidad de identificar tempranamente a estudiantes con riesgo de bajo desempeño y apoyar la toma de decisiones en las instituciones educativas. En los últimos años, el uso de inteligencia artificial en educación ha permitido procesar grandes volúmenes de datos académicos, institucionales, socioeconómicos y geográficos, con el fin de reconocer patrones que influyen en los resultados de aprendizaje. Sin embargo, una de las principales limitaciones de muchos estudios previos es que se han concentrado principalmente en la precisión de los modelos, dejando en segundo plano la interpretabilidad y la aplicación real de los resultados en la gestión educativa.

De acuerdo con el artículo revisado, investigaciones recientes han demostrado que los modelos de Machine Learning pueden mejorar la predicción del rendimiento académico cuando integran variables contextuales, como el tipo de institución, las condiciones socioeconómicas, el acceso a recursos tecnológicos, la infraestructura y el promedio académico previo. No obstante, los autores señalan que muchos de estos modelos funcionan como “cajas negras”, es decir, generan predicciones sin explicar claramente qué factores influyen en ellas. Esta falta de transparencia limita su adopción en contextos educativos reales, donde docentes, directivos y responsables de políticas necesitan comprender las razones detrás de una predicción antes de tomar decisiones.

En este contexto, cobra importancia la **inteligencia artificial explicable o Explainable Artificial Intelligence (XAI)**. Esta área busca que los modelos predictivos no solo sean precisos, sino también comprensibles para los usuarios. En educación, la explicabilidad es fundamental porque permite identificar qué variables están afectando el desempeño de los estudiantes y cómo pueden diseñarse estrategias de intervención. El artículo destaca el uso de técnicas como **SHAP**, que permite analizar la contribución de cada variable en la predicción del modelo. De esta manera, el sistema no solo indica el nivel probable de rendimiento académico, sino que también explica qué factores están impulsando ese resultado.

El estado actual de la investigación muestra que existen diversos algoritmos aplicados a la predicción académica, entre ellos Random Forest, XGBoost, SVM, redes neuronales, regresión logística y árboles de decisión. Sin embargo, los autores resaltan que modelos como **XGBoost** y **Random Forest** ofrecen un equilibrio adecuado entre rendimiento predictivo e interpretabilidad, especialmente cuando se combinan con herramientas explicativas. En el artículo, XGBoost alcanza un desempeño superior, con un coeficiente de determinación de $R^2 = 0.91$, superando enfoques tradicionales y reduciendo el error cuadrático medio en 15 %.

Otro aspecto importante del estado del arte es la incorporación de sistemas de apoyo a la decisión. Muchos trabajos previos se han limitado a construir modelos predictivos de forma experimental, sin integrarlos en plataformas que puedan ser utilizadas por instituciones educativas. En cambio, el artículo revisado propone un sistema interactivo que permite visualizar predicciones, analizar variables relevantes y simular escenarios de política educativa. Esta orientación representa un avance significativo, porque convierte el modelo en una herramienta práctica para directivos y responsables de la gestión educativa.

Asimismo, la literatura reciente reconoce que el rendimiento académico no depende únicamente de las capacidades individuales del estudiante, sino también de factores estructurales. El artículo evidencia que variables como el nivel socioeconómico, el tipo de institución, la proporción estudiante-docente, el acceso a recursos tecnológicos y el promedio académico previo explican gran parte de la variabilidad del desempeño. En concreto, el análisis de importancia de variables muestra que cinco factores explican el 72 % de la variabilidad en el rendimiento académico. Esto demuestra que las decisiones educativas deben considerar tanto aspectos académicos como condiciones institucionales y sociales.

En síntesis, el estado del arte evidencia que la inteligencia artificial aplicada a la educación ha avanzado desde modelos predictivos centrados solo en la exactitud hacia enfoques más explicables, escalables y orientados a la toma de decisiones. El artículo de Guevara-Reyes y colaboradores aporta a esta línea al integrar Machine Learning, interpretabilidad con SHAP y un sistema de soporte para decisiones educativas. Su principal valor está en demostrar que los modelos predictivos pueden ser útiles no solo para anticipar el rendimiento académico, sino también para diseñar políticas, optimizar recursos y generar intervenciones basadas en evidencia.

Motivación del autor

La motivación principal de los autores surge de una limitación frecuente en la aplicación de **inteligencia artificial en educación**: muchos modelos de Machine Learning logran buenos niveles de precisión para predecir el rendimiento académico, pero no explican claramente cómo llegan a sus resultados ni ofrecen información accionable para la toma de decisiones. Esta falta de interpretabilidad dificulta que docentes, directivos y administradores educativos confíen en los modelos, ya que en el ámbito educativo no basta con obtener una predicción; también es necesario comprender qué factores influyen en ella y cómo se puede intervenir para mejorar los resultados.

Asimismo, los autores se motivan por la necesidad de desarrollar herramientas que permitan anticipar el bajo rendimiento académico considerando factores **geográficos, institucionales, socioeconómicos y académicos**. El artículo señala que las instituciones educativas suelen tener dificultades para identificar las causas del bajo desempeño estudiantil, especialmente cuando los modelos funcionan como “cajas negras” y no ofrecen explicaciones útiles para orientar acciones pedagógicas o administrativas.

Por ello, la investigación busca integrar modelos predictivos optimizados, como **XGBoost** y **Random Forest**, con técnicas de interpretabilidad basadas en **SHAP** y un sistema interactivo de apoyo a la decisión. La motivación no es únicamente predecir el rendimiento estudiantil, sino convertir esa predicción en una herramienta comprensible y práctica para diseñar estrategias educativas, simular políticas, optimizar recursos y apoyar intervenciones basadas en evidencia.

Descripción del aporte del autor

El aporte principal de Rodrigo Guevara-Reyes, Iván Ortiz-Garcés, Roberto Andrade, Fernanda Cox-Riquetti y William Villegas-Ch en el artículo “**Machine learning models for academic**

performance prediction: interpretability and application in educational decision-making”

consiste en desarrollar un modelo predictivo de rendimiento académico que no solo se enfoca en alcanzar alta precisión, sino también en ofrecer interpretabilidad y utilidad práctica para la toma de decisiones educativas. Este aporte es relevante porque muchas investigaciones previas en inteligencia artificial aplicada a la educación han priorizado la exactitud de los modelos, pero han dejado en segundo plano la explicación de los resultados y su aplicación en escenarios reales de gestión educativa.

Uno de los aportes más importantes del artículo es que responde a una limitación frecuente de los modelos de Machine Learning: su funcionamiento como “cajas negras”. En el contexto educativo, esta limitación es especialmente delicada, porque las predicciones pueden influir en decisiones sobre estudiantes, docentes, recursos institucionales y políticas educativas. Si un modelo predice bajo rendimiento, pero no explica por qué, los docentes y autoridades tienen dificultades para confiar en el resultado y actuar de manera adecuada. Por esta razón, los autores incorporan técnicas de **inteligencia artificial explicable**, específicamente **SHAP**, con el propósito de mostrar qué variables influyen más en el rendimiento académico y cómo contribuyen a cada predicción.

El artículo también aporta al integrar diferentes tipos de variables en la predicción del rendimiento académico. A diferencia de estudios que solo consideran calificaciones o datos individuales del estudiante, esta investigación incorpora factores **geográficos, institucionales, socioeconómicos y académicos**. Entre las variables analizadas se encuentran la zona, provincia, cantón, área urbana o rural, tipo de institución, régimen escolar, infraestructura, accesibilidad, proporción estudiante-docente, recursos disponibles y puntajes académicos en áreas como Matemática, Lengua y Literatura, Ciencias Naturales y Ciencias Sociales. Esta integración permite comprender el rendimiento académico como un fenómeno multidimensional, influido no solo por el estudiante, sino también por el entorno educativo en el que aprende.

Otro aporte relevante es el uso de datos oficiales del sistema educativo ecuatoriano. Los autores trabajaron con información proveniente del **Archivo Maestro de Instituciones Educativas (AMEI)** y de las evaluaciones **Ser Bachiller**, lo que permitió construir una base de datos amplia y representativa. El estudio utilizó alrededor de **50 000 registros estudiantiles**, posteriormente depurados y procesados para entrenar y validar los modelos predictivos. Este volumen de datos fortalece el aporte del trabajo, porque permite analizar patrones educativos a gran escala y no solamente casos aislados o muestras pequeñas.

Desde el punto de vista metodológico, los autores aportan un proceso completo de preparación de datos. Realizan limpieza de valores nulos, tratamiento de datos inconsistentes, codificación de variables categóricas, normalización, selección de características y control de multicolinealidad. Este procedimiento es importante porque la calidad de los datos influye directamente en la confiabilidad del modelo. Además, los autores consideran aspectos como la eliminación de duplicados, la verificación de códigos institucionales, la revisión de inconsistencias geográficas y académicas, así como estrategias para reducir sesgos en la representación de instituciones públicas, privadas, urbanas y rurales.

El aporte técnico del artículo se evidencia en la comparación y optimización de modelos de Machine Learning. Los autores seleccionan principalmente **Random Forest** y **XGBoost**, debido a su capacidad para manejar relaciones no lineales, trabajar con datos complejos y ofrecer un equilibrio entre precisión e interpretabilidad. XGBoost se destaca como el modelo con mejor rendimiento, alcanzando un **R² de 0.91** y reduciendo el error cuadrático medio en un **15 %** en comparación con modelos base. Este resultado demuestra que el modelo tiene una alta capacidad para explicar y predecir el rendimiento académico.

Sin embargo, el aporte del estudio no se limita a indicar qué modelo predice mejor. Los autores complementan la predicción con una capa de interpretabilidad mediante SHAP. Esta técnica permite analizar el peso de cada variable en las predicciones y ofrece explicaciones tanto globales como individuales. Gracias a ello, el estudio identifica que cinco variables explican el **72 % de la variabilidad** en el rendimiento académico: nivel socioeconómico, tipo de institución, proporción estudiante-docente, acceso a recursos tecnológicos y promedio académico previo. Este hallazgo resulta fundamental porque orienta a las instituciones sobre los factores que deben priorizar para mejorar los resultados educativos.

Otro aporte importante es que el estudio vincula la predicción con la **toma de decisiones educativas**. Muchas investigaciones construyen modelos que quedan en el plano experimental, pero este artículo propone un sistema de apoyo a la decisión que permite visualizar predicciones, interpretar resultados y simular escenarios de política educativa. En ese sentido, los autores no solo desarrollan un modelo, sino también una herramienta que puede ser utilizada por administradores, directivos y responsables de políticas públicas para explorar estrategias de mejora.

El sistema propuesto incluye una interfaz interactiva o dashboard, donde los usuarios pueden analizar indicadores de rendimiento académico, filtrar información por ubicación geográfica, tipo de institución y recursos disponibles, además de visualizar explicaciones basadas en SHAP. Este componente convierte el modelo en una herramienta práctica, ya que facilita la comprensión de los resultados y permite que los responsables educativos tomen decisiones basadas en evidencia. Por ejemplo, el sistema puede ayudar a identificar instituciones con bajo rendimiento, analizar las variables que explican esa situación y priorizar intervenciones.

Un aporte especialmente valioso del artículo es la simulación de políticas educativas. Los autores evalúan cómo ciertos cambios podrían impactar en el rendimiento académico, como mejorar la formación docente, ampliar el acceso a tecnología, reducir la proporción estudiante-docente o fortalecer la infraestructura escolar. Según los resultados, mejorar la capacitación docente y el acceso a tecnología puede aumentar el rendimiento académico en **18 %** y reducir la deserción en **12 %**. Este aporte es relevante porque permite pasar de la simple descripción del problema a la planificación de soluciones concretas.

Desde una perspectiva institucional, el artículo aporta un modelo escalable y aplicable a entornos reales. Los autores no se limitan a entrenar el modelo en laboratorio, sino que plantean una arquitectura de implementación con procesamiento de datos, API, dashboard, sistema de soporte a decisiones y mecanismos de despliegue en entornos de producción. Esto demuestra una preocupación por la viabilidad técnica del sistema, su eficiencia computacional y su posible integración en plataformas educativas existentes.

También es importante destacar el aporte ético del artículo. Los autores reconocen que el uso de inteligencia artificial en educación puede generar riesgos, especialmente relacionados con sesgos, privacidad, desigualdad y uso inadecuado de las predicciones. Por ello, plantean la necesidad de que los resultados del modelo no sean utilizados como criterios definitivos para evaluar estudiantes o instituciones, sino como una herramienta complementaria para identificar patrones, orientar intervenciones y mejorar la planificación educativa. Esta postura es importante porque evita una visión tecnocrática de la educación y mantiene la supervisión humana como elemento central.

En conclusión, el aporte de los autores es amplio porque integra precisión predictiva, explicabilidad, utilidad institucional y responsabilidad ética. El artículo demuestra que los modelos de Machine Learning pueden ser útiles para anticipar el rendimiento académico, pero su verdadero valor aparece cuando sus resultados son comprensibles y accionables. Al combinar XGBoost, Random Forest, SHAP y un sistema interactivo de apoyo a la decisión, los autores proponen una solución que permite identificar factores de riesgo, explicar predicciones,

simular políticas educativas y optimizar estrategias institucionales. Por ello, esta investigación representa un avance importante en la aplicación de inteligencia artificial para la gestión educativa basada en evidencia.

Proceso para obtener el aporte

El proceso seguido por los autores para obtener su aporte se desarrolló mediante una metodología integral que combinó **recolección de datos educativos, preprocesamiento, modelamiento predictivo, interpretabilidad y construcción de un sistema de apoyo a la decisión**. A diferencia de investigaciones que solo entrenan modelos de Machine Learning para medir precisión, este estudio buscó construir una solución completa que permitiera predecir el rendimiento académico, explicar los factores que influyen en los resultados y convertir esa información en una herramienta útil para la gestión educativa.

En primer lugar, los autores recopilaron información de fuentes oficiales del sistema educativo ecuatoriano. Utilizaron datos del **Archivo Maestro de Instituciones Educativas (AMEI)** y de las evaluaciones **Ser Bachiller**, integrando registros académicos, institucionales, geográficos y socioeconómicos. La base de datos incluyó información sobre zona, provincia, cantón, parroquia, área urbana o rural, tipo de institución, régimen escolar, infraestructura, acceso a servicios, recursos disponibles, proporción estudiante-docente y resultados académicos en distintas áreas evaluadas. Esta integración permitió analizar el rendimiento académico desde una perspectiva amplia, considerando no solo el desempeño individual del estudiante, sino también las condiciones del entorno educativo.

Luego, los autores realizaron una etapa rigurosa de **preprocesamiento de datos**. En esta fase se trataron valores nulos, registros duplicados, inconsistencias en códigos institucionales, errores en variables geográficas y datos atípicos. También se codificaron variables categóricas mediante técnicas como *One-Hot Encoding* y *Label Encoding*, se normalizaron variables numéricas con *MinMaxScaler* y se aplicaron procedimientos de selección de características. Además, se evaluó la multicolinealidad mediante correlación de Pearson y el factor de inflación de varianza, con el fin de eliminar variables redundantes y mejorar la eficiencia del modelo. Después de este proceso, el conjunto final quedó conformado por aproximadamente **48 000 registros** y **27 características** distribuidas en categorías geográficas, institucionales, socioeconómicas y académicas.

Posteriormente, los autores desarrollaron la fase de **modelamiento predictivo**. Para ello evaluaron modelos de Machine Learning capaces de trabajar con relaciones no lineales y datos complejos, especialmente **Random Forest** y **XGBoost**. El conjunto de datos fue dividido en 80 % para entrenamiento y 20 % para prueba, manteniendo la representatividad de las categorías de rendimiento académico. Además, se aplicó validación cruzada de cinco pliegues para reducir la dependencia de una sola partición de datos y obtener métricas más estables. Los hiperparámetros de los modelos fueron optimizados mediante **Optuna**, lo que permitió encontrar configuraciones adecuadas sin realizar una búsqueda manual exhaustiva.

Una vez entrenados los modelos, los autores evaluaron su rendimiento mediante métricas como **R², MSE, precisión, recall y F1-score**. Esta etapa permitió identificar que **XGBoost** fue el modelo con mejor desempeño predictivo, alcanzando un R² de 0.91 y reduciendo el error cuadrático medio en 15 % respecto a modelos base. Sin embargo, el aporte no se quedó únicamente en la predicción. Para superar el problema de la “caja negra”, los autores incorporaron técnicas de interpretabilidad basadas en **SHAP**, las cuales permitieron determinar la contribución de cada variable en las predicciones y explicar tanto los resultados globales como los casos individuales.

Finalmente, los autores integraron el modelo en un **sistema de apoyo a la decisión**. Este sistema incluyó una arquitectura con procesamiento de datos, API, dashboard interactivo y módulo de

visualización para que administradores y responsables educativos pudieran explorar predicciones, analizar variables influyentes y simular escenarios de política educativa. Mediante este proceso, el aporte fue obtenido no solo como un modelo estadístico de alta precisión, sino como una herramienta práctica, interpretable y escalable para orientar decisiones educativas basadas en evidencia.

Proceso para resolver el problema

El proceso para resolver el problema planteado en el artículo parte de una dificultad central: los modelos de predicción del rendimiento académico suelen alcanzar buenos niveles de precisión, pero muchas veces no explican sus resultados ni se integran en herramientas útiles para la toma de decisiones educativas. Esto genera una brecha entre la predicción técnica y la acción pedagógica o institucional. Por ello, los autores proponen una solución que combina **Machine Learning, interpretabilidad con SHAP** y un **sistema interactivo de apoyo a la decisión**, con el fin de anticipar el desempeño académico y orientar estrategias educativas basadas en evidencia.

Primero, los autores recopilan e integran datos oficiales del sistema educativo ecuatoriano, principalmente del **Archivo Maestro de Instituciones Educativas (AMEI)** y de las evaluaciones **Ser Bachiller**. Esta información incluye variables geográficas, institucionales, socioeconómicas y académicas, como zona, provincia, área urbana o rural, tipo de institución, infraestructura, acceso a servicios, recursos tecnológicos, proporción estudiante-docente y puntajes obtenidos en áreas evaluadas. Esta etapa permite construir una visión amplia del rendimiento académico, entendiendo que este no depende solo del estudiante, sino también de las condiciones institucionales y sociales en las que aprende.

Después, los datos pasan por un proceso de limpieza y preparación. Se corrigen valores nulos, duplicados, inconsistencias institucionales y datos atípicos; además, se codifican variables categóricas, se normalizan variables numéricas y se seleccionan las características más relevantes. Esta fase es importante porque un modelo predictivo solo puede ser confiable si la información utilizada es consistente y representativa. Con ello, los autores reducen el ruido en los datos y mejoran la capacidad del sistema para encontrar patrones reales asociados al rendimiento académico.

Luego, se entrenan modelos de Machine Learning, principalmente **Random Forest** y **XGBoost**, debido a su capacidad para trabajar con relaciones complejas y datos no lineales. El conjunto de datos se divide en entrenamiento y prueba, y se aplica validación cruzada para asegurar que los resultados no dependan de una sola partición. Además, los hiperparámetros se optimizan mediante técnicas automatizadas, lo que permite mejorar el desempeño predictivo. Los resultados muestran que XGBoost alcanza el mejor rendimiento, con un **R² de 0.91** y una reducción del **15 % en el error cuadrático medio** frente a modelos base.

Sin embargo, la solución no termina con la predicción. Para resolver el problema de la falta de transparencia, los autores incorporan **SHAP**, una técnica de inteligencia artificial explicable que permite identificar qué variables influye más en cada resultado. Gracias a este análisis, el sistema muestra que factores como el nivel socioeconómico, el tipo de institución, la proporción estudiante-docente, el acceso a tecnología y el promedio académico previo explican gran parte de la variabilidad del rendimiento. Así, el modelo deja de ser una “caja negra” y se convierte en una herramienta comprensible para docentes, directivos y responsables de políticas educativas.

Finalmente, los autores integran el modelo en un sistema de apoyo a la decisión mediante un dashboard interactivo. Esta plataforma permite visualizar predicciones, analizar factores influyentes y simular escenarios de intervención, como mejorar la capacitación docente, aumentar el acceso a tecnología o reducir la proporción estudiante-docente. De esta manera, el

problema se resuelve conectando predicción, explicación y acción institucional. La propuesta permite identificar riesgos académicos, comprender sus causas y diseñar estrategias educativas más precisas, transparentes y basadas en datos.

Métricas y resultados

En el artículo, los autores evaluaron el desempeño de los modelos predictivos utilizando métricas como **R²**, **Mean Square Error (MSE)**, **precisión**, **recall** y **F1-score**. Estas métricas permitieron medir la capacidad del modelo para predecir el rendimiento académico y comprobar su estabilidad mediante validación cruzada. Además, se evaluó la eficiencia del sistema en entornos de baja y alta carga, considerando tiempos de respuesta y capacidad de integración en plataformas reales de apoyo a la decisión educativa.

Los resultados muestran que el modelo **XGBoost** obtuvo el mejor rendimiento predictivo, alcanzando un **R² de 0.91** y reduciendo el **MSE en 15 %** frente a modelos base. Asimismo, el análisis de interpretabilidad con **SHAP** permitió identificar que cinco variables explican el **72 % de la variabilidad** del rendimiento académico: nivel socioeconómico, tipo de institución, proporción estudiante-docente, acceso a recursos tecnológicos y promedio académico previo.

También se realizaron simulaciones de políticas educativas. Los resultados indicaron que mejorar la formación docente y ampliar el acceso a tecnología puede aumentar el rendimiento académico en **18 %** y reducir la deserción en **12 %**. En cuanto al rendimiento operativo, el sistema mantuvo tiempos de respuesta inferiores a **1 segundo** en baja carga y menores a **2 segundos** en alta concurrencia, con una eficiencia computacional de **92 %** en baja carga y **85 %** en alta carga. Estos resultados demuestran que el modelo no solo es preciso, sino también interpretable, escalable y útil para la toma de decisiones educativas.

Observaciones/críticas

Una observación importante sobre el artículo es que presenta un aporte sólido al combinar **predicción, interpretabilidad y apoyo a la toma de decisiones educativas**. A diferencia de investigaciones que solo buscan mejorar la precisión del modelo, este trabajo intenta que los resultados sean comprensibles y aplicables para docentes, directivos y responsables de políticas educativas. El uso de **SHAP** es una fortaleza porque permite identificar qué factores influyen en el rendimiento académico y evita que el modelo funcione únicamente como una “caja negra”.

Sin embargo, una crítica relevante es que el estudio depende de la calidad y disponibilidad de los datos utilizados. Aunque trabaja con una base amplia de registros, los propios autores reconocen que el modelo se basa principalmente en variables estructurales y contextuales, pero no incorpora con suficiente profundidad aspectos cualitativos como metodologías docentes, motivación estudiantil, clima familiar, compromiso del alumno o calidad real de la enseñanza. Estos factores también pueden influir de manera importante en el rendimiento académico.

Otra limitación es que las simulaciones de políticas educativas, aunque útiles, se desarrollan bajo supuestos controlados. Por ejemplo, mejorar el acceso a tecnología o la formación docente puede tener efectos positivos, pero en la realidad esos cambios dependen de presupuesto, implementación, capacitación, seguimiento y aceptación institucional. Por ello, los resultados deben interpretarse como escenarios estimados y no como garantías absolutas.

A pesar de estas limitaciones, el artículo es valioso porque propone un modelo escalable, explicable y orientado a la acción. Su mayor fortaleza está en demostrar que la inteligencia artificial puede apoyar la gestión educativa cuando sus predicciones son transparentes, éticas y utilizadas como complemento de la decisión humana.

34. ARTÍCULO 34

Author (s): Wei Dai; Jionghao Lin; Flora Ji-Yoon Jin; Yi-Shan Tsai; Namrata Srivastava; Pierre Le Bodic; Dragan Gašević; Guanliang Chen

Title of paper: Learning Analytics for Early Identification of At-Risk Students and Feedback Intervention

Journal: Journal of Learning Analytics

Volume (issue): Volume 12, Issue 3

pag – pag (year): pp. 102–125 (2025)

Estado del arte

La identificación temprana de estudiantes en riesgo académico se ha consolidado como una línea central dentro de la **analítica del aprendizaje**, especialmente en educación superior. El aumento de estudiantes universitarios, junto con la expansión de plataformas digitales como Moodle, Ed u otros sistemas de gestión del aprendizaje, ha permitido recopilar grandes cantidades de datos sobre la actividad académica de los alumnos. Estos datos incluyen accesos a materiales, participación en foros, entrega de tareas, revisión de calificaciones, tiempo de conexión, regularidad de estudio y desempeño en evaluaciones. A partir de esta información, los investigadores han desarrollado modelos predictivos orientados a identificar, desde las primeras semanas del curso, a estudiantes con alta probabilidad de desaprobación o abandonar una asignatura.

La literatura muestra que muchos estudios han centrado sus esfuerzos en mejorar la precisión de los modelos de predicción. Para ello, se han utilizado técnicas como regresión logística, árboles de decisión, random forest, gradient boosting, redes neuronales y otros algoritmos de machine learning. Estos modelos suelen formular el problema como una tarea de clasificación, diferenciando entre estudiantes que probablemente aprobarán y estudiantes en riesgo de fallar el curso. Entre los indicadores más utilizados se encuentran las características demográficas, como edad o género, y principalmente los indicadores de compromiso académico, como frecuencia de acceso, participación en actividades, entrega de trabajos y uso de recursos de aprendizaje. Diversas investigaciones han señalado que los datos de participación y comportamiento en plataformas virtuales suelen ser predictores relevantes del rendimiento académico.

Sin embargo, un punto crítico en el estado del arte es que la predicción por sí sola no garantiza una mejora en el aprendizaje. Identificar estudiantes en riesgo puede ser útil, pero si esta información no se acompaña de intervenciones oportunas, el impacto educativo es limitado. Por ello, algunos estudios han propuesto sistemas de alerta temprana, llamadas telefónicas, reuniones con docentes, talleres de apoyo o mensajes automatizados. No obstante, muchas de estas intervenciones presentan dificultades: algunas requieren mucho tiempo del profesorado, otras son difíciles de escalar y otras no se diseñan con fundamentos sólidos sobre cómo debe ser una retroalimentación efectiva. Esta situación evidencia una brecha importante entre la capacidad técnica para predecir el riesgo y la capacidad pedagógica para intervenir adecuadamente.

En este contexto, el artículo analizado aporta una perspectiva relevante porque combina dos elementos: modelos predictivos de analítica del aprendizaje e intervención mediante retroalimentación. Los autores señalan que gran parte de la investigación previa se ha concentrado en desarrollar modelos avanzados de machine learning, pero ha prestado menor atención al diseño de intervenciones oportunas y pedagógicamente fundamentadas. Además, cuando se han usado mensajes o correos para apoyar a estudiantes en riesgo, pocas investigaciones los han diseñado a partir de teorías consolidadas de retroalimentación efectiva. Por ello, este estudio propone enviar correos de intervención diseñados por expertos en

feedback, basados en un marco de **retroalimentación relacional**, cuyo objetivo es fortalecer la relación entre estudiante, docente y comunidad de aprendizaje.

Otro aspecto importante del estado del arte es la generalización de los modelos predictivos. Muchos modelos funcionan bien cuando se entrenan y prueban dentro del mismo curso o semestre, pero pueden perder precisión al aplicarse a nuevas cohortes de estudiantes. Esto ocurre por cambios en el comportamiento estudiantil, modificaciones en el diseño del curso, diferencias demográficas o variaciones en la relación entre participación y rendimiento académico. El artículo aborda este problema al entrenar modelos con datos de una oferta previa del curso y aplicarlos en una cohorte posterior, evaluando si el modelo mantiene un desempeño aceptable. Este enfoque es importante porque los sistemas de alerta temprana reales necesitan funcionar en contextos cambiantes, no solo en condiciones controladas.

El estudio se sitúa también en una tendencia más amplia: pasar de la analítica descriptiva y predictiva hacia una analítica orientada a la acción. En otras palabras, no basta con saber quién está en riesgo; es necesario proporcionar información clara, accionable y motivadora que ayude al estudiante a modificar su comportamiento. La retroalimentación relacional utilizada en el artículo busca justamente eso: aclarar el desempeño del estudiante, ofrecer acciones concretas para mejorar, invitar a la comunicación con docentes y compañeros, y generar emociones positivas que favorezcan la recepción del mensaje.

En síntesis, el estado del arte evidencia que la identificación temprana de estudiantes en riesgo ha avanzado considerablemente gracias a los modelos de machine learning y al uso de datos de plataformas educativas. No obstante, persisten desafíos relacionados con la generalización de los modelos, la escalabilidad de las intervenciones y el diseño pedagógico de la retroalimentación. El artículo contribuye a esta línea al integrar predicción temprana, evaluación de generalización entre cohortes y una intervención basada en feedback relacional, mostrando una propuesta más completa para apoyar a estudiantes en riesgo desde las primeras etapas del curso.

Motivación del autor

La motivación principal de los autores surge de una limitación frecuente en la analítica del aprendizaje: muchos estudios se concentran en construir modelos predictivos cada vez más precisos para identificar estudiantes en riesgo, pero no siempre acompañan esa predicción con intervenciones oportunas que realmente ayuden a mejorar el aprendizaje. Para los autores, detectar a un estudiante con probabilidad de desaprobación no es suficiente si la institución no ofrece una acción concreta, clara y útil que lo motive a retomar su participación en las actividades del curso. Por ello, el estudio busca unir la predicción temprana con una intervención pedagógica basada en retroalimentación efectiva.

Además, los autores se motivan por mejorar la forma en que se diseñan los mensajes de apoyo enviados a los estudiantes. Señalan que pocas investigaciones han elaborado este tipo de retroalimentación con base en teorías consolidadas. Por esta razón, proponen correos de intervención diseñados bajo un enfoque de **retroalimentación relacional**, cuyo propósito es aclarar el desempeño del estudiante, ofrecer acciones concretas de mejora, promover la comunicación con docentes y compañeros, y generar una sensación de apoyo. Su motivación final es desarrollar una estrategia escalable, humana y pedagógicamente fundamentada para identificar estudiantes en riesgo desde las primeras semanas y estimular su compromiso con las actividades de aprendizaje.

Descripción del aporte del autor

El principal aporte de los autores consiste en integrar la **analítica predictiva del aprendizaje** con una **intervención temprana basada en retroalimentación relacional**, con el propósito de

apoyar a estudiantes universitarios en riesgo académico desde las primeras semanas del curso. A diferencia de muchos estudios que se enfocan únicamente en construir modelos de machine learning para predecir el bajo rendimiento, este artículo propone una estrategia más completa: primero identifica a los estudiantes con probabilidad de desaprobación y luego les envía una intervención diseñada pedagógicamente para motivar su participación en las actividades de aprendizaje. De esta manera, el aporte no se limita a la predicción, sino que avanza hacia una analítica del aprendizaje orientada a la acción educativa.

Uno de los aportes más importantes del artículo es demostrar que los modelos predictivos pueden utilizarse en un contexto real de enseñanza para identificar estudiantes en riesgo en momentos tempranos del semestre. Los autores trabajaron con un curso universitario de algoritmos y programación, una asignatura fundamental dentro de la formación en tecnología. Este tipo de cursos suele ser decisivo, porque si los estudiantes no logran dominar los contenidos iniciales, pueden tener dificultades en asignaturas posteriores y aumentar su riesgo de fracaso académico o abandono. Por ello, identificar oportunamente a quienes presentan bajo compromiso o baja probabilidad de aprobación resulta fundamental para ofrecer apoyo antes de que el problema sea irreversible.

El estudio aporta una metodología clara para construir y aplicar modelos predictivos entre cohortes. Los autores utilizaron datos históricos de una oferta previa del curso, correspondiente al primer semestre de 2022, para entrenar modelos de machine learning. Luego aplicaron estos modelos en una nueva cohorte del mismo curso, correspondiente al primer semestre de 2023. Esta decisión es relevante porque permite evaluar la **generalización del modelo**, es decir, su capacidad para funcionar con estudiantes distintos a aquellos con los que fue entrenado. En contextos educativos reales, las cohortes cambian cada semestre; por tanto, un modelo útil no debe funcionar únicamente con datos pasados, sino mantener un desempeño aceptable cuando se aplica a nuevos grupos de estudiantes.

Otro aporte metodológico importante es la comparación entre distintos algoritmos de predicción. Los autores evaluaron modelos como **regresión logística**, **random forest** y **gradient boosting tree**, técnicas ampliamente utilizadas en la analítica del aprendizaje para tareas de clasificación. Después de comparar su desempeño, eligieron el modelo **random forest**, debido a que obtuvo mejores resultados promedio en términos de AUC. Esta selección permitió construir dos modelos predictivos: uno entrenado con datos desde la semana 0 hasta la semana 4, aplicado en la semana 5; y otro entrenado con datos desde la semana 0 hasta la semana 7, aplicado en la semana 8. Esta organización evidencia un aporte práctico, ya que permite intervenir en dos momentos estratégicos del curso: antes del primer periodo de evaluación y después del avance inicial del semestre.

El artículo también aporta una selección amplia y organizada de variables predictivas. Los autores utilizaron datos de interacción registrados en plataformas educativas como Ed y Moodle, además de información demográfica y académica previa. Entre las variables consideradas se encuentran indicadores generales de compromiso, como número de sesiones, duración total de sesiones, proporción de días activos y semanas activas; indicadores específicos de acciones, como participación en foros, consumo de contenidos, revisión de reportes de calificaciones, visitas a la página principal del curso, uso de materiales y actividades relacionadas con tareas; así como indicadores de regularidad del aprendizaje. Esta riqueza de variables permite representar no solo cuánto interactúa el estudiante con la plataforma, sino también cómo, cuándo y con qué regularidad lo hace.

Un aporte relevante del estudio es mostrar que los indicadores de compromiso académico son más importantes que las variables demográficas para predecir el riesgo académico. Mediante el análisis de importancia de características, los autores encontraron que las variables más influyentes estaban relacionadas con la participación del estudiante en la plataforma de aprendizaje, como la duración de las sesiones, la proporción de días activos y la interacción con

materiales. Este hallazgo tiene un valor pedagógico importante, porque sugiere que el bajo rendimiento no debe interpretarse solamente desde características personales del estudiante, sino también desde su comportamiento de aprendizaje. En otras palabras, el riesgo académico puede detectarse observando señales tempranas de desconexión o baja participación.

Sin embargo, el aporte más distintivo del artículo se encuentra en la intervención mediante **correos de retroalimentación relacional**. Los autores reconocen que predecir quién está en riesgo no basta para mejorar el aprendizaje. Por eso diseñaron mensajes de intervención dirigidos a los estudiantes identificados como en riesgo de desaprobación. Estos correos no fueron redactados de manera improvisada ni como simples advertencias, sino que fueron elaborados por expertos en retroalimentación a partir de un marco teórico de feedback relacional. Este enfoque busca fortalecer la relación entre el estudiante, el docente y la comunidad de aprendizaje, aumentando la probabilidad de que el estudiante acepte, valore y utilice la retroalimentación recibida.

La retroalimentación enviada a los estudiantes incluye cuatro principios centrales. Primero, **aclara el desempeño del estudiante**, mostrando información concreta sobre su participación en línea, como el tiempo promedio dedicado al curso y la cantidad de actividades visitadas. Segundo, ofrece **información accionable**, indicando qué actividades faltan por completar y recordando fechas importantes, como entregas de tareas. Tercero, promueve la **comunicación con la comunidad de aprendizaje**, invitando al estudiante a participar en foros, compartir dudas y comunicarse con el equipo docente. Cuarto, busca generar **emociones positivas**, utilizando un tono respetuoso, cercano y de apoyo, en lugar de un mensaje sancionador o amenazante. Este diseño constituye un aporte pedagógico importante porque convierte la alerta temprana en una oportunidad de orientación y acompañamiento.

Otro aporte significativo es que la intervención es **escalable**. En educación superior, donde los cursos pueden tener cientos o miles de estudiantes, no siempre es viable realizar reuniones individuales con todos los alumnos en riesgo. Los correos electrónicos, en cambio, permiten llegar rápidamente a muchos estudiantes con bajo costo y poca carga adicional para el profesorado. No obstante, el artículo muestra que la escalabilidad no debe implicar despersonalización. Los mensajes pueden incluir datos específicos del estudiante, como su nivel de participación y actividades pendientes, manteniendo un enfoque personalizado y útil.

El estudio también aporta evidencia sobre el impacto de la intervención en el compromiso estudiantil. Después de enviar los correos, los autores analizaron si los estudiantes identificados como en riesgo visitaban actividades que antes no habían revisado. Los resultados muestran que más del 30% de los estudiantes en riesgo identificados visitaron actividades previamente no realizadas dentro de las dos semanas posteriores a la intervención. Este resultado es relevante porque indica que la retroalimentación no solo fue recibida, sino que en varios casos estuvo asociada con cambios concretos en el comportamiento de aprendizaje.

Además, el artículo aporta una evaluación de las percepciones estudiantiles sobre la intervención. Aunque la tasa de respuesta fue limitada, los estudiantes que respondieron mostraron una satisfacción general con los correos recibidos. También se encontró que una parte importante de ellos prefería recibir este tipo de intervención con mayor frecuencia que dos veces por semestre. Esto sugiere que algunos estudiantes valoran el apoyo temprano y podrían beneficiarse de sistemas más flexibles, donde puedan elegir cuándo y con qué frecuencia recibir retroalimentación. Este punto es importante porque la intervención no debe imponerse de manera rígida, sino adaptarse a las preferencias y necesidades de los estudiantes.

Desde el punto de vista de la investigación en analítica del aprendizaje, el artículo aporta al debate sobre la **generalización de modelos predictivos**. Los resultados muestran que los modelos entrenados y probados dentro del mismo semestre alcanzaron mejores métricas que los modelos entrenados en un semestre y aplicados en otro. Sin embargo, los modelos

transferidos a la nueva cohorte mantuvieron un desempeño aceptable, con valores de AUC superiores a 0.7. Esto evidencia que los modelos pueden ser útiles para nuevas cohortes, aunque también deben actualizarse regularmente para mantener su precisión. Este hallazgo es importante porque confirma que los cambios entre cohortes, conocidos como drift o cambio en los datos, pueden afectar el rendimiento predictivo.

Otro aporte del artículo es su enfoque ético y responsable. Los autores trabajaron con datos de plataformas educativas y respetaron procedimientos de consentimiento, anonimización y protección de información. Este punto es fundamental porque la analítica del aprendizaje utiliza datos sensibles sobre el comportamiento académico de los estudiantes. Por ello, el uso de estos modelos debe realizarse con transparencia, cuidado y finalidad pedagógica. El artículo muestra que la predicción debe estar al servicio del apoyo estudiantil, no de la vigilancia o sanción.

En conclusión, el aporte de los autores se resume en la construcción de una estrategia integral para apoyar a estudiantes en riesgo académico. Esta estrategia combina modelos predictivos tempranos, evaluación de generalización entre cohortes, análisis de variables de compromiso y una intervención basada en retroalimentación relacional. Su valor principal está en demostrar que la analítica del aprendizaje puede ser más efectiva cuando no se queda en la predicción, sino que se conecta con acciones humanas, oportunas y pedagógicamente fundamentadas. De esta manera, el artículo contribuye a una educación superior más preventiva, personalizada y centrada en el acompañamiento del estudiante.

Proceso para obtener el aporte

Para obtener su aporte, los autores desarrollaron un proceso metodológico dividido en dos grandes etapas: **entrenamiento del modelo predictivo e implementación de la intervención con retroalimentación**. El estudio se realizó en un curso universitario de algoritmos y programación, utilizando datos de dos semestres consecutivos. En la primera etapa, correspondiente al primer semestre de 2022, los autores utilizaron los datos históricos de los estudiantes para construir modelos capaces de predecir qué alumnos estarían en riesgo de desaprobación. En la segunda etapa, correspondiente al primer semestre de 2023, aplicaron esos modelos a una nueva cohorte para identificar estudiantes en riesgo y enviarles correos de retroalimentación diseñados para mejorar su compromiso con las actividades del curso.

El primer paso del proceso fue la **recolección de datos** desde las plataformas educativas usadas en el curso, principalmente **Ed** y **Moodle**. Estas plataformas registraban información sobre las acciones de los estudiantes, como visitas a materiales de aprendizaje, participación en foros, revisión de calificaciones, acceso a la página principal del curso, actividades relacionadas con tareas y uso general de los recursos virtuales. Además, los autores incorporaron información demográfica y académica previa, como edad, género, tipo de grado, ciudadanía, años desde el inicio de la carrera y calificaciones obtenidas en cursos anteriores. Con ello, buscaron construir una representación amplia del comportamiento y perfil académico de cada estudiante.

El segundo paso fue la **ingeniería de características**. Los autores organizaron las variables en grupos relacionados con el compromiso estudiantil. Consideraron indicadores generales, como número de sesiones, duración total de las sesiones, proporción de días activos y semanas activas; indicadores específicos de acciones, como participación en foros, consumo de materiales, revisión de reportes de notas y actividades de asignaciones; e indicadores de regularidad, que permitían analizar si el estudiante mantenía una participación constante o irregular. Este paso fue fundamental porque permitió transformar los registros de actividad en variables útiles para los modelos de machine learning.

El tercer paso consistió en **construir y comparar modelos predictivos**. Los autores probaron tres algoritmos: **regresión logística**, **random forest** y **gradient boosting tree**. Estos modelos fueron evaluados semanalmente desde la semana 0 hasta la semana 7 del semestre fuente,

utilizando el AUC como métrica principal. Después de la comparación, seleccionaron **random forest**, ya que mostró el mejor desempeño promedio. Con este algoritmo construyeron dos modelos: el primero entrenado con datos de la semana 0 a la semana 4, para identificar estudiantes en riesgo en la semana 5; y el segundo entrenado con datos de la semana 0 a la semana 7, para identificar estudiantes en riesgo en la semana 8.

El cuarto paso fue aplicar los modelos a la nueva cohorte del semestre 2023. Los estudiantes cuya predicción indicaba una calificación final menor al 50% fueron considerados **estudiantes en riesgo**. Una vez identificados, los autores enviaron correos de intervención inmediatamente después de la predicción. Estos correos no fueron simples advertencias, sino mensajes diseñados bajo el enfoque de **retroalimentación relacional**. Incluían información sobre el nivel de participación del estudiante, actividades pendientes, recordatorios de tareas, invitación a comunicarse con docentes y compañeros, y un tono positivo orientado a generar apoyo y confianza.

Finalmente, los autores evaluaron el aporte desde tres dimensiones. Primero, analizaron la **generalización del modelo**, comparando su rendimiento cuando era entrenado y probado en el mismo semestre frente a cuando era aplicado a una nueva cohorte. Segundo, midieron el **cambio en el compromiso estudiantil**, observando si los estudiantes en riesgo visitaban actividades que antes no habían revisado después de recibir la retroalimentación. Tercero, aplicaron una **encuesta de percepción** para conocer cómo valoraban los estudiantes los correos recibidos. De esta manera, el aporte se obtuvo mediante un proceso integral que unió predicción temprana, diseño pedagógico de retroalimentación y evaluación del comportamiento posterior de los estudiantes.

Proceso para resolver el problema

Para resolver el problema de la identificación y apoyo oportuno a estudiantes en riesgo académico, los autores propusieron una estrategia que combina **modelos predictivos de analítica del aprendizaje** con una **intervención temprana mediante retroalimentación relacional**. El problema central era que muchos estudiantes pueden desaprobado o abandonar un curso si no reciben apoyo a tiempo, pero los métodos tradicionales para detectarlos suelen ser lentos, manuales y difíciles de aplicar en cursos con muchos alumnos. Además, la predicción por sí sola no mejora el aprendizaje si no se acompaña de una acción pedagógica concreta.

El primer paso fue utilizar datos históricos del curso para construir modelos capaces de identificar estudiantes en riesgo. Los autores recolectaron información de plataformas como Ed y Moodle, incluyendo visitas a materiales, participación en foros, revisión de calificaciones, acceso a actividades, duración de sesiones, días activos y regularidad de uso. También incorporaron datos demográficos y académicos previos. Con esta información entrenaron distintos modelos de machine learning, como regresión logística, random forest y gradient boosting tree, seleccionando finalmente **random forest** por su mejor desempeño predictivo.

Luego, aplicaron los modelos en una nueva cohorte del mismo curso. El primer modelo utilizó datos de las semanas 0 a 4 para identificar estudiantes en riesgo en la semana 5, y el segundo utilizó datos de las semanas 0 a 7 para identificar nuevos casos en la semana 8. Los estudiantes cuya predicción indicaba una nota final menor al 50% fueron clasificados como estudiantes en riesgo. Esta identificación temprana permitió actuar antes de que terminara el curso, cuando aún era posible modificar hábitos de estudio y aumentar la participación en las actividades.

El tercer paso fue enviar una intervención por correo electrónico a los estudiantes identificados. Estos mensajes fueron diseñados con base en la **retroalimentación relacional**, por lo que no se limitaron a advertir sobre el riesgo, sino que ofrecieron información clara, acciones concretas y apoyo emocional. Los correos indicaban cuánto tiempo había dedicado el estudiante al curso, qué actividades no había visitado, qué tareas debía completar y cómo podía comunicarse con

docentes o compañeros. Además, el tono del mensaje fue positivo y respetuoso, buscando motivar al estudiante en lugar de generar ansiedad.

Finalmente, los autores evaluaron si la solución funcionaba. Analizaron la generalización del modelo entre semestres, los cambios en la participación de los estudiantes después de recibir el correo y las percepciones de los estudiantes sobre la intervención. Así, el problema se resolvió mediante un proceso integral: detectar tempranamente el riesgo académico, entregar retroalimentación útil y motivadora, y medir si los estudiantes aumentaban su compromiso con las actividades del curso.

Métricas y resultados

Para evaluar el estudio, los autores utilizaron métricas tanto del **modelo predictivo** como de la **intervención de retroalimentación**. En la predicción de estudiantes en riesgo, emplearon **accuracy**, **macro F1-score**, **AUC**, **NPV** y **TNR**. El AUC fue una métrica clave para medir la capacidad del modelo de distinguir entre estudiantes en riesgo y no en riesgo. Los modelos entrenados y probados dentro del mismo semestre obtuvieron mejores resultados, con AUC de **0.98** en los datos de semanas 0 a 4 y también **0.98** en semanas 0 a 7. Cuando el modelo fue entrenado con datos del semestre 2022 y aplicado al semestre 2023, el rendimiento disminuyó, pero siguió siendo aceptable, con AUC de **0.72** para semanas 0 a 4 y **0.78** para semanas 0 a 7. Esto demuestra que el modelo tiene capacidad de generalización, aunque su precisión mejora cuando se actualiza con datos de la cohorte actual.

Respecto a la intervención, en la semana 5 se identificaron **239 estudiantes en riesgo**. Antes del correo de retroalimentación, estos estudiantes habían visitado en promedio **2.69 actividades** de 19 requeridas. Una semana después, el promedio aumentó a **3.66**, y dos semanas después subió a **3.92**. Además, **58 estudiantes** visitaron al menos una actividad no revisada una semana después de la intervención, y **76 estudiantes**, equivalentes al **31.80%**, lo hicieron dentro de las dos semanas posteriores. En la encuesta, aunque respondió solo el **9.27%** de los estudiantes en riesgo, los participantes manifestaron satisfacción general con la retroalimentación, y el **60%** indicó que preferiría recibir este tipo de intervención con mayor frecuencia que dos veces por semestre.

Observaciones/críticas

Una observación positiva del artículo es que presenta una propuesta más completa que muchos estudios tradicionales de analítica del aprendizaje, porque no se limita a predecir qué estudiantes están en riesgo, sino que también implementa una intervención concreta mediante correos de retroalimentación relacional. Esto es valioso porque la predicción, por sí sola, no mejora el aprendizaje si no se transforma en acciones pedagógicas oportunas. Además, el diseño de los mensajes se basa en principios de retroalimentación efectiva, incluyendo información clara sobre el desempeño del estudiante, actividades pendientes, invitación a comunicarse con docentes y compañeros, y un tono positivo de apoyo.

Sin embargo, también existen algunas limitaciones. Primero, el modelo perdió precisión al aplicarse a una cohorte distinta, lo que demuestra que los sistemas predictivos deben actualizarse con frecuencia para evitar problemas de generalización. Segundo, aunque hubo mejora en el compromiso de algunos estudiantes, solo alrededor de un tercio de los estudiantes en riesgo visitó actividades previamente no revisadas después de la intervención, por lo que el impacto no fue igual para todos. Además, la encuesta tuvo una tasa de respuesta baja, de **9.27%**, lo cual limita la interpretación de las percepciones estudiantiles. A pesar de estas críticas, el estudio es importante porque demuestra que la analítica del aprendizaje debe combinar predicción temprana, retroalimentación bien diseñada y seguimiento del comportamiento estudiantil para generar un verdadero apoyo educativo.

Author (s): Mohd Fazil; Angélica Rísquez; Claire Halpin.

Title of paper: *A Novel Deep Learning Model for Student Performance Prediction Using Engagement Data.*

Journal: *Journal of Learning Analytics.*

Volume (issue): 11(2).

pag – pag (year): 23–41 (2024).

Estado del arte

El estudio sobre la **predicción del rendimiento académico mediante datos de interacción en entornos virtuales de aprendizaje** se ha fortalecido en los últimos años debido al uso creciente de plataformas digitales en la educación superior. Los **Virtual Learning Environments (VLE)** registran una gran cantidad de información sobre las actividades de los estudiantes, como accesos a materiales, participación en foros, envío de tareas, consultas de recursos, evaluaciones y frecuencia de interacción. Estos datos permiten analizar el comportamiento del estudiante durante el proceso de aprendizaje y relacionarlo con su desempeño académico final.

Dentro de este campo, la **Learning Analytics** y la **Educational Data Mining** han permitido desarrollar modelos capaces de identificar estudiantes en riesgo, predecir abandono, reconocer patrones de participación y apoyar la toma de decisiones pedagógicas. Según el artículo revisado, la analítica del aprendizaje consiste en recolectar, analizar y examinar información estudiantil para comprender el entorno de aprendizaje y optimizarlo. Sin embargo, uno de los principales retos consiste en desarrollar métodos robustos, sostenibles y útiles para que los datos no se utilicen únicamente como vigilancia institucional, sino como un medio para apoyar a los estudiantes, especialmente a los más vulnerables.

El estado actual de la investigación muestra dos grandes enfoques en la predicción del rendimiento académico. El primero corresponde a los modelos clásicos de **Machine Learning**, que utilizan características diseñadas manualmente a partir de datos académicos, demográficos o de interacción. Entre estos modelos se encuentran árboles de decisión, máquinas de soporte vectorial, Random Forest, XGBoost y redes neuronales simples. Aunque estos métodos han mostrado resultados interesantes, presentan una limitación importante: la creación manual de características puede ser lenta, específica del dominio y difícil de escalar en grandes volúmenes de datos educativos.

El segundo enfoque corresponde a los modelos de **Deep Learning**, que buscan aprender representaciones de los estudiantes de manera más automática a partir de datos complejos. Estos modelos incluyen redes neuronales artificiales, redes recurrentes, LSTM, BiLSTM, redes convolucionales y mecanismos de atención. En comparación con los modelos clásicos, el aprendizaje profundo puede capturar patrones temporales y secuenciales más complejos, especialmente cuando se trabaja con registros de interacción generados semana a semana en plataformas virtuales. No obstante, muchos modelos previos de Deep Learning aplicados a Learning Analytics han sido relativamente simples y no han integrado de manera suficiente componentes avanzados como mecanismos de atención o procesamiento separado de diferentes dimensiones del comportamiento estudiantil.

El artículo de Fazil, Rísquez y Halpin se ubica precisamente en esta brecha de investigación. Los autores proponen un modelo denominado **ASIST**, que significa *Attention-aware convolutional Stacked BiLSTM*, diseñado para predecir el rendimiento de los estudiantes utilizando datos de compromiso e interacción con el VLE. A diferencia de enfoques previos que modelan toda la información como una sola secuencia, ASIST procesa distintas dimensiones del comportamiento estudiantil por separado: información demográfica y académica, interacción semanal, eventos semanales, eventos acumulados, interacción diaria

semanal y evaluaciones continuas. Esta arquitectura permite captar patrones más finos y variados del comportamiento del estudiante.

Otro aspecto importante del estado del arte es la necesidad de **predicción temprana**. En educación, predecir el rendimiento al final del semestre puede tener valor académico, pero resulta poco útil si ya no existe tiempo para intervenir. Por ello, la literatura reciente destaca la importancia de modelos capaces de identificar estudiantes en riesgo durante las primeras semanas del curso. El artículo responde a esta necesidad mediante una versión llamada **ASISTearly**, que utiliza únicamente las primeras siete semanas de datos de interacción y aun así mantiene un rendimiento competitivo. Esto permite que los docentes puedan implementar intervenciones tempranas para apoyar a estudiantes en riesgo antes de que el bajo desempeño sea irreversible.

El artículo también aporta al analizar distintos tipos de comportamiento en el VLE. Los autores muestran que los estudiantes de alto rendimiento suelen interactuar con mayor frecuencia en la plataforma, realizan más eventos semanales y presentan patrones de participación más consistentes que los estudiantes en riesgo. Además, el análisis de ablación evidencia que el conteo semanal de eventos tiene el mayor impacto en el desempeño del modelo, mientras que la interacción diurna semanal tiene menor influencia. Esto confirma que no solo importa cuántas veces entra un estudiante al sistema, sino también qué actividades realiza dentro de él.

En síntesis, el estado del arte muestra que la predicción del rendimiento académico ha evolucionado desde modelos clásicos basados en características manuales hacia arquitecturas profundas capaces de aprender representaciones más complejas del comportamiento estudiantil. El artículo revisado aporta a esta evolución al proponer un modelo avanzado que combina BiLSTM, CNN y atención para analizar datos de interacción en VLE. Su principal valor está en demostrar que los datos de compromiso digital pueden utilizarse para predecir estudiantes de alto rendimiento, rendimiento moderado y en riesgo, así como para apoyar estrategias de intervención temprana en la educación superior.

Motivación del autor

La motivación principal de los autores surge de la necesidad de mejorar la predicción del rendimiento académico utilizando los datos que generan los estudiantes en los **entornos virtuales de aprendizaje**. Las plataformas VLE registran múltiples huellas digitales del proceso educativo, como accesos, eventos, frecuencia de interacción, uso de recursos y participación en actividades. Sin embargo, muchos estudios previos no aprovechan completamente esta riqueza de información, ya que suelen utilizar modelos estadísticos, algoritmos clásicos de Machine Learning o redes neuronales simples que no capturan adecuadamente la complejidad del comportamiento estudiantil.

Asimismo, los autores se motivan por superar las limitaciones de los modelos existentes, especialmente aquellos que dependen de características diseñadas manualmente o que procesan toda la información como una sola secuencia. Según el artículo, esto puede reducir la capacidad del modelo para identificar patrones específicos de interacción, como el comportamiento semanal, los eventos realizados, la participación acumulada y la regularidad diaria dentro del semestre. Por ello, los autores proponen un modelo más avanzado, llamado **ASIST**, que combina BiLSTM, CNN y mecanismos de atención para representar mejor el comportamiento académico y digital del estudiante.

Finalmente, otra motivación importante es la necesidad de realizar **predicciones tempranas** que permitan intervenir a tiempo. No basta con saber al final del curso quién tendrá bajo rendimiento; lo valioso es identificar a los estudiantes en riesgo durante las primeras semanas para brindar apoyo oportuno. Por esta razón, los autores extienden su modelo a **ASISTearly**,

capaz de predecir el desempeño usando solo las primeras siete semanas de datos, con el propósito de orientar intervenciones pedagógicas y promover el éxito estudiantil.

Descripción del aporte del autor

El aporte principal de Mohd Fazil, Angélica Rísquez y Claire Halpin en el artículo “**A Novel Deep Learning Model for Student Performance Prediction Using Engagement Data**” consiste en proponer un modelo avanzado de **Deep Learning** para predecir el rendimiento académico de los estudiantes a partir de datos de compromiso e interacción en un entorno virtual de aprendizaje. El modelo recibe el nombre de **ASIST**, que significa *Attention-aware convolutional Stacked BiLSTM*, y fue diseñado para clasificar a los estudiantes en tres categorías: estudiantes de alto rendimiento, estudiantes de rendimiento moderado y estudiantes en riesgo académico. Este aporte es relevante porque responde a una necesidad actual de las instituciones de educación superior: identificar tempranamente a los estudiantes que podrían tener dificultades y utilizar los datos educativos para ofrecer apoyo oportuno.

Uno de los aportes más importantes del artículo es que los autores aprovechan la gran cantidad de información generada por los **Virtual Learning Environments (VLE)**. Estas plataformas registran las acciones de los estudiantes durante el curso, como accesos, consultas de materiales, participación en actividades, eventos realizados, envíos de tareas y uso de recursos académicos. En lugar de utilizar estos datos únicamente como registros administrativos, los autores los transforman en insumos para comprender el comportamiento de aprendizaje y predecir el desempeño final. De esta manera, el estudio aporta al campo de **Learning Analytics** porque demuestra cómo los datos digitales pueden convertirse en información útil para la toma de decisiones pedagógicas.

El artículo también aporta al superar una limitación frecuente de los estudios previos: muchos modelos predictivos tratan toda la información del estudiante como una sola secuencia o dependen de características diseñadas manualmente. Esta forma de trabajo puede ser limitada porque no distingue adecuadamente las diferentes dimensiones del comportamiento estudiantil. En cambio, **ASIST** modela por separado varios tipos de información: datos demográficos y académicos, interacción semanal con el VLE, eventos semanales, eventos acumulados, interacción diurna semanal y resultados de evaluación continua. Esta separación permite que el modelo identifique patrones más específicos y finos del comportamiento de los estudiantes.

Otro aporte relevante es la arquitectura del modelo. **ASIST** combina diferentes componentes de Deep Learning, como **BiLSTM**, **CNN** y mecanismos de **atención**. Las redes **BiLSTM** permiten analizar información secuencial considerando tanto el contexto anterior como el posterior dentro de una serie temporal. Esto es útil porque el comportamiento de un estudiante no debe analizarse de forma aislada, sino como una evolución a lo largo de las semanas del semestre. Por otro lado, las redes convolucionales permiten analizar patrones espaciales o estructurados, como la interacción diurna semanal organizada por días y semanas. Finalmente, el mecanismo de atención permite asignar mayor peso a las características más importantes para la predicción.

El uso del mecanismo de atención constituye un aporte importante porque permite que el modelo no trate todas las variables con la misma relevancia. En el comportamiento estudiantil, algunas acciones pueden ser más significativas que otras. Por ejemplo, no tiene el mismo peso iniciar sesión una vez en la plataforma que entregar una evaluación, consultar materiales clave o realizar actividades académicas de manera constante. Por ello, el mecanismo de atención ayuda a resaltar las características más influyentes, mejorando la capacidad del modelo para aprender representaciones más útiles del estudiante.

Desde el punto de vista metodológico, los autores aportan una evaluación rigurosa del modelo en un contexto real. El estudio utilizó datos de la **University of Limerick**, en Irlanda, correspondientes a tres módulos grandes de primer año: química, gestión y economía. Los datos

abarcaron cuatro años académicos, desde 2018/19 hasta 2021/22. En total, el conjunto de datos incluyó 1 557 estudiantes en el módulo 1, 2 078 estudiantes en el módulo 2 y 2 433 estudiantes en el módulo 3. Esta amplitud fortalece el aporte del estudio porque permite evaluar el modelo en distintos cursos y cohortes.

Otro aporte significativo es la transformación de las calificaciones universitarias en categorías comprensibles para la predicción. Los autores agruparon las calificaciones originales en tres clases: **High-performer**, **Moderate-performer** y **At-risk**. Esta clasificación resulta útil desde una perspectiva educativa porque permite identificar no solo a quienes tienen bajo rendimiento, sino también distinguir entre estudiantes de desempeño medio y alto. De esta manera, el modelo no se limita a una predicción binaria de aprobar o desaprobado, sino que ofrece una clasificación más amplia del rendimiento académico.

El artículo también aporta al analizar diferentes dimensiones del comportamiento en el VLE. Los autores consideran, por ejemplo, la **interacción semanal**, que mide la frecuencia con que los estudiantes acceden a la plataforma; el **comportamiento semanal de eventos**, que registra la cantidad de actividades realizadas; el **conteo acumulado de eventos**, que permite observar qué tipos de acciones son más frecuentes; y la **interacción diurna semanal**, que organiza la actividad según días y semanas. Esta forma de modelar los datos permite comprender mejor cómo se diferencian los estudiantes de alto rendimiento, moderados y en riesgo.

Un hallazgo importante es que los estudiantes de alto rendimiento suelen interactuar más con la plataforma y realizar más eventos semanales que los estudiantes en riesgo. Esto indica que el compromiso digital puede ser un indicador relevante del rendimiento académico. Sin embargo, el aporte del artículo no consiste simplemente en afirmar que más interacción significa mejor rendimiento, sino en demostrar que distintos patrones de interacción pueden ser procesados por un modelo profundo para mejorar la predicción de desempeño.

Otro aporte central es la comparación de ASIST con diversos modelos de referencia. Los autores evaluaron su propuesta frente a modelos de Deep Learning y modelos clásicos de Machine Learning, como ANN, árbol de decisión, Random Forest, XGBoost y SVM. Los resultados muestran que ASIST supera a la mayoría de los modelos comparados, especialmente en la métrica **AUC**, que es importante cuando los datos están desbalanceados. El modelo alcanzó valores de AUC entre **0.86 y 0.90** en los tres conjuntos de datos, lo que demuestra una buena capacidad para distinguir entre las categorías de rendimiento estudiantil.

Asimismo, los autores aportan mediante un análisis de ablación, el cual permite identificar qué componentes del comportamiento estudiantil influyen más en el rendimiento del modelo. Este análisis mostró que el **conteo semanal de eventos** fue el componente con mayor impacto en ASIST, mientras que la interacción diurna semanal tuvo menor influencia. Este aporte es importante porque ayuda a comprender qué tipo de datos del VLE resultan más útiles para predecir el rendimiento académico. En otras palabras, no solo se evalúa si el modelo funciona, sino también qué información aporta más valor predictivo.

El aporte práctico más relevante del artículo es la creación de una versión para predicción temprana llamada **ASISTearly**. Esta versión utiliza únicamente las primeras siete semanas de datos de interacción, con el objetivo de identificar a los estudiantes en riesgo antes de que termine el semestre. Esto tiene una gran utilidad educativa, porque permite que docentes e instituciones actúen durante el periodo en que todavía es posible intervenir. Según los resultados, ASISTearly mantiene un rendimiento competitivo, con valores de AUC entre **0.83 y 0.89**, lo que demuestra que es posible realizar predicciones útiles con información parcial del curso.

Este aporte es especialmente importante porque la predicción temprana tiene mayor valor pedagógico que una predicción realizada al final del curso. Si una institución identifica al

estudiante en riesgo cuando el semestre ya terminó, la información sirve principalmente para análisis posterior. En cambio, si el riesgo se detecta durante las primeras semanas, el docente puede ofrecer tutorías, retroalimentación, materiales de apoyo, seguimiento personalizado o estrategias de acompañamiento. Por ello, ASISTearly representa una herramienta potencial para implementar protocolos de intervención temprana.

Finalmente, el aporte general de los autores consiste en demostrar que los modelos de Deep Learning pueden utilizarse de manera efectiva en Learning Analytics cuando se diseñan considerando distintas dimensiones del comportamiento estudiantil. ASIST no solo predice el rendimiento, sino que integra datos académicos, demográficos, evaluativos y de interacción digital en una arquitectura unificada. Su valor está en combinar precisión predictiva, análisis de comportamiento y utilidad práctica para la intervención educativa. En conclusión, el artículo representa una contribución importante porque propone un modelo avanzado, evaluado con datos reales, capaz de apoyar la identificación temprana de estudiantes en riesgo y orientar estrategias institucionales para mejorar el éxito académico.

Proceso para obtener el aporte

El proceso seguido por los autores para obtener su aporte se basó en el diseño, construcción y evaluación de un modelo de **Deep Learning** orientado a predecir el rendimiento académico de los estudiantes a partir de datos de compromiso en un entorno virtual de aprendizaje. Para ello, los autores partieron de una necesidad concreta dentro de la analítica del aprendizaje: aprovechar los registros generados por los estudiantes en las plataformas VLE para identificar patrones de comportamiento y anticipar si un estudiante será de alto rendimiento, rendimiento moderado o estará en riesgo académico. A diferencia de estudios previos que usan modelos simples o características diseñadas manualmente de forma compleja, los autores propusieron un modelo llamado **ASIST**, capaz de aprender representaciones más completas del estudiante.

En primer lugar, los autores recopilaron datos reales de la **University of Limerick**, en Irlanda. La información provino de tres módulos grandes de primer año pertenecientes a distintas áreas académicas: química, gestión y economía. Estos datos abarcaron cuatro años académicos, desde 2018/19 hasta 2021/22. El conjunto de datos incluyó información demográfica, académica, registros de interacción con el VLE y resultados de evaluación continua. En total, se trabajó con **1 557 estudiantes** en el módulo 1, **2 078 estudiantes** en el módulo 2 y **2 433 estudiantes** en el módulo 3.

Luego, los autores realizaron una etapa de **preprocesamiento de datos**. En esta fase se limpiaron registros duplicados, se eliminaron usuarios con información incompleta y se ajustaron las calificaciones originales de la universidad a tres categorías de rendimiento: **High-performer**, **Moderate-performer** y **At-risk**. Esta clasificación permitió transformar el problema en una tarea de predicción multiclase. Además, los autores organizaron los registros del VLE para construir diferentes representaciones del comportamiento estudiantil durante las 14 semanas del semestre.

Posteriormente, se realizó el modelamiento de los datos. Los autores no trataron toda la información como una sola secuencia, sino que construyeron cinco representaciones principales del estudiante: información demográfica y académica, interacción semanal, eventos semanales, eventos acumulados, interacción diurna semanal y evaluación continua. Esta separación fue importante porque permitió analizar diferentes dimensiones del compromiso digital. Por ejemplo, la interacción semanal mostró cuántas veces el estudiante accedía a la plataforma, mientras que el conteo de eventos permitió observar qué actividades realizaba dentro del VLE.

Después, los autores diseñaron la arquitectura del modelo **ASIST**. Para procesar las secuencias de interacción semanal, eventos semanales, eventos acumulados e información académica, utilizaron redes **Stacked BiLSTM**, capaces de capturar patrones temporales en ambas

direcciones. Para procesar la interacción diurna semanal, organizada como una matriz de días y semanas, aplicaron una red **CNN**, útil para identificar patrones espaciales o estructurados. Además, incorporaron un mecanismo de **atención**, que asigna mayor peso a las características más relevantes para la predicción. Finalmente, las representaciones generadas por las redes se unieron en una capa de concatenación junto con la información de evaluación continua, y una capa softmax clasificó a los estudiantes en las tres categorías de rendimiento.

En la fase de evaluación, los autores entrenaron el modelo con el 80 % de los datos y utilizaron el 20 % restante para prueba. Emplearon métricas como Accuracy, Precision, Recall, F-score y AUC, debido a que las clases estaban desbalanceadas y no bastaba con medir solo la exactitud. ASIST fue comparado con modelos de referencia, como ANN, árbol de decisión, Random Forest, XGBoost, SVM y variantes del propio modelo sin atención o con arquitectura simplificada. Finalmente, los autores extendieron ASIST a una versión de predicción temprana llamada **ASISTearly**, utilizando únicamente las primeras siete semanas de datos. Así, el aporte fue obtenido mediante un proceso completo que incluyó recopilación de datos reales, limpieza, representación del comportamiento estudiantil, diseño de una arquitectura profunda, comparación experimental y validación de su utilidad para la intervención temprana.

Proceso para resolver el problema

El proceso para resolver el problema planteado en el artículo parte de una necesidad central en la educación superior: identificar de manera temprana a los estudiantes que podrían presentar bajo rendimiento académico, con el fin de aplicar intervenciones oportunas. Los autores reconocen que los entornos virtuales de aprendizaje generan una gran cantidad de datos sobre el comportamiento de los estudiantes, pero muchas veces estos datos no se aprovechan de forma adecuada para comprender la relación entre compromiso digital y desempeño académico. Por ello, proponen un modelo de **Deep Learning** llamado **ASIST**, diseñado para aprender representaciones del estudiante a partir de diferentes tipos de información académica, demográfica y de interacción con el VLE.

Primero, los autores recopilan datos reales de la **University of Limerick**, correspondientes a tres módulos de primer año y cuatro años académicos. Esta información incluye registros académicos, datos demográficos, resultados de evaluaciones continuas y actividad dentro del entorno virtual de aprendizaje. Luego, los datos son limpiados y organizados, eliminando duplicados, registros incompletos y ajustando las calificaciones originales a tres categorías: estudiantes de alto rendimiento, rendimiento moderado y estudiantes en riesgo. Esta clasificación permite que el problema se aborde como una tarea de predicción multiclase.

Después, los autores modelan el comportamiento estudiantil en varias dimensiones. En lugar de procesar toda la información como una sola secuencia, separan los datos en diferentes representaciones: interacción semanal, eventos semanales, eventos acumulados, interacción diurna semanal, información demográfica y académica, y evaluación continua. Esta estrategia permite captar patrones más específicos del comportamiento del estudiante. Por ejemplo, no solo se analiza cuántas veces accede a la plataforma, sino también qué actividades realiza, con qué frecuencia participa y cómo evoluciona su interacción durante el semestre.

Posteriormente, estas representaciones son procesadas mediante la arquitectura **ASIST**. Las secuencias de comportamiento son analizadas con redes **Stacked BiLSTM**, capaces de capturar patrones temporales antes y después de cada punto de la secuencia. La interacción diurna semanal se procesa mediante una red **CNN**, útil para identificar patrones entre días y semanas. Además, el mecanismo de **atención** asigna mayor importancia a las características más relevantes para la predicción. Finalmente, las representaciones generadas se concatenan con la información de evaluación continua y pasan por una capa softmax que clasifica al estudiante como de alto rendimiento, rendimiento moderado o en riesgo.

Para comprobar la solución, los autores comparan ASIST con modelos clásicos y modelos profundos de referencia, como ANN, árbol de decisión, Random Forest, XGBoost y SVM. También realizan análisis de ablación para determinar qué componentes del comportamiento influyen más en el rendimiento del modelo. Los resultados muestran que el conteo semanal de eventos tiene el mayor impacto, mientras que la interacción diurna semanal tiene menor influencia. Además, desarrollan **ASISTearly**, una versión que utiliza solo las primeras siete semanas de datos, permitiendo detectar estudiantes en riesgo cuando aún existe tiempo para intervenir. Así, el problema se resuelve mediante una arquitectura predictiva que transforma los datos de interacción en información útil para apoyar decisiones pedagógicas tempranas.

Métricas y resultados

En el artículo, los autores evaluaron el modelo **ASIST** como un problema de clasificación multiclase, ya que el objetivo era predecir si el estudiante pertenecía a la categoría de **alto rendimiento, rendimiento moderado o en riesgo académico**. Para medir el desempeño del modelo utilizaron cinco métricas principales: **Accuracy, Precision, Recall, F-score** y **AUC**. La inclusión de AUC fue especialmente importante porque los conjuntos de datos estaban desbalanceados, es decir, había mayor cantidad de estudiantes de rendimiento moderado que de alto rendimiento o en riesgo.

Los resultados muestran que **ASIST** obtuvo un rendimiento superior frente a modelos base de Deep Learning y Machine Learning tradicional. En los tres módulos analizados, el modelo alcanzó valores de **AUC entre 0.86 y 0.90**. Específicamente, obtuvo un AUC de **0.8858** en el módulo 1, **0.9040** en el módulo 2 y **0.8614** en el módulo 3. Además, logró una Accuracy de **0.7519, 0.8245 y 0.7207** respectivamente, superando a la mayoría de modelos comparados, como ANN, árbol de decisión, Random Forest, XGBoost y SVM.

También se realizó un análisis de ablación para conocer qué tipo de comportamiento tenía mayor impacto en la predicción. Los resultados indicaron que el **conteo semanal de eventos** fue el componente más influyente en el desempeño del modelo, mientras que la interacción diurna semanal tuvo menor efecto. Finalmente, la versión **ASISTearly**, que usa solo las primeras siete semanas de datos, alcanzó valores de AUC entre **0.83 y 0.89**, demostrando que el modelo puede servir para identificar estudiantes en riesgo de manera temprana y apoyar intervenciones oportunas.

Observaciones/críticas

Una observación importante sobre el artículo es que presenta un aporte metodológico sólido al proponer un modelo avanzado de **Deep Learning** para predecir el rendimiento académico usando datos de interacción en entornos virtuales de aprendizaje. La arquitectura **ASIST** es valiosa porque integra diferentes componentes, como **BiLSTM, CNN** y mecanismo de **atención**, lo que permite analizar varias dimensiones del comportamiento estudiantil y no solo una secuencia general de actividad. Además, la versión **ASISTearly** representa una fortaleza práctica, ya que permite realizar predicciones con las primeras siete semanas de datos y abre la posibilidad de intervenir a tiempo en estudiantes en riesgo.

Sin embargo, una crítica relevante es que, aunque el modelo alcanza buenos resultados predictivos, sigue siendo una arquitectura compleja y parcialmente difícil de interpretar para docentes o responsables académicos. El mecanismo de atención ayuda a identificar cierta relevancia de variables, pero no ofrece explicaciones tan directas como otros enfoques de inteligencia artificial explicable. Por ello, sería recomendable complementar el modelo con técnicas más interpretables que permitan comprender mejor por qué un estudiante es clasificado como “en riesgo”.

Otra limitación es que el estudio se basa en datos de una sola universidad irlandesa y en tres módulos específicos de primer año. Aunque los resultados son prometedores, su generalización a otras instituciones, países, plataformas o asignaturas debe comprobarse con nuevos estudios. Además, el uso de datos de interacción en VLE puede no reflejar completamente el aprendizaje real del estudiante, ya que algunos alumnos pueden estudiar fuera de la plataforma o acceder a recursos externos. A pesar de estas limitaciones, el artículo es valioso porque demuestra que los datos de compromiso digital pueden apoyar la detección temprana del riesgo académico y orientar mejores estrategias de acompañamiento estudiantil.

36. ARTÍCULO 36

Author (s): Ifeanyi Glory Ndukwe; Ben Kei Daniel

Title of paper: Teaching analytics, value and tools for teacher data literacy: a systematic and tripartite approach

Journal: International Journal of Educational Technology in Higher Education

Volume (issue): Volume 17, Article 22

pag – pag (year): pp. 1–31 (2020)

Estado del arte

La analítica educativa se ha convertido en una línea de investigación fundamental en la educación superior, debido al crecimiento de los entornos virtuales, las plataformas de aprendizaje y la generación masiva de datos académicos. Inicialmente, las investigaciones se concentraron en la **analítica académica** y la **analítica del aprendizaje**, orientadas principalmente a estudiar el rendimiento institucional, la permanencia estudiantil, la predicción de estudiantes en riesgo, la personalización del aprendizaje y los patrones de participación de los alumnos. Sin embargo, gran parte de estos estudios se enfocó en el estudiante y en sus huellas digitales dentro de los sistemas de gestión del aprendizaje, dejando en segundo plano el papel del docente y la forma en que los datos pueden ayudar a mejorar la práctica pedagógica.

En este contexto surge la **Teaching Analytics —TA—** o analítica de la enseñanza, entendida como un enfoque que combina experiencia docente, analítica visual y diseño basado en investigación para fortalecer la capacidad pedagógica del profesor mediante el uso de datos. A diferencia de la analítica del aprendizaje, que analiza principalmente cómo aprende el estudiante, la analítica de la enseñanza busca ofrecer información sobre cómo enseña el docente, cómo se desarrollan las actividades de clase, qué decisiones pedagógicas se toman y cómo estas influyen en los resultados de aprendizaje. Por ello, la TA se presenta como una herramienta para promover la reflexión docente, mejorar la toma de decisiones y fortalecer la calidad de la enseñanza.

La literatura revisada por los autores muestra que todavía no existe un consenso definitivo sobre qué constituye exactamente la Teaching Analytics. Algunos estudios la entienden como el análisis de actividades docentes, tales como la forma de dictar clases, el uso de herramientas tecnológicas, la comunicación en el aula o la gestión de actividades. Otros trabajos la consideran como una extensión de la analítica del aprendizaje, orientada a entregar al docente información sobre la participación y desempeño de los estudiantes para facilitar intervenciones pedagógicas. También existen investigaciones que integran tanto actividades del docente como del estudiante, formando enfoques de Teaching and Learning Analytics. Esta diversidad conceptual evidencia que el campo aún se encuentra en proceso de construcción teórica.

Los estudios previos han empleado diversas fuentes de datos para apoyar la analítica de la enseñanza. Entre ellas se encuentran datos de plataformas virtuales, registros de LMS, foros, correos, redes sociales, videos de clase, audio, imágenes, sensores, eye-tracking, EEG, acelerómetros, datos fisiológicos, observaciones en el aula, diarios docentes y evaluaciones estudiantiles sobre la enseñanza. Estas fuentes permiten analizar tanto el entorno virtual como

el aula física. No obstante, los autores señalan que muchas tecnologías de recolección de datos pueden ser costosas, difíciles de implementar a gran escala o sensibles desde el punto de vista ético y de privacidad. Por ello, el desarrollo de TA requiere equilibrar la riqueza de los datos con la viabilidad práctica y el respeto a los participantes.

Respecto a las técnicas utilizadas, la literatura incluye métodos de clasificación, clustering, procesamiento de lenguaje natural, análisis de redes sociales, análisis multimodal, modelos predictivos, redes neuronales y visualizaciones mediante dashboards. Los **Teaching Analytics Dashboards —TAD—** ocupan un lugar importante, porque permiten presentar datos de manera visual para que el docente pueda observar patrones, identificar problemas y reflexionar sobre su práctica. Estos tableros pueden mostrar información sobre participación estudiantil, uso de recursos, interacción en clase, retroalimentación, tiempos de actividad o incluso comportamientos del docente durante la enseñanza. De este modo, la visualización se convierte en un puente entre los datos y la acción pedagógica.

El artículo analizado contribuye al estado del arte al realizar una revisión sistemática de investigaciones publicadas entre 2012 y 2019, utilizando el **modelo tripartito** como enfoque metodológico. Este modelo organiza la revisión en tres fases: descripción, síntesis y crítica. A partir de este proceso, los autores identifican los principales discursos sobre TA, sus herramientas, fuentes de datos, métodos de análisis, formas de visualización y posibles acciones pedagógicas. Además, proponen un marco conceptual que relaciona la Teaching Analytics con la Learning Analytics y el Learning Design, colocando al docente como actor central del uso de datos para mejorar la enseñanza.

En síntesis, el estado del arte muestra que la Teaching Analytics es un campo emergente, necesario para complementar la analítica centrada en el estudiante. Su importancia radica en que permite al docente desarrollar alfabetización en datos, reflexionar sobre su práctica y tomar decisiones pedagógicas basadas en evidencia. Sin embargo, el campo aún enfrenta desafíos conceptuales, metodológicos y éticos, especialmente en relación con la definición de TA, la formación docente en uso de datos, la integración de diversas fuentes de información y la protección de la privacidad. El aporte del artículo está en ordenar este campo, establecer límites conceptuales y proponer modelos que orienten futuras investigaciones sobre analítica de la enseñanza.

Motivación del autor

La motivación principal de los autores surge de la necesidad de dar mayor claridad teórica y práctica al campo de la **Teaching Analytics —TA—** o analítica de la enseñanza. Aunque la analítica del aprendizaje ha tenido un crecimiento importante en la educación superior, la mayoría de investigaciones se ha centrado en los estudiantes, sus patrones de participación, su rendimiento y su riesgo académico. Sin embargo, los autores observan que se ha prestado menos atención al docente, a sus prácticas pedagógicas y a la forma en que los datos pueden ayudarle a reflexionar, tomar decisiones y mejorar la calidad de su enseñanza.

Por esta razón, los autores buscan revisar sistemáticamente la literatura sobre TA para comprender su significado, sus herramientas, sus fuentes de datos y su valor para la formación docente. Su motivación también está relacionada con la necesidad de fortalecer la **alfabetización de datos del profesorado**, ya que muchos docentes no cuentan con las habilidades suficientes para interpretar analíticas educativas y convertirlas en acciones pedagógicas. En ese sentido, el estudio pretende proponer un marco conceptual y un **Teaching Outcome Model —TOM—** que ayude a los profesores a utilizar datos sobre sus actividades de enseñanza, reflexionar sobre su práctica y mejorar los resultados de aprendizaje.

Descripción del aporte del autor

El principal aporte de Ndukwe y Daniel consiste en organizar, clarificar y fortalecer el campo de la **Teaching Analytics —TA—** o analítica de la enseñanza, un área emergente dentro de la educación superior que busca apoyar al docente en el uso de datos para mejorar su práctica pedagógica. A diferencia de la analítica del aprendizaje, que se ha enfocado principalmente en los estudiantes, sus interacciones, su rendimiento y su riesgo académico, la Teaching Analytics coloca al profesor en el centro del proceso analítico. Su finalidad es que los docentes puedan comprender mejor lo que ocurre durante la enseñanza, reflexionar sobre sus decisiones pedagógicas y actuar con base en evidencias para mejorar los resultados de aprendizaje.

Uno de los aportes más importantes del artículo es que ofrece una revisión sistemática y crítica de la literatura sobre TA. Los autores revisaron publicaciones comprendidas entre 2012 y 2019, identificando inicialmente 58 artículos, de los cuales finalmente seleccionaron 31 para el análisis. Para realizar esta revisión, aplicaron el **modelo tripartito**, compuesto por tres fases: descripción, síntesis y crítica. Esta metodología permitió no solo resumir los estudios existentes, sino también agrupar ideas, comparar enfoques, identificar vacíos y proponer nuevos elementos conceptuales. Gracias a este procedimiento, el artículo no se limita a recopilar información, sino que produce una interpretación ordenada del estado actual de la analítica de la enseñanza.

Un segundo aporte fundamental es la delimitación conceptual de la Teaching Analytics. Los autores muestran que en la literatura no existe una definición única y consolidada de TA. Algunos estudios la consideran como el análisis de las actividades del docente; otros la entienden como una extensión de la analítica del aprendizaje orientada a apoyar decisiones pedagógicas; y otros la relacionan con el análisis conjunto de actividades de docentes y estudiantes. Frente a esta dispersión conceptual, el artículo contribuye al proponer una visión más integradora: la TA debe entenderse como el uso de datos relacionados con la enseñanza, el aprendizaje, las actividades docentes y los entornos educativos para mejorar la práctica docente y los resultados de aprendizaje.

Otro aporte relevante es que los autores establecen una diferencia clara entre **Teaching Analytics**, **Learning Analytics** y **Learning Design**. La analítica del aprendizaje se enfoca principalmente en los datos del estudiante y su proceso de aprendizaje; el diseño del aprendizaje se relaciona con la planificación pedagógica, las actividades, los recursos y las estrategias de enseñanza; mientras que la analítica de la enseñanza se concentra en cómo el docente utiliza datos para reflexionar y mejorar su práctica. Esta distinción es importante porque evita confundir la TA con simples reportes de actividad estudiantil. Para los autores, la TA debe proporcionar información útil para el profesor, no solo sobre lo que hacen los estudiantes, sino también sobre cómo las decisiones docentes, los métodos de enseñanza y el diseño del curso influyen en el aprendizaje.

El artículo aporta también un **marco conceptual triádico** que relaciona TA, LA y LD con el docente en el centro. Este marco propone que la mejora educativa surge de la interacción entre los datos del aprendizaje, el diseño pedagógico y la práctica docente. En una primera relación, el docente puede usar la analítica del aprendizaje para comprender cómo participan los estudiantes y ajustar el diseño del curso. En una segunda relación, puede analizar su propia enseñanza y reflexionar sobre cómo sus decisiones afectan el aprendizaje. En una tercera relación, puede vincular datos del estudiante y datos de la enseñanza para obtener una visión más completa del proceso educativo. Este marco es valioso porque muestra que el docente no debe ser un receptor pasivo de reportes, sino un actor activo que interpreta datos y toma decisiones pedagógicas.

Un aporte práctico importante del estudio es la identificación de fuentes de datos útiles para la Teaching Analytics. Los autores agrupan distintas fuentes, como datos digitales de plataformas LMS, registros de participación, datos sociales de foros o redes, textos provenientes de evaluaciones y comentarios, imágenes, videos, audio, datos fisiológicos y sensores. Esta clasificación demuestra que la enseñanza puede analizarse desde múltiples dimensiones: lo que

ocurre en plataformas virtuales, lo que sucede en el aula física, las interacciones entre estudiantes y docentes, la comunicación, la retroalimentación y las percepciones de los estudiantes. De esta manera, el artículo amplía la comprensión de qué tipo de datos pueden ser relevantes para mejorar la enseñanza.

Asimismo, los autores aportan una revisión de las herramientas y técnicas utilizadas en TA. En la literatura se identifican métodos como clasificación, clustering, procesamiento de lenguaje natural, análisis de redes sociales, minería de datos, aprendizaje automático, redes neuronales, análisis multimodal y visualización de datos. Esta diversidad metodológica muestra que la Teaching Analytics no depende de una sola técnica, sino que puede apoyarse en diferentes enfoques según el tipo de problema pedagógico que se quiera resolver. Por ejemplo, el procesamiento de lenguaje natural puede utilizarse para analizar comentarios de estudiantes; el análisis de redes puede ayudar a comprender interacciones en foros; y las técnicas de clasificación pueden identificar patrones en actividades docentes o estudiantiles.

Otro aporte esencial del artículo se encuentra en la importancia otorgada a la **visualización de datos**. Los autores destacan el papel de los **Teaching Analytics Dashboards —TAD—**, tableros diseñados para que los docentes puedan observar información relevante sobre su enseñanza y el aprendizaje de sus estudiantes. Estos dashboards pueden presentar gráficos, tablas, mapas de calor, líneas de tiempo, redes, visualizaciones individuales o grupales, e incluso información en tiempo real. Su valor está en transformar datos complejos en representaciones comprensibles que permitan al docente reflexionar, identificar problemas y tomar decisiones. En este sentido, la visualización funciona como un puente entre el análisis técnico y la acción pedagógica.

El artículo también aporta una perspectiva crítica sobre la **alfabetización de datos del profesorado**. Los autores señalan que no basta con entregar datos o dashboards a los docentes; también es necesario que ellos desarrollen capacidades para interpretar, cuestionar y usar esos datos de manera responsable. Si un profesor no cuenta con habilidades de alfabetización de datos, puede interpretar mal la información y tomar decisiones equivocadas que afecten a los estudiantes. Por ello, la TA debe ir acompañada de formación docente, reflexión pedagógica y comprensión ética del uso de datos. Este aporte es especialmente importante porque coloca al docente como sujeto activo de la analítica, no como simple usuario de herramientas tecnológicas.

Un aporte destacado es la propuesta del **Teaching Outcome Model —TOM—**, modelo que funciona como un ciclo para guiar el uso de datos en la mejora de la enseñanza. Este modelo incluye cuatro etapas principales: recolección de datos, análisis de datos, visualización de datos y acción pedagógica. En la primera etapa se recopilan datos relacionados con la enseñanza y el aprendizaje; en la segunda se aplican técnicas analíticas para encontrar patrones; en la tercera se presentan los resultados mediante visualizaciones comprensibles; y en la cuarta el docente toma decisiones para mejorar su práctica, rediseñar actividades, cambiar métodos de enseñanza, ofrecer retroalimentación o realizar nuevas investigaciones.

El valor del TOM está en que convierte la analítica en un proceso continuo de mejora. No se trata de analizar datos una sola vez, sino de establecer un ciclo permanente en el que el docente observa, interpreta, reflexiona, actúa y vuelve a evaluar. Este enfoque se relaciona con el diseño basado en investigación, ya que promueve una enseñanza iterativa, reflexiva y situada. Para los autores, la TA debe servir para que los profesores identifiquen dificultades, ajusten sus estrategias y mejoren progresivamente la calidad de la enseñanza.

Otro aporte del artículo es su énfasis en el uso de la analítica para la **reflexión docente**. La reflexión es presentada como una actividad clave para el desarrollo profesional del profesor. A través de datos sobre participación, interacciones, evaluaciones, videos de clase o comentarios estudiantiles, los docentes pueden examinar aspectos de su práctica que quizá no perciben

durante la enseñanza. Por ejemplo, pueden identificar si el tiempo asignado a una actividad fue adecuado, si ciertos recursos no fueron utilizados, si los estudiantes tienen dificultades recurrentes o si la comunicación en clase necesita mejorar. Esto permite pasar de una reflexión basada solo en percepciones personales a una reflexión apoyada en evidencias.

El artículo también aporta una mirada ética y crítica sobre el uso de datos educativos. Los autores reconocen que la recolección y análisis de información sobre docentes y estudiantes puede generar riesgos relacionados con privacidad, sesgos, vigilancia y mal uso de datos. Por ello, destacan la necesidad de políticas claras de gobernanza de datos, definición de propósitos, consentimiento, seguridad y acceso responsable a la información. Este punto es importante porque la Teaching Analytics no debe convertirse en un mecanismo de control del docente, sino en una herramienta para apoyar su desarrollo profesional y mejorar la experiencia educativa.

Desde una perspectiva institucional, el aporte del artículo es mostrar que la Teaching Analytics puede contribuir a la transformación de la educación superior. Al proporcionar datos útiles sobre enseñanza, aprendizaje, diseño pedagógico y resultados, las instituciones pueden apoyar mejor a sus docentes, mejorar programas, fortalecer la calidad educativa y promover decisiones basadas en evidencia. Sin embargo, los autores advierten que esta transformación requiere una participación activa de los profesores. La TA no debe imponerse de arriba hacia abajo, sino construirse con los docentes como actores principales.

En conclusión, el aporte de Ndukwe y Daniel se resume en tres dimensiones fundamentales. Primero, clarifican conceptualmente el campo de la Teaching Analytics y establecen sus diferencias y relaciones con la Learning Analytics y el Learning Design. Segundo, sistematizan fuentes de datos, herramientas, técnicas de análisis y visualizaciones que pueden apoyar la reflexión docente. Tercero, proponen el Teaching Outcome Model como una guía práctica para transformar los datos en acciones pedagógicas. Su contribución es significativa porque desplaza la atención desde una analítica centrada únicamente en el estudiante hacia una analítica que también fortalece al docente, su alfabetización de datos, su reflexión profesional y su capacidad para mejorar la enseñanza basada en evidencia.

Proceso para obtener el aporte

Para obtener su aporte, los autores desarrollaron un proceso metodológico basado en una **revisión sistemática de literatura** sobre Teaching Analytics —TA— o analítica de la enseñanza. El propósito fue comprender cómo se ha definido este campo, qué valor tiene para los docentes, qué herramientas se han utilizado y cómo puede contribuir al desarrollo de la alfabetización de datos del profesorado. Para ello, los autores utilizaron el **modelo tripartito**, una estrategia de revisión que organiza el análisis en tres fases: descripción, síntesis y crítica. Esta metodología les permitió no solo recopilar información, sino también interpretarla, clasificarla y proponer nuevos marcos conceptuales para el uso de datos en la mejora de la enseñanza.

El primer paso del proceso fue **delimitar el área de investigación**. Los autores partieron de la necesidad de diferenciar la Teaching Analytics de otros campos cercanos, como la Learning Analytics y la Academic Analytics. Mientras la analítica del aprendizaje se orienta principalmente al estudiante y a sus procesos de aprendizaje, la analítica de la enseñanza busca apoyar al docente en la comprensión de su propia práctica pedagógica. Con esta delimitación, los autores formularon preguntas de investigación relacionadas con los discursos actuales sobre TA, sus componentes principales y la forma en que puede utilizarse para informar la práctica docente.

El segundo paso fue la **búsqueda y selección de artículos científicos**. Los autores utilizaron la base de datos Scopus y aplicaron combinaciones de palabras clave como Teaching Analytics, Learning Analytics, Teacher Inquiry, Data Literacy, Learning Design, Learning Management

System, Visualization y Student Evaluation on Teaching. La búsqueda se limitó a publicaciones entre **2012 y 2019**, en idioma inglés, incluyendo artículos de revistas y conferencias revisadas por pares. Inicialmente identificaron **58 publicaciones**; después de aplicar criterios de inclusión y exclusión, eliminar duplicados y revisar títulos, resúmenes y textos completos, finalmente seleccionaron **31 artículos** para el análisis.

El tercer paso fue la fase **descriptiva** del modelo tripartito. En esta etapa, los autores revisaron cómo la literatura conceptualiza la Teaching Analytics y qué usos se le ha dado. Identificaron que algunos estudios la entienden como análisis de actividades del docente, otros como apoyo para comprender la actividad estudiantil, y otros como una integración de datos de docentes y estudiantes. Esta fase permitió reconocer que el campo todavía carece de una definición única y que se encuentra en proceso de consolidación teórica.

El cuarto paso fue la fase de **síntesis**. Los autores agruparon los estudios según fuentes de datos, herramientas, métodos de análisis, técnicas de visualización y posibles acciones pedagógicas. Encontraron que la TA utiliza datos digitales de plataformas LMS, videos, audios, sensores, eye-tracking, EEG, comentarios estudiantiles, redes sociales y evaluaciones de enseñanza. También identificaron técnicas como clasificación, clustering, procesamiento de lenguaje natural, análisis de redes, aprendizaje automático y dashboards. Esta clasificación permitió ordenar el conocimiento existente y mostrar qué recursos pueden ayudar al docente a interpretar datos sobre su enseñanza.

Finalmente, los autores desarrollaron la fase **crítica**, donde analizaron los vacíos y limitaciones del campo. A partir de esta reflexión, propusieron un **marco conceptual triádico** que relaciona Teaching Analytics, Learning Analytics y Learning Design, colocando al docente como actor central. Además, plantearon el **Teaching Outcome Model —TOM—**, un ciclo compuesto por recolección de datos, análisis, visualización y acción pedagógica. Así, el aporte se obtuvo mediante un proceso sistemático, crítico y conceptual que permitió transformar la literatura revisada en una propuesta para orientar a los docentes en el uso de datos, la reflexión sobre su práctica y la mejora de los resultados de aprendizaje.

Proceso para resolver el problema

Para resolver el problema de la falta de claridad conceptual y práctica sobre la **Teaching Analytics —TA—**, los autores desarrollaron una revisión sistemática orientada a ordenar el campo y proponer una guía útil para docentes e investigadores. El problema central identificado fue que, aunque la analítica del aprendizaje ha avanzado bastante en educación superior, la mayoría de estudios se ha enfocado en el estudiante, dejando menos desarrollado el análisis de la práctica docente. Además, no existía un consenso claro sobre qué significa TA, qué datos debe utilizar, qué herramientas son adecuadas y cómo puede ayudar realmente al profesor a mejorar su enseñanza.

El primer paso para resolver este problema fue revisar la literatura científica existente entre 2012 y 2019. Los autores buscaron artículos en Scopus utilizando términos relacionados con Teaching Analytics, Learning Analytics, Teacher Inquiry, Data Literacy, Learning Design, Visualisation y Learning Management System. Luego aplicaron criterios de inclusión y exclusión para seleccionar estudios realmente vinculados con la analítica de la enseñanza. De una búsqueda inicial de 58 publicaciones, finalmente eligieron 31 artículos para el análisis. Este proceso permitió reunir la evidencia disponible y reconocer cómo se había estudiado la TA hasta ese momento.

El segundo paso fue aplicar el **modelo tripartito**, compuesto por tres fases: descripción, síntesis y crítica. En la fase descriptiva, los autores analizaron cómo distintos estudios definían y utilizaban la Teaching Analytics. En la fase de síntesis, organizaron la información en categorías como fuentes de datos, herramientas, técnicas de análisis, métodos de visualización

y acciones pedagógicas. En la fase crítica, identificaron vacíos conceptuales y metodológicos, especialmente la falta de una definición compartida, la escasa atención a la alfabetización de datos docentes y la necesidad de conectar la analítica con decisiones pedagógicas concretas.

El tercer paso fue diferenciar la Teaching Analytics de campos cercanos, como la **Learning Analytics** y el **Learning Design**. Los autores señalaron que la Learning Analytics se enfoca principalmente en el aprendizaje del estudiante, mientras que la Teaching Analytics debe centrarse en el docente, su práctica pedagógica, sus decisiones y su capacidad para usar datos en la mejora de la enseñanza. Esta diferenciación permitió resolver parte del problema conceptual y establecer límites más claros para el campo.

Finalmente, los autores propusieron dos soluciones principales: un **marco conceptual triádico** y el **Teaching Outcome Model —TOM—**. El marco triádico relaciona TA, LA y LD, ubicando al docente en el centro del proceso de análisis y toma de decisiones. Por su parte, el TOM plantea un ciclo de mejora compuesto por recolección de datos, análisis, visualización y acción pedagógica. Así, el problema se resolvió proponiendo una estructura clara para que los docentes puedan usar datos, reflexionar sobre su práctica, rediseñar estrategias de enseñanza y mejorar los resultados de aprendizaje.

Métricas y resultados

En este artículo, los autores no presentan métricas experimentales tradicionales como **accuracy**, **precision**, **recall**, **F1-score** o **AUC**, porque no desarrollan un modelo predictivo aplicado a estudiantes, sino una **revisión sistemática de literatura** sobre Teaching Analytics. Por ello, las métricas principales del estudio corresponden al proceso de búsqueda, selección y análisis bibliográfico. Inicialmente se identificaron **58 publicaciones** en la base de datos Scopus, relacionadas con Teaching Analytics, Learning Analytics, Teacher Inquiry, Data Literacy, Learning Design y Visualisation. Después de eliminar duplicados, revisar títulos, resúmenes y aplicar criterios de inclusión y exclusión, quedaron **31 artículos** para el análisis final. La revisión consideró estudios publicados entre **2012 y 2019**, únicamente en inglés y provenientes de revistas o conferencias revisadas por pares.

Los resultados principales muestran que la Teaching Analytics es un campo todavía emergente y poco consolidado conceptualmente. Los autores encontraron que no existe una definición única de TA: algunos estudios la entienden como análisis de actividades docentes, otros como apoyo al profesor mediante datos del estudiante, y otros como integración entre enseñanza y aprendizaje. Además, identificaron diversas fuentes de datos utilizadas en TA, como registros de LMS, videos, audios, sensores, eye-tracking, EEG, redes sociales, textos y evaluaciones estudiantiles. También hallaron técnicas como clasificación, clustering, procesamiento de lenguaje natural, análisis de redes, deep learning y dashboards. Como resultado final, los autores propusieron un **marco conceptual triádico** que relaciona Teaching Analytics, Learning Analytics y Learning Design, y el **Teaching Outcome Model —TOM—**, compuesto por recolección de datos, análisis, visualización y acción pedagógica para mejorar la práctica docente.

Observaciones/críticas

Una observación positiva del artículo es que aporta claridad a un campo todavía poco desarrollado: la **Teaching Analytics**. El estudio es valioso porque no se limita a describir investigaciones previas, sino que organiza la literatura, identifica fuentes de datos, herramientas, métodos de análisis y formas de visualización que pueden ayudar al docente a mejorar su práctica. Además, al proponer el **Teaching Outcome Model —TOM—**, los autores ofrecen una guía útil para transformar los datos en acciones pedagógicas concretas. Esto es importante porque muchos docentes reciben datos de plataformas educativas, encuestas o

evaluaciones, pero no siempre cuentan con las competencias necesarias para interpretarlos y usarlos de manera efectiva.

Sin embargo, también se pueden señalar algunas críticas. La principal limitación es que el artículo es una revisión teórica y sistemática, por lo que no valida empíricamente el modelo TOM en un aula real ni demuestra con datos experimentales si mejora efectivamente la enseñanza. Además, la revisión solo consideró publicaciones entre **2012 y 2019** y únicamente en inglés, lo que pudo dejar fuera investigaciones relevantes en otros idiomas o años posteriores. Otra limitación es que, aunque se discuten muchas fuentes de datos, algunas como sensores, EEG, eye-tracking o grabaciones de video pueden ser costosas y generar problemas éticos de privacidad. A pesar de ello, el artículo constituye un aporte importante porque coloca al docente en el centro del uso de datos y resalta la necesidad de fortalecer su alfabetización analítica para mejorar la calidad educativa.

37. ARTÍCULO 37

Author (s): Christothea Herodotou; Galina Naydenova; Avi Boroowa; Alison Gilmour; Bart Rienties.

Title of paper: How Can Predictive Learning Analytics and Motivational Interventions Increase Student Retention and Enhance Administrative Support in Distance Education?

Journal: *Journal of Learning Analytics*.

Volume (issue): 7(2).

pag – pag (year): 72–83 (2020).

Estado del arte

El estudio sobre **Predictive Learning Analytics (PLA)** se ha convertido en una línea relevante dentro de la educación superior, especialmente porque permite identificar estudiantes con riesgo de abandonar, reprobar o no completar sus estudios. En los últimos años, las instituciones educativas han empezado a utilizar datos académicos, demográficos, administrativos y de interacción en plataformas virtuales para anticipar comportamientos estudiantiles y diseñar acciones de apoyo. Sin embargo, aunque el potencial de la analítica predictiva es ampliamente reconocido, todavía existe una brecha importante entre la predicción del riesgo y la aplicación efectiva de intervenciones que realmente mejoren la retención estudiantil.

De acuerdo con el artículo revisado, las PLA permiten pronosticar resultados futuros mediante el procesamiento de información que las universidades ya recopilan de manera rutinaria. Estos sistemas pueden ayudar a identificar grupos o estudiantes individuales que necesitan apoyo adicional para alcanzar los resultados esperados. No obstante, los autores señalan que la evidencia sobre la efectividad real de estas herramientas todavía es limitada, ya que muchas investigaciones se han desarrollado en estudios de caso pequeños, contextos experimentales o entornos como los MOOC, sin demostrar suficientemente su impacto en la gestión institucional a gran escala.

Dentro del estado del arte, destacan sistemas de alerta temprana como **Course Signals**, **E2 Coach** y **OU Analyse**, los cuales han sido utilizados para detectar estudiantes en riesgo y facilitar intervenciones oportunas. Estos modelos se basan en la idea de que los datos pueden producir “inteligencia accionable”, es decir, información que no solo describe una situación, sino que permite tomar decisiones concretas. En educación a distancia, esta capacidad resulta especialmente importante porque los problemas de participación, motivación o abandono no siempre son visibles para los docentes como ocurre en la educación presencial.

El artículo también muestra que la retención estudiantil es uno de los desafíos más importantes en la educación a distancia. En este tipo de modalidad existe una mayor “distancia transaccional” entre el estudiante, la institución y los docentes. Esta distancia no solo es física,

sino también psicológica y comunicativa. Por ello, la comunicación temprana y personalizada puede ayudar a reducir la sensación de aislamiento, fortalecer el sentido de pertenencia y motivar al estudiante a continuar. Desde esta perspectiva, las PLA no deben limitarse a identificar estudiantes en riesgo, sino que deben conectarse con estrategias de acompañamiento humano.

Otro aspecto importante del estado del arte es la diferencia entre **intervenciones motivacionales** e **intervenciones pedagógicas**. Las intervenciones pedagógicas buscan mejorar directamente el aprendizaje mediante tutorías, recursos adaptativos, ejercicios personalizados o plataformas inteligentes. En cambio, las intervenciones motivacionales buscan reforzar la participación, la confianza y la permanencia del estudiante mediante mensajes, llamadas telefónicas, correos electrónicos u otros medios de contacto. El artículo se enfoca en este segundo tipo de intervención, debido a que en educación a distancia el apoyo emocional, administrativo y motivacional puede influir de manera significativa en la continuidad de los estudios.

La literatura previa ha mostrado resultados mixtos sobre el impacto de estas intervenciones. Algunos estudios encontraron mejoras pequeñas pero positivas en la retención cuando se enviaron correos motivacionales o mensajes personalizados. Otros trabajos, en cambio, no encontraron efectos claros, o señalaron que las diferencias se explicaban más por características individuales de los estudiantes que por la intervención misma. Por ello, el artículo de Herodotou y colaboradores aporta al campo al aplicar un diseño experimental más sólido, mediante un **ensayo controlado aleatorizado**, para evaluar si una intervención motivacional guiada por PLA podía mejorar la retención estudiantil en la Open University del Reino Unido.

En este contexto, los autores utilizaron el **Student Probabilities Model (SPM)**, un modelo predictivo basado en regresión logística que estima la probabilidad de que un estudiante continúe y complete su curso. Este modelo considera variables como perfil del estudiante, estudios previos, progreso académico, número de créditos, calificaciones, intentos fallidos, retiros anteriores y características del curso. Su utilidad está en que permite seleccionar de manera más precisa a los estudiantes que necesitan apoyo, superando métodos tradicionales basados en indicadores aislados como baja calificación previa, falta de estudios formales o nivel socioeconómico.

En síntesis, el estado del arte muestra que la analítica predictiva tiene un gran potencial para apoyar la retención en educación superior, pero su verdadero valor aparece cuando se vincula con intervenciones concretas, oportunas y humanas. El artículo revisado aporta a esta línea al demostrar que las PLA pueden ayudar a los equipos de apoyo estudiantil a seleccionar mejor a los estudiantes en riesgo y dirigir intervenciones motivacionales de bajo costo, como mensajes, llamadas y correos. Así, la investigación fortalece la idea de que la analítica del aprendizaje no debe quedarse en la predicción, sino convertirse en una herramienta práctica para mejorar el acompañamiento, la permanencia y la finalización de los estudios.

Motivación del autor

La motivación principal de los autores surge de la necesidad de demostrar que la **analítica predictiva del aprendizaje** no debe quedarse únicamente en identificar estudiantes en riesgo, sino que debe utilizarse para diseñar intervenciones concretas que mejoren la retención estudiantil. Aunque las instituciones de educación superior muestran interés por las herramientas predictivas, los autores señalan que todavía existe poca evidencia sólida sobre su aplicación efectiva en contextos reales y a gran escala. Por ello, buscan comprobar si un modelo predictivo puede orientar mejor el trabajo de los equipos de apoyo estudiantil y ayudar a los alumnos con mayor probabilidad de abandonar o no completar sus estudios.

Otra motivación importante está relacionada con la educación a distancia. En esta modalidad, los estudiantes pueden sentirse más aislados, tener menor contacto directo con docentes y presentar mayores riesgos de abandono. Además, las instituciones no siempre cuentan con suficientes recursos humanos para contactar a todos los estudiantes que podrían necesitar apoyo. Frente a esta situación, los autores se motivan por utilizar el **Student Probabilities Model (SPM)** para seleccionar con mayor precisión a los estudiantes en riesgo y dirigir hacia ellos intervenciones motivacionales de bajo costo.

Finalmente, la investigación se motiva por evaluar si acciones simples, como mensajes de texto, llamadas telefónicas y correos electrónicos, pueden generar un impacto real en la permanencia. El propósito de los autores es comprobar si una comunicación temprana, humana y personalizada puede reducir la distancia entre estudiante e institución, fortalecer la motivación y mejorar la finalización del curso.

Descripción del aporte del autor

El aporte principal de Christothea Herodotou, Galina Naydenova, Avi Boroowa, Alison Gilmour y Bart Rienties en el artículo **“How Can Predictive Learning Analytics and Motivational Interventions Increase Student Retention and Enhance Administrative Support in Distance Education?”** consiste en demostrar que la **analítica predictiva del aprendizaje** puede ser utilizada de manera práctica para identificar estudiantes en riesgo y orientar intervenciones motivacionales capaces de mejorar la retención en educación a distancia. Este aporte es relevante porque muchas investigaciones sobre Learning Analytics se concentran en construir modelos predictivos, pero no siempre evalúan si esas predicciones producen mejoras reales cuando se aplican en una institución educativa.

Uno de los aportes más importantes del artículo es que conecta la predicción con la acción. Los autores no se limitan a identificar estudiantes con baja probabilidad de continuar sus estudios, sino que utilizan esa información para diseñar y aplicar una intervención concreta mediante mensajes de texto, llamadas telefónicas y correos electrónicos. De esta manera, la analítica predictiva deja de ser solo una herramienta de diagnóstico y se convierte en un recurso para tomar decisiones administrativas y brindar apoyo oportuno a los estudiantes. Este enfoque es valioso porque muestra que los datos educativos tienen mayor impacto cuando se integran con estrategias humanas de acompañamiento.

El estudio aporta especialmente al contexto de la **educación a distancia**, donde la retención estudiantil representa un desafío constante. En esta modalidad, los estudiantes no siempre tienen contacto presencial con docentes o compañeros, por lo que pueden experimentar aislamiento, desmotivación o dificultades para mantenerse comprometidos con el curso. Los autores toman como base la idea de la “distancia transaccional”, entendida como la separación física, psicológica y comunicativa entre el estudiante y la institución. Desde esta perspectiva, una intervención motivacional temprana puede reducir esa distancia y fortalecer el vínculo entre el estudiante y el equipo de apoyo universitario.

Otro aporte fundamental es el uso del **Student Probabilities Model (SPM)** como herramienta para seleccionar estudiantes con riesgo de no completar sus estudios. Este modelo predictivo calcula la probabilidad de que un estudiante permanezca en un curso y lo complete. Para ello, considera diferentes variables relacionadas con el perfil del estudiante, sus estudios previos, su progreso académico, el número de créditos matriculados, sus calificaciones, retiros anteriores, intentos fallidos y características del curso. En el artículo, los autores muestran que el SPM permitió identificar con mayor precisión a los estudiantes en riesgo en comparación con indicadores tradicionales utilizados por los equipos de apoyo estudiantil.

Este punto es importante porque, antes de aplicar modelos predictivos, los equipos de apoyo solían seleccionar estudiantes en riesgo mediante indicadores aislados, como no tener

calificaciones formales, presentar progreso académico insuficiente, estar matriculados en más de 120 créditos o pertenecer a zonas de mayor privación socioeconómica. Aunque estos indicadores pueden ser útiles, no siempre permiten seleccionar adecuadamente a quienes realmente necesitan apoyo. El artículo demuestra que el SPM fue más efectivo al identificar estudiantes con baja probabilidad de completar sus estudios, permitiendo que los recursos institucionales se dirijan hacia quienes más los necesitan.

El aporte también se observa en el diseño experimental utilizado. Los autores realizaron un **ensayo controlado aleatorizado**, lo cual fortalece la validez del estudio porque permite comparar de manera más rigurosa los efectos de la intervención. En total, participaron estudiantes de pregrado de la Open University del Reino Unido identificados por el SPM como estudiantes con baja probabilidad de completar sus estudios. Estos estudiantes fueron asignados aleatoriamente a un grupo de control y a un grupo de intervención. El grupo de intervención recibió un mensaje de texto inicial, luego una llamada telefónica y, en caso de no ser contactado por teléfono, un correo electrónico. Esta organización permitió evaluar si la intervención motivacional generaba diferencias reales en la retención.

Otro aporte relevante es que la intervención fue sencilla, de bajo costo y aplicable a gran escala. No se trató de una intervención compleja basada en plataformas sofisticadas, sino de una estrategia de comunicación directa y humana. El mensaje de texto avisaba al estudiante que sería contactado; la llamada buscaba conocer cómo se sentía frente al inicio de sus estudios, si tenía dudas, si contaba con la información necesaria y si necesitaba ayuda; y el correo funcionaba como seguimiento cuando no era posible establecer contacto telefónico. Este diseño muestra que, en ocasiones, acciones simples pueden tener un impacto significativo cuando se aplican a los estudiantes adecuados y en el momento oportuno.

El artículo aporta también al destacar el papel de los **Student Support Teams (SSTs)**. Estos equipos cumplen una función clave en la educación a distancia porque monitorean, orientan y acompañan a los estudiantes durante su trayectoria académica. Sin embargo, debido a la cantidad de alumnos y a la limitación de recursos humanos, no siempre es posible contactar a todos los estudiantes que podrían necesitar ayuda. En este sentido, el SPM ayuda a los SSTs a priorizar sus esfuerzos. El aporte del artículo consiste en mostrar que la analítica predictiva puede mejorar la administración del apoyo estudiantil, haciendo que el trabajo de los equipos sea más focalizado, eficiente y basado en evidencia.

Los resultados del estudio constituyen otro aporte significativo. La intervención produjo mejores resultados de retención en el grupo intervenido en comparación con el grupo de control. Los autores encontraron diferencias estadísticamente significativas en varios hitos del curso, como el inicio del curso, el 25 %, el 50 %, el 100 % de los puntos de responsabilidad financiera y la finalización del curso. En la finalización, el grupo de intervención alcanzó una proporción mayor de estudiantes que completaron el curso frente al grupo de control. Esto demuestra que una intervención motivacional temprana, guiada por analítica predictiva, puede contribuir a mejorar la permanencia estudiantil.

Un aspecto importante del aporte es que la intervención fue aplicada **antes del inicio del curso**, aproximadamente seis semanas antes. Esto refuerza la idea de que el apoyo temprano puede ser decisivo en la educación a distancia. Muchas veces, las instituciones intervienen cuando el estudiante ya presenta baja participación, no entrega tareas o está cerca de abandonar. En cambio, este estudio muestra que es posible actuar antes de que el problema se manifieste con mayor gravedad. Así, el artículo aporta una perspectiva preventiva y no solo reactiva del apoyo estudiantil.

El estudio también aporta al comparar diferentes formas de contacto. Los autores analizaron si las llamadas telefónicas o los correos electrónicos producían efectos distintos. Aunque en algunos hitos las llamadas parecieron tener mejores resultados y en otros los correos fueron

efectivos, no se encontró una diferencia concluyente entre ambos medios. Esto sugiere que tanto el contacto telefónico como el correo pueden ser útiles, siempre que formen parte de una estrategia de apoyo bien dirigida. Este hallazgo es práctico porque permite a las instituciones elegir medios de comunicación según sus recursos y capacidad operativa.

Otro aporte importante es que el artículo evidencia que la analítica predictiva puede mejorar la **administración institucional**. En lugar de depender únicamente del juicio manual o de listas generales de estudiantes, los equipos de apoyo pueden utilizar probabilidades de riesgo para organizar mejor su trabajo. Esto permite atender a estudiantes con mayor necesidad, reducir el uso ineficiente de recursos y aumentar el impacto de las acciones de acompañamiento. Por tanto, el aporte no es solo pedagógico, sino también administrativo y organizacional.

Desde una perspectiva crítica, el artículo también contribuye al debate sobre el uso responsable de Learning Analytics. Los autores muestran que las predicciones no deben utilizarse para etiquetar negativamente a los estudiantes, sino para ofrecer apoyo. En este sentido, el estudiante clasificado como “en riesgo” no es tratado como un problema, sino como una persona que puede beneficiarse de una comunicación temprana, orientación y motivación. Esta visión es importante porque coloca la analítica predictiva al servicio del acompañamiento humano y no de la vigilancia institucional.

Además, el estudio aporta evidencia sobre la importancia de combinar tecnología y apoyo humano. El modelo predictivo identifica estudiantes con riesgo, pero la intervención depende de equipos de apoyo que se comunican con ellos, escuchan sus preocupaciones y ofrecen orientación. Esto demuestra que la tecnología por sí sola no resuelve el problema de la retención; necesita estar integrada en una estrategia institucional donde participen personas capacitadas para interpretar los datos y actuar de manera adecuada.

Finalmente, el aporte general del artículo puede resumirse en tres dimensiones. Primero, aporta una dimensión predictiva, al utilizar el SPM para identificar estudiantes con baja probabilidad de completar sus estudios. Segundo, aporta una dimensión interventiva, al aplicar mensajes, llamadas y correos para reforzar la motivación y la permanencia. Tercero, aporta una dimensión administrativa, al mostrar que los equipos de apoyo pueden usar la analítica predictiva para dirigir mejor sus recursos. En conjunto, el artículo demuestra que las PLA pueden tener un impacto real cuando se convierten en acciones concretas, tempranas y centradas en el estudiante. Por ello, esta investigación es valiosa para instituciones de educación a distancia que buscan mejorar la retención, optimizar el apoyo estudiantil y fortalecer la finalización de los cursos mediante decisiones basadas en datos.

Proceso para obtener el aporte

El proceso seguido por los autores para obtener su aporte se basó en la aplicación de un **ensayo controlado aleatorizado** orientado a comprobar si la analítica predictiva del aprendizaje podía mejorar la selección de estudiantes en riesgo y apoyar intervenciones motivacionales en educación a distancia. Para ello, primero identificaron una problemática institucional concreta: los equipos de apoyo estudiantil necesitaban contactar a estudiantes con probabilidad de abandonar o no completar sus cursos, pero los métodos tradicionales de selección se basaban en indicadores aislados y no siempre permitían priorizar adecuadamente los recursos disponibles.

En primer lugar, los autores utilizaron el **Student Probabilities Model (SPM)**, un modelo predictivo basado en regresión logística que estima la probabilidad de que un estudiante alcance determinados hitos del curso, permanezca matriculado y llegue a completarlo. Este modelo considera variables relacionadas con el perfil del estudiante, estudios previos, progreso académico, número de créditos, calificaciones, retiros anteriores, intentos fallidos, características del curso y otros factores institucionales. Antes de aplicar la intervención, los

autores compararon el SPM con los criterios tradicionales usados por los equipos de apoyo, como no tener calificaciones formales, presentar progreso académico insuficiente, estar matriculado en más de 120 créditos o pertenecer a zonas de mayor privación socioeconómica. El SPM mostró una mayor capacidad para identificar estudiantes que finalmente no completarían sus estudios.

Luego, los autores seleccionaron a estudiantes con una probabilidad de finalización ubicada entre **31 % y 40 %**, porque representaban un grupo en riesgo, pero con posibilidades reales de beneficiarse de una intervención motivacional. Esta decisión también respondió a criterios prácticos, ya que los equipos de apoyo estudiantil tenían recursos limitados y necesitaban concentrar sus esfuerzos en un grupo manejable. A partir de esta selección, se conformó la muestra del estudio, integrada por estudiantes de pregrado de la Open University del Reino Unido.

Posteriormente, los estudiantes fueron asignados aleatoriamente a dos grupos: un **grupo de control** y un **grupo de intervención**. El grupo de control recibió el apoyo habitual de la institución, mientras que el grupo de intervención recibió una estrategia adicional de contacto motivacional. Esta intervención consistió primero en un mensaje de texto que avisaba al estudiante que sería contactado por teléfono; después se realizó una llamada telefónica para conversar sobre cómo se sentía respecto al inicio del curso, si tenía dudas, si contaba con la información necesaria y si necesitaba apoyo. En los casos en que no se logró contacto telefónico, se envió un correo electrónico de seguimiento.

Finalmente, los autores evaluaron el efecto de la intervención comparando ambos grupos en diferentes hitos del curso: inicio, 25 %, 50 %, 100 % de los puntos de responsabilidad financiera y finalización. Para analizar los resultados, utilizaron pruebas de **Chi-cuadrado**, verificando si existían diferencias estadísticamente significativas entre el grupo de control y el grupo intervenido. De esta manera, el aporte fue obtenido mediante un proceso riguroso que combinó predicción del riesgo, selección focalizada de estudiantes, intervención motivacional temprana y evaluación experimental de los resultados de retención.

Proceso para resolver el problema

El proceso para resolver el problema planteado en el artículo parte de una dificultad central en la educación a distancia: muchos estudiantes abandonan o no completan sus cursos, pero las instituciones no siempre logran identificarlos y apoyarlos a tiempo. En este contexto, los autores proponen utilizar la **analítica predictiva del aprendizaje** no solo como una herramienta para detectar estudiantes en riesgo, sino como una base para organizar intervenciones motivacionales tempranas, humanas y de bajo costo. La finalidad es mejorar la retención estudiantil y, al mismo tiempo, optimizar el trabajo administrativo de los equipos de apoyo.

Primero, los autores emplean el **Student Probabilities Model (SPM)**, un modelo predictivo que calcula la probabilidad de que un estudiante permanezca en el curso y llegue a completarlo. Este modelo utiliza variables relacionadas con el perfil del estudiante, estudios previos, progreso académico, cantidad de créditos matriculados, calificaciones, retiros anteriores y características del curso. Con esta información, el SPM permite identificar con mayor precisión a los estudiantes que tienen baja probabilidad de completar sus estudios, superando métodos tradicionales basados en indicadores aislados como bajo nivel de calificación previa, progreso académico insuficiente o condiciones socioeconómicas desfavorables.

Luego, los autores seleccionan a estudiantes con una probabilidad de finalización entre **31 % y 40 %**, debido a que representaban un grupo en riesgo, pero todavía con posibilidades reales de responder positivamente al apoyo institucional. Después, estos estudiantes fueron asignados aleatoriamente a un grupo de control y a un grupo de intervención. Esta asignación permitió evaluar de manera más objetiva si la intervención motivacional producía efectos positivos en la

retención, evitando que los resultados dependieran únicamente de características previas de los estudiantes.

La intervención aplicada fue sencilla, pero estratégicamente diseñada. Primero, los estudiantes del grupo de intervención recibieron un mensaje de texto informándoles que serían contactados por la universidad. Luego, los equipos de apoyo estudiantil realizaron llamadas telefónicas para preguntar cómo se sentían al iniciar el curso, si tenían dudas, si contaban con la información necesaria y si necesitaban orientación. Cuando no se logró contacto por teléfono, se envió un correo electrónico. Esta comunicación buscó reducir la distancia entre el estudiante y la institución, reforzar la motivación, resolver dudas iniciales y hacer visible la disponibilidad de apoyo.

Finalmente, para comprobar si el problema se estaba resolviendo, los autores compararon la permanencia del grupo de control y del grupo intervenido en distintos hitos del curso: inicio, 25 %, 50 %, 100 % y finalización. Los resultados mostraron diferencias estadísticamente significativas a favor del grupo intervenido, lo que indica que la estrategia ayudó a que más estudiantes continuaran y completaran sus estudios. Así, el problema se resolvió conectando tres elementos: predicción del riesgo mediante PLA, intervención motivacional temprana y evaluación rigurosa de la retención. El aporte central es que la analítica predictiva se convierte en una herramienta práctica para dirigir apoyo humano hacia quienes más lo necesitan.

Métricas y resultados

En el artículo, las métricas principales se centraron en la **retención estudiantil** y la **finalización del curso**. Para evaluar el impacto de la intervención, los autores compararon el grupo de control y el grupo intervenido en diferentes hitos académicos: inicio del curso, 25 %, 50 %, 100 % de los puntos de responsabilidad financiera y finalización. Además, utilizaron pruebas de **Chi-cuadrado** para determinar si las diferencias entre ambos grupos eran estadísticamente significativas. También se evaluó la capacidad del **Student Probabilities Model (SPM)** para identificar estudiantes en riesgo, comparándolo con indicadores tradicionales usados por los equipos de apoyo estudiantil.

Los resultados mostraron que el **SPM** fue más efectivo para seleccionar estudiantes en riesgo que varios criterios tradicionales. Por ejemplo, el modelo identificó correctamente un **55 %** de estudiantes que no completaron sus cursos, superando indicadores como no tener calificaciones formales, tener más de 120 créditos o pertenecer a zonas de bajo índice socioeconómico. En cuanto a la intervención motivacional, el grupo intervenido obtuvo mejores resultados de retención en todos los hitos evaluados. Al inicio del curso, permaneció registrado el **94.2 %** del grupo de intervención frente al **87.7 %** del grupo de control. En el 50 % del curso, continuaba el **88.1 %** del grupo intervenido frente al **73.6 %** del grupo de control. Finalmente, completó el curso el **56.1 %** del grupo intervenido frente al **45.9 %** del grupo de control.

Estos resultados evidencian que la combinación de **analítica predictiva** e **intervenciones motivacionales** mediante texto, llamada o correo tuvo un efecto positivo en la permanencia estudiantil. Además, la estrategia permitió a los equipos de apoyo dirigir sus recursos hacia estudiantes con mayor necesidad, mejorando la administración del acompañamiento a escala y con bajo costo.

Observaciones/críticas

Una observación importante sobre el artículo es que presenta un aporte práctico y bien fundamentado, porque no se limita a explicar el potencial de la **analítica predictiva del aprendizaje**, sino que demuestra su aplicación mediante una intervención real con estudiantes de educación a distancia. Su mayor fortaleza está en conectar el modelo predictivo **Student Probabilities Model (SPM)** con acciones concretas de apoyo, como mensajes de texto,

llamadas telefónicas y correos electrónicos. Además, el uso de un **ensayo controlado aleatorizado** fortalece la validez del estudio, ya que permite comparar de manera más rigurosa el grupo intervenido con el grupo de control.

Sin embargo, una crítica relevante es que la intervención se aplicó en una sola institución, la **Open University del Reino Unido**, por lo que sus resultados podrían variar en otros contextos educativos, especialmente en universidades presenciales, instituciones con menor infraestructura tecnológica o sistemas educativos con características diferentes. Además, aunque la intervención mejoró la retención, no queda completamente claro cuál de los medios de contacto fue más efectivo, ya que las llamadas y los correos mostraron resultados positivos en distintos momentos del curso, pero sin diferencias concluyentes entre ambos.

Otra limitación es que la intervención fue principalmente motivacional y administrativa, no pedagógica. Es decir, ayudó a mantener el contacto con los estudiantes y reforzar su permanencia, pero no necesariamente abordó de manera directa dificultades académicas específicas, como comprensión de contenidos, desarrollo de habilidades o mejora del rendimiento. Por ello, futuras investigaciones podrían combinar intervenciones motivacionales con tutorías académicas personalizadas.

A pesar de estas limitaciones, el artículo es valioso porque demuestra que la analítica predictiva puede ser útil cuando se usa para apoyar al estudiante y no solo para clasificarlo como “en riesgo”. Su principal fortaleza está en mostrar que los datos pueden orientar una intervención humana, temprana, focalizada y de bajo costo para mejorar la retención estudiantil.

38. ARTÍCULO 38

Author (s): Marc Philipp Janson; Stefan Janke

Título of paper: The influence of e-learning on exam performance and the role of achievement goals in shaping learning patterns

Journal: International Journal of Educational Technology in Higher Education

Volume (issue): Volume 21, Article 56

pag – pag (year): pp. 1–22 (2024)

Estado del arte

El uso de entornos digitales de aprendizaje se ha convertido en una estrategia cada vez más importante dentro de la educación superior, especialmente porque permite ofrecer oportunidades de estudio más flexibles, accesibles y adaptadas al ritmo de cada estudiante. Dentro de estos entornos, los **sistemas inteligentes de tutoría** ocupan un lugar relevante, ya que proporcionan ejercicios, retroalimentación correctiva, repetición de contenidos y actividades ajustadas al nivel de habilidad del estudiante. La literatura previa ha mostrado que estos sistemas pueden favorecer el aprendizaje, mejorar el desempeño académico y ofrecer apoyo adicional fuera del aula tradicional. Además, al estar disponibles mediante dispositivos personales, pueden ampliar las oportunidades de práctica y reducir ciertas brechas asociadas a la falta de acceso a tutorías presenciales.

Sin embargo, aunque los sistemas inteligentes de tutoría ofrecen recursos valiosos, su efectividad depende en gran medida del uso que hacen los estudiantes. En los ambientes digitales, el aprendizaje suele ser más autónomo y autorregulado, porque el estudiante decide cuándo ingresar, cuánto tiempo practicar, cómo distribuir sus sesiones y qué tan cerca del examen empieza a estudiar. Por esta razón, la investigación actual no solo se interesa por saber si las plataformas digitales mejoran el rendimiento, sino también por comprender **por qué y cómo los estudiantes las utilizan**. Este punto es fundamental, porque incluso una herramienta bien diseñada puede tener poco impacto si los estudiantes la usan tarde, de manera irregular o sin una motivación clara.

La literatura sobre aprendizaje autorregulado ha señalado que no basta con medir el tiempo total de estudio. También es importante analizar los **patrones de aprendizaje**, como la distribución del tiempo, la constancia de uso y el retraso en el inicio de las actividades. Diversos estudios sobre práctica distribuida indican que estudiar en sesiones repartidas a lo largo del tiempo suele ser más beneficioso que concentrar el estudio en pocos días. De manera similar, la literatura sobre procrastinación sostiene que retrasar las actividades de aprendizaje puede afectar negativamente el rendimiento académico. En este sentido, los datos de registro o **log files** de las plataformas digitales permiten observar el comportamiento real del estudiante, más allá de lo que declara en encuestas.

Otro enfoque relevante para comprender el uso de estas herramientas es la **teoría de metas de logro**. Esta teoría sostiene que los estudiantes se orientan hacia el aprendizaje de distintas maneras. Algunos tienen metas de dominio o aprendizaje, centradas en comprender, mejorar y desarrollar competencias; otros poseen metas de desempeño, enfocadas en obtener buenas calificaciones, superar a sus compañeros o demostrar capacidad; y también existen metas de evitación del trabajo, donde el estudiante busca reducir el esfuerzo. Estas metas pueden influir en las estrategias que el estudiante elige, en su persistencia y en la forma en que distribuye su tiempo de estudio. Por ejemplo, las metas de dominio suelen relacionarse con mayor persistencia y procesamiento profundo, mientras que las metas de evitación del trabajo se asocian con menor compromiso y mayor tendencia a postergar.

El artículo analizado se ubica precisamente en la intersección entre aprendizaje digital, motivación y rendimiento académico. Los autores señalan que todavía existe poca claridad sobre cómo las metas de logro influyen en el uso de sistemas inteligentes de tutoría y cómo esos patrones de uso se relacionan con el desempeño en exámenes. Además, proponen que no basta con considerar las metas del estudiante; también es necesario analizar si el estudiante cree que la herramienta digital es útil para alcanzar dichas metas. Esta idea se apoya en la teoría expectativa-valor, según la cual una persona se compromete con una actividad cuando valora el resultado y cree que esa actividad le ayudará a conseguirlo.

En este marco, los autores plantean que el comportamiento en e-learning puede depender tanto de las metas personales como de la **instrumentalidad percibida** del sistema inteligente de tutoría. Por ejemplo, un estudiante con fuertes metas de dominio podría usar más la plataforma si considera que esta le ayuda realmente a comprender el contenido. Del mismo modo, un estudiante orientado a obtener buenas notas podría utilizar el sistema si cree que este le permitirá prepararse mejor para el examen. Esta integración entre metas de logro e instrumentalidad percibida representa una contribución importante al estado del arte, porque permite explicar no solo la motivación general del estudiante, sino también su decisión concreta de usar una herramienta digital.

El estudio también responde a una necesidad metodológica actual: aprovechar los datos objetivos de uso de plataformas digitales para comprender el aprendizaje. En lugar de depender únicamente de autoinformes, los autores analizaron datos de registro de **91 estudiantes universitarios** que utilizaron un sistema inteligente de tutoría para prepararse para un examen de estadística. A partir de esos registros, evaluaron variables como el tiempo total de aprendizaje, la distribución del aprendizaje y el retraso en el inicio o concentración de las actividades. Esta aproximación permite observar con mayor precisión cómo se comportan los estudiantes en un entorno real de aprendizaje digital.

En síntesis, el estado del arte muestra que los sistemas inteligentes de tutoría son herramientas prometedoras para apoyar el aprendizaje en educación superior, pero su impacto depende de los patrones de uso y de la motivación del estudiante. La investigación previa ha demostrado la importancia del aprendizaje autorregulado, la práctica distribuida y la prevención de la procrastinación. No obstante, aún se requiere comprender mejor cómo las metas de logro y las creencias sobre la utilidad de la herramienta influyen en el comportamiento digital. El artículo

contribuye a esta línea al integrar teoría motivacional, datos objetivos de e-learning y rendimiento en exámenes, mostrando que el análisis del comportamiento en plataformas digitales debe considerar tanto lo tecnológico como lo psicológico.

Motivación del autor

La motivación principal de los autores surge de la necesidad de comprender mejor **por qué y cómo los estudiantes utilizan los sistemas inteligentes de tutoría** dentro de entornos digitales de aprendizaje. Aunque investigaciones previas han demostrado que estas herramientas pueden mejorar el aprendizaje y apoyar la preparación académica, todavía no está completamente claro qué patrones de uso son más beneficiosos ni qué factores motivacionales explican que algunos estudiantes las utilicen de forma constante, temprana y efectiva, mientras que otros las usan tarde o de manera limitada.

Por esta razón, los autores buscan relacionar el uso del e-learning con variables psicológicas, especialmente las **metas de logro** y la **instrumentalidad percibida** del sistema. Su interés no es solo medir si la herramienta mejora el rendimiento en el examen, sino explicar cómo las metas de aprendizaje, desempeño o evitación del trabajo influyen en el tiempo de estudio, la distribución del aprendizaje y el retraso en el uso de la plataforma. En ese sentido, el estudio pretende aportar una comprensión más profunda del aprendizaje autorregulado en ambientes digitales, mostrando que la efectividad de un sistema inteligente de tutoría depende no solo de su diseño tecnológico, sino también de la motivación del estudiante y de la creencia de que la herramienta realmente le ayudará a alcanzar sus objetivos académicos.

Descripción del aporte del autor

El principal aporte de Janson y Janke consiste en analizar cómo el uso de un **sistema inteligente de tutoría** se relaciona con el rendimiento en un examen universitario, y cómo las **metas de logro** de los estudiantes influyen en sus patrones de aprendizaje dentro de un entorno digital. El artículo no se limita a afirmar que el e-learning puede mejorar el rendimiento académico, sino que intenta explicar por qué algunos estudiantes aprovechan mejor estas herramientas que otros. Para ello, los autores combinan datos objetivos de uso de la plataforma, rendimiento real en examen y variables motivacionales, lo que permite ofrecer una visión más completa del aprendizaje digital en educación superior.

Uno de los aportes centrales del estudio es que desplaza la atención desde la simple disponibilidad de tecnología educativa hacia el análisis del **comportamiento real del estudiante**. Muchas investigaciones sobre plataformas digitales se enfocan en determinar si una herramienta funciona o no, pero prestan menos atención a la manera en que los estudiantes la utilizan. En este caso, los autores sostienen que el impacto de un sistema inteligente de tutoría depende de los patrones de uso: cuánto tiempo estudia el estudiante, cómo distribuye ese tiempo y si comienza a usar la herramienta con anticipación o de manera tardía. Este enfoque es importante porque una plataforma puede estar bien diseñada, pero su efectividad disminuye si el estudiante la usa únicamente poco antes del examen.

El artículo aporta evidencia sobre la importancia del **aprendizaje autorregulado** en los entornos digitales. Los sistemas inteligentes de tutoría suelen utilizarse fuera del aula, sin supervisión directa del docente y en momentos elegidos por el propio estudiante. Por eso, su aprovechamiento depende de la capacidad del alumno para organizar su tiempo, mantener la constancia y evitar la postergación. Los autores analizan tres indicadores de comportamiento: el tiempo total de aprendizaje, la distribución del aprendizaje y el retraso del aprendizaje. Esta clasificación permite comprender mejor la calidad del uso de la plataforma, ya que no basta con saber si el estudiante ingresó o no al sistema; también importa cuándo lo hizo y cómo organizó su práctica.

Otro aporte relevante es el uso de **datos de registro o log files** del sistema inteligente de tutoría. En lugar de depender solamente de encuestas o percepciones del estudiante, los autores utilizaron datos objetivos generados por la plataforma. Estos registros permitieron calcular el tiempo real dedicado a las actividades, la distribución diaria del aprendizaje y el momento en que los estudiantes concentraron la mayor parte de su estudio. Este enfoque fortalece la investigación, porque reduce la dependencia de respuestas subjetivas y permite observar el comportamiento digital de los estudiantes en condiciones reales de preparación para un examen.

El estudio también aporta una integración teórica importante entre la **teoría de metas de logro** y la **teoría expectativa-valor**. La teoría de metas de logro explica qué tipo de objetivos persiguen los estudiantes cuando aprenden. Algunos buscan dominar la tarea y cumplir bien los requisitos del curso; otros desean aprender y mejorar sus competencias; otros buscan demostrar capacidad ante los demás o evitar pareceres incompetentes; y otros intentan reducir el esfuerzo. Sin embargo, los autores señalan que las metas por sí solas no explican completamente el uso de una herramienta digital. También es necesario considerar si el estudiante cree que la herramienta es útil para alcanzar esas metas. Por ello, incorporan la idea de **instrumentalidad percibida**, es decir, la creencia de que el sistema inteligente de tutoría ayuda a conseguir los objetivos académicos.

Este aporte teórico es significativo porque permite explicar mejor la decisión de usar o no usar una plataforma de e-learning. Por ejemplo, un estudiante puede tener una fuerte meta de aprender, pero si considera que el sistema no le ayuda a comprender mejor el contenido, quizá no lo utilice con frecuencia. De la misma manera, un estudiante que quiere cumplir bien con los requisitos del curso puede usar más la plataforma si cree que esta le permite prepararse mejor para el examen. Así, el artículo muestra que la motivación no debe analizarse de forma aislada, sino en relación con la percepción que tiene el estudiante sobre la utilidad concreta de la herramienta.

Otro aporte importante es que el estudio se realizó en un contexto real de educación superior. Los autores trabajaron con **91 estudiantes universitarios alemanes** que utilizaron un sistema inteligente de tutoría como preparación para un examen de estadística en un curso de pregrado en psicología. La investigación tuvo un diseño de campo, lo que significa que los datos fueron obtenidos en una situación auténtica de aprendizaje, no en un laboratorio artificial. Esto aumenta la relevancia práctica del estudio, porque permite observar cómo los estudiantes se comportan cuando realmente están preparándose para un examen importante.

El sistema inteligente de tutoría utilizado ofrecía ejercicios de práctica con retroalimentación correctiva. Además, tenía características de **variabilidad** y **adaptividad**. La variabilidad se reflejaba en la generación de problemas con valores diferentes y opciones de respuesta modificadas, evitando que el estudiante memorizara respuestas sin comprender los conceptos. La adaptividad permitía ajustar la práctica según la probabilidad de que el estudiante resolviera correctamente los ejercicios, repitiendo contenidos difíciles y reduciendo la insistencia en los ya dominados. Este tipo de herramienta resulta valiosa porque no solo entrega ejercicios, sino que adapta la experiencia de práctica al progreso del estudiante.

Desde el punto de vista metodológico, los autores aportan un modelo de análisis basado en **ecuaciones estructurales**. Este modelo permitió examinar las relaciones entre metas de logro, creencias de instrumentalidad, patrones de aprendizaje y rendimiento en el examen. En otras palabras, los autores no analizaron cada variable por separado, sino que propusieron un modelo explicativo para comprender cómo la motivación puede influir en el comportamiento digital y cómo ese comportamiento puede relacionarse con el desempeño académico. Este enfoque aporta mayor profundidad al estudio, porque busca explicar mecanismos y no solo asociaciones simples.

Uno de los hallazgos más importantes del artículo es que el **retraso del aprendizaje** fue el principal predictor del rendimiento en el examen. Los estudiantes que comenzaron a usar el sistema de tutoría demasiado tarde o concentraron gran parte de su práctica cerca del examen obtuvieron peores resultados. En cambio, el tiempo total de uso y la distribución del tiempo no mostraron efectos directos significativos sobre el rendimiento. Este resultado aporta una idea práctica muy importante: no siempre estudiar más tiempo en la plataforma garantiza mejores resultados; lo decisivo puede ser empezar a usarla con suficiente anticipación para familiarizarse con el sistema, aprovechar la retroalimentación y beneficiarse de la práctica adaptativa.

Este aporte tiene implicaciones directas para docentes e instituciones. Si se implementan sistemas inteligentes de tutoría, no basta con ponerlos a disposición de los estudiantes; también es necesario orientar su uso desde el inicio del curso. Los docentes pueden recomendar que los estudiantes comiencen a practicar temprano, explicar los beneficios de la herramienta y advertir sobre los riesgos de postergar su uso hasta los días previos al examen. De esta manera, el estudio ofrece una orientación práctica para mejorar la efectividad del e-learning en la preparación académica.

El artículo también aporta evidencia sobre la relación entre metas de logro y patrones de uso. Los autores encontraron que las **metas de aproximación a la tarea**, es decir, el deseo de cumplir bien con los requisitos del curso, se asociaron con mayor tiempo de aprendizaje cuando los estudiantes percibían que el sistema era útil para alcanzar esa meta. Esto indica que los estudiantes orientados a dominar la tarea pueden involucrarse más con el sistema si creen que la herramienta les ayuda directamente a prepararse. Por tanto, una estrategia pedagógica útil sería mostrar explícitamente cómo el sistema de tutoría contribuye al éxito en el curso y al dominio de los contenidos.

Asimismo, los autores observaron que las **metas de evitación de apariencia**, relacionadas con evitar parecer incompetente, se asociaron con un aprendizaje más concentrado o menos distribuido. Esto sugiere que algunos estudiantes motivados por el miedo a quedar mal pueden acumular actividades de estudio en periodos cercanos al examen. Este hallazgo es relevante porque muestra que no todas las metas de logro conducen a estrategias de aprendizaje adaptativas. Algunas orientaciones motivacionales pueden llevar a formas de estudio menos efectivas, especialmente cuando se combinan con ansiedad, presión social o preocupación por la imagen académica.

Otro aporte del estudio es que cuestiona una idea simplista sobre el e-learning: la creencia de que más uso siempre equivale a mejor rendimiento. Los resultados muestran que la relación entre uso de la plataforma y éxito académico es más compleja. El momento de uso, la familiaridad con la herramienta, el tipo de motivación y la percepción de utilidad influyen en la forma en que el estudiante se beneficia del sistema. Por ello, el artículo invita a analizar los datos de plataformas digitales con mayor cuidado, considerando no solo la cantidad de clics o minutos, sino también los patrones temporales y las variables psicológicas que explican el comportamiento.

El estudio también contribuye al campo de la investigación con log files. Los autores muestran que los registros digitales pueden ser una fuente rica para comprender el aprendizaje, pero también advierten que deben interpretarse con apoyo de teorías psicológicas. Los datos por sí solos no explican completamente por qué un estudiante estudia tarde, distribuye su práctica o usa poco la herramienta. Para comprender esos patrones, es necesario vincularlos con teorías de motivación, autorregulación y expectativas de utilidad. Este enfoque fortalece la investigación en analítica del aprendizaje porque integra evidencia conductual y explicación teórica.

Desde una perspectiva práctica, el artículo aporta recomendaciones para mejorar la implementación de sistemas inteligentes de tutoría. Primero, los docentes deben introducir la herramienta desde etapas tempranas del curso, no solo como recurso opcional antes del examen. Segundo, deben comunicar claramente su utilidad para dominar contenidos y cumplir con los objetivos de la asignatura. Tercero, deben ayudar a los estudiantes a evitar el retraso del aprendizaje, promoviendo rutinas de uso más constantes. Cuarto, las instituciones deben considerar que las herramientas digitales no sustituyen la autorregulación; más bien, la requieren. Un sistema inteligente puede ofrecer retroalimentación y ejercicios adaptativos, pero el estudiante necesita motivación y organización para aprovecharlo.

El aporte del artículo también se encuentra en su carácter pre-registrado, lo que fortalece la transparencia de la investigación. Al declarar previamente sus preguntas e hipótesis, los autores aumentan la confianza en el proceso analítico y reducen el riesgo de interpretar los datos de manera oportunista. Este aspecto metodológico es importante en la investigación educativa actual, donde cada vez se valora más la claridad, la reproducibilidad y la transparencia de los estudios empíricos.

No obstante, el valor del artículo no está en presentar una solución definitiva, sino en abrir una línea de investigación más fina sobre la relación entre motivación y aprendizaje digital. Los autores reconocen que el uso de sistemas inteligentes de tutoría no ocurre en el vacío: los estudiantes también pueden estudiar con apuntes, grupos, lecturas, clases o materiales adicionales. Por ello, los patrones registrados en la plataforma muestran una parte importante, pero no completa, del proceso de aprendizaje. Aun así, el estudio demuestra que los datos de uso digital, cuando se combinan con teoría motivacional, pueden revelar aspectos valiosos sobre la preparación académica.

En conclusión, el aporte de Janson y Janke consiste en demostrar que la efectividad del e-learning depende de la interacción entre tecnología, motivación y autorregulación. El estudio evidencia que los sistemas inteligentes de tutoría pueden apoyar la preparación académica, pero sus beneficios dependen de cómo y cuándo los estudiantes los utilizan. El hallazgo más relevante es que retrasar el uso de la herramienta se asocia con menor rendimiento en el examen, mientras que las metas de logro y la instrumentalidad percibida ayudan a explicar diferencias en los patrones de aprendizaje. De esta manera, el artículo contribuye a una comprensión más humana y psicológica del e-learning, mostrando que la tecnología educativa solo alcanza su verdadero potencial cuando se integra con hábitos de estudio adecuados, orientación docente y motivación académica bien dirigida.

Proceso para obtener el aporte

Para obtener su aporte, los autores desarrollaron un estudio de campo pre-registrado en el que combinaron datos motivacionales, registros objetivos de uso de una plataforma digital y rendimiento real en examen. El propósito fue analizar cómo los estudiantes utilizan un **sistema inteligente de tutoría** durante la preparación académica y qué papel cumplen sus **metas de logro** y sus creencias sobre la utilidad del sistema en la formación de patrones de aprendizaje. Para ello, trabajaron con **91 estudiantes universitarios alemanes** de un curso de estadística en psicología, quienes utilizaron el sistema como herramienta de preparación para el examen final.

El primer paso fue seleccionar el contexto de estudio. Los autores eligieron un sistema inteligente de tutoría porque este tipo de herramienta permite ofrecer ejercicios de práctica, retroalimentación correctiva y adaptación al nivel del estudiante. El sistema generaba ejercicios variables para evitar que los alumnos memorizaran respuestas y, además, ajustaba la práctica según la probabilidad de que el estudiante resolviera correctamente los ejercicios. De esta manera, el sistema permitía observar un comportamiento real de aprendizaje autorregulado, ya que los estudiantes decidían cuándo ingresar, cuánto tiempo practicar y cómo distribuir sus actividades antes del examen.

El segundo paso fue recolectar información sobre las **metas de logro** y las **creencias de instrumentalidad**. Al inicio del uso del sistema, los estudiantes respondieron cuestionarios sobre distintos tipos de metas: metas de aproximación a la tarea, metas de aprendizaje, metas de apariencia, metas normativas, metas de evitación y metas de evitación del trabajo. Además, los autores midieron si los estudiantes consideraban que el sistema inteligente de tutoría era útil para alcanzar esas metas. Este paso fue importante porque permitió vincular el comportamiento en la plataforma con variables psicológicas relacionadas con la motivación académica.

El tercer paso fue recopilar los **datos de registro** del sistema. A partir del log files, los autores calcularon tres indicadores principales de aprendizaje. El primero fue el **tiempo total de aprendizaje**, medido como la cantidad de tiempo que cada estudiante dedicó a las actividades dentro del sistema. El segundo fue la **distribución del aprendizaje**, relacionada con qué tan repartido estuvo el estudio a lo largo de los días disponibles. El tercero fue el **retraso del aprendizaje**, calculado según el momento en que el estudiante alcanzó el 50% de sus actividades acumuladas antes del examen. Estos indicadores permitieron analizar no solo cuánto estudiaban los estudiantes, sino también cuándo y cómo organizaban su práctica.

El cuarto paso fue vincular los datos de uso con el **rendimiento en el examen**. Después de terminado el semestre, los autores relacionaron los registros del sistema con los resultados reales del examen, siempre con consentimiento informado de los estudiantes. Posteriormente, aplicaron modelos de ecuaciones estructurales para analizar las relaciones entre metas de logro, instrumentalidad percibida, patrones de aprendizaje y desempeño académico. Este análisis permitió evaluar si las metas influían en el comportamiento digital y si ese comportamiento se asociaba con mejores o peores resultados.

Finalmente, mediante este proceso, los autores identificaron que el **retraso del aprendizaje** fue el patrón más importante asociado con el rendimiento en el examen. Los estudiantes que postergaron el uso del sistema hasta momentos cercanos a la evaluación tendieron a obtener peores resultados. Además, encontraron que ciertas metas de logro, como las metas de aproximación a la tarea, podían relacionarse con mayor tiempo de uso cuando los estudiantes percibían que la herramienta era útil. Así, el aporte se obtuvo al integrar teoría motivacional, datos objetivos de e-learning y rendimiento académico real para explicar cómo los estudiantes usan los sistemas inteligentes de tutoría.

Proceso para resolver el problema

Para resolver el problema de cómo influyen los entornos de **e-learning** en el rendimiento académico y cómo las metas de logro moldean los patrones de aprendizaje, los autores plantearon un estudio que unió tres elementos: motivación del estudiante, comportamiento real dentro de un sistema inteligente de tutoría y desempeño en el examen. El problema principal era que, aunque los sistemas inteligentes de tutoría han demostrado ser útiles para apoyar el aprendizaje, todavía no se comprende completamente por qué algunos estudiantes los usan de manera efectiva y otros los utilizan tarde, poco o de forma irregular. Por eso, los autores buscaron explicar el uso de la herramienta desde una perspectiva psicológica y no solamente tecnológica.

El primer paso fue analizar el aprendizaje digital como una actividad autorregulada. En este tipo de entornos, el estudiante decide cuándo estudiar, cuánto tiempo dedicar, qué ritmo seguir y si usa la herramienta desde el inicio o solo cerca del examen. Por ello, los autores no se limitaron a medir si el sistema fue utilizado, sino que observaron tres patrones específicos: **tiempo total de aprendizaje**, **distribución del aprendizaje** y **retraso del aprendizaje**. Esta decisión permitió evaluar la calidad del uso del sistema, ya que estudiar muchas horas no necesariamente garantiza buenos resultados si el estudiante concentra todo el esfuerzo al final.

El segundo paso fue incorporar las **metas de logro** como explicación del comportamiento del estudiante. Los autores consideraron que los alumnos pueden usar la plataforma por diferentes razones: dominar los contenidos, mejorar sus competencias, obtener una buena calificación, superar a otros, evitar pareceres incompetentes o reducir el esfuerzo. Además, añadieron la **instrumentalidad percibida**, es decir, la creencia de que el sistema inteligente de tutoría realmente ayuda a alcanzar esas metas. Con esto, el problema se abordó de manera más completa, porque el uso del e-learning depende tanto de la motivación personal como de la confianza en la utilidad de la herramienta.

El tercer paso fue recolectar datos reales de uso del sistema mediante **log files**. Estos registros permitieron conocer cuánto tiempo estudió cada estudiante, cómo distribuyó sus sesiones y en qué momento concentró la mayor parte de sus actividades antes del examen. Luego, estos datos fueron relacionados con los resultados reales del examen de estadística. Para analizar estas relaciones, los autores aplicaron modelos de ecuaciones estructurales, lo que permitió evaluar si las metas de logro y la instrumentalidad percibida influían en los patrones de aprendizaje y si estos patrones se relacionaban con el rendimiento.

Finalmente, los autores resolvieron el problema demostrando que el factor más relevante no fue simplemente estudiar más tiempo, sino **no retrasar el inicio del aprendizaje**. Los estudiantes que usaron el sistema demasiado tarde tendieron a obtener peores resultados en el examen. Además, encontraron que ciertas metas, como la aproximación a la tarea, podían aumentar el tiempo de uso cuando los estudiantes percibían que el sistema era útil para cumplir los requisitos del curso. Así, el estudio concluye que los sistemas inteligentes de tutoría pueden apoyar el rendimiento, pero su efectividad depende de que los estudiantes los usen de manera temprana, autorregulada y con una percepción clara de su utilidad académica.

Métricas y resultados

Para evaluar el estudio, los autores utilizaron datos de **91 estudiantes universitarios** que emplearon un sistema inteligente de tutoría para prepararse para un examen de estadística. Las variables principales fueron el **tiempo total de aprendizaje**, la **distribución del aprendizaje**, el **retraso del aprendizaje** y el **rendimiento en el examen**. El tiempo total de aprendizaje se calculó a partir de los registros de uso del sistema; la distribución del aprendizaje midió qué tan repartidas estuvieron las sesiones de estudio; y el retraso del aprendizaje indicó qué tan tarde el estudiante concentró la mayor parte de sus actividades antes del examen. Además, se aplicaron **modelos de ecuaciones estructurales** para analizar la relación entre metas de logro, instrumentalidad percibida, patrones de aprendizaje y desempeño académico.

Los resultados mostraron que los estudiantes usaron el sistema en promedio **19.66 horas**, aunque con variación considerable entre participantes. El hallazgo más relevante fue que el **retraso del aprendizaje predijo negativamente el rendimiento en el examen**, con coeficientes entre $\beta = -0.41$ y $\beta = -0.49$, lo que significa que quienes postergaron el uso del sistema obtuvieron peores resultados. En cambio, el tiempo total de aprendizaje y la distribución del tiempo no tuvieron efectos directos significativos sobre el rendimiento. También se encontró que el índice de aprendizaje del software se relacionó positivamente con el éxito en el examen ($r = .38$). Respecto a la motivación, las metas de aproximación a la tarea predijeron mayor tiempo de aprendizaje cuando los estudiantes percibían que el sistema era útil. En conjunto, los resultados indican que el uso temprano del e-learning es más importante que simplemente acumular muchas horas de estudio cerca del examen.

Observaciones/críticas

Una observación positiva del artículo es que ofrece una mirada más profunda sobre el uso del **e-learning**, porque no se limita a medir si el sistema inteligente de tutoría mejora el rendimiento, sino que analiza **cómo y cuándo** los estudiantes lo utilizan. Este enfoque es

valioso porque permite comprender que la efectividad de una plataforma digital no depende únicamente de su diseño tecnológico, sino también de la motivación, la autorregulación y los hábitos de estudio del estudiante. Además, el uso de **log files** fortalece la investigación, ya que permite observar comportamientos reales dentro del sistema y no solo respuestas declaradas por los estudiantes.

Sin embargo, también existen algunas limitaciones. En primer lugar, la muestra fue reducida, con solo **91 estudiantes**, y pertenecía a un curso específico de estadística en psicología, por lo que los resultados no pueden generalizarse automáticamente a otras carreras, asignaturas o plataformas. Además, más de la mitad de los participantes no autorizó vincular sus datos con el rendimiento del examen, lo que pudo afectar el análisis final. Otra crítica es que el estudio solo observa el comportamiento dentro del sistema inteligente de tutoría, pero no registra otras formas de estudio, como lectura de apuntes, trabajo en grupo o asistencia a clases. A pesar de ello, el artículo aporta evidencia importante: retrasar el uso de la plataforma se asocia con peores resultados, por lo que docentes e instituciones deberían promover el uso temprano y constante de estas herramientas digitales.

39. ARTÍCULO 39

Author (s): Dennis Fount; Julia Chen; Kin Cheung.

Title of paper: *Exploring language needs of college transfer students with learning analytics: towards a more equitable experience.*

Journal: *International Journal of Educational Technology in Higher Education.*

Volume (issue): 20(60).

pag – pag (year): 1–15 (2023).

Estado del arte

El estudio sobre las necesidades lingüísticas de los **estudiantes transferidos** o *college transfer students* se ha convertido en una línea relevante dentro de la educación superior, especialmente en contextos donde existen trayectorias alternativas para acceder a la universidad. Estos estudiantes suelen completar primero un programa subuniversitario, como un diploma superior o grado asociado, y luego ingresan a una licenciatura. Esta ruta amplía el acceso a la educación superior y puede favorecer la equidad; sin embargo, también genera desafíos particulares, porque los estudiantes transferidos no siempre llegan a la universidad con las mismas condiciones académicas, lingüísticas y administrativas que los estudiantes de ingreso directo.

De acuerdo con el artículo revisado, los estudiantes transferidos enfrentan diversos problemas asociados a su trayectoria educativa. Uno de ellos es la llamada **pérdida de créditos**, que ocurre cuando la universidad receptora no reconoce todos los créditos cursados previamente. Esto obliga al estudiante a matricularse en más asignaturas para cumplir los requisitos de graduación, aumentando su carga académica, el costo económico y la presión durante el semestre. Esta situación puede afectar con mayor fuerza a estudiantes de menores recursos, por lo que se convierte en un problema de equidad y accesibilidad educativa.

Otro concepto importante dentro del estado del arte es el **transfer shock**, que se refiere al conjunto de dificultades que experimentan los estudiantes al pasar de una institución de origen a una universidad. Estas dificultades pueden incluir adaptación a nuevas exigencias académicas, relación con docentes y compañeros, manejo de información institucional, carga de trabajo, integración social y comprensión de las normas universitarias. Aunque algunos estudios recientes también reconocen que los estudiantes transferidos pueden traer ventajas, como mayor madurez o mejores estrategias de estudio, la literatura coincide en que requieren un acompañamiento específico para lograr una experiencia universitaria más equitativa.

En el caso de Hong Kong, contexto del artículo, la vía de transferencia conocida como “2+2” permite que los estudiantes completen dos años de subgrado y luego ingresen al tercer año de una licenciatura. Esta ruta es competitiva y ofrece una segunda oportunidad para acceder a la universidad. Sin embargo, también implica que los estudiantes deben completar su grado en un tiempo limitado y con una carga académica considerable. Por ello, conocer sus necesidades reales es fundamental para que la universidad no solo abra el acceso, sino que también garantice condiciones adecuadas para la permanencia y el éxito académico.

Una necesidad especialmente relevante es el dominio del **inglés académico**. La literatura revisada por los autores indica que muchos estudiantes transferidos presentan menor confianza y menor competencia lingüística en inglés que los estudiantes de ingreso directo. Esto puede afectar no solo su desempeño en cursos de comunicación o escritura académica, sino también su rendimiento en otras asignaturas, ya que el inglés suele ser el medio principal para leer textos, redactar trabajos, realizar presentaciones y participar en actividades universitarias. Por ello, las dificultades lingüísticas pueden convertirse en una barrera transversal para el éxito académico.

En este contexto, la **Learning Analytics** aparece como una herramienta útil para analizar de manera más objetiva las trayectorias y necesidades de estos estudiantes. La analítica del aprendizaje permite recolectar, analizar y reportar datos sobre los estudiantes y sus contextos, con el propósito de comprender y mejorar el aprendizaje. Aunque muchos estudios sobre estudiantes transferidos han utilizado encuestas o entrevistas, el artículo destaca que todavía faltan investigaciones de mayor escala que utilicen datos institucionales y del sistema de gestión del aprendizaje para identificar patrones de éxito o riesgo en cursos específicos.

El artículo se ubica precisamente en esa brecha. A diferencia de investigaciones centradas en la finalización de grado, retención o promedio general, este estudio analiza el desempeño de los estudiantes transferidos en **cursos de lengua**. Para ello, utiliza datos de 706 estudiantes transferidos en Hong Kong, recuperados del registro académico universitario y del sistema de gestión del aprendizaje. Los autores buscan identificar qué factores predicen el éxito en cursos de lengua y comparar el desempeño de estos estudiantes con el de sus pares de ingreso directo.

El estado del arte muestra que factores como el GPA en la institución previa, la carga académica, los créditos requeridos para graduarse y la finalización de cursos de inglés pueden influir en el éxito universitario. Sin embargo, pocos estudios han examinado cómo estos factores afectan específicamente el rendimiento en cursos de comunicación académica. El artículo aporta al mostrar que el puntaje de inglés en exámenes públicos, el GPA actual, el GPA de graduación del programa subuniversitario y la carga de cursos son predictores importantes del éxito en cursos de lengua.

En síntesis, el estado del arte evidencia que los estudiantes transferidos representan una población con trayectorias educativas distintas, oportunidades importantes y desafíos particulares. La literatura reconoce problemas de carga académica, pérdida de créditos, adaptación universitaria y necesidades lingüísticas. Frente a ello, la analítica del aprendizaje permite comprender mejor sus dificultades mediante datos reales y orientar apoyos más justos. El artículo de Fong, Chen y Cheung aporta a esta línea al demostrar que la equidad en educación superior no depende solo de permitir el ingreso, sino también de identificar necesidades específicas y diseñar apoyos adecuados para que los estudiantes transferidos puedan tener éxito.

Motivación del autor

La motivación principal de los autores surge de la necesidad de comprender y atender mejor las dificultades que enfrentan los **estudiantes transferidos** en la educación superior, especialmente en relación con sus necesidades lingüísticas. Aunque la vía de transferencia permite que más estudiantes accedan a una licenciatura, este acceso no garantiza automáticamente una

experiencia equitativa. Muchos estudiantes llegan a la universidad después de completar un subgrado y deben adaptarse rápidamente a nuevas exigencias académicas, mayor carga de cursos, requisitos de graduación y uso intensivo del inglés académico.

Otra motivación importante es que investigaciones previas han señalado desafíos como la pérdida de créditos, el *transfer shock* y la baja confianza en el dominio del inglés, pero muchas de estas investigaciones se han basado principalmente en encuestas o entrevistas. Por ello, los autores buscan utilizar **Learning Analytics** para obtener una visión más amplia y basada en datos reales del registro académico y del sistema de gestión del aprendizaje. El objetivo es identificar qué factores predicen el éxito de los estudiantes transferidos en cursos de lengua y cómo se diferencian de los estudiantes de ingreso directo.

Finalmente, los autores se motivan por promover una experiencia universitaria más equitativa. Su intención no es solo describir las dificultades de los estudiantes transferidos, sino generar evidencia que permita diseñar apoyos concretos, como programas previos al semestre, secciones específicas de cursos de lengua, mejor planificación de carga académica y sistemas inteligentes de orientación. De esta manera, la investigación busca que la universidad no solo facilite el acceso, sino también la permanencia y el éxito académico.

Descripción del aporte del autor

El aporte principal de Dennis Fount, Julia Chen y Kin Cheung en el artículo “**Exploring language needs of college transfer students with learning analytics: towards a more equitable experience**” consiste en analizar, mediante **Learning Analytics**, las necesidades lingüísticas y académicas de los estudiantes transferidos en educación superior, con el propósito de identificar factores que influyen en su éxito en cursos de lengua y proponer medidas para una experiencia universitaria más equitativa. Este aporte es relevante porque no se limita a describir que los estudiantes transferidos tienen dificultades, sino que utiliza datos institucionales reales para comprender con mayor precisión qué variables afectan su desempeño y cómo la universidad puede apoyarlos mejor.

Uno de los aportes más importantes del artículo es que centra la atención en una población estudiantil con una trayectoria educativa distinta: los **college transfer students** o estudiantes transferidos. Estos estudiantes no ingresan directamente a la universidad después de la secundaria, sino que primero completan un programa subuniversitario, como un diploma superior o un grado asociado, y luego se incorporan a una licenciatura. Esta vía amplía el acceso a la educación superior, pero también genera desafíos particulares. Los autores muestran que la equidad no debe entenderse solo como la posibilidad de ingresar a la universidad, sino también como la capacidad de permanecer, adaptarse y tener éxito dentro de ella.

El artículo aporta al evidenciar que los estudiantes transferidos pueden enfrentar barreras estructurales. Una de ellas es la carga académica, relacionada con la cantidad de créditos que deben completar para graduarse. Cuando la universidad no reconoce suficientes créditos obtenidos en la institución previa, los estudiantes deben matricularse en más cursos durante el semestre. Esto puede afectar su tiempo, energía, rendimiento y bienestar académico. Por ello, los autores destacan que la experiencia de estos estudiantes no depende únicamente de sus habilidades individuales, sino también de decisiones institucionales sobre transferencia de créditos, planificación curricular y apoyo académico.

Otro aporte importante es que el estudio coloca las **necesidades lingüísticas** en el centro del análisis. En contextos universitarios donde el inglés es una lengua clave para leer, escribir, presentar trabajos y participar en cursos académicos, una menor competencia lingüística puede convertirse en una barrera para el aprendizaje. Los autores muestran que los estudiantes transferidos presentan niveles más bajos de desempeño lingüístico que los estudiantes de ingreso directo, especialmente en áreas como **lenguaje y vocabulario** y **habilidades de**

presentación. Esto significa que sus dificultades no se reducen únicamente a la escritura académica, sino que incluyen aspectos más generales de dominio del inglés.

El artículo también aporta al diferenciar entre **acceso y equidad real**. Permitir que un estudiante ingrese a una licenciatura mediante una vía alternativa es importante, pero no suficiente si luego debe enfrentar una carga excesiva, menor preparación lingüística o falta de apoyos adecuados. Desde esta perspectiva, el estudio plantea que las universidades deben observar con más atención las trayectorias de los estudiantes transferidos y no asumir que todos los estudiantes llegan con las mismas condiciones. Esta mirada es valiosa porque permite diseñar políticas más inclusivas y sensibles a las diferencias entre grupos estudiantiles.

Desde el punto de vista metodológico, el aporte de los autores está en utilizar **Learning Analytics** para analizar datos provenientes del registro académico y del sistema de gestión del aprendizaje. En lugar de basarse únicamente en entrevistas o encuestas, el estudio trabaja con información institucional de **706 estudiantes transferidos** que cursaron asignaturas de comunicación lingüística durante un periodo de dos años. Esta decisión permite obtener una visión más amplia y objetiva sobre los factores que predicen el éxito o riesgo académico en cursos de lengua.

Otro aporte relevante es la identificación de variables predictoras del desempeño en cursos de lengua. Los autores analizaron factores como la carga académica del semestre, los créditos requeridos para graduarse, el tipo de subgrado completado, el GPA obtenido en el programa subuniversitario, el tipo de institución previa, el GPA actual en la universidad y el resultado del examen público de inglés. A partir de estos datos, el estudio encontró que el puntaje de inglés en el examen público, el GPA actual, el GPA de graduación del subgrado y la carga académica son factores importantes para predecir el éxito en los cursos de lengua.

El uso de un **árbol de clasificación** constituye otro aporte importante del artículo. Esta técnica permite construir un modelo comprensible para identificar estudiantes con riesgo de bajo desempeño. A diferencia de otros modelos estadísticos más difíciles de interpretar, el árbol de clasificación muestra reglas claras que pueden ser entendidas por docentes, administradores y responsables de apoyo académico. Por ejemplo, el estudio evidencia que si un estudiante no alcanza determinado nivel en el examen público de inglés, puede ser clasificado rápidamente como estudiante en riesgo. Esto facilita que la universidad identifique a quienes necesitan apoyo antes de que el problema se agrave.

El modelo de clasificación logró una precisión aproximada de **70.94 %**, lo cual los autores consideran comparable con estudios previos sobre predicción del éxito de estudiantes transferidos. Además, un aspecto importante es que el modelo tuvo un porcentaje relativamente bajo de estudiantes en riesgo clasificados erróneamente como satisfactorios. Esto es relevante porque, desde una perspectiva de apoyo educativo, es preferible ofrecer ayuda adicional a estudiantes que quizá no la necesiten tanto, antes que dejar sin apoyo a estudiantes que realmente están en riesgo.

Otro aporte significativo se encuentra en la comparación entre estudiantes transferidos y estudiantes de ingreso directo. Los autores analizaron el rendimiento en cinco áreas: desarrollo de contenido, organización, lenguaje y vocabulario, habilidades de presentación y referencias. Los resultados mostraron que los estudiantes transferidos tuvieron un rendimiento inferior en todas las áreas, con diferencias estadísticamente significativas. Sin embargo, las mayores diferencias aparecieron en **lenguaje y vocabulario** y **habilidades de presentación**. Este hallazgo permite precisar mejor qué tipo de apoyo lingüístico necesitan.

Este aporte es importante porque ayuda a cuestionar la idea de que los estudiantes transferidos solo necesitan apoyo en escritura académica o citación de fuentes. El estudio demuestra que también requieren fortalecimiento en habilidades lingüísticas generales. Esto puede explicarse

porque, en Hong Kong, los requisitos de inglés para ingresar a programas subuniversitarios pueden ser menores que los requisitos para ingresar directamente a la universidad. Por ello, aunque los estudiantes hayan avanzado en habilidades académicas durante su subgrado, no necesariamente han desarrollado el mismo nivel de competencia general en inglés que sus compañeros de ingreso directo.

El artículo también aporta recomendaciones concretas. Una de ellas es implementar programas de apoyo lingüístico **antes del inicio del semestre**, para que los estudiantes transferidos puedan reforzar su inglés sin añadir más presión durante un periodo académico ya cargado. Esta propuesta es pertinente porque el estudio muestra que la carga de cursos influye en el desempeño. Si el apoyo se ofrece dentro del semestre como una obligación adicional, podría aumentar la presión en lugar de reducirla.

Otra recomendación importante es agrupar a estudiantes transferidos en secciones específicas de cursos de lengua. Esto no significa reducir los estándares académicos, sino ofrecer una enseñanza más ajustada a sus necesidades. En estas secciones, los docentes podrían brindar mayor retroalimentación sobre gramática, vocabulario, expresión oral y presentación académica. Esta medida permitiría mantener los mismos resultados de aprendizaje, pero con estrategias pedagógicas más adecuadas para un grupo con trayectoria diferente.

Los autores también aportan una reflexión institucional sobre la necesidad de mejorar la comunicación entre community colleges y universidades. Si las instituciones coordinan mejor los resultados de aprendizaje y los sistemas de transferencia de créditos, los estudiantes podrían evitar cargas académicas excesivas. Esto tendría un impacto indirecto en su rendimiento lingüístico, porque una menor sobrecarga permitiría dedicar más tiempo y energía a cursos de lengua y adaptación universitaria.

Finalmente, el aporte general del artículo está en mostrar que **Learning Analytics puede servir para promover la equidad educativa**. Los datos no se usan únicamente para medir rendimiento, sino para identificar barreras, reconocer necesidades específicas y proponer apoyos institucionales. El estudio demuestra que los estudiantes transferidos no deben ser vistos desde una lógica de déficit, sino desde una comprensión más amplia de sus trayectorias. Sus dificultades lingüísticas y académicas están relacionadas con factores previos, institucionales y curriculares. Por ello, la investigación es valiosa porque ofrece evidencia para que las universidades diseñen intervenciones más justas, oportunas y centradas en las necesidades reales de los estudiantes transferidos.

Proceso para obtener el aporte

El proceso seguido por los autores para obtener su aporte se basó en el uso de **Learning Analytics** con énfasis en la analítica académica, es decir, en el análisis de perfiles estudiantiles y datos institucionales para comprender el desempeño de los estudiantes transferidos en cursos de lengua. En primer lugar, los autores identificaron una problemática concreta: aunque la vía de transferencia permite ampliar el acceso a la universidad, los estudiantes que siguen esta trayectoria pueden enfrentar dificultades específicas relacionadas con carga académica, reconocimiento de créditos, adaptación universitaria y dominio del inglés. Por ello, el estudio buscó analizar, con datos reales, qué factores predicen el éxito de estos estudiantes en cursos de comunicación lingüística.

Para desarrollar la investigación, los autores recuperaron información de sistemas oficiales de la universidad. El primer conjunto de datos provino del **registro académico**, donde se identificaron estudiantes transferidos que habían cursado asignaturas de comunicación lingüística durante los dos años académicos previos. Este registro incluía información como ID estudiantil anonimizado, código del curso, nota del curso, GPA actual, programa de estudio, créditos requeridos para graduarse, tipo de subgrado completado, institución de procedencia,

GPA de graduación del subgrado y resultado del examen público de inglés. El segundo conjunto de datos provino del **Learning Management System**, lo que permitió obtener las calificaciones de otros estudiantes que cursaron las mismas asignaturas y comparar el rendimiento de los estudiantes transferidos con el promedio de sus cohortes .

Luego, los autores definieron la muestra principal del estudio. Esta estuvo conformada por **706 estudiantes transferidos** de Hong Kong que debían cursar al menos una asignatura de comunicación lingüística en la universidad. Dentro de este grupo, algunos habían completado un grado asociado y otros un diploma superior. Es importante señalar que el estudio solo incluyó a los estudiantes transferidos que tenían obligación de cursar al menos una asignatura de lengua; por tanto, quienes fueron exonerados de estos cursos no formaron parte de la muestra analizada.

Posteriormente, se realizó el procesamiento y organización de los datos. Para responder la primera pregunta de investigación, los autores reorganizaron la base de datos de modo que cada fila representara a un estudiante. A partir de la nota final del curso de lengua, construyeron una variable binaria llamada **riesgo**, donde los estudiantes con notas de F a C+ fueron clasificados como de desempeño en riesgo, mientras que los estudiantes con notas de B a A+ fueron considerados con desempeño satisfactorio. Además, se incorporaron variables predictoras como carga académica del semestre, créditos requeridos para graduarse, GPA actual, resultado del examen público de inglés, GPA de graduación del subgrado, tipo de institución previa y tipo de subgrado completado.

Después, para identificar los factores críticos que explicaban el éxito o riesgo en el curso de lengua, los autores aplicaron un **árbol de clasificación**. Esta técnica fue elegida porque permite producir reglas claras y fáciles de interpretar para diferentes actores universitarios. El modelo permitió observar qué variables eran más decisivas para clasificar a los estudiantes como satisfactorios o en riesgo, destacando especialmente el resultado del examen público de inglés, el GPA del subgrado, el GPA actual, los créditos requeridos para graduarse y la carga académica del semestre.

Finalmente, para responder la segunda pregunta de investigación, los autores compararon el desempeño de los estudiantes transferidos con el promedio de sus compañeros de ingreso directo en cinco áreas: desarrollo de contenido, organización, lenguaje y vocabulario, habilidades de presentación y referencias. Para ello, aplicaron pruebas **t de muestras pareadas** y corrección de Bonferroni, con el fin de evitar errores por múltiples comparaciones. Así, el aporte fue obtenido mediante un proceso ordenado que combinó datos institucionales, análisis predictivo e interpretación comparativa, permitiendo identificar necesidades lingüísticas específicas y proponer medidas de apoyo más equitativas para estudiantes transferidos.

Proceso para resolver el problema

El proceso para resolver el problema planteado en el artículo parte de una preocupación central: los estudiantes transferidos acceden a la universidad mediante una trayectoria alternativa, pero ese acceso no siempre garantiza una experiencia equitativa. Estos estudiantes pueden enfrentar dificultades relacionadas con la carga académica, la pérdida o no reconocimiento de créditos, la adaptación al nuevo contexto universitario y el dominio del inglés académico. Frente a esta situación, los autores proponen utilizar **Learning Analytics** para identificar, con datos reales, qué factores influyen en el éxito de los estudiantes transferidos en cursos de lengua y cómo su desempeño se diferencia del de los estudiantes de ingreso directo.

Primero, los autores recopilan información institucional de dos fuentes principales: el **registro académico universitario** y el **sistema de gestión del aprendizaje**. Del registro académico obtienen datos de los estudiantes transferidos, como curso matriculado, nota del curso, GPA actual, programa de estudio, créditos requeridos para graduarse, tipo de subgrado, institución de procedencia, GPA de graduación del subgrado y resultado del examen público de inglés. Del

sistema de gestión del aprendizaje recuperan las calificaciones de todos los estudiantes que cursaron las mismas asignaturas, lo cual permite comparar el rendimiento de los transferidos con el promedio de sus cohortes .

Luego, los autores procesan los datos para convertirlos en variables útiles para el análisis. Para identificar estudiantes en riesgo, transforman la nota final del curso de lengua en una variable binaria: los estudiantes con notas entre F y C+ son clasificados como de **desempeño en riesgo**, mientras que quienes obtienen de B a A+ son considerados de **desempeño satisfactorio**. Además, organizan variables predictoras relacionadas con la carga académica, créditos requeridos para graduarse, GPA actual, resultado del examen público de inglés, GPA del subgrado, tipo de institución previa y tipo de subgrado completado.

Después, aplican un **árbol de clasificación** para determinar qué factores predicen mejor el éxito en los cursos de lengua. Esta técnica permite generar reglas interpretables para docentes y autoridades universitarias. Los resultados muestran que el puntaje del examen público de inglés, el GPA de graduación del subgrado, el GPA actual, los créditos requeridos para graduarse y la carga académica son factores relevantes. Así, el problema comienza a resolverse porque la universidad puede identificar tempranamente a estudiantes con mayor riesgo y no esperar hasta que fallen el curso.

Posteriormente, los autores comparan el rendimiento de los estudiantes transferidos con el de los estudiantes de ingreso directo mediante pruebas estadísticas. Analizan cinco dimensiones: desarrollo de contenido, organización, lenguaje y vocabulario, habilidades de presentación y referencias. Los resultados muestran que los estudiantes transferidos obtienen puntuaciones más bajas en todas las áreas, especialmente en lenguaje, vocabulario y presentación oral. Esto permite precisar qué tipo de apoyo necesitan y evita asumir que todos sus problemas se relacionan únicamente con escritura académica.

Finalmente, el artículo propone soluciones orientadas a la equidad: programas de apoyo lingüístico antes del inicio del semestre, secciones específicas de cursos de lengua para estudiantes transferidos, mejor coordinación entre instituciones para facilitar la transferencia de créditos y dashboards inteligentes que ayuden a planificar la carga académica. De esta manera, el problema se resuelve conectando datos institucionales, análisis predictivo y acciones de apoyo concretas para mejorar la accesibilidad y el éxito académico de los estudiantes transferidos.

Métricas y resultados

En el artículo, las métricas principales se organizaron en dos niveles de análisis. Primero, los autores evaluaron la capacidad del **árbol de clasificación** para predecir si los estudiantes transferidos tendrían un desempeño en riesgo o satisfactorio en cursos de lengua. Para ello, dividieron los datos en un conjunto de entrenamiento del **70 %** y un conjunto de prueba del **30 %**. El modelo alcanzó una precisión de **70.94 %**, considerada aceptable y comparable con estudios previos sobre predicción del éxito académico de estudiantes transferidos.

Los resultados del árbol de clasificación mostraron que los factores más importantes para predecir el éxito en cursos de lengua fueron el **resultado del examen público de inglés**, el **GPA de graduación del subgrado**, el **GPA actual en la universidad**, los **créditos requeridos para graduarse** y la **carga académica del semestre**. Un hallazgo relevante fue que los estudiantes con bajo resultado en el examen público de inglés eran clasificados rápidamente como estudiantes en riesgo, lo que evidencia la importancia de la competencia lingüística previa.

En el segundo nivel, los autores compararon el rendimiento de los estudiantes transferidos con el promedio de sus cohortes mediante pruebas **t de muestras pareadas**. Los resultados

indicaron que los estudiantes transferidos obtuvieron puntuaciones más bajas en las cinco áreas evaluadas: desarrollo de contenido, organización, lenguaje y vocabulario, habilidades de presentación y referencias. Todas las diferencias fueron estadísticamente significativas ($p < 0.01$). Las mayores brechas aparecieron en **lenguaje y vocabulario** con un tamaño de efecto de $d = 0.35$, y en **habilidades de presentación** con $d = 0.25$. Estos resultados confirman que los estudiantes transferidos necesitan apoyo específico en competencia lingüística general y expresión oral académica.

Observaciones/críticas

Una observación importante sobre el artículo es que presenta un aporte valioso al utilizar **Learning Analytics** para analizar las necesidades reales de los estudiantes transferidos en cursos de lengua. Su principal fortaleza está en que no se limita a describir dificultades generales, sino que identifica factores concretos asociados al riesgo académico, como el resultado del examen público de inglés, el GPA del subgrado, el GPA actual, los créditos requeridos para graduarse y la carga académica. Esto permite que la universidad diseñe apoyos más precisos y no trate a todos los estudiantes transferidos como un grupo homogéneo.

Sin embargo, una crítica relevante es que el estudio se concentra principalmente en variables institucionales y académicas, pero no incorpora factores cualitativos como motivación, ansiedad lingüística, estrategias de estudio, percepción de apoyo docente o experiencias personales durante la transición universitaria. Los propios autores reconocen que aspectos como las actitudes hacia el aprendizaje de lenguas, el proceso de aprendizaje y el diseño curricular no fueron considerados, aunque también pueden influir en el éxito de los estudiantes en cursos de inglés.

Otra limitación es que la muestra corresponde a estudiantes transferidos de una universidad en Hong Kong y a cursos de lengua específicos, por lo que los resultados no necesariamente pueden generalizarse a otros países, instituciones o áreas académicas. Además, el estudio solo incluye a estudiantes transferidos que debían cursar asignaturas de lengua; aquellos exonerados quedaron fuera del análisis.

A pesar de estas limitaciones, el artículo es sólido porque demuestra que el acceso a la universidad no garantiza por sí solo equidad. Su mayor aporte está en mostrar que los datos institucionales pueden ayudar a identificar barreras específicas y orientar medidas de apoyo más justas para estudiantes con trayectorias educativas diferentes.

40. ARTÍCULO 40

Author (s): Roberto Bertolini; Stephen J. Finch; Ross H. Nehm

Title of paper: Enhancing data pipelines for forecasting student performance: integrating feature selection with cross-validation

Journal: International Journal of Educational Technology in Higher Education

Volume (issue): Volume 18, Article 44

pag – pag (year): pp. 1–23 (2021)

Estado del arte

La minería de datos educativos —**Educational Data Mining, EDM**— se ha consolidado como un campo de investigación orientado a analizar grandes volúmenes de información académica con el propósito de mejorar la toma de decisiones en las instituciones educativas. En educación superior, una de sus aplicaciones más importantes es la predicción del rendimiento estudiantil, especialmente para identificar estudiantes con riesgo de bajo desempeño, desaprobación, abandono o retraso en su trayectoria académica. A partir de datos institucionales, registros de cursos, características académicas previas y actividad en plataformas digitales, los

investigadores construyen modelos predictivos que permiten anticipar resultados y diseñar intervenciones educativas más oportunas.

Dentro de este campo, los **pipelines de datos** cumplen un papel fundamental. Un pipeline es una secuencia organizada de pasos que permite reunir, limpiar, transformar, modelar, evaluar e interpretar datos. En educación, estos procesos se utilizan para desarrollar sistemas de alerta temprana, modelos de predicción de desempeño y herramientas de apoyo para docentes y autoridades. Normalmente, un pipeline educativo incluye la integración de datos universitarios y del curso, la partición de los datos en entrenamiento y prueba, el preprocesamiento, la imputación de valores faltantes, el entrenamiento de modelos de minería de datos y la evaluación de resultados. Sin embargo, la calidad del pipeline depende no solo del algoritmo utilizado, sino también de la selección adecuada de variables o características.

La literatura previa ha demostrado que diferentes métodos de minería de datos pueden predecir el éxito estudiantil con niveles aceptables de precisión. Entre los algoritmos más usados se encuentran la regresión logística, random forest, redes neuronales, árboles de decisión, modelos de boosting y técnicas de regularización. No obstante, muchos estudios se han centrado principalmente en comparar el rendimiento de los algoritmos, dejando en segundo plano un problema clave: **qué variables deben utilizarse antes de construir el modelo**. En grandes bases educativas, no todas las características disponibles aportan información relevante. Algunas variables pueden ser redundantes, irrelevantes o incluso introducir ruido, lo cual puede afectar la precisión del modelo y dificultar su interpretación.

En este sentido, la **selección de características** se ha convertido en una etapa importante dentro de los estudios de EDM. Su objetivo es identificar un subconjunto de variables relevantes para predecir el resultado de interés, como aprobar o desaprobado un curso. Esta selección puede reducir la complejidad del modelo, disminuir la cantidad de datos que deben gestionar las instituciones y facilitar que docentes y responsables académicos comprendan los factores asociados al rendimiento. Además, al trabajar con menos variables, los modelos denominados “caja negra” pueden volverse más interpretables, permitiendo convertir los resultados predictivos en acciones pedagógicas concretas.

Sin embargo, el estado del arte también muestra limitaciones en la forma en que se ha aplicado la selección de características. Algunos estudios utilizan una sola técnica de selección, mientras que otros aplican varias, pero no siempre evalúan si las variables seleccionadas son estables en distintos subconjuntos de datos. Esto es un problema importante, porque si una técnica selecciona variables muy diferentes cada vez que se modifica la muestra de entrenamiento, el modelo puede ser poco confiable y difícil de aplicar en contextos reales. Además, en muchos estudios la selección de variables se realiza antes o después del entrenamiento sin integrarse de manera sistemática con la validación cruzada, lo que limita la evaluación rigurosa del proceso.

El artículo analizado se ubica precisamente en esta brecha de investigación. Los autores proponen mejorar los pipelines de predicción del rendimiento estudiantil integrando la **selección de características con la validación cruzada**. Esta integración permite evaluar la relevancia de las variables dentro de cada subconjunto de entrenamiento y luego construir un ranking consensuado de características importantes mediante el **método de Borda**. La idea central es que las variables más relevantes sean aquellas que aparecen consistentemente como importantes en distintos pliegues de la validación cruzada. De esta manera, el pipeline no solo busca mejorar la precisión predictiva, sino también aumentar la estabilidad, interpretabilidad y utilidad práctica del modelo.

Para aplicar su propuesta, los autores trabajan con datos de **3225 estudiantes** de un curso introductorio de biología en una universidad pública de investigación en Estados Unidos. El conjunto de datos incluyó **57 características** relacionadas con información demográfica, datos preuniversitarios, características académicas universitarias, accesos al LMS, ayuda financiera

y variables específicas del curso. Además, el desempeño se formuló como una clasificación binaria: estudiantes que aprobaban y estudiantes que no aprobaban el curso. Este enfoque responde a una preocupación frecuente en educación superior: identificar factores que afectan el rendimiento en cursos introductorios, especialmente aquellos que funcionan como asignaturas críticas para la continuidad académica.

El estudio también se relaciona con una tendencia actual en EDM: construir modelos que no solo sean precisos, sino también **accionables**. Para los docentes y autoridades, no basta con saber que un estudiante está en riesgo; también necesitan comprender qué factores explican ese riesgo. Si el modelo identifica que el GPA, los créditos matriculados o el desempeño en evaluaciones conceptuales son variables importantes, entonces la institución puede diseñar estrategias más específicas, como tutorías académicas, orientación sobre carga académica o refuerzo en conceptos clave del curso. En este sentido, la interpretabilidad se convierte en una condición necesaria para que la predicción pueda transformarse en intervención educativa.

En síntesis, el estado del arte muestra que la predicción del rendimiento estudiantil ha avanzado gracias al uso de modelos de minería de datos y pipelines educativos. No obstante, persisten desafíos relacionados con la selección de variables, la estabilidad de los predictores, la interpretabilidad de los modelos y la utilidad práctica para docentes y stakeholders. El artículo contribuye a este campo al proponer un pipeline modificado que integra selección de características, validación cruzada y ranking consensuado, ofreciendo una metodología más estable, comprensible y orientada a intervenciones educativas basadas en evidencia.

Motivación del autor

La motivación principal de los autores surge de la necesidad de mejorar los **pipelines de datos educativos** utilizados para predecir el rendimiento estudiantil. Aunque muchos estudios de minería de datos educativos han comparado algoritmos para anticipar el éxito o fracaso académico, los autores observan que se ha prestado menos atención a la selección previa de variables relevantes. Este punto es importante porque los modelos predictivos pueden trabajar con grandes cantidades de datos, pero no todas las características aportan información útil. Algunas pueden ser redundantes, poco interpretables o generar ruido, dificultando que docentes y autoridades comprendan qué factores influyen realmente en el desempeño del estudiante.

Por esta razón, los autores buscan integrar la **selección de características** con la **validación cruzada**, para construir modelos más estables, interpretables y útiles en la práctica educativa. Su motivación no es solo aumentar la precisión predictiva, sino también identificar un conjunto reducido de variables que permita a los docentes tomar decisiones concretas. Al detectar factores como el promedio académico, la carga de créditos o el desempeño en evaluaciones conceptuales, las instituciones pueden diseñar intervenciones más focalizadas. En ese sentido, el estudio pretende que los modelos de predicción no funcionen como “cajas negras”, sino como herramientas comprensibles y accionables para mejorar el rendimiento de los estudiantes universitarios.

Descripción del aporte del autor

El principal aporte de Bertolini, Finch y Nehm consiste en proponer una metodología para mejorar los **pipelines de datos educativos** utilizados en la predicción del rendimiento estudiantil, integrando la **selección de características** con la **validación cruzada**. El estudio se ubica dentro del campo de la **minería de datos educativos —Educational Data Mining, EDM—**, cuyo objetivo es analizar grandes conjuntos de datos académicos para anticipar resultados como aprobación, desaprobación, retención o abandono. Sin embargo, los autores señalan que gran parte de la investigación previa se ha centrado en comparar algoritmos predictivos, dejando menos atendida una etapa clave: determinar qué variables son realmente relevantes antes de construir el modelo. Por ello, su aporte busca mejorar no solo la precisión

de las predicciones, sino también la interpretabilidad y utilidad práctica de los modelos para docentes, administradores y otros actores educativos.

Uno de los aportes más importantes del artículo es que propone una modificación al pipeline tradicional de ciencia de datos. Normalmente, un pipeline educativo incluye pasos como integración de datos, limpieza, imputación, transformación, entrenamiento del modelo y evaluación. Sin embargo, los autores sostienen que la **selección de características** debe ocupar un lugar más estratégico dentro del proceso, porque no todas las variables disponibles en una base de datos aportan información útil para predecir el rendimiento. Algunas características pueden ser irrelevantes, redundantes o introducir ruido en el modelo. Cuando se trabaja con demasiadas variables, el modelo puede volverse más complejo, menos interpretable y más difícil de traducir en acciones educativas concretas.

El aporte metodológico del estudio consiste en integrar la selección de características dentro de la etapa de **validación cruzada**. La validación cruzada se utiliza para entrenar y evaluar modelos en distintos subconjuntos de datos, reduciendo el riesgo de sobreajuste y mejorando la capacidad de generalización. Los autores aprovechan esta etapa para aplicar técnicas de selección de características en cada pliegue del entrenamiento. De esta forma, las variables no se seleccionan una sola vez sobre todo el conjunto de datos, sino que se evalúan repetidamente en diferentes particiones. Esto permite observar cuáles características aparecen de manera consistente como importantes, aumentando la confianza en que realmente están asociadas con el rendimiento estudiantil.

Otro aporte relevante es el uso del **método de Borda** como estrategia de ranking consensuado. En cada pliegue de la validación cruzada, las técnicas de selección de características ordenan las variables según su importancia. Luego, el método de Borda suma y organiza esas posiciones para obtener un ranking final. Las variables con mejor posición promedio son consideradas más relevantes. Este procedimiento permite resolver un problema frecuente en EDM: distintas particiones de datos o distintas técnicas pueden producir rankings diferentes. Al aplicar un sistema de consenso, los autores logran identificar un conjunto más estable de predictores. Esto ayuda a que el pipeline sea más confiable y menos dependiente de una sola muestra o ejecución.

El estudio también aporta una evaluación comparativa de técnicas de selección de características. Los autores analizan cuatro métodos de filtro: **Correlation Attribute Evaluation —CAE—**, **Fisher's Scoring Algorithm —FSA—**, **Information Gain —IG—** y **Relief Attribute Evaluation —RAE—**. Estas técnicas se aplican antes del entrenamiento del modelo, con el objetivo de seleccionar variables relevantes de manera independiente del algoritmo predictivo. La ventaja de los métodos de filtro es que pueden utilizarse con distintos modelos de minería de datos y facilitan la construcción de pipelines más simples e interpretables. Esta comparación permite conocer qué técnicas funcionan mejor en el contexto de predicción del rendimiento en un curso universitario de biología.

Además, el artículo aporta una comparación entre diferentes métodos de minería de datos. Los autores utilizan **regresión logística —LR—**, **elastic net regression —GLMNET—**, **random forest —RF—** y **extreme gradient boosting —XGBoost—**. Estos modelos representan enfoques distintos, desde métodos más interpretables como la regresión logística hasta modelos más complejos o de tipo ensamble. Al combinar distintas técnicas de selección con distintos algoritmos, el estudio permite observar cómo la selección de variables afecta la eficacia predictiva de cada método. Este aporte es importante porque no asume que un único modelo sea siempre superior, sino que evalúa el desempeño del pipeline completo.

El contexto empírico del estudio también constituye un aporte relevante. Los autores aplican su metodología a la predicción del rendimiento de **3225 estudiantes** matriculados en un curso introductorio de biología en una universidad pública de investigación en Estados Unidos. El conjunto de datos incluyó **57 características**, agrupadas en información demográfica, datos

preuniversitarios, características académicas universitarias, accesos al LMS, métricas de ayuda financiera y variables específicas del curso. El resultado a predecir fue el rendimiento final del estudiante, clasificado como aprobación o desaprobación. Este contexto resulta importante porque los cursos introductorios de ciencias suelen ser asignaturas críticas, donde el bajo rendimiento puede afectar la continuidad académica, especialmente en estudiantes de grupos subrepresentados o de primera generación universitaria.

Un aporte práctico del artículo es que muestra cómo los modelos predictivos pueden volverse más **accionables** para los docentes. Si un modelo utiliza muchas variables y funciona como una “caja negra”, puede ofrecer una predicción, pero no necesariamente ayuda a entender qué hacer con ella. En cambio, al seleccionar un conjunto reducido de características, los docentes pueden identificar factores concretos asociados con el desempeño. Por ejemplo, el estudio encontró que variables como el **promedio académico universitario —GPA—**, el **GPA de secundaria**, el **número de créditos cursados** y el desempeño en evaluaciones conceptuales fueron predictores importantes. Esta información puede orientar intervenciones más específicas, como apoyo académico temprano, orientación sobre carga de cursos, tutorías o refuerzo en conceptos fundamentales.

El artículo también aporta evidencia sobre la estabilidad de las técnicas de selección. No basta con que una técnica seleccione variables aparentemente importantes; también es necesario que esas variables sean consistentes en diferentes subconjuntos de datos. Para evaluar esto, los autores utilizan una métrica de estabilidad denominada **SC metric**, que permite medir si los métodos seleccionan conjuntos similares de características en los distintos pliegues de validación cruzada. Los resultados muestran que **CAE** y **FSA** fueron las técnicas más estables, mientras que **RAE** presentó alta inestabilidad. Este hallazgo es importante porque una técnica inestable puede producir modelos poco confiables y dificultar la interpretación pedagógica de los resultados.

Otro aporte importante es que el estudio demuestra que la selección de características puede mejorar la eficacia predictiva en determinados modelos. Según los resultados, las técnicas **CAE** y **FSA** incrementaron significativamente el AUC en modelos como la regresión logística y GLMNET. En particular, la regresión logística se benefició considerablemente de la reducción de variables, llegando a obtener resultados comparables con modelos más complejos. Esto es relevante porque la regresión logística suele ser más interpretable para docentes y administradores que modelos tipo caja negra. Por tanto, una buena selección de características puede permitir utilizar modelos más simples sin sacrificar demasiado rendimiento.

Sin embargo, el artículo también muestra que la selección de características no siempre mejora todos los modelos. En el caso de **random forest** y **XGBoost**, la reducción a seis características no produjo mejoras generales e incluso redujo el desempeño en algunos escenarios. Este resultado es valioso porque evita una conclusión simplista. La selección de variables puede ser beneficiosa, pero su impacto depende del algoritmo, del tipo de datos y del contexto. De esta manera, los autores aportan una visión equilibrada: no presentan la selección de características como una solución universal, sino como una estrategia que debe evaluarse cuidadosamente dentro de cada pipeline.

El estudio también aporta una mirada temporal al proceso predictivo. Los autores construyen modelos en distintos momentos del curso: antes del inicio, en la semana 3, en la semana 6 y en la semana 9. Esto permite observar cómo cambian los predictores a medida que se acumula más información. Antes del curso, predominan variables académicas previas, como GPA y evaluaciones conceptuales. En semanas intermedias, aparecen variables como créditos matriculados o registros de acceso. En la semana 9, la primera calificación de examen se convierte en un predictor altamente relevante del resultado final. Esta organización temporal permite que las instituciones comprendan qué información es útil en cada etapa y cómo pueden intervenir de manera más oportuna.

Desde el punto de vista educativo, el aporte del artículo se relaciona con la posibilidad de construir **sistemas de alerta temprana más interpretables**. Un sistema de alerta temprana no debe limitarse a decir que un estudiante está en riesgo; también debe ofrecer pistas sobre los factores que explican ese riesgo. Si los predictores más importantes son académicos, las intervenciones pueden centrarse en tutorías, actividades de refuerzo o acompañamiento en contenidos. Si están relacionados con carga académica, se pueden diseñar orientaciones sobre planificación de cursos. Si aparecen indicadores de uso de plataformas, se puede promover mayor participación en recursos digitales. Así, el pipeline propuesto permite conectar la predicción con decisiones educativas más claras.

Otro aporte destacable es que la metodología reduce la carga de gestión de datos para las instituciones. En educación superior, los datos suelen estar dispersos en distintas fuentes: sistemas administrativos, registros académicos, LMS, ayudas financieras y bases de datos específicas de cursos. Gestionar demasiadas variables puede ser costoso y complejo. Al identificar un subconjunto reducido y estable de características, el pipeline facilita que las instituciones trabajen con información más manejable, sin perder necesariamente capacidad predictiva. Esto es especialmente útil para docentes y gestores que necesitan herramientas prácticas, no solo modelos técnicamente sofisticados.

El artículo también contribuye al debate sobre la interpretabilidad de los modelos de machine learning en educación. En contextos educativos, la interpretabilidad es fundamental porque las predicciones afectan decisiones sobre estudiantes reales. Un modelo difícil de explicar puede generar desconfianza o conducir a intervenciones poco claras. Al seleccionar variables antes del entrenamiento, los autores hacen que incluso modelos complejos puedan entenderse mejor, porque se conoce qué características principales ingresan al proceso. Esto ayuda a comunicar los resultados a docentes, asesores académicos y autoridades, favoreciendo el uso responsable de la analítica educativa.

Asimismo, el aporte tiene una dimensión ética y pedagógica. Al identificar factores académicos y de curso como predictores más relevantes que muchas variables demográficas, el estudio sugiere que las intervenciones deberían centrarse en aspectos modificables del aprendizaje y la trayectoria académica, no en etiquetar a estudiantes por características personales. Esto es importante porque los modelos predictivos pueden generar riesgos si se usan para estigmatizar. En cambio, cuando se orientan hacia variables accionables, pueden apoyar una toma de decisiones más justa y útil.

En conclusión, el aporte de Bertolini, Finch y Nehm se resume en la propuesta de un pipeline de datos educativos más estable, interpretable y accionable. Su principal innovación es integrar la selección de características con la validación cruzada y utilizar el método de Borda para construir rankings consensuados de variables importantes. Esta metodología permite mejorar el desempeño de algunos modelos, identificar predictores consistentes y ofrecer información comprensible para docentes y stakeholders. El valor del estudio está en demostrar que la predicción del rendimiento estudiantil no debe depender únicamente de algoritmos más complejos, sino de procesos bien diseñados que seleccionen variables relevantes, reduzcan el ruido, faciliten la interpretación y orienten intervenciones educativas concretas para mejorar el éxito académico.

Proceso para obtener el aporte

Para obtener su aporte, los autores desarrollaron un proceso metodológico orientado a mejorar los **pipelines de predicción del rendimiento estudiantil** mediante la integración de la **selección de características** con la **validación cruzada**. El objetivo fue construir un procedimiento más estable, interpretable y útil para docentes y responsables académicos, evitando que los modelos predictivos dependan de demasiadas variables irrelevantes o difíciles de interpretar. Para ello, aplicaron su propuesta en un curso introductorio de biología de una

universidad pública de investigación en Estados Unidos, utilizando datos de **3225 estudiantes** matriculados entre otoño de 2014 y primavera de 2017. El resultado a predecir fue si el estudiante aprobaría o desaprobaba el curso, considerando como desaprobación las notas de **D+ o inferiores** y como aprobación las notas de **C- o superiores**.

El primer paso consistió en la **integración de datos universitarios y datos específicos del curso**. Los autores reunieron un conjunto de **57 características** provenientes de distintas fuentes institucionales. Estas variables incluían datos demográficos, información preuniversitaria, características académicas universitarias, registros de acceso al LMS, métricas de ayuda financiera y datos propios del curso de biología, como resultados en evaluaciones conceptuales. Esta etapa fue importante porque permitió construir una base amplia para analizar qué factores podían estar relacionados con el desempeño final del estudiante.

El segundo paso fue el **preprocesamiento de los datos**. Los autores transformaron variables categóricas en variables indicadoras, imputaron datos faltantes mediante la técnica **MICE**, estandarizaron las variables usando puntuaciones z y aplicaron **SMOTE** para corregir el desbalance entre estudiantes aprobados y desaprobados. Este procedimiento fue necesario porque, en el conjunto total, la mayoría de estudiantes aprobó el curso, mientras que el grupo de desaprobados fue menor. Si este desbalance no se corregía, los modelos podían favorecer la clase mayoritaria y reducir su capacidad para identificar correctamente a estudiantes con bajo desempeño.

El tercer paso consistió en aplicar la **selección de características durante la validación cruzada de diez pliegues**. En cada pliegue, los autores usaron técnicas de filtro para ordenar las variables según su relación con el resultado académico. Las técnicas evaluadas fueron **Correlation Attribute Evaluation —CAE—**, **Fisher's Scoring Algorithm —FSA—**, **Information Gain —IG—** y **Relief Attribute Evaluation —RAE—**. Luego, para obtener un ranking final más estable, aplicaron el **método de Borda**, que suma las posiciones obtenidas por cada variable en los distintos pliegues. De esta manera, las características más importantes fueron aquellas que aparecieron de forma consistente en los primeros lugares.

El cuarto paso fue seleccionar un subconjunto reducido de variables. A partir de las **57 características iniciales**, los autores utilizaron un criterio basado en $\log_2(m)$, lo que llevó a escoger aproximadamente **seis predictores principales** para entrenar los modelos finales. Con esto buscaron reducir la complejidad del pipeline y facilitar la interpretación de los resultados. Después, entrenaron cuatro métodos de minería de datos: **regresión logística**, **elastic net regression —GLMNET—**, **random forest** y **XGBoost**. Estos modelos fueron evaluados en distintos momentos del curso: antes del inicio, en la semana 3, en la semana 6 y en la semana 9, incorporando progresivamente nuevas variables disponibles en cada etapa.

Finalmente, los autores evaluaron el desempeño del pipeline mediante el **AUC**, comparando los resultados con y sin selección de características. También midieron la estabilidad de las variables seleccionadas mediante la métrica **SC** y analizaron la similitud entre técnicas usando el **índice de Jaccard**. Este proceso permitió comprobar que **CAE** y **FSA** fueron técnicas más estables y útiles, mientras que **RAE** resultó menos confiable. Así, el aporte se obtuvo mediante un pipeline que integra datos institucionales, preprocesamiento, selección estable de características, validación cruzada, ranking consensuado y evaluación predictiva, logrando modelos más interpretables y accionables para apoyar intervenciones educativas.

Proceso para resolver el problema

Para resolver el problema de la predicción del rendimiento estudiantil de manera más interpretable y útil para la toma de decisiones educativas, los autores propusieron modificar el pipeline tradicional de minería de datos educativos. El problema central era que muchos modelos predictivos utilizan una gran cantidad de variables, lo que puede aumentar la

complejidad del sistema, reducir la interpretabilidad y dificultar que docentes y autoridades comprendan qué factores influyen realmente en el desempeño académico. Por ello, los autores plantearon integrar la **selección de características** con la **validación cruzada**, con el fin de identificar variables relevantes antes de entrenar los modelos finales.

El primer paso fue reunir datos institucionales y del curso de biología. Los autores trabajaron con información de **3225 estudiantes** y **57 características**, incluyendo datos demográficos, antecedentes académicos, ayuda financiera, accesos al LMS y variables específicas del curso. Luego, definieron el problema como una clasificación binaria: estudiantes que aprobaron el curso y estudiantes que no lo aprobaron. Esta formulación permitió aplicar métodos de minería de datos para anticipar el desempeño final.

Después, se realizó el preprocesamiento de los datos. Las variables categóricas fueron transformadas en indicadores, los valores faltantes fueron imputados mediante **MICE**, las variables fueron estandarizadas y se aplicó **SMOTE** para corregir el desbalance entre estudiantes aprobados y desaprobados. Este paso fue necesario para mejorar la calidad del conjunto de datos y evitar que los modelos favorecieran únicamente a la clase mayoritaria.

El tercer paso fue aplicar la selección de características dentro de una validación cruzada de diez pliegues. En cada pliegue, se utilizaron técnicas de filtro como **CAE**, **FSA**, **IG** y **RAE** para ordenar las variables según su importancia. Luego, mediante el **método de Borda**, se obtuvo un ranking consensuado de predictores. A partir de este ranking, se seleccionaron aproximadamente seis variables principales, reduciendo la complejidad del modelo y facilitando su interpretación.

Finalmente, los autores entrenaron y evaluaron distintos métodos de minería de datos, como **regresión logística**, **GLMNET**, **random forest** y **XGBoost**, en diferentes momentos del curso: antes del inicio, semana 3, semana 6 y semana 9. La solución permitió identificar predictores estables, como el promedio académico, créditos cursados y evaluaciones conceptuales, y demostró que algunas técnicas de selección, especialmente **CAE** y **FSA**, podían mejorar el desempeño predictivo en modelos como regresión logística y GLMNET. Así, el problema se resolvió mediante un pipeline más simple, estable, interpretable y orientado a intervenciones educativas concretas.

Métricas y resultados

Para evaluar el pipeline propuesto, los autores utilizaron principalmente la métrica **AUC** —**Area Under the Curve**—, con el fin de comparar el rendimiento predictivo de los modelos cuando se aplicaba selección de características y cuando esta etapa se omitía. También emplearon la métrica **SC** para medir la estabilidad de las características seleccionadas en los pliegues de validación cruzada, y el **índice de Jaccard** para analizar la similitud entre los conjuntos de variables identificados por distintas técnicas de selección. Los métodos de minería de datos evaluados fueron **regresión logística** —**LR**—, **elastic net regression** —**GLMNET**—, **random forest** —**RF**— y **XGBoost**, combinados con técnicas de selección como **CAE**, **FSA**, **IG** y **RAE**.

Los resultados mostraron que la selección de características mejoró especialmente el desempeño de **LR** y **GLMNET**. Las técnicas **FSA** y **CAE** incrementaron significativamente el AUC promedio, con mejoras de **0.058** y **0.040** puntos, respectivamente. En el caso de la regresión logística, los aumentos del AUC oscilaron aproximadamente entre **13.53%** y **44.77%**, alcanzando valores superiores a **0.90** en la semana 9 con CAE y FSA. Además, **CAE** y **FSA** fueron las técnicas más estables, con valores SC entre **0.87** y **1.00**, mientras que **RAE** fue la menos estable y obtuvo el peor rendimiento. Como predictores principales, el método de Borda identificó el **GPA universitario**, el **GPA de secundaria**, el **número de créditos cursados** y el desempeño en evaluaciones conceptuales. En conjunto, los resultados evidencian

que integrar selección de características con validación cruzada puede producir modelos más interpretables, estables y útiles para orientar intervenciones académicas.

Observaciones/críticas

Una observación positiva del artículo es que propone una mejora metodológica muy útil para la minería de datos educativos, ya que no se limita a comparar algoritmos predictivos, sino que atiende un aspecto clave del proceso: la **selección de características**. El trabajo resulta valioso porque busca que los modelos de predicción del rendimiento estudiantil sean más interpretables y accionables para docentes y autoridades. Al integrar la selección de variables con la validación cruzada y utilizar el método de Borda para obtener un ranking consensuado, los autores ofrecen una forma más estable de identificar los factores que realmente influyen en el desempeño académico.

Sin embargo, también existen algunas limitaciones. El estudio se aplicó únicamente a un curso introductorio de biología en una universidad específica, por lo que sus resultados no pueden generalizarse automáticamente a otras asignaturas, carreras o instituciones. Además, aunque la reducción a seis características mejora la interpretabilidad, puede dejar fuera variables importantes en algunos modelos, especialmente en algoritmos complejos como **Random Forest** y **XGBoost**, donde la selección de características no siempre mejoró el rendimiento. También se observa que el estudio no incluyó técnicas de reducción de dimensionalidad ni métodos wrapper o embedded, que podrían compararse en futuras investigaciones. A pesar de estas limitaciones, el artículo aporta una propuesta sólida porque demuestra que un pipeline bien diseñado puede mejorar la predicción, reducir la complejidad y facilitar intervenciones académicas más claras y basadas en evidencia.